

概率与数理统计讲义

唐聿劼

2026

本讲义仍处于草稿阶段

若发现讲义的任何错误, 或对讲义内容有任何意见与建议,
欢迎将其反馈给 yujietang@pku.edu.cn

目 录

第一部分 概率论	1
第一章 概率论的基本概念	2
1.1 随机试验	2
1.2 集合论回顾	4
1.3 样本空间、事件与概率	7
1.4 概率的基本性质	14
1.5 古典概型	18
1.6 条件概率的初步介绍	23
1.7 事件的独立性	32
1.8 (*) 概率的连续性	36
1.9 习题	37
第二章 离散型随机变量	44
2.1 随机变量的定义	44
2.2 离散型随机变量	47
2.3 离散型随机向量	53
2.4 随机变量的独立性	56
2.5 期望与方差	60
2.6 伯努利过程	67
2.7 习题	74

第三章 连续型随机变量	81
3.1 连续型随机变量	81
3.2 连续型随机向量	85
3.3 连续型随机变量的独立性	88
3.4 连续型随机变量的期望	93
3.5 一般随机变量与分布函数	96
3.6 一般随机变量的期望	104
3.7 习题	111
第四章 随机变量的深入内容	118
4.1 随机变量函数的分布	118
4.2 协方差与相关系数	127
4.3 矩与矩母函数	132
4.4 条件分布与条件期望	137
4.5 (*) 二维正态分布	149
4.6 习题	154
第五章 大数定律与中心极限定理	164
5.1 几乎必然收敛与依概率收敛	164
5.2 大数定律	165
5.3 中心极限定理	169
5.4 (*) 一些定理的证明	172
5.5 习题	176
第二部分 数理统计	182
第六章 数理统计的基本概念	183
6.1 总体、样本与统计量	183
6.2 重要抽样分布	185

6.3	(*) 相关定理的证明	194
6.4	习题	196
第七章	参数估计 I: 点估计	199
7.1	点估计问题	200
7.2	点估计方法的评价	201
7.3	矩估计与最大似然估计	207
7.4	贝叶斯参数估计方法简介	216
7.5	习题	219
第八章	参数估计 II: 区间估计	223
8.1	区间估计与置信区间	223
8.2	单个总体下的区间估计	228
8.3	两个总体下的区间估计	233
8.4	习题	237
第九章	假设检验	241
9.1	假设检验的问题设定与流程	241
9.2	假设检验的 Neyman–Pearson 理论简介	247
9.3	单个总体下的假设检验	255
9.4	两个总体下的假设检验	263
9.5	(*) 一些非参数检验问题	270
9.6	(*) Neyman–Pearson 引理	277
9.7	习题	280
第十章	一元线性回归	285
10.1	一元线性回归模型	285
10.2	未知参数的点估计	287
10.3	回归系数的区间估计与假设检验	295

10.4 因变量的点预测与区间预测	300
10.5 回归显著性检验	302
10.6 残差分析初步	304
10.7 习题	308
附录 A 一些数学上的补充说明	312
A.1 形如 $\sum_{x \in \mathcal{X}} f(x)$ 的求和式	312
A.2 Γ 函数以及涉及正态分布密度函数的积分	319
A.3 一些线性代数知识	321
附录 B (*) 一般情形的条件期望	324
B.1 一般情形条件期望的定义	325
B.2 条件期望的性质	328
B.3 条件期望的计算	330
附录 C (*) 假设检验的补充证明	332
C.1 p 值法与拒绝域法的等价性	332
C.2 显著性水平与第 I 类错误概率的关系	335
参考文献	338

第一部分

概率论

第一章 概率论的基本概念

1.1 随机试验

在现实生活中, 我们经常会遇到各种具有不确定性的现象, 这些现象的结果难以由已知的信息和条件确定下来. 产生不确定性的原因可以是多方面的, 例如我们可能缺乏足够的信息, 或是现象背后的物理机制过于复杂, 从而难以进行准确的预测; 又如现象背后的物理机制本身具有内在的不确定性, 使得我们从原理上就不可能得出确定的结论. 但对于某些不确定现象, 我们发现其背后具有一定的**统计规律性**. 具体而言, 这些具有统计规律性的不确定现象具有如下特点:

1. 一定程度的可重复性: 导致不确定现象的过程可以在 (近似) 相同的条件下被重复执行, 且下一次重复的过程可以认为不受到之前过程的影响.
2. 具备较为规律的 “平均行为”: 导致不确定现象的过程在被重复足够多的次数以后, 对所得到的结果进行统计, 会发现它们的 “平均行为” 具有收敛于一确定规律的趋势.

例 1.1. 考虑一悬浮在水中的花粉粒, 观察其在一段长度固定的时间 T 内的运动轨迹. 我们会发现, 花粉粒在这段时间内的轨迹难以预测, 却具有上述意义下的统计规律性:

1. 获得花粉粒轨迹的过程具有一定的可重复性: 我们固定温度、气压等环境因素, 并且每次在观测时间达到 T 之后, 将花粉移回至某个起始位置, 再经过足够长时间后, 重新进行持续时间为 T 的花粉粒轨迹观测, 则可以认为后一次的观测过程是对前一次观测的重复, 并且两次观测之间互相没有影响.
2. 对花粉粒的轨迹进行足够多次 (例如 N 次) 观测以后, 对每个 $k = 1, \dots, N$, 计算如下量:
 - 在第 k 次观测中, 若花粉在时间段 T 内的位移大小曾经超过 R , 则令 $\lambda_k = 1$,

否则令 $\lambda_k = 0$.

- 第 k 次观测中, 花粉在时间段 T 内的总位移 $\mathbf{r}_k$.
- 第 k 次观测中, 花粉在前 $T/2$ 的时间段内的位移 $\mathbf{p}_k$ 与后 $T/2$ 时间段内的位移 $\mathbf{q}_k$.
- 第 k 次观测中, 花粉的位移大小第一次大于 R 时所耗费的时间 τ_k (若花粉的位移大小始终小于 R , 则令 $\tau_k = T$).

我们发现, 如下平均量

$$\frac{1}{N} \sum_{k=1}^N \lambda_k, \quad \frac{1}{N} \sum_{k=1}^N \mathbf{r}_k, \quad \frac{1}{N} \sum_{k=1}^N |\mathbf{r}_k|^2, \quad \frac{1}{N} \sum_{k=1}^N \mathbf{p}_k \mathbf{q}_k^T, \quad \frac{1}{N} \sum_{k=1}^N \tau_k,$$

在 N 足够大时均有收敛于一个定值的趋势; 换句话说, 上述几个量所描述的花粉轨迹的“平均行为”存在规律性. ■

我们将那些具有统计规律性的不确定现象称为随机现象, 并用**随机试验**这一概念指代可以在相同的条件下重复进行的, 对随机现象进行实现与观察的理想化过程. 我们要求随机试验的所有可能结果是确定且已知的. 需要注意的是, 随机试验不仅可以代表现实世界中的试验, 还可以代表一些理想化的思想实验.

概率论就是在对随机现象与随机试验进行定量研究的过程当中, 逐步发展起来的数学理论. 大致说来, 对于一个随机试验, 概率论用如下方式对其进行数学建模:

1. 确定随机试验的所有可能结果, 并用一个非空集合 Ω 对其进行描述. 集合 Ω 被称为**样本空间**.
2. 将 Ω 的(某些)子集称为**事件**, 并约定: 若某次随机试验的结果 ω 属于某个事件 $E \subseteq \Omega$, 则称在该次随机试验中发生了事件 E .
3. 对每一个事件 E 赋予一**概率** $\mathbb{P}(E)$, 用来刻画随机试验的统计规律性. 具体来说, 假设我们重复了 n 次随机试验, 且这 n 次试验互不影响, 将其中事件 E 发生的次数记为 $q_n(E)$, 则事件 E 在这 n 次试验中发生的**频率**为

$$\text{Fr}_n(E) = \frac{q_n(E)}{n}.$$

理想情况下, 我们希望概率 $\mathbb{P}(E)$ 等于 n 趋向无穷大时的频率 $\text{Fr}_n(E)$ 的极限值.

上述过程中涉及到一些概率论的基本概念, 包括样本空间、事件、概率等等, 将在 1.3 节进行更为严格的定义. 需要注意的是, 现实世界中我们只可能对随机试验重复有限多次,

理论上我们是没办法从无限多次的试验结果中求出 $\lim_{n \rightarrow \infty} Fr_n(E)$ 的. 一般来说, 确定一个事件的概率 $\mathbb{P}(E)$ 不仅涉及到基于概率论的理论推导, 还可能涉及到超出概率论范围的对具体随机现象与随机试验的认识.

注意到概率论当中的样本空间、事件等概念均涉及到集合论的相关内容, 下面一节将对概率论当中所涉及的部分集合论知识进行简短的回顾.

1.2 集合论回顾

数学上, **集合** (set) 的严格定义由公理集合论给出, 然而对公理集合论的介绍超出了本课程的要求. 本节不对集合这一基本概念进行严格的定义, 读者可直观上将一个集合理解为一组确定性对象组成的整体, 这组对象被称为该集合的**元素**. 特别地, 集合具有如下性质:

1. 给定任意的对象 x 与集合 A , 要么 x 是 A 的元素 (或者说 x 属于 A , 记作 $x \in A$), 要么 x 不是 A 的元素 (或者说 x 不属于 A , 记作 $x \notin A$).
2. 两个集合 A 与 B 相等, 当且仅当 A 的所有元素也都是 B 的元素, 且 B 的所有元素也都是 A 的元素. 换句话说, $A = B$ 当且仅当对任意的 $x \in A$ 均有 $x \in B$, 且对任意的 $x \in B$ 均有 $x \in A$.

不包含任何元素的集合被称为**空集** (empty set), 在本讲义中用 $\emptyset$ 表示. 换句话说, 对任意对象 x , 均有 $x \notin \emptyset$. 其它一些常见的集合包括自然数集 $\mathbb{N} = \{0, 1, 2, \dots\}$ 、正整数集 $\mathbb{N}_+ = \{1, 2, 3, \dots\}$ 、整数集 $\mathbb{Z} = \{0, \pm 1, \pm 2, \pm 3, \dots\}$ 、有理数集 $\mathbb{Q}$ 、实数集 $\mathbb{R}$ 等.

给定集合 A 与 B , 若 A 的所有元素都是 B 的元素 (即对任意 $x \in A$ 均有 $x \in B$), 则称 A 是 B 的**子集** (subset), 记作 $A \subseteq B$ 或 $B \supseteq A$. 注意到对任意集合 A , 均有 $A \subseteq A$ 以及 $\emptyset \subseteq A$. 一个集合 A 的所有子集可以构成一个集合, 称作 A 的**幂集** (power set), 在本讲义中记作 2^A .

设 A 为一集合, 而 $\varphi(x)$ 为一关于变量 x 的命题. 若对任意对象 x , $x \in A$ 当且仅当命题 $\varphi(x)$ 成立, 则我们可将集合 A 表示为 $\{x \mid \varphi(x)\}$ 或 $\{x : \varphi(x)\}$. 需要注意的是, 并非所有关于 x 的命题 $\varphi(x)$ 都能按照这种方式给出相应的集合¹. 但另一方面, 公理集合论允许我们按如下方式构造集合: 给定集合 B 与关于 x 的命题 $\varphi(x)$, 则 B 中所有满

¹ 例如对于命题 $x \notin x$ 就不存在相应的集合 $\{x \mid x \notin x\}$, 否则会导致罗素悖论.

足命题 $\varphi(x)$ 的元素 x 可构成一集合, 记作 $\{x \in B \mid \varphi(x)\}$ 或 $\{x \in B : \varphi(x)\}$, 这个集合是 B 的一个子集. 例如, $\mathbb{R}$ 当中的开区间与闭区间可表示为²

$$]a, b[= \{x \in \mathbb{R} \mid a < x < b\}, \quad [a, b] = \{x \in \mathbb{R} \mid a \leq x \leq b\}.$$

本讲义中, “区间” 这个概念也包括形如 $] -\infty, b] = \{x \in \mathbb{R} \mid x \leq b\}$ 的无限区间, 以及形如 $[a, a] = \{a\}$ 的单点集.

对于一个无限集 A , 若它的所有元素可以被一个序列所穷尽, 也就是说存在一个序列 $(a_n)_{n=1}^{\infty}$, 使得

$$A = \{a_1, a_2, a_3, \dots\},$$

则称 A 是**可数无限集** (countably infinite set) 或**可列集** (denumerable set). 我们用**(至多) 可数集** (countable set) 来称呼有限或可数无限的集合. 不是可数集的集合被称作**不可数集** (uncountable set). 可以证明:

- 可数集的子集仍是可数集.
- 若一个映射 $f: A \rightarrow B$ 的定义域 A 为可数集, 那么 A 在映射 f 下的像集

$$\text{Im } f = \{y \in B \mid \text{存在 } x \in A \text{ 使得 } y = f(x)\} = \{f(x) \mid x \in A\}$$

也是可数集.

在常见的集合中, 自然数集 $\mathbb{N}$ 、正整数集 $\mathbb{N}_+$ 、整数集 $\mathbb{Z}$ 、有理数集 $\mathbb{Q}$ 为可数无限集, 而实数集 $\mathbb{R}$ 、欧氏空间 $\mathbb{R}^n$ 、欧氏空间中的开集为不可数集.

接下来我们回顾一些常见的集合运算:

- 给定任意集合 A 与 B , 它们的**并集** (union, 记作 $A \cup B$) 是恰好包含所有属于 A 或属于 B 的对象的集合, 即 $A \cup B = \{x \mid x \in A \text{ 或 } x \in B\}$.

两个集合的并集运算满足如下交换律与结合律:

$$A \cup B = B \cup A, \quad (A \cup B) \cup C = A \cup (B \cup C).$$

由此不难将并集运算推广到有限多个集合上.

- 给定任意集合 A 与 B , 它们的**交集** (intersection, 记作 $A \cap B$) 是恰好包含所有既属于 A 也属于 B 的对象的集合, 即 $A \cap B = \{x \mid x \in A \text{ 且 } x \in B\}$.

² 本讲义中用 $]a, b[$ 而非 (a, b) 表示开区间, 这是为了不和二元有序对 (a, b) 相混淆.

两个集合的交集运算满足如下交换律与结合律:

$$A \cap B = B \cap A, \quad (A \cap B) \cap C = A \cap (B \cap C).$$

由此不难将交集运算推广到有限多个集合上.

- 更一般地, 设 $\mathcal{I}$ 为某个非空集合 (可以是有限集、可数无限集或不可数无限集), 且每个 $i \in \mathcal{I}$ 都对应于一个集合 A_i , 此时称这些 A_i 构成一指标集为 $\mathcal{I}$ 的集族, 并用符号 $\{A_i\}_{i \in \mathcal{I}}$ 来表示. 我们将所有 A_i 的并集 $\bigcup_{i \in \mathcal{I}} A_i$ 定义为

$$\bigcup_{i \in \mathcal{I}} A_i = \{x \mid \text{存在某个 } i \in \mathcal{I} \text{ 使得 } x \in A_i\}.$$

所有 A_i 的交集 $\bigcap_{i \in \mathcal{I}} A_i$ 则被定义为

$$\bigcap_{i \in \mathcal{I}} A_i = \{x \mid \text{对任意 } i \in \mathcal{I} \text{ 均有 } x \in A_i\}.$$

当 $\mathcal{I} = \mathbb{N}_+$ 时, 我们通常将 $\bigcup_{i \in \mathcal{I}} A_i$ 与 $\bigcap_{i \in \mathcal{I}} A_i$ 分别记为 $\bigcup_{i=1}^{\infty} A_i$ 与 $\bigcap_{i=1}^{\infty} A_i$. 例如,

$$\begin{aligned} \bigcup_{i=1}^{\infty} \left[0, \frac{i}{i+1}\right] &= \left\{x \mid \text{存在正整数 } i \text{ 使得 } x \in \left[0, \frac{i}{i+1}\right]\right\} \\ &= \{x \in \mathbb{R} \mid 0 \leq x < 1\} = [0, 1[. \end{aligned}$$

又如,

$$\begin{aligned} \bigcap_{i=1}^{\infty} \left]0, \frac{1}{i}\right[&= \left\{x \mid \text{对任意正整数 } i \text{ 均有 } x \in \left]0, \frac{1}{i}\right[\right\} \\ &= \left\{x \in \mathbb{R} \mid x > 0 \text{ 且对任意正整数 } i \text{ 均有 } x < \frac{1}{i}\right\} = \emptyset. \end{aligned}$$

可以证明, 当 $\mathcal{I}$ 为可数集且每个 A_i 都是可数集时, 并集 $\bigcup_{i \in \mathcal{I}} A_i$ 依然是可数集, 或者说, 可数个可数集的并集为可数集. 而对于交集 $\bigcap_{i \in \mathcal{I}} A_i$, 由于它包含于任一 A_i 当中, 故只要存在某个 $i \in \mathcal{I}$ 使得 A_i 是可数集, 则交集 $\bigcap_{i \in \mathcal{I}} A_i$ 就是可数集.

- 给定集合 A, B , **差集** $A \setminus B$ 为恰好包括所有属于 A 但不属于 B 的对象的集合, 即 $A \setminus B = \{x \in A \mid x \notin B\}$.

当集合 B 是集合 A 的子集时, 我们也称集合 $A \setminus B$ 是集合 B 在集合 A 中的**补集** (complement). 特别是, 当集合 A 已经事先给定且不会产生歧义时, 我们也会用 B^c 来表示 B 在 A 中的补集. 注意到此时有 $(B^c)^c = B$.

- 关于并集、交集与差集, 还有如下运算律成立:

1. 分配律:

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C), \quad A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

更一般地, 设 $\mathcal{I}$ 为任意非空集合, 每个 $i \in \mathcal{I}$ 对应于一个集合 B_i , 则

$$A \cup \left(\bigcap_{i \in \mathcal{I}} B_i \right) = \bigcap_{i \in \mathcal{I}} (A \cup B_i), \quad A \cap \left(\bigcup_{i \in \mathcal{I}} B_i \right) = \bigcup_{i \in \mathcal{I}} (A \cap B_i).$$

2. 德·摩根律 (De Morgan's laws): 设 A, B 均为某个集合 U 的子集, 则

$$(A \cup B)^c = A^c \cap B^c, \quad (A \cap B)^c = A^c \cup B^c,$$

其中的 c 均表示在 U 中的补集. 更一般地, 设 $\mathcal{I}$ 为任意非空集合, 每个 $i \in \mathcal{I}$ 对应于 U 的一个子集 A_i , 则有

$$\left(\bigcup_{i \in \mathcal{I}} A_i \right)^c = \bigcap_{i \in \mathcal{I}} A_i^c, \quad \left(\bigcap_{i \in \mathcal{I}} A_i \right)^c = \bigcup_{i \in \mathcal{I}} A_i^c.$$

- 给定集合 A, B , 我们将所有形如 (a, b) 的有序对 (其中 $a \in A, b \in B$) 构成的集合称作 A 与 B 的**笛卡尔积** (Cartesian product), 记作 $A \times B$, 即

$$A \times B = \{(a, b) \mid a \in A, b \in B\}.$$

类似地, 也可定义有限个集合的笛卡尔积. 特别是, 对任意集合 A , 我们定义

$$A^n = \{(a_1, \dots, a_n) \mid a_i \in A, \forall i = 1, \dots, n\}.$$

例如, $\mathbb{R}^n$ 即为所有形如 $(x_1, \dots, x_n)$ 的 n 维实向量构成的集合.

可以证明, 有限个可数集的笛卡尔积依然是可数集.

在部分教材中, 交集 $A \cap B$ 有时也被记为 AB , 差集 $A \setminus B$ 有时也被记为 $A - B$, 补集 B^c 有时也被记为 $\bar{B}$.

1.3 样本空间、事件与概率

概率论用如下数学对象对某个随机试验进行抽象:

- 我们将随机试验的所有可能结果用一个非空集合 Ω 表示. Ω 被称作**样本空间**, 其中的每个元素 $\omega \in \Omega$ 代表一个可能的试验结果, 不同的试验结果在同一次试验中不能一同发生. 样本空间 Ω 中的元素也被称为**样本点**.

- 样本空间 Ω 的 (某些) 子集被称为 Ω 中的**事件**. 在某一次随机试验中, 我们称事件 $E \subseteq \Omega$ 发生当且仅当该次试验的结果 ω 是 E 的元素. 我们将所有事件构成的集族称为**事件域**, 它是样本空间幂集 2^Ω 的子集.
- 对每一个事件 E , 我们指定一个实数 $\mathbb{P}(E)$ 作为其**概率**. 换句话说, $\mathbb{P}$ 是将每个事件映为其概率的映射, 映射 $\mathbb{P}$ 本身被称为**概率测度**.

事件域与概率测度并不能随意指定, 它们需要满足如下定义:

定义 1.1. 设 Ω 为一个样本空间, $\mathcal{F}$ 是幂集 2^Ω 的子集 (也就是说 $\mathcal{F}$ 的每个元素都是 Ω 的子集). 若 $\mathcal{F}$ 满足如下条件, 则称 $\mathcal{F}$ 为 Ω 上的一个**事件域**³:

1. $\Omega \in \mathcal{F}$.
2. 对任意 $E \in \mathcal{F}$, 有 $E^c = \Omega \setminus E \in \mathcal{F}$.
3. 任取 $\mathcal{F}$ 中的一族集合 $\{E_i\}_{i \in \mathcal{I}}$, 其中 $\mathcal{I}$ 为可数的指标集, 则总有 $\bigcup_{i \in \mathcal{I}} E_i \in \mathcal{F}$.

在指定事件域 $\mathcal{F}$ 后, $\mathcal{F}$ 的元素即被称作**事件** (event). 定义 1.1 中的几个条件可重述如下: 1. Ω 是一个事件; 2. 每个事件 E 在 Ω 中的补集 E^c 依然是一个事件; 3. 可数多个事件的并依然是一个事件. 我们将在 1.3.2 小节对事件这一概念进行进一步说明.

定义 1.2. 设 Ω 为一样本空间, $\mathcal{F}$ 为 Ω 上的事件域. 若映射 $\mathbb{P}: \mathcal{F} \rightarrow \mathbb{R}$ 满足如下条件, 则称 $\mathbb{P}$ 为 $\mathcal{F}$ 上的一个**概率测度** (probability measure):

1. 对任意 $E \in \mathcal{F}$, 均有 $0 \leq \mathbb{P}(E) \leq 1$.
2. $\mathbb{P}(\Omega) = 1$.
3. (可数可加性) 若 $E_1, E_2, E_3, \dots$ 为 $\mathcal{F}$ 中的一列可数无限多个集合, 且对任意 $i \neq j$ 均有 $E_i \cap E_j = \emptyset$, 则级数 $\sum_{i=1}^{\infty} \mathbb{P}(E_i)$ 收敛, 且

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(E_i).$$

我们将样本空间 Ω 、事件域 $\mathcal{F} \subseteq 2^\Omega$ 、概率测度 $\mathbb{P}: \mathcal{F} \rightarrow \mathbb{R}$ 构成的三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 称作一个**概率空间** (probability space). 而对任意事件 $E \in \mathcal{F}$, 我们将 $\mathbb{P}(E)$ 称作 E 的**概率**.

³更通用的术语是 σ -代数 (σ -algebra), 但本讲义既打算解释该名称中“ σ ”和“代数”各自的含义, 也不想在此 σ -代数这个概念上花费太多笔墨, 故用一个更温和且更贴合概率论的名称“事件域”来代替.

上述定义是对现实世界的随机现象与随机试验进行数学抽象, 并加以一定的理论考虑而提出的, 它们规定了描述随机试验所需要的数学对象以及这些数学对象所要满足的理论条件. 作为数学理论的概率论, 就是以上述定义 (以及条件概率、独立性等基本概念) 为基础发展起来的. 概率论主要关心的一些典型问题如下:

假设已经给定了如下资料: (i) 样本空间 Ω ; (ii) Ω 的一族子集 $\{E_i, i \in \mathcal{I}\}$ 作为我们所关心的一些事件; (iii) 事件族 $\{E_i, i \in \mathcal{I}\}$ 中一些简单事件的概率值或者这些概率所满足的关系. 则

- 应当如何由简单事件的概率值或概率的关系, 计算出 $\{E_i, i \in \mathcal{I}\}$ 当中其它事件的概率;
- 在获取到额外信息 (例如获知某些事件已经发生) 的条件下, 应当如何对概率进行修正或更新.

注 1.1. 之前说过, 理想情况下, 我们希望一个事件 E 的概率 $\mathbb{P}(E)$ 等于试验重复的次数 n 趋于无穷大时频率 $\text{Fr}_n(E)$ 的极限, 但在定义 1.2 当中, 我们并不直接把“概率等于频率的极限”作为概率的原始数学定义, 而是从“概率等于频率的极限”这一理想当中抽象出一些基本性质, 利用这些基本性质来定义概率测度 $\mathbb{P}$ (我们将在后文的注 1.2 对此给出具体的解释). 这种概率的定义方式常被称为概率的公理化定义, 它是数学家 Колмогоров (柯尔莫哥洛夫, Kolmogorov) 在 1933 年的著作 [1] 中总结并提出的, 是现代概率论发展的重要里程碑.

实际上, 把“概率等于频率的极限”作为原始定义来建立概率论会遇到不少问题, 例如我们一开始就需要考察随机试验重复无限多次的复杂情形, 又如这样的理论中“独立性”的概念在逻辑上似乎有陷入循环论证的风险; 此外, 从现代概率论的角度来看, “概率等于频率的极限”也不一定是一个必然发生的事件. 而以概率的公理化定义为基础的现代概率论则能够较好地规避这些问题. 在现代概率论当中, “概率等于频率的极限”成为了概率的公理化定义以及独立性定义的某种推论, 被称为“大数定律”.

概率的公理化定义的另一个特点在于, 它将“为什么会有随机现象、随机现象为什么服从统计规律”这一涉及到具体物理机制的问题从“如何对随机现象进行数学描述”中剥离出去. 这种剥离一方面使得概率论本身获得了足够的抽象从而成为了一门独立的数学理论, 另一方面也使得我们在应用概率论时可以以更加唯象的方式入手, 而无需对随机现象背后的物理机制有特别充分的了解, 这进一步拓展了概率论的应用范围. ■

1.3.1 不能大量重复的不确定现象与主观概率

以公理化定义为基础的概率论甚至可以用于对带有不确定性但又不能大量重复的现象进行描述. 最常见的一个例子是天气预报, 我们经常会见到类似于“明天白天的降水概率为 80%”的说法, 这里的降水概率并不是说将明天重复 n 次, 其中发生降水的次数占总重复次数的比例在 n 趋于无穷时的极限值, 而是为明天发生降水的可能性大小提供一个定量的衡量, 这个概率越大, 则我们对于“明天会下雨”这个判断的把握也就越大. 又如, 某个学生在考完期末考试以后对自己的考试分数进行预估, 给出了“超过 90 分的概率有七成”的预测, 这里的“七成”同样是一种对可能性大小的衡量, 而非是某种频率的极限. 我们甚至会对某些在原则上已确定但由于信息匮乏而导致不确定的结果谈论其可能性大小, 例如地质勘探队员可能会说“这片区域的地下八成埋藏着石油”.

注意到上述几个例子中给出的概率不可避免地带有一些主观色彩, 因为它们会直接或间接地依赖于个人所具有的知识、经验与信息: 降水概率的评估依赖于收集到的气象数据与具体的气象模型, 而气象模型的建立并非完全客观, 或多或少会依赖于个人的知识与经验; 考试分数的评估则依赖于考生自己对正确答案的掌握以及对阅卷人员评分尺度的了解; 衡量地下埋藏石油的可能性则更是直接依赖于勘探数据信息以及相关知识经验. 这类依赖于个人知识、经验与信息的, 对带有不确定性但又不可大量重复的现象进行定量刻画的概率经常被叫作主观概率. 相关的理论分析与大量的实践经验表明, 在对主观概率施加一定的相容性限制后, 用概率论为主观概率进行数学建模是可行的, 也就是说我们依然可以用一个概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 对不确定现象进行建模: 样本空间 Ω 包含了不确定现象的所有可能结果, 事件 $E \in \mathcal{F}$ 发生当且仅当不确定现象的最终结果为 E 的元素, 而映射 $\mathbb{P}$ 则将事件对应到主观概率; 感兴趣的读者可参考 [2] 当中的论述. 主观概率能够为不确定环境下的决策提供非常有价值的指导.

本讲义当中对概率论的讲授将主要基于可重复的随机试验及概率代表频率极限的视角, 但某些例子则会涉及主观概率.

需要指出, 基于公理化定义的概率论本身并不涉及概率在现实世界中的对应, 上述对于频率极限与主观概率的区分并不会使概率论内部产生本质上的分歧. 然而, 这种区分对于与现实世界联系紧密的数理统计方法则会产生较为深刻的影响, 进而发展出所谓的“频率学派”与“贝叶斯学派”两个派别的数理统计理论. 由于课程内容设计的原因, 本讲义的数理统计部分主要关注频率学派的理论. 对贝叶斯学派理论感兴趣的读者可

在学习完概率论部分以后阅读相关教材.

1.3.2 对事件这一概念的进一步说明

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间. 我们先回顾一下事件发生的含义: 在某一次随机试验中, 我们称事件 $E \in \mathcal{F}$ 发生当且仅当该次试验的结果 ω 是 E 的元素. 接下来, 基于事件发生的含义与定义 1.1, 我们引入一些关于事件的基本概念和基本运算.

- 由定义 1.1, 可知 Ω 以及 $\emptyset = \Omega^c$ 都是事件. 不难看出, 无论随机试验的结果 ω 如何, Ω 总是发生 (因 ω 必定属于 Ω), 而 $\emptyset$ 总是不发生 (因 ω 必定不属于 $\emptyset$). 我们将 Ω 称为**必然事件**, $\emptyset$ 称为**不可能事件**.
- 由于事件都是样本空间 Ω 的子集, 故而事件之间也可以有包含关系. 若事件 E 是事件 F 的子集, 那么事件 E 发生时事件 F 必然发生.
- 任取两个事件 E 和 F , 根据定义 1.1 的第 3 个条件, 可知它们的并集 $E \cup F$ 也是一个事件. 由并集的定义以及事件发生的含义, 可知事件 $E \cup F$ 发生当且仅当 E 发生或 F 发生.

更一般地, 对于可数多个事件 $E_1, E_2, \dots$, 其并集 $\bigcup_i E_i$ 也是一个事件, 该事件发生当且仅当 $E_1, E_2, \dots$ 中至少有一个发生.

- 任取两个事件 E 和 F , 由集合的德·摩根律可得 $E \cap F = (E^c \cup F^c)^c$, 再利用上一条结论以及定义 1.1 的第 2 个条件, 可知交集 $E \cap F$ 也是一个事件. 由交集的定义以及事件发生的含义, 可知事件 $E \cap F$ 发生当且仅当 E 和 F 都发生.

更一般地, 对于可数多个事件 $E_1, E_2, \dots$, 其交集 $\bigcap_i E_i$ 也是一个事件, 该事件发生当且仅当 $E_1, E_2, \dots$ 这些事件全都发生.

- 若两个事件 E, F 的交 $E \cap F$ 为空集, 则说事件 E 与事件 F **互斥**或**互不相容** (mutually exclusive). 两个互斥的事件不能在同一次随机试验中都发生.
- 任取事件 E , 根据定义 1.1 的第 3 个条件, 可知其补集 E^c 也是一个事件. 我们称 E 与 E^c 互为**对立事件**. 注意到对立事件必为互斥事件. 在某一次随机试验中, 事件 E 与其对立事件 E^c 有且仅有一个发生.

在本小节的最后, 我们对事件域 $\mathcal{F}$ 这一概念的引入进行必要的说明. 一些初等概率论的教材并未明确引入事件域的概念, 而是将事件直接定义为样本空间的子集, 这种做法对于绝大多数实际应用是足够的, 但在数学上缺乏一定的严格性. 例如, 若想要

对“在区间 $[0, 1]$ 内均匀地取一个随机数”这个试验建立数学模型, 则可以取样本空间 $\Omega = [0, 1]$ (可参考后面的例 1.4), 而随机数的均匀性则要求任意区间 $I \subseteq \Omega$ 的概率正比于 I 的长度, 但可以证明, 我们无法构造出一个定义域为 2^Ω 的概率测度 $\mathbb{P}$ 使其满足这个均匀性要求; 或者说, 我们无法对每个 Ω 的子集都赋予相应的概率值, 使其与均匀性要求相容⁴. 概率论应对这个问题的办法是将概率测度 $\mathbb{P}$ 的定义域缩小到 2^Ω 的一个子集 $\mathcal{F}$ (也就是事件域) 上, 但仍要求 $\mathcal{F}$ 中的元素经过一些基本的集合运算 (包括补集运算、可数并运算、可数交运算⁵) 后依然在 $\mathcal{F}$ 当中, 从而方便对事件进行各种常见的运算. 通常, 当 Ω 为可数集时, 我们几乎总是取事件域 $\mathcal{F}$ 为幂集 2^Ω , 即 Ω 的所有子集都是事件; 当 Ω 为不可数集时, 事件域 $\mathcal{F}$ 的选取则属于高等概率论的内容, 本讲义不对其进行展开. 在随后的内容中, 若无特别说明, 均假定事件域 $\mathcal{F}$ 随样本空间 Ω 一同给出, 且它囊括了我们想要讨论的事件.

1.3.3 一些随机试验及其样本空间的例子

下面我们给出一些随机试验以及相应的样本空间 Ω 的例子.

例 1.2 (抛 2 次硬币). 假设我们的随机试验为掷 2 次硬币, 硬币的正反面分别用 H 和 T 表示. 则样本空间可以取为

$$\begin{aligned}\Omega &= \{(\omega_1, \omega_2) \mid \text{对每个 } i = 1, 2, \omega_i \text{ 均为 H 或 T}\} \\ &= \{(H, H), (H, T), (T, H), (T, T)\}\end{aligned}$$

由于 Ω 为有限集, 故可以取 $\mathcal{F} = 2^\Omega$, 也就是说 Ω 的所有子集都是事件. 以下给出了一些事件的例子:

1. 事件 $\{(H, H), (H, T)\}$ 的含义可写为“第一次抛出的为正面”;
2. 事件 $\{(H, T), (T, H)\}$ 的含义可写为“两次抛硬币的结果不同”;
3. 事件 $\{(H, H), (H, T), (T, H)\}$ 的含义可写为“抛出反面的次数至多为 1”;
4. 事件 $\{(H, H), (T, H), (T, T)\}$ 的含义可写为“第一次抛出反面, 或第二次抛出正面”.

由于集合 $\mathcal{F} = 2^\Omega$ 包含 $2^4 = 16$ 个不同的元素, 故总共有 16 个不同的事件. ■

⁴ 这个结果属于测度论的内容, 感兴趣的读者可参阅 [3] 的附录 A1.1 等相关文献.

⁵ 此处的可数并、可数交运算不能推广到任意并、任意交运算, 否则一旦每个单点集 $\{\omega\}$ 都属于 $\mathcal{F}$ (也就是说“随机试验的结果为 ω ”对每个 $\omega \in \Omega$ 都是一个事件), 则任意 Ω 的子集 $E = \bigcup_{\omega \in E} \{\omega\}$ 都将属于 $\mathcal{F}$, 从而 $\mathcal{F}$ 必定等于 2^Ω , 这便违背了缩小 $\mathbb{P}$ 的定义域的初衷.

例 1.3 (抛 n 次硬币). 更一般地, 若随机试验为抛 n 次硬币, 则样本空间可以取为

$$\Omega = \{(\omega_1, \dots, \omega_n) \mid \text{对每个 } i = 1, 2, \dots, n, \omega_i \text{ 均为 H 或 T}\}.$$

同样地, 由于 Ω 为有限集, 故可以取 $\mathcal{F} = 2^\Omega$. 若用 E_i 表示“第 i 次抛硬币的结果为正面”这一事件, 即

$$E_i = \{(\omega_1, \dots, \omega_n) \in \Omega \mid \omega_i = \text{H}\},$$

则

- “每一次抛硬币的结果均为正面”这一事件可表示为 $\bigcap_{i=1}^n E_i$;
- “至少有一次抛硬币的结果为正面”这一事件可表示为 $\bigcup_{i=1}^n E_i$;
- 给定小于等于 n 的正整数 m 以及小于等于 $n - m + 1$ 的正整数 i , “从第 i 次开始连着 m 次都抛出正面”这一事件可表示为

$$E_i \cap E_{i+1} \cap \dots \cap E_{i+m-1} = \bigcap_{j=0}^{m-1} E_{i+j};$$

- 给定小于等于 n 的正整数 m , “出现了连着 m 次抛出正面”这一事件可表示为

$$\bigcup_{i=1}^{n-m+1} (E_i \cap E_{i+1} \cap \dots \cap E_{i+m-1}) = \bigcup_{i=1}^{n-m+1} \bigcap_{j=0}^{m-1} E_{i+j}. \quad \blacksquare$$

例 1.4 (区间 $[0, 1]$ 上的随机数). 假设我们的随机试验是用随机数生成器生成一个属于 $[0, 1]$ 的随机数, 则样本空间可以取为 $\Omega = [0, 1]$, 此时“随机数落在区间 $I \subset [0, 1]$ 当中”这一事件则可直接用区间 I 本身来表示. ■

例 1.5 (抛无限多次硬币). 假设我们的随机试验为抛 (可数) 无限多次硬币, 硬币的正反面分别用 H 和 T 表示⁶. 则样本空间可以取为

$$\Omega = \{(\omega_1, \omega_2, \omega_3, \dots) \mid \text{每个 } \omega_i \text{ 均为 H 或 T}\}.$$

接下来, 用 $q_n(\omega_1, \dots, \omega_n)$ 表示 $\omega_1, \dots, \omega_n$ 当中 H 出现的次数, 则事件

$$\left\{ (\omega_1, \omega_2, \omega_3, \dots) \in \Omega \mid \lim_{n \rightarrow \infty} \frac{q_n(\omega_1, \dots, \omega_n)}{n} = \frac{1}{2} \right\}$$

的含义是“前 n 次抛硬币中抛出正面的频率在 $n \rightarrow \infty$ 时趋向于 $1/2$ ”. ■

⁶ 这个随机试验并不能在真实世界中实现, 然而对它的研究依然具有重要的价值. 一方面, 抛 n 次硬币的试验都可以看成是抛无限多次硬币的一个“子试验”; 另一方面, 对抛无限多次硬币的研究使得我们能更深入地研究抛 n 次硬币在 $n \rightarrow \infty$ 时的极限行为.

例 1.6 (悬浮于水中的花粉粒的轨迹). 该随机试验的描述见例 1.1. 对于该随机试验, 我们通常取样本空间为

$$\Omega = \{r : [0, +\infty[\rightarrow \mathbb{R}^3 \mid r \text{ 在 } [0, +\infty[\text{ 上连续}\}.$$

注意到该例当中, 样本空间 Ω 似乎取得有些“过大”: 真实实验只能观察长度有限的时间段内有限个时刻 $0 \leq t_1 < \cdots < t_n \leq T$ 的花粉位置信息, 而没有办法观察到无穷长时间段 $[0, +\infty[$ 内的整条连续时间轨迹. 这里 Ω 的取法带有一定的理想化与抽象的过程, 它的一大优点在于能使我们的模型与观测时刻 $0 \leq t_1 < \cdots < t_n \leq T$ 无关, 从而具有普适性. ■

1.4 概率的基本性质

在熟悉了样本空间与事件的概念之后, 本节我们将从定义 1.2 出发, 推导概率测度的一些普遍成立的基本性质.

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间. 由定义 1.2 可知, 对任意事件 E , 其概率 $\mathbb{P}(E)$ 必定取值于 $[0, 1]$ 中; 此外, 必然事件 Ω 的概率为 1. 不可能事件 $\emptyset$ 的概率可以从定义 1.2 中概率的可数可加性推得.

引理 1.1. $\mathbb{P}(\emptyset) = 0$.

证明. 令 $E_i = \emptyset, i = 1, 2, \dots$, 则有 $\bigcup_{i=1}^{\infty} E_i = \emptyset$ 以及 $E_i \cap E_j = \emptyset$, 则由概率的可数可加性可得

$$\mathbb{P}(\emptyset) = \mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(E_i) = \sum_{i=1}^{\infty} \mathbb{P}(\emptyset).$$

上式成立当且仅当 $\mathbb{P}(\emptyset) = 0$. □

需要注意的是, 一般情况下 $\mathbb{P}(E) = 1$ 并不意味着 E 为必然事件, $\mathbb{P}(E) = 0$ 也并不意味着 E 为不可能事件. 若事件 E 满足 $\mathbb{P}(E) = 1$, 我们称 E 是**几乎必然** (almost surely, 缩写为 a.s.) 发生的.

接下来我们介绍概率的有限可加性, 它也同样是可数可加性的推论.

命题 1.2 (有限可加性). 设 $E_1, \dots, E_n$ 为有限个事件, 且对任意 $i \neq j$ 均有 $E_i \cap E_j = \emptyset$, 则

$$\mathbb{P}(E_1 \cup \cdots \cup E_n) = \mathbb{P}(E_1) + \cdots + \mathbb{P}(E_n).$$

证明. 令 $E_{n+1} = E_{n+2} = \cdots = \emptyset$, 则事件列 $E_1, \dots, E_n, E_{n+1} \dots$ 中的事件两两互不相交, 利用概率的可数可加性并注意到 $\bigcup_{i=1}^{\infty} E_i = E_1 \cup \cdots \cup E_n$ 以及 $\mathbb{P}(\emptyset) = 0$ 即可. $\square$

利用概率的可加性, 我们可以进一步得到概率的如下性质:

命题 1.3. 令 E, F 为任意事件, 则有

1. $\mathbb{P}(E^c \cap F) = \mathbb{P}(F) - \mathbb{P}(E \cap F)$. 特别是, 当 $F = \Omega$ 时, 有 $\mathbb{P}(E^c) = 1 - \mathbb{P}(E)$.
2. 若 $E \subseteq F$, 则 $\mathbb{P}(E) \leq \mathbb{P}(F)$.
3. $\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F)$.

证明. 1. 注意到 $(E \cap F) \cup (E^c \cap F) = F$ 以及 $(E \cap F) \cap (E^c \cap F) = \emptyset$, 由概率的有限可加性可得

$$\mathbb{P}(F) = \mathbb{P}((E \cap F) \cup (E^c \cap F)) = \mathbb{P}(E \cap F) + \mathbb{P}(E^c \cap F),$$

再移项即可.

2. 当 $E \subseteq F$ 时, 有 $E \cap F = E$, 故由第 1 条性质以及概率的非负性可得

$$0 \leq \mathbb{P}(E^c \cap F) = \mathbb{P}(F) - \mathbb{P}(E \cap F) = \mathbb{P}(F) - \mathbb{P}(E),$$

从而 $\mathbb{P}(E) \leq \mathbb{P}(F)$.

3. 注意到

$$E \cup F = E \cup (F \cap E^c), \quad E \cap (F \cap E^c) = \emptyset,$$

故

$$\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F \cap E^c),$$

再由第 1 条性质得

$$\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F). \quad \square$$

由等式 $\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F)$ 以及概率的非负性, 可得

$$\mathbb{P}(E \cup F) \leq \mathbb{P}(E) + \mathbb{P}(F).$$

对于有限个事件的情形, 则有如下推广的结果:

定理 1.4. 给定 n 个事件 $E_1, \dots, E_n$, 我们有

$$\mathbb{P}(E_1 \cup \dots \cup E_n) \leq \sum_{i=1}^n \mathbb{P}(E_i), \quad (\text{Boole 不等式})$$

以及

$$\mathbb{P}(E_1 \cap \dots \cap E_n) \geq 1 - \sum_{i=1}^n (1 - \mathbb{P}(E_i)). \quad (\text{Bonferroni 不等式})$$

证明. Boole 不等式可对 n 做数学归纳法证得: 对于初始情况, 显然有 $\mathbb{P}(E_1) \leq \mathbb{P}(E_1)$; 而若 $\mathbb{P}(E_1 \cup \dots \cup E_n) \leq \sum_{i=1}^n \mathbb{P}(E_i)$, 则

$$\begin{aligned} \mathbb{P}(E_1 \cup \dots \cup E_{n+1}) &= \mathbb{P}((E_1 \cup \dots \cup E_n) \cup E_{n+1}) \\ &\leq \mathbb{P}(E_1 \cup \dots \cup E_n) + \mathbb{P}(E_{n+1}) \\ &\leq \mathbb{P}(E_1) + \dots + \mathbb{P}(E_n) + \mathbb{P}(E_{n+1}) = \sum_{i=1}^{n+1} \mathbb{P}(E_i), \end{aligned}$$

其中第二步用到了两个事件之并的概率上界, 而第三步则用到了归纳假设.

Bonferroni 不等式可看成 Boole 不等式的推论:

$$\begin{aligned} \mathbb{P}(E_1 \cap \dots \cap E_n) &= \mathbb{P}((E_1^c \cup \dots \cup E_n^c)^c) \\ &= 1 - \mathbb{P}(E_1^c \cup \dots \cup E_n^c) \\ &\geq 1 - \sum_{i=1}^n \mathbb{P}(E_i^c) = 1 - \sum_{i=1}^n (1 - \mathbb{P}(E_i)), \end{aligned}$$

其中第一步用到了德·摩根律, 而第二步以及最后一步用到了 $\mathbb{P}(E^c) = 1 - \mathbb{P}(E)$. □

此外, 等式 $\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F)$ 也可按如下方式进一步推广到三个事件 E, F, G 的并的概率上:

$$\begin{aligned} \mathbb{P}(E \cup F \cup G) &= \mathbb{P}(E \cup F) + \mathbb{P}(G) - \mathbb{P}((E \cup F) \cap G) \\ &= \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F) + \mathbb{P}(G) - \mathbb{P}((E \cup F) \cap G) \\ &= \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F) + \mathbb{P}(G) - \mathbb{P}((E \cap G) \cup (F \cap G)) \\ &= \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F) + \mathbb{P}(G) \\ &\quad - [\mathbb{P}(E \cap G) + \mathbb{P}(F \cap G) - \mathbb{P}((E \cap G) \cap (F \cap G))] \\ &= \mathbb{P}(E) + \mathbb{P}(F) + \mathbb{P}(G) \\ &\quad - \mathbb{P}(E \cap F) - \mathbb{P}(E \cap G) - \mathbb{P}(F \cap G) + \mathbb{P}(E \cap F \cap G), \end{aligned}$$

其中第三步利用了集合交并运算的分配律 $(E \cup F) \cap G = (E \cap G) \cup (F \cap G)$. 而对于更一般的 n 个事件的并 $E_1 \cup \cdots \cup E_n$, 其概率可由如下的容斥原理 (inclusion-exclusion principle) 给出:

$$\begin{aligned} & \mathbb{P}(A_1 \cup \cdots \cup A_n) \\ &= \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i_1 < i_2 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2}) + \cdots \\ & \quad + (-1)^{k-1} \sum_{1 \leq i_1 < \cdots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}) + \cdots + (-1)^{n-1} \mathbb{P}(A_1 \cap \cdots \cap A_n). \end{aligned}$$

该式同样可以用数学归纳法证明, 感兴趣的读者可自行尝试. 不过利用下一章将介绍的期望的线性, 可以给上式一个更直接的证明, 我们将在习题 2.7 中完成其证明过程.

例 1.7. 设事件 E, F, G 满足 $\mathbb{P}(E) = \mathbb{P}(F) = \mathbb{P}(G) = 1/4$, $\mathbb{P}(E \cap F) = 1/8$, $E \cap G = F \cap G = \emptyset$, 则 E, F, G 当中至少有一个发生的概率是多少?

首先注意到, “ E, F, G 当中至少有一个发生” 这一事件可表示为 $E \cup F \cup G$, 故而待求概率为 $\mathbb{P}(E \cup F \cup G)$. 接下来利用容斥不等式可得

$$\begin{aligned} \mathbb{P}(E \cup F \cup G) &= \mathbb{P}(E) + \mathbb{P}(F) + \mathbb{P}(G) \\ & \quad - \mathbb{P}(E \cap F) - \mathbb{P}(E \cap G) - \mathbb{P}(F \cap G) \\ & \quad + \mathbb{P}(E \cap F \cap G). \end{aligned}$$

上式右端 $\mathbb{P}(E), \mathbb{P}(F), \mathbb{P}(G)$ 以及 $\mathbb{P}(E \cap F)$ 的值已经给出; 由于 $E \cap G = F \cap G = \emptyset$, 故 $\mathbb{P}(E \cap G) = \mathbb{P}(F \cap G) = 0$; 而由 $E \cap G = \emptyset$ 可推出 $E \cap F \cap G = \emptyset$, 故 $\mathbb{P}(E \cap F \cap G) = 0$. 将这些结果代入上式, 可得

$$\mathbb{P}(E \cup F \cup G) = \frac{5}{8}. \quad \blacksquare$$

注 1.2. 现在, 我们可以为定义 1.2 中对概率测度 $\mathbb{P}$ 施加的三个条件提供一些解释. 这三个条件其实都可以看成是由频率所满足的性质移植或推广而来的: 假设我们重复了 n 次随机试验, 且它们互不影响, 将任一事件 E 发生的次数记为 $q_n(E)$, 频率记为 $\text{Fr}_n(E) = q_n(E)/n$, 则

1. 由 $0 \leq q_n(E) \leq n$ 可知 $0 \leq \text{Fr}_n(E) \leq 1$.
2. Ω 为必然事件, 这意味着 $q_n(\Omega) = n$, 从而 $\text{Fr}_n(\Omega) = 1$.
3. 设 k 个事件 $E_1, \dots, E_k$ 两两互斥, 则 $q_n(E_1 \cup E_2 \cup \cdots \cup E_k) = q_n(E_1) + q_n(E_2) + \cdots + q_n(E_k)$.

$\cdots + q_n(E_k)$, 从而

$$\text{Fr}_n(E_1 \cup E_2 \cup \cdots \cup E_k) = \text{Fr}_n(E_1) + \text{Fr}_n(E_2) + \cdots + \text{Fr}_n(E_k).$$

因而, 若希望对任意事件 E , 在 $n \rightarrow \infty$ 时频率 $\text{Fr}_n(E)$ 将趋向于概率 $\mathbb{P}(E)$, 则概率测度 $\mathbb{P}$ 也应当满足 (i) 对任意事件 E 有 $0 \leq \mathbb{P}(E) \leq 1$; (ii) $\mathbb{P}(\Omega) = 1$; (iii) 有限可加性: 对有限多个两两互斥的事件 $E_1, \dots, E_k$, 有 $\mathbb{P}\left(\bigcup_{i=1}^k E_i\right) = \sum_{i=1}^k \mathbb{P}(E_i)$. 注意到在定义 1.2 中, 我们将有限可加性推广为了可数可加性. 实际上, 可数可加性在概率论的建立中发挥了至关重要的作用; 若只要求概率测度满足有限可加性, 则很难发展出一套内容丰富的概率理论. 但对可数可加性进行深入讨论则是高等概率论课程的内容, 考虑到本讲义面向的读者水平, 我们在讲义正文中不会对其进行特别深入讨论. ■

1.5 古典概型

当样本空间 Ω 只有有限个元素时, 若我们没有证据指出其中的某个结果会比其它结果更有可能发生, 则通常将概率模型取为**古典概型** (classical probability). 在古典概型中, 取样本空间为 $\Omega = \{\omega_1, \dots, \omega_N\}$, 其中 $\omega_1, \dots, \omega_N$ 代表 N 个可能的结果, 事件域 $\mathcal{F}$ 取为 2^Ω (即 Ω 的所有子集都是事件), 概率测度 $\mathbb{P}$ 则由

$$\mathbb{P}(E) = \frac{|E|}{N} = \sum_{\omega \in E} \frac{1}{N}, \quad \forall E \subseteq \Omega$$

给出, 其中我们用 $|E|$ 表示集合 E 中元素的个数. 不难验证上述 $\mathbb{P}$ 的确满足定义 1.2, 此外

$$\mathbb{P}(\{\omega_1\}) = \cdots = \mathbb{P}(\{\omega_N\}) = \frac{1}{N},$$

也就是说每个仅包含单个结果的事件都具有相同的概率 $1/N$.

由于古典概型中的概率与计数直接相关, 因此关于古典概型的概率论问题通常会用到组合计数的诸多方法. 本讲义只要求读者了解基本的组合计数方法, 而不会涉及更加复杂的组合学技术与技巧. 接下来我们对一些基本的组合计数方法进行简要回顾; 相关结果更详细的介绍以及证明可参考 [4-5] 等教材.

乘法原理: 设某个试验共包括 r 个依次执行的阶段, 其中

1. 第 1 个阶段总共有 n_1 个可能的结果;

2. 在完成前 $i-1$ 个阶段并得到一个相应的结果后, 第 i 个阶段将总共有 n_i 个可能的结果 (n_i 的大小不受前 $i-1$ 个阶段的具体结果的影响).

则该试验总共有 $n_1 \cdot n_2 \cdots n_r$ 个可能的结果.

加法原理: 设完成某个试验有 r 种不同的途径, 且只能在这 r 种途径中选一种来完成该试验. 若采取第 i 种途径时总共有 n_i 个可能的结果, 且选择不同的途径必定导致不同的结果, 则该试验总共有 $n_1 + n_2 + \cdots + n_r$ 个可能的结果.

排列: 假设有 n 个不同的个体, 我们需要从中选出 m 个个体并将它们排成一个序列. 则总共有

$$n(n-1) \cdots (n-m+1) = \frac{n!}{(n-m)!}$$

个可能的排列方式.

组合: 假设一个集合包含 n 个不同的元素, 我们需要从中选出 m 个元素构成一个子集. 则可能得到的子集总共有

$$\frac{n(n-1) \cdots (n-m+1)}{m!} = \frac{n!}{m!(n-m)!}$$

个. 上式给出的正整数又被称作**二项式系数** (binomial coefficient), 记作 $\binom{n}{m}$, 这是因为二项式定理给出

$$(x+y)^n = \sum_{m=0}^n \binom{n}{m} x^m y^{n-m}.$$

(*) **多项式系数:** 给定一组自然数 $n_1, \dots, n_r$ 以及 $n = n_1 + \cdots + n_r$, 相应的**多项式系数** (multinomial coefficient) 被定义为

$$\binom{n}{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \cdots n_r!}.$$

多项式系数的含义可以有如下两种解释:

- 设总共有 r 类对象, 其中第 i 类对象包含 n_i 个不可区分的个体, 我们需要将这 $n = n_1 + \cdots + n_r$ 个个体排成一个序列. 则可以证明, 可能的排列方式总共有 $\binom{n}{n_1, n_2, \dots, n_r}$ 个.

- 设一个集合 A 总共有 n 个元素, 我们需要将这个集合划分为 r 个互不相交的子集 $A_1, \dots, A_r$, 其中要求子集 A_i 包含 n_i 个元素. 则可以证明, 可能的子集划分方式总共有 $\binom{n}{n_1, n_2, \dots, n_r}$ 个.

实际上, 第一种解释下的排列方式与第二种解释下的子集划分方式有一一对应关系: 给定第一种解释下的任一排列方式, 将其中第 k 个位置上的个体的类别记为 $\sigma(k) \in \{1, \dots, r\}$, 那么对于集合 $A = \{a_1, \dots, a_n\}$, 通过将元素 a_k 分到子集 $A_{\sigma(k)}$ 当中, 即可对应到一个子集划分方式. 反过来, 设 $A = \{a_1, \dots, a_n\}$, 且 $A = A_1 \cup \dots \cup A_r$ 给出了一种子集划分方式, 则通过在第 k 位置上放置一个第 i 类对象的个体, 其中 i 满足 $a_k \in A_i$, 即可得到第一种解释下的一个排列方式.

此外, 多项式系数还出现在多项式定理当中:

$$(x_1 + x_2 + \dots + x_r)^n = \sum \binom{n}{n_1, n_2, \dots, n_r} x_1^{n_1} x_2^{n_2} \dots x_r^{n_r},$$

其中的求和遍历所有满足 $n_1 + \dots + n_r = n$ 的自然数 $n_1, \dots, n_r$.

例 1.8. 有一副去掉大小王的扑克牌共 52 张, 将这 52 张牌洗牌后发给 4 个人, 每人 13 张, 则每个人牌中都包含一张 A 的概率是多少?

对于该题, 样本空间的取法并不唯一, 不同的取法将导致不同的求解方法. 这里我们给出两种方法, 第一种方法相对常规, 计算量稍大; 第二种方法有些巧妙, 计算量较小.

- 方法一: 采取如下的发牌过程: 将 52 张牌随机打乱次序, 而后将第 1 至第 13 张牌发给第 1 个人, 第 14 至第 26 张牌发给第 2 个人, 依次类推. 在方法一中, 我们将 52 张牌不同的排序均看作不同的结果. 将 52 张扑克牌构成的集合记为 P , 则样本空间 Ω 可表示为

$$\Omega = \{\omega : \{1, \dots, 52\} \rightarrow P \mid \omega \text{ 为双射}\}.$$

而 Ω 中的任意元素 ω 则对应到如下发牌结果: 第 i 个人 ($i = 1, 2, 3, 4$) 被发到的牌为 $\omega(13(i-1)+1)$ 到 $\omega(13i)$. 按照这种取法, 样本空间的大小为 $|\Omega| = 52!$. 接下来考虑“每个人牌中都包含一张 A”这一事件, 并将其记为 E . 我们按照如下步骤枚举 E 当中的所有元素:

1. 首先, 对每个 $i = 1, 2, 3, 4$, 从 $13(i-1)+1$ 到 $13i$ 当中挑出一个位置来, 作为第 i 个人手中 A 的位次. 这一步总共有 13^4 种可能性.
2. 接下来, 将 4 张 A 进行随机排列, 按照排列顺序依次分配给 4 个人. 这一步总共有 $4!$ 种可能性.

3. 最后, 将剩下的 48 张牌进行随机排列, 按照排列顺序依次分配到 4 个人剩余的 48 个位次上. 这一步总共有 $48!$ 种可能性.

利用乘法原理, 可得 E 当中元素的总数为 $13^4 \times 4! \times 48!$, 从而

$$\mathbb{P}(E) = \frac{|E|}{|\Omega|} = \frac{13^4 \times 4! \times 48!}{52!} = \frac{2197}{20825} \approx 0.1055.$$

- 方法二: 仍采用方法一的发牌过程. 考虑到我们只关心四张 A 的发牌情况, 取样本空间 Ω 为⁷

$$\Omega = \{\omega \subseteq \{1, \dots, 52\} \mid |\omega| = 4\},$$

也就是说, Ω 中的任一试验结果 ω 为一个集合, 它包含了四个 1 到 52 之间的互不相同的数, 我们用这个集合代表 52 张牌打乱次序后, 4 张 A 所处的位次 (此处不对 4 张 A 进行区分). 按照这种取法, 样本空间的大小由组合数给出:

$$|\Omega| = \binom{52}{4}.$$

仍将事件 “每个人牌中都包含一张 A” 记为 E , 则某个试验结果 ω 属于 E 当且仅当 ω 中的四个数分别处于 1 到 13, 14 到 26, 27 到 39, 40 到 52 之间, 而枚举所有这些集合是直接的: 只要分别从 1 到 13, 14 到 26, 27 到 39, 40 到 52 之间取一个数构成集合即可, 利用乘法原理可得

$$|E| = 13^4.$$

最后利用古典概型计算 E 的概率, 可得

$$\mathbb{P}(E) = \frac{13^4}{\binom{52}{4}} = \frac{2197}{20825} \approx 0.1055.$$

感兴趣的读者可进一步尝试其它做法. ■

例 1.9 (Banach 火柴盒问题). Banach 火柴盒问题 (Banach matchbox problem) 的表述如下: 一个人有两个火柴盒, 一开始每个火柴盒里有 n 根火柴, 之后每次随机选择一

⁷ (*) 实际上, 方法二的样本空间可以看成是对方法一的样本空间按照等价关系 $\sim$ 取商集得到的, 其中等价关系 $\sim$ 的定义为

$$\omega_1 \sim \omega_2 \iff \omega_1^{-1}(\{\spadesuit A, \heartsuit A, \diamondsuit A, \clubsuit A\}) = \omega_2^{-1}(\{\spadesuit A, \heartsuit A, \diamondsuit A, \clubsuit A\}), \quad \forall \omega_1, \omega_2 : \{1, \dots, 52\} \xrightarrow{\text{双射}} P.$$

而由于等价关系 $\sim$ 划分出的等价类都具有相同的元素个数, 故无论按方法一还是方法二取样本空间, 基于相应的古典概型进行概率计算将给出一致的结果.

个火柴盒并从里面取 1 根火柴, 直到某次取火柴时发现那个待取的火柴盒已经空了, 求此时另一个火柴盒里还剩 k 根火柴的概率.

首先注意到如下事实: 若取火柴时发现待取火柴盒已空而另一个火柴盒还剩 k 根火柴, 则此时必定是第 $n + (n - k) + 1 = 2n - k + 1$ 次取火柴; 反之, 若第 $2n - k + 1$ 次取火柴时发现待取火柴盒已空, 那么另一个火柴盒必定剩余 k 根火柴. 此外, 整个试验中取火柴的总次数 (包括发现火柴盒空了的这一次) 不会超过 $2n + 1$. 基于以上观察, 我们可以把原问题变换成如下等价的问题: 一个人独立重复地抛 $2n + 1$ 次均匀硬币, 并将其结果记录为多元组 $(\omega_1, \dots, \omega_{2n+1})$, 其中 $\omega_i \in \{H, T\}$, 则 $(\omega_1, \dots, \omega_{2n-k+1})$ 当中恰好出现 $n + 1$ 次 ω_{2n-k+1} 的概率是多少?

对于变换后的问题, 显然可以令

$$\Omega = \{(\omega_1, \dots, \omega_{2n+1}) \mid \omega_i \in \{H, T\}, \forall i\},$$

并取 $\mathbb{P}$ 为 Ω 上的古典概型, 其中每个 Ω 的单点集的概率为 $1/2^{2n+1}$. 记事件

$$E = \{(\omega_1, \dots, \omega_{2n+1}) \mid (\omega_1, \dots, \omega_{2n-k+1}) \text{ 当中恰好出现 } n + 1 \text{ 次 } \omega_{2n-k+1}\},$$

$$E_H = \{(\omega_1, \dots, \omega_{2n+1}) \mid \omega_{2n-k+1} = H \text{ 且 } (\omega_1, \dots, \omega_{2n-k}) \text{ 当中恰好出现 } n \text{ 次 } H\}$$

$$E_T = \{(\omega_1, \dots, \omega_{2n+1}) \mid \omega_{2n-k+1} = T \text{ 且 } (\omega_1, \dots, \omega_{2n-k}) \text{ 当中恰好出现 } n \text{ 次 } T\},$$

则 $E = E_H \cup E_T$ 且 $E_H \cap E_T = \emptyset$, 故

$$\mathbb{P}(E) = \mathbb{P}(E_H) + \mathbb{P}(E_T).$$

而 E_H 中的元素可以用如下方法不重不漏地构造出来: 首先从 $(\omega_1, \dots, \omega_{2n-k})$ 中取出 n 个分量并将它们的值赋为 H , 其余 $n - k$ 个分量赋值为 T ; 再令 $\omega_{2n-k+1} = H$; 最后依次对 $\omega_i, i > 2n - k + 1$ 赋值 H 或 T . 由乘法公式与排列数公式可得 E_H 的元素个数为

$$\binom{2n-k}{n} \cdot 2^k$$

故

$$\mathbb{P}(E_H) = \binom{2n-k}{n} \cdot 2^k \cdot \frac{1}{2^{2n+1}} = \binom{2n-k}{n} \cdot \frac{1}{2^{2n-k+1}},$$

由对称性可得 E_T 与 E_H 包含相同多的元素, 故

$$\mathbb{P}(E_T) = \binom{2n-k}{n} \cdot \frac{1}{2^{2n-k+1}}.$$

最终有

$$\mathbb{P}(E) = \binom{2n-k}{n} \cdot \frac{1}{2^{2n-k}}. \quad \blacksquare$$

1.6 条件概率的初步介绍

1.6.1 条件概率的定义

相当多的随机试验具有阶段性的特点, 即整个试验可以分为多个阶段, 而当前阶段执行的后果会依赖于其它一些阶段的执行情况. 对于这种多阶段性的随机试验, 我们往往会面临如下两类问题:

1. 对于多阶段的随机试验, 在试验开始之前我们可能对最终结果有一个粗略的预测, 但随着试验的进行, 每完成一阶段都会获得部分观测信息. 我们能否用这些观测信息, 来修正我们对最终结果的预测?
2. 多阶段的随机试验可能难以一次性进行整体的概率建模, 但在划分阶段后, 我们就可以在已知前 $k-1$ 个阶段执行情况条件下对第 k 个阶段进行建模. 那么我们应当如何将这些分阶段的概率模型进行整合, 从而得到整个随机试验的概率模型?

对于主观概率, 也有与之类似的问题需要解决, 包括如何利用新得到的知识或信息更新主观概率等. 为解决上述问题, 我们需要引入条件概率的概念. 本节中, 我们首先考虑一个简单的情形: 假设已知一个概率大于 0 的事件 F 发生了, 我们希望把原来的概率测度 $\mathbb{P}$ 更新为一个新的概率测度 $\mathbb{P}_F$ (暂且将其称为条件概率测度). 我们要求这个条件概率测度应具有如下性质:

1. $\mathbb{P}_F(F) = 1$;
2. 若事件 $E_1, E_2 \subseteq F$ 且 $\mathbb{P}_F(E_2) > 0$, 则 $\mathbb{P}_F(E_1)/\mathbb{P}_F(E_2) = \mathbb{P}(E_1)/\mathbb{P}(E_2)$.

这两个性质直观上看是比较自然的: 已知 F 发生的情况下, 自然应当把 F 的概率更新为 1; 而若事件 E_1 与 E_2 都是 F 的子集 (也就是说不存在 F 不发生但 E_1 或 E_2 发生的情况), 那么已知 F 发生的情况下 E_1 与 E_2 的条件概率之比应当与之前保持一致. 现任取一事件 E , 则根据第一个性质有

$$\mathbb{P}_F(E \cap F^c) \leq \mathbb{P}_F(F^c) = 1 - \mathbb{P}_F(F) = 0,$$

从而由概率的可加性可得到

$$\mathbb{P}_F(E) = \mathbb{P}_F(E \cap F) + \mathbb{P}_F(E \cap F^c) = \mathbb{P}_F(E \cap F),$$

接下来再根据第二个性质并注意到 $E \cap F \subseteq F$, 可得

$$\frac{\mathbb{P}_F(E \cap F)}{\mathbb{P}_F(F)} = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)},$$

综合以上结果即可算得

$$\mathbb{P}_F(E) = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)}.$$

由此我们做出如下定义:

定义 1.3. 设 E, F 为两个事件, 且 $\mathbb{P}(F) > 0$. 我们把在事件 F 发生的条件下事件 E 的**条件概率** (conditional probability) 定义为

$$\mathbb{P}(E|F) = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)}. \quad (1.1)$$

需要注意的是, 若 $\mathbb{P}(F) = 0$, 则条件概率 $\mathbb{P}(E|F)$ 一般来说是没有定义的.

例 1.10 (古典概型中的条件概率). 设 Ω 为样本空间, $\mathbb{P}$ 为 Ω 上的古典概型, 事件 F 满足 $\mathbb{P}(F) > 0$. 则对任意事件 E , 有

$$\mathbb{P}(E|F) = \frac{|E \cap F|}{|F|} = \sum_{\omega \in E \cap F} \frac{1}{|F|}.$$

换句话说, $\mathbb{P}(E|F)$ 等于把集合 E 中不属于 F 的元素取掉以后, 剩下的元素在 F 的元素中所占的比例. 这说明对于古典概型, 把 F 发生的条件下 E 的条件概率定义为 $\mathbb{P}(E \cap F)/\mathbb{P}(F)$ 是符合直观的. ■

以下命题指出, 若固定事件 F 并把条件概率 $\mathbb{P}(E|F)$ 看成 E 的函数, 则它的确给出了一个概率测度, 且符合本节一开始列出的条件概率测度应当具备的两条性质.

命题 1.5. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, 事件 F 满足 $\mathbb{P}(F) > 0$. 令

$$\mathbb{P}_F(E) = \mathbb{P}(E|F), \quad \forall E \in \mathcal{F},$$

则 $\mathbb{P}_F$ 给出了事件域 $\mathcal{F}$ 上的一个概率测度, 且满足

1. $\mathbb{P}_F(F) = 1$;
2. 若 $E_1, E_2 \subseteq F$ 且 $\mathbb{P}_F(E_2) > 0$, 则 $\mathbb{P}_F(E_1)/\mathbb{P}_F(E_2) = \mathbb{P}(E_1)/\mathbb{P}(E_2)$.

证明. 显然有 $\mathbb{P}_F(\Omega) = 1$. 对任意事件 E , 不难由 $0 \leq \mathbb{P}(E \cap F) \leq \mathbb{P}(F)$ 得到 $0 \leq \mathbb{P}_F(E) \leq 1$. 现取 $E_1, E_2, \dots$ 为一列两两互斥的事件, 则对任意 $i \neq j$ 有

$$(E_i \cap F) \cap (E_j \cap F) = (E_i \cap E_j) \cap F = \emptyset,$$

故

$$\begin{aligned}
 \mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i \middle| F\right) &= \frac{1}{\mathbb{P}(F)} \mathbb{P}\left(\left(\bigcup_{i=1}^{\infty} E_i\right) \cap F\right) \\
 &= \frac{1}{\mathbb{P}(F)} \mathbb{P}\left(\bigcup_{i=1}^{\infty} (E_i \cap F)\right) \\
 &= \frac{1}{\mathbb{P}(F)} \sum_{i=1}^{\infty} \mathbb{P}(E_i \cap F) \\
 &= \frac{1}{\mathbb{P}(F)} \sum_{i=1}^{\infty} \mathbb{P}(E_i | F) \mathbb{P}(F) = \sum_{i=1}^{\infty} \mathbb{P}(E_i | F),
 \end{aligned}$$

其中第二步利用了并集与交集运算的分配律, 第三步利用了 $\mathbb{P}$ 的可数可加性.

$\mathbb{P}_F$ 满足的几条性质可直接从条件概率的定义得到. □

命题 1.5 意味着, 在一个随机试验中, 若我们知道某个事件 F 已经发生了 (要求 $\mathbb{P}(F) > 0$), 则可以把原来的概率测度 $\mathbb{P}$ 替换为条件概率测度 $\mathbb{P}(\cdot | F)$ 来帮助我们修正对随机试验最终结果的预测.

例 1.11 (Boy or girl paradox). 你知道你的邻居有两个小孩, 但一开始并不知道他们的性别. 现考虑如下两个场景:

1. 有一天, 你在和物业人员交谈时得知, 邻居的两个小孩中至少有一个男孩, 但除此以外未得到其它信息.
2. 有一天, 你在小区里看到你的邻居带着一个男孩出来拿快递. 通过交谈得知, 你的邻居今天是以随机的方式等可能地选了一个小孩出来拿快递.

在上述两个场景下, 试分别求邻居的两个小孩都是男孩的概率 (忽略男女性别在出生率上的差异).

上述问题要让我们求的是已知部分信息之后的条件概率. 我们对两个场景进行分别建模. 对于邻居的两个孩子, 将用第一个指代年龄较大的孩子, 用第二个指代年龄较小的孩子.

1. 对于场景一, 除了邻居两个小孩的性别具有随机性外, 不再具有其它的随机性, 故取样本空间为

$$\begin{aligned}
 \Omega &= \{(\omega_1, \omega_2) \mid \omega_1, \omega_2 \in \{\text{男}, \text{女}\}\} \\
 &= \{\text{男}, \text{女}\} \times \{\text{男}, \text{女}\},
 \end{aligned}$$

其中 $(\omega_1, \omega_2) \in \Omega$ 的两个分量 ω_1 与 ω_2 分别表示第一个与第二个小孩的性别. 由于

样本空间 Ω 为有限集, 且在忽略男女出生率差别的假设下, Ω 中的任意一个结果都不比其它结果更特殊, 故可取 $\mathbb{P}$ 为 Ω 上的古典概型. 令 E 表示“两个小孩都是男孩”这一事件, F 表示“两个小孩里至少有一个是男孩”这一事件, 则 E 与 F 作为 Ω 的子集由

$$E = \{(\text{男}, \text{男})\} \quad \text{与} \quad F = \{(\text{男}, \text{男}), (\text{男}, \text{女}), (\text{女}, \text{男})\}$$

给出, 故待求的条件概率 $\mathbb{P}(E|F)$ 为

$$\mathbb{P}(E|F) = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)} = \frac{\mathbb{P}(\{(\text{男}, \text{男})\})}{\mathbb{P}(\{(\text{男}, \text{男}), (\text{男}, \text{女}), (\text{女}, \text{男})\})} = \frac{1}{3}.$$

2. 对于场景二, 除了小孩性别的随机性外, 还需要考虑带哪个小孩出来拿快递的随机性. 可令样本空间为

$$\begin{aligned} \Omega' &= \{(\omega_1, \omega_2, k) \mid \omega_1, \omega_2 \in \{\text{男}, \text{女}\}, k \in \{1, 2\}\} \\ &= \{\text{男}, \text{女}\} \times \{\text{男}, \text{女}\} \times \{1, 2\}, \end{aligned}$$

其中 $(\omega_1, \omega_2, k) \in \Omega'$ 多出来的第三个分量 k 表示邻居带出来的是第几个小孩. 同样取 $\mathbb{P}'$ 为 Ω' 上的古典概型. 令 E' 表示“两个小孩都是男孩”这一事件, F' 表示“当天邻居带出来的小孩是男孩”这一事件, 则 E' 与 F' 作为 Ω' 的子集由

$$\begin{aligned} E' &= \{(\text{男}, \text{男}, 1), (\text{男}, \text{男}, 2)\}, \\ F' &= \{(\text{男}, \text{男}, 1), (\text{男}, \text{女}, 1), (\text{男}, \text{男}, 2), (\text{女}, \text{男}, 2)\} \end{aligned}$$

给出. 待求的条件概率 $\mathbb{P}'(E'|F')$ 即为

$$\begin{aligned} \mathbb{P}'(E'|F') &= \frac{\mathbb{P}'(E' \cap F')}{\mathbb{P}'(F')} \\ &= \frac{\mathbb{P}'(\{(\text{男}, \text{男}, 1), (\text{男}, \text{男}, 2)\})}{\mathbb{P}'(\{(\text{男}, \text{男}, 1), (\text{男}, \text{女}, 1), (\text{男}, \text{男}, 2), (\text{女}, \text{男}, 2)\})} \\ &= \frac{1}{2}. \end{aligned}$$

上述问题有趣的一点是, 在两个场景之中, 你根据已知的信息都可以得到“两个小孩中至少有一个男孩”的结论, 然而最终算得的条件概率却不一致. 这说明, 为了得出确切的条件概率, 仅仅知道“两个小孩中至少有一个男孩”是不够的, 我们还需要明确具体是通过怎样的过程得到这个结论的, 不同的过程甚至需要用不同的概率空间进行建模. 这个问题也被称为 boy or girl paradox.

注: 本例中的概率应理解为主观概率; 见 1.3.1 小节的说明. ■

1.6.2 乘法公式与全概率公式

虽然在式 (1.1) 中, 我们用 (非条件) 概率 $\mathbb{P}(\cdot)$ 来定义条件概率 $\mathbb{P}(\cdot|F)$, 但许多情况下 $\mathbb{P}(\cdot|F)$ 反而是更容易建模的量, 而 (非条件) 概率则是需要计算的量, 此时下面的两个定理就变得非常有用了.

定理 1.6. 设事件 F 满足 $\mathbb{P}(F) > 0$, 则对任意事件 E , 有

$$\mathbb{P}(E \cap F) = \mathbb{P}(E|F) \mathbb{P}(F). \quad (1.2a)$$

更一般地, 设 $E_1, \dots, E_n$ 为 n 个事件, 且 $\mathbb{P}(E_1 \cap \dots \cap E_{n-1}) > 0$, 则

$$\begin{aligned} & \mathbb{P}(E_1 \cap \dots \cap E_n) \\ &= \mathbb{P}(E_n | E_1 \cap \dots \cap E_{n-1}) \mathbb{P}(E_{n-1} | E_1 \cap \dots \cap E_{n-2}) \cdots \mathbb{P}(E_2 | E_1) \mathbb{P}(E_1). \end{aligned} \quad (1.2b)$$

证明. 式 (1.2a) 是条件概率定义的直接推论. 而式 (1.2b) 则可以由式 (1.2a) 不断递推得到:

$$\begin{aligned} & \mathbb{P}(E_1 \cap \dots \cap E_n) \\ &= \mathbb{P}(E_n | E_1 \cap \dots \cap E_{n-1}) \mathbb{P}(E_1 \cap \dots \cap E_{n-1}) \\ &= \mathbb{P}(E_n | E_1 \cap \dots \cap E_{n-1}) \mathbb{P}(E_{n-1} | E_1 \cap \dots \cap E_{n-2}) \mathbb{P}(E_1 \cap \dots \cap E_{n-2}) \\ &= \cdots \\ &= \mathbb{P}(E_n | E_1 \cap \dots \cap E_{n-1}) \mathbb{P}(E_{n-1} | E_1 \cap \dots \cap E_{n-2}) \cdots \mathbb{P}(E_2 | E_1) \mathbb{P}(E_1), \end{aligned}$$

其中 $\mathbb{P}(E_1 \cap \dots \cap E_i) > 0, i = 1, \dots, n-2$ 可由 $\mathbb{P}(E_1 \cap \dots \cap E_{n-1}) > 0$ 保证. $\square$

定理 1.7. 设事件 $F_1, \dots, F_n$ 两两互斥, $\bigcup_{i=1}^n F_i$ 为必然事件, 且对每个 $i = 1, \dots, n$ 均有 $\mathbb{P}(F_i) > 0$. 则对任意事件 E , 有

$$\mathbb{P}(E) = \sum_{i=1}^n \mathbb{P}(E|F_i) \mathbb{P}(F_i). \quad (1.3)$$

证明. 由于 $F_1, \dots, F_n$ 两两互斥, 可知 $i \neq j$ 时 $(E \cap F_i) \cap (E \cap F_j) = E \cap (F_i \cap F_j) = \emptyset$, 即 $E \cap F_1, \dots, E \cap F_n$ 也两两互斥. 而由 $F_1 \cup \dots \cup F_n$ 为必然事件以及并集与交集运算的分配律可得

$$E = E \cap (F_1 \cup \dots \cup F_n) = (E \cap F_1) \cup \dots \cup (E \cap F_n).$$

故可将概率的可加性用于事件组 $E \cap F_1, \dots, E \cap F_n$ 并得到

$$\mathbb{P}(E) = \sum_{i=1}^n \mathbb{P}(E \cap F_i),$$

最后由式 (1.2a) 即得待证等式. $\square$

式 (1.2) 被称为条件概率的**乘法公式**, 而式 (1.3) 则被称为**全概率公式**, 它们为解决本节开头提出的第二类问题 (即如何将分阶段的概率模型进行整合) 奠定了基础. 全概率公式的一个特例是

$$\mathbb{P}(E) = \mathbb{P}(E|F)\mathbb{P}(F) + \mathbb{P}(E|F^c)\mathbb{P}(F^c),$$

其中需假设 $0 < \mathbb{P}(F) < 1$.

例 1.12. 假设有某个传感器需要将其测量数据上传至服务器, 数据以 0、1 两种符号构成的符号串表示. 设符号串中的每个符号在传输时需要依次经过三个二进制信道, 每个信道在传输符号 0 时有 0.05 的概率发生错误变为 1, 而传输符号 1 时有 0.1 的概率发生错误变为 0 (如图 1.1). 则从传感器发出一个符号 0 能够被服务器正确接收的概率是多少?




图 1.1: 例 1.12 中的二进制信道图示.

我们用 E_i 表示符号 0 经过 i 个信道传输后还保持为 0, 则待求概率为 $\mathbb{P}(E_3)$, 而由全概率公式, 有

$$\begin{aligned} \mathbb{P}(E_3) &= \mathbb{P}(E_3|E_2)\mathbb{P}(E_2) + \mathbb{P}(E_3|E_2^c)\mathbb{P}(E_2^c) \\ &= 0.95\mathbb{P}(E_2) + 0.1\mathbb{P}(E_2^c). \end{aligned}$$

而对于 $\mathbb{P}(E_2)$, 同样可由全概率公式得到

$$\begin{aligned} \mathbb{P}(E_2) &= \mathbb{P}(E_2|E_1)\mathbb{P}(E_1) + \mathbb{P}(E_2|E_1^c)\mathbb{P}(E_1^c) \\ &= 0.95\mathbb{P}(E_1) + 0.1\mathbb{P}(E_1^c). \end{aligned}$$

$\mathbb{P}(E_2^c)$ 则满足 $\mathbb{P}(E_2^c) = 1 - \mathbb{P}(E_2)$. 再将 $\mathbb{P}(E_1) = 0.95$, $\mathbb{P}(E_1^c) = 0.05$ 代入以上几式, 即可求得 $\mathbb{P}(E_3) = 0.871375$.

同理, 可求得传感器发出符号 1 能被服务器正确接收的概率是 0.74275. ■

例 1.13 (Pólya 罐子模型). 设一个罐子中一开始有 x 个标号为 1 的球与 y 个标号为 0 的球. 之后我们重复如下过程: 从罐子中随机取一个球, 记下它的标号, 将这个球放回的同时将 c 个与之标号一样的球加入罐子当中. 则经过 n 轮取球和放球的操作后, 罐子中有 $x + kc$ 个标号 1 的球与 $b + (n - k)c$ 个标号 0 的球的概率是多少?

首先用 $E_{n,k}$ 表示事件 “ n 轮过后, 罐子中有 $r + kc$ 个标号 1 的球与 $b + (n - k)c$ 个标号 0 的球”, 并对任意 $c_1, \dots, c_n \in \{0, 1\}$, 用 $F_{c_1, \dots, c_n}$ 表示事件 “ n 轮中抽出的球的标号依次为 $c_1, \dots, c_n$ ”, 则由概率的可加性可得

$$\mathbb{P}(E_{n,k}) = \sum_{\substack{c_1, \dots, c_n \in \{0, 1\}: \\ c_1 + \dots + c_n = k}} \mathbb{P}(F_{c_1, \dots, c_n}).$$

接下来, 设 $c_1 + \dots + c_n = k$, 我们用乘法公式计算 $\mathbb{P}(F_{c_1, \dots, c_n})$:

$$\begin{aligned} \mathbb{P}(F_{c_1, \dots, c_n}) &= \mathbb{P}(F_{c_1, \dots, c_n} | F_{c_1, \dots, c_{n-1}}) \mathbb{P}(F_{c_1, \dots, c_{n-1}}) \\ &= \begin{cases} \frac{x + (k-1)c}{x + y + (n-1)c} \mathbb{P}(F_{c_1, \dots, c_{n-1}}), & \text{若 } c_n = 1, \\ \frac{y + (n-k-1)c}{x + y + (n-1)c} \mathbb{P}(F_{c_1, \dots, c_{n-1}}), & \text{若 } c_n = 0. \end{cases} \end{aligned} \quad (1.4)$$

我们对上式做一些简单的解释: 若 $c_n = 1$, 因 $c_1 + \dots + c_n = k$, 故前 $n-1$ 轮中有 $k-1$ 轮抽出了标号为 1 的球, 因而在 $F_{c_1, \dots, c_{n-1}}$ 的条件下 $F_{c_1, \dots, c_n}$ 的条件概率即为 $x + y + (n-1)c$ 个球中有 $x + (k-1)c$ 个标号为 1 时抽出标号为 1 的球的概率; $c_n = 0$ 的情况类似. 而 $n = 1$ 时则有

$$\mathbb{P}(F_{c_1}) = \begin{cases} \frac{x}{x + y}, & \text{若 } c_1 = 1, \\ \frac{y}{x + y}, & \text{若 } c_1 = 0. \end{cases} \quad (1.5)$$

利用式 (1.4) 与 (1.5) 进行若干步递推后不难发现, $\mathbb{P}(F_{c_1, \dots, c_n})$ 的值仅取决于 k , 且它等于

$$\mathbb{P}(F_{c_1, \dots, c_n}) = \frac{\prod_{i=0}^{k-1} (x + ic) \prod_{i=0}^{n-k-1} (y + ic)}{\prod_{i=0}^{n-1} (x + y + ic)}$$

(式中连乘的上标若小于下标则该连乘的结果取为 1). 最后可得

$$\begin{aligned}\mathbb{P}(E_{n,k}) &= \sum_{\substack{c_1, \dots, c_n \in \{0,1\}: \\ c_1 + \dots + c_n = k}} \frac{\prod_{i=0}^{k-1} (x + ic) \prod_{i=0}^{n-k-1} (y + ic)}{\prod_{i=0}^{n-1} (x + y + ic)} \\ &= \binom{n}{k} \frac{\prod_{i=0}^{k-1} (x + ic) \prod_{i=0}^{n-k-1} (y + ic)}{\prod_{i=0}^{n-1} (x + y + ic)},\end{aligned}$$

其中最后一步我们利用了这样一个事实: 方程 $c_1 + \dots + c_n = k$ 的满足 $c_1, \dots, c_n \in \{0, 1\}$ 的解总共有 $\binom{n}{k}$ 组. ■

1.6.3 贝叶斯公式

定理 1.8. 设事件 $F_1, \dots, F_n$ 两两互斥, $\bigcup_{i=1}^n F_i$ 为必然事件, 且对每个 $i = 1, \dots, n$ 均有 $\mathbb{P}(F_i) > 0$. 则对任意概率大于 0 的事件 E , 有

$$\mathbb{P}(F_i | E) = \frac{\mathbb{P}(E | F_i) \mathbb{P}(F_i)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E | F_i) \mathbb{P}(F_i)}{\sum_{j=1}^n \mathbb{P}(E | F_j) \mathbb{P}(F_j)}, \quad \forall i = 1, \dots, n. \quad (1.6)$$

证明. 由条件概率的定义可得

$$\mathbb{P}(F_i | E) = \frac{\mathbb{P}(E \cap F_i)}{\mathbb{P}(E)}.$$

将乘法公式用在上式的分子部分即可得到式 (1.6) 的第一个等号, 再用全概率公式处理分母部分即可得到式 (1.6) 的第二个等号. □

定理 1.8 通常被称为**贝叶斯定理** (Bayes' theorem), 等式 (1.6) 被称为**贝叶斯公式**或**逆概率公式**, 其中概率 $\mathbb{P}(F_i)$ 通常被称为事件 F_i 的**先验概率** (prior probability), $\mathbb{P}(F_i | E)$ 则被称为 (事件 E 发生后) F_i 的**后验概率** (posterior probability). 贝叶斯公式的一个特例是

$$\mathbb{P}(F | E) = \frac{\mathbb{P}(E | F) \mathbb{P}(F)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E | F) \mathbb{P}(F)}{\mathbb{P}(E | F) \mathbb{P}(F) + \mathbb{P}(E | F^c) \mathbb{P}(F^c)},$$

其中需假设 $\mathbb{P}(E) > 0$ 以及 $0 < \mathbb{P}(F) < 1$.

贝叶斯公式常用来解决如下类问题: 设某个随机试验分为两个阶段, 第一个阶段当中事件 $F_1, \dots, F_n$ 有且仅有一个发生, 而第二阶段的试验结果则依赖于 $F_1, \dots, F_n$ 当中具体是哪个事件发生, 现在由于某些原因我们无法观测第一阶段 $F_1, \dots, F_n$ 当中到底哪个发生了, 但可以观测到第二阶发生了事件 E , 则应当如何用这个第二阶段获得的信息反过来更新第一阶段中事件 $F_1, \dots, F_n$ 的 (条件) 概率, 也就是利用观测到的第二阶段的信息为未被观测到的第一阶段到底发生哪个事件进行概率上的推断.

例 1.14. 假设有一种罕见病, 在人群中的发病率为 10^{-5} . 现在针对这种罕见病开发了一种快速诊断方法, 该方法应用在病患身上时将以 99% 的概率给出阳性结果, 而应用在健康人身上时将以 1% 的概率给出阳性结果. 现假设在人群中随机选择一人并应用这种诊断方法后给出了阳性结果, 试问这个人患病的概率是多少?

我们用事件 E_+ 表示诊断结果为阳性, 事件 H 表示随机选择的这个人患病. 则由贝叶斯公式可得

$$\begin{aligned}\mathbb{P}(H|E_+) &= \frac{\mathbb{P}(E_+|H)\mathbb{P}(H)}{\mathbb{P}(E_+|H)\mathbb{P}(H) + \mathbb{P}(E_+|H^c)\mathbb{P}(H^c)} \\ &= \frac{0.99 \cdot 10^{-5}}{0.99 \cdot 10^{-5} + 0.01 \cdot (1 - 10^{-5})} < 0.1\%.\end{aligned}$$

以上计算说明, 这种快速诊断方法应用在一般人群中误报阳性的几率非常大, 因此是有非常大缺陷的.

接下来假设我们想要对该诊断方法进行改进, 使其应用在病患身上时的阳性率依然保持在 99%, 但应用在健康人身上时的阳性率下降到 α . 则此时有

$$\mathbb{P}(H|E_+) = \frac{0.99 \cdot 10^{-5}}{0.99 \cdot 10^{-5} + \alpha \cdot (1 - 10^{-5})} \approx \frac{10^{-5}}{10^{-5} + \alpha}.$$

由上式可看出, 若要使得 $\mathbb{P}(H|E_+)$ 提升到 50% 以上, 则要求 $\alpha \lesssim 10^{-5}$; 若要使得 $\mathbb{P}(H|E_+)$ 提升到 95% 以上, 则要求 $\alpha \lesssim 5 \times 10^{-7}$. ■

例 1.15 (三门问题, Monty Hall Problem). 美国曾有一电视游戏节目, 在该游戏节目中, 参赛者会看见三扇门, 其中一扇门的背后放有一辆汽车, 另外两扇门背后则都放着山羊. 参赛者首先选择一扇门, 随后节目主持人会在未选的两扇门中随机开启一扇背后是山羊的门, 并让参赛者决定是否改选另一扇未开启的门. 在参赛者做出最终决定后, 若被选的门背后是汽车, 则参赛者将赢得这辆汽车, 否则会输掉游戏. 那么在这个游戏中, 参赛者是否应该改选另一扇未开启的门?

简单起见, 假设汽车与山羊均随机放置在门背后. 现假设参赛者选择 1 号门, 而主持人打开了 3 号门. 则

$$\begin{aligned}&\mathbb{P}(\text{汽车在 1 号门} | \text{主持人打开 3 号门}) \\ &= \frac{\mathbb{P}(\text{主持人打开 3 号门} | \text{汽车在 1 号门}) \mathbb{P}(\text{汽车在 1 号门})}{\sum_{i=1}^3 \mathbb{P}(\text{主持人打开 3 号门} | \text{汽车在 } i \text{ 号门}) \mathbb{P}(\text{汽车在 } i \text{ 号门})} \\ &= \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2} \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3}} = \frac{1}{3},\end{aligned}$$

而

$$\begin{aligned} & \mathbb{P}(\text{汽车在 2 号门} | \text{主持人打开 3 号门}) \\ &= \frac{\mathbb{P}(\text{主持人打开 3 号门} | \text{汽车在 2 号门}) \mathbb{P}(\text{汽车在 2 号门})}{\sum_{i=1}^3 \mathbb{P}(\text{主持人打开 3 号门} | \text{汽车在 } i \text{ 号门}) \mathbb{P}(\text{汽车在 } i \text{ 号门})} \\ &= \frac{1 \cdot \frac{1}{3}}{\frac{1}{2} \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3}} = \frac{2}{3}, \end{aligned}$$

故这种情况下参赛者应改选 2 号门. 由问题的对称性可知参赛者总是应该改选另一扇未开启的门. ■

1.7 事件的独立性

定义 1.4. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, E, F 为 $\mathcal{F}$ 中的两个事件. 若

$$\mathbb{P}(E \cap F) = \mathbb{P}(E) \mathbb{P}(F),$$

则称 E 与 F 相互**独立** (independent).

不难看出, 当 $\mathbb{P}(F) > 0$ 时, $\mathbb{P}(E \cap F) = \mathbb{P}(E) \mathbb{P}(F)$ 等价于 $\mathbb{P}(E|F) = \mathbb{P}(E)$, 因而 E 与 F 相互独立可以直观解释为事件 F 的发生并不影响事件 E 的概率. 同理, 当 $\mathbb{P}(E) > 0$ 时, E 与 F 相互独立可以直观解释为事件 E 的发生并不影响事件 F 的概率.

例 1.16 (古典概型中的独立性). 设一个随机试验总共有两个阶段, 其中第一个阶段总共有 m 种可能结果, 第二个阶段总共有 n 种可能的结果, 且每种结果的可能性相同. 对于这样的随机试验, 我们将第一阶段的结果用 $1, \dots, m$ 标号, 将第二阶段的结果用 $1, \dots, n$ 标号, 则可以取样本空间为

$$\begin{aligned} \Omega &= \{(\omega_1, \omega_2) \mid \omega_1 \in \{1, \dots, m\}, \omega_2 \in \{1, \dots, n\}\} \\ &= \{1, \dots, m\} \times \{1, \dots, n\}, \end{aligned}$$

并取 $\mathbb{P}$ 为 Ω 上的古典概型.

现对任意 $A \subseteq \{1, \dots, m\}$ 与 $B \subseteq \{1, \dots, n\}$, 令

$$E_{1,A} = \{(\omega_1, \omega_2) \mid \omega_1 \in A\} = \{\text{第一个阶段的结果属于集合 } A\},$$

$$E_{2,B} = \{(\omega_1, \omega_2) \mid \omega_2 \in B\} = \{\text{第二个阶段的结果属于集合 } B\}.$$

则

$$\mathbb{P}(E_{1,A} \cap E_{2,B}) = \mathbb{P}(\{(\omega_1, \omega_2) \mid \omega_1 \in A, \omega_2 \in B\}) = \mathbb{P}(A \times B) = \frac{|A| \cdot |B|}{m \cdot n},$$

而

$$\mathbb{P}(E_{1,A}) = \frac{|A| \cdot n}{m \cdot n} = \frac{|A|}{m}, \quad \mathbb{P}(E_{2,B}) = \frac{m \cdot |B|}{m \cdot n} = \frac{|B|}{n},$$

故

$$\mathbb{P}(E_{1,A} \cap E_{2,B}) = \mathbb{P}(E_{1,A}) \mathbb{P}(E_{2,B}).$$

以上结果可以总结为如下结论: 设一个两阶段的随机试验服从古典概型, 且第二阶段可能发生的结果与第一阶段的结果无关, 那么当事件 E 发生与否完全取决于第一阶段的结果, 且事件 F 发生与否完全取决于第二阶段的结果时, E 与 F 是相互独立的.

反过来, 对于一个两阶段的随机试验, 若第一阶段和第二阶段的结果各自均为有限个且等概率的, 且声称第一阶段与第二阶段相互独立, 则此时概率空间的标准取法如下: 取样本空间为 $\Omega_1 \times \Omega_2$, 其中 Ω_1 和 Ω_2 分别为第一阶段和第二阶段的所有可能结果构成的集合, 并取概率测度 $\mathbb{P}$ 为 $\Omega_1 \times \Omega_2$ 上的古典概型⁸. ■

例 1.17. 设集合 S 包含 n 个元素 ($n \geq 1$), 从 S 的 2^n 个子集中依次等概率地选出两个子集 A, B , 且 A 与 B 的选取相互独立. 令 E 表示事件“ A 是 B 的子集”, 则 $\mathbb{P}(E)$ 是多少?

首先明确此问题的概率空间. 根据例 1.16 中的讨论, 我们将样本空间 Ω 取为

$$\Omega = 2^S \times 2^S = \{(A, B) \mid A \subseteq S, B \subseteq S\},$$

并取 $\mathbb{P}$ 为 Ω 上的古典概型. 此时事件 E 即可表示为

$$E = \{(A, B) \in \Omega \mid A \subseteq B\}.$$

为了计算 E , 我们考虑按如下方式将 E 表示为若干个互斥事件的并:

$$E = \bigcup_{B' \in 2^S} \{(A, B') \mid A \subseteq S\} = \bigcup_{k=0}^n \bigcup_{\substack{B' \in 2^S, \\ |B'|=k}} \{(A, B') \mid A \subseteq S\}.$$

之所以对 E 进行这样的分解表示, 是因为固定 $B' \subseteq S$ 并且已知 $|B'| = k$ (即 B' 恰好包含 k 个元素) 的情况下, 集合 $\{(A, B') \mid A \subseteq S\}$ 的元素个数很好求: 它就等于 B' 的子

⁸ (*) 这种标准取法可以进一步推广到两个阶段相互独立但各自的结果并非有限或等概率的情形, 感兴趣且学有余力的读者可自行查阅乘积概率空间、乘积测度相关的内容.

集个数, 即 2^k . 根据概率的可加性, 可得

$$\begin{aligned}\mathbb{P}(E) &= \sum_{k=0}^n \sum_{\substack{B' \in 2^S, \\ |B'|=k}} \mathbb{P}(\{(A, B') \mid A \subseteq S\}) \\ &= \sum_{k=0}^n \sum_{\substack{B' \in 2^S, \\ |B'|=k}} \frac{2^k}{4^n} = \frac{1}{4^n} \sum_{k=0}^n \binom{n}{k} 2^k \\ &= \frac{1}{4^n} \cdot (1+2)^n = \left(\frac{3}{4}\right)^n,\end{aligned}$$

其中第三个等号是因为满足 $|B'| = k$ 的 S 的子集 B' 共有 $\binom{n}{k}$ 个, 而第四个等号则利用了二项式定理.

思考: 不进行具体计算, 你能否直接从上面的结果看出事件 “ $A \cap B$ 为空集” 的概率? ■

接下来我们将独立性这一概念推广到多个事件上.

定义 1.5. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, $\mathcal{I}$ 为一非空集合, 且每个 $i \in \mathcal{I}$ 对应于一个 $\mathcal{F}$ 中的事件 E_i . 若对 $\mathcal{I}$ 的任意非空有限子集 $\mathcal{J}$, 都有

$$\mathbb{P}\left(\bigcap_{j \in \mathcal{J}} E_j\right) = \prod_{j \in \mathcal{J}} \mathbb{P}(E_j),$$

则称事件族 $\{E_i\}_{i \in \mathcal{I}}$ 中的事件**相互独立** (mutually independent),

例如, 设 E, F, G 为三个事件, 则这三个事件相互独立的充要条件是如下四个等式成立:

$$\begin{aligned}\mathbb{P}(E \cap F) &= \mathbb{P}(E) \mathbb{P}(F), & \mathbb{P}(E \cap G) &= \mathbb{P}(E) \mathbb{P}(G), \\ \mathbb{P}(F \cap G) &= \mathbb{P}(F) \mathbb{P}(G), & \mathbb{P}(E \cap F \cap G) &= \mathbb{P}(E) \mathbb{P}(F) \mathbb{P}(G).\end{aligned}$$

例 1.16 的结论可推广到多阶段的随机试验中: 设一个 r 阶段的随机试验服从古典概型, 且每个阶段可能发生的结果与其它阶段的结果均无关, 那么给定一组事件 $E_1, \dots, E_r$, 当各个事件 E_i 发生与否完全取决于第 i 阶段的结果时, 这组事件 $E_1, \dots, E_r$ 是相互独立的. 该结论的证明留给读者自行完成.

例 1.18 (本例改编自 [6] 第一章的习题 31.c). 仍考虑例 1.12 中传感器向服务器上传数据的问题, 则传感器与服务器之间的信道可以等效成图 1.2 所示, 其中我们用 p_0 表示




图 1.2: 例 1.18 中的等效信道图示, 其中 $p_0 = 0.871375$, $p_1 = 0.74275$.

符号 0 传输不出错的概率, 用 p_1 表示符号 1 传输不出错的概率. 我们进一步假设在依次传输多个符号时, 各个符号是否传输错误是相互独立的. 为了提升传输的正确率, 我们考虑如下策略: 传感器每次都会将同一个符号连续发送 3 次, 而服务器在收到 3 个依次传输的符号后, 找出其中占多数的符号作为传输的结果. 例如, 若服务器收到 010, 则认为传感器发送的是符号 0. 在这种策略下, 符号 0 能够被正确传输的概率是多少?

用 G 表示服务器最终能正确接收传感器发送的符号 0, 用 $F_i, i = 1, 2, 3$ 表示符号 0 在第 i 次传输时没有出现错误, 则有

$$G = (F_1 \cap F_2 \cap F_3) \cup (F_1^c \cap F_2 \cap F_3) \cup (F_1 \cap F_2^c \cap F_3) \cup (F_1 \cap F_2 \cap F_3^c),$$

从而由概率的有限可加性可得

$$\mathbb{P}(F) = \mathbb{P}(F_1 \cap F_2 \cap F_3) + \mathbb{P}(F_1^c \cap F_2 \cap F_3) + \mathbb{P}(F_1 \cap F_2^c \cap F_3) + \mathbb{P}(F_1 \cap F_2 \cap F_3^c).$$

而由 F_1, F_2, F_3 相互独立, 可得

$$\mathbb{P}(F_1 \cap F_2 \cap F_3) = \mathbb{P}(F_1) \mathbb{P}(F_2) \mathbb{P}(F_3) = p_0^3,$$

而

$$\mathbb{P}(F_1^c \cap F_2 \cap F_3) = \mathbb{P}(F_1^c) \mathbb{P}(F_2) \mathbb{P}(F_3) = (1 - p_0)p_0^2,$$

且同理有 $\mathbb{P}(F_1 \cap F_2^c \cap F_3) = \mathbb{P}(F_1 \cap F_2 \cap F_3^c) = (1 - p_0)p_0^2$. 故

$$\mathbb{P}(G) = p_0^3 + 3(1 - p_0)p_0^2 \approx 0.9546.$$

同理可得, 通过将单个符号重复传输 3 次, 符号 1 被正确传输的概率能被提升至 $p_1^3 + 3(1 - p_1)p_1^2 \approx 0.8355$. ■

1.8 (*) 概率的连续性

概率的连续性是证明概率论中许多重要结论的基本工具, 本节对其进行简要介绍.

定义 1.6. 设 $E_1, E_2, E_3, \dots$ 为一列事件.

1. 若对任意正整数 n , 均有 $E_n \subseteq E_{n+1}$, 则称事件列 $E_1, E_2, E_3, \dots$ 是递增的.

对于递增的事件列 $E_1, E_2, E_3, \dots$, 我们定义其极限为

$$\lim_{n \rightarrow \infty} E_n = \bigcup_{n=1}^{\infty} E_n.$$

2. 若对任意正整数 n , 均有 $E_n \supseteq E_{n+1}$, 则称事件列 $E_1, E_2, E_3, \dots$ 是递减的.

对于递减的事件列 $E_1, E_2, E_3, \dots$, 我们定义其极限为

$$\lim_{n \rightarrow \infty} E_n = \bigcap_{n=1}^{\infty} E_n.$$

接下来的定理指出, 对于递增或递减的事件列, 其概率的极限等于极限的概率, 即取极限与取概率的操作可交换, 从而可以认为概率测度对于递增或递减的事件列具有“连续性”.

定理 1.9. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, $E_1, E_2, E_3, \dots$ 为 $\mathcal{F}$ 中一系列递增或递减的事件, 则

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} E_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(E_n).$$

证明. 首先考虑 $E_1, E_2, E_3, \dots$ 递增的情形. 令

$$F_n = E_n \setminus \bigcup_{i=1}^{n-1} F_i, \quad n = 1, 2, \dots$$

(当 $n = 1$ 时我们取 $\bigcup_{i=1}^{n-1} F_i = \emptyset$), 则不难看出对任意正整数 n , 有

$$\bigcup_{i=1}^n F_i = F_n \cup \bigcup_{i=1}^{n-1} F_i = \left(E_n \setminus \bigcup_{i=1}^{n-1} F_i\right) \cup \bigcup_{i=1}^{n-1} F_i = E_n$$

以及 $F_n = E_n \setminus E_{n-1}$ (这里取 $E_0 = \emptyset$). 从而对于任意正整数 $i < j$, 有

$$\begin{aligned} F_i \cap F_j &= (E_i \setminus E_{i-1}) \cap (E_j \setminus E_{j-1}) \\ &= (E_i \cap E_{i-1}^c) \cap (E_j \cap E_{j-1}^c) \\ &\subseteq E_i \cap E_{j-1}^c = \emptyset, \end{aligned}$$

其中最后一步用到了 $E_i \subseteq E_{j-1}$, 因此 $F_1, F_2, F_3, \dots$ 两两互斥. 此外,

$$\begin{aligned}\bigcup_{n=1}^{\infty} F_n &= \{\omega \in \Omega \mid \text{存在正整数 } n \text{ 使得 } \omega \in E_n \setminus E_{n-1}\} \\ &= \{\omega \in \Omega \mid \text{存在正整数 } n \text{ 使得 } \omega \in E_n\} \\ &= \bigcup_{n=1}^{\infty} E_n = \lim_{n \rightarrow \infty} E_n.\end{aligned}$$

故由概率的可数可加性得

$$\begin{aligned}\mathbb{P}\left(\lim_{n \rightarrow \infty} E_n\right) &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} F_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(F_n) \\ &= \lim_{n \rightarrow \infty} \sum_{i=1}^n \mathbb{P}(F_i) = \lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcup_{i=1}^n F_i\right) = \lim_{n \rightarrow \infty} \mathbb{P}(E_n).\end{aligned}$$

而若 $E_1, E_2, E_3, \dots$ 为递减的事件列, 则不难看出 $E_1^c, E_2^c, E_3^c, \dots$ 递增, 且

$$\lim_{n \rightarrow \infty} E_n = \bigcap_{n=1}^{\infty} E_n = \left(\bigcup_{n=1}^{\infty} E_n^c\right)^c = \left(\lim_{n \rightarrow \infty} E_n^c\right)^c,$$

故由递增情形的结论可得

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} E_n\right) = 1 - \mathbb{P}\left(\lim_{n \rightarrow \infty} E_n^c\right) = 1 - \lim_{n \rightarrow \infty} \mathbb{P}(E_n^c) = \lim_{n \rightarrow \infty} \mathbb{P}(E_n).$$

定理得证. □

1.9 习题

习题 1.1. 任给事件 E, F , 定义 $E \triangle F$ 为“ E 与 F 当中有且仅有一个发生”这一事件.

1. 证明 $E \triangle F = (E \setminus F) \cup (F \setminus E) = (E \cup F) \setminus (E \cap F)$.
2. 证明 $\mathbb{P}(E \triangle F) = \mathbb{P}(E) + \mathbb{P}(F) - 2\mathbb{P}(E \cap F)$.

注: $E \triangle F$ 常被称为 E 与 F 的对称差 (symmetric difference).

习题 1.2. 令 $\Omega = \mathbb{N}$ 以及 $\mathcal{F} = 2^{\mathbb{N}}$. 证明: 不存在定义在 $\mathcal{F}$ 上的概率测度 $\mathbb{P}$, 使得对任意 $i, j \in \mathbb{N}$, 均有 $\mathbb{P}(\{i\}) = \mathbb{P}(\{j\})$. 这意味着我们无法以等可能的方式随机取自然数.

习题 1.3. 设 Ω 为样本空间, $\mathbb{P}$ 为 Ω 上的古典概型, 且事件 $F \in 2^{\Omega}$ 的概率 $\mathbb{P}(F)$ 大于 0. 令映射 $\hat{\mathbb{P}}: 2^F \rightarrow \mathbb{R}$ 为 $\hat{\mathbb{P}}(E) = \mathbb{P}(E|F)$, $\forall E \subseteq F$, 则 $\hat{\mathbb{P}}$ 是否是 F 上的古典概型?

习题 1.4. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, 事件 F, G 满足 $\mathbb{P}(F \cap G) > 0$. 令

$$\mathbb{P}_F(E) = \mathbb{P}(E|F), \quad \forall E \in \mathcal{F}.$$

命题 1.5 指出 $\mathbb{P}_F$ 为定义在 $\mathcal{F}$ 上的一个概率测度. 证明

$$\mathbb{P}_F(E|G) = \mathbb{P}(E|F \cap G), \quad \forall E \in \mathcal{F}.$$

习题 1.5 (辛普森悖论, Simpson's paradox). 设事件 A, B, C 满足

$$\mathbb{P}(A|B \cap C) > \mathbb{P}(A|B^c \cap C) \quad \text{以及} \quad \mathbb{P}(A|B \cap C^c) > \mathbb{P}(A|B^c \cap C^c),$$

则是否有 $\mathbb{P}(A|B) > \mathbb{P}(A|B^c)$? 若是请给出证明, 若否请给出反例.

习题 1.6 (后验概率的序贯更新). 设事件 $F_1, \dots, F_n$ 两两互斥, $\bigcup_{i=1}^n F_i$ 为必然事件, 且对每个 $i = 1, \dots, n$ 均有 $\mathbb{P}(F_i) > 0$. 又假设事件 $E_1, \dots, E_T$ 满足 $E_1 \supseteq E_2 \supseteq \dots \supseteq E_T$ 以及 $\mathbb{P}(E_T) > 0$, 且在某次试验中, 我们观测到 $E_1, E_2, \dots, E_T$ 依次发生. 令

$$P_i(t) = \mathbb{P}(F_i|E_t)$$

表示观测到 E_t 发生时事件 F_i 的后验概率. 证明: 对任意 $i = 1, \dots, n$ 与 $t = 1, \dots, T-1$, 有

$$P_i(t+1) = \frac{\mathbb{P}(E_{t+1}|F_i \cap E_t) P_i(t)}{\sum_{j=1}^n \mathbb{P}(E_{t+1}|F_j \cap E_t) P_j(t)}.$$

习题 1.7. 设 E, F 为两个事件, 证明如下四个命题等价:

1. $\mathbb{P}(E \cap F) = \mathbb{P}(E) \mathbb{P}(F)$, 即 E 与 F 独立.
2. $\mathbb{P}(E^c \cap F) = \mathbb{P}(E^c) \mathbb{P}(F)$, 即 E^c 与 F 独立.
3. $\mathbb{P}(E \cap F^c) = \mathbb{P}(E) \mathbb{P}(F^c)$, 即 E 与 F^c 独立.
4. $\mathbb{P}(E^c \cap F^c) = \mathbb{P}(F^c) \mathbb{P}(E^c)$, 即 E^c 与 F^c 独立.

习题 1.8. 设 $E_1, \dots, E_n$ 为相互独立的事件, 证明

$$\mathbb{P}(E_1 \cup \dots \cup E_n) = 1 - \prod_{i=1}^n (1 - \mathbb{P}(E_i)) \geq 1 - \exp\left(-\sum_{i=1}^n \mathbb{P}(E_i)\right).$$

习题 1.9. 一个罐子中有 b 个蓝球和 r 个红球. 甲从罐子中不放回地随机取球, 直到所有的球都被取出.

1. 甲在第 k 次取球时第一次取到红球的概率是多少?
2. 甲最后取出的球是蓝球的概率是多少?

习题 1.10. 从一副 54 张的扑克牌中随机抽取五张.

1. 这五张牌构成顺子 (五张牌点数顺连但不是同一花色) 的概率是多少? 设最小的顺子为 A-2-3-4-5, 最大的顺子为 10-J-Q-K-A.
2. 这五张牌构成三带二 (三张同一点数的牌, 加一对其他点数的牌) 的概率是多少?

习题 1.11. 设一个班上有 m 位同学出生在公元 Y 年 (Y 年不是闰年), 并设这 m 名同学的生日服从 $\Omega = \{(b_1, \dots, b_m) \mid b_i \in \{1, 2, \dots, 365\}, \forall i\}$ 上的古典概型.

1. 试求这 m 位同学中至少有两位生日相同的概率. 提示 考虑对立事件.
2. 当 m 的取值为多少时这个概率大于 $1/2$?
3. 设 i, j 为 $\{1, 2, \dots, m\}$ 中给定的两个不相等的正整数. 令事件 E 表示 “第 i 个同学的生日在 6 月份”, 事件 F 表示 “第 j 个同学的生日在元旦当天”.
 - (a) 请分别表示出集合 E 与集合 F 中的所有元素.
 - (b) 判断 E 和 F 是否相互独立, 并证明你的结论.
 - (c) 如果把 F 改成 “第 j 个同学与第 i 个同学出生在同一个月份”, 此时 E 和 F 是否相互独立? 如果把 F 改成 “第 j 个同学的生日与第 i 个同学相差不到 30 天”, 此时 E 和 F 是否相互独立?

习题 1.12. 假设我们将字符串 “ABRACADABRA” 的 11 个字符随机打乱得到一个新的字符串, 则新的字符串中包含 “ARAB” 作为子字符串 (即从某个位置开始依次连续出现 ‘A’ ‘R’ ‘A’ ‘B’ 四个字符) 的概率是多少?

习题 1.13. 甲的手上有三枚硬币, 其中两枚的两面都是正面, 剩下一枚一面是正面一面是反面. 甲首先将这三枚硬币都抛出, 并在正面朝上的硬币中随机选一枚 (称其为硬币 A). 接下来, 甲再抛一次硬币 A, 结果依然是正面朝上. 则硬币 A 的另一面是反面的概率是多少?

习题 1.14. 设有某种传染病 X , 一个健康人在接触 X 的患者后立刻患上 X 的概率为 $1/2$. 某一天健康的甲接触了一位 X 的患者乙, 考虑到 X 的传染性, 甲决定进行自我隔

离, 在隔离期间每天服用一次药物 A. 假设对于 X 的患者, 每服用一次药物 A, 有 $1/4$ 的概率会让其马上康复, 且药效与该患者之前是否服用过 A 无关. 在隔离 3 天后, 医院对甲进行检测, 发现甲未患上 X, 则甲在接触乙后实际患上 X 的概率是多少?

注: 本题改编自 [7] 习题 3.9.

习题 1.15. 你知道你的邻居有两个小孩, 但一开始并不知道他们的性别. 有一天, 你在和小区蛋糕店的老板交谈时得知, 邻居的两个小孩中有一个出生在一月份的男孩, 但除此以外未得到其它信息. 试求邻居的两个小孩都是男孩的概率 (忽略男女性别在出生率上的差异, 设两个小孩各自出生在哪个月份是等可能且相互独立的).

习题 1.16. 设有 A、B、C、D 四个国家, 它们通过两两谈判的方式决定两个国家之间是否开通双向的直飞航班. 设每一对国家谈判成功 (即开通双向直飞航班) 的概率为 p , 而谈判破裂的概率为 $1 - p$.

1. 从 D 国出发搭乘直飞或中转航线能够到达 A 国的概率;
2. 在 A 国与 B 国间没有直飞航班的条件下, 从 D 国出发搭乘直飞或中转航线能够到达 A 国的条件概率;
3. 在 B 国与 C 国间没有直飞航班的条件下, 从 D 国出发搭乘直飞或中转航线能够到达 A 国的条件概率;
4. 在 D 国与 A 国间没有直飞航班的条件下, 从 D 国出发搭乘中转航线能够到达 A 国的条件概率.

注: 本题改编自 [8] 第 1.8 节第 19 题.

习题 1.17. 设有 k 个罐子, 每个罐子当中一开始有 r 个红球和 b 个蓝球. 现从第 1 个罐子中随机取一个球放入第 2 个罐子中并搅匀, 再从第 2 个罐子中随机取一个球放入第 3 个罐子中并搅匀……直到从 $k - 1$ 个罐子中取出一球放入第 k 个罐子中并搅匀. 则此时从第 k 个罐子中随机取出一球为红球的概率是多少?

习题 1.18. 设有 $N + 1$ 枚不均匀的硬币, 其中第 i 枚硬币抛出正面的概率为 $p_i = (i - 1)/N$. 你从这 $N + 1$ 枚硬币中随机选取一枚, 然后重复抛这枚硬币 m 次. 假设 N 非常大, 试求这 m 次抛出结果均为正面的条件下, 你再抛一次这枚硬币结果为正面的概率.

注: 本题改编自 [6] 第一章的习题 46.

习题 1.19 (秘书问题, secretary problem). 假设某公司的经理需要从 N 个候选人中招聘一位秘书, 招聘的流程如下: 首先用公平抽签的方式决定这 N 个候选人的面试顺序, 而后经理按顺序依次对候选人进行单独面试, 每面试一个候选人, 经理会根据候选人作为秘书的资质对其进行打分, 而后当场决定是否录用该候选人, 若决定录用则整个招聘流程结束, 剩余的候选人也被淘汰; 若决定不录用则继续面试下一个候选人, 该候选人直接被淘汰. 直到面试到最后一个候选人, 此时这个候选人将直接被录用. 假设这些候选人作为秘书的资质都各不相同.

为了招聘到资质足够高的秘书, 经理决定采用如下策略:

- 对于前 M 个候选人均选择不予录用, 并记录下这 M 个候选人的最高分.
- 从第 $M+1$ 个候选人开始, 若其分数超过前 M 人的最高分则录用该候选人, 否则淘汰该候选人, 直至面试到最后一人.

试求这种策略下, 被录用的人在所有候选人中资质最高的概率, 并在 N 非常大的情况下, 求出使得该概率 (近似) 取到最大值的 M .

习题 1.20 (赌徒破产问题, gambler's ruin problem). 甲与乙两个人参与了如下游戏过程: 总共有 N 张扑克牌, 游戏开始时甲手上有 i 张, 乙手上有 $N-i$ 张. 随后甲乙两人抛一枚硬币, 若硬币正面朝上则甲从乙那里拿一张扑克牌到自己手里, 若硬币反面朝上则乙从甲那里拿一张扑克牌到自己手里. 甲乙两人重复这个抛硬币—拿扑克牌的过程, 直到一个人手上的扑克牌全都被拿光, 则另一个人获胜. 设抛硬币的结果相互独立, 硬币正面朝上的概率为 $p \in]0, 1[$. 我们希望求出两人各自获胜的概率.

1. 对任意 $i \in \{0, \dots, N\}$, 记 P_i 为初始时甲手上有 i 张牌的情况下最终甲获胜的概率. 证明

$$P_i = p \cdot P_{i+1} + (1-p) \cdot P_{i-1}, \quad \forall i = 1, \dots, N-1. \quad (1.7)$$

提示 可以利用如下直观上易接受的事实 (不要求严格证明): 在第一次抛硬币为正面的条件下, 甲赢得游戏的条件概率为 P_{i+1} ; 在第一次抛硬币为反面的条件下, 甲赢得游戏的条件概率为 P_{i-1} .

2. 证明 $(P_{i+1} - P_i)_{i=0}^{N-1}$ 构成一等比数列, 并求出其通项.
3. 求出 P_1 的值. **提示** 利用 $1 = P_N - P_0 = \sum_{i=0}^{N-1} (P_{i+1} - P_i)$. 注意区分 $p = 1/2$ 与

$p \neq 1/2$ 的情形.

4. 求出 $1 \leq i \leq N-1$ 时 P_i 的值.

习题 1.21. 设一架满员的客机开始登机, 机上共有 $N \geq 2$ 个旅客座位. 然而第一位登机的旅客在廊桥上不慎丢失了登机牌, 在不知道座位号码的情况下他随机选了一个位置就坐. 接下来登机的旅客若发现自己的位置已经被别人乘坐, 就在剩余的空座位上随机选一个位置就坐, 否则还是坐到自己原定的位置上. 试求最后一位登机的乘客在自己原定位位置上就坐的概率.

提示 将待求的概率记为 P_N . 先针对 $N=2, N=3, N=4$ 等简单情形进行分析, 找到规律以后, 试建立 P_N 与 P_i ($i < N$) 的关系并利用数学归纳法证明你找到的规律.

习题 1.22. (*) 设 $E_1, E_2, E_3, \dots$ 为一列事件, 且对任意正整数 i 均有 $\mathbb{P}(E_i) = 1$. 证明

$$\mathbb{P}\left(\bigcap_{i=1}^{\infty} E_i\right) = 1,$$

也就是说, 可数多个几乎必然发生的事件的交依然是几乎必然发生的.

习题 1.23 (Ross-Littlewood 悖论). (*) 考虑如下思想实验: 假设有可数无限多个小球, 它们被正整数 $1, 2, 3, \dots$ 标号; 另有一个可以容纳可数无限多个小球的花瓶, 这个花瓶一开始是空的. 现执行如下任务:

- I. 将变量 i 赋值为 0;
- II. 在 2^{-i} 分钟内完成如下操作: 先往花瓶中放入编号为 $10i+1, 10i+2, \dots, 10i+10$ 的十个小球, 再从花瓶中均匀地随机选一个小球取出.
- III. 令 $i \leftarrow i+1$ 并返回第 II 步.

则在任务开始的两分钟后, 往花瓶中放十个小球并随机取出一个小球的步骤将被执行(可数)无限多次. 现在我们想要知道, 最终花瓶中有多少小球.

1. 令 $F_{1,i}$ 表示事件“编号为 1 的小球在第 i 次取球后仍未被从花瓶中取出”, 试求 $\mathbb{P}(F_{1,i})$.
2. 令 E_1 表示事件“编号为 1 的小球在某次取球时被从花瓶中取出”, 试说明 $E_1^c = \bigcap_{i=1}^{\infty} F_{1,i}$, 并利用概率的连续性计算 $\mathbb{P}(E_1)$.
3. 令 E_k ($k \in \mathbb{N}_+$) 表示事件“编号为 k 的小球在某次取球时被从花瓶中取出”, 试计算 $\mathbb{P}(E_k)$.

4. 令 E 表示事件“每个小球均在某一次取球时被从花瓶中取出”, 试证明 $\mathbb{P}(E) = 1$.
由此, 你觉得最终花瓶中有多少个小球?

注: 关于 Ross–Littlewood 悖论, 感兴趣的读者可参阅 https://en.wikipedia.org/wiki/Ross-Littlewood_paradox 当中的讨论.

第二章 离散型随机变量

2.1 随机变量的定义

在许多随机试验中, 相较于直接考察试验结果的统计规律, 我们往往会从各个试验结果中提炼出一些定量特征来进行研究, 这些定量特征可以看成是试验结果的函数. 在概率论中, 我们将试验结果的实值函数称为随机变量. 引入随机变量能够带来如下几个方面的好处:

- 在某些随机试验中, 我们只关心试验结果的某个函数的取值情况, 此时将研究重点放在相应的随机变量上能使我们更有针对性地揭示统计规律;
- 样本空间作为一个一般的集合, 有时难以直接对其元素进行运算或比较大小关系, 而样本空间上的实值函数则可进行各种运算及大小关系的比较, 从而能帮助我们挖掘更深层次的统计规律;
- 随机变量将“底层”的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 包装为分布函数、分布列、概率密度函数等利用微积分知识即可方便使用的“接口”, 这为概率建模与相关的推导提供了莫大的便利.

定义 2.1. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, $X : \Omega \rightarrow \mathbb{R}$ 为定义在 Ω 上的实值函数. 若对任意 $\mathbb{R}$ 中的区间 I , 均有

$$\{\omega \in \Omega \mid X(\omega) \in I\} \in \mathcal{F},$$

则称 X 为一个**随机变量** (random variable).

定义 2.1 中要求形如 $\{\omega \in \Omega \mid X(\omega) \in I\}$ 的集合都在事件域 $\mathcal{F}$ 中, 它保证了 $\{\omega \in \Omega \mid X(\omega) \in I\}$ 的概率是有定义的, 也就是说对任意区间 I , 我们都可以谈论“随机变量 X 的取值落在区间 I 中”这一事件的概率.

给定随机变量 X 以及关于实数 x 的命题 $\varphi(x)$, 我们经常用记号 $\{\varphi(X)\}$ 来表示集合 $\{\omega \in \Omega \mid \varphi(X(\omega)) \text{ 成立}\}$, 即由所有使得命题 $\varphi(X(\omega))$ 成立的试验结果 ω 构成的集合, 例如

$$\{X \text{ 是有理数}\} = \{\omega \in \Omega \mid X(\omega) \text{ 是有理数}\}.$$

对于实际问题中所关心的绝大多数命题 $\varphi(x)$, 原则上均可证明 $\{\varphi(X)\}$ 为一事件. 进一步, $\{\varphi(X)\}$ 的概率也就有了定义¹, 此时我们用 $\mathbb{P}(\varphi(X))$ 表示 $\{\varphi(X)\}$ 的概率. 例如

$$\mathbb{P}(a \leq X < b) = \mathbb{P}(\{\omega \in \Omega \mid a \leq X(\omega) < b\}),$$

它表示随机变量 X 的取值落在区间 $[a, b]$ 内的概率.

从已有的随机变量出发, 可以构造出新的随机变量. 具体而言, 给定 n 个随机变量 $X_1, \dots, X_n$ 以及函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 我们用 $f(X_1, \dots, X_n)$ 表示将 $\omega \in \Omega$ 映为 $f(X_1(\omega), \dots, X_n(\omega))$ 的函数. 对于绝大多数实际问题中遇到的函数 f , 原则上均可证明 $f(X_1, \dots, X_n)$ 为一随机变量; 特别是, 给定随机变量 X, Y 以及实数 λ , 则 $\lambda X, |X|, X + Y, X \cdot Y$ 均为随机变量¹.

在本讲义中, 若无特别说明, 均假定形如 $\{\varphi(X)\}$ 的集合是一个事件 (也就是说其概率 $\mathbb{P}(\varphi(X))$ 有定义), 而形如 $f(X_1, \dots, X_n)$ 的函数为一随机变量.

例 2.1 (指示函数). 事件的指示函数是最简单的一类随机变量. 设 S 为任意集合, A 为 S 的任一子集, 我们定义 A 的**指示函数** (indicator function) $1_A: S \rightarrow \mathbb{R}$ 为

$$1_A(x) = \begin{cases} 1, & \text{若 } x \in A, \\ 0, & \text{若 } x \notin A. \end{cases}$$

现设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, 任给一事件 E , 我们证明其指示函数 1_E 为随机变量: 任取区间 $I \subseteq \mathbb{R}$, 有

$$\{1_E \in I\} = \{\omega \in \Omega \mid 1_E(\omega) \in I\} = \begin{cases} \Omega, & \{0, 1\} \subseteq I, \\ E, & 1 \in I, 0 \notin I, \\ E^c, & 0 \in I, 1 \notin I, \\ \emptyset & \{0, 1\} \cap I = \emptyset, \end{cases}$$

¹ 相关证明超出本讲义范围, 属于高等概率论的内容.

而 $\Omega, E, E^c, \emptyset$ 均为事件, 故 1_E 为一随机变量. 不难看出, 随机变量 1_E 在事件 E 发生时取值为 1, 而在 E 没有发生时取值为 0.

指示函数在概率论中有着基础性作用, 从指示函数出发, 可以构造一系列更加复杂的随机变量. 例如, 设 $E_1, E_2, \dots$ 为一列两两互斥的事件, $x_1, x_2, \dots$ 为任意一列实数, 则可以证明

$$X = \sum_{i=1}^{\infty} x_i \cdot 1_{E_i}$$

为一随机变量, 该随机变量在事件 E_i 发生时的取值即为 x_i , 而在所有 E_i 都不发生的时候取值为 0. ■

例 2.2. 设概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 中 $\Omega = [0, 1]$, 概率测度 $\mathbb{P}$ 对任意 $[0, 1]$ 的子区间 J 均有定义, 且 $\mathbb{P}(J)$ 等于 J 的长度. 现任取 $\alpha > 0$, 并定义 $X : \Omega \rightarrow \mathbb{R}$ 为

$$X(\omega) = \alpha\omega, \quad \omega \in [0, 1].$$

则对任意区间 $I \subseteq \mathbb{R}$, 有

$$\{X \in I\} = \{\omega \in [0, 1] \mid \alpha\omega \in I\}$$

由于 $\omega \mapsto \alpha\omega$ 是严格单调的连续函数, 可知上式右端为 $[0, 1]$ 的子区间或空集, 故 $\mathbb{P}(X \in I)$ 有定义, 从而由区间 I 的任意性可得 X 为一随机变量.

注意到对任意区间 $I \subseteq \mathbb{R}$, 有

$$\begin{aligned} \mathbb{P}(X \in I) &= \mathbb{P}(\{\omega \in [0, 1] \mid \alpha\omega \in I\}) \\ &= \int_0^1 1_{\{\alpha x \in I\}}(x) dx \\ &= \int_0^\alpha 1_I(t) \cdot \alpha^{-1} dt = \int_I \alpha^{-1} 1_{[0, \alpha]}(t) dt, \end{aligned}$$

其中我们进行了积分换元 $t = \alpha x$. 上式意味着 $\mathbb{P}(X \in I)$ 可以表示为一个非负函数 $t \mapsto \alpha^{-1} 1_{[0, \alpha]}(t)$ 在区间 I 上的积分. ■

例 2.1 与例 2.2 各自给出了如下两类随机变量的典型例子: 前一类随机变量可能的取值只有可数多个; 后一类随机变量可能的取值有不可数个, 且它取值于任一区间的概率等于某个非负函数在该区间上的积分. 我们将前一类随机变量称为**离散型随机变量**, 而后一类随机变量则称为**连续型随机变量**. 考虑到数学工具上的限制以及大多数实际应用的情形, 本讲义中将分别对这两类随机变量进行较为详细的讨论, 而一般性的随机变量理论则只做简要介绍.

2.2 离散型随机变量

定义 2.2. 设 X 为一随机变量. 若 X 只有可数多个可能的取值, 则称其为一**离散型随机变量** (discrete random variable). 换句话说, X 为离散型随机变量当且仅当其值域

$$\text{Im } X = \{X(\omega) \mid \omega \in \Omega\}$$

为可数集.

对于离散型随机变量 X , 我们定义其**分布列** (probability mass function, p.m.f.) $p_X: \mathbb{R} \rightarrow [0, 1]$ 为

$$p_X(x) = \mathbb{P}(X = x), \quad x \in \mathbb{R}.$$

需要注意的是, 虽然分布列 p_X 的定义域为 $\mathbb{R}$, 但 $p_X(x)$ 只对可数多个点 x 取非零值 (见下面的定理 2.1). 为方便起见, 在表示分布列 p_X 时, 我们通常只列出那些非零的概率值 $p_X(x)$. 在许多教材中, 分布列也经常用如下表格来表示:

X	x_1	x_2	$\cdots$	x_n	$\cdots$
$\mathbb{P}$	$p_X(x_1)$	$p_X(x_2)$	$\cdots$	$p_X(x_n)$	$\cdots$

其中 $x_1, x_2, \dots$ 不重复地枚举了满足 $p_X(x) > 0$ 的所有 x .

注 2.1. 后文中我们将经常遇到形如

$$\sum_{\substack{s \in S \cap A: \\ \varphi(s) \text{ 且 } h(s) \neq 0}} h(s), \quad (2.1)$$

的求和式, 其中函数 $h: S \rightarrow \mathbb{R}$ 只在 S 的一个可数子集上取非零值, A 为任意集合, $\varphi(s)$ 为任意关于 $s \in S$ 的命题. 为符号上的简洁, 我们将把

$$\sum_s h(s), \quad \sum_{s \in A} h(s), \quad \sum_{s: \varphi(s)} h(s), \quad \sum_{s \in A: \varphi(s)} h(s)$$

分别作为

$$\sum_{s \in S: h(s) \neq 0} h(s), \quad \sum_{s \in S \cap A: h(s) \neq 0} h(s), \quad \sum_{\substack{s \in S: \\ \varphi(s) \text{ 且 } h(s) \neq 0}} h(s), \quad \sum_{\substack{s \in S \cap A: \\ \varphi(s) \text{ 且 } h(s) \neq 0}} h(s)$$

的简写形式.

关于求和式 (2.1) 取值的严格定义可参考附录 A.1. ■

以下定理给出了分布列所满足的性质.

定理 2.1. 设 X 为一离散型随机变量, p_X 为其分布列, 则

1. 对任意 $x \in \mathbb{R}$, 均有 $p_X(x) \geq 0$.
2. $\{x \in \mathbb{R} \mid p_X(x) > 0\}$ 为可数集.
3. $\sum_x p_X(x) = 1$.

证明. $p_X(x) \geq 0$ 是概率测度定义的直接推论.

为证明第 2 条性质, 注意到

$$p_X(x) = \mathbb{P}(X = x) = \mathbb{P}(\emptyset) = 0, \quad \text{若 } x \notin \text{Im } X,$$

故 $p_X(x) > 0$ 意味着 $x \in \text{Im } X$, 也即是说 $\{x \in \mathbb{R} \mid p_X(x) > 0\}$ 是 $\text{Im } X$ 的子集. 由离散型随机变量的定义, 可知 $\text{Im } X$ 为可数集, 而可数集的子集必定是可数集, 因此 $\{x \in \mathbb{R} \mid p_X(x) > 0\}$ 也是可数集.

接下来我们证明第 3 条性质:

$$\begin{aligned} 1 &= \mathbb{P}(X \in \text{Im } X) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(X = x) = \sum_{x \in \text{Im } X} p_X(x) \\ &= \sum_{x: p_X(x) > 0} p_X(x) + \sum_{x \in \text{Im } X: p_X(x) = 0} p_X(x) = \sum_{x: p_X(x) > 0} p_X(x), \end{aligned}$$

其中第一步是因为 $\{X \in \text{Im } X\}$ 是必然事件, 第二步则利用了概率的可数可加性. $\square$

定理 2.1 的逆定理也同样成立.

定理 2.2. 若 $p: \mathbb{R} \rightarrow \mathbb{R}$ 为一函数, 满足

1. 对任意 $x \in \mathbb{R}$, 均有 $p(x) \geq 0$.
2. $\{x \in \mathbb{R} \mid p(x) > 0\}$ 为可数集.
3. $\sum_x p(x) = 1$.

则存在一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 以及 $X: \Omega \rightarrow \mathbb{R}$, 使得 X 为一离散型随机变量, 且 p 为 X 的分布列.

定理 2.2 的证明将放到 2.2.2 小节中. 该定理指出, 只要我们给出满足定理 2.2 条件的函数 $p: \mathbb{R} \rightarrow \mathbb{R}$, 则以 p 为分布列的离散型随机变量就一定存在, 此时我们说 p 给出

了一个**离散型分布**. 该定理也意味着, 当我们需要用单个离散型随机变量对某个随机试验进行建模与刻画时, 只需给定其分布列即可, 而无需考虑更加底层的概率空间的构造.

在给定离散型随机变量 X 的分布列 p_X 之后, 对于任意 $\mathbb{R}$ 的子集 B , 我们有

$$\begin{aligned}\mathbb{P}(X \in B) &= \mathbb{P}(X \in B \cap \text{Im } X) \\ &= \mathbb{P}\left(\bigcup_{x \in B \cap \text{Im } X} \{X = x\}\right) \\ &= \sum_{x \in B \cap \text{Im } X} \mathbb{P}(X = x) = \sum_{x \in B : p_X(x) > 0} p_X(x),\end{aligned}$$

其中第三步利用了概率的可数可加性. 因此, 理论上我们可以通过

$$\mathbb{P}(X \in B) = \sum_{x \in B} p_X(x) \quad (2.2)$$

来计算任意形如 $\{X \in B\}$ 的事件的概率. 这说明, 对于单个离散型随机变量, 其分布列能够完整刻画其统计规律.

注 2.2. 当我们需要考虑多个离散型随机变量, 尤其是需要考察多个离散型随机变量之间的关系时, 仅用它们各自的分布列并不能完整刻画它们的统计规律. 例如, 具有相同的分布列的两个离散型随机变量可以相同也可以不同. 我们将在 2.3 节介绍如何处理有限多个离散型随机变量. ■

例 2.3 (离散型随机变量的函数的分布). 设 X 为一离散型随机变量, $g: \mathbb{R} \rightarrow \mathbb{R}$ 为一实值函数, 令 $Y = g(X)$. 则随机变量 Y 的值域为

$$\begin{aligned}\text{Im } Y &= \{g(X(\omega)) \mid \omega \in \Omega\} \\ &= \{g(x) \mid x \in \text{Im } X\},\end{aligned}$$

由于 $\text{Im } X$ 为可数集, 故 $\text{Im } Y$ 也是可数集, 因此 Y 也是离散型随机变量, 其分布列可由如下过程求得:

$$\begin{aligned}p_Y(y) &= \mathbb{P}(Y = y) \\ &= \mathbb{P}\left(\bigcup_{\substack{x \in \text{Im } X : \\ g(x) = y}} \{X = x\}\right) \\ &= \sum_{\substack{x \in \text{Im } X : \\ g(x) = y}} \mathbb{P}(X = x) = \sum_{x : g(x) = y} p_X(x), \quad \forall y \in \mathbb{R},\end{aligned}$$

其中第三步用到了概率的可数可加性. 换句话说, 为了计算 $\{Y = y\}$ 的概率, 我们需要先在 X 的值域 $\text{Im } X$ 中找到方程 $g(x) = y$ 的所有解 x , 然后把相应的概率 $\mathbb{P}(X = x)$ 全都加起来. ■

2.2.1 一些重要的离散型分布

伯努利分布. 设 $p \in [0, 1]$. 若离散型随机变量 X 的分布列为

$$p_X(x) = \begin{cases} p, & x = 1, \\ 1 - p, & x = 0, \end{cases}$$

则称 X 服从参数为 p 的伯努利分布 (Bernoulli distribution). 不难看出, 对任意事件 E , 其指示函数 1_E 服从参数为 $\mathbb{P}(E)$ 的伯努利分布.

二项分布. 设 n 为正整数, $p \in [0, 1]$. 若离散型随机变量 X 的分布列为

$$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n,$$

则称 X 服从参数为 (n, p) 的二项分布 (binomial distribution), 通常记为 $X \sim B(n, p)$. 不难验证上式的确给出了一个离散型分布: 对任意 $k = 0, 1, \dots, n$ 均有 $\binom{n}{k} p^k (1-p)^{n-k} \geq 0$, 且二项式定理给出

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = [p + (1-p)]^n = 1.$$

图 2.1 给出了参数分别为 $(n, p) = (12, 1/2)$ 与 $(n, p) = (12, 1/3)$ 的二项分布的分布列图像.

几何分布. 设 $p \in]0, 1[$. 若离散型随机变量 X 的分布列为

$$p_X(k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots,$$

则称 X 服从参数为 p 的几何分布 (geometric distribution). 不难验证上式的确给出了一个离散型分布: 对任意正整数 k 均有 $(1-p)^{k-1} p \geq 0$, 且由几何级数求和公式可得

$$\sum_{k=1}^{\infty} (1-p)^{k-1} p = \frac{p}{1 - (1-p)} = 1.$$

图 2.2 给出了参数分别为 $p = 1/3$ 与 $p = 1/2$ 的几何分布的分布列图像.




图 2.1: 二项分布的分布列图像.




图 2.2: 几何分布的分布列图像.

泊松分布. 设 $\lambda \in]0, +\infty[$. 若离散型随机变量 X 的分布列为

$$p_X(k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots,$$

则称 X 服从参数为 λ 的泊松分布 (Poisson distribution). 不难验证上式的确给出了一个离散型分布: 对任意自然数 k 均有 $e^{-\lambda} \lambda^k / k! \geq 0$, 且由指数函数的泰勒级数表示可得

$$\sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1.$$

图 2.3 给出了参数分别为 $\lambda = 1$ 与 $\lambda = 4$ 的泊松分布的分布列图像.

二项分布、几何分布与泊松分布的意义将在 2.6 节进行介绍.




图 2.3: 泊松分布的分布列图像.

离散均匀分布. 设集合 S 为 $\mathbb{R}$ 的一个有限子集, 用 $|S|$ 表示其元素个数. 若离散型随机变量 X 的分布列为

$$p_X(x) = \begin{cases} \frac{1}{|S|}, & \text{若 } x \in S, \\ 0, & \text{其它情况,} \end{cases}$$

则称 X 服从有限集 S 上的离散均匀分布 (discrete uniform distribution). 不难看出, 离散均匀分布和古典概型有着密切的联系: 若 $(\Omega, 2^\Omega, \mathbb{P})$ 为一古典概型, 而随机变量 $X: \Omega \rightarrow \mathbb{R}$ 为一个单射, 则 X 服从有限集 $\text{Im } X = \{X(\omega) \mid \omega \in \Omega\}$ 上的均匀分布.

2.2.2 定理 2.2 的证明

取样本空间为 $\Omega = \{x \in \mathbb{R} \mid p(x) > 0\}$, 事件域为 $\mathcal{F} = 2^\Omega$. 注意到每个事件都是可数集, 可令 $\mathbb{P}$ 为

$$\mathbb{P}(E) = \sum_{x \in E} p(x), \quad \forall E \subseteq \Omega.$$

不难看出

$$\mathbb{P}(\Omega) = \sum_{x \in \Omega} p(x) = 1.$$

而对任意事件 E , 有 $\mathbb{P}(E) \geq 0$ 以及 $\mathbb{P}(E) = \sum_{x \in E} p(x) \leq \sum_{x \in \Omega} p(x) = 1$. 为证明 $\mathbb{P}$ 的可数可加性, 令 $E_1, E_2, \dots$ 为一列两两互不相交的事件, 则有

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{x \in \bigcup_{i=1}^{\infty} E_i} p(x) = \sum_{i=1}^{\infty} \sum_{x \in E_i} p(x) = \sum_{i=1}^{\infty} \mathbb{P}(E_i),$$

其中第二步利用了 $E_1, E_2, \dots$ 两两互不相交的条件以及定理 A.2. 故 $\mathbb{P}$ 为一概率测度. 最后取函数 $X: \Omega \rightarrow \mathbb{R}$ 为 $X(\omega) = \omega$, 则易知 X 为离散型随机变量, 其分布列为 p , 从而定理 2.2 成立.

2.3 离散型随机向量

许多情况下, 我们关心不止一个随机变量, 而是多个随机变量 $X_1, \dots, X_n$, 且不止关心它们各自的统计规律, 还需要研究它们的相互关系, 此时将这些随机变量作为整体来研究则尤为重要.

定义 2.3. 给定 n 个随机变量 $X_1, \dots, X_n$, 我们将它们构成的有序组 $(X_1, \dots, X_n)$ 称为 n 维随机向量 (n -dimensional random vector).

我们也可以将随机向量 $(X_1, \dots, X_n)$ 看作是将任一样本点 $\omega \in \Omega$ 对应到 n 维向量 $(X_1(\omega), \dots, X_n(\omega)) \in \mathbb{R}^n$ 的一个映射. 在本讲义中, 我们有时用大写粗体字母 (如 $\mathbf{X}, \mathbf{Y}$) 表示一个随机向量, 并用 $\mathbf{X}(\omega)$ 表示 $(X_1(\omega), \dots, X_n(\omega))$.

注 2.3. 在本讲义中, 为了符号上的便利, 我们将形如 $(a_1, \dots, a_n)$ 的有序组 (包括数组和随机向量) 均看作列向量 (即 $n \times 1$ 维矩阵). ■

本章中我们关注由离散型随机变量构成的随机向量. 为教学上的方便与简洁, 我们主要介绍二维随机向量的相关概念与结果, 但这些概念与结果通常不难推广到一般的 n 维情况.

定义 2.4. 若 X, Y 均为离散型随机变量, 则称 (X, Y) 为离散型随机向量, 其联合分布列 (joint probability mass function, joint p.m.f.) 被定义为函数

$$p_{X,Y}(x, y) = \mathbb{P}(X = x, Y = y), \quad (x, y) \in \mathbb{R}^2,$$

在不产生混淆的情况下, 也可将联合分布列简称为分布列.

和一维情形的定理 2.1 与 2.2 类似, 对于离散型随机向量 (X, Y) , 不难证明其联合分布列 $p_{X,Y}$ 具有如下性质:

- 对任意 $(x, y) \in \mathbb{R}^2$, 均有 $p_{X,Y}(x, y) \geq 0$.

- $\{(x, y) \in \mathbb{R}^2 \mid p_{X,Y}(x, y) > 0\}$ 为可数集.
- $\sum_{(x,y)} p_{X,Y}(x, y) = 1.$

反过来, 若某个函数 $p: \mathbb{R}^2 \rightarrow \mathbb{R}$ 满足上述三条性质, 则存在概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 及定义在 Ω 上的离散型随机向量 (X, Y) 使其联合分布列为 p . 因而, 当某个随机试验可以用有限多个离散型随机变量来建模与刻画时, 我们只需给定这些随机变量 (作为随机向量) 的联合分布列即可, 而无需给出概率空间的具体构造.

此外, 利用概率的可数可加性不难证明, 对任意 $B \subseteq \mathbb{R}^2$, 均有

$$\mathbb{P}((X, Y) \in B) = \sum_{(x,y) \in B} p_{X,Y}(x, y). \quad (2.3)$$

例 2.4 (离散型随机向量的函数的分布). 本例可看成例 2.3 的推广. 设 (X, Y) 为一离散型随机向量, $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为二元实值函数, 令 $Z = g(X, Y)$. 则随机变量 Z 的值域为

$$\begin{aligned} \text{Im } Z &= \{g(X(\omega), Y(\omega)) \mid \omega \in \Omega\} \\ &= \{g(x, y) \mid (x, y) \in \text{Im}(X, Y)\}, \end{aligned}$$

由于 $\text{Im}(X, Y) \subseteq \text{Im } X \times \text{Im } Y$ 为可数集, 故 $\text{Im } Z$ 也是可数集, 因此 Z 也是离散型随机变量, 其分布列为

$$p_Z(z) = \sum_{\substack{(x,y): \\ g(x,y)=z}} p_{X,Y}(x, y), \quad \forall z \in \mathbb{R}.$$

上式的推导过程与一维情形的例 2.3 类似, 请读者自行完成. ■

2.3.1 边缘分布

设 (X, Y) 为 2 维随机向量, $p_{X,Y}$ 为其联合分布列. 我们将分量 X 的分布列 p_X 称为 $p_{X,Y}$ 关于第 1 个分量的**边缘分布列** (marginal probability mass function, marginal p.m.f.), 类似地将 Y 的分布列 p_Y 称为 $p_{X,Y}$ 关于第 2 个分量的边缘分布列.

以下定理指出, 对于离散型随机向量, 其边缘分布列由联合分布列唯一确定:

定理 2.3. 设 (X, Y) 为离散型随机向量, $p_{X,Y}$ 为其联合分布列, 则 $p_{X,Y}$ 关于第 1 个分量的边缘分布列 (即 X 的分布列) 为

$$p_X(x) = \sum_y p_{X,Y}(x, y), \quad \forall x \in \mathbb{R}.$$

换句话说, 为求得 $p_X(x)$, 我们将 x 固定后, 对所有 (大于 0 的) $p_{X,Y}(x,y)$ 求和. 类似地, $p_{X,Y}$ 关于第 2 个分量的边缘分布列 (即 Y 的分布列) 为

$$p_Y(y) = \sum_x p_{X,Y}(x,y), \quad \forall y \in \mathbb{R}.$$

上述定理的证明是概率可数可加性的直接应用, 这里就不给出具体过程了. 需要着重强调的是, 一般情况下, 离散型随机向量的联合分布列并不能由它的各个边缘分布列唯一确定; 这也是为什么我们需要引入多元的联合分布列来定量刻画离散型随机向量的统计规律.




图 2.4: 例 2.5 中随机向量 (X,Y) 的联合分布列图像.

例 2.5. 本例中我们考虑一种最为简单的离散型随机向量的情形. 设 (X,Y) 为离散型随机向量, X 与 Y 的取值范围均为 $\{0,1\}$, 则 (X,Y) 的联合分布列 $p_{X,Y} : \mathbb{R}^2 \rightarrow [0,1]$ 只可能在 $(0,0), (0,1), (1,0), (1,1)$ 四个点取非零值, 我们将这四个非零值分别记为 $\theta_{00}, \theta_{01}, \theta_{10}, \theta_{11}$ (见图 2.4), 它们必须满足如下约束:

- 对任意 $i, j \in \{0,1\}$, 均有 $\theta_{ij} \geq 0$;
- $\theta_{00} + \theta_{01} + \theta_{10} + \theta_{11} = 1$.

X 与 Y 各自的边缘分布列则为

$$\begin{aligned} p_X(0) &= \theta_{00} + \theta_{01}, & p_X(1) &= \theta_{10} + \theta_{11}, \\ p_Y(0) &= \theta_{00} + \theta_{10}, & p_Y(1) &= \theta_{01} + \theta_{11}. \end{aligned}$$

若记

$$\theta_X = \theta_{10} + \theta_{11}, \quad \theta_Y = \theta_{01} + \theta_{11},$$

则 X 服从参数为 θ_X 的伯努利分布, 而 Y 服从参数为 θ_Y 的伯努利分布. 不难看出, 即使给定 θ_X 和 θ_Y , 依然无法唯一确定 $\theta_{00}, \theta_{01}, \theta_{10}, \theta_{11}$ 这四个数的取值, 这为联合分布列不能由边缘分布列唯一确定提供了一个具体的例子. ■

2.4 随机变量的独立性

本节我们介绍随机变量的独立性, 它给出了多个随机变量取值互不影响的数学描述.

定义 2.5. 设 $X_1, \dots, X_n$ 为 n 个随机变量. 若对任意区间 $I_1, \dots, I_n \subseteq \mathbb{R}$, 都有

$$\mathbb{P}(X_1 \in I_1, \dots, X_n \in I_n) = \prod_{i=1}^n \mathbb{P}(X_i \in I_i),$$

则称 $X_1, \dots, X_n$ **相互独立** (mutually independent).

利用条件概率的概念, 可证明 $X_1, \dots, X_n$ 相互独立当且仅当如下条件成立: 任取 $\{1, \dots, n\}$ 的一个非空真子集 $\mathcal{I}$ 以及区间 $I_1, \dots, I_n \subseteq \mathbb{R}$, 只要

$$\mathbb{P}(X_k \in I_k, \forall k \notin \mathcal{I}) > 0,$$

就有

$$\mathbb{P}(X_i \in I_i, \forall i \in \mathcal{I} | X_k \in I_k, \forall k \notin \mathcal{I}) = \mathbb{P}(X_i \in I_i, \forall i \in \mathcal{I}).$$

直观上看, 上述条件就是说, 从 $X_1, \dots, X_n$ 当中任意挑出一组随机变量, 则这组随机变量 (作为随机向量) 取值的统计规律不会受到其它随机变量取值的影响, 而这也就是随机变量独立性的一种直观的理解方式.

值得指出, 在对实际问题进行概率建模时, 我们往往不是从定义出发来推导/验证随机变量的独立性, 而是从产生这些随机变量的实际背景出发, 并根据上述独立性的直观理解方式, 直接判断独立性 (或近似独立性) 是否得到满足, 再利用独立性定义及相关性导出其它结论; 当基于独立性假定所建立的概率模型与实际现象不符时, 我们再考虑替换掉独立性假设.

例 2.6. 设甲的家里有一台光猫和一台无线路由器, 光猫的寿命服从参数为 p_1 的几何分布, 而无线路由器的寿命则服从参数为 p_2 的几何分布, 二者的寿命相互独立. 我们要求出光猫先于无线路由器损坏的概率.

将光猫的寿命记为 X_1 , 无线路由器的寿命记为 X_2 , 则待求的概率为 $\mathbb{P}(X_1 < X_2)$, 而注意到 $\{X_1 < X_2\} = \bigcup_{k=1}^{\infty} \{X_1 = k, X_2 > k\}$, 故有

$$\begin{aligned}
 \mathbb{P}(X_1 < X_2) &= \mathbb{P}\left(\bigcup_{k=1}^{\infty} \{X_1 = k, X_2 > k\}\right) \\
 &= \sum_{k=1}^{\infty} \mathbb{P}(X_1 = k, X_2 > k) = \sum_{k=1}^{\infty} \mathbb{P}(X_1 = k) \cdot \mathbb{P}(X_2 > k) \\
 &= \sum_{k=1}^{\infty} \mathbb{P}(X_1 = k) \left(\sum_{j=k+1}^{\infty} \mathbb{P}(X_2 = j) \right) \\
 &= \sum_{k=1}^{\infty} (1 - p_1)^{k-1} p_1 \left(\sum_{j=k+1}^{\infty} (1 - p_2)^{j-1} p_2 \right) \\
 &= \sum_{k=1}^{\infty} (1 - p_1)^{k-1} p_1 \cdot (1 - p_2)^k = \frac{p_1(1 - p_2)}{1 - (1 - p_1)(1 - p_2)},
 \end{aligned}$$

其中第 2、4 步利用了概率的可数可加性, 第 3 步利用了 X_1 与 X_2 的独立性. ■

接下来我们将重点放在离散型随机变量上. 以下定理指出, 两个离散型随机变量的独立性可以根据其联合分布列来判断; 此外, 若已知两个离散型随机变量相互独立, 则它们的联合分布列可以由边缘分布列确定. 该定理也不难推广到多个离散型随机变量的情况.

定理 2.4. 设 X, Y 为两个离散型随机变量, $p_{X,Y}$ 为 (X, Y) 的联合分布列, p_X, p_Y 为 X, Y 各自的边缘分布列, 则以下三个命题等价:

1. X, Y 相互独立.
2. 联合分布列 $p_{X,Y}$ 满足

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y), \quad \forall (x, y) \in \mathbb{R}^2. \quad (2.4)$$

3. 存在函数 $g, h: \mathbb{R} \rightarrow \mathbb{R}$ 使得

$$p_{X,Y}(x, y) = g(x) \cdot h(y), \quad \forall (x, y) \in \mathbb{R}^2. \quad (2.5)$$

证明. • 命题 1 $\Rightarrow$ 命题 2: 设 X, Y 相互独立. 则对任意 $(x, y) \in \mathbb{R}^2$, 令 $I = [x, x] = \{x\}, J = [y, y] = \{y\}$, 由独立性定义即得到

$$\begin{aligned}
 p_{X,Y}(x, y) &= \mathbb{P}(X \in I, Y \in J) \\
 &= \mathbb{P}(X \in I) \cdot \mathbb{P}(Y \in J) = p_X(x) \cdot p_Y(y).
 \end{aligned}$$

故式 (2.4) 成立.

- 命题 2 $\Rightarrow$ 命题 1: 设式 (2.4) 成立. 任取区间 $I, J \subseteq \mathbb{R}$, 则

$$\begin{aligned}
 \mathbb{P}(X \in I, Y \in J) &= \sum_{(x,y) \in I \times J} p_{X,Y}(x, y) \\
 &= \sum_{(x,y) \in I \times J} p_X(x) \cdot p_Y(y) \\
 &= \sum_{x \in I} \sum_{y \in J} p_X(x) \cdot p_Y(y) \\
 &= \sum_{x \in I} p_X(x) \sum_{y \in J} p_Y(y) \\
 &= \mathbb{P}(X \in I) \cdot \mathbb{P}(Y \in J).
 \end{aligned}$$

由区间 I, J 的任意性, 可得 X, Y 相互独立.

- 命题 2 $\Rightarrow$ 命题 3: 显然.
- 命题 3 $\Rightarrow$ 命题 2: 设式 (2.5) 成立. 两边对 y 求和, 并由边缘分布列与联合分布列的关系, 可得

$$p_X(x) = g(x) \sum_y h(y),$$

两边再对 x 求和并利用 $\sum_x p_X(x) = 1$ 可得

$$1 = \sum_x g(x) \sum_y h(y).$$

类似地有

$$p_Y(y) = h(y) \sum_x g(x),$$

故对任意 $(x, y) \in \mathbb{R}^2$, 有

$$\begin{aligned}
 p_X(x) \cdot p_Y(y) &= g(x) h(y) \sum_x g(x) \sum_y h(y) \\
 &= g(x) h(y) = p_{X,Y}(x, y).
 \end{aligned}$$

因此式 (2.4) 成立. □

例 2.7 (独立离散型随机变量的和). 设 X, Y 为相互独立的离散型随机变量, 我们考察 $Z = X + Y$ 的分布. 由例 2.4 的结果可知, Z 是离散型随机变量, 其分布列为

$$p_Z(z) = \sum_{(x,y): x+y=z} p_{X,Y}(x, y) = \sum_x p_{X,Y}(x, z-x)$$

(该式对于 X, Y 不独立的情形也是成立的). 接下来, 利用 X, Y 的独立性与定理 2.4 即可得到

$$p_Z(z) = \sum_x p_X(x) p_Y(z - x).$$

同理有

$$p_Z(z) = \sum_y p_X(z - y) p_Y(y).$$

以上两个计算 $p_Z(z)$ 的公式又被称为**卷积公式** (convolution formula). ■

以下定理指出, 相互独立的离散型随机变量在经过函数变换后依然保持独立性.

定理 2.5. 设 $n + m$ 个离散型随机变量 $X_1, \dots, X_n, Y_1, \dots, Y_m$ 相互独立, $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 与 $g: \mathbb{R}^m \rightarrow \mathbb{R}$ 为任意函数. 则随机变量 $f(X_1, \dots, X_n)$ 与 $g(Y_1, \dots, Y_m)$ 相互独立.

证明. 为符号上的简洁, 我们以 $n = 2, m = 1$ 的情形为特例给出证明, 但不难将该证明推广到一般情况.

令 $U = f(X_1, X_2), V = g(Y_1)$, 则 (U, V) 的联合分布列为

$$\begin{aligned} p_{U,V}(u, v) &= \mathbb{P}(U = u, V = v) \\ &= \sum_{\substack{(x_1, x_2, y_1): \\ f(x_1, x_2) = u, g(y_1) = v}} \mathbb{P}(X_1 = x_1, X_2 = x_2, Y_1 = y_1) \\ &= \sum_{\substack{(x_1, x_2): \\ f(x_1, x_2) = u}} \sum_{y_1: g(y_1) = v} \mathbb{P}(X_1 = x_1) \cdot \mathbb{P}(X_2 = x_2) \cdot \mathbb{P}(Y_1 = y_1) \\ &= \sum_{\substack{(x_1, x_2): \\ f(x_1, x_2) = u}} \mathbb{P}(X_1 = x_1) \mathbb{P}(X_2 = x_2) \cdot \sum_{y_1: g(y_1) = v} \mathbb{P}(Y_1 = y_1). \end{aligned}$$

令

$$h_1(u) = \sum_{\substack{(x_1, x_2): \\ f(x_1, x_2) = u}} \mathbb{P}(X_1 = x_1) \mathbb{P}(X_2 = x_2), \quad h_2(v) = \sum_{y_1: g(y_1) = v} \mathbb{P}(Y_1 = y_1),$$

则有 $p_{U,V}(u, v) = h_1(u) \cdot h_2(v)$, 故由定理 2.4 得 U, V 相互独立. □

实际上, 定理 2.5 在 $X_1, \dots, X_n, Y_1, \dots, Y_m$ 为一般随机变量 (也就是不全为离散型随机变量) 的时候也是成立的, 其证明超出本课程的范围, 但直观上可以这样理解: 由于 $X_1, \dots, X_n, Y_1, \dots, Y_m$ 相互独立, 故 $X_1, \dots, X_n$ 取值的统计规律不会受到 $Y_1, \dots, Y_m$ 取

值的影响, 而这意味着 $f(X_1, \dots, X_n)$ 取值的统计规律不会受到 $g(Y_1, \dots, Y_m)$ 取值的影响, 从而

$$\mathbb{P}(f(X_1, \dots, X_n) \in I_1 | g(Y_1, \dots, Y_m) \in I_2) = \mathbb{P}(f(X_1, \dots, X_n) \in I_1)$$

对任意 $\mathbb{R}$ 中的区间 I_1, I_2 均成立 (只要条件概率存在). 接下来由条件概率与独立性的定义即可看出 $f(X_1, \dots, X_n)$ 与 $g(Y_1, \dots, Y_m)$ 相互独立.

最后, 我们给出一列 (可数无限个) 随机变量的独立性的定义, 它将在 2.6 节定义伯努利过程时用到.

定义 2.6. 设 $X_1, X_2, X_3, \dots$ 为一随机变量序列. 若任取大于等于 2 的正整数 n , 均有 $X_1, \dots, X_n$ 相互独立, 则称这列随机变量 $X_1, X_2, X_3, \dots$ **相互独立**.

2.5 期望与方差

离散型随机变量的分布列能够完整刻画其统计规律性, 但不一定能较为直观地给出随机变量取值上的一些特点. 本节中我们引入一些随机变量的数字特征, 这些数字特征能够更加直观地揭示随机变量取值在某些方面的性质.

我们首先介绍离散型随机变量的期望, 它是随机变量的所有取值相对于各自概率的加权平均.

定义 2.7. 设 X 为离散型随机变量, p_X 为其分布列. 若 $\sum_x |x| \cdot p_X(x)$ 收敛, 则定义 X 的**期望** (expected value 或 expectation) 为

$$\mathbb{E}[X] = \sum_x x \cdot p_X(x).$$

若 $\sum_x |x| \cdot p_X(x)$ 发散, 则称 $\mathbb{E}[X]$ 不存在.

直观上, 我们可以把随机变量 X 的期望 $\mathbb{E}[X]$ 看作是最能代表 X 的一个确定性数值. 此外, 由期望的定义式, 我们也可以将 $\mathbb{E}[X]$ 直观理解为分布列 p_X 的“质心”.

定义 2.7 之所以要求 $\sum_x |x| \cdot p_X(x)$ 收敛时 $\mathbb{E}[X]$ 才能存在, 是为了保证 $\sum_x x \cdot p_X(x)$ 的值与求和式中各项的排列顺序没有关系; 对此不太熟悉的读者可回顾数学分析中级数的绝对收敛以及黎曼重排定理的相关知识, 例如可参阅 [9] 第十八章第 5 节.

例 2.8. 设 E 为任一事件, 则有

$$\mathbb{E}[1_E] = 1 \cdot \mathbb{P}(E) + 0 \cdot \mathbb{P}(E^c) = \mathbb{P}(E).$$

换句话说, 任一事件的概率就等于其指示函数的期望. 从该结论还可看出, 若一个随机变量服从参数为 p 的伯努利分布, 则其期望就等于 p . ■

接下来我们介绍一个计算期望的重要方法.

定理 2.6. 设 X 为离散型随机变量, p_X 为其分布列, $g: \mathbb{R} \rightarrow \mathbb{R}$ 为任意函数. 则 $\mathbb{E}[g(X)]$ 存在当且仅当 $\sum_x |g(x)| \cdot p_X(x)$ 收敛, 且 $\mathbb{E}[g(X)]$ 存在时有

$$\mathbb{E}[g(X)] = \sum_x g(x) \cdot p_X(x).$$

类似地, 若 (X, Y) 为离散型随机向量, $p_{X,Y}$ 为其分布列, $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为任意二元函数, 则 $\mathbb{E}[h(X, Y)]$ 存在当且仅当 $\sum_{(x,y)} |h(x, y)| \cdot p_{X,Y}(x, y)$ 收敛, 且 $\mathbb{E}[h(X, Y)]$ 存在时有

$$\mathbb{E}[h(X, Y)] = \sum_{(x,y)} h(x, y) \cdot p_{X,Y}(x, y).$$

证明. 这里只给出二维随机向量情形的证明. 注意到 (X, Y) 为离散型随机向量时, $h(X, Y)$ 为离散型随机变量, 故 $\mathbb{E}[h(X, Y)]$ 存在当且仅当

$$\sum_z z \cdot \mathbb{P}(h(X, Y) = z)$$

绝对收敛, 且 $\mathbb{E}[h(X, Y)]$ 存在时即等于该求和式的值. 另一方面, 由例 2.4 可得

$$\mathbb{P}(h(X, Y) = z) = \sum_{\substack{(x,y): \\ h(x,y)=z}} p_{X,Y}(x, y),$$

从而

$$\begin{aligned} \sum_z z \cdot \mathbb{P}(h(X, Y) = z) &= \sum_z z \cdot \sum_{\substack{(x,y): \\ h(x,y)=z}} p_{X,Y}(x, y) \\ &= \sum_z \sum_{\substack{(x,y): \\ h(x,y)=z}} h(x, y) \cdot p_{X,Y}(x, y) \\ &= \sum_{(x,y)} h(x, y) \cdot p_{X,Y}(x, y), \end{aligned}$$

上式左端绝对收敛当且仅当右端绝对收敛¹. 综合以上结果即得待证等式. $\square$

在一些英文文献中, 定理 2.6 又被称为 **law of the unconscious statistician (LOTUS)**. 该定理为计算随机变量函数的期望提供了一条简单的途径, 特别是我们并不需要事先求出随机变量函数的分布.

例 2.9. 设离散型随机变量 X 的分布列为

$$p_X(x) = \begin{cases} \frac{c}{(x+1)(x+2)(x+3)}, & \text{若 } x \in \mathbb{N}, \\ 0, & \text{其它情形,} \end{cases}$$

其中 c 为一待定常数. 则 (i) c 的值是多少? (ii) $\mathbb{E}[X]$ 是否存在? 若存在, 它的值是多少? (iii) $\mathbb{E}[X^2]$ 是否存在? 若存在, 它的值是多少?

首先, c 的值可通过 $\sum_x p_X(x) = 1$ 反解出来:

$$\begin{aligned} 1 &= \sum_x p_X(x) = \sum_{x=0}^{\infty} \frac{c}{(x+1)(x+2)(x+3)} \\ &= c \sum_{x=0}^{\infty} \left(\frac{1}{(x+1)(x+2)} - \frac{1}{(x+1)(x+3)} \right) \\ &= c \sum_{x=0}^{\infty} \left(\frac{1}{x+1} - \frac{1}{x+2} \right) - \frac{c}{2} \sum_{x=0}^{\infty} \left(\frac{1}{x+1} - \frac{1}{x+3} \right) \\ &= c - \frac{c}{2} \left(1 + \frac{1}{2} \right) = \frac{c}{4}, \end{aligned}$$

从而 $c = 4$.

接下来我们计算 $\mathbb{E}[X]$:

$$\begin{aligned} \mathbb{E}[X] &= \sum_{x=0}^{\infty} \frac{4x}{(x+1)(x+2)(x+3)} \\ &= \sum_{x=0}^{\infty} \left(\frac{4}{(x+2)(x+3)} - \frac{4}{(x+1)(x+2)(x+3)} \right) \\ &= 4 \sum_{x=0}^{\infty} \left(\frac{1}{x+2} - \frac{1}{x+3} \right) - \sum_x p_X(x) \\ &= 4 \cdot \frac{1}{2} - 1 = 1. \end{aligned}$$

¹ 这里实际上涉及到了绝对收敛级数的重排定理, 对此有了解的读者可进一步验证相关的推导细节. 也可参考附录 A.1 中的定理 A.2.

最后, 利用 LOTUS (定理 2.6) 可得 $\mathbb{E}[X^2]$ 存在当且仅当 $\sum_x x^2 \cdot p_X(x)$ 收敛, 但当 x 为正整数时有

$$\begin{aligned} x^2 \cdot p_X(x) &= \frac{4x^2}{(x+1)(x+2)(x+3)} = \frac{x}{x+1} \cdot \frac{x}{x+2} \cdot \frac{4}{x+3} \\ &\geq \frac{1}{2} \cdot \frac{1}{3} \cdot \frac{4}{x+3} = \frac{2}{3(x+3)}, \end{aligned}$$

而 $\sum_{x=1}^{\infty} \frac{2}{3(x+3)}$ 发散, 故 $\sum_x x^2 \cdot p_X(x)$ 发散, 从而 $\mathbb{E}[X^2]$ 不存在. $\blacksquare$

以下几个定理则给出了期望的几条重要性质. 首先介绍的是期望的线性, 它不仅是期望最重要的理论性质之一, 而且在许多问题中是简化期望计算的重要工具.

定理 2.7 (期望的线性). 设 X, Y 为离散型随机变量, 且 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 均存在, 则

$$\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y]$$

对任意实数 α, β 均成立.

证明. 将 (X, Y) 的联合分布列记为 $p_{X,Y}$, X 与 Y 各自的边缘分布列分别记为 p_X 与 p_Y . 由定理 2.6 可得

$$\begin{aligned} \mathbb{E}[\alpha X + \beta Y] &= \sum_{(x,y)} (\alpha x + \beta y) \cdot p_{X,Y}(x, y) \\ &= \alpha \sum_x x \sum_y p_{X,Y}(x, y) + \beta \sum_y y \sum_x p_{X,Y}(x, y) \\ &= \alpha \sum_x x \cdot p_X(x) + \beta \sum_y y \cdot p_Y(y) \\ &= \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y], \end{aligned}$$

其中第三步用到了边缘分布列所满足的定理 2.3. $\square$

需要强调的是, 期望的线性的成立条件是非常弱的: 只要随机变量 X 与 Y 各自的期望存在, 期望的线性 $\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y]$ 就必定成立, 而对 X 与 Y 是否独立等没有要求.

例 2.10. 假设有 $n \geq 2$ 个玩家参与某个游戏, 这个游戏有一个投票环节, 要求每个玩家从其余 $n-1$ 个玩家中选出一个并为他投票, 而后统计各个玩家获得的票数. 若每个玩家的投票是完全随机且互不影响的, 则最终得票数为 0 的玩家个数的期望是多少?

我们用期望的线性来求解这个问题. 对任意的 $i \neq j$, 令事件 $F_{i,j}$ 代表第 j 个玩家给第 i 个玩家投了票, 并令事件 F_i 代表第 i 个玩家的得票数为 0, 则有 $\mathbb{P}(F_{i,j}) = 1/(n-1)$ 以及

$$\begin{aligned}\mathbb{P}(E_i) &= \mathbb{P}\left(\bigcap_{j \neq i} F_{i,j}^c\right) = \prod_{j \neq i} \mathbb{P}(F_{i,j}^c) \\ &= \prod_{j \neq i} (1 - \mathbb{P}(F_{i,j})) = \left(1 - \frac{1}{n-1}\right)^{n-1}, \quad \forall i = 1, \dots, n,\end{aligned}$$

其中第二步用到了事件 $F_{i,1}, \dots, F_{i,i-1}, F_{i,i+1}, \dots, F_{i,n}$ 的独立性 (因不同玩家的投票互不影响). 接下来, 注意到得票为 0 的玩家个数可表示为

$$X = \sum_{i=1}^n 1_{E_i},$$

利用期望的线性即可得

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[1_{E_i}] = \sum_{i=1}^n \mathbb{P}(E_i) = n \left(1 - \frac{1}{n-1}\right)^{n-1}.$$

该例的求解思路可以进一步一般化: 设随机变量 X 代表 n 个个体中满足某个给定性质的个体的总数, 为了求出 $\mathbb{E}[X]$, 可令事件 E_i 代表第 i 个个体满足给定性质, 则 $X = \sum_{i=1}^n 1_{E_i}$, 故我们可以先求出 i 个对象满足该性质的概率 $\mathbb{P}(E_i) = \mathbb{E}[1_{E_i}]$, 再由期望的线性可知 $\mathbb{E}[X]$ 就等于所有的 $\mathbb{P}(E_i)$ 的和; 见习题 2.9. 上述求解过程并不要求知道 X 的分布列. ■

接下来的定理则给出了非负随机变量期望的基本性质.

定理 2.8. 设 X 为离散型随机变量, 满足 $\mathbb{P}(X \geq 0) = 1$. 则如下命题成立:

1. 若 $\mathbb{E}[X]$ 存在, 则 $\mathbb{E}[X] \geq 0$.
2. $\mathbb{E}[X] = 0$ 当且仅当 $\mathbb{P}(X = 0) = 1$.

证明. 记 X 的分布列为 p_X .

1. 由 $\mathbb{P}(X \geq 0) = 1$ 可知, 当 $p_X(x) > 0$ 时必定有 $x \geq 0$, 再由期望的定义式即可直接得到 $\mathbb{E}[X] \geq 0$.
2. $\mathbb{P}(X = 0) = 1 \Rightarrow \mathbb{E}[X] = 0$: 由 $\mathbb{P}(X = 0) = 1$ 可得 $x \neq 0$ 时有

$$\mathbb{P}(X = x) \leq \mathbb{P}(X \neq 0) = 0,$$

故对任意 $x \in \mathbb{R}$ 均有 $x \cdot \mathbb{P}(X = x) = 0$, 代入期望的定义即得 $\mathbb{E}[X] = 0$.

$\mathbb{E}[X] = 0 \Rightarrow \mathbb{P}(X = 0) = 1$: 当 $\mathbb{E}[X] = 0$ 时, 由于期望定义式中求和的各项均非负, 可得 $p_X(x) > 0$ 时必定有 $x \cdot p_X(x) = 0$, 从而 $p_X(x)$ 仅在 $x = 0$ 时为正数, 而在 $x \neq 0$ 时均为零. 故

$$1 = \sum_x p_X(x) = p_X(0) = \mathbb{P}(X = 0). \quad \square$$

以下定理指出, 若两个随机变量相互独立, 则它们的乘积的期望等于各自期望的乘积.

定理 2.9. 设 X, Y 为相互独立的离散型随机变量, 且二者的期望均存在, 则

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

证明. 由定理 2.4, 可得 (X, Y) 的联合分布列 $p_{X,Y}$ 与边缘分布列 p_X, p_Y 满足

$$p_{X,Y}(x, y) = p_X(x) p_Y(y), \quad \forall (x, y) \in \mathbb{R}^2,$$

故

$$\begin{aligned} \mathbb{E}[XY] &= \sum_{(x,y)} xy \cdot p_{X,Y}(x, y) \\ &= \sum_{(x,y)} xy \cdot p_X(x) p_Y(y) \\ &= \sum_x x \cdot p_X(x) \sum_y y \cdot p_Y(y) \\ &= \mathbb{E}[X] \cdot \mathbb{E}[Y], \end{aligned}$$

其中第三步把对 (x, y) 的多重求和变换为先对 y 再对 x 的累次求和, 其合法性可由 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 的存在性保证. $\square$

2.5.1 方差

定义 2.8. 设 X 为一离散型随机变量. 若 $\mathbb{E}[X]$ 与 $\mathbb{E}[(X - \mathbb{E}[X])^2]$ 均存在, 则定义 X 的**方差** (variance) 为

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2],$$

并定义 X 的**标准差** (standard deviation) 为 $\sigma(X) = \sqrt{\text{Var}(X)}$.

若 $\mathbb{E}[X]$ 或 $\mathbb{E}[(X - \mathbb{E}[X])^2]$ 不存在, 则称 $\text{Var}(X)$ 不存在.

根据方差的定义, 我们可以直观上认为 $\text{Var}(X)$ 度量了 X 的取值相对于期望 $\mathbb{E}[X]$ 的分散/偏离/波动程度, 也就是说, $\text{Var}(X)$ 越大, 则 X 的取值相对于 $\mathbb{E}[X]$ 的分散/偏离/波动的程度也就越大, 而 $\text{Var}(X)$ 越小, 则 X 的取值越集中于 $\mathbb{E}[X]$ 附近. 这个直观解释可以由如下等式进一步佐证:

$$\text{Var}(aX + b) = a^2 \text{Var}(X), \quad (2.6)$$

其中 a, b 为任意实数. 换句话说, 对 X 的取值进行整体性的平移不会改变其方差, 而若对其取值进行倍数为 a 的放缩, 则方差将变为原来的 a^2 倍. 该等式的证明是直接的:

$$\begin{aligned} \text{Var}(aX + b) &= \mathbb{E}[(aX + b - \mathbb{E}[aX + b])^2] \\ &= \mathbb{E}[(aX - a\mathbb{E}[X])^2] \\ &= a^2 \mathbb{E}[(X - \mathbb{E}[X])^2] = a^2 \text{Var}(X). \end{aligned}$$

将 $(X - \mathbb{E}[X])^2$ 展开并利用期望的线性不难算得

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2. \quad (2.7)$$

在许多情况下用上式计算方差会更加方便. 若进一步将 X 的分布列代入并利用期望的 LOTUS (定理 2.6), 则有

$$\text{Var}(X) = \sum_x x^2 \cdot p_X(x) - \left(\sum_x x \cdot p_X(x) \right)^2. \quad (2.8)$$

例 2.11. 设 X 服从参数为 p 的伯努利分布, 则

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = 1^2 \cdot p + 0^2 \cdot (1 - p) - p^2 = p(1 - p). \quad \blacksquare$$

例 2.12. 设 X 服从 $\{a, \dots, a + n - 1\}$ 上的离散均匀分布, 其中 a 为一实数, n 为一正整数, 我们希望求出 X 的方差. 为此, 注意到 $\text{Var}(X) = \text{Var}(X - r)$, 而 $X - r$ 则服从 $\{0, \dots, n - 1\}$ 上的均匀分布, 则由式 (2.8) 可得

$$\text{Var}(X) = \sum_{k=0}^{n-1} k^2 \cdot \frac{1}{n} - \left(\sum_{k=0}^{n-1} k \cdot \frac{1}{n} \right)^2 = \frac{(n-1)(2n-1)}{6} - \left(\frac{n-1}{2} \right)^2 = \frac{n^2 - 1}{12}. \quad \blacksquare$$

接下来的定理指出, 相互独立的随机变量的和的方差等于它们的方差的和. 这个便利的性质也是人们更愿意用方差来衡量随机变量相对于期望分散程度的原因之一.

定理 2.10. 设 $X_1, \dots, X_n$ 相互独立, 且它们的方差存在, 则

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

证明. 这里只给出 $n = 2$ 时的证明. 一般情形的证明是类似的.

由方差的定义与期望的线性, 可得

$$\begin{aligned} \text{Var}(X_1 + X_2) &= \mathbb{E}[(X_1 + X_2 - \mathbb{E}[X_1 + X_2])^2] \\ &= \mathbb{E}[(X_1 - \mathbb{E}[X_1])^2] + \mathbb{E}[(X_2 - \mathbb{E}[X_2])^2] \\ &\quad + 2\mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])] \\ &= \text{Var}(X_1) + \text{Var}(X_2) + 2\mathbb{E}[(X_1 - \mathbb{E}[X_1])] \cdot \mathbb{E}[(X_2 - \mathbb{E}[X_2])] \\ &= \text{Var}(X_1) + \text{Var}(X_2), \end{aligned}$$

其中第三步来自于 X_1 与 X_2 的独立性. 定理得证. □

2.6 伯努利过程

本节中, 我们基于伯努利过程来阐述二项分布、几何分布与泊松分布的来源、意义和联系.

定义 2.9. 设 $X_1, X_2, \dots$ 为一列随机变量, $p \in]0, 1]$. 若如下条件成立, 则称随机变量列 $(X_n)_{n=1}^\infty$ 为一参数为 p 的**伯努利过程** (Bernoulli process):

1. $X_1, X_2, X_3, \dots$ 相互独立.
2. 每个 X_n 均服从参数为 p 的伯努利分布, 即

$$\mathbb{P}(X_n = 1) = p, \quad \mathbb{P}(X_n = 0) = 1 - p.$$

相当多的实际场景都可以用伯努利过程进行建模, 例如, 以下场景中的随机变量序列 $(X_n)_{n=1}^\infty$ 都可以 (近似地) 看作是伯努利过程:

1. 一家公司进行抽奖促销活动, X_n 代表第 n 个参加抽奖的人抽中还是未抽中.
2. 工厂生产某种产品, X_n 代表第 n 件产品合格还是不合格.
3. 甲与乙进行多局比赛, X_n 代表第 n 局比赛中甲还是乙赢.
4. 考察股票指数的涨跌, X_n 代表股票指数在第 n 天是涨还是跌.

5. 某市的市民中心接待访客, X_n 代表第 n 秒是否有访客到来.

给定一伯努利过程 $(X_n)_{n=1}^{\infty}$, 我们进一步定义

$$N_0 = 0, \quad N_n = \sum_{k=1}^n X_k, \quad n = 1, 2, 3, \dots$$

并用递归的方式定义

$$T_1 = \min\{n \in \mathbb{N}_+ \mid N_n \geq 1\},$$

$$T_k = \min\{n \in \mathbb{N}_+ \mid N_n \geq k\} - \sum_{i=1}^{k-1} T_i, \quad k = 2, 3, 4, \dots$$

可以将伯努利过程 $(X_n)_{n=1}^{\infty}$ 及相应的 $(N_n)_{n=1}^{\infty}$ 、 $(T_k)_{k=1}^{\infty}$ 与独立重复的伯努利试验相关联: 设有某个试验, 其结果只有成功和失败两种, 成功的概率为 p , 失败的概率为 $1-p$, 我们把这样的试验被称为伯努利试验. 我们在离散时刻 $n = 1, 2, 3, \dots$ 独立地重复该试验, 每个时刻对应于一次试验, 则事件 $\{X_n = 1\}$ 代表第 n 次试验成功, 而 N_n 的值代表了时间段 $\{1, \dots, n\}$ 内试验的总成功次数, T_1 的值代表了从初始时刻到第 1 次成功之间的等待时间, $k \geq 2$ 时 T_k 的值代表了第 $k-1$ 次成功到第 k 次成功之间的等待时间; 见图 2.5.




图 2.5: 伯努利过程中 X_n, N_n 与 T_k 的图示.

接下来, 我们研究由伯努利过程 $(X_n)_{n=1}^{\infty}$ 衍生出的随机变量 N_n 与 T_k 的分布.

N_n 的分布. 我们先考察 N_n 的分布. 显然 N_n 为离散型随机变量, 其取值范围为 $\{0, 1, \dots, n\}$. 任取 $k \in \{0, 1, \dots, n\}$, 由基础的组合数学知识可知, 事件 $\{N_n = k\}$ 可看成是 $\binom{n}{k}$ 个形如

$$\{X_1 = x_1, \dots, X_n = x_n\}, \quad x_1, \dots, x_n \text{ 当中有 } k \text{ 个等于 } 1, \text{ 其余 } n-k \text{ 个等于 } 0$$

的互不相交的事件的并, 而由于 $X_1, X_2, \dots$ 相互独立, 可知每个形如上式的事件的概率为

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_1 = x_1) \cdots \mathbb{P}(X_n = x_n) = p^k(1-p)^{n-k}.$$

故 N_n 的分布列为

$$p_{N_n}(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (2.9)$$

由此可看出 N_n 服从参数为 p 的二项分布.

上述结果为二项分布期望与方差的计算提供了一种简便方法: 利用期望的线性, 可得

$$\mathbb{E}[N_n] = \mathbb{E}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{E}[X_i] = np,$$

以及

$$\text{Var}(N_n) = \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = np(1-p).$$

上式第二步用到了 $X_1, X_2, \dots$ 的独立性. 注意到期望与方差的值仅取决于分布本身, 可得参数为 (n, p) 的二项分布的期望为 np , 方差为 $np(1-p)$.

例 2.13. 设 U 服从参数为 (n_1, p) 的二项分布, V 服从参数为 (n_2, p) 的二项分布, 且 U 与 V 相互独立. 则 $Z = U + V$ 服从怎样的分布?

该问题当然可以通过代入卷积公式进行具体计算的方法来求解, 不过我们这里给出一种更简便的做法: 考虑一参数为 p 的伯努利过程 $(X_n)_{n=1}^\infty$, 并令

$$U' = \sum_{i=1}^{n_1} X_i, \quad V' = \sum_{i=n_1+1}^{n_1+n_2} X_i,$$

则 U' 与 U 同分布, V' 与 V 同分布, 且 U' 与 V' 相互独立. 由卷积公式可知 $Z' = U' + V'$ 与 $Y = U + V$ 也是同分布的, 但由伯努利过程的性质可知, $Z' = \sum_{i=1}^{n_1+n_2} X_i$ 显然服从参数为 $(n_1 + n_2, p)$ 的二项分布, 故 Z 同样服从参数为 $(n_1 + n_2, p)$ 的二项分布.

直观上, 可以认为上述解法是给随机变量 U 与 V 赋予了更加具体的实现方法, 即将 U 看作一伯努利过程前 n_1 个时刻中的成功次数, 而将 V 看作同一个伯努利过程随后 n_2 个时刻中的成功次数, 那么 $U + V$ 自然就是该伯努利过程在 $n_1 + n_2$ 个时刻中的总成功次数. ■

T_1 的分布. 接下来我们考察从初始时刻到第一次成功的等待时间 T_1 , 它是一个离散型随机变量, 其取值可以是任意正整数. 为求出 T_1 的分布, 任取一正整数 k , 由 T_1 的定义可得,

$$T_1 = k \iff X_1 = \cdots = X_{k-1} = 0, X_k = 1.$$

故

$$\{T_1 = k\} = \{X_1 = \cdots = X_{k-1} = 0, X_k = 1\}.$$

由 $X_1, X_2, \dots$ 的独立性可得

$$\begin{aligned} \mathbb{P}(T_1 = k) &= \mathbb{P}(X_1 = \cdots = X_{k-1} = 0, X_k = 1) \\ &= \mathbb{P}(X_1 = 0) \cdots \mathbb{P}(X_{k-1} = 0) \cdot \mathbb{P}(X_k = 1) = (1-p)^{k-1}p, \end{aligned}$$

从而 T_1 的分布列为

$$p_{T_1}(k) = (1-p)^{k-1}p, \quad k = 1, 2, 3, \dots$$

这意味着 T_1 服从参数为 p 的几何分布.

几何分布的无记忆性. 考虑这样一个情形: 我们对前 m 个时刻的随机变量 $X_1, \dots, X_m$ 进行了观察, 发现它们的值均为 0 (也就是说, 前 m 个时刻没有一次伯努利试验是成功的), 在这个条件下, 我们还需要等多长时间才能有一次成功的试验? 换句话说, 在给定 $T_1 > m$ 的条件下, $T_1 - m$ 的 (条件) 分布是怎样的?

相关的计算是较为直接的: 对任意正整数 k , 有

$$\begin{aligned} &\mathbb{P}(T_1 - m = k | T_1 > m) \\ &= \frac{\mathbb{P}(T_1 = m + k, T_1 > m)}{\mathbb{P}(T_1 > m)} = \frac{\mathbb{P}(T_1 = m + k)}{\mathbb{P}(T_1 > m)} \\ &= \frac{(1-p)^{m+k-1}p}{\sum_{r=m+1}^{\infty} (1-p)^{r-1}p} = \frac{(1-p)^{m+k-1}p}{(1-p)^m} = (1-p)^{k-1}p. \end{aligned} \tag{2.10}$$

不难发现上式最右端就等于 $\mathbb{P}(T_1 = k)$. 换句话说, 已知 $T_1 > m$ 的作用相当于把时间原点向右平移了 m 个单位时间, 而 $n = m + 1$ 时刻起试验成功与否对于前 m 个时刻的结果是没有记忆的. 一般地, 给定一取值为正整数的随机变量 X , 若 X 满足

$$\mathbb{P}(X = m + k | X > m) = \mathbb{P}(X = k), \quad \forall m, k \in \mathbb{N}_+,$$

我们就称随机变量 X 具有**无记忆性**. 考虑到这里的随机变量 T_1 是直接由伯努利过程中构造而来的, 其无记忆性是非常容易理解的, 但不难看出式 (2.10) 的推导过程仅利用了 T_1 的概率分布而不涉及其具体构造, 因此无记忆性是任意服从几何分布的随机变量都具有的性质.

另一方面, 也可以证明, 若一个取值为正整数的随机变量具有无记忆性, 则它必定服从几何分布.

定理 2.11. 设随机变量 X 的值域为 $\mathbb{N}_+$, 对任意 $t \in \mathbb{N}_+$ 均有 $\mathbb{P}(X > t) > 0$, 且

$$\mathbb{P}(X = t + 1 | X > t) = \mathbb{P}(X = 1),$$

则 $0 < \mathbb{P}(X = 1) < 1$, 且 X 服从参数为 $p = \mathbb{P}(X = 1)$ 的几何分布.

定理 2.11 的证明将留作习题.

几何分布常用来对 (取值为正整数的) 设备的寿命进行建模. 由定理 2.11 可知, 若某设备在 t 时刻正常工作的条件下, 在 $t + 1$ 时刻损坏的概率均为一常数 $p \in]0, 1[$ 而与 t 无关, 则可以认为该设备的寿命²服从参数为 p 的几何分布.

T_k ($k \geq 2$) 的分布. 我们不妨直接求解 $(T_1, \dots, T_k)$ 的联合分布: 令 $t_1, \dots, t_k \in \mathbb{N}_+$ 任意, 并为了方便记 $s_k = \sum_{i=1}^k t_i$. 注意到

$$\begin{aligned} T_1 = t_1, \dots, T_k = t_k & \iff X_{s_1} = \dots X_{s_k} = 1 \\ & \text{且对其它 } 1 \leq n < s_k \text{ 有 } X_n = 0, \end{aligned}$$

故

$$\begin{aligned} \mathbb{P}(T_1 = t_1, \dots, T_k = t_k) &= p^k (1 - p)^{s_k - k} \\ &= p^k (1 - p)^{\sum_{i=1}^k t_i - k} \\ &= \prod_{i=1}^k ((1 - p)^{t_i - 1} p). \end{aligned}$$

² 此处的“寿命”是指算入 0 时刻后设备正常工作所持续的离散时刻的总数.

不难由上式看出 $T_1, \dots, T_k$ 独立同分布, 且均服从参数为 p 的几何分布.

2.6.1 二项分布的泊松分布近似

现在我们考虑一个特殊情况: 设伯努利试验成功的概率 p 非常小, 但另一方面, 我们关心的是 n 很大时 N_n 的分布情况. 若进一步假定 np^2 很小, 则在这种情形下, 我们可以给分布列 (2.9) 找一个更好用的近似计算式.

设 k 是一个正整数, 满足 k^2 远小于 n , 则有

$$\begin{aligned} p_{N_n}(k) &= \frac{n(n-1)\cdots(n-k+1)}{k(k-1)\cdots 1} p^k (1-p)^{n-k} \\ &= (1-p)^{n-k} \frac{(np)^k}{k!} \cdot \prod_{i=0}^{k-1} \left(1 - \frac{i}{n}\right). \end{aligned}$$

接下来我们对上式右端做近似:

1. 为了对 $\prod_{i=0}^{k-1} \left(1 - \frac{i}{n}\right)$ 取近似, 注意到

$$1 \geq \prod_{i=0}^{k-1} \left(1 - \frac{i}{n}\right) \geq 1 - \frac{\sum_{i=0}^{k-1} i}{n} = 1 - \frac{k(k-1)}{2n}.$$

故 k^2 远小于 n 时 $\prod_{i=0}^{k-1} \left(1 - \frac{i}{n}\right)$ 可以近似为 1.

2. 为了对 $(1-p)^{n-k}$ 取近似, 注意到

$$\begin{aligned} \left| \ln \frac{(1-p)^{n-k}}{e^{-np}} \right| &= |n(\ln(1-p) + p) - k \ln(1-p)| \\ &\leq n|\ln(1-p) + p| + k|\ln(1-p)| \\ &\leq \frac{1}{1-p} (np^2 + kp) = \frac{1}{1-p} \left(np^2 + \sqrt{\frac{k^2}{n} \cdot np^2} \right) \\ &\leq \frac{1}{1-p} \left(np^2 + \frac{k^2}{2n} + \frac{np^2}{2} \right), \end{aligned}$$

其中用到了不等式

$$\frac{-p}{1-p} \leq \ln(1-p) \leq -p, \quad \forall p < 1.$$

因此 np^2 与 k^2/n 非常小时可以取近似

$$(1-p)^{n-k} \approx e^{-np}.$$

综上可得

$$p_{N_n}(k) \approx e^{-np} \frac{(np)^k}{k!} \quad (2.11)$$

不难看出上式右端与参数为 np 的泊松分布相吻合; 换句话说, 在一定范围内, 我们可以用参数为 np 的泊松分布去近似参数为 (n, p) 的二项分布. 这里再明确一下式 (2.11) 成立的条件: (i) n 非常大; (ii) np^2 非常小; (iii) k^2 远小于 n .

实际上, 由上面的计算过程不难证明如下命题:

命题 2.12. 给定 $\lambda > 0$, 对任意足够大的正整数 n , 令 $p_n = \lambda/n$, 并令

$$b(k; n, p_n) = \binom{n}{k} p_n^k (1 - p_n)^{n-k},$$

则对任意自然数 k , 有

$$\lim_{n \rightarrow \infty} b(k; n, p_n) = e^{-\lambda} \frac{\lambda^k}{k!}.$$

基于以上结果, 我们通常会用泊松分布来对小概率事件在较长的一段时间内发生的次数进行建模. 一些具体的例子包括: 一本书一页中的错别字个数, 某地区一段时间内发生 6 级以上地震的次数, 一段时间内某种放射性物质发出并由探测器接收到的 α 粒子的数目, 甚至是一大片宇宙空间内有生命存在的星球的个数等.

例 2.14. 甲参加了学校举办的合唱比赛, 这次合唱比赛还有另外 550 人参加, 则在这些人中恰有一个人与甲的生日相同的概率是多少? 假设这 550 人的生日相互独立且均匀分布在 365 天之中, 没有人的生日是 2 月 29 日.

用 N 代表这 550 人中与甲的生日相同的人数. 根据假设, 不难看出 N 服从参数为 $(550, 1/365)$ 的二项分布, 故

$$\mathbb{P}(N = 1) = \binom{550}{1} \cdot \frac{1}{365} \left(1 - \frac{1}{365}\right)^{549}.$$

上述概率在没有较高精度的计算设备时并不容易计算, 它的值约为 0.334154. 接下来, 我们用参数为 $np = 550/365$ 的泊松分布进行近似计算:

$$\mathbb{P}(N = 3) \approx e^{-550/365} \frac{550/365}{1!} = 0.333928 \dots$$

可以看出用泊松分布近似计算的结果是比较准确的. ■

2.7 习题

习题 2.1. 1. 设 E, F 为两个事件. 证明 E, F 相互独立当且仅当它们的指示函数 $1_E, 1_F$ 相互独立.

2. 设 $E_1, \dots, E_n$ 为 n 个事件. 证明 $E_1, \dots, E_n$ 相互独立当且仅当它们的指示函数 $1_{E_1}, \dots, 1_{E_n}$ 相互独立.

习题 2.2. 与、或、异或是基本的二元位运算, 它们的定义如下:

$$a \wedge b = \begin{cases} 1, & a = b = 1, \\ 0, & a = 0 \text{ 或 } b = 0, \end{cases} \quad a \vee b = \begin{cases} 1, & a = 1 \text{ 或 } b = 1, \\ 0, & a = b = 0, \end{cases} \quad a \oplus b = \begin{cases} 1, & a \neq b, \\ 0, & a = b. \end{cases}$$

设 X 服从参数为 p 的伯努利分布, Y 服从参数为 q 的伯努利分布, 且 X 与 Y 相互独立. 试求 $X \wedge Y, X \vee Y$ 以及 $X \oplus Y$ 的分布.

习题 2.3. 设离散型随机向量 (X, Y) 的联合分布列为

$$p_{X,Y}(x, y) = \begin{cases} \frac{C}{(x+y-1)(x+y)(x+y+1)}, & \text{若 } x \in \mathbb{N}_+ \text{ 且 } y \in \mathbb{N}_+ \\ 0, & \text{其它情形,} \end{cases}$$

其中 C 为待定系数. 试求: (i) C 的值; (ii) X 与 Y 各自的边缘分布; (iii) $U = X + Y$ 的概率分布; (iv) $V = X - Y$ 的概率分布.

注: 本题改编自 [8] 第 3.8 节习题 2.

习题 2.4. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, U, V 为定义于 Ω 上的随机变量, 它们的值域均为 $\{1, -1\}$, 且满足

$$\begin{aligned} \mathbb{P}(U = 1) &= \mathbb{P}(U = -1) = \frac{1}{2}, \\ \mathbb{P}(V = 1 | U = 1) &= \mathbb{P}(V = -1 | U = -1) = \frac{1}{3}, \\ \mathbb{P}(V = -1 | U = 1) &= \mathbb{P}(V = 1 | U = -1) = \frac{2}{3}. \end{aligned}$$

令

$$E = \{\omega \in \Omega \mid \text{一元二次方程 } x^2 + U(\omega)x + V(\omega) = 0 \text{ 有实数解}\}.$$

1. 求 $\mathbb{P}(E)$.

2. 令随机变量 $Y: \Omega \rightarrow \mathbb{R}$ 为

$$Y(\omega) = \begin{cases} \text{方程 } x^2 + U(\omega)x + V(\omega) = 0 \text{ 较大的实数解,} & \text{若 } \omega \in E, \\ 0, & \text{若 } \omega \notin E. \end{cases}$$

求 $\mathbb{E}[Y]$.

注: 本题改编自 [10] 第 3.6 节习题 9.

习题 2.5. 设 X 为一离散型随机变量, 其值域包含于自然数集 $\mathbb{N}$, 且 $\mathbb{E}[X]$ 存在. 证明

$$\mathbb{E}[X] = \sum_{n=1}^{\infty} \mathbb{P}(X \geq n) = \sum_{n=0}^{\infty} \mathbb{P}(X > n).$$

提示 由期望的定义出发, 证明

$$\mathbb{E}[X] = \sum_{n=1}^{\infty} n \cdot \mathbb{P}(X = n) = \sum_{n=1}^{\infty} \sum_{m=1}^n \mathbb{P}(X = n),$$

然后交换求和次序 (无需说明交换求和次序的合法性).

习题 2.6. 求解如下离散型概率分布的期望与方差: (i) 参数为 p 的几何分布; (ii) 参数为 λ 的泊松分布.

习题 2.7. 证明如下结论:

1. 对任意事件 A, B , 均有 $1_A \cdot 1_B = 1_{A \cap B}$ 以及 $1_{A^c} = 1 - 1_A$.

2. 给定任意 n 个事件 $A_1, \dots, A_n$, 有

$$\begin{aligned} 1_{A_1 \cup \dots \cup A_n} &= 1 - \prod_{i=1}^n (1 - 1_{A_i}) \\ &= \sum_{i=1}^n 1_{A_i} - \sum_{1 \leq i_1 < i_2 \leq n} 1_{A_{i_1} \cap A_{i_2}} + \dots \\ &\quad + (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} 1_{A_{i_1} \cap \dots \cap A_{i_k}} + \dots + (-1)^{n-1} 1_{A_1 \cap \dots \cap A_n}. \end{aligned}$$

3. 给定任意 n 个事件 $A_1, \dots, A_n$, 有

$$\begin{aligned} &\mathbb{P}(A_1 \cup \dots \cup A_n) \\ &= \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i_1 < i_2 \leq n} \mathbb{P}(A_{i_1} \cap A_{i_2}) + \dots \\ &\quad + (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) + \dots + (-1)^{n-1} \mathbb{P}(A_1 \cap \dots \cap A_n). \end{aligned}$$

上述等式又被称为概率的**容斥原理** (inclusion-exclusion principle).

习题 2.8. 设有 N 个人参加面试, 每个人需要从一个装了 N 道题目的黑盒子中随机抽取一道作为自己的面试题, 抽取是有放回. 试问面试过程结束后, 至少有一道题目未被抽到的概率是多少?

提示 将事件“第 i 道题未被抽到”记为 E_i , 用 $E_i, i = 1, \dots, N$ 表示事件“至少有一道题目未被抽到”, 而后尝试用概率的容斥原理.

习题 2.9. 设 $E_1, \dots, E_n$ 为 n 个事件, 并令 $X = \sum_{i=1}^n 1_{E_i}$. 证明

$$\begin{aligned}\mathbb{E}[X] &= \sum_{i=1}^n \mathbb{P}(E_i), \\ \text{Var}(X) &= \sum_{i=1}^n \mathbb{P}(E_i)(1 - \mathbb{P}(E_i)) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n (\mathbb{P}(E_i \cap E_j) - \mathbb{P}(E_i)\mathbb{P}(E_j)).\end{aligned}$$

提示 利用期望的线性. 求 $\text{Var}(X)$ 时, 将 $(\sum_{i=1}^n 1_{E_i})^2$ 展开, 并注意到 $1_{E_i}^2 = 1_{E_i}$.

习题 2.10. 设 $(\Omega, 2^\Omega, \mathbb{P})$ 为一概率空间, 其中 Ω 为可数集.

1. 证明: 任意定义域为 Ω 的函数 $X: \Omega \rightarrow \mathbb{R}$ 一定是一个离散型随机变量.
2. 设 $X: \Omega \rightarrow \mathbb{R}$ 为一随机变量, 且 $\mathbb{E}[X]$ 存在. 证明

$$\mathbb{E}[X] = \sum_{\omega \in \Omega} X(\omega) \cdot \mathbb{P}(\{\omega\}).$$

3. 在样本空间 Ω 为可数集的假设下, 利用第 2 小题的结论, 给出期望的线性

$$\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y]$$

的新的证明 (其中 X, Y 均为定义在 Ω 上的随机变量).

习题 2.11. 令 n 为大于等于 3 的正整数, 并令 S_n 表示所有 $\{1, \dots, n\} \rightarrow \{1, \dots, n\}$ 的双射构成的集合. 给定 $\sigma \in S_n$ 以及 $k \in \{1, \dots, n\}$, 若如下三个条件中有一个得到满足:

1. $2 \leq k \leq n-1$ 且 $\sigma(k) > \sigma(k+1)$ 以及 $\sigma(k) > \sigma(k-1)$;
2. $k=1$ 且 $\sigma(k) > \sigma(k+1)$;
3. $k=n$ 且 $\sigma(k) > \sigma(k-1)$;

则称 k 是 σ 的一个局部极大值点. 现从 S_n 中均匀地随机选一个元素, 并将其局部极大值点的个数计作 X , 试求 $\mathbb{E}[X]$.

注: 本题选自 [7] 习题 4.10.

习题 2.12. 证明定理 2.11: 设随机变量 X 的值域为 $\mathbb{N}_+$, 对任意 $t \in \mathbb{N}_+$ 均有 $\mathbb{P}(X > t) > 0$, 且

$$\mathbb{P}(X = t + 1 | X > t) = \mathbb{P}(X = 1),$$

则 $0 < \mathbb{P}(X = 1) < 1$, 且 X 服从参数为 $p = \mathbb{P}(X = 1)$ 的几何分布.

提示 首先证明递推关系

$$\mathbb{P}(X = k + 1) = p \left(1 - \sum_{j=1}^k \mathbb{P}(X = j) \right),$$

而后利用数学归纳法证明 $\mathbb{P}(X = k) = (1 - p)^{k-1}p$.

习题 2.13 (Erdős-Rényi 随机图). 设有 n 个顶点, 标号为 $1, 2, \dots, n$. 对于每一对顶点 i, j (其中 $i \neq j$), 我们以概率 p 将这两点用一条边连接起来, 且 i, j 之间是否连边与其它各对顶点之间是否连边相互独立. 通过这种方法生成的随机图被称为 Erdős-Rényi 随机图, 我们将其用 $\mathcal{G}(n, p)$ 表示.

1. 在 $\mathcal{G}(n, p)$ 中任取一顶点后, 将该顶点的度 (即该顶点总共连有多少条边) 记为 D , 试求出 D 的分布列.
2. 若 $p = \lambda/(n-1)$, 其中 $\lambda > 0$ 为一常数, 试证明

$$\lim_{n \rightarrow \infty} \mathbb{P}(D = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad \forall k \in \mathbb{N}.$$

3. 令 T 表示 $\mathcal{G}(n, p)$ 中三角形的个数, 也即 $\mathcal{G}(n, p)$ 当中有多少组 (互不相同的) 顶点 i, j, k 使得它们两两之间都有边相连. 试求出 $\mathbb{E}[T]$.

习题 2.14 (超几何分布). 设一个罐子中有 b 个蓝色球和 $m - b$ 个红色球. 现从这个罐子中无放回地随机抽取 n 个球, 并用 B 表示这 n 个球中蓝色球的个数.

1. 证明: 对任意满足 $\max\{0, n + b - m\} \leq k \leq \min\{b, n\}$ 的整数 k , 有

$$\mathbb{P}(B = k) = \frac{\binom{b}{k} \binom{m-b}{n-k}}{\binom{m}{n}},$$

而对其余的 x 则均有 $\mathbb{P}(B = x) = 0$.

我们将 B 服从的离散型分布称作参数为 (m, b, n) 的**超几何分布** (hypergeometric distribution).

2. 试求参数为 (m, b, n) 的超几何分布的期望与方差.

提示 令 E_i 表示第 i 个抽取的球为蓝色, 则 $B = \sum_{i=1}^n 1_{E_i}$, 而后用习题 2.9 的结论.

3. 现设 b 为 m 的函数, 且 $m \rightarrow \infty$ 时有 $b/m \rightarrow p$, 其中 $p \in [0, 1]$. 固定 n 与 k , 证明

$$\lim_{m \rightarrow \infty} \mathbb{P}(B = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

4. 现设 X 与 Y 相互独立且分别服从参数为 (b, p) 与 $(m-b, p)$ 的二项分布. 给定任意正整数 n 与自然数 k , 试求条件概率 $\mathbb{P}(X = k | X + Y = n)$.

习题 2.15. 设 $X_1, X_2, \dots$ 为一参数为 p 的伯努利过程. 令 N 服从参数为 λ 的泊松分布, 并设 $N, X_1, X_2, \dots$ 相互独立. 令

$$U = \sum_{i=1}^N X_i.$$

1. 求 $(U, N - U)$ 的联合分布列, 并证明 U 与 $N - U$ 相互独立.

提示 注意到

$$\begin{aligned} \mathbb{P}(U = x, N - U = y) &= \mathbb{P}(U = x, N = x + y) \\ &= \mathbb{P}\left(\sum_{i=1}^{x+y} X_i = x, N = x + y\right) = \mathbb{P}\left(\sum_{i=1}^{x+y} X_i = x\right) \mathbb{P}(N = x + y). \end{aligned}$$

2. 求 U 的分布列.

习题 2.16 (多项分布). 设 $X_1, \dots, X_n$ 为独立同分布的离散型随机变量, 它们的值域均为 $\{1, 2, \dots, r\}$ (r 为给定正整数), 分布列为

$$p_{X_1}(k) = \dots = p_{X_n}(k) = p_k, \quad k = 1, 2, \dots, r,$$

其中 $p_1, p_2, \dots, p_r$ 为给定的非负实数, 满足 $\sum_{k=1}^r p_k = 1$. 现对每个 $k = 1, 2, \dots, r$, 定义

$$N_k = \sum_{i=1}^n 1_{\{X_i=k\}}.$$

1. 求 $(N_1, \dots, N_r)$ 的联合分布列.

2. 求每个 N_k 的边缘分布列.
3. 求 $k \neq j$ 时 $\mathbb{E}[N_k N_j]$ 的值.

习题 2.17 (负二项分布). 设 $X_1, X_2, \dots$ 为一参数为 p 的伯努利过程. 对任意正整数 r , 令 H_r 为第 r 次伯努利试验成功时的总试验次数.

1. 证明: H_r 的分布列为

$$p_{H_r}(k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, r+2, \dots$$

我们将上述分布列给出的概率分布称为参数为 (r, p) 的**负二项分布** (negative binomial distribution) 或帕斯卡分布 (Pascal distribution).

2. 试求参数为 (r, p) 的负二项分布的期望与方差.

提示 利用 $H_r = \sum_{k=1}^r T_k$, 其中各 T_k 的含义如图 2.5 所示.

3. 设一个人不断地掷一枚均匀立方体骰子, 直到掷出大于 2 的点数达到五次为止. 试求整个过程中掷出点数小于等于 2 的次数的期望.
4. 考虑 Banach 火柴盒问题 (例 1.9), 假设随机选择火柴盒时不再是等概率地选取, 而是以概率 p 选择一号火柴盒, 以概率 $1-p$ 选择二号火柴盒. 试求这种情况下, 某次取火柴发现待取火柴盒已空时另一个火柴盒里还剩 k 根火柴的概率.

习题 2.18. 1. 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量, 集合 $A, B \subseteq \mathbb{R}$ 互不相交, 且满足 $\mathbb{P}(X_1 \in A \cup B) > 0$. 令

$$T = \min\{n \in \mathbb{N}_+ \mid X_n \in A \cup B\}.$$

证明

$$\mathbb{P}(X_T \in A) = \frac{\mathbb{P}(X_1 \in A)}{\mathbb{P}(X_1 \in A \cup B)}.$$

提示 先证明 $\{X_T \in A\} = \bigcup_{\tau=1}^{\infty} \{X_1 \notin A \cup B, \dots, X_{\tau-1} \notin A \cup B, X_{\tau} \in A\}$.

2. 考虑这样一个游戏: 设你有一对均匀的六面骰子, 你先掷一次这对骰子并得到点数之和 X , 若 X 等于 7 或 11 则直接获胜, 若 X 等于 2、3 或 12 则直接输掉游戏, 否则进入下一个环节: 你重复投掷这一对骰子, 直到掷出的点数之和等于 7 或 X 时停止游戏, 若停止时掷出的点数之和为 7 则输掉游戏, 否则获胜. 试求在这个游戏中获胜的概率.

注: 本题取自 [4] 第二章习题 26.

习题 2.19 (De Montmort 匹配问题). 设有 n 个编号为 1 到 n 的小球, 以及 n 个编号为 1 到 n 的盒子. 将 n 个小球充分打乱后放到 n 个盒子中, 每个盒子中有一个小球. 令 K 表示盒子编号与小球编号相匹配的数目.

1. 求 $\mathbb{P}(K = 0)$, 即每个盒子的编号和其中小球的编号都不相同的概率.

提示 令事件 E_i 表示“第 i 个盒子中的小球编号为 i ”, 则 $\mathbb{P}(K = 0) = \mathbb{P}(\bigcap_{i=1}^n E_i^c)$, 接下来用习题 2.7 的结论求该式右端的概率.

2. 求 $\mathbb{E}[K]$ 以及 $\text{Var}(K)$.

提示 利用 $K = \sum_{i=1}^n 1_{E_i}$, $1_{E_i} \cdot 1_{E_j} = 1_{E_i \cap E_j}$ 以及期望的线性.

3. 求随机变量 K 的分布列 p_K . (*) 该分布列是否满足 $\sum_k p_K(k) = 1$?
4. 证明 n 趋于无穷大时 $p_K(k)$ 趋向于 $e^{-1}/k!$. 这说明 n 很大时, K 近似服从参数为 1 的泊松分布.

习题 2.20 (赠券收集问题, coupon collector's problem). 某商家为促销歌手 A 的唱片, 在顾客每购买一张歌手 A 的唱片后即附赠一张海报. 假设商家手上总共有 N 种海报, 每次赠送海报时都是从这 N 种当中随机选择一种赠送. 现张三希望通过不断购买歌手 A 的唱片来收集这些海报. 若张三在购买了 T 张唱片后终于集齐了所有 N 种海报, 试求 $\mathbb{E}[T]$.

习题 2.21. 设有一枚不均匀的硬币, 它抛出正面的概率为 $p \in]0, 1/2[$, 抛出反面的概率为 $1 - p$; p 的取值未知.

1. 试设计一种方法, 通过独立重复地抛掷这枚不均匀硬币来产生一个随机数 X , 使得 X 服从参数为 $1/2$ 的伯努利分布.

提示 注意到若连续抛掷两次硬币, 则出现先正后反与出现先反后正的概率相等³.

2. 在你给出的方法中, 平均需要抛掷多少次硬币才能产生一个随机数?

³ 此为 John von Neumann 给出的思路, 见 [11].

第三章 连续型随机变量

3.1 连续型随机变量

定义 3.1. 设 X 为一随机变量. 若存在非负函数 $f_X: \mathbb{R} \rightarrow [0, +\infty[$, 使得对任意区间 $I \subseteq \mathbb{R}^n$, 均有

$$\mathbb{P}(X \in I) = \int_I f_X(x) dx, \quad (3.1)$$

则称随机变量 X 为一**连续型随机变量** (continuous random variable), 并称函数 f_X 为 X 的一个**概率密度函数** (probability density function, p.d.f.).

注 3.1. 连续型随机变量的概率密度函数并不唯一, 因为我们可以改变 f_X 在有限多个点的值而不影响式 (3.1) 成立. 但可以证明, 若两个函数 $f_X^{(1)}$ 与 $f_X^{(2)}$ 均满足式 (3.1), 函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $\int_{-\infty}^{+\infty} g(x) f_X^{(1)}(x) dx$ 存在, 则 $\int_{-\infty}^{+\infty} g(x) f_X^{(2)}(x) dx$ 同样存在, 且有

$$\int_{-\infty}^{+\infty} g(x) f_X^{(2)}(x) dx = \int_{-\infty}^{+\infty} g(x) f_X^{(1)}(x) dx.$$

因此, 即使选取不同的概率密度函数, 它们在积分号下的行为也是一致的. 在本讲义随后的部分中, 对于连续型随机变量 X , 我们将用 f_X 来表示任一满足式 (3.1) 的概率密度函数, 而不去考虑概率密度函数的不唯一性. ■

定义 3.1 虽然仅直接给出了随机变量 X 落于某区间的概率值, 但由于实际问题中常见的子集 $B \subseteq \mathbb{R}$ 通常都能表示为可数多个互不相交的区间的并, 故我们可以用概率的可数可加性得到

$$\mathbb{P}(X \in B) = \int_B f_X(x) dx,$$

其中的积分 $\int_B f_X(x) dx$ 读者也可理解为 $\int_{-\infty}^{+\infty} 1_B(x) \cdot f_X(x) dx$, 即 $f_X(x)$ 与指示函数 $1_B(x)$ 相乘后对 x 在整个实数轴上的积分. 此外, 由定义不难看出, 对于连续型随机变

量 X , 它取某个给定值的概率总是零:

$$\mathbb{P}(X = a) = \int_a^a f_X(x) dx = 0.$$

而对于左端点为 a 、右端点为 b 的区间 I , 无论 I 是闭区间、开区间还是半开半闭区间, X 落于区间 I 的概率都是相同的:

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

概率密度函数 f_X 可以按如下方式进行直观理解: 当 $\delta > 0$ 足够小, 且 f_X 在点 x 处连续时, 则 $f_X(x) \cdot \delta$ 给出了 X 处于 x 到 $x + \delta$ 之间的概率, 即

$$f_X(x) \cdot \delta \approx \mathbb{P}(X \in [x, x + \delta[),$$

或

$$f_X(x) = \lim_{\delta \rightarrow 0^+} \frac{\mathbb{P}(X \in [x, x + \delta[)}{\delta}.$$

$f_X(x)$ 本身并不是任何事件的概率, 因此它可以大于 1; 函数 f_X 甚至可以在 $\mathbb{R}$ 上没有上界. 此外, 式 (3.1) 在形式上类似于物理学中利用线密度计算一维物体某一段的质量, 其中 $f_X(x)$ 起到的就是线密度的作用, 这个类比也为概率密度函数提供了一种直观的理解方式.

概率密度函数所满足的基本性质由如下定理列出.

定理 3.1. 设 X 为一连续型随机变量, 则 X 的概率密度函数 f_X 满足

1. 非负性: 对任意 $x \in \mathbb{R}$, 均有 $f_X(x) \geq 0$;

2. 归一性: $\int_{-\infty}^{+\infty} f_X(x) dx = 1$.

证明. 非负性来自于概率密度函数的定义. 归一性则来自于

$$\int_{-\infty}^{+\infty} f_X(x) dx = \mathbb{P}(X \in]-\infty, +\infty[) = \mathbb{P}(\Omega) = 1. \quad \square$$

定理 3.1 的逆定理也同样成立: 若函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ 满足非负性与归一性条件, 则存在一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 及其上的随机变量 X , 使得 X 为连续型随机变量, 且 f 为 X 的概率密度函数. 此时我们称 f 给出了一个**连续型分布**. 这个结论的证明不做要求.

需要指出, “连续型随机变量”这一术语中的“连续型”容易被误解, 读者尤其要注意以下几点:

- 取值范围连续的随机变量不一定是连续型随机变量 (见后面的例 3.6 与例 3.10) .
- 连续型随机变量的概率密度函数不一定连续 (见下一小节将要介绍的区间上的均匀分布与指数分布) .

3.1.1 常见的连续型分布

均匀分布. 设 $I \subseteq \mathbb{R}$ 为一非空的有限长区间且不是单点集, 我们用 $m(I)$ 表示区间 I 的长度. 若连续型随机变量 X 的概率密度函数为

$$f_X(x) = \frac{1}{m(I)} \cdot 1_I(x) = \begin{cases} \frac{1}{m(I)}, & \text{若 } x \in I, \\ 0, & \text{其它情形,} \end{cases}$$

则称 X 服从区间 I 上的**均匀分布** (uniform distribution)¹. 不难看出例 2.2 当中的随机变量 X 即服从 $[0, \alpha]$ 上的均匀分布. 图 3.1 给出了区间上均匀分布的概率密度函数图像.




图 3.1: 区间 $[a, b]$ 上均匀分布的概率密度函数图像.

指数分布. 设 $\lambda \in]0, +\infty[$. 若连续型随机变量 X 的概率密度函数为

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0, \end{cases}$$

¹ 依照此处的定义以及注 3.1, 闭区间 $[a, b]$ 与开区间 $]a, b[$ 上的均匀分布实际上是同一种分布, 本讲义不对它们做出区分, 但在某些场合会根据 X 的值域为 $[a, b]$ 还是 $]a, b[$ 来对它们进行区分.

则称 X 服从参数为 λ 的**指数分布** (exponential distribution). 不难验证上式的确给出了一个概率密度函数. 人们常用服从指数分布的随机变量对等待时间、器件寿命等量进行建模. 图 3.2 给出了指数分布的概率密度函数图像.




图 3.2: 参数为 λ 的指数分布的概率密度函数图像.

正态分布/高斯分布. 设 $\mu \in \mathbb{R}$, $\sigma \in]0, +\infty[$. 若连续型随机变量 X 的概率密度函数为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad (3.2)$$

则称 X 服从参数为 (μ, σ^2) 的**(一维) 正态分布或高斯分布** (univariate normal/Gaussian distribution). 通常我们用 $\mathcal{N}(\mu, \sigma^2)$ 指代参数为 (μ, σ^2) 的正态分布, 并用 $X \sim \mathcal{N}(\mu, \sigma^2)$ 表示 X 服从该正态分布. 图 3.3 给出了正态分布的概率密度函数图像.




图 3.3: 正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的概率密度函数图像.

为验证式 (3.2) 的确给出了一个概率密度函数, 需要利用积分

$$\int_{-\infty}^{+\infty} \exp(-x^2) dx = \sqrt{\pi}.$$

我们将具体的计算细节留给读者完成.

此外, 我们将一维正态分布 $\mathcal{N}(0, 1)$ 称为**标准正态分布** (standard normal distribution), 其概率密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

3.2 连续型随机向量

为教学上的方便, 本节中主要介绍二维连续型随机向量的相关概念与结果, 但它们不难推广到更一般的 n 维情况.

定义 3.2. 设 (X, Y) 为一随机向量. 若存在非负二元函数 $f_{X,Y} : \mathbb{R}^2 \rightarrow [0, +\infty[$, 使得对任意区间 $I, J \subseteq \mathbb{R}$, 有

$$\mathbb{P}((X, Y) \in I \times J) = \iint_{I \times J} f_{X,Y}(x, y) \, dx dy, \quad (3.3)$$

则称随机向量 (X, Y) 为一**连续型随机向量**, 并称函数 $f_{X,Y}$ 为随机向量 (X, Y) 的一个**联合概率密度函数** (joint probability density function, joint p.d.f.)².

对于连续型随机向量 (X, Y) , 虽然定义 3.2 仅直接给出了 (X, Y) 取值于矩形区域中的概率, 但对于常见的 $\mathbb{R}^2$ 的子集 B , 原则上均可证明

$$\mathbb{P}((X, Y) \in B) = \iint_B f_{X,Y}(x, y) \, dx dy, \quad (3.4)$$

其中积分 $\iint_B f_{X,Y}(x, y) \, dx dy$ 可以理解为 $\iint_{\mathbb{R}^2} \mathbf{1}_B(x, y) \cdot f_{X,Y}(x, y) \, dx dy$. 上式的严格证明属于高等概率论的内容, 本讲义不做要求, 但读者应能够熟练运用.

与一维情形类似, 若 (X, Y) 为连续型随机向量, 则其联合概率密度函数 $f_{X,Y}$ 满足

1. 非负性: 对任意 $(x, y) \in \mathbb{R}^2$, 均有 $f_{X,Y}(x, y) \geq 0$;
2. 归一性: $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \, dx dy = 1$.

该结论的证明留给读者完成. 这个结论的逆命题也同样成立: 若二元函数 $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ 满足非负性与归一性条件, 则存在一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 及其上的连续型随机向量 (X, Y) , 使得 f 为 (X, Y) 的联合概率密度函数. 该逆命题的证明不做要求.

² 与一维情形的注 3.1 类似, 连续型随机向量的联合概率密度函数也不具有严格的唯一性, 但这种不唯一性不会影响概率以及期望的相关计算, 故我们通常不去考虑这种不唯一性.

例 3.1. 设 (X, Y) 为连续型随机向量, 其联合概率密度函数为

$$f_{X,Y}(x, y) = \begin{cases} ce^{-\lambda x - \mu y}, & \text{若 } x > 0 \text{ 且 } y > 0, \\ 0, & \text{其它情形,} \end{cases}$$

其中 c, λ, μ 均为正的常数, 我们希望回答如下问题: (i) 如何用 λ 与 μ 表示 c ? (ii) 概率 $\mathbb{P}(X < Y)$ 的值是多少?

对于第一个问题, 我们利用联合概率密度函数的归一性, 可得

$$1 = c \int_0^{+\infty} \left(\int_0^{+\infty} e^{-\lambda x - \mu y} dx \right) dy = \frac{c}{\lambda \mu},$$

故 $c = \lambda \mu$.

对于第二个问题, 令 $B = \{(x, y) \in \mathbb{R}^2 \mid x < y\}$, 则 $\mathbb{P}(X < Y) = \mathbb{P}((X, Y) \in B)$, 再利用式 (3.4), 可得

$$\begin{aligned} \mathbb{P}(X < Y) &= \iint_B f_{X,Y}(x, y) dx dy \\ &= \int_0^{+\infty} \left(\int_x^{+\infty} \lambda \mu e^{-\lambda x - \mu y} dy \right) dx \\ &= \int_0^{+\infty} \lambda e^{-(\lambda + \mu)x} dx \\ &= \frac{\lambda}{\lambda + \mu}. \end{aligned}$$

注: 在学习了 3.3 节的内容以后, 读者应当能看出 X 与 Y 相互独立, 且分别服从参数为 λ 与 μ 的指数分布. ■

需要指出的是, 当 X 与 Y 分别为连续型随机变量时, (X, Y) 并不一定是连续型随机向量. 例如, 若 X 服从 $[0, 1]$ 上的均匀分布, 而 $Y = -X$, 则 X, Y 均为连续型随机变量, 但由于 $\mathbb{P}(X + Y = 0) = 1$, 而对任意非负的可积函数 $f: \mathbb{R}^2 \rightarrow [0, +\infty[$, 均有

$$\iint_B f(x, y) dx dy = 0, \quad \text{其中 } B = \{(x, y) \in \mathbb{R}^2 \mid x + y = 0\},$$

可知 (X, Y) 不是连续型随机向量.

但另一方面, 可以证明, 若 (X, Y) 为连续型随机向量, 则 X 与 Y 均为连续型随机变量, 且他们各自的概率密度函数可由联合概率密度函数 $f_{X,Y}$ 求得.

定理 3.2. 设 (X, Y) 为连续型随机向量, 其联合分布密度函数为 $f_{X,Y}$. 则 X 与 Y 均为连续型随机变量, 且二者的概率密度函数分别为

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy, \quad x \in \mathbb{R};$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx, \quad y \in \mathbb{R}.$$

证明. 任取区间 $I \subseteq \mathbb{R}$, 并令 $J =]-\infty, +\infty[$, 则由定义 3.2, 有

$$\begin{aligned} \mathbb{P}(X \in I) &= \mathbb{P}((X, Y) \in I \times J) \\ &= \iint_{I \times J} f_{X,Y}(x, y) dx dy \\ &= \int_I \left(\int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy \right) dx. \end{aligned}$$

观察上式并与定义 3.1 及式 (3.1) 对比, 即可看出 X 为连续型随机变量, 其概率密度函数为

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy.$$

对于随机变量 Y 同理. □

我们将定理 3.2 中 X, Y 的概率密度函数 f_X, f_Y 分别称为 $f_{X,Y}$ 关于第 1 个与第 2 个分量的**边缘概率密度函数** (marginal probability density function, marginal p.d.f.). 同样需要强调的是, 一般情况下, 连续性随机向量的联合概率密度函数并不能由各个边缘概率密度函数唯一确定.




图 3.4: 例 3.2 中 X 与 Y 的概率分布.

例 3.2. 记平面 $\mathbb{R}^2$ 上圆心为原点、半径为 r 的圆盘为

$$\mathbb{D}_r = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq r^2\}.$$

设连续型随机向量 (X, Y) 的联合概率密度函数为

$$f_{X,Y}(x, y) = \begin{cases} c, & \text{若 } (x, y) \in \mathbb{D}_r, \\ 0, & \text{若 } (x, y) \in \mathbb{R}^2 \setminus \mathbb{D}_r, \end{cases}$$

其中 c 为一个待定常数. 根据 $\iint_{\mathbb{R}^2} f_{X,Y}(x, y) dx dy = 1$, 不难看出 $c = (\pi r^2)^{-1}$. 图 3.4a 给出了 $f_{X,Y}$ 的图像. 有时我们将上述分布称为圆盘 $\mathbb{D}_r$ 上的均匀分布. 此时 X 的边缘概率密度函数为

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy \\ &= \begin{cases} \int_{-\sqrt{r^2-x^2}}^{\sqrt{r^2-x^2}} \frac{1}{\pi r^2} dy = \frac{2}{\pi r^2} \sqrt{r^2-x^2}, & \text{若 } |x| \leq r, \\ 0, & \text{若 } |x| > r. \end{cases} \end{aligned}$$

f_X 的图像见图 3.4b. 利用类似的步骤 (或根据对称性) 可得 Y 的边缘概率密度函数为

$$f_Y(y) = f_X(y) = \begin{cases} \frac{2}{\pi r^2} \sqrt{r^2-y^2}, & \text{若 } |y| \leq r, \\ 0, & \text{若 } |y| > r, \end{cases}$$

即 Y 与 X 同分布.

现令连续型随机向量 (U, V) 的联合概率密度函数为

$$f_{U,V}(u, v) = \begin{cases} \frac{4}{\pi^2} \sqrt{1-u^2} \sqrt{1-v^2}, & \text{若 } |u| \leq 1 \text{ 且 } |v| \leq 1, \\ 0, & \text{若 } |u| > 1 \text{ 或 } |v| > 1. \end{cases}$$

则不难验证, 随机变量 U, V 同分布且均与 X 同分布, 但随机向量 (U, V) 与随机向量 (X, Y) 各自的二维联合分布并不相同. ■

3.3 连续型随机变量的独立性

在第 2.4 节中, 我们已经给出了随机变量独立性的一般性定义 (即定义 2.5), 该定义自然也适用于连续型随机变量.

例 3.3. 设 (X, Y) 服从圆盘 $\mathbb{D}_r = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq r^2\}$ 上的均匀分布, 其联合

概率密度函数以及两个边缘概率密度函数已经在例 3.2 中给出. 注意到

$$\begin{aligned}\mathbb{P}\left(X > \frac{r}{\sqrt{2}}\right) \cdot \mathbb{P}\left(Y > \frac{r}{\sqrt{2}}\right) &= \int_{r/\sqrt{2}}^r \frac{2}{\pi r^2} \sqrt{r^2 - x^2} dx \int_{r/\sqrt{2}}^r \frac{2}{\pi r^2} \sqrt{r^2 - y^2} dy \\ &= \left(\frac{\pi - 2}{4\pi}\right)^2,\end{aligned}$$

但显然有 $\mathbb{P}(X > r/\sqrt{2}, Y > r/\sqrt{2}) = 0$, 故 X 与 Y 不相互独立. ■

下面我们介绍连续型随机变量相互独立的充要条件: 两个连续型随机变量相互独立, 当且仅当其联合概率密度函数可表示为各自 (边缘) 概率密度函数的乘积; 这个结论与离散情形下的定理 2.4 相对应.

定理 3.3. 设 X, Y 为两个连续型随机变量, f_X, f_Y 为各自的概率密度函数. 则以下三个命题等价:

1. X 与 Y 相互独立.
2. (X, Y) 为连续型随机向量, 且二元函数

$$(x, y) \mapsto f_X(x) \cdot f_Y(y), \quad (x, y) \in \mathbb{R}^2 \quad (3.5)$$

给出 (X, Y) 的联合概率密度函数.

3. (X, Y) 为连续型随机向量, 且存在一元函数 $g, h: \mathbb{R} \rightarrow \mathbb{R}$ 使得二元函数

$$(x, y) \mapsto g(x) \cdot h(y), \quad (x, y) \in \mathbb{R}^2. \quad (3.6)$$

给出 (X, Y) 的联合概率密度函数.

证明. • 命题 1 $\Rightarrow$ 命题 2: 设 X, Y 相互独立. 任取区间 $I, J \subseteq \mathbb{R}$, 则有

$$\begin{aligned}\mathbb{P}((X, Y) \in I \times J) &= \mathbb{P}(X \in I, Y \in J) \\ &= \mathbb{P}(X \in I) \cdot \mathbb{P}(Y \in J) \\ &= \int_I f_X(x) dx \int_J f_Y(y) dy \\ &= \iint_{I \times J} f_X(x) \cdot f_Y(y) dx dy.\end{aligned}$$

将上式与定义 3.2 对照, 可得 (X, Y) 为连续型随机向量, 且函数 $(x, y) \mapsto f_X(x) \cdot f_Y(y)$ 为 (X, Y) 的联合概率密度函数.

- 命题 2 $\Rightarrow$ 命题 1: 设式 (3.5) 给出 (X, Y) 的联合概率密度函数. 任取区间 $I, J \subseteq \mathbb{R}$, 则

$$\begin{aligned}\mathbb{P}(X \in I, Y \in J) &= \mathbb{P}((X, Y) \in I \times J) \\ &= \iint_{I \times J} f_X(x) \cdot f_Y(y) \, dx dy \\ &= \int_I f_X(x) \, dx \int_J f_Y(y) \, dy = \mathbb{P}(X \in I) \cdot \mathbb{P}(X \in J).\end{aligned}$$

由区间 I, J 的任意性可得 X, Y 相互独立.

- 命题 2 $\Rightarrow$ 命题 3: 显然.
- 命题 3 $\Rightarrow$ 命题 2: 证明思路与离散情形相类似, 具体细节留给读者自行完成. $\square$

利用定理 3.3, 可以直接看出例 3.2 中 X 与 Y 不相互独立, 但 U 与 V 则相互独立.

例 3.4. 甲、乙两人都会在每个月第一个周日上午去理发店理发. 甲会在 9:00 到 11:00 之间均匀地随机选一个时刻到达理发店, 乙则会在 8:30 到 10:00 之间均匀地随机选一个时刻到达理发店. 二人到达理发店的时刻相互独立, 且两人理发花去的时间均为 20 分钟. 则甲、乙能在理发店碰面的概率是多少?

设甲在 8:30 之后 X 小时到达理发店, 乙在 8:30 之后 Y 小时到达理发店, 则 X 服从 $I = [1/2, 5/2]$ 上的均匀分布, Y 服从 $J = [0, 3/2]$ 上的均匀分布, 且 X, Y 相互独立, 故

$$f_{X,Y}(x, y) = \frac{1}{5/2 - 1/2} \mathbf{1}_I(x) \cdot \frac{1}{3/2 - 0} \mathbf{1}_J(y) = \frac{1}{3} \mathbf{1}_{I \times J}(x, y).$$

而甲、乙能在理发店碰面当且仅当 $|X - Y| \leq 1/3$, 故待求概率为

$$\mathbb{P}\left(|X - Y| \leq \frac{1}{3}\right) = \iint_{|x-y| \leq 1/3} f_{X,Y}(x, y) \, dx dy = \frac{1}{3} \iint_B dx dy,$$

其中

$$B = \left\{ (x, y) \in I \times J \mid |x - y| \leq \frac{1}{3} \right\}.$$

我们在平面直角坐标系上画出 B 的图像, 如图 3.5 所示, 不难算得 B 的面积为 $2/3$. 最终可得

$$\mathbb{P}\left(|X - Y| \leq \frac{1}{3}\right) = \frac{2}{9}. \quad \blacksquare$$




图 3.5: 例 3.4 中区域 $B = \{(x, y) \in I \times J \mid |x - y| \leq 1/3\}$ 的图像. B 的四个顶点的坐标分别为 $(1/2, 1/6)$, $(1/2, 5/6)$, $(7/6, 3/2)$, $(11/6, 3/2)$.

例 3.5. 在区间 $[0, 1]$ 上均匀且独立地随机取两点, 这两个点将区间 $[0, 1]$ 分为三段, 我们将其中最长一段的长度用随机变量 X 表示. 则对任意给定的 $x \in \mathbb{R}$, $X > x$ 的概率是多少?

不难看出 X 必然大于等于 $1/3$ 而小于等于 1 , 故接下来只需要考察 $1/3 \leq x < 1$ 时 $X > x$ 的概率. 将正方形区域 $[0, 1] \times [0, 1]$ 用 S 表示, 我们用随机变量 Y_1, Y_2 分别代表在区间 $[0, 1]$ 上均匀且独立地取出的两点, 则由定理 3.3, 可得 (Y_1, Y_2) 为连续型随机向量, 且联合概率密度函数 f_{Y_1, Y_2} 为

$$f_{Y_1, Y_2}(y_1, y_2) = f_{Y_1}(y_1) \cdot f_{Y_2}(y_2) = \mathbf{1}_{[0, 1]}(y_1) \cdot \mathbf{1}_{[0, 1]}(y_2) = \mathbf{1}_S(y_1, y_2),$$

故而对于任意的平面区域 $B \subseteq \mathbb{R}^2$, 有

$$\mathbb{P}((Y_1, Y_2) \in B) = \iint_B f_{Y_1, Y_2}(y_1, y_2) dy_1 dy_2 = \iint_{B \cap S} dy_1 dy_2,$$

也就是说 $\mathbb{P}((Y_1, Y_2) \in B)$ 就等于 $B \cap S$ 的面积.

接下来, 由于 X 是三段中最长一段的长度, X 小于等于 x 等价于这三段的长度都小于等于 x , 这提示着我们 $\{X > x\}$ 的对立事件 $\{X \leq x\}$ 似乎处理起来更方便. 对 $Y_1 \leq Y_2$ 与 $Y_1 > Y_2$ 两种情况分类讨论, 有

$$\mathbb{P}(X \leq x) = \mathbb{P}(X \leq x, Y_1 \leq Y_2) + \mathbb{P}(X \leq x, Y_1 > Y_2),$$

而 $Y_1 \leq Y_2$ 时 $X = \max\{Y_1, Y_2 - Y_1, 1 - Y_2\}$, 故

$$\begin{aligned} \{X \leq x, Y_1 \leq Y_2\} &= \{\max\{Y_1, Y_2 - Y_1, 1 - Y_2\} \leq x, Y_1 \leq Y_2\} \\ &= \{Y_1 \leq x, Y_2 - Y_1 \leq x, 1 - Y_2 \leq x, Y_1 \leq Y_2\} \end{aligned}$$




图 3.6: 例 3.5 中区域 $\{(y_1, y_2) \in S \mid y_1 \leq x, y_2 - y_1 \leq x, 1 - y_2 \leq x, y_1 \leq y_2\}$ 的图像.

因而 $\mathbb{P}(X \leq x, Y_1 \leq Y_2)$ 就等于区域

$$\{(y_1, y_2) \in S \mid y_1 \leq x, y_2 - y_1 \leq x, 1 - y_2 \leq x, y_1 \leq y_2\}$$

的面积, 该区域的形状如图 3.6 所示, 算出其面积之后可得

$$\mathbb{P}(X \leq x, Y_1 \leq Y_2) = \begin{cases} \frac{1}{2}(3x-1)^2, & \text{若 } \frac{1}{3} \leq x < \frac{1}{2}, \\ -\frac{3}{2}x^2 + 3x - 1, & \text{若 } \frac{1}{2} \leq x < 1. \end{cases}$$

对于 $\mathbb{P}(X \leq x, Y_1 > Y_2)$ 也可采取上述步骤进行计算, 但更加简单的方法是利用对称性, 并注意到 (Y_1, Y_2) 为连续型随机向量意味着 $\mathbb{P}(X \leq x, Y_1 = Y_2) = 0$, 从而有

$$\mathbb{P}(X \leq x, Y_1 > Y_2) = \mathbb{P}(X \leq x, Y_1 \geq Y_2) = \mathbb{P}(X \leq x, Y_1 \leq Y_2)$$

以及 $\mathbb{P}(X \leq x) = 2\mathbb{P}(X \leq x, Y_1 \leq Y_2)$. 综上可得

$$\mathbb{P}(X > x) = 1 - \mathbb{P}(X \leq x) = \begin{cases} 1, & \text{若 } x \leq \frac{1}{3}, \\ -9x^2 + 6x, & \text{若 } \frac{1}{3} \leq x \leq \frac{1}{2}, \\ 3x^2 - 6x + 3, & \text{若 } \frac{1}{2} \leq x < 1, \\ 0, & \text{若 } x \geq 1. \end{cases}$$

3.4 连续型随机变量的期望

定义 3.3. 设 X 为连续型随机变量, f_X 为其概率密度函数. 若积分 $\int_{-\infty}^{+\infty} |x| \cdot f_X(x) dx$ 收敛, 则定义 X 的**期望** (expected value 或 expectation) 为

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f_X(x) dx. \quad (3.7)$$

若积分 $\int_{-\infty}^{+\infty} |x| \cdot f_X(x) dx$ 发散, 则称 $\mathbb{E}[X]$ 不存在.

不难发现连续型随机变量期望的定义与离散情形有着形式上的相似之处: 我们利用如下形式上的对应关系:

$$\begin{aligned} p_X(x) &\longleftrightarrow f_X(x) dx \\ \sum_x &\longleftrightarrow \int_{-\infty}^{+\infty} \end{aligned}$$

把离散型随机变量期望定义式中的 $p_X(x)$ 替换为 $f_X(x) dx$ 并把求和替换为积分即可得到式 (3.7). 实际上, 连续型随机变量的期望可以看作是用离散型随机变量逼近而得到: 给定任意正整数 n , 我们用一系列点

$$\cdots < x_{n,-2} < x_{n,-1} < x_{n,0} < x_{n,1} < x_{n,2} < \cdots$$

将整个实数轴划分为可数多个小区间 $[x_{n,i}, x_{n,i+1}[$, 使得每个小区间的长度 $\Delta x_{n,i} = x_{n,i+1} - x_{n,i}$ 小于等于 $1/n$. 接下来对任意样本空间 Ω 中的元素 ω , 令

$$X_n(\omega) = x_{n,i}, \quad \text{若 } x_{n,i} \leq X(\omega) < x_{n,i+1}, \quad i \in \mathbb{Z},$$

则 X_n 为一离散型随机变量, 且对任意 $\omega \in \Omega$ 均有 $|X_n(\omega) - X(\omega)| < 1/n$. 而 X_n 的期望由下式给出³:

$$\begin{aligned} \mathbb{E}[X_n] &= \sum_i x_{n,i} \cdot \mathbb{P}(X_n = x_{n,i}) \\ &= \sum_i x_{n,i} \cdot \mathbb{P}(x_{n,i} \leq X < x_{n,i+1}) \\ &\approx \sum_i x_{n,i} \cdot f_X(x_{n,i}) \Delta x_{n,i} \\ &\approx \int_{-\infty}^{+\infty} x \cdot f_X(x) dx = \mathbb{E}[X]. \end{aligned}$$

³ 这个推导数学上不算严谨, 但对于提供直观理解是有帮助的.

上式的近似在 n 越大时越精确, 并且可以证明 $n \rightarrow \infty$ 时有 $\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$ (当 $\mathbb{E}[X]$ 存在时).

由于连续型随机变量的期望可以用离散型随机变量的期望进行逼近, 我们可以合理地猜测, 许多离散情形下期望的性质可以推广或迁移到连续情形. 例如, 将定理 2.8 的第一部分推广到连续情形是相当直接的: 若 $\mathbb{P}(X \geq 0) = 1$, 则总可以取 $f_X(x) = 0, \forall x \in]-\infty, 0[$, 此时即有 $\mathbb{E}[X] = \int_0^{+\infty} x f_X(x) dx \geq 0$ (只要该式右端积分收敛). 又如, 我们还可以将期望的线性进行推广, 从而将连续型随机变量也包括进来:

定理 3.4 (期望的线性). 设 X, Y 为离散型或连续型的随机变量, 且 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 均存在, α, β 为任意两个实数. 则

$$\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y].$$

接下来的定理则给出了连续型随机变量期望的 law of the unconscious statistician (LOTUS).

定理 3.5. 设 X 为连续型随机变量, f_X 为其概率密度函数, $g: \mathbb{R} \rightarrow \mathbb{R}$ 为任意函数. 则 $\mathbb{E}[g(X)]$ 存在当且仅当积分 $\int_{-\infty}^{+\infty} |g(x)| \cdot f_X(x) dx$ 收敛, 且 $\mathbb{E}[g(X)]$ 存在时有

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) dx.$$

类似地, 设 (X, Y) 为连续型随机向量, $f_{X,Y}$ 为其联合概率密度函数, $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 为任意二元函数. 则 $\mathbb{E}[g(X, Y)]$ 存在当且仅当积分 $\iint_{\mathbb{R}^2} |g(x, y)| \cdot f_{X,Y}(x, y) dx dy$ 收敛, 且 $\mathbb{E}[g(X, Y)]$ 存在时有

$$\mathbb{E}[g(X, Y)] = \iint_{\mathbb{R}^2} g(x, y) \cdot f_{X,Y}(x, y) dx dy.$$

然而, 目前我们尚不能给出定理 3.4 与 3.5 的证明, 这是因为它们实际上牵扯到了一般随机变量的期望, 而我们还未对其进行定义. 例如对于定理 3.5, 即使 X 是连续型随机变量, 其函数 $g(X)$ 是否是连续型或离散型变量并无保证, 故计算 $\mathbb{E}[g(X)]$ 之前需要先对一般随机变量的期望给出定义. 在第 3.6 节中, 我们将对一般随机变量的期望进行介绍, 而后再证明定理 3.4 与 3.5.

例 3.6. 设随机变量 X 服从参数为 λ 的指数分布, 其中 $\lambda > 0$, 令 $Y = \max\{X, \lambda^{-1}\}$. 则

$$\mathbb{P}(Y = \lambda^{-1}) = \mathbb{P}(X \leq \lambda^{-1}) = \int_0^{\lambda^{-1}} \lambda e^{-\lambda t} dt = 1 - e^{-1} > 0,$$

故 Y 不是连续型随机变量. 另一方面, $y < \lambda^{-1}$ 时显然有 $\mathbb{P}(Y = y) = 0$ (因 Y 的取值至少为 λ^{-1}), 而 $y > \lambda^{-1}$ 时有

$$\mathbb{P}(Y = y) = \mathbb{P}(\max\{X, \lambda^{-1}\} = y) = \mathbb{P}(X = y) = 0,$$

因而

$$\sum_y \mathbb{P}(Y = y) = \mathbb{P}(Y = \lambda^{-1}) = 1 - e^{-1} < 1.$$

上式意味着 Y 的分布不能由一个分布列刻画 (否则应当有 $\sum_y \mathbb{P}(Y = y) = 1$), Y 也不是离散型随机变量.

不过, 我们可以把 Y 表示为连续型随机变量 X 的一个函数 $g(X)$, 其中 $g(x) = \max\{x, \lambda^{-1}\}$, 故按照定理 3.5, 我们依然可以计算 $\mathbb{E}[Y] = \mathbb{E}[g(X)]$:

$$\begin{aligned} \mathbb{E}[Y] &= \int_{-\infty}^{+\infty} g(x) f_X(x) dx \\ &= \int_0^{+\infty} \max\{x, \lambda^{-1}\} \cdot \lambda e^{-\lambda x} dx \\ &= \int_0^{\lambda^{-1}} \lambda^{-1} \cdot \lambda e^{-\lambda x} dx + \int_{\lambda^{-1}}^{+\infty} x \cdot \lambda e^{-\lambda x} dx \\ &= \frac{e+1}{\lambda e}. \end{aligned}$$

在 3.6 节的例 3.16 当中, 我们将介绍从 Y 的分布出发直接求解 $\mathbb{E}[Y]$ 的方法, 该方法给出的结果与利用定理 3.5 得到的结果是一致的. ■

接下来我们引入连续型随机变量的方差. 实际上, 连续型随机变量的方差的定义与离散情形 (即定义 2.8) 是一样的:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2],$$

其中要求上式右端当中的期望均存在; 否则称 $\text{Var}(X)$ 不存在. 此外, 等式

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

与

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

等的推导与离散情形完全相同, 因为我们只需利用期望的线性即可.

例 3.7. 设 X 服从区间 I 上的均匀分布, 其中 I 的左右端点分别为 a, b ($a < b$), 则 X 的期望与方差分别为

$$\begin{aligned}\mathbb{E}[X] &= \int_a^b x \cdot \frac{1}{b-a} dx = \frac{a+b}{2}, \\ \text{Var}(X) &= \int_a^b x^2 \cdot \frac{1}{b-a} dx - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12}.\end{aligned}$$

例 3.8. 设 X 服从参数为 λ 的指数分布, 则 X 的期望与方差分别为

$$\begin{aligned}\mathbb{E}[X] &= \int_0^{+\infty} x \cdot \lambda e^{-\lambda x} dx = \frac{1}{\lambda}, \\ \text{Var}(X) &= \int_0^{+\infty} x^2 \cdot \lambda e^{-\lambda x} dx - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}.\end{aligned}$$

例 3.9. 设 $X \sim \mathcal{N}(\mu, \sigma^2)$. 注意到 $f_X(x)$ 关于 $x = \mu$ 左右对称, 且不难说明 $\int_{-\infty}^{+\infty} |x| \cdot f_X(x) dx$ 收敛, 故

$$\mathbb{E}[X] = \mu.$$

X 的方差为

$$\begin{aligned}\text{Var}(X) &= \int_{-\infty}^{+\infty} (x - \mu)^2 \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) dx \\ &= \sigma^2 \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} u^2 \exp\left(-\frac{u^2}{2}\right) dx = \sigma^2,\end{aligned}$$

其中第二步进行了换元 $u = (x - \mu)/\sigma$, 而最后一步积分的计算可参考附录 A.2.

3.5 一般随机变量与分布函数

本节中, 我们对一般随机变量的理论进行简单介绍.

首先回答一个问题: 任一随机变量是否必定是离散型或连续型之一? 答案是否定的. 例如, 例 3.6 就给出了一个随机变量 Y , 它的分布既不能用一个分布列刻画, 也不能用一个概率密度函数刻画; 在例 3.14 中我们将看到, 它服从所谓的离散—连续混合型分布. 此外, 利用一些实分析上的技巧, 可以给出一个相当病态的例子 (不要求掌握).

例 3.10. (*) 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, 随机变量 $X: \Omega \rightarrow \mathbb{R}$ 服从 $[0, 1]$ 上的均匀

分布. 任取 $\omega \in \Omega$, 将 $X(\omega)$ 展开为二进制小数⁴

$$X(\omega) = \sum_{n=1}^{\infty} \frac{a_n(\omega)}{2^n}, \quad a_n(\omega) \in \{0, 1\},$$

再令

$$Y(\omega) = \sum_{n=1}^{\infty} \frac{2a_n(\omega)}{3^n}.$$

由此可以得到一个随机变量 $Y: \Omega \rightarrow \mathbb{R}$. 可以证明, 对任意 $a \in \mathbb{R}$, 均有 $\mathbb{P}(Y = a) = 0$, 故 Y 不可能是一个离散型随机变量. 但也可以证明, 并不存在定义在 $\mathbb{R}$ 上的非负函数 f 使得 $\mathbb{P}(Y \in I) = \int_I f(x) dx$, 因此 Y 也不是一个连续型随机变量. ■

为了研究那些既非离散型也非连续型的随机变量, 并且也为了用一个统一的数学工具去刻画随机变量取值的统计规律, 我们引入分布函数的概念.

定义 3.4. 设 X 为一随机变量, 令函数 $F_X: \mathbb{R} \rightarrow [0, 1]$ 定义如下:

$$F_X(x) = \mathbb{P}(X \leq x), \quad \forall x \in \mathbb{R}.$$

我们称 F_X 为随机变量 X 的**分布函数**, 也称为**累积分布函数** (cumulative distribution function, c.d.f.).

对于任意的随机变量 X , 其分布函数 F_X 都是有定义的, 这是因为随机变量的定义要求 $\{X \leq x\} = \{X \in]-\infty, x]\}$ 必须是一个事件, 从而其概率有定义. 后面我们将看到, 分布函数能够完整刻画单个随机变量的统计规律, 并且大多数随机变量的数字特征 (包括期望、方差等) 仅依赖于其分布函数.

以下定理总结了分布函数所具有的基本性质.

定理 3.6. 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一概率空间, $X: \Omega \rightarrow \mathbb{R}$ 为一随机变量, F_X 为其分布函数. 则

1. F_X 在 $\mathbb{R}$ 上单调不减.
2. $F_X(x) \in [0, 1], \forall x \in \mathbb{R}$, 并且

$$F_X(+\infty) := \lim_{x \rightarrow +\infty} F_X(x) = 1, \quad F_X(-\infty) := \lim_{x \rightarrow -\infty} F_X(x) = 0.$$

⁴ (*) 若存在正整数 p, q 使得 $X(\omega) = p/2^q$, 则 $X(\omega)$ 存在两种二进制小数表示, 为明确起见, 这种情况下我们取 $n > q$ 时 $a_n(\omega) = 0$ 的那种二进制小数表示.

3. F_X 在 $\mathbb{R}$ 上右连续, 即对任意的 $x \in \mathbb{R}$, 有

$$F_X(x+0) := \lim_{\delta \rightarrow 0^+} F_X(x+\delta) = F_X(x).$$

定理 3.6 中分布函数单调不减的证明较为直接: 注意到 $x_1 \leq x_2$ 时有

$$\begin{aligned} F_X(x_2) &= \mathbb{P}(X \leq x_2) \\ &= \mathbb{P}(\{X \leq x_1\} \cup \{x_1 < X \leq x_2\}) \\ &= \mathbb{P}(X \leq x_1) + \mathbb{P}(x_1 < X \leq x_2) = F_X(x_1) + \mathbb{P}(x_1 < X \leq x_2), \end{aligned}$$

即

$$\mathbb{P}(x_1 < X \leq x_2) = F_X(x_2) - F_X(x_1).$$

再由概率的非负性可直接得到 $x_1 \leq x_2$ 时有 $F_X(x_2) - F_X(x_1) \geq 0$. $F_X(x) \in [0, 1]$, $\forall x \in \mathbb{R}$ 则是概率测度定义的直接推论. 其余性质的证明需要用到概率测度的连续性, 我们将其放在 3.5.2 小节作为选读内容.

定理 3.6 的逆定理也同样成立: 若函数 $F: \mathbb{R} \rightarrow \mathbb{R}$ 满足 (i) F 在 $\mathbb{R}$ 上单调不减; (ii) $F(+\infty) = 1$, $F(-\infty) = 0$; (iii) F 在 $\mathbb{R}$ 上右连续, 则存在一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 及随机变量 $X: \Omega \rightarrow \mathbb{R}$, 使得 F 为 X 的分布函数, 此时我们称函数 F 给出了一个**概率分布** (或简称为**分布**). 这个结论的证明不做要求.

分布函数 F_X 直接给出了 $\{X \leq x\}$ 的概率, 而 $\{X < x\}$ 的概率则由如下命题给出, 其证明放在 3.5.3 小节中作为选读内容:

命题 3.7. 设 X 为一随机变量, F_X 为其分布函数, $x \in \mathbb{R}$, 则有

$$\mathbb{P}(X < x) = F_X(x-0) = \lim_{\delta \rightarrow 0^+} F_X(x-\delta).$$

基于命题 3.7, 我们可以进一步由概率的可加性得到 X 落于任意区间内的概率, 例如

$$\mathbb{P}(a < X < b) = \mathbb{P}(X < b) - \mathbb{P}(X \leq a) = F_X(b-0) - F_X(a).$$

而对于更加一般的 $\mathbb{R}$ 的子集 B , 只要它可以表示为可数个互不相交的区间的并, 我们就可以利用概率的可数可加性来求得 $\mathbb{P}(X \in B)$. 在这个意义上, 我们可以说分布函数能够完整刻画单个随机变量的统计规律.

对于离散型或连续型的随机变量 X , 不难由它的分布列 p_X 或概率密度函数 f_X 求出分布函数 F_X :

$$F_X(x) = \begin{cases} \sum_{t: t \leq x} p_X(t), & \text{若 } X \text{ 是离散型随机变量,} \\ \int_{-\infty}^x f_X(t) dt, & \text{若 } X \text{ 是连续型随机变量.} \end{cases}$$

由上式可看出, 离散型随机变量的分布函数是阶跃的: 若 $p_X(x) = \mathbb{P}(X = x) > 0$, 则分布函数 F_X 的值在 x 处有幅度为 $p_X(x)$ 的跳跃; 连续型随机变量的分布函数则必定是连续函数⁵. 图 3.7 与 3.8 分别给出了一些离散型与连续型概率分布的分布函数图像.

反过来, 给定 X 的分布函数, 我们也可以去求它的分布列或概率密度函数:

- 当 X 的值域是可数集, 即 X 为离散型随机变量时, 其分布列为

$$p_X(x) = F_X(x) - F_X(x-0), \quad \forall x \in \mathbb{R}.$$

- 当 F_X 为连续函数时, 令

$$f(x) = \begin{cases} F'_X(x), & \text{若 } F_X \text{ 在 } x \text{ 处可导,} \\ 0, & \text{若 } F_X \text{ 在 } x \text{ 处不可导,} \end{cases} \quad \forall x \in \mathbb{R}.$$

若进一步有 $F_X(x) = \int_{-\infty}^x f(t) dt$, 则 X 是连续型随机变量, 上式算出的 f 即为 X 的概率密度函数; 否则 X 不是连续型随机变量⁶.

例 3.11 (均匀分布的分布函数). 设 X 服从区间 $[a, b]$ 上的均匀分布, 其中 $a < b$, 则其分布函数 F_X 为

$$F_X(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases}$$

它是一个分段线性函数, 其图像如图 3.8a 所示. ■

例 3.12 (指数分布的分布函数与无记忆性). 设 X 服从参数为 λ 的指数分布. 则其分

⁵ 但分布函数为连续函数的随机变量不一定是连续型随机变量.

⁶ “否则”部分的严格证明超出本讲义范围, 不做要求.




图 3.7: 一些离散型概率分布的分布函数.

布函数为

$$F_X(x) = \begin{cases} \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}, & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0. \end{cases}$$

指数分布的分布函数图像如图 3.8b 所示.

指数分布具有与几何分布类似的**无记忆性**: 若 X 服从参数为 λ 的指数分布, s 为非负实数, 则对任意 $t \in \mathbb{R}$, 当 $t \geq 0$ 时有

$$\mathbb{P}(X - s > t | X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t),$$

而当 $t < 0$ 时有 $\mathbb{P}(X - s > t | X > s) = 1 = \mathbb{P}(X > t)$. 从而

$$\mathbb{P}(X - s \leq t | X > s) = F_X(t), \quad \forall t \in \mathbb{R}.$$

这意味着, 若我们把 X 看成从零时刻开始到某件事情发生所需要等待的时间, 则已知 $X > s$ 的作用相当于把时间原点向右平移了 s , 而 s 时刻以后所需要的额外的等待时间依然服从原来的指数分布, 它“忘记”了这件事情在 s 时刻之前并未发生的这段历史. ■




图 3.8: 一些连续型概率分布的分布函数.

例 3.13 (正态分布的分布函数). 设 $X \sim \mathcal{N}(0, 1)$, 则其分布函数为

$$F_X(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{t^2}{2}\right) dt, \quad \forall x \in \mathbb{R}.$$

等号右端的积分并没有初等函数表达式, 我们将它作为特殊函数处理, 记作

$$\begin{aligned} \Phi: \mathbb{R} &\rightarrow \mathbb{R} \\ x &\mapsto \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{t^2}{2}\right) dt. \end{aligned}$$

更一般地, 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则其分布函数为

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(t-\mu)^2}{2\sigma^2}\right) dt \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{(x-\mu)/\sigma} \exp\left(-\frac{u^2}{2}\right) du = \Phi\left(\frac{x-\mu}{\sigma}\right), \end{aligned}$$

其中第二步做了换元 $u = (x - \mu)/\sigma$. 正态分布的分布函数图像如图 3.8c 所示. ■

例 3.14. 设 Y, Z_1, Z_2 为概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的相互独立的随机变量, 其中 Y 服从参数为 θ 的伯努利分布; Z_1 为离散型随机变量, 分布列为 $p: \mathbb{R} \rightarrow [0, 1]$; Z_2 为连续型随机变量, 概率密度函数为 $f: \mathbb{R} \rightarrow \mathbb{R}$. 令随机变量 X 为

$$X(\omega) = \begin{cases} Z_1(\omega), & \text{若 } Y(\omega) = 1, \\ Z_2(\omega), & \text{若 } Y(\omega) = 0, \end{cases} \quad \forall \omega \in \Omega,$$

或者用指示函数更简洁地写为

$$X = Z_1 \cdot \mathbf{1}_{\{Y=1\}} + Z_2 \cdot \mathbf{1}_{\{Y=0\}}.$$

我们希望求出 X 的分布函数 F_X .

求解过程是比较直接的: 任取 $x \in \mathbb{R}$, 有

$$\begin{aligned} F_X(x) &= \mathbb{P}(X \leq x) \\ &= \mathbb{P}(X \leq x, Y = 1) + \mathbb{P}(X \leq x, Y = 0) \\ &= \mathbb{P}(Z_1 \leq x, Y = 1) + \mathbb{P}(Z_2 \leq x, Y = 0) \\ &= \mathbb{P}(Z_1 \leq x) \cdot \mathbb{P}(Y = 1) + \mathbb{P}(Z_2 \leq x) \cdot \mathbb{P}(Y = 0), \end{aligned}$$

其中, 第一步即为分布函数的定义; 第二步来自于概率的可加性; 第三步来自于随机变量 X 的定义; 第四步利用了 Y, Z_1, Z_2 之间的独立性. 最后, 将 Y, Z_1, Z_2 各自的概率分布代入, 可得

$$F_X(x) = \theta \sum_{t:t \leq x} p(t) + (1 - \theta) \int_{-\infty}^x f(t) dt. \quad (3.8)$$

有时也将形如式 (3.8) 的分布称为离散—连续混合型分布. ■

3.5.1 随机向量的联合分布函数

对于一般的二维随机向量 (X, Y) , 我们可定义其**联合分布函数** (又称作**联合累积分布函数**, joint cumulative distribution function, joint c.d.f.) 为

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y).$$

该定义可以很容易推广到更高维的随机向量.

理论上可以证明, 只要已知分布函数 $F_{X,Y}$, 那么对于常见的平面上的区域 $B \subseteq \mathbb{R}^2$, 其概率 $\mathbb{P}((X, Y) \in B)$ 都能被唯一确定下来. 然而, 直接由 $F_{X,Y}$ 出发来计算 $\mathbb{P}((X, Y) \in B)$ 对于许多问题而言并不方便, 更常见的做法是先考察 (X, Y) 是否是离散型或连续型随机向量并求出其联合分布列或联合概率密度, 或是以之后将要介绍的条件期望为工具进行求解. 本讲义中, 我们不对联合分布函数进行较为详细的介绍, 而仅罗列一些相关结论如下:

- (X, Y) 为连续型随机向量当且仅当其联合分布函数可表示为如下形式:

$$F_{X,Y}(x, y) = \int_{-\infty}^x \left(\int_{-\infty}^y f_{X,Y}(s, t) dt \right) ds, \quad \forall (x, y) \in \mathbb{R}^2.$$

此外, 若已知 (X, Y) 为连续型随机向量, 且 $F_{X,Y}$ 在某个平面上的开区域 $\mathcal{U} \subseteq \mathbb{R}^2$

内二阶连续可导, 则有

$$f_{X,Y}(x, y) = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}(x, y), \quad \forall (x, y) \in \mathcal{U}.$$

上述结果常用于求解连续型随机向量 (X, Y) 的联合概率密度函数.

- 已知 (X, Y) 的联合分布函数, 则 X 与 Y 各自的分布函数 (也就是**边缘分布函数**) 被唯一确定:

$$F_X(x) = \lim_{y \rightarrow +\infty} F_{X,Y}(x, y), \quad \forall x \in \mathbb{R},$$

$$F_Y(y) = \lim_{x \rightarrow +\infty} F_{X,Y}(x, y), \quad \forall y \in \mathbb{R}.$$

- X, Y 相互独立的充要条件是

$$F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y), \quad \forall (x, y) \in \mathbb{R}^2,$$

3.5.2 (*) 定理 3.6 其余结论的证明

记样本空间为 Ω . 我们先证明 $\lim_{x \rightarrow +\infty} F_X(x) = 1$. 注意到 $F_X(x)$ 为单调不减的函数, 因此只需证数列 $(F_X(n))_{n=1}^{\infty}$ 在 $n \rightarrow \infty$ 时的极限为 1. 现对任意正整数 n , 令 $E_n = \{X \leq n\}$, 则 $E_1, E_2, \dots$ 为递增的事件列, 且

$$\lim_{n \rightarrow \infty} E_n = \bigcup_{n=1}^{\infty} E_n = \{\omega \in \Omega \mid \text{存在正整数 } n \text{ 使得 } X(\omega) \leq n\} = \Omega.$$

故由概率的连续性可得

$$1 = \mathbb{P}(\Omega) = \lim_{n \rightarrow \infty} \mathbb{P}(E_n) = \lim_{n \rightarrow \infty} F_X(n).$$

接下来证明 $\lim_{x \rightarrow -\infty} F_X(x) = 0$. 注意到

$$\begin{aligned} 0 \leq F_X(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(-X \geq -x) \\ &\leq \mathbb{P}(-X > -x - 1) = 1 - \mathbb{P}(-X \leq -x - 1) \\ &= 1 - F_{-X}(-x - 1), \end{aligned}$$

而 F_{-X} 作为随机变量 $-X$ 的分布函数满足 $\lim_{x \rightarrow +\infty} F_{-X}(x) = 1$, 故令上式中 $x \rightarrow -\infty$ 即可得到 $\lim_{x \rightarrow -\infty} F_X(x) = 0$.

最后我们证明 F_X 的右连续性. 给定任意 $x \in \mathbb{R}$, 记 $G_n = \{X \leq x + 1/n\}$, $\forall n \in \mathbb{N}_+$, 则 $G_1, G_2, \dots$ 为递减的事件列, 且

$$\lim_{n \rightarrow \infty} G_n = \bigcap_{n=1}^{\infty} G_n = \left\{ \omega \in \Omega \mid \text{对任意正整数 } n, \text{ 均有 } X(\omega) \leq x + \frac{1}{n} \right\} = \{X \leq x\},$$

故由概率的连续性可得

$$F_X(x) = \mathbb{P}(X \leq x) = \lim_{n \rightarrow \infty} \mathbb{P}(G_n) = \lim_{n \rightarrow \infty} F_X\left(x + \frac{1}{n}\right).$$

而 F_X 的单调性保证了右极限 $F_X(x+0)$ 存在且等于 $\lim_{n \rightarrow \infty} F_X(x + 1/n)$, 故 $F_X(x+0) = F_X(x)$.

3.5.3 (*) 命题 3.7 的证明

记样本空间为 Ω . 令

$$E_n = \left\{ X \leq x - \frac{1}{n} \right\}, \quad n = 1, 2, \dots,$$

由于 $1/n$ 随 n 的增大单调递减, 故 E_n 成立时 E_{n+1} 必定成立, 因此 $E_1, E_2, \dots$ 为一递增的事件列. 另一方面,

$$\begin{aligned} \lim_{n \rightarrow \infty} E_n &= \bigcup_{n=1}^{\infty} E_n \\ &= \left\{ \omega \in \Omega \mid \text{存在正整数 } n \text{ 使得 } X(\omega) \leq x - \frac{1}{n} \right\} \\ &= \{s \in S \mid X(s) < x\} = \{X < x\}, \end{aligned}$$

其中利用了 $n \rightarrow \infty$ 时 $1/n \rightarrow 0$. 故由概率的连续性可得

$$\mathbb{P}(X < x) = \mathbb{P}\left(\lim_{n \rightarrow \infty} E_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(E_n) = \lim_{n \rightarrow \infty} F_X\left(x - \frac{1}{n}\right) = F_X(x-0),$$

其中 $F_X(x-0)$ 的存在性由 F_X 的单调性保证.

3.6 一般随机变量的期望

一般随机变量的期望属于高等概率论的内容, 由于数学工具的匮乏, 本课程将不给出一般随机变量期望的定义, 而将主要介绍一些一般情形下期望的重要性质.

我们首先用如下定理给出一种理解一般随机变量期望的方法, 即一般随机变量的期望都可以用离散型随机变量的期望进行逼近. 该定理的证明不做要求.

定理 3.8. 设 X 为任一随机变量. 任取一严格递减且趋于 0 的序列 $(\delta_n)_{n=1}^\infty$, 并令 $X_1, X_2, \dots$ 为一列离散型随机变量, 使得 $\{|X_n - X| \leq \delta_n\}$ 均为必然事件. 则 $\mathbb{E}[X]$ 存在当且仅当每个 $\mathbb{E}[X_n]$ 均存在, 且 $\mathbb{E}[X]$ 存在时有

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n].$$

定理 3.8 说明, 对于任意的随机变量 X , 可通过构造一系列离散型随机变量 $(X_n)_{n=1}^\infty$ 对 X 进行逼近, 并考察 $\mathbb{E}[X_n]$ 的存在性以及极限来判断 $\mathbb{E}[X]$ 的存在性并求 $\mathbb{E}[X]$ 的值. 满足定理 3.8 条件的离散型随机变量列 $(X_n)_{n=1}^\infty$ 则可通过如下方式构造: 给定 $(\delta_n)_{n=1}^\infty$, 令

$$\theta_n(x) = \begin{cases} k\delta_n, & \text{若存在正整数 } k \text{ 使得 } k\delta_n \leq x < (k+1)\delta_n, \\ 0, & \text{若 } -\delta_n < x < \delta_n, \\ -k\delta_n, & \text{若存在正整数 } k \text{ 使得 } -(k+1)\delta_n < x \leq -k\delta_n, \end{cases} \quad (3.9)$$

则有 $|\theta_n(x) - x| \leq \delta_n, \forall x \in \mathbb{R}$, 因而令 $X_n = \theta_n(X)$ 即可使得随机变量列 $(X_n)_{n=1}^\infty$ 满足定理 3.8 的条件. 此外, 上式给出的函数 θ_n 还具有如下几条性质: (i) $\theta_n(x)$ 关于 x 单调不减; (ii) $\theta_n(x)$ 与 x 具有相同的符号; (iii) $|\theta_n(x)| = \theta_n(|x|) \leq |x|$.

基于以上结果, 我们可以比较方便地将离散随机变量期望的许多结果推广到一般随机变量的期望.

引理 3.9 (期望仅由分布决定). 设 X, Y 为两个同分布的随机变量, 也就是说对任意区间 $I \subseteq \mathbb{R}$ 均有

$$\mathbb{P}(X \in I) = \mathbb{P}(Y \in I).$$

则 $\mathbb{E}[X]$ 存在当且仅当 $\mathbb{E}[Y]$ 存在, 且 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 存在时有

$$\mathbb{E}[X] = \mathbb{E}[Y].$$

证明. (*) 这里仅给出思路: 令函数 θ_n 由式 (3.9) 给出, 其中取 $\delta_n = 1/n$. 再令 $X_n = \theta_n(X), Y_n = \theta_n(Y)$, 则 X_n, Y_n 均为离散型随机变量. 接下来由 $\mathbb{P}(X \in I) = \mathbb{P}(Y \in I)$ 以及 θ_n 的单调性可证明对任意正整数 n , $X_n = \theta_n(X)$ 与 $Y_n = \theta_n(Y)$ 具有相同的分布列, 故 $\mathbb{E}[X_n]$ 存在当且仅当 $\mathbb{E}[Y_n]$ 存在, 且它们都存在时有 $\mathbb{E}[X_n] = \mathbb{E}[Y_n]$. 最后, 由于 $|X_n - X| \leq 1/n$ 以及 $|Y_n - Y| \leq 1/n$, 可利用定理 3.8 得到

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \lim_{n \rightarrow \infty} \mathbb{E}[Y_n] = \mathbb{E}[Y]. \quad \square$$

命题 3.10. 设 X, Y 为随机变量.

1. $\mathbb{E}[X]$ 存在当且仅当 $\mathbb{E}[|X|]$ 存在.
2. 若 $|X| \leq Y$ 必然成立, 且 $\mathbb{E}[Y]$ 存在, 则 $\mathbb{E}[X]$ 存在, 且 $|\mathbb{E}[X]| \leq \mathbb{E}[Y]$.

证明. (*) 令函数 θ_n 由式 (3.9) 给出, 其中取 $\delta_n = 1/n$. 再令 $X_n = \theta_n(X)$, 则有 $|X_n - X| \leq 1/n$, 且因 θ_n 满足 $\theta_n(|x|) = |\theta_n(x)|$, 故 $||X_n| - |X|| = |\theta_n(|X|) - |X|| \leq 1/n$.

我们先证明 $\mathbb{E}[X]$ 的存在性等价于 $\mathbb{E}[|X|]$ 的存在性. 由定理 3.8 可得, $\mathbb{E}[X]$ 的存在性等价于每个 $\mathbb{E}[X_n]$ 的存在性, 而 $\mathbb{E}[|X|]$ 的存在性等价于每个 $\mathbb{E}[|X_n|]$ 的存在性. 而由离散型随机变量期望的 LOTUS (定理 2.6), 可得 $\mathbb{E}[X_n]$ 的存在性等价于 $\mathbb{E}[|X_n|]$ 的存在性. 综上可得 $\mathbb{E}[X]$ 的存在性等价于 $\mathbb{E}[|X|]$ 的存在性.

接下来设 $0 \leq X \leq Y$ 且 $\mathbb{E}[Y]$ 存在. 令 $Y_n = \theta_n(Y)$, 则由 θ_n 的单调性可得 $X_n = \theta_n(X) \leq \theta_n(Y) = Y_n$, 故⁷

$$\begin{aligned}\mathbb{E}[Y_n] &= \sum_{y: y \geq 0} y \cdot \mathbb{P}(Y_n = y) = \sum_{(x, y): 0 \leq x \leq y} y \cdot \mathbb{P}(X_n = x, Y_n = y) \\ &\geq \sum_{(x, y): 0 \leq x \leq y} x \cdot \mathbb{P}(X_n = x, Y_n = y) = \sum_{x: x \geq 0} x \cdot \mathbb{P}(X_n = x) = \mathbb{E}[X_n].\end{aligned}$$

最后利用定理 3.8 并令 $n \rightarrow \infty$ 即得 $\mathbb{E}[X]$ 存在且有 $\mathbb{E}[Y] \geq \mathbb{E}[X]$. □

定理 3.11 (期望的线性). 设随机变量 X, Y 的期望 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 均存在, α, β 为任意两个实数. 则

$$\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y].$$

证明. 不妨设 α, β 不全为 0, 否则等式是显然的.

令函数 θ_n 由式 (3.9) 给出, 其中取 $\delta_n = 1/n$. 再令 $X_n = \theta_n(X), Y_n = \theta_n(Y)$, 则由定理 3.8 可得

$$\mathbb{E}[X] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n], \quad \mathbb{E}[Y] = \lim_{n \rightarrow \infty} \mathbb{E}[Y_n].$$

令 $Z_n = \alpha X_n + \beta Y_n$, 则有

$$\begin{aligned}|Z_n - (\alpha X + \beta Y)| &\leq |\alpha| \cdot |X_n - X| + |\beta| \cdot |Y_n - Y| \\ &\leq \frac{|\alpha| + |\beta|}{n}.\end{aligned}$$

⁷ 推导中我们对求和式进行了重排, 且利用了如下结论: 若 $f, g: \mathbb{R}^2 \rightarrow [0, +\infty[$ 仅在可数个点上取非零值, 且 $f(x, y) \leq g(x, y), \forall (x, y) \in \mathbb{R}^2$, 则 $\sum_{(x, y)} g(x, y)$ 收敛时 $\sum_{(x, y)} f(x, y)$ 必收敛, 且 $\sum_{(x, y)} f(x, y) \leq \sum_{(x, y)} g(x, y)$. 可参考附录 A.1 中的相关结论.

因 $Z_1, Z_2, \dots$ 均为离散型随机变量, 且 $(|\alpha| + |\beta|)/n$ 严格单调递减趋于 0, 故 $(Z_n)_{n=1}^\infty$ 满足定理 3.8 的条件, 从而

$$\begin{aligned}\mathbb{E}[\alpha X + \beta Y] &= \lim_{n \rightarrow \infty} \mathbb{E}[Z_n] \\ &= \lim_{n \rightarrow \infty} (\alpha \mathbb{E}[X_n] + \beta \mathbb{E}[Y_n]) \\ &= \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y].\end{aligned}$$

其中第二步用到了离散型随机变量期望的线性. □

定理 3.12. 设 X 为随机变量, 满足 $\mathbb{P}(X \geq 0) = 1$. 则如下命题成立:

1. 若 $\mathbb{E}[X]$ 存在, 则 $\mathbb{E}[X] \geq 0$.
2. $\mathbb{E}[X] = 0$ 当且仅当 $\mathbb{P}(X = 0) = 1$.

证明. 1. 令函数 θ_n 由式 (3.9) 给出, 其中取 $\delta_n = 1/n$. 再令 $X_n = \theta_n(X)$, 则定理 3.8 保证了 $\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$. 另一方面, 由 $|X_n - X| \leq 1/n$ 可得 $X_n + 1/n \geq X$, 故 $\mathbb{P}(X_n + 1/n \geq 0) = 1$. 而由于 $X_n + 1/n$ 也是离散型随机变量, 由定理 2.8 可得

$$0 \leq \mathbb{E}\left[X_n + \frac{1}{n}\right] = \mathbb{E}[X_n] + \frac{1}{n}.$$

令 $n \rightarrow \infty$ 并由 $\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$ 即得到 $\mathbb{E}[X] \geq 0$.

2. $\mathbb{P}(X = 0) = 1 \Rightarrow \mathbb{E}[X] = 0$: 由于 $\mathbb{E}[X]$ 仅取决于 X 的分布, 而 $\mathbb{P}(X = 0) = 1$ 意味着 X 与常函数 0 同分布, 故 $\mathbb{E}[X] = \mathbb{E}[0] = 0$.

(*) $\mathbb{E}[X] = 0 \Rightarrow \mathbb{P}(X = 0) = 1$: 用反证法, 假设 $\mathbb{E}[X] = 0$ 但 $\mathbb{P}(X = 0) < 1$. 对任意正整数 n , 令 $E_n = \{X > 1/n\}$, 则不难看出 $E_1, E_2, \dots$ 为单调递增事件列, 且 $\lim_{n \rightarrow \infty} E_n = \{X > 0\}$. 由概率的连续性可得

$$\lim_{n \rightarrow \infty} \mathbb{P}(E_n) = \mathbb{P}(X > 0).$$

由 $\mathbb{P}(X = 0) < 1$ 可得 $\mathbb{P}(X > 0) > 0$, 结合上式可知存在自然数 N 使得 $\mathbb{P}(E_N) > 0$. 另一方面, 注意到

$$\left\{X - \frac{1}{N} \mathbf{1}_{E_N} \geq 0\right\}$$

为必然事件, 故由定理第 1 部分以及期望的线性得

$$0 \leq \mathbb{E}\left[X - \frac{1}{N} \mathbf{1}_{E_N}\right] = \mathbb{E}[X] - \frac{1}{N} \mathbb{P}(E_N) = -\frac{1}{N} \mathbb{P}(E_N) < 0,$$

产生矛盾. □

下面我们证明连续型随机变量期望的 LOTUS, 即定理 3.5.

证明 (定理 3.5). (*) 简单起见, 这里只给出二元函数情形的证明, 且不论证 $\mathbb{E}[g(X, Y)]$ 的存在性. 令函数 θ_n 由式 (3.9) 给出, 其中取 $\delta_n = 1/n$. 再令 $Z_n = \theta_n(g(X, Y))$, 则 Z_n 为离散型随机变量, 且有

$$\begin{aligned}\mathbb{E}[Z_n] &= \sum_z z \cdot \mathbb{P}(Z_n = z) \\ &= \sum_z z \cdot \iint_{\theta_n(g(x, y))=z} f_{X,Y}(x, y) \, dx dy \\ &= \sum_z \iint_{\theta_n(g(x, y))=z} \theta_n(g(x, y)) \cdot f_{X,Y}(x, y) \, dx dy \\ &= \iint_{\mathbb{R}^2} \theta_n(g(x, y)) \cdot f_{X,Y}(x, y) \, dx dy.\end{aligned}$$

而由于

$$\begin{aligned}& \left| \iint_{\mathbb{R}^2} \theta_n(g(x, y)) \cdot f_{X,Y}(x, y) \, dx dy - \iint_{\mathbb{R}^2} g(x, y) \cdot f_{X,Y}(x, y) \, dx dy \right| \\ & \leq \iint_{\mathbb{R}^2} |\theta_n(g(x, y)) - g(x, y)| \cdot f_{X,Y}(x, y) \, dx dy \\ & \leq \iint_{\mathbb{R}^2} \frac{1}{n} \cdot f_{X,Y}(x, y) \, dx dy = \frac{1}{n},\end{aligned}$$

故取 $n \rightarrow \infty$ 的极限即可得到

$$\begin{aligned}\mathbb{E}[g(X, Y)] &= \lim_{n \rightarrow \infty} \mathbb{E}[Z_n] \\ &= \lim_{n \rightarrow \infty} \iint_{\mathbb{R}^2} \theta_n(g(x, y)) \cdot f_{X,Y}(x, y) \, dx dy \\ &= \iint_{\mathbb{R}^2} g(x, y) \cdot f_{X,Y}(x, y) \, dx dy,\end{aligned}$$

其中第一个等号来自于定理 3.8. □

以上介绍的一般情形下期望的性质希望读者能够记住并学会如何运用, 但它们的证明只要求读者能够顺下来即可, 不要求掌握.

最后我们指出, 给定两个随机变量, 当它们相互独立且各自的期望均存在时, 其乘积的期望等于各自期望的乘积.

定理 3.13. 设 X, Y 为相互独立的随机变量, 且二者的期望均存在, 则

$$\mathbb{E}[XY] = \mathbb{E}[X] \cdot \mathbb{E}[Y].$$

证明. 这里只给出 X, Y 均为连续型随机变量时的证明. 由定理 3.5 得

$$\begin{aligned}\mathbb{E}[XY] &= \iint_{\mathbb{R}^2} xy \cdot f_{X,Y}(x, y) \, dx dy \\ &= \iint_{\mathbb{R}^2} (x \cdot f_X(x)) (y \cdot f_Y(y)) \, dx dy \\ &= \int_{-\infty}^{+\infty} x \cdot f_X(x) \, dx \int_{-\infty}^{+\infty} y \cdot f_Y(y) \, dy = \mathbb{E}[X] \cdot \mathbb{E}[Y].\end{aligned}$$

上式第二步用到了定理 3.3 的结论: X, Y 为连续型随机变量时, X 与 Y 相互独立的充要条件是 $(x, y) \mapsto f_X(x) \cdot f_Y(y)$ 给出 (X, Y) 的联合概率密度函数, 其中 f_X 与 f_Y 分别为 X 与 Y 的边缘概率密度函数.

上述证明要求读者掌握. 对于更加一般的情形, 依然可以采取离散型随机变量逼近的思路给出证明, 但具体的证明步骤则需要用到额外的工具 (单调收敛定理), 这里就不展开了, 也不要求读者掌握. $\square$

例 3.15. 设随机变量 X 的分布函数 $F_X: \mathbb{R} \rightarrow [0, 1]$ 为

$$F_X(x) = \theta \sum_{t \leq x} p(t) + (1 - \theta) \int_{-\infty}^x f(t) \, dt,$$

其中 $\theta \in [0, 1]$ 为一常数, $p: \mathbb{R} \rightarrow [0, 1]$ 为一分布列, $f: \mathbb{R} \rightarrow [0, +\infty[$ 为一概率密度函数. 设 $\sum_x |x| p(x)$ 与 $\int_{-\infty}^{+\infty} |x| f(x) \, dx$ 均收敛, 我们希望求出 X 的期望.

我们先利用例 3.14 的结论, 构造一个与 X 同分布的随机变量: 令 Y, Z_1, Z_2 为相互独立的随机变量, 其中 Y 服从参数为 θ 的伯努利分布; Z_1 为离散型随机变量, 其分布列为 p ; Z_2 为连续型随机变量, 其概率密度函数为 f_2 , 则随机变量

$$\tilde{X} = Z_1 \cdot \mathbf{1}_{\{Y=1\}} + Z_2 \cdot \mathbf{1}_{\{Y=0\}}$$

与 X 同分布, 从而有 $\mathbb{E}[X] = \mathbb{E}[\tilde{X}]$. 接下来, 我们计算其期望:

$$\begin{aligned}\mathbb{E}[X] &= \mathbb{E}[Z_1 \cdot \mathbf{1}_{\{Y=1\}} + Z_2 \cdot \mathbf{1}_{\{Y=0\}}] \\ &= \mathbb{E}[Z_1] \mathbb{E}[\mathbf{1}_{\{Y=1\}}] + \mathbb{E}[Z_2] \mathbb{E}[\mathbf{1}_{\{Y=0\}}] \\ &= \mathbb{P}(Y = 1) \mathbb{E}[Z_1] + \mathbb{P}(Y = 0) \mathbb{E}[Z_2],\end{aligned}$$

其中第二步利用了期望的线性以及 Y, Z_1, Z_2 之间的独立性 (定理 3.13). 最后, 代入 $\mathbb{P}(Y = 1) = 1 - \mathbb{P}(Y = 0) = \theta$ 以及 $\mathbb{E}[Z_1] = \sum_x x p(x)$, $\mathbb{E}[Z_2] = \int_{-\infty}^{+\infty} x f(x) \, dx$, 可得

$$\mathbb{E}[X] = \theta \sum_x x p(x) + (1 - \theta) \int_{-\infty}^{+\infty} x f(x) \, dx.$$

上述结论可以进一步推广: 设 $g: \mathbb{R} \rightarrow \mathbb{R}$ 为一给定函数, 且求和式 $\sum_x |g(x)|p(x)$ 与积分 $\int_{-\infty}^{+\infty} |g(x)|f(x) dx$ 均收敛, 则不难验证

$$g(\tilde{X}) = g(Z_1) \cdot 1_{\{Y=1\}} + g(Z_2) \cdot 1_{\{Y=0\}},$$

基于类似的步骤, 并利用离散型与连续型随机变量期望的 LOTUS, 可推得

$$\mathbb{E}[g(X)] = \theta \sum_x g(x) p(x) + (1 - \theta) \int_{-\infty}^{+\infty} g(x) f(x) dx. \quad (3.10)$$

例 3.16. 设 X 服从参数为 λ 的指数分布, 而 $Y = \max\{X, \lambda^{-1}\}$. 在例 3.6 中我们用连续型随机变量期望的 LOTUS 计算了 $\mathbb{E}[Y]$, 这次我们尝试从 Y 的分布出发来计算 $\mathbb{E}[Y]$.

注意到 Y 的取值至少为 λ^{-1} , 故 $y < \lambda^{-1}$ 时显然有 $\mathbb{P}(Y \leq y) = 0$. 而 $y \geq \lambda^{-1}$ 时, 由于 $\max\{X, \lambda^{-1}\} \leq y$ 当且仅当 $X \leq y$, 故有

$$F_Y(y) = \mathbb{P}(\max\{X, \lambda^{-1}\} \leq y) = \mathbb{P}(X \leq y) = \int_0^y \lambda e^{-\lambda t} dt = 1 - e^{-\lambda y}.$$

综上所述可知

$$\begin{aligned} F_Y(y) &= \begin{cases} 1 - e^{-\lambda y}, & \text{若 } y \geq \lambda^{-1}, \\ 0, & \text{若 } y < \lambda^{-1} \end{cases} \\ &= (1 - e^{-1}) \sum_{t: t \leq y} p(t) + e^{-1} \int_{-\infty}^y f(t) dt, \end{aligned}$$

其中

$$p(t) = \begin{cases} 1, & \text{若 } t = \lambda^{-1}, \\ 0, & \text{若 } t \neq \lambda^{-1}, \end{cases} \quad f(t) = \begin{cases} \lambda e^{-\lambda t+1}, & \text{若 } t > \lambda^{-1}, \\ 0, & \text{若 } t \leq \lambda^{-1}. \end{cases}$$

将上述结果与例 3.14 进行对比, 可知 Y 服从一离散—连续混合型分布. 故由式 (3.10), 可得

$$\begin{aligned} \mathbb{E}[Y] &= (1 - e^{-1}) \sum_y y p(y) + e^{-1} \int_{-\infty}^{+\infty} y f(y) dy \\ &= (1 - e^{-1}) \cdot \lambda^{-1} + e^{-1} \int_{\lambda^{-1}}^{+\infty} \lambda y e^{-\lambda y+1} dy \\ &= \frac{e+1}{\lambda e}. \end{aligned}$$

该结果与例 3.6 中得到的结果是一致的. ■

3.7 习题

习题 3.1 (Pareto 分布). 设随机变量 X 满足

$$\mathbb{P}(X \geq x) = \begin{cases} \left(\frac{x_m}{x}\right)^\alpha, & \text{若 } x \geq x_m, \\ 1, & \text{若 } x < x_m, \end{cases}$$

其中 x_m 与 α 为给定的正实数.

1. 证明 X 为连续型随机变量, 并求出其概率密度函数.
2. 求 α 的取值范围使得 $\mathbb{E}[X]$ 存在, 并求出 $\mathbb{E}[X]$ 存在时的值.
3. 求 α 的取值范围使得 $\text{Var}(X)$ 存在, 并求出 $\text{Var}(X)$ 存在时的值.
4. 是否存在 α 使得 $\mathbb{E}[X^\beta]$ 对任意 $\beta > 0$ 均存在?
5. 设 $z > x_m$. 试求 $\mathbb{P}(X > x | X > z)$.

习题 3.2. 设 (X, Y) 为连续型随机向量.

1. 若 (X, Y) 的联合概率密度函数为

$$f_{X,Y}(x, y) = \begin{cases} c e^{-2x} e^{-3y}, & \text{若 } x > 0 \text{ 且 } y > 0, \\ 0, & \text{其它情况,} \end{cases}$$

其中 c 为某个常数. 试求 c 的值, 并判断 X, Y 是否相互独立.

2. 若 (X, Y) 的联合概率密度函数为

$$f_{X,Y}(x, y) = \begin{cases} cxy, & \text{若 } x > 0, y > 0 \text{ 且 } x + y < 1, \\ 0, & \text{其它情况,} \end{cases}$$

其中 c 为某个常数. 试求 c 的值, 并判断 X, Y 是否相互独立.

注: 本题改编自 [4] 第 6.2 节例 2f.

习题 3.3. 设随机变量 X 服从参数为 $\lambda > 0$ 的指数分布, 并令 N 为不大于 X 的最大整数. 证明 N 与 $X - N$ 相互独立, 并分别求出 N 与 $X - N$ 的分布.

提示 由于 N 取值为自然数, 而 $X - N$ 取值于 $[0, 1]$, 故 N 与 $X - N$ 独立当且仅当

$$\mathbb{P}(N = n, X - N \in I) = \mathbb{P}(N = n) \cdot \mathbb{P}(X - N \in I)$$

对任意自然数 n 以及区间 $I \subseteq [0, 1[$ 均成立, 而

$$\begin{aligned}\mathbb{P}(N = n, X - N \in I) &= \mathbb{P}(X - n \in I), \\ \mathbb{P}(X - N \in I) &= \sum_{n=0}^{\infty} \mathbb{P}(N = n, X - N \in I), \\ \mathbb{P}(N = n) &= \mathbb{P}(n \leq X < n + 1).\end{aligned}$$

习题 3.4. 设 X 为一连续型随机变量, 且期望 $\mathbb{E}[X]$ 存在.

1. 若 X 的取值总是非负的, 证明

$$\mathbb{E}[X] = \int_0^{+\infty} \mathbb{P}(X > x) dx.$$

提示 由期望的定义出发, 证明

$$\mathbb{E}[X] = \int_0^{+\infty} \left(\int_0^x f_X(t) dt \right) dx,$$

然后交换积分次序 (无需说明积分次序交换的合法性).

2. 对于 X 的取值可正可负的情形, 证明

$$\mathbb{E}[X] = \int_0^{+\infty} (\mathbb{P}(X > x) - \mathbb{P}(X \leq -x)) dx.$$

3. 设 X 的取值总是非负的, $\alpha > 0$ 为给定常数. 若积分

$$\int_0^{+\infty} x^\alpha \mathbb{P}(X > x) dx$$

收敛, 试回答该积分值给出了哪个随机变量的期望, 并给出证明.

习题 3.5. 若 X 为离散型非负随机变量, 公式 $\mathbb{E}[X] = \int_0^{+\infty} \mathbb{P}(X > x) dx$ 是否成立?

提示 注意到 $\int_0^{+\infty} \mathbb{P}(X > u) dx = \int_0^{+\infty} \sum_u 1_{u>x}(x, u) \cdot p_X(u) dx$, 其中 $1_{u>x}(x, u)$ 在 $u > x$ 时为 1 而在其它情形下为 0. 接下来交换求和与积分次序.

注: $\mathbb{E}[X] = \int_0^{+\infty} \mathbb{P}(X > x) dx$ 对于任意的非负随机变量其实都是成立的, 有些教材直接基于它来定义一般随机变量的期望, 不过若采取这种定义, 期望的线性并不容易证明.

习题 3.6. 在区间 $[0, 1]$ 上均匀且独立地随机取两点, 这两个点将区间 $[0, 1]$ 分为三段, 把其中最长一段的长度用随机变量 X 表示. 试求 X 的期望与方差.

提示 利用例 3.5 与习题 3.4 的结论.

习题 3.7. 设 $g: \mathbb{R} \rightarrow \mathbb{R}$ 为一给定函数, X 与 $g(X)$ 均为连续型随机变量, X 的概率密度函数为 f_X . 试利用习题 3.4 的结论, 证明

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) dx.$$

提示 由习题 3.4 的结论, 可得

$$\mathbb{E}[g(X)] = \int_0^{+\infty} (\mathbb{P}(g(X) > t) - \mathbb{P}(g(X) \leq -t)) dt.$$

接下来, 证明

$$\begin{aligned}\mathbb{P}(g(X) > t) &= \int_{-\infty}^{+\infty} 1_{g(x) > t}(x, t) \cdot f_X(x) dx, \\ \mathbb{P}(g(X) \leq -t) &= \int_{-\infty}^{+\infty} 1_{g(x) \leq -t}(x, t) \cdot f_X(x) dx,\end{aligned}$$

其中 $1_{g(x) > t}(x, t)$ 在 $g(x) > t$ 时等于 1 而其它情况下等于 0; $1_{g(x) \leq -t}(x, t)$ 类似. 最后将以上两式代入之前的 $\mathbb{E}[g(X)]$ 的表达式中, 并交换积分次序 (无需说明积分次序交换的合法性).

习题 3.8. 设 X 为一随机变量, $\text{Var}(X)$ 存在. 证明: 对任意 $c \in \mathbb{R}$, 均有

$$\text{Var}(X) \leq \mathbb{E}[(X - c)^2],$$

且上式中取等号当且仅当 $c = \mathbb{E}[X]$.

习题 3.9. 设 X 为一随机变量, 且其值域为区间 $[a, b]$ 的子集, 其中 $a \leq b$ 为给定实数. 证明: $\text{Var}(X)$ 存在, 且 $\text{Var}(X) \leq (b - a)^2/4$.

提示 为证明 $\text{Var}(X) \leq (b - a)^2/4$, 可利用习题 3.8 的结论, 将 $c = (a + b)/2$ 代入, 并证明 $\mathbb{E}[(X - (a + b)/2)^2] \leq (b - a)^2/4$.

注: 本题取自 [6] 例 5.3.

习题 3.10. 设 X 为一随机变量. 利用定理 3.12 证明: $\text{Var}(X) = 0$ 当且仅当存在某个实数 c 使得 $\mathbb{P}(X = c) = 1$.

习题 3.11 (柯西-施瓦茨不等式, Cauchy-Schwarz inequality). 设 X, Y 为两个随机变量, 且 $\mathbb{E}[X^2]$ 与 $\mathbb{E}[Y^2]$ 均存在.

1. 证明 $\mathbb{E}[XY]$ 存在. 提示 注意到 $|XY| \leq (X^2 + Y^2)/2$, 再利用命题 3.10.

2. 证明 $|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}$, 其中取到等号当且仅当存在不全为零的常数 α, β 使得 $\mathbb{P}(\alpha X + \beta Y = 0) = 1$.

提示 注意到 $\mathbb{E}[(\alpha X + \beta Y)^2]$ 为关于 (α, β) 的半正定二次型, 利用线性代数中半正定二次型的相关判据.

习题 3.12 (琴生不等式, Jensen's inequality). 设 X 为一随机变量, 其期望 $\mathbb{E}[X]$ 存在, $g: \mathbb{R} \rightarrow \mathbb{R}$ 为一阶连续可微函数, $g'(x)$ 在 $x \in \mathbb{R}$ 上单调不减, 且 $\mathbb{E}[g(X)]$ 存在, 证明

$$g(\mathbb{E}[X]) \leq \mathbb{E}[g(X)].$$

提示 先证明对任意 $x, t \in \mathbb{R}$, 有

$$g(x) \geq g(t) + g'(t)(x - t),$$

再在上式中代入 $x = X, t = \mathbb{E}[X]$ 并取期望.

习题 3.13. 设函数 $g: [0, 1] \rightarrow \mathbb{R}$ 在区间 $[0, 1]$ 上可积且满足 $0 \leq g(x) \leq 1, \forall x \in [0, 1]$. 设随机变量 X, Y 相互独立且均服从区间 $[0, 1]$ 上的均匀分布. 令

$$U = \mathbf{1}_{\{Y \leq g(X)\}}, \quad V = g(X), \quad W = \frac{1}{2}(g(X) + g(1 - X)).$$

1. 证明

$$\mathbb{E}[U] = \mathbb{E}[V] = \mathbb{E}[W] = \int_0^1 g(x) dx.$$

2. 证明 $\text{Var}(W) \leq \text{Var}(V) \leq \text{Var}(U)$.

注: 本题取自 [8] 第 4.14 节习题 9.

习题 3.14 (Importance sampling). 设 X 为一连续型随机变量, 其概率密度函数为 f_X . $Y_1, \dots, Y_n$ 为 n 个同分布的连续型随机变量, 它们的概率密度函数为 f_Y , 且 $f_Y(y) > 0, \forall y \in \mathbb{R}$. $g: \mathbb{R} \rightarrow \mathbb{R}$ 为一函数, 且 $\mathbb{E}[g(X)]$ 存在. 令

$$Z = \frac{1}{n} \sum_{i=1}^n g(Y_i) \cdot \frac{f_X(Y_i)}{f_Y(Y_i)}.$$

证明

$$\mathbb{E}[Z] = \mathbb{E}[g(X)].$$

习题 3.15 (Wald 恒等式). 设 $X_1, X_2, X_3, \dots$ 为一列独立同分布的随机变量, 且 $\mathbb{E}[X_1]$ 存在. T 为一离散型随机变量, 其取值均为自然数, 且期望 $\mathbb{E}[T]$ 存在. 证明: 当

$$\mathbb{E}[X_n 1_{\{n \leq T\}}] = \mathbb{E}[X_n] \mathbb{P}(T \geq n), \quad \forall n = 1, 2, \dots$$

时, 有

$$\mathbb{E}\left[\sum_{n=1}^T X_n\right] = \mathbb{E}[X_1] \cdot \mathbb{E}[T].$$

提示 将上式左端改写为 $\mathbb{E}\left[\sum_{n=1}^{\infty} X_n \cdot 1_{\{n \leq T\}}\right]$, 而后交换期望与级数求和的次序 (无需说明交换次序的合法性).

习题 3.16. 设 $X_1, X_2, X_3, \dots$ 为一列独立同分布的随机变量, 且 $\mathbb{E}[X_1]$ 存在. $B \subseteq \mathbb{R}$ 为一给定的集合, 满足 $\mathbb{P}(X_1 \in B) \in]0, 1[$. 令

$$T = \min\{k \in \mathbb{N}_+ \mid X_k \in B\},$$

也就是说, T 表示 X_k 的取值首次落入集合 B 时 k 的值.

1. T 服从什么分布?
2. 对任意的正整数 n , 随机变量 $1_{\{n \leq T\}}$ 是否是 $(X_1, \dots, X_{n-1})$ 的函数? 请说明理由, 并由此证明 $\mathbb{E}[X_n 1_{\{n \leq T\}}] = \mathbb{E}[X_n] \mathbb{P}(T \geq n)$.
3. 利用 Wald 恒等式 (习题 3.15 的结论), 证明

$$\mathbb{E}\left[\sum_{n=1}^T X_n\right] = \frac{\mathbb{E}[X_1]}{\mathbb{P}(X_1 \in B)}.$$

4. 设某名客服人员服务单个顾客所需要的时间服从参数为 λ 的指数分布, 且不同顾客的服务时间相互独立. 但若服务某个顾客的时间超过了一个阈值 τ , 则客服部门的主管会即刻收到提示. 假设该客服始终有顾客需要服务且中间没有休息时间. 令 T 表示该客服开始工作到主管收到第一次提示之间的时长, 试求 T 的期望.

习题 3.17. 有两台设备 A、B 接在同一条供电线路上, 该供电线路上可能会出现三种供电异常: 第一种异常将使 A 发生故障但 B 仍正常工作; 第二种异常将使 B 发生故障但 A 仍正常工作; 第三种异常将使 A、B 同时发生故障. 设三种供电异常第一次发生的时刻相互独立且服从参数分别为 $\lambda_1, \lambda_2, \lambda_3$ 的指数分布. 令 X_A, X_B 分别表示 A、B 首次发生故障的时刻.

1. 试对任意 $s, t > 0$ 求 $\mathbb{P}(X_A > s, X_B > t)$.
2. (X_A, X_B) 是否是连续型随机向量? 提示 $\mathbb{P}(X_A = X_B)$ 是否为 0?

注: 本题取自 [4] 第六章自测题 6.8.

习题 3.18 (Buffon 投针问题). 假设有一大片地面上被画了足够多条互相平行的直线, 相邻两条平行线的距离均为 L . 现往地面上以足够均匀的方式随机地投一根针, 针的长度为 $\ell < L$. 试求针与地面某条直线相交的概率.

习题 3.19 (Bertrand 悖论). 假设我们希望在单位圆内随机取一条弦. 令点 O 为单位圆圆心. 我们考虑以下三种不同的取法:

1. 在单位圆周上均匀且独立地随机取两个点 A 与 B , 取弦 AB .
2. 在单位圆内均匀地随机取一个非圆心的点 P , 取过点 P 且与 OP 垂直的弦.
3. 在单位圆周上先均匀地随机取一点 Q_1 , 再在半径 OQ_1 上均匀地随机选一个点 Q_2 , 最后取过点 Q_2 且与 OQ_1 相垂直的弦.

试求上述三种不同取法下, 弦的长度大于 ℓ 的概率, 其中 $\ell \in]0, 2[$ 为给定的实数.

习题 3.20. 设 X, Y 服从 $]0, 1[$ 上的均匀分布且相互独立.

1. 令 Z 为 X/Y 四舍五入后得到的自然数. 试求 Z 为偶数的概率.
2. 令 W 为 X/Y 向下取整后得到的自然数 (即 W 为小于等于 X/Y 的最大自然数). 试求 W 为偶数的概率.

提示 (i) 在以 X 为横轴、 Y 为纵轴的平面直角坐标系上将事件 $\{Z \text{ 为偶数}\}$ 与 $\{W \text{ 为偶数}\}$ 所对应的区域表示出来. (ii) 如下级数和可能对求解有帮助:

$$\sum_{k=0}^{\infty} \frac{(-1)^k}{k+1} = \ln 2, \quad \sum_{k=0}^{\infty} \frac{(-1)^k}{2k+1} = \pi/4.$$

习题 3.21. 设有一个球面, 它 10% 的区域被染成了蓝色, 其余 90% 的区域被染成了红色. 证明: 无论球面上红色和蓝色区域具体的形状如何, 我们总能找到一个正方体使其八个顶点均落在该球面上的红色区域中.

提示 考虑在球面上“均匀”地随机选取八个能构成正方体的顶点, 计算落在球面红色区域的顶点数的期望 (可利用期望的线性), 再与待证结论进行比较.

注: 本题摘自 [8]1.8 节习题 28.

习题 3.22. 设随机变量 (X, Y) 的联合分布函数为

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \begin{cases} 1, & \text{若 } \min\{x, y\} \geq 1, \\ \min\{x, y\}, & \text{若 } 0 < \min\{x, y\} < 1, \\ 0, & \text{若 } \min\{x, y\} \leq 0. \end{cases}$$

1. 求 X, Y 各自的边缘分布.
2. $\frac{\partial^2 F_{X,Y}(x, y)}{\partial x \partial y}$ 在哪些点不存在? 存在时又等于多少?
3. (*) 证明 $\mathbb{P}(X = Y) = 1$, 从而 (X, Y) 不是连续型随机向量.

提示 此题有多种解法, 一种较为直接的解法如下: 令

$$E_{n,k} = \left\{ \frac{k-1}{2^n} < X \leq \frac{k}{2^n}, \frac{k-1}{2^n} < Y \leq \frac{k}{2^n} \right\}, \quad \forall n \in \mathbb{N}_+, k \in \{1, \dots, 2^n\}.$$

注意到 $\{X = Y\} = \bigcap_{n=1}^{\infty} \bigcup_{k=1}^{2^n} E_{n,k}$, 再利用概率的可加性与连续性.

第四章 随机变量的深入内容

4.1 随机变量函数的分布

本节中我们主要考虑这样一类问题: 给定 n 维随机向量 $\mathbf{X}$ 并知道它的联合分布 (以联合分布列/联合概率密度函数/联合分布函数的形式给出), 以及 (向量值) 函数 $g: \text{Im } \mathbf{X} \rightarrow \mathbb{R}^m$, 如何求出 m 维随机向量 $\mathbf{Y} = g(\mathbf{X})$ 的联合分布? 一般来说这类问题需要具体情况具体分析, 并没有完全通用的方法. 第二章的例 2.3、2.4 及 2.7 已经对 $\mathbf{X}$ 为离散型的一些情况进行了讨论, 本节中我们将对其它一些特殊情况进行介绍.

4.1.1 连续型随机变量函数的分布

先考虑一个比较简单的情况: 设 X 为一连续型随机变量, 其概率密度函数 f_X 已知, g 为一元实值函数, 其定义域包含 X 的值域. 我们想要考察 $Y = g(X)$ 的概率分布.

当函数 g 的值域为可数集时, 可知 $Y = g(X)$ 的值域也必定是可数集, 从而 Y 必定为一离散型随机变量, 只需计算其分布列即可完整描述其概率分布:

$$p_Y(y) = \mathbb{P}(g(X) = y) = \int_{g(x)=y} f_X(x) dx.$$

换句话说, 我们需要先对任意 $y \in \text{Im } g$ 求出方程 $g(x) = y$ 的解集 $\{x \mid g(x) = y\}$, 而后在这个解集上对概率密度函数 f_X 进行积分.

当函数 g 的值域为不可数集时, 我们通常要求解 $Y = g(X)$ 的分布函数:

$$F_Y(y) = \mathbb{P}(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx, \quad \forall y \in \mathbb{R}.$$

为计算上式右端积分, 需要对任意 $y \in \mathbb{R}$ 求解不等式 $g(x) \leq y$, 再在解集 $\{x \mid g(x) \leq y\}$ 上对概率密度函数 f_X 进行积分.

例 4.1. 设 X 服从 $]0, 1[$ 上的均匀分布. 令 $F: \mathbb{R} \rightarrow]0, 1[$ 为一连续且严格单调递增的函数, 且满足

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1.$$

由数学分析知识可证明 F 有连续且严格单调递增的反函数 $F^{-1}:]0, 1[\rightarrow \mathbb{R}$. 我们考虑随机变量 $Y = F^{-1}(X)$ 的分布: 注意到对任意 $x \in]0, 1[$ 及 $y \in \mathbb{R}$, $F^{-1}(x) \leq y$ 当且仅当 $x \leq F(y)$, 故

$$\mathbb{P}(Y \leq y) = \mathbb{P}(F^{-1}(X) \leq y) = \mathbb{P}(X \leq F(y)) = \int_{-\infty}^{F(y)} 1_{]0, 1[}(x) dx = F(y),$$

故 $Y = F^{-1}(X)$ 的分布函数就是 F .

这个例子为生成概率分布为 F 的随机数提供了一种方法: 若 F 连续且严格单调递增, 则可以首先生成一个服从 $]0, 1[$ 上均匀分布的随机数 x , 然后求出方程 $F(y) = x$ 的解 y , 此时 y 作为一个随机数, 即服从 F 给出的概率分布. 需要注意的是, 该方法中需要求解方程 $F(y) = x$, 这在许多实际情况中会有困难. ■

当函数 g 的性质较好 (例如 g 在定义域上除开有限多个点可导, 且导函数的零点只有有限多个) 时, 应检查一下是否能将 $F_Y(y)$ 表示为一个函数在区间 $]-\infty, y]$ 上的积分, 或是检查 F_Y 是否连续并在除开个别点以后处处可导, 因为这些性质的成立意味着 Y 为连续型随机变量, 可以用概率密度函数来描述其概率分布. 我们用两个例子对此进行进一步说明.

例 4.2. 设 X 为一连续型随机变量, $Y = X^2$. 为了求出 Y 的分布, 我们考察其分布函数 $F_Y(y) = \mathbb{P}(Y \leq y)$. 显然 $y \leq 0$ 时有 $\mathbb{P}(Y \leq y) = 0$, 而 $y > 0$ 时,

$$F_Y(y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq X \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} f_X(x) dx.$$

上式右端在 $y \rightarrow 0^+$ 时趋于 0, 且对任意 $y > 0$ 均可导, 其导函数为

$$\frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}},$$

故不难看出 Y 为一连续型随机变量, 其概率密度函数为

$$f_Y(y) = \begin{cases} \frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}}, & y > 0, \\ 0, & y \leq 0. \end{cases}$$

特别是, 当 $X \sim \mathcal{N}(0, 1)$ 时, 有

$$f_Y(y) = \begin{cases} \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2}, & y > 0, \\ 0, & y \leq 0, \end{cases}$$

此时我们称 Y 服从自由度为 1 的 χ^2 分布. ■

例 4.3. 设 X 为一连续型随机变量, 其值域为 $] -1, 1[$ 的子集, 概率密度函数为 f_X , 而 $Y = \sqrt{1 - X^2}$. 为了求出 Y 的分布, 我们考察其分布函数 $F_Y(y) = \mathbb{P}(Y \leq y)$. 不难看出对任意 $y < 0$ 有 $\mathbb{P}(Y \leq y) = 0$, 而对任意 $y \geq 1$ 有 $\mathbb{P}(Y \leq y) = 1$. 当 $0 \leq y < 1$ 时, 有

$$\begin{aligned} \mathbb{P}(Y \leq y) &= \mathbb{P}(\sqrt{1 - X^2} \leq y) = \mathbb{P}(X^2 \geq 1 - y^2) \\ &= \mathbb{P}\left(\left\{X \geq \sqrt{1 - y^2}\right\} \cup \left\{X \leq -\sqrt{1 - y^2}\right\}\right) \\ &= \mathbb{P}\left(X \geq \sqrt{1 - y^2}\right) + \mathbb{P}\left(X \leq -\sqrt{1 - y^2}\right) \\ &= \int_{\sqrt{1 - y^2}}^1 f_X(x) dx + \int_{-1}^{-\sqrt{1 - y^2}} f_X(x) dx. \end{aligned}$$

注意到上式右端在 $y \in [0, 1[$ 时均可导, 其导函数为

$$\frac{y}{\sqrt{1 - y^2}} \cdot \left(f_X(\sqrt{1 - y^2}) + f_X(-\sqrt{1 - y^2})\right).$$

此外, $F_Y(y)$ 在 $y = 0$ 与 $y = 1$ 处均连续. 故不难看出 Y 为一连续型随机变量, 其概率密度函数由

$$f_Y(y) = \begin{cases} \frac{y}{\sqrt{1 - y^2}} \cdot \left(f_X(\sqrt{1 - y^2}) + f_X(-\sqrt{1 - y^2})\right), & 0 \leq y < 1, \\ 0, & y < 0 \text{ 或 } y \geq 1 \end{cases}$$

给出. ■

接下来我们考虑一个更具体的特殊情况: 设函数 g 定义在开区间 $]a, b[$ 上且为严格单调递增的连续函数 (允许 $a = -\infty$ 或 $b = +\infty$). 由基本的数学分析知识可知, g 的值域也为某个开区间 $] \alpha, \beta[$ (允许 $\alpha = -\infty$ 或 $\beta = +\infty$), 且存在定义在 $] \alpha, \beta[$ 上的严格单调递增的反函数 h :

$$h(g(x)) = x, \quad \forall x \in]a, b[.$$

我们进一步假定 h 在 $] \alpha, \beta[$ 上处处可导.

我们利用前面给出的方法求解 $Y = g(X)$ 的分布函数. 由于 X 为一连续型随机变量, 且对任意 $x \in]a, b[$, $g(x) \leq y$ 当且仅当 $x \leq h(y)$, 故 $y \in]\alpha, \beta[$ 时, 有

$$\begin{aligned} F_Y(y) &= \mathbb{P}(g(X) \leq y) \\ &= \int_{g(x) \leq y} f_X(x) dx \\ &= \int_a^{h(y)} f_X(x) dx, \end{aligned}$$

接下来利用定积分换元公式做换元 $x = h(t)$, 可得 $\alpha < y < \beta$ 时有

$$F_Y(y) = \int_{\alpha}^y f_X(h(t)) \cdot h'(t) dt,$$

而 $y \leq \alpha$ 时 $F_Y(y) = \mathbb{P}(g(X) \leq y) = 0$, $y \geq \beta$ 时 $F_Y(y) = \mathbb{P}(g(X) \leq y) = 1$. 此外, α 为有限实数时, $F_Y(y)$ 在 $y = \alpha$ 处连续; β 为有限实数时, $F_Y(y)$ 在 $y = \beta$ 处连续. 综上所述可知 Y 为一连续型随机变量, 其概率密度函数为

$$f_Y(y) = \begin{cases} f_X(h(y)) \cdot h'(y), & y \in]\alpha, \beta[, \\ 0, & y \notin]\alpha, \beta[. \end{cases}$$

上述推导过程同样可用于 g 在 $]a, b[$ 上连续、严格递减且存在可导反函数的情形, 具体的推导步骤这里不再展开. 综上, 可得如下结论:

定理 4.1. 设 X 为一连续型随机变量, $]a, b[$ 为一包含 X 值域的开区间 (允许 $a = -\infty$ 或 $b = +\infty$), 函数 $g:]a, b[\rightarrow \mathbb{R}$ 连续、严格单调且值域为 $]\alpha, \beta[$ (允许 $\alpha = -\infty$ 或 $\beta = +\infty$), 其反函数 $h:]\alpha, \beta[\rightarrow]a, b[$ 处处可导. 则 $Y = g(X)$ 为一连续型随机变量, 其概率密度函数为

$$f_Y(y) = \begin{cases} f_X(h(y)) \cdot |h'(y)|, & y \in]\alpha, \beta[, \\ 0, & y \notin]\alpha, \beta[. \end{cases}$$

4.1.2 连续型随机向量函数的分布

本小节中我们考虑二维连续型随机向量的函数的分布: 设 (X, Y) 为连续型随机向量, 其概率密度函数 $f_{X,Y}$ 已知, g 为二元实值函数, 其定义域包含 (X, Y) 的值域. 我们想要考察 $Z = g(X, Y)$ 的概率分布.

与一维情形类似, 当函数 g 的值域为可数集时, $Z = g(X, Y)$ 为一离散型随机变量, 只需计算其分布列即可完整描述其概率分布:

$$p_Y(z) = \mathbb{P}(g(X, Y) = z) = \iint_{g(x, y)=z} f_{X, Y}(x, y) \, dx dy, \quad \forall z \in \mathbb{R}.$$

而若 g 的值域为不可数集, 则通常从 $Z = g(X, Y)$ 的分布函数入手:

$$F_Z(z) = \mathbb{P}(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f_{X, Y}(x, y) \, dx dy.$$

对于二维情况, 区域 $\{(x, y) \mid g(x, y) \leq z\}$ 通常会更加复杂, 一般我们会考虑将其分解为可数个不相交的简单区域, 而后在这些简单区域上求解重积分, 最后求和. 此外, 也不要忘记检查 Z 是否是连续型随机变量, 并进一步求它的概率密度函数来描述其概率分布. 我们用几个例子对此进行说明.

例 4.4 (独立变量最大值的分布). 设 X, Y 相互独立, 我们希望考查 $Z = \max\{X, Y\}$ 的概率分布. 先暂时不假定 X, Y 为连续型随机变量, 则 Z 的分布函数为

$$\begin{aligned} \mathbb{P}(Z \leq z) &= \mathbb{P}(\max\{X, Y\} \leq z) \\ &= \mathbb{P}(X \leq z, \dots, Y \leq z) \\ &= \mathbb{P}(X \leq z) \cdots \mathbb{P}(Y \leq z) = F_X(z) \cdot F_Y(z), \end{aligned}$$

其中第二步是因为 $\max\{x, y\} \leq z$ 当且仅当 $x \leq z$ 且 $y \leq z$, 而第三步则用到了独立性.

下面进一步假定 X, Y 均为连续型随机变量, 其概率密度函数分别为 f_X 与 f_Y . 则此时 Z 也是连续型随机变量, 其概率密度函数 f_Z 可通过导函数的莱布尼兹律得到:

$$f_Z(z) = f_X(z)F_Y(z) + F_X(z)f_Y(z).$$

若 X, Y 还服从同一个分布, 记它们的分布函数为 F , 概率密度函数为 f , 则有

$$f_Z(z) = 2F(z)f(z).$$

利用类似的方法, 读者可自行推导 $X_1, \dots, X_n$ 相互独立时 $\max\{X_1, \dots, X_n\}$ 以及 $\min\{X_1, \dots, X_n\}$ 的分布. ■

例 4.5 (连续型随机向量分量之和的分布). 设 (X, Y) 为连续型随机向量, 其联合概

率密度函数为 $f_{X,Y}$, 令 $Z = X + Y$. 则 Z 的分布函数为

$$\begin{aligned} F_Z(z) &= \mathbb{P}(X + Y \leq z) \\ &= \iint_{x+y \leq z} f_{X,Y}(x, y) \, dx dy = \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{z-x} f_{X,Y}(x, y) \, dy \right) dx \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^z f_{X,Y}(x, t-x) \, dt \right) dx = \int_{-\infty}^z \left(\int_{-\infty}^{+\infty} f_{X,Y}(x, t-x) \, dx \right) dt, \end{aligned}$$

其中第三步将重积分化为了累次积分, 而第四步则对积分 $\int_{-\infty}^{z-x} f_{X,Y}(x, y) \, dy$ 进行了换元 $t = y + x$. 观察上式最右端即可看出 Z 为连续型随机变量, 其概率密度函数为

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(x, z-x) \, dx, \quad z \in \mathbb{R}.$$

对上式中的积分做换元 $y = z - x$ 还能得到

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(z-y, y) \, dy, \quad z \in \mathbb{R}.$$

若 X, Y 还相互独立, 则有

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) \, dx = \int_{-\infty}^{+\infty} f_X(z-y) f_Y(y) \, dy \quad z \in \mathbb{R}.$$

上式也被称为**卷积公式** (convolution formula). ■

例 4.6. 设 $X_1, \dots, X_n$ 相互独立且均服从参数为 λ 的指数分布. 则

$$\begin{aligned} f_{X_1+X_2}(z) &= \int_{-\infty}^{+\infty} f_{X_1}(x) f_{X_2}(z-x) \, dx \\ &= \begin{cases} \int_0^z \lambda^2 \cdot e^{-\lambda x} \, dx = \lambda^2 z e^{-\lambda z}, & \text{若 } z > 0, \\ 0, & \text{若 } z \leq 0. \end{cases} \end{aligned}$$

以及

$$\begin{aligned} f_{X_1+X_2+X_3}(z) &= \int_{-\infty}^{+\infty} f_{X_1+X_2}(x) f_{X_3}(z-x) \, dx \\ &= \begin{cases} \int_0^z \lambda^3 x e^{-\lambda x} \, dx = \frac{\lambda^3}{2} z^2 e^{-\lambda z}, & \text{若 } z > 0, \\ 0, & \text{若 } z \leq 0. \end{cases} \end{aligned}$$

重复上述递推过程, 不难得到

$$f_{X_1+\dots+X_n}(z) = \begin{cases} \frac{\lambda^n}{(n-1)!} z^{n-1} e^{-\lambda z}, & \text{若 } z > 0, \\ 0, & \text{若 } z \leq 0. \end{cases}$$

一般地, 给定正实数 α, β , 若随机变量 Z 的概率密度函数为

$$f_Z(z) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} z^{\alpha-1} e^{-\beta z}, & \text{若 } z > 0, \\ 0, & \text{若 } z \leq 0, \end{cases} \quad (4.1)$$

则称 Z 服从参数为 (α, β) 的 **Gamma 分布** (Gamma distribution). ■

例 4.7. 设 X 为离散型随机变量, 分布列为 p_X ; Y 为连续型随机变量, 概率密度函数为 f_Y . X 与 Y 相互独立. 则 $Z = X + Y$ 服从怎样的分布?

我们先求出 Z 的分布函数. 记 X 的值域为 $\text{Im } X$. 令 $z \in \mathbb{R}$ 任意, 则有

$$\begin{aligned} F_Z(z) &= \mathbb{P}(X + Y \leq z) = \sum_{x \in \text{Im } X} \mathbb{P}(X + Y \leq z, X = x) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(X = x, Y \leq z - x) \\ &= \sum_{x \in \text{Im } X} \mathbb{P}(X = x) \mathbb{P}(Y \leq z - x) \\ &= \sum_x p_X(x) \int_{-\infty}^{z-x} f_Y(y) dy, \end{aligned}$$

其中第二个等号来自于概率的可数可加性, 第四个等号来自于 X, Y 的独立性. 接下来, 对积分 $\int_{-\infty}^{z-x} f_Y(y) dy$ 做换元 $t = y + x$, 可得

$$\int_{-\infty}^{z-x} f_Y(y) dy = \int_{-\infty}^z f_Y(t - x) dt.$$

将其代入前面 $F_Z(z)$ 的表达式, 可得

$$\begin{aligned} F_Z(z) &= \sum_x p_X(x) \int_{-\infty}^z f_Y(t - x) dt = \int_{-\infty}^z p_X(x) f_Y(t - x) dt \\ &= \int_{-\infty}^z \left(\sum_x p_X(x) f_Y(t - x) \right) dt, \end{aligned}$$

其中最后一步我们交换了求和与积分的次序 (交换次序的合法性由实分析中的 Fubini 定理保证, 不要求读者了解). 将上式与连续型随机变量的定义进行对照, 可知 Z 为连续型随机变量, 其概率密度函数为

$$f_Z(z) = \sum_x p_X(x) f_Y(z - x), \quad z \in \mathbb{R}.$$

上式也可以看成是一种特殊的卷积公式. ■

4.1.3 (*) 连续型随机向量经过可逆变换后的分布

本小节中我们考虑这样一个情形: $\mathbf{X} = (X, Y)$ 为连续型随机向量, 其联合概率密度函数为 $f_{X,Y} : \mathbb{R}^2 \rightarrow [0, +\infty[$. $\mathcal{D}$ 与 $\mathcal{R}$ 均为平面 $\mathbb{R}^2$ 的开子集, 且 $\mathcal{D}$ 包含 (X, Y) 的值域. 映射 $\mathbf{g} : \mathcal{D} \rightarrow \mathcal{R}$ 为双射, 且 $\mathbf{g}$ 与其逆映射 $\mathbf{g}^{-1}$ 均连续可微. 令

$$(U, V) = \mathbf{g}(X, Y).$$

我们希望求解随机向量 (U, V) 的联合分布.

由于 $\mathbf{g}$ 为双射且 $\mathbf{g}$ 与 $\mathbf{g}^{-1}$ 均连续可微, 故直观上 (U, V) 应当是一个连续型随机向量, 这里我们直接求解 (U, V) 的联合概率密度函数. 任取区间 $I, J \subseteq \mathbb{R}$, 并记

$$B = \{(x, y) \in \mathbb{R}^2 \mid \mathbf{g}(x, y) \in I \times J\},$$

也就是说, B 当中的点 (x, y) 都是使得 $\mathbf{g}(x, y)$ 取值落在矩形区域 $I \times J$ 中的那些点. 则有

$$\begin{aligned} \mathbb{P}((U, V) \in I \times J) &= \mathbb{P}((X, Y) \in B) = \iint_B f_{\mathbf{X}}(\mathbf{x}) \, d\mathbf{x} dy \\ &= \iint_{\mathcal{D}} 1_B(x, y) \cdot f_{X,Y}(x, y) \, d\mathbf{x} dy \\ &= \iint_{\mathcal{R}} 1_B(\mathbf{g}^{-1}(u, v)) \cdot f_{X,Y}(\mathbf{g}^{-1}(u, v)) \cdot |\det D\mathbf{g}^{-1}(u, v)| \, du dv. \end{aligned}$$

这里对上式最右端的符号以及最后一个等号做一些说明: $\det$ 表示取行列式, $D\mathbf{g}^{-1}(u, v)$ 表示向量值函数 $\mathbf{g}^{-1}$ 在点 (u, v) 处的雅可比矩阵; 若记 $\mathbf{g}^{-1}$ 的两个分量为 h_1, h_2 (它们均为定义在 $\mathcal{R}$ 上的连续可微函数), 则

$$\det D\mathbf{g}^{-1}(u, v) = \begin{vmatrix} \frac{\partial h_1(u, v)}{\partial u} & \frac{\partial h_1(u, v)}{\partial v} \\ \frac{\partial h_2(u, v)}{\partial u} & \frac{\partial h_2(u, v)}{\partial v} \end{vmatrix};$$

此外, 我们还对上式第二行中的重积分进行了换元 $(x, y) = \mathbf{g}^{-1}(u, v)$, 并利用了如下换元定理:

定理 4.2 (重积分换元定理). 设 $\mathcal{R}$ 和 $\mathcal{D}$ 均为 $\mathbb{R}^n$ 中的开集, φ 为 $\mathcal{R} \rightarrow \mathcal{D}$ 的双射, 且 φ 与 φ^{-1} 均连续可微, 则对于 $\mathcal{D}$ 上的任意可积函数 f , 有

$$\int_{\mathcal{D}} f(\mathbf{x}) \, d\mathbf{x} = \int_{\mathcal{R}} f(\varphi(\mathbf{y})) |\det D\varphi(\mathbf{y})| \, d\mathbf{y}.$$

关于上述定理更详细的信息可参考 [12] 第 10.6 节, 而若读者对勒贝格积分没有了解, 则可参考 [13] 第 13.5 及 13.6 节给出的上述定理的黎曼积分版本.

我们继续上面的推导:

$$\begin{aligned}\mathbb{P}((U, V) \in I \times J) &= \iint_{\mathcal{R}} 1_B(\mathbf{g}^{-1}(u, v)) \cdot f_{X,Y}(\mathbf{g}^{-1}(u, v)) \cdot |\det D\mathbf{g}^{-1}(u, v)| \, du dv \\ &= \iint_{\mathcal{R}} 1_{I \times J}(u, v) \cdot f_{X,Y}(\mathbf{g}^{-1}(u, v)) \cdot |\det D\mathbf{g}^{-1}(u, v)| \, du dv \\ &= \iint_{I \times J} f_{U,V}(u, v) \, du dv,\end{aligned}$$

其中第二步是因为 $\mathbf{g}^{-1}(u, v) \in B$ 当且仅当 $(u, v) \in I \times J$, 而最后一步中我们令

$$f_{U,V}(u, v) = \begin{cases} f_{X,Y}(\mathbf{g}^{-1}(u, v)) \cdot |\det D\mathbf{g}^{-1}(u, v)|, & \text{若 } (u, v) \in \mathcal{R}, \\ 0, & \text{若 } (u, v) \notin \mathcal{R}. \end{cases}$$

由于 I, J 可以是任意的两个区间, 由连续型随机向量的定义可知, (U, V) 为连续型随机向量, 其联合概率密度函数即为 $f_{U,V}$.

我们将以上结果总结为如下定理:

定理 4.3. 设 (X, Y) 为连续型随机向量, 其联合概率密度函数为 $f_{X,Y}$. $\mathcal{D}$ 与 $\mathcal{R}$ 均为平面 $\mathbb{R}^2$ 的开子集, 且 $\mathcal{D}$ 包含 (X, Y) 的值域. $\mathbf{g}: \mathcal{D} \rightarrow \mathcal{R}$ 为一双射, 且 $\mathbf{g}$ 与 $\mathbf{g}^{-1}$ 均连续可微. 则 $(U, V) = \mathbf{g}(X, Y)$ 为连续型随机向量, 其联合概率密度函数为

$$f_{U,V}(u, v) = \begin{cases} f_{X,Y}(\mathbf{g}^{-1}(u, v)) \cdot |\det D\mathbf{g}^{-1}(u, v)|, & \text{若 } (u, v) \in \mathcal{R}, \\ 0, & \text{若 } (u, v) \notin \mathcal{R}. \end{cases} \quad (4.2)$$

其中 $D\mathbf{g}^{-1}(u, v)$ 表示 $\mathbf{g}^{-1}$ 在 (u, v) 处的雅可比矩阵.

该定理的一个重要特殊情形是 $\mathbf{g}$ 为一可逆仿射变换, 也就是说存在可逆实方阵 $\mathbf{A} = [a_{ij}]$ 与实向量 $\mathbf{b} = (b_1, b_2)$ 使得¹

$$\mathbf{g}(\mathbf{x}) = \mathbf{Ax} + \mathbf{b} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + b_1 \\ a_{21}x_1 + a_{22}x_2 + b_2 \end{bmatrix}, \quad \forall \mathbf{x} = (x_1, x_2) \in \mathbb{R}^2.$$

此时有

$$\det D\mathbf{g}^{-1}(\mathbf{y}) = \det(\mathbf{A}^{-1}) = \frac{1}{\det \mathbf{A}}, \quad \forall \mathbf{y} \in \mathbb{R}^2,$$

故我们有如下推论:

¹ 本讲义中形如 $(x_1, \dots, x_n)$ 的多元组均看成列向量.

推论 4.4. 设 $\mathbf{X}$ 为二维连续型随机向量, 其联合概率密度函数为 $f_{\mathbf{X}}$, $\mathbf{A} \in \mathbb{R}^{2 \times 2}$ 为可逆实方阵, $\mathbf{b} \in \mathbb{R}^2$ 为实向量. 则 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 为连续型随机向量, 其联合概率密度函数为

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})) \cdot \frac{1}{|\det \mathbf{A}|}, \quad \forall \mathbf{y} \in \mathbb{R}^2. \quad (4.3)$$

定理 4.3 与推论 4.4 不难推广到一般的 n 维连续型随机向量的情形.

4.2 协方差与相关系数

让我们考虑这样一个问题: 给定两个随机变量 X, Y , 它们的和 $X + Y$ 的方差等于什么? 由方差的定义可得

$$\begin{aligned} \text{Var}(X + Y) &= \mathbb{E}[(X - \mathbb{E}[X] + Y - \mathbb{E}[Y])^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X])^2] + \mathbb{E}[(Y - \mathbb{E}[Y])^2] + 2\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]. \end{aligned}$$

我们看到 $X + Y$ 的方差不仅包含了 X 的方差与 Y 的方差的和, 还包括了一个交叉项 $\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$. 我们将这个交叉项定义为随机变量 X 与 Y 的协方差.

定义 4.1. 给定随机变量 X, Y , 设 $\mathbb{E}[X]$ 与 $\mathbb{E}[Y]$ 均存在. 若期望

$$\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

存在, 则将该期望称作 X 与 Y 的**协方差** (covariance), 记作 $\text{Cov}(X, Y)$ 或 σ_{XY} .

由定义不难看出协方差具有对称性 $\text{Cov}(X, Y) = \text{Cov}(Y, X)$, 且方差其实是协方差的一个特例, 即 $\text{Var}(X) = \text{Cov}(X, X)$. 我们将协方差 $\text{Cov}(X, Y)$ 的定义式展开, 可得

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[XY - \mathbb{E}[X]Y - X\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \end{aligned} \quad (4.4)$$

在许多场合中用上式计算协方差是更加方便的.

以下命题指出, 协方差具有“双线性”的性质.

定理 4.5. 设 $X_1, \dots, X_m$ 与 $Y_1, \dots, Y_n$ 为两组随机变量, 且协方差 $\text{Cov}(X_i, Y_j)$ 对任意 $i = 1, \dots, m$ 与 $j = 1, \dots, n$ 均存在. $\alpha_1, \dots, \alpha_m$ 与 $\beta_1, \dots, \beta_n$ 为两组取值任意的实数, 则有

$$\text{Cov}\left(\sum_{i=1}^m \alpha_i X_i, \sum_{j=1}^n \beta_j Y_j\right) = \sum_{i=1}^m \sum_{j=1}^n \alpha_i \beta_j \text{Cov}(X_i, Y_j).$$

证明. 由协方差的定义与期望的线性, 可得

$$\begin{aligned}
 \text{Cov}\left(\sum_{i=1}^m \alpha_i X_i, \sum_{j=1}^n \beta_j Y_j\right) &= \mathbb{E}\left[\left(\sum_{i=1}^m \alpha_i X_i - \mathbb{E}\left[\sum_{i=1}^m \alpha_i X_i\right]\right)\left(\sum_{j=1}^n \beta_j Y_j - \mathbb{E}\left[\sum_{j=1}^n \beta_j Y_j\right]\right)\right] \\
 &= \mathbb{E}\left[\left(\sum_{i=1}^m \alpha_i (X_i - \mathbb{E}[X_i])\right)\left(\sum_{j=1}^n \beta_j (Y_j - \mathbb{E}[Y_j])\right)\right] \\
 &= \sum_{i=1}^m \sum_{j=1}^n \alpha_i \beta_j \mathbb{E}[(X_i - \mathbb{E}[X_i])(Y_j - \mathbb{E}[Y_j])] \\
 &= \sum_{i=1}^m \sum_{j=1}^n \alpha_i \beta_j \text{Cov}(X_i, Y_j).
 \end{aligned}$$

证毕. □

例 4.8. 设 X, Y 为两个随机变量, 二者各自的方差与协方差均存在, 且 $\text{Var}(X) > 0$. 我们考虑如何用 X 的一次函数 $\beta X + \alpha$ 来近似 Y . 具体而言, 我们希望找到 $\alpha, \beta \in \mathbb{R}$ 使得近似误差的均方值

$$\mathbb{E}[(Y - (\beta X + \alpha))^2]$$

达到最小.

为求得最优的 α 与 β , 首先注意到

$$\begin{aligned}
 &\mathbb{E}[(Y - (\beta X + \alpha))^2] \\
 &= \mathbb{E}[(Y - \mathbb{E}[Y] - \beta(X - \mathbb{E}[X])) + (\mathbb{E}[Y] - (\beta \mathbb{E}[X] + \alpha))]^2] \\
 &= \mathbb{E}[(Y - \mathbb{E}[Y] - \beta(X - \mathbb{E}[X]))^2] + \mathbb{E}[(\mathbb{E}[Y] - (\beta \mathbb{E}[X] + \alpha))^2] \\
 &\quad + 2 \mathbb{E}[(Y - \mathbb{E}[Y] - \beta(X - \mathbb{E}[X]))(\mathbb{E}[Y] - (\beta \mathbb{E}[X] + \alpha))] \\
 &= \mathbb{E}[(Y - \mathbb{E}[Y] - \beta(X - \mathbb{E}[X]))^2] + (\mathbb{E}[Y] - (\beta \mathbb{E}[X] + \alpha))^2 \\
 &= \text{Var}(X) \left(\beta - \frac{\text{Cov}(X, Y)}{\text{Var}(X)}\right)^2 + (\alpha - (\mathbb{E}[Y] - \beta \mathbb{E}[X]))^2 + \text{Var}(Y) - \frac{(\text{Cov}(X, Y))^2}{\text{Var}(X)}.
 \end{aligned}$$

观察上式右端的形式不难看出, 若要使 $\mathbb{E}[(Y - (\beta X + \alpha))^2]$ 取到最小值, 则 β 与 α 应满足

$$\begin{aligned}
 \beta &= \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \\
 \alpha &= \mathbb{E}[Y] - \beta \mathbb{E}[X] = \mathbb{E}[Y] - \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \mathbb{E}[X].
 \end{aligned}$$

也就是说, 若以误差的均方值为衡量标准, 则

$$f^*(X) = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \cdot (X - \mathbb{E}[X]) + \mathbb{E}[Y] \quad (4.5)$$

是在所有 X 的一次函数中对 Y 的最佳近似. 此外, 不难得到最佳近似导致的误差的均方值为

$$\mathbb{E}[(Y - f^*(X))^2] = \text{Var}(Y) - \frac{(\text{Cov}(X, Y))^2}{\text{Var}(X)}. \quad (4.6)$$

■

式 (4.5) 进一步揭示了协方差 $\text{Cov}(X, Y)$ 的直观意义:

1. 当 $\text{Cov}(X, Y) > 0$ 时, 最佳近似 $f^*(X)$ 中 X 的系数是正的. 直观上看, 这可以解释为当 X 的取值增加时, Y 的取值具有增加的趋势. 此时我们称 X 与 Y **正相关** (positively correlated).
2. 类似地, $\text{Cov}(X, Y) < 0$ 的情形可以直观解释为当 X 的取值增加时, Y 的取值具有减小的趋势. 此时我们称 X 与 Y **负相关** (negatively correlated).
3. 当 $\text{Cov}(X, Y) = 0$ 时, 直观上可认为 X 取值的增减在整体趋势上对 Y 的取值没有影响. 此时我们称 X 与 Y **不相关** (uncorrelated). 由式 (4.4) 可得 X 与 Y 不相关的充要条件是 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.

不难看出若 X 与 Y 相互独立且二者的期望均存在, 则 X 与 Y 不相关; 但需注意该结论的逆命题不成立: X 与 Y 不相关推不出 X 与 Y 相互独立.

例 4.9. 记 $\mathbb{D} = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq 1\}$ 为平面 $\mathbb{R}^2$ 上的单位圆盘, (X, Y) 为连续型随机向量且联合概率密度函数为

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{\pi}, & (x, y) \in \mathbb{D}, \\ 0, & (x, y) \notin \mathbb{D}. \end{cases}$$

则由对称性不难看出 $\mathbb{E}[X] = \mathbb{E}[Y] = 0$ 以及

$$\mathbb{E}[XY] = \iint_{\mathbb{D}} xy \cdot \frac{1}{\pi} dx dy = 0.$$

从而

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0,$$

即 X 与 Y 不相关. 另一方面, 在例 3.3 中我们已经得知 X 与 Y 并非相互独立. ■

下面我们给出两个反例, 提醒读者在处理不相关的随机变量时需小心, 有些对于相互独立随机变量成立的性质不一定能推广到互不相关的随机变量上.

例 4.10. 设 X, Y 相互独立且均服从参数为 $1/2$ 的伯努利分布. 令

$$Z = 1_{\{X \neq Y\}} = \begin{cases} 0, & \text{若 } X = Y, \\ 1, & \text{若 } X \neq Y. \end{cases}$$

显然 X, Y 不相关. 而由

$$\mathbb{E}[Z] = 1 \cdot \mathbb{P}(Z = 1) = \frac{1}{2}$$

以及

$$\mathbb{E}[XZ] = 1 \cdot \mathbb{P}(XZ = 1) = \mathbb{P}(X = 1, Z = 1) = \mathbb{P}(X = 1, Y = 0) = \frac{1}{4}$$

可得 $\mathbb{E}[XZ] = \mathbb{E}[X]\mathbb{E}[Z]$, 故 X, Z 不相关. 同理可得 Y, Z 不相关. 因而 X, Y, Z 这三个随机变量两两互不相关. 但另一方面, 不难看出乘积 XYZ 总是等于 0, 故

$$\mathbb{E}[XYZ] = 0 \neq \mathbb{E}[X]\mathbb{E}[Y]\mathbb{E}[Z].$$

这说明对于三个或三个以上两两互不相关的随机变量, “乘积的期望等于期望的乘积”这一性质一般不再成立. ■

例 4.11. 设 $X \sim \mathcal{N}(0, 1)$, $Y = |X|$. 则

$$\mathbb{E}[XY] = \int_{-\infty}^{+\infty} x|x| \cdot f_X(x) dx = 0,$$

其中我们利用了期望的 LOTUS. 故 $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$, 也就是说 X 与 Y 不相关. 另一方面, 令 $f(x) = |x|, g(y) = y$, 则显然 $f(X) = |X| = Y$ 与 $g(Y) = Y$ 不是互不相关的. 这说明 “互不相关的随机变量各自被函数作用后依然互不相关” 一般是不成立的, 这与随机变量相互独立的情形是不同的. ■

以下定理指出, 两两不相关的随机变量和的方差等于这些随机变量方差的和, 它其实是协方差双线性的直接推论.

定理 4.6. 设随机变量 $X_1, \dots, X_n$ 两两不相关且方差均存在, 则

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

证明. 利用方差与协方差的关系以及协方差的双线性(定理 4.5), 可得

$$\begin{aligned}\operatorname{Var}\left(\sum_{i=1}^n X_i\right) &= \operatorname{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j\right) \\ &= \sum_{i=1}^n \sum_{j=1}^n \operatorname{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \operatorname{Var}(X_i) + \sum_{i \neq j} \operatorname{Cov}(X_i, X_j).\end{aligned}$$

由于 $X_1, \dots, X_n$ 两两不相关, 可知 $i \neq j$ 时交叉项 $\operatorname{Cov}(X_i, X_j)$ 均等于 0, 代入上式即得到待证等式. $\square$

4.2.1 相关系数

现假设 $\operatorname{Var}(X) > 0$ 且 $\operatorname{Var}(Y) > 0$. 由式 (4.6) 以及 $\mathbb{E}[(Y - f^*(X))^2] \geq 0$, 可得

$$|\operatorname{Cov}(X, Y)| \leq \sigma(X) \sigma(Y),$$

其中 $\sigma(X) = \sqrt{\operatorname{Var}(X)}$ 与 $\sigma(Y) = \sqrt{\operatorname{Var}(Y)}$ 分别为 X 与 Y 的标准差. 这提示我们可以对 $\operatorname{Cov}(X, Y)$ 进行归一化来更好地刻画两个随机变量之间的相关性.

定义 4.2. 给定两个随机变量 X, Y , 设 $\operatorname{Var}(X) > 0$, $\operatorname{Var}(Y) > 0$, 且协方差 $\operatorname{Cov}(X, Y)$ 存在. 则其**相关系数** (correlation) 被定义为

$$\frac{\operatorname{Cov}(X, Y)}{\sigma(X) \sigma(Y)}.$$

通常将 X 与 Y 的相关系数记为 ρ_{XY} .

相关系数 ρ_{XY} 的取值范围为 $[-1, 1]$, 且

1. $\rho_{XY} > 0$ 时 X 与 Y 正相关, $\rho_{XY} < 0$ 时 X 与 Y 负相关, $\rho_{XY} = 0$ 时 X 与 Y 不相关.
2. 令 $f^*(X) = \beta X + \alpha$ 为例 4.8 给出的 X 的一次函数中对 Y 的最佳近似. 我们考虑用 $\beta(X - \mathbb{E}[X])$ 近似 $Y - \mathbb{E}[Y]$ 所导致的相对均方误差:

$$\frac{\mathbb{E}[(Y - \mathbb{E}[Y] - \beta(X - \mathbb{E}[X]))^2]}{\operatorname{Var}(Y)} = \frac{\mathbb{E}[(Y - f^*(X))^2]}{\operatorname{Var}(Y)} = 1 - \rho_{XY}^2.$$

因此 $|\rho_{XY}|$ 越接近于 1, 则 $\beta(X - \mathbb{E}[X])$ 近似 $Y - \mathbb{E}[Y]$ 的相对均方误差越小. 换句话说, $|\rho_{XY}|$ 越接近于 1, 则可以认为 $Y - \mathbb{E}[Y]$ 与 $X - \mathbb{E}[X]$ 之间具有越显著的线

性关系. 特别地, $\rho_{XY} = 1$ 当且仅当存在 $c > 0$ 使得 $Y - \mathbb{E}[Y] = c(X - \mathbb{E}[X])$ 几乎必然成立, 而 $\rho_{XY} = -1$ 当且仅当存在 $c < 0$ 使得 $Y - \mathbb{E}[Y] = c(X - \mathbb{E}[X])$ 几乎必然成立.

上述结论中 $\rho_{XY} = \pm 1$ 的充要条件的证明留作习题 4.9.

4.3 矩与矩母函数

我们首先对矩的概念进行简单介绍.

定义 4.3. 设 X 为一随机变量, k 为一正整数. 若 $\mathbb{E}[X^k]$ 存在, 则称其为随机变量 X 的 k 阶矩 (k th moment).

不难看出期望 $\mathbb{E}[X]$ 就是 X 的一阶矩, 而方差则是二阶矩与一阶矩平方之差. 下面的命题则指出, 由高阶矩的存在性可推出低阶矩的存在性.

命题 4.7. 给定 $\alpha > 0$, 若 $\mathbb{E}[X^\alpha]$ 存在, 则对任意的 $\beta \in]0, \alpha[$, $\mathbb{E}[X^\beta]$ 均存在.

证明. 由命题 3.10 第 1 部分可知 $\mathbb{E}[|X^\alpha|]$ 存在. 接下来, 注意到对任意 $t \in \mathbb{R}$ 与 $0 < s \leq 1$ 有 $|t|^s \leq 1 + |t|$, 故

$$|X^\beta| = |X^\alpha|^{\frac{\beta}{\alpha}} \leq 1 + |X^\alpha|,$$

再利用命题 3.10 的第 2 部分以及期望的线性, 可得 $\mathbb{E}[|X^\beta|]$ 存在, 最后由命题 3.10 的第 1 部分得 $\mathbb{E}[X^\beta]$ 存在. $\square$

由命题 4.7 可得到这样一个推论: 若二阶矩 $\mathbb{E}[X^2]$ 存在, 则一阶矩 $\mathbb{E}[X]$ 存在, 故由 $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ 可得, $\text{Var}(X)$ 的存在性等价于 $\mathbb{E}[X^2]$ 的存在性.

下面我们引入矩母函数的概念.

定义 4.4. 设 X 为一随机变量. 若存在包含 0 点的开区间 $I \subseteq \mathbb{R}$, 使得对任意 $t \in I$, 期望 $\mathbb{E}[e^{tX}]$ 均存在, 则称函数

$$M_X(t) = \mathbb{E}[e^{tX}], \quad t \in I$$

为 X 的矩母函数 (moment generating function).

以下定理解释了为何把 $M_X(t) = \mathbb{E}[e^{tX}]$ 称作 X 的“矩母函数”.

定理 4.8. 设 X 的矩母函数 M_X 在 0 的某个开邻域上有定义, 则对任意正整数 k , $\mathbb{E}[X^k]$ 均存在, 且

$$M_X^{(k)}(0) = \mathbb{E}[X^k],$$

其中 $M_X^{(k)}$ 表示 M_X 的 k 阶导数.

证明. 这里只给出 M_X 高阶导数与高阶矩关系的证明, 而高阶矩存在性的证明不做要求 (可参考 [14] 第 21 节 Moment Generating Functions 部分).

设 $M_X(t)$ 在 $-\delta < t < \delta$ 时有定义, 其中 $\delta > 0$. 由指数函数的幂级数展开可得

$$e^{tX} = \sum_{k=0}^{\infty} \frac{X^k}{k!} \cdot t^k,$$

故

$$M_X(t) = \mathbb{E}\left[\sum_{k=0}^{\infty} \frac{X^k}{k!} \cdot t^k\right] = \sum_{k=0}^{\infty} \frac{\mathbb{E}[X^k]}{k!} \cdot t^k, \quad \forall t \in]-\delta, \delta[,$$

推导中我们交换了无穷级数与期望的次序, 其合法性的来由不做要求. 注意到上式最右端给出了一个关于 t 的幂级数, 对其进行逐项求导 (可参考 [9] 第十九章 4.4b 节定理 3) 可得

$$M_X^{(k)}(t) = \sum_{j=k}^{\infty} \frac{\mathbb{E}[X^j]}{(j-k)!} \cdot t^{j-k}, \quad \forall t \in]-\delta, \delta[.$$

故

$$M_X^{(k)}(0) = \mathbb{E}[X^k]. \quad \square$$

接下来我们介绍矩母函数的其它重要性质.

定理 4.9. 设 X 与 Y 的矩母函数在 0 的某个邻域上处处相等, 则 X 与 Y 同分布, 也就是说对任意区间 $I \subseteq \mathbb{R}$, 有 $\mathbb{P}(X \in I) = \mathbb{P}(Y \in I)$.

定理 4.9 说明随机变量的分布可由其矩母函数唯一决定. 该定理的证明不做要求.

定理 4.10. 设随机变量 X 的矩母函数为 M_X , α, β 为任意实数. 则 $Y = \alpha X + \beta$ 的矩母函数为

$$M_Y(t) = e^{\beta t} M_X(\alpha t),$$

其中 t 须使得 $M_X(\alpha t)$ 有定义.

证明. 由简单的计算即可得

$$M_Y(t) = \mathbb{E}[e^{t(\alpha X + \beta)}] = e^{\beta t} \mathbb{E}[e^{(\alpha t)X}] = e^{\beta t} M_X(\alpha t). \quad \square$$

定理 4.11. 设随机变量 X, Y 相互独立, 且二者的矩母函数 M_X 与 M_Y 均存在, 则 $X + Y$ 的矩母函数 M_{X+Y} 为

$$M_{X+Y}(t) = M_X(t) \cdot M_Y(t),$$

其中 t 须使得 $M_X(t)$ 与 $M_Y(t)$ 均有定义.

证明. 由 X 与 Y 相互独立可得 e^X 与 e^Y 相互独立, 故

$$M_{X+Y}(t) = \mathbb{E}[e^{t(X+Y)}] = \mathbb{E}[e^{tX} \cdot e^{tY}] = \mathbb{E}[e^{tX}] \cdot \mathbb{E}[e^{tY}] = M_X(t) \cdot M_Y(t). \quad \square$$

需要注意定理 4.11 当中要求 X 与 Y 相互独立.

将定理 4.9 与 4.11 结合, 可得到求解独立随机变量 X 与 Y 和的分布的另一种方法: 我们先算出 X 与 Y 各自的矩母函数, 再将二者相乘算出 $X + Y$ 的矩母函数 M_{X+Y} , 最后将 M_{X+Y} 与已知的各种分布的矩母函数进行对照, 找到 $X + Y$ 服从的分布. 表 4.1 列出了一些常用概率分布的矩母函数.

例 4.12. 设 X 服从参数为 λ 的泊松分布, 则其矩母函数为

$$\begin{aligned} M_X(t) &= \sum_{k=0}^{\infty} e^{tk} \cdot e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} \\ &= e^{-\lambda} \cdot \exp(\lambda e^t) = \exp(\lambda(e^t - 1)), \end{aligned} \quad (4.7)$$

其中 $t \in \mathbb{R}$. 现设 Y 与 X 独立且服从参数为 μ 的泊松分布, 则 $X + Y$ 的矩母函数为

$$\begin{aligned} M_{X+Y}(t) &= M_X(t) \cdot M_Y(t) = \exp(\lambda(e^t - 1)) \cdot \exp(\mu(e^t - 1)) \\ &= \exp((\lambda + \mu)(e^t - 1)), \quad \forall t \in \mathbb{R}. \end{aligned}$$

将上式与式 (4.7) 比较可得, $X + Y$ 服从参数为 $\lambda + \mu$ 的泊松分布. ■

表 4.1: 一些常用概率分布的矩母函数

X 的分布	参数	分布列/概率密度函数	矩母函数 $M_X(t)$
伯努利分布	p	$p_X(0) = 1 - p, p_X(1) = p$	$1 - p + pe^t$
二项分布	(n, p)	$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}$ ($k = 0, \dots, n$)	$(1 - p + pe^t)^n$
几何分布	p	$p_X(k) = (1-p)^{k-1} p$ ($k = 1, 2, \dots$)	$\frac{pe^t}{1 - (1-p)e^t}$ ($t < -\ln(1-p)$)
负二项分布	(r, p)	$p_X(k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}$ ($k = r, r+1, \dots$)	$\left(\frac{pe^t}{1 - (1-p)e^t} \right)^r$ ($t < -\ln(1-p)$)
泊松分布	λ	$p_X(k) = e^{-\lambda} \lambda^k / k!$ ($k = 0, 1, 2, \dots$)	$\exp(\lambda(e^t - 1))$
均匀分布	$[a, b]$	$f_X(x) = \frac{1}{b-a} \quad (x \in [a, b])$	$\frac{e^{bt} - e^{at}}{(b-a)t}$
指数分布	λ	$f_X(x) = \lambda e^{-\lambda x} \quad (x \geq 0)$	$\frac{1}{1 - \lambda^{-1}t} \quad (t < \lambda)$
正态分布	(μ, σ^2)	$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	$\exp(\mu t + \frac{1}{2}\sigma^2 t^2)$
Gamma 分布	(α, β)	$f_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \quad (x > 0)$	$(1 - \beta^{-1}t)^{-\alpha} \quad (t < \beta)$

例 4.13. 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则其矩母函数为

$$\begin{aligned}
 M_X(t) &= \int_{-\infty}^{+\infty} \exp(tx) \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx \\
 &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} \exp\left(-\frac{x^2 - 2\mu x - 2t\sigma^2 x + \mu^2}{2\sigma^2}\right) dx \\
 &= \exp\left(-\frac{-2\mu t\sigma^2 - t^2\sigma^4}{2\sigma^2}\right) \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} \exp\left(-\frac{(x - \mu - t\sigma^2)^2}{2\sigma^2}\right) dx \\
 &= \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right), \tag{4.8}
 \end{aligned}$$

其中 $t \in \mathbb{R}$.

现设 $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ 且 X_1, X_2 独立, $\alpha_1, \alpha_2, \beta$ 为三个任意的实数.

令 $Y = \alpha_1 X_1 + \alpha_2 X_2 + \beta$, 则 Y 的矩母函数为

$$\begin{aligned} M_Y(t) &= e^{\beta t} M_{\alpha_1 X_1 + \alpha_2 X_2}(t) = e^{\beta t} M_{\alpha_1 X_1}(t) \cdot M_{\alpha_2 X_2}(t) = e^{\beta t} M_{X_1}(\alpha_1 t) \cdot M_{X_2}(\alpha_2 t) \\ &= e^{\beta t} \cdot \exp\left(\mu_1 \alpha_1 t + \frac{1}{2} \sigma_1^2 \alpha_1^2 t^2\right) \cdot \exp\left(\mu_2 \alpha_2 t + \frac{1}{2} \sigma_2^2 \alpha_2^2 t^2\right) \\ &= \exp\left((\alpha_1 \mu_1 + \alpha_2 \mu_2 + \beta)t + \frac{1}{2}(\alpha_1^2 \sigma_1^2 + \alpha_2^2 \sigma_2^2)t^2\right), \quad \forall t \in \mathbb{R}, \end{aligned}$$

其中第一步与第三步用到了定理 4.10. 将上式与式 (4.8) 比较, 可得 $Y \sim \mathcal{N}(\alpha_1 \mu_1 + \alpha_2 \mu_2 + \beta, \alpha_1^2 \sigma_1^2 + \alpha_2^2 \sigma_2^2)$.

类似地, 设 $X_1, \dots, X_n$ 相互独立, 且 X_i 服从正态分布 $\mathcal{N}(\mu_i, \sigma_i^2)$. 令 $\alpha_1, \dots, \alpha_n$ 与 β 为任意实数, 则

$$Y = \sum_{i=1}^n \alpha_i X_i + \beta$$

服从正态分布 $\mathcal{N}(\sum_{i=1}^n \alpha_i \mu_i + \beta, \sum_{i=1}^n \alpha_i^2 \sigma_i^2)$. ■

例 4.14. 设 $N, X_1, X_2, \dots$ 为相互独立的随机变量, N 服从参数为 p 的几何分布 (其中 $0 < p < 1$), 而 $X_1, X_2, \dots$ 服从参数为 λ 的指数分布. 则 $Y = \sum_{i=1}^N X_i$ 服从怎样的分布?

首先考察 X_i 的矩母函数:

$$M_{X_i}(t) = \int_0^{+\infty} e^{tx} \cdot \lambda e^{-\lambda x} dx = \frac{1}{1 - \lambda^{-1}t}, \quad \forall t < \lambda.$$

接下来, 为求出 Y 的分布, 我们从它的矩母函数入手. 注意到

$$\begin{aligned} M_Y(t) &= \mathbb{E}\left[\exp\left(t \cdot \sum_{i=1}^N x_i\right)\right] = \mathbb{E}\left[\exp\left(t \cdot \sum_{i=1}^N x_i\right) \cdot \sum_{n=1}^{\infty} 1_{\{N=n\}}\right] \\ &= \sum_{n=1}^{\infty} \mathbb{E}\left[\exp\left(t \cdot \sum_{i=1}^N x_i\right) \cdot 1_{\{N=n\}}\right] = \sum_{n=1}^{\infty} \mathbb{E}\left[\exp\left(t \cdot \sum_{i=1}^n x_i\right) \cdot 1_{\{N=n\}}\right] \\ &= \sum_{n=1}^{\infty} \mathbb{E}\left[1_{\{N=n\}} \cdot \prod_{i=1}^n e^{tX_i}\right], \end{aligned}$$

再利用 $N, X_1, X_2, \dots$ 的独立性, 并由指数分布的矩母函数, 可得

$$\begin{aligned} M_Y(t) &= \sum_{n=1}^{\infty} \mathbb{P}(N=n) \cdot \prod_{i=1}^n \mathbb{E}[e^{tX_i}] \\ &= \sum_{n=1}^{\infty} (1-p)^{n-1} p \cdot \left(\frac{1}{1 - \lambda^{-1}t}\right)^n = \frac{1}{1 - (p\lambda)^{-1}t}, \end{aligned}$$

其中 $t < p\lambda$. 故可得 Y 服从参数为 $p\lambda$ 的指数分布. ■

4.4 条件分布与条件期望

4.4.1 条件分布

本小节中, 我们介绍一个随机变量 X 在给定另一个随机变量 Y 的取值时的条件分布. 由于数学工具的限制, 我们只讨论 (X, Y) 为离散型随机向量或连续型随机向量的情形.

(X, Y) 为离散型随机向量. 当 (X, Y) 为离散型随机向量时, 条件分布的定义是比较直接的. 设 $y \in \mathbb{R}$ 使得 $\mathbb{P}(Y = y) > 0$, 则定义 $Y = y$ 的条件下 X 的**条件分布列** (conditional probability mass function, conditional p.m.f.) 为

$$p_{X|Y}(x|y) = \mathbb{P}(X = x|Y = y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}, \quad \forall x \in \mathbb{R}.$$

不难证明, 若固定 y 而把 $p_{X|Y}(x|y)$ 看成 x 的函数, 则它的确给出了一个分布列 (也就是说它满足定理 2.2 的条件).

当 $p_Y(y) = 0$ 时, 为了方便, 我们规定 $p_{X|Y}(x|y) = p_X(x)$, 但需注意此时 $p_{X|Y}(x|y)$ 不代表 $\mathbb{P}(X = x|Y = y)$.

以下命题可以看成是全概率公式的一个特例, 也是为了给连续型随机向量的情形做一些准备, 其证明是直接的, 故留给读者自行完成.

命题 4.12. 设 (X, Y) 为离散型随机向量. 则任取区间 $I, J \subseteq \mathbb{R}$, 均有

$$\mathbb{P}(X \in I, Y \in J) = \sum_{y \in J} \left(\sum_{x \in I} p_{X|Y}(x|y) \right) \cdot p_Y(y). \quad (4.9)$$

反之, 若二元实值函数 $q: \mathbb{R}^2 \rightarrow \mathbb{R}$ 使得等式²

$$\mathbb{P}(X \in I, Y \in J) = \sum_{y \in J} \left(\sum_{x \in I} q(x, y) \right) \cdot p_Y(y),$$

对任意区间 $I, J \subseteq \mathbb{R}$ 都成立, 则 $p_Y(y) > 0$ 时均有 $q(x, y) = p_{X|Y}(x|y)$, $\forall x \in \mathbb{R}$.

例 4.15. 设 X, Y 为相互独立的随机变量, 且分别服从参数为 λ_1 与 λ_2 的泊松分布. 令

² 这里为了使求和式 $\sum_{x \in I} q(x, y)$ 有意义, 要求固定 y 时, $q(x, y)$ 只对可数多个 x 取非零值.

$Z = X + Y$. 则对任意正整数 z , $Z = z$ 的条件下 X 的条件分布列为

$$\begin{aligned} p_{X|Z}(x|z) &= \frac{\mathbb{P}(X=x, Z=z)}{\mathbb{P}(Z=z)} = \frac{\mathbb{P}(X=x, Y=z-x)}{\mathbb{P}(Z=z)} \\ &= e^{-\lambda_1} \frac{\lambda_1^x}{x!} \cdot e^{-\lambda_2} \frac{\lambda_2^{z-x}}{(z-x)!} \cdot \left[e^{-(\lambda_1+\lambda_2)} \frac{(\lambda_1+\lambda_2)^z}{z!} \right]^{-1} \\ &= \binom{z}{x} \left(\frac{\lambda_1}{\lambda_1+\lambda_2} \right)^x \left(\frac{\lambda_2}{\lambda_1+\lambda_2} \right)^{z-x}, \quad \forall x=0, \dots, z, \end{aligned}$$

其中我们利用了例 4.12 的结论来计算 $\mathbb{P}(Z=z)$. 而 x 取其它值时有 $p_{X|Z}(x|z) = 0$. 故 $Z=z$ 的条件下 X 服从参数为 $(z, \lambda_1/(\lambda_1+\lambda_2))$ 的二项分布. ■

(X, Y) 为连续型随机向量. 当 (X, Y) 为连续型随机向量时, 定义 $Y=y$ 的条件下 X 的条件分布需要一些额外手段, 这是因为此时 Y 为连续型随机变量, $\mathbb{P}(Y=y)$ 总是为 0, 故而形如 $\mathbb{P}(X \in I | Y=y)$ 的条件概率是没有定义的. 严格处理这个问题需要一些实分析的知识, 超出本课程的范围, 这里给出一种在直观上较易于接受但缺乏一定数学严格性的处理方法: 注意到命题 4.12 意味着我们可以把式 (4.9) 作为条件分布列的第二定义, 故对于连续型随机向量的情形, 不妨考虑在式 (4.9) 中把分布列形式上换成概率密度乘以微元, 把求和形式上换成积分, 再将 $Y=y$ 的条件下 X 的**条件概率密度函数** (conditional probability density function, conditional p.d.f.) $f_{X|Y}(x|y)$ 定义为使得以下等式对任意区间 $I, J \subseteq \mathbb{R}$ 均成立的函数:

$$\mathbb{P}(X \in I, Y \in J) = \int_J \left(\int_I f_{X|Y}(x|y) dx \right) f_Y(y) dy. \quad (4.10)$$

将上式右端的累次积分写成重积分的形式, 再与联合分布密度函数的定义式 (3.3) 进行比较, 即可看出当 $f_Y(y) > 0$ 时, 可将 $f_{X|Y}(x|y)$ 取为

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}. \quad (4.11)$$

许多初等概率论教材也直接将上式作为条件概率密度函数 $f_{X|Y}$ 的定义. 当 $f_Y(y) = 0$ 时, $f_{X|Y}(x|y)$ 的取值对于式 (4.10) 的成立没有影响. 为了方便, 我们规定 $f_Y(y) = 0$ 时 $f_{X|Y}(x|y) = f_X(x)$.

条件概率密度函数也有如下不严格的解释方式: 设 $f_{X,Y}$ 连续, 取非常小的 $\epsilon > 0$,

且假定 $\mathbb{P}(|Y - y| \leq \epsilon) > 0$, 则对任意区间 $I \subseteq \mathbb{R}$, 有

$$\begin{aligned}\mathbb{P}(X \in I | |Y - y| \leq \epsilon) &= \frac{\mathbb{P}(X \in I, |Y - y| \leq \epsilon)}{\mathbb{P}(|Y - y| \leq \epsilon)} \\ &= \frac{\iint_{I \times [y-\epsilon, y+\epsilon]} f_{X,Y}(x, v) dx dv}{\int_{y-\epsilon}^{y+\epsilon} f_Y(v) dv} \\ &= \frac{\int_{y-\epsilon}^{y+\epsilon} \left(\int_I f_{X|Y}(x, v) dx \right) f_Y(v) dv}{\int_{y-\epsilon}^{y+\epsilon} f_Y(v) dv} \\ &\approx \frac{\left(\int_I f_{X|Y}(x, y) dx \right) f_Y(y) \cdot 2\epsilon}{f_Y(y) \cdot 2\epsilon} = \int_I f_{X|Y}(x, y) dx.\end{aligned}$$

换句话说, $f_{X|Y}$ 近似给出了 ϵ 非常小的时候, 在 $y - \epsilon \leq Y \leq y + \epsilon$ 的条件下 X 的条件分布的概率密度函数.

根据以上条件分布列与条件概率密度函数的定义, 不难得到如下定理:

定理 4.13. 1. 设 (X, Y) 为离散型随机向量, 则 X, Y 相互独立的一个充要条件为:

对任意的 $y \in \mathbb{R}$, X 的 (非条件) 分布列 $p_X(x)$ 同时也是给定 $Y = y$ 时 X 的条件分布列 $p_{X|Y}(x|y)$.

2. 设 (X, Y) 为连续型随机向量, 则 X, Y 相互独立的一个充要条件为: 对任意的 $y \in \mathbb{R}$, X 的 (非条件) 概率密度函数 $f_X(x)$ 同时也是给定 $Y = y$ 时 X 的条件概率密度函数 $f_{X|Y}(x|y)$.

值得一提的是, 虽然在前文中我们用 (X, Y) 的联合分布来定义给定 $Y = y$ 的条件下 X 的条件分布, 但在许多实际问题 (特别是涉及到贝叶斯统计推断的问题) 中, 条件分布的建模是更为直接的, 而 (X, Y) 的联合分布以及 X 的边缘分布则是需要计算的对象.

例 4.16. 考虑这样一个随机试验: 首先生成一个服从参数为 λ 的指数分布的随机数 X , 其中 λ 为给定正实数, 而后生成一个以 X 为期望、1 为方差的正态分布的随机数 Y . 对于这个随机试验, 可以直接写下给定 $X = x$ 时 Y 的条件概率密度函数:

$$f_{Y|X}(y|x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y-x)^2}{2}\right), \quad y \in \mathbb{R}.$$

此时 (X, Y) 的联合概率密度函数则为

$$f_{X,Y}(x, y) = f_{Y|X}(y|x)f_X(x) = \begin{cases} \frac{\lambda}{\sqrt{2\pi}} \exp\left(-\lambda x - \frac{(y-x)^2}{2}\right), & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0. \end{cases}$$

而 Y 的边缘概率密度函数则为

$$\begin{aligned} f_Y(y) &= \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx = \int_0^{+\infty} \frac{\lambda}{\sqrt{2\pi}} \exp\left(-\lambda x - \frac{(y-x)^2}{2}\right) dx \\ &= \lambda \exp\left(-\lambda y + \frac{\lambda^2}{2}\right) (1 - \Phi(\lambda - y)), \end{aligned}$$

其中 Φ 为标准正态分布的分布函数. ■

4.4.2 条件期望

定义 4.5. 1. 设 (X, Y) 为离散型随机向量, 且 $\mathbb{E}[X]$ 存在. 若函数 $\phi_X: \mathbb{R} \rightarrow \mathbb{R}$ 满足

$$\phi_X(y) = \sum_x x \cdot p_{X|Y}(x|y), \quad \text{若 } p_Y(y) > 0,$$

则称随机变量 $\phi_X(Y)$ 为给定 Y 的条件下 X 的**条件期望**(conditional expectation).

2. 设 (X, Y) 为连续型随机向量, 且 $\mathbb{E}[X]$ 存在. 若函数 $\phi_X: \mathbb{R} \rightarrow \mathbb{R}$ 满足

$$\phi_X(y) = \int_{-\infty}^{+\infty} x \cdot f_{X|Y}(x|y) dx, \quad \text{若 } f_Y(y) > 0,$$

则称随机变量 $\phi_X(Y)$ 为给定 Y 的条件下 X 的**条件期望**(conditional expectation).

我们把给定 Y 的条件下 X 的条件期望记为 $\mathbb{E}[X|Y]$. 我们也经常将以上定义中出现的函数 $\phi_X(y)$ 记为 $\mathbb{E}[X|Y=y]$.

注 4.1. 定义 4.5 当中并未规定 $\phi_X(y)$ 在 $p_Y(y) = 0$ 或 $f_Y(y) = 0$ 时的取值, 因此给定 Y 的条件下 X 的条件期望不一定是唯一的: 有可能存在两个随机变量 Y 的函数 $\phi_{X,1}(Y)$ 与 $\phi_{X,2}(Y)$ 均满足定义 4.5, 但可以证明, 这种情况下必定有

$$\mathbb{P}(\phi_{X,1}(Y) = \phi_{X,2}(Y)) = 1,$$

也就是说 $\phi_{X,1}(Y) = \phi_{X,2}(Y)$ 几乎必然成立. 换句话说, 条件期望 $\mathbb{E}[X|Y]$ 可以存在不同的版本, 但任意两个版本都是几乎必然相等的. 在随后的部分, 我们将用 $\mathbb{E}[X|Y]$ 指代条件期望的任意一个版本, 而用

$$\mathbb{E}[X|Y] = \phi_X(Y)$$

来表示 $\phi_X(Y)$ 是给定 Y 的条件下 X 条件期望的其中一个版本; 记号 $\mathbb{E}[X|Y=y]$ 同理. ■

注 4.2. 受到数学工具的限制, 定义 4.5 只处理了 (X, Y) 为离散型或连续型随机向量的情形. 但实际上, 只要 $\mathbb{E}[X]$ 存在, 那么对任意随机变量 Y 我们都可以定义其条件期望 $\mathbb{E}[X|Y]$ 及相应的函数 $\phi_X(y) = \mathbb{E}[X|Y=y]$. 特别是, 当 $\mathbb{P}(Y=y) > 0$ 时, 有

$$\phi_X(y) = \mathbb{E}[X|Y=y] = \frac{\mathbb{E}[X \cdot \mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y=y)}.$$

而 $\mathbb{P}(Y=y) = 0$ 时 $\phi_X(y) = \mathbb{E}[X|Y=y]$ 的一般定义则需要用到高等概率论的一些工具, 本讲义将在附录 B 中给出一个简单的介绍作为选读内容. ■

以下定理可看作是条件期望的 law of the unconscious statistician (LOTUS).

定理 4.14. 设 X, Y 为两个随机变量, 二元函数 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[h(X, Y)]$ 存在, 且对任意 $y \in \mathbb{R}$, $\mathbb{E}[h(X, y)]$ 均存在.

1. 若 (X, Y) 为离散型随机向量, 则有

$$\mathbb{E}[h(X, Y)|Y=y] = \sum_x h(x, y) \cdot p_{X|Y}(x|y);$$

2. 若 (X, Y) 为连续型随机向量, 则有

$$\mathbb{E}[h(X, Y)|Y=y] = \int_{-\infty}^{+\infty} h(x, y) \cdot f_{X|Y}(x|y) dx.$$

定理 4.14 的证明不做要求, 感兴趣的读者可参考附录 B.

注 4.3. 一般而言, 条件概率 $\mathbb{P}(E|F)$ 在 $\mathbb{P}(F) = 0$ 时是没有定义的, 这意味着当 Y 为连续型随机变量时, 我们没有办法按照条件概率的一般定义来谈论事件 $\{Y=y\}$ 发生条件下 $\{X \in B\}$ 的条件概率 (其中 y 为一给定实数, X 为一随机变量, B 为一给定集合). 但为了应用上的方便, 我们会按如下方式定义形如 $\mathbb{P}(X \in B|Y=y)$ 的所谓“条件概率”:

$$\mathbb{P}(X \in B|Y=y) = \mathbb{E}[\mathbf{1}_{\{X \in B\}}|Y=y], \quad (4.12)$$

此外, 也会定义随机变量 $\mathbb{P}(X \in B|Y)$ 为如下的条件期望:

$$\mathbb{P}(X \in B|Y) = \mathbb{E}[\mathbf{1}_{\{X \in B\}}|Y].$$

根据定理 4.14 可得, 当 (X, Y) 为连续型随机向量时, 有

$$\mathbb{P}(X \in B|Y=y) = \int_B f_{X|Y}(x|y) dx = \int_B \frac{f_{X,Y}(x, y)}{f_Y(y)} dx, \quad \text{若 } f_Y(y) > 0.$$

需要注意的是, 式 (4.12) 所定义的 $\mathbb{P}(X \in B | Y = y)$ 并不能认为是一个一般意义上的条件概率, 否则会导致 Borel–Kolmogorov 悖论, 我们将在习题 4.20 中对其进行介绍和讨论, 并建议感兴趣的读者进一步查阅该悖论的其它相关资料. ■

以下定理给出了条件期望的几个比较重要的性质.

定理 4.15. 设 X, Y, Z 为随机变量, 且 $\mathbb{E}[X], \mathbb{E}[Y]$ 存在, 则如下命题成立:

1. 线性: 对任意实数 α, β , 均有

$$\mathbb{E}[\alpha X + \beta Y | Z] = \alpha \mathbb{E}[X | Z] + \beta \mathbb{E}[Y | Z].$$

2. 若 $X \geq 0$ 几乎必然成立, 则 $\mathbb{E}[X | Z] \geq 0$ 几乎必然成立.
3. 全期望公式 (law of total expectation):

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X | Z]].$$

特别地, 若 Z 为离散型随机向量, 则

$$\mathbb{E}[X] = \sum_z \mathbb{E}[X | Z = z] \cdot p_Z(z).$$

若 Z 为连续型随机向量, 则

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} \mathbb{E}[X | Z = z] \cdot f_Z(z) \, dz.$$

4. 若函数 $h: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[h(Z)X]$ 存在, 则

$$\mathbb{E}[h(Z)X | Z] = h(Z) \mathbb{E}[X | Z].$$

5. 若 X 与 Z 相互独立, 则

$$\mathbb{E}[X | Z] = \mathbb{E}[X].$$

更一般地, 设二元函数 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[h(X, z)]$ 对任意 $z \in \mathbb{R}$ 均存在, 则 X, Z 独立时有

$$\mathbb{E}[h(X, Z) | Z = z] = \mathbb{E}[h(X, z)].$$

证明. 这里只给出 3、4、5 三条性质的证明, 且只给出 (X, Z) 为离散型或连续型随机向量时的证明, 一般情形的证明超出本课程范围.

3. 若 (X, Z) 为离散型随机向量, 则有

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X|Z]] &= \sum_z \mathbb{E}[X|Z=z] \cdot p_Z(z) \\ &= \sum_z \sum_x x \cdot p_{X|Z}(x|z) \cdot p_Z(z) \\ &= \sum_{(x,z)} x \cdot p_{X,Z}(x,z) = \mathbb{E}[X],\end{aligned}$$

其中第一步来自于期望的 LOTUS, 第二步用了 $\mathbb{E}[X|Z=z]$ 的定义.

若 (X, Z) 为连续型随机向量, 则类似有

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X|Z]] &= \int_{-\infty}^{+\infty} \mathbb{E}[X|Z=z] \cdot f_Z(z) \, dz \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} x \cdot f_{X|Z}(x|z) \, dx \right) f_Z(z) \, dz \\ &= \iint_{\mathbb{R}^2} x \cdot f_{X,Z}(x,z) \, dx \, dz = \mathbb{E}[X].\end{aligned}$$

4. 若 (X, Z) 为离散型随机向量, 则 $p_Z(z) > 0$ 时, 由条件期望的 LOTUS, 有

$$\begin{aligned}\mathbb{E}[h(Z)X|Z=z] &= \sum_x h(z) x \cdot p_{X|Z}(x|z) \\ &= h(z) \cdot \sum_x x \cdot p_{X|Z}(x|z) \\ &= h(z) \cdot \mathbb{E}[X|Z=z].\end{aligned}$$

若 (X, Z) 为连续型随机向量, 则 $f_Z(z) > 0$ 时类似有

$$\begin{aligned}\mathbb{E}[h(Z)X|Z=z] &= \int_{-\infty}^{+\infty} h(z) x \cdot f_{X|Z}(x|z) \, dx \\ &= h(z) \cdot \int_{-\infty}^{+\infty} x \cdot f_{X|Z}(x|z) \, dx \\ &= h(z) \cdot \mathbb{E}[X|Z=z],\end{aligned}$$

故两种情况下均有 $\mathbb{E}[h(Z)X|Z] = h(Z) \cdot \mathbb{E}[X|Z]$.

5. 由条件期望的定义, 若 X, Z 为相互独立的离散型随机变量, 则 $p_Z(z) > 0$ 时, 有

$$\mathbb{E}[X|Z=z] = \sum_x x \cdot p_{X|Z}(x|z) = \sum_x x \cdot p_X(x) = \mathbb{E}[X],$$

而若 X, Z 为相互独立的连续型随机变量, 则 $f_Z(z) > 0$ 时, 有

$$\mathbb{E}[X|Z=z] = \int_{-\infty}^{+\infty} x \cdot f_{X|Z}(x|z) \, dx = \int_{-\infty}^{+\infty} x \cdot f_X(x) \, dx = \mathbb{E}[X],$$

其中我们用到了定理 4.13.

关于 $\mathbb{E}[h(X, Z) | Z = z]$ 的等式的证明则可利用条件期望的 LOTUS (定理 4.14), 例如若 X, Z 为相互独立的连续型随机变量, 则 $f_Z(z) > 0$ 时, 有

$$\begin{aligned}\mathbb{E}[h(X, Z) | Z = z] &= \int_{-\infty}^{+\infty} h(x, z) f_{X|Z}(x|z) dx \\ &= \int_{-\infty}^{+\infty} h(x, z) f_X(x) dx = \mathbb{E}[h(X, z)].\end{aligned}$$

若 X, Z 为相互独立的离散型随机变量, 证明也是类似的, 这里略去. $\square$

利用条件期望的上述性质与计算方法, 我们可以给 $\mathbb{E}[X]$ 的计算提供另一套流程:

1. 选取合适的随机变量 Z , 利用全期望公式将 $\mathbb{E}[X]$ 化为 $\mathbb{E}[\mathbb{E}[X | Z]]$.
2. 利用定理 4.15 的结论, 对 $\mathbb{E}[X | Z]$ 进行化简.
3. 利用条件期望的 LOTUS, 计算化简过后余下的各个条件期望, 并最终算得 $\mathbb{E}[X]$.

例 4.17. 有一枚均匀的立方体骰子, 玩家投掷该骰子并根据投出的点数来决定其得分. 若投出的点数为 1 或 2, 则玩家得到 3 分且游戏结束; 若投出的点数为 3、4 或 5, 则玩家得到 5 分且获得一次额外的投骰子的机会; 若投出的点数为 6, 则玩家得到 7 分并获得一次额外的投骰子的机会. 试问游戏结束时, 玩家获得的总分的期望是多少?

我们将玩家最终得到的分数记为 X , 并令第一次投掷的点数为 Y . 则根据全期望公式, 有

$$\begin{aligned}\mathbb{E}[X] &= \mathbb{E}[\mathbb{E}[X | Y]] = \sum_{i=1}^6 \mathbb{E}[X | Y = i] \mathbb{P}(Y = i) \\ &= \frac{1}{6} \sum_{i=1}^6 \mathbb{E}[X | Y = i].\end{aligned}$$

而直观上, 不难看出如下等式成立³:

$$\mathbb{E}[X | Y = 1] = \mathbb{E}[X | Y = 2] = 3,$$

以及

$$\begin{aligned}\mathbb{E}[X | Y = 3] &= \mathbb{E}[X | Y = 4] = \mathbb{E}[X | Y = 5] = 5 + \mathbb{E}[X], \\ \mathbb{E}[X | Y = 6] &= 7 + \mathbb{E}[X].\end{aligned}$$

³ 要严格证明这些等式实际上并不简单, 感兴趣的读者可尝试严格证明这些等式.

将以上等式代入 $\mathbb{E}[X] = \frac{1}{6} \sum_{i=1}^6 \mathbb{E}[X|Y=i]$, 最终可解得 $\mathbb{E}[X] = 14$. ■

例 4.18. 设 X, Y 为相互独立的连续性随机变量, 各自的概率密度函数为 f_X 与 f_Y , 我们希望求解概率 $\mathbb{P}(X \leq Y)$. 这里给出一种基于条件期望的做法:

$$\begin{aligned}\mathbb{P}(X \leq Y) &= \mathbb{E}[\mathbf{1}_{\{X \leq Y\}}] = \mathbb{E}[\mathbb{E}[\mathbf{1}_{\{X \leq Y\}} | Y]] \\ &= \int_{-\infty}^{+\infty} \mathbb{E}[\mathbf{1}_{\{X \leq Y\}} | Y = y] \cdot f_Y(y) dy \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} \mathbf{1}_{x \leq y}(x, y) \cdot f_{X|Y}(x|y) dx \right) f_Y(y) dy \\ &= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^y f_X(x) dx \right) f_Y(y) dy = \int_{-\infty}^{+\infty} F_X(y) f_Y(y) dy,\end{aligned}$$

其中: 第 2、3 步利用了全期望公式; 第 4 步用条件期望的 LOTUS 对 $\mathbb{E}[\mathbf{1}_{\{X \leq Y\}} | Y = y]$ 做了展开; 我们用 $\mathbf{1}_{x \leq y}$ 简记指示函数 $\mathbf{1}_{\{(x,y) | x \leq y\}}$. ■

例 4.19. 设 $X_1, X_2, \dots, X_n$ 相互独立且服从 $[0, 1]$ 上的均匀分布, 则对任意的 $x \in [0, 1]$, $\mathbb{P}(X_1 + \dots + X_n \leq x)$ 是多少?

此题有多种解法, 这里给出一种基于条件期望的解法. 对任意小于等于 n 的正整数 m , 记 $q_m(x) = \mathbb{P}(X_1 + \dots + X_m \leq x)$, 则显然 $q_1(x) = x$, 而对于 $m > 1$, 我们尝试找到 $q_m(x)$ 与 $q_{m-1}(x)$ 之间的关系:

$$\begin{aligned}q_m(x) &= \mathbb{P}(X_1 + \dots + X_m \leq x) \\ &= \mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_m \leq x\}}] \\ &= \mathbb{E}[\mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_m \leq x\}} | X_m]] ,\end{aligned}$$

其中最后一步用到了全期望公式. 而对于 $\mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_m \leq x\}} | X_m]$, 利用定理 4.15 第 5 部分的结论, 有

$$\begin{aligned}\mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_m \leq x\}} | X_m = x_m] &= \mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_{m-1} + x_m \leq x\}}] \\ &= \begin{cases} q_{m-1}(x - x_m), & \text{若 } x_m \leq x, \\ 0, & \text{若 } x_m > x, \end{cases}\end{aligned}$$

从而 $\mathbb{E}[\mathbf{1}_{\{X_1 + \dots + X_m \leq x\}} | X_m] = \mathbf{1}_{\{X_m \leq x\}} \cdot q_{m-1}(x - X_m)$, 故

$$\begin{aligned}q_m(x) &= \mathbb{E}[\mathbf{1}_{\{X_m \leq x\}} \cdot q_{m-1}(x - X_m)] \\ &= \int_0^x q_{m-1}(x - u) du = \int_0^x q_{m-1}(u) du,\end{aligned}$$

其中在第二步利用连续型随机变量的 LOTUS 时已经考虑到 $x \leq 1$ (否则积分上限需要写为 $\min\{x, 1\}$). 将 $q_1(x) = x$ 代入上式进行递推后不难找到规律, 再利用数学归纳法即可得到

$$\mathbb{P}(X_1 + \cdots + X_n \leq x) = q_n(x) = \frac{x^n}{n!}.$$

(*) 思考: 若不限定 $x \in [0, 1]$, 则如何求解 $\mathbb{P}(X_1 + \cdots + X_n \leq x)$?

(*) 注: 上述解法可以改写为几乎不用概率论语言表述的形式: 同样记 $q_m(x) = \mathbb{P}(X_1 + \cdots + X_m \leq x)$, 考虑到 $x \in [0, 1]$, 故 $q_m(x)$ 就等于 $\mathbb{R}^m$ 中区域

$$\{(x_1, \dots, x_m) \in \mathbb{R}^m \mid x_1 + \cdots + x_m \leq x\}$$

的体积 (这种区域通常被称为单纯形, simplex), 即

$$q_m(x) = \int \cdots \int_{x_1 + \cdots + x_m \leq x} dx_1 \cdots dx_m,$$

上述重积分可以转化为如下累次积分:

$$q_m(x) = \int_0^x dx_m \int_0^{x-x_m} dx_{m-1} \cdots \int_0^{x-x_m-\cdots-x_2} dx_1,$$

而经过观察, 可以发现 $0 \leq x_m \leq x$ 时有

$$\int_0^{x-x_m} dx_{m-1} \cdots \int_0^{x-x_m-\cdots-x_2} dx_1 = q_{m-1}(x - x_m),$$

故

$$q_m(x) = \int_0^x q_{m-1}(x - x_m) dx_m,$$

上式与利用条件期望方法得到的递推式相同. 不过该解法要求对高维欧氏空间中重积分的计算有较为熟练的掌握, 而基于条件期望的解法则为相对抽象的累次积分提供了更加直观的概率意义. ■

4.4.3 条件方差

定义 4.6. 设 X, Y 为随机变量, 且 X 的方差存在. 定义给定 Y 的条件下 X 的**条件方差** (conditional variance) 为

$$\text{Var}(X|Y) = \mathbb{E}[(X - \mathbb{E}[X|Y])^2 | Y].$$

我们也记 $\text{Var}(X|Y = y) = \mathbb{E}[(X - \mathbb{E}[X|Y = y])^2 | Y = y]$.

我们也可从如下角度理解条件方差 $\text{Var}(X|Y)$: 首先对任意实数 y , 算出 X 在给定 $Y = y$ 条件下的条件分布; 接下来计算该条件分布所对应的方差, 这个方差将依赖于 y , 我们将其暂时用 $\psi_X(y)$ 表示; 最后将函数 ψ_X 作用在 Y 上, 得到的随机变量 $\psi_X(y)$ 就是条件方差 $\text{Var}(X|Y)$.

利用条件期望的性质, 可得

$$\begin{aligned}\text{Var}(X|Y) &= \mathbb{E}[X^2 + (\mathbb{E}[X|Y])^2 - 2X \cdot \mathbb{E}[X|Y] | Y] \\ &= \mathbb{E}[X^2 | Y] + \mathbb{E}[(\mathbb{E}[X|Y])^2 | Y] - 2\mathbb{E}[X \cdot \mathbb{E}[X|Y] | Y] \\ &= \mathbb{E}[X^2 | Y] + (\mathbb{E}[X|Y])^2 - 2(\mathbb{E}[X|Y])^2 \\ &= \mathbb{E}[X^2 | Y] - (\mathbb{E}[X|Y])^2,\end{aligned}$$

其中我们充分利用了 $\mathbb{E}[X|Y]$ 是 Y 的函数这一事实.

条件方差满足如下全方差公式 (law of total variance); 其证明是相当直接的, 我们将其留作习题 4.15.

定理 4.16. 设 X, Y 为随机变量, 且 X 的方差存在. 则

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X|Y)] + \text{Var}(\mathbb{E}[X|Y]).$$

例 4.20. 设 $N, X_1, X_2, \dots$ 为相互独立的随机变量, 其中 N 的取值只可能是自然数, $\text{Var}(N)$ 存在; $X_1, X_2, \dots$ 同分布且它们的方差均存在. 令

$$S = \sum_{i=1}^N X_i.$$

我们希望求解 S 的期望与方差.

为了利用全期望公式求出 $\mathbb{E}[S]$, 我们注意到

$$\mathbb{E}[S|N=n] = \mathbb{E}\left[\sum_{i=1}^N X_i \middle| N=n\right] = \mathbb{E}\left[\sum_{i=1}^n X_i\right] = n\mathbb{E}[X_1],$$

其中第二步利用了 $X_1, X_2, \dots$ 与 N 的独立性. 故由全期望公式, 可得

$$\mathbb{E}[S] = \mathbb{E}[N\mathbb{E}[X_1]] = \mathbb{E}[N]\mathbb{E}[X_1]$$

类似地, 为了求 S 的方差, 我们注意到

$$\begin{aligned}
 \text{Var}(S|N=n) &= \text{Var}\left(\sum_{i=1}^N X_i \middle| N=n\right) \\
 &= \mathbb{E}\left[\left(\sum_{i=1}^N X_i\right)^2 \middle| N=n\right] - \left(\mathbb{E}\left[\sum_{i=1}^N X_i \middle| N=n\right]\right)^2 \\
 &= \mathbb{E}\left[\left(\sum_{i=1}^n X_i\right)^2\right] - \left(\mathbb{E}\left[\sum_{i=1}^n X_i\right]\right)^2 \\
 &= \text{Var}\left(\sum_{i=1}^n X_i\right) = n \text{Var}(X_1),
 \end{aligned}$$

其中第三步也是用到了 $X_1, X_2, \dots$ 与 N 的独立性. 故由全期望公式,

$$\begin{aligned}
 \text{Var}(S) &= \mathbb{E}[N \text{Var}(X_1)] + \text{Var}(N \mathbb{E}[X_1]) \\
 &= \mathbb{E}[N] \text{Var}(X_1) + (\mathbb{E}[X_1])^2 \text{Var}(N).
 \end{aligned}$$

■

4.4.4 条件期望与最佳均方预测

考虑这样一个问题: 给定随机变量 X, Y , 我们希望找到一个 Y 的函数, 用于在每次观测到 Y 的取值时对 X 的取值进行预测. 以下定理指出, 在所有的 Y 的函数当中, 条件期望 $\mathbb{E}[X|Y]$ 能够取到最小的均方预测误差. 这是条件期望的又一条重要性质, 我们甚至可以把它作为条件期望的一个新的定义方式.

定理 4.17. 给定随机变量 X 与 Y , 设 $\mathbb{E}[X^2]$ 存在. 则任取函数 $h: \mathbb{R} \rightarrow \mathbb{R}$, 均有

$$\mathbb{E}[(X - \mathbb{E}[X|Y])^2] \leq \mathbb{E}[(X - h(Y))^2].$$

证明. 注意到

$$\begin{aligned}
 \mathbb{E}[(X - h(Y))^2] &= \mathbb{E}[(X - \mathbb{E}[X|Y] + \mathbb{E}[X|Y] - h(Y))^2] \\
 &= \mathbb{E}[(X - \mathbb{E}[X|Y])^2] + \mathbb{E}[(\mathbb{E}[X|Y] - h(Y))^2] \\
 &\quad + 2\mathbb{E}[(X - \mathbb{E}[X|Y])(\mathbb{E}[X|Y] - h(Y))].
 \end{aligned}$$

对于上式右端的交叉项, 我们做如下处理:

$$\begin{aligned}
 & \mathbb{E}[(X - \mathbb{E}[X|Y])(\mathbb{E}[X|Y] - h(Y))] \\
 &= \mathbb{E}[\mathbb{E}[(X - \mathbb{E}[X|Y])(\mathbb{E}[X|Y] - h(Y)) | Y]] \\
 &= \mathbb{E}[(\mathbb{E}[X|Y] - h(Y)) \cdot \mathbb{E}[(X - \mathbb{E}[X|Y]) | Y]] \\
 &= \mathbb{E}[(\mathbb{E}[X|Y] - h(Y)) \cdot (\mathbb{E}[X|Y] - \mathbb{E}[X|Y])] \\
 &= 0,
 \end{aligned}$$

其中第一步用到了全期望公式; 第二步则是因为 $\mathbb{E}[X|Y] - h(Y)$ 是 Y 的函数, 因而可以从条件期望中提出来; 第三步用到了条件期望的线性, 以及 $\mathbb{E}[\mathbb{E}[X|Y]|Y] = \mathbb{E}[X|Y]$. 因此

$$\begin{aligned}
 \mathbb{E}[(X - h(Y))^2] &= \mathbb{E}[(X - \mathbb{E}[X|Y])^2] + \mathbb{E}[(\mathbb{E}[X|Y] - h(Y))^2] \\
 &\geq \mathbb{E}[(X - \mathbb{E}[X|Y])^2].
 \end{aligned}$$

定理得证. □

4.5 (*) 二维正态分布

定义 4.7. 设 $\mathbf{X} = (X_1, X_2)$ 为连续型随机向量. 若存在实向量 $\boldsymbol{\mu} \in \mathbb{R}^2$ 以及实对称正定矩阵 $\boldsymbol{\Sigma} \in \mathbb{R}^{2 \times 2}$, 使得 $\mathbf{X}$ 的联合概率密度函数可表示为

$$f_{\mathbf{X}}(\mathbf{x}) = c \cdot \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right], \quad \forall \mathbf{x} \in \mathbb{R}^2, \quad (4.13)$$

其中 c 为某个正实数, 则称 $\mathbf{X}$ 服从参数为 $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的**正态分布** (normal distribution) 或**高斯分布** (Gaussian distribution), 并记为 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

利用 $\iint_{\mathbb{R}^2} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1$, 可求得式 (4.13) 中的常数 c 为

$$c = \frac{1}{\sqrt{(2\pi)^2 \cdot \det \boldsymbol{\Sigma}}}.$$

我们将具体的计算过程放在了习题 4.25 中.

本节随后的重点是给出二维正态分布的几个核心性质:

1. 正态分布的参数 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 直接给出了期望、方差与协方差信息.
2. 二维正态分布的边缘分布为一维正态分布.

3. 服从二维正态分布的随机向量经过可逆仿射变换后仍服从二维正态分布.

为了一步步推导上述性质, 我们从几个引理入手.

引理 4.18. 设 $\mathbf{X} = (X_1, X_2)$ 服从正态分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$, 则 X_1, X_2 相互独立, 且 X_1, X_2 各自均服从标准正态分布 $\mathcal{N}(0, 1)$.

引理 4.18 的证明思路是非常直接的: 为了证明 X_1, X_2 独立, 只需考察 $f_{\mathbf{X}}(x_1, x_2)$ 是否能写为一个关于 x_1 的函数与一个关于 x_2 的函数的乘积, 而对这两个函数分别归一化即可得到边缘概率密度函数; 我们将具体的证明步骤留给读者自己完成.

引理 4.19. 设 $\boldsymbol{\mu} \in \mathbb{R}^2$, 而 $\boldsymbol{\Sigma} \in \mathbb{R}^{2 \times 2}$ 为实对称正定矩阵, 随机向量 $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. 则存在可逆矩阵 $\mathbf{A} \in \mathbb{R}^{2 \times 2}$ 以及随机向量 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 满足

$$\mathbf{X} = \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}, \quad \mathbf{A}\mathbf{A}^T = \boldsymbol{\Sigma}.$$

证明. 这里给出的证明需要一些线性代数的知识, 对此比较生疏的读者可阅读附录 A.3 进行回顾.

因 $\boldsymbol{\Sigma}$ 为实对称正定矩阵, 故可对其做特征值分解:

$$\boldsymbol{\Sigma} = \mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^T,$$

其中 $\boldsymbol{\Lambda} \in \mathbb{R}^{2 \times 2}$ 为一对角阵, 其对角元 λ_1, λ_2 均大于 0, 而 $\mathbf{Q} \in \mathbb{R}^{2 \times 2}$ 为正交阵, 满足 $\mathbf{Q}^T\mathbf{Q} = \mathbf{Q}\mathbf{Q}^T = \mathbf{I}$. 令

$$\mathbf{A} = \mathbf{Q}\tilde{\boldsymbol{\Lambda}}\mathbf{Q}^T, \quad \text{其中} \quad \tilde{\boldsymbol{\Lambda}} = \begin{bmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \sqrt{\lambda_2} \end{bmatrix},$$

则不难看出 $\mathbf{A}$ 为对称阵, 且由于 $\tilde{\boldsymbol{\Lambda}}$ 的对角元均大于 0, 可知 $\mathbf{A}$ 可逆. 此外,

$$\mathbf{A}^2 = \mathbf{Q}\tilde{\boldsymbol{\Lambda}}\mathbf{Q}^T\mathbf{Q}\tilde{\boldsymbol{\Lambda}}\mathbf{Q}^T = \mathbf{Q}\tilde{\boldsymbol{\Lambda}}^2\mathbf{Q}^T = \mathbf{Q}\boldsymbol{\Lambda}^2\mathbf{Q}^T = \boldsymbol{\Sigma}.$$

接下来, 令

$$\mathbf{Z} = \mathbf{A}^{-1}(\mathbf{X} - \boldsymbol{\mu}),$$

则有 $\mathbf{X} = \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}$, 且由推论 4.4 可得

$$\begin{aligned} f_{\mathbf{Z}}(\mathbf{z}) &= f_{\mathbf{X}}(\mathbf{A}\mathbf{z} + \boldsymbol{\mu}) \cdot |\det \mathbf{A}| \\ &= \frac{1}{\sqrt{(2\pi)^2 \det \boldsymbol{\Sigma}}} \exp\left(-\frac{\mathbf{z}^T \mathbf{A} \boldsymbol{\Sigma}^{-1} \mathbf{A} \mathbf{z}}{2}\right) \cdot \sqrt{\det(\mathbf{A}^2)} \\ &= \frac{\sqrt{\det \boldsymbol{\Sigma}}}{\sqrt{(2\pi)^2 \det \boldsymbol{\Sigma}}} \exp\left(-\frac{\mathbf{z}^T \mathbf{A} (\mathbf{A}^2)^{-1} \mathbf{A} \mathbf{z}}{2}\right) = \frac{1}{\sqrt{(2\pi)^2}} \exp\left(-\frac{\mathbf{z}^T \mathbf{z}}{2}\right), \end{aligned}$$

故 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 引理得证. $\square$

接下来我们即可考察正态分布参数 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$ 的具体意义.

命题 4.20. 设 $\mathbf{X} = (X_1, X_2) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. 则

$$\boldsymbol{\mu} = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{bmatrix}.$$

证明. 先考虑 $\mathbf{X} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 的情况. 由引理 4.18, 可得 X_1, X_2 相互独立, 且每个 X_i 均服从 $\mathcal{N}(0, 1)$. 故

$$\mathbb{E}[X_1] = \mathbb{E}[X_2] = 0, \quad \text{Var}(X_1) = \text{Var}(X_2) = 1,$$

以及

$$\text{Cov}(X_1, X_2) = \text{Cov}(X_2, X_1) = \mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])] = 0,$$

故待证命题对于 $\boldsymbol{\mu} = \mathbf{0}, \boldsymbol{\Sigma} = \mathbf{I}$ 的情形成立.

接下来考虑一般情形. 记

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

由引理 4.19 可得, 存在可逆矩阵 $\mathbf{A} = [a_{ij}] \in \mathbb{R}^{2 \times 2}$ 以及随机向量 $\mathbf{Z} = (Z_1, Z_2) \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 满足 $\mathbf{X} = \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}$ 以及 $\mathbf{A}\mathbf{A}^\top = \boldsymbol{\Sigma}$, 即

$$X_i = \sum_j a_{ij} Z_j + \mu_i, \quad \forall i, \quad \text{以及} \quad \sum_j a_{ij} a_{kj} = \sigma_{ik}, \quad \forall i, k.$$

对 X_i 取期望即得到

$$\mathbb{E}[X_i] = \sum_j a_{ij} \mathbb{E}[Z_j] + \mu_i = \mu_i, \quad i = 1, 2.$$

而 X_i 的方差则为

$$\begin{aligned} \text{Var}(X_i) &= \text{Var}\left(\sum_j a_{ij} Z_j + \mu_i\right) \\ &= \sum_j a_{ij}^2 \text{Var}(Z_j) = \sum_j a_{ij}^2 = \sigma_{ii}, \quad i = 1, 2, \end{aligned}$$

其中我们利用了定理 4.6 以及式 (2.6). X_1 与 X_2 的协方差则为

$$\begin{aligned}\text{Cov}(X_1, X_2) &= \mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])] \\ &= \mathbb{E}\left[\left(\sum_j a_{1j}Z_j\right)\left(\sum_k a_{2k}Z_k\right)\right] \\ &= \sum_{j,k} a_{1j}a_{2k} \mathbb{E}[Z_jZ_k] = \sum_j a_{1j}a_{2j} = \sigma_{12}.\end{aligned}$$

证毕. □

在搞清了二维正态分布参数的意义后, 我们可以将二维正态分布的密度函数写成另外一种形式: 设 $\mathbf{X} = (X_1, X_2)$ 服从二维正态分布, 令 $\mu_i = \mathbb{E}[X_i]$, $\sigma_i = \sqrt{\text{Var}(X_i)}$, ρ 为 X_1, X_2 的相关系数, 则由

$$\begin{aligned}\begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{bmatrix}^{-1} &= \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}^{-1} \\ &= \frac{1}{1-\rho^2} \begin{bmatrix} \sigma_1^{-2} & -\rho(\sigma_1\sigma_2)^{-1} \\ -\rho(\sigma_1\sigma_2)^{-1} & \sigma_2^{-2} \end{bmatrix},\end{aligned}$$

可得

$$f_{\mathbf{X}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x_1-\mu_1}{\sigma_1} \right)^2 - 2\rho \frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{x_2-\mu_2}{\sigma_2} \right)^2 \right] \right\}.$$

下面我们考虑二维正态分布的边缘分布.

定理 4.21. 设 $\mathbf{X} = (X_1, X_2)$ 服从二维正态分布, 则 X_1 与 X_2 各自均服从一维正态分布.

证明. 为了证明上的简洁, 不妨设 $(X_1, X_2) \sim \mathcal{N}(\mathbf{0}, \Sigma)$, 其中 Σ 正定; 一般情形的证明方法是类似的.

记 $\Xi = [\xi_{ij}] = \Sigma^{-1}$, 则 Ξ 也是正定矩阵, 其对角元 ξ_{22} 大于 0. 将 $\mathbf{x}^T \Xi \mathbf{x}$ 展开:

$$\begin{aligned}\mathbf{x}^T \Xi \mathbf{x} &= \xi_{11}x_1^2 + \xi_{22}x_2^2 + 2\xi_{12}x_1x_2 \\ &= \left(\xi_{11} - \frac{\xi_{12}^2}{\xi_{22}} \right) x_1^2 + \xi_{22} \left(x_2 + \frac{\xi_{12}}{\xi_{22}}x_1 \right)^2,\end{aligned}\tag{4.14}$$

其中我们对 $\xi_{22}x_2^2 + 2\xi_{12}x_1x_2$ 做了配方. 由此得 $f_{\mathbf{X}}(\mathbf{x})$ 可表示为

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^2 \det \Sigma}} \exp \left[-\frac{1}{2} \left(\xi_{11} - \frac{\xi_{12}^2}{\xi_{22}} \right) x_1^2 \right] \cdot \exp \left[-\frac{1}{2} \xi_{22} \left(x_2 + \frac{\xi_{12}}{\xi_{22}} x_1 \right)^2 \right].$$

将上式对 x_2 在实数轴上求积分, 即得到

$$f_{X_1}(x_1) = \exp \left[-\frac{1}{2} \left(\xi_{11} - \frac{\xi_{12}^2}{\xi_{22}} \right) x_1^2 \right] \cdot \int_{-\infty}^{+\infty} \frac{\exp \left[-\frac{1}{2} \xi_{22} \left(x_2 + \frac{\xi_{12}}{\xi_{22}} x_1 \right)^2 \right]}{\sqrt{(2\pi)^2 \det \Sigma}} dx_2.$$

对上式右端的积分做换元 $y = x_2 + \xi_{12}x_1/\xi_{22}$ 后, 不难看出该积分为一个与 x_1 无关的常数, 将这个常数暂记为 c , 则有

$$f_{X_1}(x_1) = c \cdot \exp \left[-\frac{1}{2} \left(\xi_{11} - \frac{\xi_{12}^2}{\xi_{22}} \right) x_1^2 \right].$$

而由式 (4.14) 可看出 $\xi_{11} - \xi_{12}^2/\xi_{22} > 0$: 否则可以令 $x_1 \neq 0$ 以及 $x_2 = -\xi_{12}x_1/\xi_{22}$, 则此时 $\mathbf{x} = (x_1, x_2)$ 非零且满足 $\mathbf{x}^T \Xi \mathbf{x} \leq 0$, 与 Ξ 是正定矩阵相矛盾. 再结合上式给出的 f_{X_1} 的表达式, 即可看出 X_1 服从某个一维正态分布. 同理可得 X_2 服从某个一维正态分布. $\square$

接下来, 我们证明正态分布的随机变量经过可逆的仿射变换后依然服从正态分布.

定理 4.22. 设 $\mathbf{X} = (X_1, X_2) \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$, $\mathbf{M} \in \mathbb{R}^{2 \times 2}$ 为一可逆矩阵, $\boldsymbol{\eta} \in \mathbb{R}^2$, 则随机向量

$$\mathbf{Y} = \mathbf{M}\mathbf{X} + \boldsymbol{\eta}$$

服从正态分布 $\mathcal{N}(\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}, \mathbf{M}\Sigma\mathbf{M}^T)$.

证明. 由引理 4.19 可知, 存在可逆矩阵 $\mathbf{A} \in \mathbb{R}^{2 \times 2}$ 以及随机向量 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 满足 $\mathbf{X} = \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}$ 以及 $\mathbf{A}\mathbf{A}^T = \Sigma$, 从而有

$$\mathbf{Y} = \mathbf{M}\mathbf{A}\mathbf{Z} + (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}) = \mathbf{B}\mathbf{Z} + (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}),$$

其中我们记 $\mathbf{B} = \mathbf{M}\mathbf{A}$. 由于 $\mathbf{M}$ 与 $\mathbf{A}$ 均为可逆矩阵, 因此 $\mathbf{B}$ 也可逆. 此外,

$$\mathbf{B}\mathbf{B}^T = \mathbf{M}\mathbf{A}\mathbf{A}^T\mathbf{M}^T = \mathbf{M}\Sigma\mathbf{M}^T.$$

接下来即可利用推论 4.4 得到

$$\begin{aligned}
 f_Y(\mathbf{y}) &= f_Z(\mathbf{B}^{-1}(\mathbf{y} - (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}))) \cdot \frac{1}{|\det \mathbf{B}|} \\
 &= \frac{1}{\sqrt{(2\pi)^2}} \exp\left(-\frac{(\mathbf{y} - (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}))^\top (\mathbf{B}^\top)^{-1} \mathbf{B}^{-1}(\mathbf{y} - (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}))}{2}\right) \cdot \frac{1}{\sqrt{\det(\mathbf{B}\mathbf{B}^\top)}} \\
 &= \frac{1}{\sqrt{(2\pi)^2 \det(\mathbf{M}\boldsymbol{\Sigma}\mathbf{M})}} \exp\left(-\frac{(\mathbf{y} - (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}))^\top (\mathbf{M}\boldsymbol{\Sigma}\mathbf{M}^\top)^{-1} (\mathbf{y} - (\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}))}{2}\right),
 \end{aligned}$$

故 $\mathbf{Y} \sim \mathcal{N}(\mathbf{M}\boldsymbol{\mu} + \boldsymbol{\eta}, \mathbf{M}\boldsymbol{\Sigma}\mathbf{M}^\top)$. □

由定理 4.21 与 4.22, 还可得到如下推论:

推论 4.23. 设 $\mathbf{X} = (X_1, X_2) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\alpha} = (\alpha_1, \alpha_2) \in \mathbb{R}^2$ 为非零向量, $\beta \in \mathbb{R}$ 为一实数. 令

$$Y = \boldsymbol{\alpha}^\top \mathbf{X} + \beta = \sum_j \alpha_j X_j + \beta,$$

则 $Y \sim \mathcal{N}(\boldsymbol{\alpha}^\top \boldsymbol{\mu} + \beta, \boldsymbol{\alpha}^\top \boldsymbol{\Sigma} \boldsymbol{\alpha})$.

证明. 由于 $\boldsymbol{\alpha}$ 非零, 故可以找到一个非零向量 $\boldsymbol{\alpha}' = (\alpha'_1, \alpha'_2)$ 使得 $\boldsymbol{\alpha}$ 与 $\boldsymbol{\alpha}'$ 线性无关. 令

$$\mathbf{M} = \begin{bmatrix} \alpha_1 & \alpha_2 \\ \alpha'_1 & \alpha'_2 \end{bmatrix}, \quad \boldsymbol{\eta} = \begin{bmatrix} \beta \\ 0 \end{bmatrix},$$

并令 $\mathbf{Z} = \mathbf{M}\mathbf{X} + \boldsymbol{\eta}$, 则 Y 就是随机向量 $\mathbf{Z}$ 的第一个分量. 由定理 4.22 可知 $\mathbf{Z}$ 服从二维正态分布, 再由定理 4.21 可得 Y 服从一维正态分布, 该正态分布的参数可通过计算 Y 的期望与方差直接得到, 具体的计算过程交给读者完成. □

4.6 习题

习题 4.1 (柯西分布). 设随机变量 X 服从 $]-\pi/2, \pi/2[$ 上的均匀分布, 令 $Y = \tan X$.

1. 证明 Y 为连续型随机变量, 并求其概率密度函数.

注: 我们称 Y 服从的分布为**标准柯西分布** (standard Cauchy distribution).

2. 判断 Y 的期望是否存在, 并给出依据.

习题 4.2. 设 X 为一随机变量, 其分布函数为 $F(x) = \mathbb{P}(X \leq x)$, $x \in \mathbb{R}$. 进一步设 F 满足如下条件:

1. F 在 $\mathbb{R}$ 上为连续函数;
2. 存在一开区间 I , 使得 F 在 I 上严格单调递增, 且有 $\{F(x) \mid x \in I\} =]0, 1[$.

证明: 随机变量 $F(X)$ 服从 $]0, 1[$ 上的均匀分布.

提示 令 $F|_I : I \rightarrow]0, 1[$ 为将 F 的定义域限制在 I 上以后得到的函数. 根据题设条件与连续函数的介值定理, 可知 $F|_I$ 存在 $]0, 1[\rightarrow I$ 的反函数, 且该反函数严格单调递增.

习题 4.3. 设 X, Y 相互独立, 且 X 服从参数为 (s, λ) 的 Gamma 分布, Y 服从参数为 (t, λ) 的 Gamma 分布. 证明 $X + Y$ 服从参数为 $(s + t, \lambda)$ 的 Gamma 分布.

注: Gamma 分布的定义由例 4.6 当中的式 (4.1) 给出.

习题 4.4. 设随机变量 $T_1, T_2, \dots$ 相互独立且服从参数为 λ 的指数分布. 令

$$N = \max\{k \in \mathbb{N}_+ \mid T_1 + \dots + T_k \leq t\}.$$

证明 N 服从参数为 λt 的泊松分布.

提示 利用 $\{N \geq k\} = \{T_1 + \dots + T_k \leq t\}$ 计算 $\mathbb{P}(N \geq k)$, 而后用分部积分处理得到的定积分式.

习题 4.5. 设一个银行有 m 个窗口, 每个窗口为单个顾客办理业务的时间服从参数为 λ 的指数分布, 来到银行的顾客需要先叫号并排成一队, 当某个窗口空出来时, 排在队首的顾客将到该窗口办理业务. 某一天你来到该银行办理业务, 发现前面共有 n 个人正在排队或正在窗口 (其中 $n \geq m$), 令 T 表示你的排队时间, 试求 T 的分布.

提示 令 $N_i(t)$ 表示 t 时刻第 i 个窗口已接待 (包括正在接待) 的人数, 利用习题 4.4 的结论求出 $N_i(t)$ 的分布, 并说明 $N_1(t), \dots, N_m(t)$ 相互独立 (不要求严格证明), 再利用 $\mathbb{P}(T > t) = \mathbb{P}(N_1(t) + \dots + N_m(t) \leq n)$.

习题 4.6. 设 X, Y 为相互独立的连续型随机变量, 概率密度函数分别为 f_X, f_Y .

1. 证明随机变量 XY 为连续型随机变量, 且概率密度函数为

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f_X(x) f_Y\left(\frac{z}{x}\right) dx, \quad z \in \mathbb{R}$$

2. 设 $0 \notin \text{Im } X$. 证明 Y/X 为连续型随机变量, 且概率密度函数为

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} |x| f_X(x) f_Y(zx) dx, \quad z \in \mathbb{R}.$$

习题 4.7. 令 $X_1, \dots, X_n$ 为独立同分布的随机变量且服从 $]0, 1[$ 上的均匀分布, 其中 $n \geq 2$. 记

$$X_{(1)} = \min\{X_1, \dots, X_n\}, \quad X_{(n)} = \max\{X_1, \dots, X_n\}.$$

1. 证明 $(X_{(1)}, X_{(n)})$ 为二维连续型随机向量, 并求出它的联合概率密度函数.

提示 先求出 $\mathbb{P}(X_{(1)} > u, X_{(n)} \leq v), (u, v) \in \mathbb{R}^2$.

2. 求 $X_{(n)} - X_{(1)}$ 服从的概率分布.

习题 4.8. 由例 4.9 可知, 给定两个随机变量 X, Y , 由 $\text{Cov}(X, Y) = 0$ 无法推出 X 与 Y 相互独立. 但若对所有的有界函数 $g, h: \mathbb{R} \rightarrow \mathbb{R}$ 均有 $\text{Cov}(g(X), h(Y)) = 0$, 则 X, Y 是否相互独立? 若是请给出证明, 若不是请给出反例.

习题 4.9. 设 X, Y 为随机变量且 $\text{Var}(X) > 0, \text{Var}(Y) > 0$, X 与 Y 的相关系数记为 ρ_{XY} . 证明

1. $\rho_{XY} = 1$ 当且仅当存在 $c > 0$ 使得 $Y - \mathbb{E}[Y] = c(X - \mathbb{E}[X])$ 几乎必然成立.
2. $\rho_{XY} = -1$ 当且仅当存在 $c < 0$ 使得 $Y - \mathbb{E}[Y] = c(X - \mathbb{E}[X])$ 几乎必然成立.

习题 4.10. 设 $X_1, \dots, X_n$ 为独立同分布的随机变量, 且期望 $\mathbb{E}[X_1]$ 与方差 $\text{Var}(X_1)$ 均存在. 令 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$. 证明对任意 $j = 1, \dots, n$, $X_j - \bar{X}$ 与 $\bar{X}$ 不相关.

习题 4.11 (Chebyshev's association inequality). 设 X 为一随机变量, $f, g: \mathbb{R} \rightarrow \mathbb{R}$ 均为单调不减的函数, 协方差 $\text{Cov}(f(X), g(X))$ 存在.

1. 证明: 对任意 $x, y \in \mathbb{R}$, 均有 $(f(x) - f(y))(g(x) - g(y)) \geq 0$.
2. 令 X_1, X_2 为相互独立且与 X 同分布的随机变量. 证明

$$\mathbb{E}[(f(X_1) - f(X_2))(g(X_1) - g(X_2))] = 2 \text{Cov}(f(X), g(X)).$$

3. 证明 $\text{Cov}(f(X), g(X)) \geq 0$.

习题 4.12 (贝叶斯公式). 1. 设 (X, Y) 为离散型随机向量. 证明 $p_X(x) > 0$ 时有

$$p_{Y|X}(y|x) = \frac{p_{X|Y}(x|y) p_Y(y)}{\sum_{y'} p_{X|Y}(x|y') p_Y(y')}.$$

2. 设 (X, Y) 为连续型随机向量. 证明 $f_X(x) > 0$ 时有

$$f_{Y|X}(y|x) = \frac{f_{X|Y}(x|y) f_Y(y)}{\int_{-\infty}^{+\infty} f_{X|Y}(x|y') f_Y(y') dy'}.$$

习题 4.13. 设 (X, Y) 为连续型随机向量, 且对任意 $(x, y) \in \mathbb{R}^2$ 均有 $f_{Y|X}(y|x) > 0$ 及 $f_{X|Y}(x|y) > 0$.

1. 证明

$$f_X(x) = \left(\int_{-\infty}^{+\infty} \frac{f_{Y|X}(y|x)}{f_{X|Y}(x|y)} dy \right)^{-1}, \quad \forall x \in \mathbb{R},$$

2. 对任意 $(x, y) \in \mathbb{R}^2$, 试用 $f_{X|Y}(x|y)$ 与 $f_{Y|X}(y|x)$ 表示 $f_{X,Y}(x, y)$.

习题 4.14. 设 X, Y 为随机变量, 且 $\mathbb{E}[X]$ 存在. 证明 $\mathbb{E}[X|Y]$ 与 $X - \mathbb{E}[X|Y]$ 不相关.

习题 4.15. 给定随机变量 X 与 Y , 设 X 的方差存在. 证明

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X|Y)] + \text{Var}(\mathbb{E}[X|Y]).$$

习题 4.16 (无记忆性的条件期望版本). 设 A 为一概率大于 0 的事件, X 为一随机变量, 且 $\mathbb{E}[X]$ 存在. 定义 A 发生的条件下 X 的条件期望为

$$\mathbb{E}[X|A] = \frac{\mathbb{E}[X \cdot \mathbf{1}_A]}{\mathbb{P}(A)}.$$

由注 4.2 可知, 若令 $\phi_X(y) = \mathbb{E}[X|\mathbf{1}_A = y]$, 则有 $\mathbb{E}[X|A] = \phi_X(1)$.

1. 设 T 服从参数为 p 的几何分布, 函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[g(T)]$ 存在. 令 n 为任意自然数, 试利用几何分布的无记忆性, 证明

$$\mathbb{E}[g(T)|T > n] = \mathbb{E}[g(T+n)].$$

应如何直观地理解这个等式?

2. 利用第 1 小题的结论, 我们可以给出另一种几何分布期望的计算方法: 设 T 服从参数为 p 的几何分布, 首先证明

$$\mathbb{E}[T] = \mathbb{E}[T|T=1] \cdot \mathbb{P}(T=1) + \mathbb{E}[T|T>1] \cdot \mathbb{P}(T>1),$$

再基于上式推得

$$\mathbb{E}[T] = 1 \cdot p + (1 + \mathbb{E}[T])(1-p),$$

最后求解上述方程得到 $\mathbb{E}[T]$. 试写出该求解方法的完整步骤.

3. 试利用上一小题的方法, 计算参数为 p 的几何分布的方差.

4. (*) 设 T 服从参数为 λ 的指数分布, 函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[g(T)]$ 存在. 令 τ 为任意正实数, 试利用指数分布的无记忆性, 证明

$$\mathbb{E}[g(T)|T > \tau] = \mathbb{E}[g(T + \tau)].$$

习题 4.17. 假设有一名工程师需要每天到机房进行设备维护. 取上午 9 点为 0 时刻, 该工程师到达机房的时刻 Y 是随机的, 且服从 $]0, 3[$ 上的均匀分布. 他维护设备需要花费的时间 T 也是随机的, 且在 $Y = y$ 的条件下服从参数为 $\lambda(y) = 1/(4 - y)$ 的指数分布. 工程师完成设备维护后就离开机房.

1. 试求维护设备花费时间 T 的期望与方差.
2. 试求工程师离开机房的时刻的期望.
3. 现假设工程师的一名同事每天需要去机房做实验, 同事每天到达机房的时刻服从 $]0, 8[$ 上的均匀分布. 若同事到达机房时工程师仍在进行设备维护, 则工程师需要暂停他的维护工作, 等同事完成实验, 再继续维护工作. 设同事的实验所耗费的时间服从 $]0, 1[$ 上的均匀分布, 且不影响工程师维护设备总共花费的时间. 试求该情形下工程师离开机房的时刻的期望.

注: 本题改编自 [6] 第四章习题 24.

习题 4.18. 假设有一根长度为 1 的直杆, 我们用如下三种方式将这跟直杆切成三段:

1. 在直杆上均匀且独立地随机取两点, 将杆在这两点处切为三段.
2. 在直杆上均匀地随机选取一个点切成两段, 再在两段中较长的那一段上均匀地随机取一个点切开.
3. 在直杆上均匀地随机选取一个点切成两段, 再在两段中等概率地随机挑一段并将其等分.

试求上述三种情形下, 切出来的三段能够构成一个三角形的概率.

习题 4.19. 设连续型随机变量 X_1, X_2 相互独立, 且均服从标准正态分布 $\mathcal{N}(0, 1)$, 即

$$f_{X_1}(x) = f_{X_2}(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

1. 任取 $z \in \mathbb{R}$, 试求随机变量

$$Y_z = \frac{1}{\sqrt{1+z^2}} X_1 + \frac{z}{\sqrt{1+z^2}} X_2$$

的概率分布.

2. 设 Z 为一离散型随机变量, 且 X_1, X_2, Z 相互独立. 试求随机变量

$$Y = \frac{1}{\sqrt{1+Z^2}}X_1 + \frac{Z}{\sqrt{1+Z^2}}X_2$$


的概率分布.

3. 设 Z 为连续型随机变量, 且 X_1, X_2, Z 相互独立, 试求随机变量


$$Y = \frac{1}{\sqrt{1+Z^2}}X_1 + \frac{Z}{\sqrt{1+Z^2}}X_2$$

的概率分布.

提示 考虑 $F_Y(y) = \mathbb{P}(Y \leq y)$ 并利用全期望公式 $\mathbb{P}(Y \leq y) = \mathbb{E}[\mathbb{E}[1_{\{Y \leq y\}} | Z]]$.



(a) Φ 与 Θ 的定义. 可以把 Φ 与 Θ 看作以 xy 平面为赤道面时, 点 (X, Y, Z) 在球面上的经度与纬度.



(b) Ξ 与 Ψ 的定义. 可以把 Ψ 与 Ξ 看作以 xz 平面为赤道面时, 点 (X, Y, Z) 在球面上的经度与纬度.

图 4.1: 习题 4.20 图示.

习题 4.20 (Borel–Kolmogorov 悖论). 记 $S^2 := \{(x, y, z) \in \mathbb{R}^3 \mid x^2 + y^2 + z^2 = 1\}$ 为 $\mathbb{R}^3$ 中球心位于原点的单位球面. 设 3 维随机向量 (X, Y, Z) 满足 $(X, Y, Z) \in S^2$, 且对单位球面上任意面积可求的区域 $B \subset S^2$, 有

$$\mathbb{P}((X, Y, Z) \in B) = \frac{1}{4\pi} \iint_B dA,$$

其中 dA 表示单位球面 S^2 上的面元; 换句话说, (X, Y, Z) 服从单位球面上的均匀分布.

1. 令随机变量 Φ 与 Θ 表示图 4.1a 所定义的角度, 其中 $-\pi < \Phi \leq \pi$, $-\pi/2 \leq \Theta \leq \pi/2$, 且规定 $X = Y = 0$ 时 $\Phi = 0$. 证明 (Φ, Θ) 为连续型随机向量, 且它的联合概率密度函数为

$$f_{\Phi, \Theta}(\varphi, \theta) = \begin{cases} \frac{1}{4\pi} \cos \theta, & \text{若 } -\pi < \varphi \leq \pi, |\theta| \leq \frac{\pi}{2}, \\ 0, & \text{其他情况.} \end{cases}$$

2. 现令随机变量 Ξ 与 Ψ 表示图 4.1b 所定义的角度, 其中 $-\pi/2 \leq \Xi \leq \pi/2$, $-\pi < \Psi \leq \pi$, 且规定 $X = Z = 0$ 时 $\Psi = 0$. 证明 (Ξ, Ψ) 的联合概率密度函数为

$$f_{\Xi, \Psi}(\xi, \psi) = \begin{cases} \frac{1}{4\pi} \cos \xi, & \text{若 } |\xi| \leq \frac{\pi}{2}, -\pi < \psi \leq \pi, \\ 0, & \text{其他情况.} \end{cases}$$

3. 由前两小题给出的联合概率密度, 计算条件概率密度 $f_{\Phi|\Theta}(\varphi|\theta)$ 以及 $f_{\Xi|\Psi}(\xi|\psi)$.
4. 证明: 对任意区间 $I \subseteq [-\frac{\pi}{2}, \frac{\pi}{2}]$, 均有

$$\{\Phi \in I, \Theta = 0\} = \{\Xi \in I, \Psi = 0\},$$

但等式

$$\int_I f_{\Phi|\Theta}(\varphi|0) d\varphi = \int_I f_{\Xi|\Psi}(\xi|0) d\xi$$

一般不成立.

习题 4.21 (Rejection sampling). 设非负函数 $f, g: \mathbb{R} \rightarrow [0, +\infty[$ 与常数 c 满足

- $\int_{-\infty}^{+\infty} f(x) dx = \int_{-\infty}^{+\infty} g(x) dx = 1;$
- $g(x) > 0, \forall x \in \mathbb{R};$
- $\frac{f(x)}{g(x)} \leq c, \forall x \in \mathbb{R}.$

现令 $U_1, Y_1, U_2, Y_2, \dots$ 为相互独立的连续型随机变量, 且每个 U_n 服从 $[0, 1]$ 上的均匀分布, 每个 Y_n 的概率密度函数均为 g , 再令

$$X = Y_N, \quad \text{其中 } N = \min \left\{ n \mid U_n \leq \frac{f(Y_n)}{c \cdot g(Y_n)} \right\}.$$

1. 证明 X 的分布函数为

$$F_X(x) = \mathbb{P} \left(Y_1 \leq x \mid U_1 \leq \frac{f(Y_1)}{c \cdot g(Y_1)} \right).$$

2. 证明

$$\mathbb{P}\left(U_1 \leq \frac{f(Y_1)}{c \cdot g(Y_1)}\right) = \frac{1}{c}.$$

3. 证明

$$\mathbb{P}\left(Y_1 \leq x, U_1 \leq \frac{f(Y_1)}{c \cdot g(Y_1)}\right) = \frac{1}{c} \int_{-\infty}^x f(t) dt,$$

从而 X 的概率密度函数为 f .

4. 设有两个随机数生成器, 一个生成的随机数服从 $[0, 1]$ 上的均匀分布, 另一个生成的随机数具有概率密度函数 g . 说明如何用这两个随机数生成器生成一个概率密度函数为 f 的随机数.

习题 4.22. 设 $f: \{1, 2, \dots, n\} \rightarrow \mathbb{R}$ 为一函数, 且 $x \neq y$ 时 $f(x) \neq f(y)$. 假设我们并不知道 f 在每个点的取值, 但有一个黑箱, 当我们把 $x \in \{1, \dots, n\}$ 输入这个黑箱后, 这个黑箱会输出集合 $S_x = \{y \in \{1, \dots, n\} \mid f(y) > f(x)\}$. 为了利用这个黑箱找出使得 $f(x)$ 取得最大值的 x , 我们考虑如下算法:

1. 从 $\{1, \dots, n\}$ 中等概率地随机选一个点作为 X_0 , 并利用黑箱得到集合 S_{X_0} ;
2. 若 $S_{X_0} = \emptyset$ 则输出 X_0 , 算法结束; 否则执行接下来的步骤;
3. 令 $k \leftarrow 0$;
4. **repeat**
5. $k \leftarrow k + 1$;
6. 从 $S_{X_{k-1}}$ 中等概率地随机选择一个点作为 X_k ;
7. 利用黑箱得到集合 S_{X_k} ;
8. **until** $S_{X_k} = \emptyset$
9. 输出 X_k .

不难看出上述算法最终的输出结果的确能使得 f 取到最大值. 现令随机变量 R 表示整个算法从开始到结束的过程中调用黑箱的总次数, 试求 $\mathbb{E}[R]$, 并给出 n 非常大时 $\mathbb{E}[R]$ 的一个近似表达式.

提示 不妨设 $f(1) > f(2) > \dots > f(n)$. 记 $c_k = \mathbb{E}[R \mid X_0 = k]$, $k = 1, \dots, n$. 试用 $c_1, \dots, c_{k-1}$ 表示出 c_k . 算出 c_k 的头几项以后, 将它们的值与序列 $\sum_{i=1}^k i^{-1}$, $k = 1, 2, \dots$ 相比较.

注: 本题改编自 [8] 第 3.11 节习题 33.

习题 4.23. (*) 设 a, b 为给定正实数, 随机变量 X, Y 相互独立, 且 X 服从参数为 $(a, 1)$ 的 Gamma 分布, Y 服从参数为 $(b, 1)$ 的 Gamma 分布. 令 $U = X + Y, V = X/(X + Y)$.

1. 证明 U 与 V 相互独立, 并求出它们各自的分布.

2. 证明

$$\mathbb{E}\left[\frac{X}{X+Y}\right] = \frac{\mathbb{E}[X]}{\mathbb{E}[X] + \mathbb{E}[Y]}.$$

习题 4.24. (*) 设 X, Y 相互独立且均服从正态分布 $\mathcal{N}(0, 1)$, 令

$$U = X^2 + Y^2, \quad V = \text{atan2}(Y, X)$$

(其中 $\text{atan2}(y, x) \in [0, 2\pi[$ 表示坐标平面上从原点指向 (x, y) 的射线与 x 轴正方向之间的夹角, $x = y = 0$ 时取 $\text{atan2}(y, x) = 0$). 证明 U, V 相互独立, 并求出 U, V 各自的概率分布.

习题 4.25. (*) 设 $\mathbf{P} \in \mathbb{R}^{n \times n}$ 为一实对称正定矩阵, $\mathbf{q} \in \mathbb{R}^n$ 为一向量, 令

$$f(\mathbf{x}) = \exp\left(-\frac{1}{2} \mathbf{x}^\top \mathbf{P} \mathbf{x} - \mathbf{q}^\top \mathbf{x}\right), \quad \mathbf{x} \in \mathbb{R}^n.$$

证明

$$\int_{\mathbb{R}^n} f(\mathbf{x}) \, d\mathbf{x} = \sqrt{\frac{(2\pi)^n}{\det \mathbf{P}}} \exp\left(\frac{1}{2} \mathbf{q}^\top \mathbf{P}^{-1} \mathbf{q}\right).$$

提示 首先对 $-\frac{1}{2} \mathbf{x}^\top \mathbf{P} \mathbf{x} - \mathbf{q}^\top \mathbf{x}$ 配方, 将其变形为 $-\frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{P}(\mathbf{x} - \mathbf{x}_0) + c$ 的形式, 其中 $\mathbf{x}_0 \in \mathbb{R}^n$ 而 $c \in \mathbb{R}$. 再利用 $\mathbf{P}$ 的特征值分解构造矩阵 $\mathbf{B} \in \mathbb{R}^{n \times n}$ 使得 $\mathbf{B}^\top \mathbf{B} = \mathbf{P}$, 最后做换元 $\mathbf{y} = \mathbf{B}(\mathbf{x} - \mathbf{x}_0)$ 并利用重积分换元定理(可参考定理 4.2).

习题 4.26. (*) 设 $(X_1, X_2) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 其中

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

证明给定 $X_2 = x_2$ 时 X_1 的条件概率密度函数为

$$f_{X_1|X_2}(x_1|x_2) = c \cdot \exp\left\{-\frac{[x_1 - \mu_1 - \sigma_{12}\sigma_{22}^{-1}(x_2 - \mu_2)]^2}{2(\sigma_{11} - \sigma_{12}\sigma_{22}^{-1}\sigma_{21})}\right\},$$

其中 c 为某个(依赖于 x_2 的)实数. 换句话说, 给定 $X_2 = x_2$ 时 X_1 服从正态分布 $\mathcal{N}(\mu_1 + \sigma_{12}\sigma_{22}^{-1}(x_2 - \mu_2), \sigma_{11} - \sigma_{12}\sigma_{22}^{-1}\sigma_{21})$.

习题 4.27. (*) 设 $\mathbf{X} = (X_1, X_2)$ 为一随机向量.

1. 证明: 若 $\mathbf{X}$ 服从二维正态分布, 且 X_1, X_2 不相关, 则 X_1, X_2 相互独立.
2. 证明: 设 X_1, X_2 均服从一维正态分布, 且 X_1, X_2 相互独立, 则 (X_1, X_2) 服从二维正态分布.
3. 若 X_1, X_2 均服从一维正态分布, 且 X_1, X_2 不相关, 则 X_1, X_2 是否一定服从二维正态分布? 是否一定相互独立? 请给出证明或构造反例.

第五章 大数定律与中心极限定理

5.1 几乎必然收敛与依概率收敛

在大数定律中, 我们需要考虑一系列随机变量的极限行为. 由于随机变量本质上都是定义域为样本空间 Ω 的函数, 研究随机变量列的极限本质上也就是研究函数列的极限. 然而在微积分或数学分析课程中所接触过的几种函数列的收敛方式 (包括逐点收敛、一致收敛等) 在概率论中都太强了, 我们需要引入新的方式来刻画随机变量序列的收敛.

定义 5.1. 设 X 为随机变量, $X_1, X_2, \dots$ 为一列随机变量.

1. 若事件

$$\left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) \text{ 存在且等于 } X(\omega) \right\} \quad (5.1)$$

的概率为 1, 则称 X_n 在 $n \rightarrow \infty$ 时**几乎必然收敛**于 X (X_n converge to X almost surely as $n \rightarrow \infty$), 记为 $X_n \xrightarrow{a.s.} X$.

2. 若给定任意 $\epsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \leq \epsilon) = 1,$$

则称 X_n 在 $n \rightarrow \infty$ 时**依概率收敛**于 X (X_n converges to X in probability as $n \rightarrow \infty$), 记为 $X_n \xrightarrow{P} X$.

不难看出, 几乎必然收敛和逐点收敛比较类似: 逐点收敛实际上就是要求式 (5.1) 给出的事件是必然事件, 而几乎处处收敛则将其放宽为几乎必然事件. 另一方面, 依概率收敛与我们在微积分或数学分析中学过的函数列收敛方式有很大的不同, 它更适合直接在概率论的框架下理解.

可以证明, 几乎必然收敛蕴含了依概率收敛:

定理 5.1. 设 X 与 $X_1, X_2, \dots$ 为随机变量. 则当 $X_n \xrightarrow{a.s.} X$ 时, 有 $X_n \xrightarrow{P} X$.

定理 5.1 的证明超出了本讲义的范围, 我们将其作为选读内容放在 5.4.1 小节. 另一方面, 可以构造出 $(X_n)_{n=1}^{\infty}$ 与 X 的例子使得 $X_n \xrightarrow{P} X$ 但事件 (5.1) 的概率小于 1 (甚至可以是 0), 这意味着依概率收敛严格弱于几乎必然收敛.

注 5.1. (*) 几乎必然收敛与依概率收敛的区别可以这样理解: 依概率收敛 $X_n \xrightarrow{P} X$ 仅保证了对于每个足够大的自然数 n , 事件

$$\{|X_n - X| > \epsilon\}$$

的概率非常小, 且 $n \rightarrow \infty$ 时它的概率趋于 0, 但它不足以保证事件

$$\begin{aligned} E_{\epsilon} &= \{\text{存在无穷多个自然数 } m \text{ 使得 } |X_m - X| > \epsilon\} \\ &= \{\text{对每个自然数 } k, \text{ 都存在自然数 } m \geq k \text{ 使得 } |X_m - X| > \epsilon\} \\ &= \bigcap_{k=1}^{\infty} \bigcup_{m=k}^{\infty} \{|X_m - X| > \epsilon\} \end{aligned}$$

的概率为零, 也就是说在 $X_n \xrightarrow{P} X$ 时仍可能有非零的概率使得 $(X_n)_{n=1}^{\infty}$ 当中有无穷多个偏离 X 的程度超过 ϵ 的项. 而几乎必然收敛则能保证事件 E_{ϵ} 的概率为零, 这是因为 $X_n(\omega) \rightarrow X(\omega)$ 保证了对任意 $\epsilon > 0$, 只有有限多个 m 使得 $|X_m(\omega) - X(\omega)| > \epsilon$. ■

5.2 大数定律

给定一系列随机变量 $X_1, X_2, \dots$, 记

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

并将其称为样本均值. 大数定律所研究的, 就是当 $(X_n)_{n=1}^{\infty}$ 满足哪些条件时, 可以保证其样本均值 $\bar{X}_n$ 在 $n \rightarrow \infty$ 时能够收敛于一个确定性的实数; 这里的“收敛”可以是几乎必然收敛或依概率收敛, 也可以是概率论中其它有意义的收敛方式. 通常, 若在某些条件下, 我们证明了 $\bar{X}_n$ 几乎必然收敛于一个实数, 则相应的定理被称为一个**强大数定律** (strong law of large numbers); 若证明的是 $\bar{X}_n$ 依概率收敛于一个实数, 则相应的定理被称为一个**弱大数定律** (weak law of large numbers).

下面我们给出经典的 Kolmogorov 强大数定律.

定理 5.2 (Kolmogorov). 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量.

1. 若 $\mathbb{E}[X_1]$ 存在, 则有 $\bar{X}_n \xrightarrow{a.s.} \mathbb{E}[X_1]$, 也就是说, 事件

$$\left\{ \omega \in \Omega \left| \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i \text{ 存在且等于 } \mathbb{E}[X_1] \right. \right\},$$

的概率等于 1.

2. 反之, 若 $\bar{X}_n$ 在 $n \rightarrow \infty$ 时几乎必然收敛于某个实数, 则 $\mathbb{E}[X_1]$ 必定存在.

Kolmogorov 强大数定律的完整证明超出本讲义的范围, 这里只对其结论进行介绍, 而在 5.4.2 小节中将给出一个较弱版本的强大数定律的证明.

接下来我们介绍一个较为一般的弱大数定律.

定理 5.3 (Feller). 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量.

1. 若

$$\lim_{x \rightarrow +\infty} x \mathbb{P}(|X_1| > x) = 0 \quad \text{且} \quad \mu = \lim_{n \rightarrow \infty} \mathbb{E}[X_1 1_{\{|X_1| \leq n\}}] \text{ 存在,}$$

则 $\bar{X}_n \xrightarrow{P} \mu$, 也就是说, 给定任意 $\epsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \leq \epsilon\right) = 1.$$

特别是, 若 $\mathbb{E}[X_1]$ 存在, 则 $\bar{X}_n \xrightarrow{P} \mu = \mathbb{E}[X_1]$.

2. 反之, 若存在某个实数 μ 使得 $\bar{X}_n \xrightarrow{P} \mu$, 则

$$\lim_{x \rightarrow +\infty} x \mathbb{P}(|X_1| > x) = 0 \quad \text{且} \quad \lim_{n \rightarrow \infty} \mathbb{E}[X_1 1_{\{|X_1| \leq n\}}] \text{ 存在.}$$

Feller 弱大数定律的证明同样超出了本讲义的范围. 这里我们给出如下 Chebyshev 弱大数定律的证明:

定理 5.4 (Chebyshev). 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量, 且 $\text{Var}(X_1)$ 存在. 则 $\bar{X}_n \xrightarrow{P} \mathbb{E}[X_1]$.

为了证明 Chebyshev 弱大数定律, 我们先做一些准备.

引理 5.5. 1. Markov 不等式: 设随机变量 X 非负, 且 $\mathbb{E}[X]$ 存在, 则对任意 $t > 0$, 有

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X]}{t}.$$

2. Chebyshev 不等式: 设随机变量 X 的方差 $\text{Var}(X)$ 存在, 则对任意 $t > 0$, 有

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) \leq \frac{\text{Var}(X)}{t^2}.$$

证明. 1. 注意到待证不等式等价于 $t \cdot \mathbb{P}(X \geq t) \leq \mathbb{E}[X]$, $\forall t > 0$, 而

$$t \cdot \mathbb{P}(X \geq t) = t \cdot \mathbb{E}[\mathbf{1}_{\{X \geq t\}}] = \mathbb{E}[t \cdot \mathbf{1}_{\{X \geq t\}}].$$

因此 $t \cdot \mathbb{P}(X \geq t) \leq \mathbb{E}[X]$ 的一个充分条件是 $t \cdot \mathbf{1}_{\{X \geq t\}} \leq X$. 现任取 $\omega \in \Omega$, 则

$$X(\omega) - t \cdot \mathbf{1}_{\{X \geq t\}}(\omega) = \begin{cases} X(\omega) - t, & X(\omega) \geq t, \\ X(\omega), & X(\omega) < t \end{cases}$$

上式右端始终非负, 故 $t \cdot \mathbf{1}_{\{X \geq t\}} \leq X$, 从而待证不等式成立.

2. 令 $Y = (X - \mathbb{E}[X])^2$, 则有

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) = \mathbb{P}(Y \geq t^2) \leq \frac{\mathbb{E}[Y]}{t^2} = \frac{\text{Var}(X)}{t^2},$$

其中的不等号利用了 Markov 不等式. □

注 5.2. 利用 Markov 不等式以及 Chebyshev 不等式, 我们可以在随机变量的确切分布未知的情况下, 利用矩的信息, 对其**尾概率**(tail probability)给出粗略的上界. 所谓随机变量 X 的尾概率, 是指形如 $\mathbb{P}(X - \mu \geq t)$, $\mathbb{P}(X - \mu \leq -t)$ 或 $\mathbb{P}(|X - \mu| \geq t)$ 等的概率, 其中 t 为正实数, 而 μ 通常为期望 $\mathbb{E}[X]$. 在不少问题中, 我们会关注这些尾概率在 t 增长到无穷时是以何种方式衰减到零的, 并希望找到一个尾概率上界来定量刻画其衰减方式. 当然, 原始的 Markov 不等式以及 Chebyshev 不等式仅利用了不超过二阶矩的信息, 这导致它们给出的尾概率上界在很多情况下都是比较松的. 习题 5.7 展示了随机变量的任意阶矩均存在时, 如何利用矩母函数的信息, 导出尾概率的一个更紧的上界 (Chernoff 界); 感兴趣且学有余力的读者可进一步查阅**集中不等式**(concentration inequality)的相关研究. ■

在得到 Chebyshev 不等式之后, Chebyshev 弱大数定律的证明就变得比较直接了. 证明 (Chebyshev 弱大数定律). 记 $\sigma^2 = \text{Var}(X_1)$, 并令 $Y_n = \frac{1}{n} \sum_{i=1}^n X_i$, 则有

$$\mathbb{E}[Y_n] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu,$$

且由 $X_1, X_2, \dots$ 的独立性, 有

$$\text{Var}(Y_n) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}. \quad (5.2)$$

则由 Chebyshev 不等式, 可得

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| > \epsilon\right) \leq \mathbb{P}(|Y_n - \mu| \geq \epsilon) \leq \frac{\mathbb{E}[Y_n]}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2},$$

故

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \leq \epsilon\right) \geq 1 - \frac{\sigma^2}{n\epsilon^2}.$$

令上式中 $n \rightarrow \infty$, 即得到待证结论. $\square$

注 5.3. 由定理 4.6 可知, 等式 (5.2) 的成立仅要求 $X_1, \dots, X_n$ 两两互不相关且方差均为 σ^2 . 因此, 可以将定理 5.4 的条件放宽为 (i) $X_1, X_2, \dots$ 同分布且两两互不相关, 以及 (ii) $\text{Var}(X_1)$ 存在, 此时依然有 $\bar{X}_n \xrightarrow{P} \mathbb{E}[X_1]$. $\blacksquare$

以 Kolmogorov 强大数定律为代表的各种大数定律是现代概率论的重要成果, 为概率的频率诠释 (即概率代表频率在试验次数趋于无穷时的极限) 提供了重要依据. 例如, 考虑最简单的独立重复掷骰子试验, 我们用随机变量 X_n 代表第 n 次投掷的点数, 则

1. $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 为前 n 次试验投出的点数的平均值. 由于 $X_1, X_2, \dots$ 独立同分布且期望存在, 由 Kolmogorov 强大数定律可得

$$\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}[X_1] = \frac{1 + 2 + \dots + 6}{6} = \frac{7}{2}$$

以概率 1 (也就是几乎必然) 成立.

2. 对任意 $\{1, 2, \dots, 6\}$ 的子集 A , 令

$$\text{Fr}_n(A) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \in A\}},$$

即 $\text{Fr}_n(A)$ 为 n 次投掷后点数属于集合 A 的频率. 由于 $1_{\{X_1 \in A\}}, 1_{\{X_2 \in A\}}, \dots$ 独立同分布且期望存在, 由 Kolmogorov 强大数定律可得

$$\lim_{n \rightarrow \infty} \text{Fr}_n(A) = \mathbb{E}[1_{\{X_1 \in A\}}] = \mathbb{P}(X_1 \in A).$$

以概率 1 成立. 换句话说, 频率 $\text{Fr}_n(A)$ 几乎必然收敛于概率 $\mathbb{P}(X_1 \in A)$.

3. 现固定一 $\{1, 2, \dots, 6\}$ 的非空子集 B , 再任取 $\{1, 2, \dots, 6\}$ 的非空子集 A , 我们把 n 次投掷中点数属于 B 的那几次挑出来, 并计算其中点数同时属于 A 的次数的占比 (暂时将其称作“条件频率”):

$$\frac{\sum_{i=1}^n \mathbf{1}_{\{X_i \in A \cap B\}}}{\sum_{i=1}^n \mathbf{1}_{\{X_i \in B\}}} = \frac{\text{Fr}_n(A \cap B)}{\text{Fr}_n(B)},$$

而由 Kolmogorov 强大数定律可得

$$\lim_{n \rightarrow \infty} \frac{\text{Fr}_n(A \cap B)}{\text{Fr}_n(A)} = \frac{\mathbb{P}(X_1 \in A \cap B)}{\mathbb{P}(X_1 \in B)} = \mathbb{P}(X_1 \in A | X_1 \in B)$$

以概率 1 成立, 这意味着条件频率也几乎必然收敛于条件概率.

此外, 大数定律也为数理统计中众多点估计方法 (例如矩方法) 等提供了基本的理论依据.

5.3 中心极限定理

对于一系列独立同分布的随机变量 $X_1, X_2, \dots$, 大数定律保证了样本均值 $\bar{X}_n$ 时将 (在某种意义下) 收敛于期望, 而中心极限定理考虑的则是对这个收敛过程更细致的刻画, 即 n 足够大时, 样本均值 $\bar{X}_n$ 相对于其期望的涨落情况. 这里给出一个经典版本的中心极限定理:

定理 5.6. 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量, 且 $\mu = \mathbb{E}[X_1]$ 与 $\sigma = \sqrt{\text{Var}(X_1)}$ 均存在, $\sigma > 0$. 令

$$Z_n = \frac{\sum_{i=1}^n (X_i - \mu)}{\sigma \sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}, \quad \forall n = 1, 2, \dots,$$

则对任意 $z \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(Z_n \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = \Phi(z).$$

证明. (*) 令 $Y_n = (X_n - \mu)/\sigma$. 这里仅考虑矩母函数 $M_Y(t) = \mathbb{E}[e^{tY_1}]$ 在某个包含 0 的开区间 $]-\delta, \delta[$ 上有定义的情形. 任取 $t \in \mathbb{R}$, 则对足够大的正整数 n , 有

$$M_{Z_n}(t) = \mathbb{E}\left[\exp\left(\frac{t}{\sqrt{n}} \sum_{i=1}^n Y_i\right)\right] = \prod_{i=1}^n \mathbb{E}\left[\exp\left(\frac{t}{\sqrt{n}} Y_i\right)\right] = \left[M_Y\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

而由于 $\mathbb{E}[Y_1] = 0$, $\text{Var}(Y_1) = 1$, 故将 $M_Y(t)$ 在 $t = 0$ 附近做泰勒展开到二阶可得

$$M_Y(t) = 1 + \frac{1}{2}t^2 + o(t^2),$$

因此

$$M_{Z_n}(t) = \left(1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n.$$

令 $n \rightarrow \infty$ 即可得到

$$\lim_{n \rightarrow \infty} M_{Z_n}(t) = e^{\frac{t^2}{2}}.$$

上式右端恰好给出标准正态分布 $\mathcal{N}(0, 1)$ 的矩母函数, 接下来我们需要用到如下引理:

引理 5.7. 设 $Z_1, Z_2, \dots$ 为一列随机变量, 它们的分布函数为 F_{Z_n} , 矩母函数为 M_{Z_n} . 又设随机变量 Z 的分布函数为 F_Z , 矩母函数 M_Z 在 $]-\delta, \delta[$ 上有定义. 若对任意 $t \in]-\delta, \delta[$, $M_{Z_n}(t)$ 总对足够大的 n 有定义, 且

$$\lim_{n \rightarrow \infty} M_{Z_n}(t) = M_Z(t),$$

则对任意 $x \in \mathbb{R}$, 只要 F_Z 在点 x 处连续, 就有

$$\lim_{n \rightarrow \infty} F_{Z_n}(x) = F_Z(x).$$

该引理的证明不做要求. 由上述引理可立即得到

$$\lim_{n \rightarrow \infty} F_{Z_n}(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx,$$

因此待证结论成立. □

注 5.4. (*) 实际上在上述证明中, 我们只需把矩母函数 M_Y 换成**特征函数** (characteristic function)

$$\varphi_Y(t) = \mathbb{E}[\cos Y_1] + i \mathbb{E}[\sin Y_1] = \mathbb{E}[e^{itY_1}], \quad t \in \mathbb{R},$$

即可将该证明比较直接地推广到一般的情形. 特征函数与矩母函数有许多相似的性质, 例如 X, Y 独立时有 $\varphi_{X+Y} = \varphi_X \cdot \varphi_Y$, 又如引理 5.7 也有特征函数的版本. 但可以证明, 对于任意随机变量, 其特征函数在整个实数轴上均有定义, 而对各阶矩的存在性没有要求, 因此特征函数相比矩母函数有着更广泛的适用范围. ■

结合大数定律与中心极限定理, 可以不严格地认为, 对于一系列独立同分布的随机变量 $X_1, X_2, \dots$, 当 n 足够大时有

$$\frac{1}{n} \sum_{i=1}^n X_i \approx \mu + \frac{\sigma}{\sqrt{n}} \cdot Z_n,$$

其中 $\mu = \mathbb{E}[X_1]$, $\sigma = \sqrt{\text{Var}(X_1)}$, 而随机变量 Z_n 服从正态分布 $\mathcal{N}(0, 1)$. 上式指出, 样本均值相对于期望的涨落幅度正比于标准差 σ 而反比于 $\sqrt{n}$. 此外, 在数理统计的部分, 我们还将用上式来设计期望的区间估计方法.

定理 5.6 给出的是一个经典版本的中心极限定理, 其它版本的中心极限定理还包括 Lyapunov 中心极限定理、Lindeberg 中心极限定理等, 它们在不同条件下证明了样本均值相对于期望的涨落渐近服从正态分布; 见 [14] 第 27 节. 这些中心极限定理为如下经验性结论提供了理论支持:

若一个随机变量 X 是由大量微小而相互独立的随机因素叠加作用而产生的, 则 X 服从正态分布.

这也解释了为什么实际应用中会大量出现服从正态分布的随机变量. 例如, 花粉的布朗运动就是上述结论的一个典型例子.

5.3.1 利用中心极限定理近似计算概率

中心极限定理的另一大用处是对涉及大量独立同分布随机变量的和的概率进行近似计算. 设某个概率分布 F 的期望为 μ , 标准差为 $\sigma > 0$, 而 $X_1, X_2, \dots$ 是一列服从分布 F 的相互独立的随机变量. 记 $S_n = X_1 + \dots + X_n$, 则当 n 足够大时, 由中心极限定理可得

$$\mathbb{P}(S_n \leq x) = \mathbb{P}\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq \frac{x - n\mu}{\sigma\sqrt{n}}\right) \approx \Phi\left(\frac{x - n\mu}{\sigma\sqrt{n}}\right).$$

上式意味着我们可以近似认为 S_n 服从正态分布 $\mathcal{N}(n\mu, n\sigma^2)$.

例 5.1 (二项分布的正态近似). 设随机变量 S 服从参数为 (n, p) 的二项分布, 并记 $q = 1 - p$. 由二项分布与伯努利分布的关系, 可知 S 与 $X_1 + \dots + X_n$ 同分布, 其中 $X_1, \dots, X_n$ 相互独立且服从参数为 p 的伯努利分布. 现取 $k \leq l$ 为任意自然数, 则基于中心极限定理给出的 $\mathbb{P}(k \leq S \leq l)$ 的近似值为

$$\begin{aligned} \mathbb{P}(k \leq S \leq l) &= \mathbb{P}(k - 1/2 \leq S \leq l + 1/2) \\ &\approx \Phi\left(\frac{l + 1/2 - np}{\sqrt{npq}}\right) - \Phi\left(\frac{k - 1/2 - np}{\sqrt{npq}}\right). \end{aligned} \quad (5.3)$$

注意到我们在利用中心极限定理之前先将 $\mathbb{P}(k \leq S \leq l)$ 改写为 $\mathbb{P}(k - 1/2 \leq S \leq l + 1/2)$, 该步通常被称为**连续性修正** (continuity correction). 对于 $X_1 + \dots + X_n$ 为离散型随机

变量的情形, 施加这类连续性修正通常能给出更精确的估计结果. 文献 [15] 第 VII.3 节对二项分布情形的连续性修正给出了更定量的解释.

一般来说, 若要使得式 (5.3) 具有较好的精度, 则 n 应取得比较大, 且 p 不能太接近 0 或 1. 一些理论分析以及数值经验指出, 当 $np \geq 5$ 且 $nq = n(1-p) \geq 5$ 时, 式 (5.3) 通常能够给出可接受的精度. ■

例 5.2. 设有一枚立方体骰子, 我们将这枚骰子重复投掷 10 次, 并将掷出的点数之和记为 S . 我们希望对概率 $\mathbb{P}(30 \leq S \leq 40)$ 进行估计. 考虑到 S 服从的依然是离散型分布, 我们在用中心极限定理前先采取连续性修正:

$$\begin{aligned}\mathbb{P}(30 \leq S \leq 40) &= \mathbb{P}(29.5 \leq S \leq 40.5) \\ &\approx \Phi\left(\frac{40.5 - 10 \cdot 3.5}{\sqrt{35/12} \cdot \sqrt{10}}\right) - \Phi\left(\frac{29.5 - 10 \cdot 3.5}{\sqrt{35/12} \cdot \sqrt{10}}\right) \\ &= 2\Phi\left(\frac{40.5 - 10 \cdot 3.5}{\sqrt{35/12} \cdot \sqrt{10}}\right) - 1 \approx 0.6915,\end{aligned}$$

计算中我们还利用了函数 Φ 的对称性 $\Phi(x) + \Phi(-x) = 1$. 实际上, 利用卷积公式交由计算机可算出精确值:

$$\mathbb{P}(30 \leq S \leq 40) = \frac{10384949}{15116544} = 0.68699 \dots$$

可看出中心极限定理 (附加连续性修正) 给出的估计值与精确值相差不到 5×10^{-3} . 感兴趣的读者可尝试计算不采取连续性修正时的估计值, 并将其与精确值进行比较. ■

5.4 (*) 一些定理的证明

5.4.1 几乎处处收敛与依概率收敛

本小节将证明定理 5.1, 即几乎必然收敛蕴含依概率收敛.

任取 $\epsilon > 0$, 记

$$E = \left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) \text{ 存在且等于 } X(\omega) \right\}.$$

则由极限的定义, 可得

$$\begin{aligned}
 E^c &= \{ \text{存在 } \epsilon_0 > 0, \text{ 使得对任意正整数 } N, \text{ 存在 } n \geq N \text{ 使 } |X_n - X| > \epsilon_0 \} \\
 &= \bigcup_{\epsilon_0 > 0} \{ \text{对任意正整数 } N, \text{ 存在 } n \geq N \text{ 使 } |X_n - X| > \epsilon_0 \} \\
 &\supseteq \{ \text{对任意正整数 } N, \text{ 存在 } n \geq N \text{ 使 } |X_n - X| > \epsilon \} \\
 &= \bigcap_{N=1}^{\infty} \{ \text{存在 } n \geq N \text{ 使 } |X_n - X| > \epsilon \} = \bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{ |X_n - X| > \epsilon \}.
 \end{aligned}$$

由于 $\mathbb{P}(E^c) = 0$, 故上式最右端事件的概率也为 0. 记 $A_N = \bigcup_{n=N}^{\infty} \{|X_n - X| > \epsilon\}$, 则有 $A_1 \supseteq A_2 \supseteq A_3 \supseteq \dots$, 故由概率的单调连续性可得

$$0 = \mathbb{P}\left(\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{|X_n - X| > \epsilon\}\right) = \mathbb{P}\left(\bigcap_{N=1}^{\infty} A_N\right) = \lim_{N \rightarrow \infty} \mathbb{P}(A_N).$$

另一方面, $A_N \supseteq \{|X_N - X| > \epsilon\}$, 因此 $\mathbb{P}(|X_N - X| > \epsilon) \leq \mathbb{P}(A_N)$, 再令 $N \rightarrow \infty$ 即得到

$$\lim_{N \rightarrow \infty} \mathbb{P}(|X_N - X| > \epsilon) = 0.$$

由 $\epsilon > 0$ 的任意性可知 $X_n \xrightarrow{P} X$.

5.4.2 Borel–Cantelli 引理与强大数定律

Borel–Cantelli 第一与第二引理是概率论中用于研究随机变量序列几乎必然收敛性的基础工具. 本节中我们对 Borel–Cantelli 第一引理做简要介绍, 并进一步证明一个较弱的强大数定律.

引理 5.8 (Borel–Cantelli 第一引理). 设 $A_n, n \in \mathbb{N}_+$ 为一列事件, 且级数 $\sum_{n=1}^{\infty} \mathbb{P}(A_n)$ 收敛, 则事件

$$\{\omega \in \Omega \mid \text{存在无穷多个正整数 } n, \text{ 使得 } \omega \in A_n\}.$$

的概率为 0.

证明. 记 $B = \{\omega \in \Omega \mid \text{存在无穷多个正整数 } n, \text{ 使得 } \omega \in A_n\}$, 则有

$$\begin{aligned}
 B &= \{\omega \in \Omega \mid \text{对任意正整数 } k, \text{ 均存在 } n \geq k, \text{ 使得 } \omega \in A_n\} \\
 &= \bigcap_{k=1}^{\infty} \{\omega \in \Omega \mid \text{存在 } n \geq k, \text{ 使得 } \omega \in A_n\} \\
 &= \bigcap_{k=1}^{\infty} \bigcup_{n=k}^{\infty} A_n.
 \end{aligned}$$

记 $C_k = \bigcup_{n=k}^{\infty} A_n$, 则有 $C_1 \supseteq C_2 \supseteq C_3 \supseteq \cdots$ 以及 $B = \bigcap_{k=1}^{\infty} C_k$, 因而由概率的单调连续性可得

$$\mathbb{P}(B) = \lim_{k \rightarrow \infty} \mathbb{P}(C_k).$$

另一方面, 令 $D_{k,j} = \bigcup_{n=k}^j A_n$, 则有 $D_{k,k} \subseteq D_{k,k+1} \subseteq D_{k,k+2} \subseteq \cdots$, 以及

$$\bigcup_{j=k}^{\infty} D_{k,j} = \bigcup_{j=k}^{\infty} \bigcup_{n=k}^j A_n = \bigcup_{n=k}^{\infty} A_n,$$

故由概率的单调连续性以及次可加性可得

$$\mathbb{P}(C_k) = \lim_{j \rightarrow \infty} \mathbb{P}(D_{k,j}) = \lim_{j \rightarrow \infty} \mathbb{P}\left(\bigcup_{n=k}^j A_n\right) \leq \lim_{j \rightarrow \infty} \sum_{n=k}^j \mathbb{P}(A_n) = \sum_{n=k}^{\infty} \mathbb{P}(A_n),$$

从而

$$\mathbb{P}(B) = \lim_{k \rightarrow \infty} \mathbb{P}(C_k) \leq \lim_{k \rightarrow \infty} \sum_{n=k}^{\infty} \mathbb{P}(A_n) = 0,$$

其中最后一步用到了级数 $\sum_{n=1}^{\infty} \mathbb{P}(A_n)$ 的收敛性. □

下面我们将证明如下强大数定律, 该定理及证明取自 [8] 第 7.4 节定理(3):

定理 5.9. 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量, 且 $\mathbb{E}[X_1]$ 与 $\text{Var}(X_1)$ 均存在. 则有 $\bar{X}_n \xrightarrow{a.s.} \mathbb{E}[X_1]$, 也就是说事件

$$\left\{ \omega \in \Omega \left| \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i \text{ 存在且等于 } \mathbb{E}[X_1] \right. \right\}$$

的概率为 1.

证明. 首先考虑 X_n 均为非负变量的情形. 记 $\mu = \mathbb{E}[X_1]$, $\sigma^2 = \text{Var}(X_1)$. 由切比雪夫不等式, 可得对于任意 $\epsilon > 0$, 有

$$\mathbb{P}(|\bar{X}_{n^2} - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_{n^2})}{\epsilon^2} = \frac{\sigma^2}{n^2 \epsilon}.$$

令

$$A_{\epsilon,n} = \{|\bar{X}_{n^2} - \mu| > \epsilon\},$$

则

$$\sum_{n=1}^{\infty} \mathbb{P}(A_{\epsilon,n}) \leq \frac{\sigma^2}{\epsilon} \sum_{n=1}^{\infty} \frac{1}{n^2},$$

故级数 $\sum_{n=1}^{\infty} \mathbb{P}(A_{\epsilon,n})$ 收敛. 由 Borel–Cantelli 第一引理可得, 对任意 $\epsilon > 0$, 事件

$$\begin{aligned} B_{\epsilon} &= \{\omega \in \Omega \mid \text{存在无穷多正整数 } n \text{ 使得 } \omega \in A_{\epsilon,n}\} \\ &= \{\text{存在无穷多正整数 } n \text{ 使得 } |\bar{X}_{n^2} - \mu| > \epsilon\} \end{aligned}$$

的概率为 0. 另一方面, 若记事件

$$\tilde{E} = \left\{ \lim_{n \rightarrow \infty} \bar{X}_{n^2} \text{ 存在且等于 } \mu \right\},$$

则根据极限定义, 有

$$\begin{aligned} \tilde{E}^c &= \{\text{存在 } \epsilon_0 > 0, \text{ 使得对任意正整数 } N, \text{ 存在 } n \geq N \text{ 使 } |\bar{X}_{n^2} - \mu| > \epsilon_0\}, \\ &= \{\text{存在 } \epsilon_0 > 0, \text{ 使得 } |\bar{X}_{n^2} - \mu| > \epsilon_0 \text{ 对无穷多个正整数 } n \text{ 成立}\} \\ &= \left\{ \text{存在正整数 } k, \text{ 使得 } |\bar{X}_{n^2} - \mu| > \frac{1}{k} \text{ 对无穷多个正整数 } n \text{ 成立} \right\} \\ &= \bigcup_{k=1}^{\infty} \left\{ |\bar{X}_{n^2} - \mu| > \frac{1}{k} \text{ 对无穷多个正整数 } n \text{ 成立} \right\} = \bigcup_{k=1}^{\infty} B_{\frac{1}{k}}. \end{aligned}$$

不难看出对任意正整数 k 均有 $B_{\frac{1}{k}} \subseteq B_{\frac{1}{k+1}}$, 因此由概率的连续性,

$$\mathbb{P}(\tilde{E}^c) = \lim_{k \rightarrow \infty} \mathbb{P}\left(B_{\frac{1}{k}}\right) = 0.$$

也就是说, 事件 $\tilde{E}$ 的概率为 1.

下面我们将证明对任意的 $\omega \in \tilde{E}$, 不仅 $\bar{X}_{n^2}(\omega)$ 收敛于 μ , 而且 $\bar{X}_n(\omega)$ 也同样收敛于 μ . 对任意正整数 k , 记 $n(k)$ 为满足 $n(k)^2 \leq k$ 的最大正整数. 任取 $\omega \in \tilde{E}$, 则由 X_n 的非负性, 可得

$$\sum_{i=1}^{n(k)^2} X_i(\omega) \leq \sum_{i=1}^k X_i(\omega) \leq \sum_{i=1}^{(n(k)+1)^2} X_i(\omega),$$

将上式除以 k , 即可得到

$$\frac{n(k)^2}{k} \bar{X}_{n(k)^2}(\omega) \leq \bar{X}_k(\omega) \leq \frac{(n(k)+1)^2}{k} \bar{X}_{(n(k)+1)^2}(\omega),$$

令上式 $k \rightarrow \infty$ 并注意到 $n(k)^2/k \rightarrow 1$ 以及 $(n(k)+1)^2/k \rightarrow 1$, 即可由极限的夹挤原理得到

$$\lim_{k \rightarrow \infty} \bar{X}_k(\omega) = \lim_{n \rightarrow \infty} \bar{X}_{n^2}(\omega) = \mu.$$

由 $\omega \in \tilde{E}$ 的任意性, 可得事件

$$\left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} \bar{X}_n \text{ 存在且等于 } \mu \right\}$$

就等于事件 $\tilde{E}$, 从而其概率为 1.

以上证明假定了 X_n 均为非负随机变量. 对于一般情形, 考虑 $X_n^+ = \max\{X_n, 0\}$ 以及 $X_n^- = \max\{-X_n, 0\}$. 由于

$$0 \leq X_n^+ \leq |X_n|, \quad 0 \leq X_n^- \leq |X_n|,$$

故 $\mathbb{E}[X_n]$ 与 $\text{Var}(X_n)$ 的存在性保证了 $\mathbb{E}[X_n^+]$ 与 $\mathbb{E}[X_n^-]$ 以及 $\text{Var}(X_n^+)$ 与 $\text{Var}(X_n^-)$ 的存在性. 令

$$\bar{X}_n^+ = \frac{1}{n} \sum_{i=1}^n X_i^+, \quad \bar{X}_n^- = \frac{1}{n} \sum_{i=1}^n X_i^-,$$

并令

$$\begin{aligned} E_+ &= \left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} \bar{X}_n^+ \text{ 存在且等于 } \mathbb{E}[X_1^+] \right\}, \\ E_- &= \left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} \bar{X}_n^- \text{ 存在且等于 } \mathbb{E}[X_1^-] \right\}, \\ E &= \left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} \bar{X}_n \text{ 存在且等于 } \mathbb{E}[X_1] \right\}, \end{aligned}$$

则有 $\mathbb{P}(E_+) = \mathbb{P}(E_-) = 1$, 以及 $E_+ \cap E_- \subseteq E$, 从而

$$\mathbb{P}(E^c) = \mathbb{P}(E_+^c \cup E_-^c) \leq \mathbb{P}(E_+^c) + \mathbb{P}(E_-^c) = 0,$$

即 $\mathbb{P}(E) = 1$. □

5.5 习题

习题 5.1. 设 $U_1, U_2, \dots$ 为一列独立同分布的随机变量, 均服从区间 $[0, a]$ 上的均匀分布, 其中 a 为一个正的常数. 令 $Z_n = \max\{U_1, \dots, U_n\}$. 证明 $Z_n \xrightarrow{P} a$.

习题 5.2. 设 $X_1, X_2, \dots$ 为一列服从标准柯西分布的独立同分布随机变量. 令

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

证明: 对任意正整数 n , 随机变量 $\bar{X}_n$ 均服从标准柯西分布. 由此进一步证明 $(X_n)_{n=1}^\infty$ 不服从弱大数定律.

习题 5.3. 设 $X_1, X_2, \dots$ 为一列独立同分布的随机变量, 且 $\text{Var}(X_1)$ 存在. 令

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n \left(X_i - \frac{1}{n} \sum_{j=1}^n X_j \right)^2,$$

$$\tilde{S}_n^2 = \frac{n-1}{n} S_n^2.$$

利用 Kolmogorov 强大数定律, 证明 $n \rightarrow \infty$ 时有 $S_n^2 \xrightarrow{a.s.} \text{Var}(X_1)$ 以及 $\tilde{S}_n^2 \xrightarrow{a.s.} \text{Var}(X_1)$.

提示 令 $\mu = \mathbb{E}[X_1]$. 先证明

$$\tilde{S}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 - (\bar{X}_n - \mu)^2,$$

再用 Kolmogorov 强大数定律证明 $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \xrightarrow{a.s.} \text{Var}(X_1)$ 与 $(\bar{X}_n - \mu)^2 \xrightarrow{a.s.} 0$.

习题 5.4 (Cantelli 不等式/单边 Chebyshev 不等式). 设随机变量 X 的方差 $\text{Var}(X)$ 存在, 则对任意 $t > 0$, 有

$$\mathbb{P}(X - \mathbb{E}[X] \geq t) \leq \frac{\text{Var}(X)}{\text{Var}(X) + t^2}.$$

提示 注意到 t, c 均为正实数时有

$$\begin{aligned} \mathbb{P}(X - \mathbb{E}[X] \geq t) &= \mathbb{P}(X - \mathbb{E}[X] + c \geq t + c) \\ &\leq \mathbb{P}((X - \mathbb{E}[X] + c)^2 \geq (t + c)^2). \end{aligned}$$

用 Markov 不等式得到上式右端的一个上界, 最后调整 c 的值使得该上界被最小化.

习题 5.5. 1. 设 $Z_1, Z_2, \dots$ 为一列随机变量, 且它们的 k 阶矩均存在 (k 为一个给定常数). 证明: 若 $\lim_{n \rightarrow \infty} \mathbb{E}[|Z_n|^k] = 0$, 则 $Z_n \xrightarrow{P} 0$.

2. 设 $S_1, S_2, \dots$ 为一列随机变量, 且 $\mathbb{E}[S_n]$ 以及 $\text{Var}(S_n)$ 对任意正整数 n 均存在. 证明: 若取值非零的数列 $(b_n)_{n=1}^\infty$ 满足 $\lim_{n \rightarrow \infty} \text{Var}(S_n)/b_n^2 = 0$, 则

$$\frac{S_n - \mathbb{E}[S_n]}{b_n} \xrightarrow{P} 0.$$

习题 5.6. 考虑习题 2.20 的情景, 其中我们改用 T_N 表示集齐所有 N 种海报时已购买的唱片张数. 证明 $N \rightarrow \infty$ 时

$$\frac{T_N - N \sum_{m=1}^N m^{-1}}{N \ln N} \xrightarrow{P} 0,$$

从而有 $T_N/(N \ln N) \xrightarrow{P} 1$.

提示 令 $b_N = N \ln N$, 并证明 $\lim_{N \rightarrow \infty} \text{Var}(T_N)/b_N^2 = 0$, 再利用习题 5.5 第 2 部分的结论.

习题 5.7 (Chernoff 界). 设 X 为一随机变量, 且对任意 $\lambda \in \mathbb{R}$, 期望 $\mathbb{E}[e^{\lambda X}]$ 均存在. 令

$$M_X(\lambda) = \mathbb{E}[e^{\lambda X}], \quad \lambda \in \mathbb{R}.$$

1. 利用 Markov 不等式证明: 对任意的 $a \in \mathbb{R}$ 与 $\lambda > 0$, 有

$$\mathbb{P}(X \geq a) \leq e^{-\lambda a} M_X(\lambda),$$

并由此得到

$$\mathbb{P}(X \geq a) \leq \inf_{\lambda > 0} [e^{-\lambda a} M_X(\lambda)]. \quad (5.4)$$

上式即一般的 Chernoff 界.

2. 设 $a > \mathbb{E}[X]$. 固定 a 并令

$$\varphi(\lambda) = \lambda a - \ln M_X(\lambda), \quad \lambda \in \mathbb{R}.$$

试证明

$$\varphi'(\lambda) = \frac{\mathbb{E}[(a - X)e^{\lambda X}]}{\mathbb{E}[e^{\lambda X}]},$$

并由此得到 $\varphi'(0) > 0$ 以及

$$\inf_{\lambda > 0} [e^{-\lambda a} M_X(\lambda)] < 1.$$

提示 证明时可直接利用等式 $\frac{d}{d\lambda} \mathbb{E}[e^{\lambda X}] = \mathbb{E}[\frac{\partial}{\partial \lambda}(e^{\lambda X})]$.

3. 设 $X_1, \dots, X_n$ 相互独立, 且各自的矩母函数 $M_{X_i}(\lambda) = \mathbb{E}[e^{\lambda X_i}]$ 对任意 $\lambda \in \mathbb{R}$ 均有定义. 证明对任意 $t > \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i]$, 有

$$\mathbb{P}\left(\frac{1}{n} \sum_{i=1}^n X_i \geq t\right) \leq \inf_{\lambda > 0} \left[e^{-n\lambda t} \prod_{i=1}^n M_{X_i}(\lambda) \right]. \quad (5.5)$$

4. 设 $R_1, \dots, R_n$ 独立同分布且服从参数为 $p \in]0, 1[$ 的伯努利分布. 利用式 (5.5) 证明: 对于任意的 $\epsilon \in]0, \min\{p, 1-p\}[$, 有

$$\mathbb{P}\left(\frac{1}{n} \sum_{i=1}^n R_i \geq p + \epsilon\right) \leq e^{-nD(p+\epsilon||p)}, \quad (5.6a)$$

$$\mathbb{P}\left(\frac{1}{n} \sum_{i=1}^n R_i \leq p - \epsilon\right) \leq e^{-nD(p-\epsilon||p)}, \quad (5.6b)$$

其中

$$D(x \| y) = x \ln \frac{x}{y} + (1-x) \ln \frac{1-x}{1-y}.$$

5. 利用 Chebyshev 不等式求出

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n R_i - p\right| \geq \epsilon\right)$$

的一个上界, 并将其与式 (5.6) 相比较, 特别是讨论二者在 n 充分大时的差异.

习题 5.8 (Hoeffding 不等式). 设 $X_1, \dots, X_n$ 为独立的随机变量, $\mathbb{E}[X_i]$ 均为 0, 且对任意 $i = 1, \dots, n$, 存在 $a_i < 0$ 与 $b_i > 0$ 使得 $\mathbb{P}(a_i \leq X_i \leq b_i) = 1$. 令 $S_n = \sum_{i=1}^n X_i$.

1. 任取 $\lambda \in \mathbb{R}$, 利用指数函数的凸性证明不等式

$$e^{\lambda z} \leq \frac{z - a_i}{b_i - a_i} e^{\lambda b_i} + \frac{b_i - z}{b_i - a_i} e^{\lambda a_i}, \quad \forall z \in [a_i, b_i], i = 1, \dots, n,$$

并进一步证明

$$\mathbb{E}[e^{\lambda X_i}] \leq \frac{b_i e^{\lambda a_i} - a_i e^{\lambda b_i}}{b_i - a_i}.$$

2. 任取 $\theta \in]0, 1[$, 令

$$g_\theta(\gamma) = \ln(\theta e^{-\gamma(1-\theta)} + (1-\theta)e^{\gamma\theta}), \quad \gamma \in \mathbb{R}.$$

证明

$$g_\theta''(\gamma) \leq \frac{1}{4}, \quad \forall \gamma \in \mathbb{R},$$

再利用 g_θ 的麦克劳林展开证明

$$g_\theta(\gamma) \leq \frac{\gamma^2}{8}, \quad \forall \gamma \in \mathbb{R},$$

并由此证明

$$\ln \mathbb{E}[e^{\lambda X_i}] \leq \frac{\lambda^2}{8} (b_i - a_i)^2.$$

3. 利用式 (5.5) 证明: 对任意 $\epsilon > 0$, 有

$$\mathbb{P}\left(\frac{S_n}{n} \geq \epsilon\right) \leq \inf_{\lambda > 0} \exp\left[-\lambda n \epsilon + \frac{\lambda^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right],$$

并由此得到

$$\mathbb{P}\left(\frac{S_n}{n} \geq \epsilon\right) \leq \exp\left(-\frac{2\epsilon^2 n^2}{\sum_{i=1}^n (b_i - a_i)^2}\right) \quad (5.7a)$$

以及

$$\mathbb{P}\left(\left|\frac{S_n}{n}\right| \geq \epsilon\right) \leq 2 \exp\left(-\frac{2\epsilon^2 n^2}{\sum_{i=1}^n (b_i - a_i)^2}\right). \quad (5.7b)$$

以上两个不等式被称为 Hoeffding 不等式.

4. 设 $R_1, \dots, R_n$ 独立同分布且服从参数为 $p \in]0, 1[$ 的伯努利分布. 给定任意 $\epsilon > 0$, 利用 Hoeffding 不等式 (5.7) 求出

$$\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n R_i - p\right| \geq \epsilon\right)$$

的一个上界, 并将其与式 (5.6) 以及 Chebyshev 不等式给出的上界进行比较, 特别是讨论三者当 n 充分大时的差异.

习题 5.9. 证明: 对任意 $x > 0$, 有

$$\int_x^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt \leq \exp\left(-\frac{x^2}{2}\right).$$

提示 利用 Chernoff 界.

习题 5.10. 设随机变量 $X_1, X_2, \dots$ 独立同分布, 它们的值域为 $\{1, 2, \dots, S\}$, 其中 S 是一个大于 1 的正整数, 且对任意 $s = 1, \dots, S$ 均有 $\mathbb{P}(X_1 = s) > 0$. 令

$$p_0(s) = \mathbb{P}(X_1 = s), \quad \forall s = 1, \dots, S.$$

再设函数 $p_1: \{1, \dots, S\} \rightarrow]0, 1[$ 满足 $\sum_{s=1}^S p_1(s) = 1$, 且 $p_1(s)$ 与 $p_0(s)$ 不全相等. 令

$$Z_n = \prod_{i=1}^n \frac{p_1(X_i)}{p_0(X_i)}, \quad \forall n = 1, 2, \dots$$

证明 $\mathbb{E}[Z_n] = 1, \forall n = 1, 2, \dots$, 但 $Z_n \xrightarrow{a.s.} 0$.

提示 利用强大数定律证明 $\frac{1}{n} \ln Z_n$ 几乎必然收敛于一个严格小于 0 的数.

习题 5.11. 某个寝室的饮水机换上了容量为 10 升的桶装水. 假设寝室成员每次接水的量为独立同分布的随机变量, 其期望为 0.3 升, 标准差为 0.08 升. 试近似求解接水 36 次后该桶水仍未被喝完的概率.

习题 5.12. 保险公司推出了一款针对 A 国家旅游的意外伤害保险. 已知在 A 国家旅游时发生意外伤害的概率为 0.2%, 投保人参保需要交 140 元保费, 而旅游途中若发生意外伤害则保险公司将赔付 5 万元.

1. 若该保险总共售卖了 3600 份, 试近似求解该保险亏本的概率.
2. 试求出一正整数 n , 使得卖出的保险份数大于等于 n 时, 该保险亏本的概率能降到约 5% 以下.

习题 5.13. 1. 设 X 服从参数为 $\lambda = 100$ 的泊松分布, 试求 $\mathbb{P}(X \geq 120)$ 的一个近似值.

2. 设 X 服从参数为 $r = 50, p = 1/5$ 的负二项分布, 也就是说

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, r+2, \dots$$

试求 $\mathbb{P}(220 \leq X \leq 280)$ 的一个近似值.

3. 设 X 服从参数为 $\alpha = 40, \beta = 1/2$ 的 Gamma 分布, 试求 $\mathbb{P}(X \leq 70)$ 的一个近似值.

习题 5.14. (*) 考虑习题 2.20 的情景, 其中我们改用 T_N 表示集齐所有 N 种海报时已购买的唱片张数, 并令 $X_N = N^{-1}(T_N - N \ln N)$.

1. 试求 X_N 的矩母函数 $M_{X_N}(t) = \mathbb{E}[\exp(tX_N)]$.
2. 固定 t , 试求极限

$$\lim_{N \rightarrow \infty} M_{X_N}(t).$$

提示 你可以利用如下公式:

$$\lim_{n \rightarrow \infty} \frac{n! n^z}{\prod_{k=0}^n (z+k)} = \Gamma(z), \quad \forall z \in \mathbb{C} \setminus \{0, -1, -2, \dots\},$$

其中 $\Gamma(\cdot)$ 表示 Γ 函数.

3. 证明: 对任意 $x \in \mathbb{R}$, 当 $N \rightarrow \infty$ 时有 $\mathbb{P}(X_N \leq x) \rightarrow e^{-e^{-x}}$.

提示 求出分布 $F(x) = e^{-e^{-x}}$ 的概率密度函数与矩母函数, 再利用引理 5.7.

第二部分

数理统计

第六章 数理统计的基本概念

从本章开始, 我们进入数理统计部分. 数理统计学以概率论方法为基础, 研究如何针对某个随机现象收集合适的数据, 并基于概率模型对获得的数据进行分析, 从而对所研究的随机现象作出恰当的推断. 数理统计学是一门应用性非常强的学科, 其理论的发展往往由实际问题所驱动. 本章将对数理统计学中的一些基本概念进行介绍, 而在随后的章节中, 我们将介绍数理统计中几类重要的基本问题, 包括点估计、区间估计、假设检验等. 最后一章将介绍一元线性回归模型, 它可以用来刻画变量间带有随机性的依赖关系.

6.1 总体、样本与统计量

在数理统计学的不同发展阶段, 人们对“**总体**”(population)这个概念有着不同的认识. 起初, 我们把“总体”简单理解为被研究对象的全体, 这是因为数理统计学在发展早期主要关注于如何对有限多个体构成的群体收集数据并刻画该群体的某些定量特征, 例如我们希望知道全国人口的年龄分布情况, 或是调查一所学校学生的心肺功能与体育锻炼时长的联系. 而随着概率论逐步完善并被引入数理统计学作为理论基础, 数理统计学所考虑的研究对象也从有限多个体构成的群体演变与拓展为较为一般的随机现象. 如今在数理统计学中, 我们通常将“总体”理解为一个概率分布, 这个概率分布给出了待研究的随机现象中我们所关心的某个或某些定量特征的统计规律. 习惯上, 我们常用分布的符号或随机变量的符号指代一个总体. 例如, 我们可以直接用一个分布函数 $F(x)$ 来指代一个总体; 又如, 当总体的分布函数 $F(x)$ 存在相应的概率密度函数 $f(x)$ 时, 我们也可以用 $f(x)$ 指代这个总体; 我们也可以用随机变量 X 指代一个总体, 此时 X 所服从的分布即为该总体所对应的概率分布.

在数理统计问题中, 总体的具体信息通常是未知的, 而我们的任务则是通过合适的

试验或观察, 获取关于总体的具有代表性的数据, 并从这些数据对总体的未知信息以及关键性质进行推断. 这些具有代表性的数据被称为总体的**样本** (sample), 而获取这些样本的过程被称为**抽样**. 本讲义中, 我们只考虑最简单的一类样本, 被称为简单随机样本.

定义 6.1. 设某个总体由其分布函数 $F(x)$ 给出. 若随机变量 $X_1, \dots, X_n$ 相互独立且服从 $F(x)$ 所给出的分布, 则称 $X_1, \dots, X_n$ 为总体 $F(x)$ 的一组**简单随机样本**; 正整数 n 被称为该样本的**容量**.

在现实世界中, 简单随机样本通常是通过对某个随机现象进行独立重复观测来获取的, 并且我们获取的实际上是**样本值** $x_1, \dots, x_n$. 但为了对统计推断方法的性能进行推导与分析, 需要将样本作为随机变量处理, 以充分利用概率论提供的各种工具. 此外, 若不做特别说明, 本讲义中的样本均指简单随机样本.

接下来我们介绍统计量的概念. 本讲义中所介绍的数理统计方法, 几乎都离不开统计量的构造与分析.

定义 6.2. 设 $X_1, \dots, X_n$ 为一组容量为 n 的样本, $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 为 n 元函数, 则称随机变量 $g(X_1, \dots, X_n)$ 为一个**统计量** (statistic).

一般来说, 我们要求统计量 $g(X_1, \dots, X_n)$ 的值在总体未知的情况下依然能由样本 $X_1, \dots, X_n$ 的取值算出来, 否则这个统计量就无法用于总体未知的统计推断问题. 这意味着函数 g 不能依赖于总体的具体分布信息.

例 6.1. 设 $X_1, \dots, X_n$ 为某个总体的一组样本. 我们将统计量

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

称为该样本的**样本均值** (sample mean); 将统计量

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

称为该样本的**样本方差** (sample variance). 注意到在样本方差的定义中, 我们用 $n-1$ 而不是 n 作为系数的分母, 这样定义的原因将在第七章中进行解释. 有时我们也会用 $\bar{X}_n$ 与 S_n^2 分别表示样本均值与样本方差, 以强调它们与样本容量 n 的依赖关系.

下面我们考虑样本均值的分布. 当总体为正态分布 $\mathcal{N}(\mu, \sigma^2)$ 时, 利用例 4.13 的结论可得, 样本均值 $\bar{X}$ 服从正态分布 $\mathcal{N}(\mu, \sigma^2/n)$. 而若仅假设总体存在方差, 但样本容量

n 足够大, 则此时由中心极限定理可得 $\bar{X}$ 近似服从正态分布 $\mathcal{N}(\mu, \sigma^2/n)$.

样本方差的概率分布则更复杂一些. 在 6.2 节中, 我们将分析总体为正态分布时样本方差的概率分布. ■

例 6.2. 设 $X_1, \dots, X_n$ 为总体 $F(x)$ 的一组样本. 对任意 $x \in \mathbb{R}$, 定义

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq x\}},$$

也就是说, 我们先统计 $X_1, \dots, X_n$ 中有多少个是小于等于 x 的, 再将其除以样本容量 n 即得到 $\hat{F}_n(x)$. 显然对于给定的 $x \in \mathbb{R}$, $\hat{F}_n(x)$ 为一统计量. 我们将 $\hat{F}_n(x)$, $x \in \mathbb{R}$ 这一族统计量称为**经验分布函数** (empirical distribution function), 取这个名称是因为

$$\mathbb{E}[\hat{F}_n(x)] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[1_{\{X_i \leq x\}}] = F(x),$$

且由强大数定律可得¹, 给定任意 $x \in \mathbb{R}$, 均有

$$\hat{F}_n(x) \xrightarrow{a.s.} F(x). \quad \blacksquare$$

6.2 重要抽样分布

统计量的概率分布被称为**抽样分布**. 本节我们将研究一些与正态总体相关的抽样分布, 这些抽样分布将对本讲义介绍的统计推断方法的理论分析起到重要作用.

6.2.1 χ^2 分布 (卡方分布)

我们称随机变量 X 服从**自由度为 n 的 χ^2 分布** (χ^2 distribution 或 chi-squared distribution), 若 X 为连续型随机变量, 且其概率密度函数为

$$f_X(x) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2}, & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0, \end{cases}$$

¹ (*) 实际上有如下更强的结论成立:

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

换句话说, 经验分布函数 $\hat{F}_n$ 几乎必然地一致收敛于分布函数 F . 该结论被称为 Glivenko-Cantelli 定理.

其中 n 为一正整数. 我们用 $\chi^2(n)$ 或 χ_n^2 来指代自由度为 n 的 χ^2 分布, 并用 $X \sim \chi^2(n)$ 或 $X \sim \chi_n^2$ 表示 X 服从自由度为 n 的 χ^2 分布. 图 6.1 给出了 χ^2 分布概率密度函数的典型图像.




图 6.1: 自由度为 n 的 χ^2 分布概率密度函数图像.

我们马上将看到, χ^2 分布与来自正态总体的样本方差的分布直接相关. 接下来先给出 χ^2 分布自身的一些性质.

命题 6.1. 设 X 服从自由度为 n 的 χ^2 分布, 则其矩母函数为

$$M_X(t) = \left(\frac{1}{1-2t} \right)^{n/2}, \quad t \in \left] -\infty, \frac{1}{2} \right[.$$

其期望为 $\mathbb{E}[X] = n$, 方差为 $\text{Var}(X) = 2n$.

证明. 我们有

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] = \frac{1}{2^{n/2} \Gamma(n/2)} \int_0^{+\infty} e^{tx} \cdot x^{n/2-1} e^{-x/2} dx \\ &= \frac{1}{2^{n/2} \Gamma(n/2)} \int_0^{+\infty} x^{n/2-1} e^{-(1/2-t)x} dx. \end{aligned}$$

不难看出 $t \geq 1/2$ 时 $\mathbb{E}[e^{tX}]$ 不存在. 而当 $t < 1/2$ 时, 有

$$\begin{aligned} M_X(t) &= \left(\frac{1}{1/2-t} \right)^{n/2} \frac{1}{2^{n/2} \Gamma(n/2)} \int_0^{+\infty} u^{n/2-1} e^{-u} du \\ &= \left(\frac{1}{1-2t} \right)^{n/2}, \end{aligned}$$

其中做了换元 $u = (1/2 - t)x$ 并利用了 Γ 函数的定义.

$\mathbb{E}[X]$ 与 $\text{Var}(X)$ 可通过

$$\mathbb{E}[X] = \left. \frac{d}{dt} M_X(t) \right|_{t=0} = n \left(\frac{1}{1-2t} \right)^{n/2+1} \Big|_{t=0} = n$$

以及

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \left. \frac{d^2}{dt^2} M_X(t) \right|_{t=0} - n^2 \\ &= n(n+2) \left(\frac{1}{1-2t} \right)^{n/2+2} \Big|_{t=0} - n^2 = 2n \end{aligned}$$

得到. □

- 推论 6.2.** 1. 设 $X_1, \dots, X_k$ 相互独立且各自服从自由度为 $n_1, \dots, n_k$ 的 χ^2 分布, 则 $Y = \sum_{i=1}^k X_i$ 服从自由度为 $\sum_{i=1}^k n_i$ 的 χ^2 分布.
2. 设 $X_1, \dots, X_n$ 相互独立且均服从一元标准正态分布 $\mathcal{N}(0, 1)$, 则 $Y = \sum_{i=1}^n X_i^2$ 服从自由度为 n 的 χ^2 分布.

证明. 1. 我们考虑 Y 的矩母函数, 由定理 4.11 可得

$$M_Y(t) = \prod_{i=1}^k M_{X_i}(t) = \prod_{i=1}^k \left(\frac{1}{1-2t} \right)^{n_i/2} = \left(\frac{1}{1-2t} \right)^{\frac{1}{2} \sum_{i=1}^k n_i}, \quad \forall t \in \left] -\infty, \frac{1}{2} \right[.$$

故 Y 服从自由度为 $\sum_{i=1}^k n_i$ 的 χ^2 分布.

2. 由例 4.2 的结论可知, 每个 X_i^2 均服从自由度为 1 的 χ^2 分布, 再由第一部分的结论可得 $Y = \sum_{i=1}^n X_i^2$ 服从自由度为 n 的 χ^2 分布. □

在经过上述准备后, 我们介绍定理 6.3, 它给出了 χ^2 分布最重要的应用场合: 刻画来自正态总体的样本方差的分布; 该定理也与下一节介绍的 t 分布的重要性质密切相关. 定理的证明由于牵扯到一些连续型随机向量仿射变换 (推论 4.4) 以及实对阵矩阵正交对角化的知识, 故作为选读内容放在 6.3.1 小节给出, 但我们鼓励学有余力的读者掌握这个证明.

定理 6.3. 设 $X_1, \dots, X_n$ 为正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的一组样本. 令 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 为其样本均值,

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

为其样本方差. 则

1. $\bar{X}$ 与 S^2 相互独立.

2. 随机变量

$$\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$$

服从自由度为 $n-1$ 的 χ^2 分布.

6.2.2 t 分布

我们称随机变量 X 服从**自由度为 n 的 t 分布** (t distribution 或 Student's t distribution²), 若 X 为连续型随机变量, 且其概率密度函数为

$$f_X(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi n} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad x \in \mathbb{R},$$

其中 n 为一正整数. 我们用 $t(n)$ 或 t_n 来指代自由度为 n 的 t 分布, 并用 $X \sim t(n)$ 或 $X \sim t_n$ 表示 X 服从自由度为 n 的 t 分布. 图 6.2 给出了 t 分布概率密度函数的典型图像, 其中 $n = \infty$ 的情形实际上考虑的是 $n \rightarrow \infty$ 时分布 $t(n)$ 的概率密度函数的极限; 可以证明固定 $x \in \mathbb{R}$ 时, 有³

$$\lim_{n \rightarrow \infty} \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi n} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right),$$

这说明分布 $t(n)$ 的概率密度函数在 $n \rightarrow \infty$ 时将逐点收敛于标准正态分布的概率密度函数.

以下定理给出了 t 分布的由来, 其证明作为选读内容将在 6.3.2 小节给出.

定理 6.4. 设 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$ 且 X, Y 相互独立. 不妨设 Y 的值域不包含 0. 则随机变量


$$\frac{X}{\sqrt{Y/n}}$$

² 这里的 Student 来自于统计学家 William Sealy Gosset 使用的一个假名, 他在 1908 年发表于 *Biometrika* 的论文 “The probable error of a mean” 中用 Student 来署名. 之后著名统计学家 Ronald Fisher 在其工作中将这个分布称作 “Student's distribution”, 并用 t 作为相应统计量的符号, “Student's t distribution” 这个名称也就逐渐被广泛接受.

³ 该极限可由斯特林公式

$$\lim_{x \rightarrow +\infty} \frac{\Gamma(x)}{\sqrt{2\pi} x^{x-1/2} e^{-x}} = 1$$

出发证明.

图 6.2: 自由度为 n 的 t 分布概率密度函数图像.

服从自由度为 n 的 t 分布.

将定理 6.4 与定理 6.3 结合, 可得到如下重要推论.

推论 6.5. 设 $X_1, \dots, X_n$ 为正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的一组样本. 令

$$T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}},$$

其中 $\bar{X}$ 为样本均值, S^2 为样本方差. 则统计量 T 服从自由度为 $n-1$ 的 t 分布.

证明. 令 $U = \sqrt{n}(\bar{X} - \mu)/\sigma$, $V = (n-1)S^2/\sigma^2$. 由例 4.13 的结论可得 $U \sim \mathcal{N}(0, 1)$. 接下来利用定理 6.3, 可得 $V \sim \chi_{n-1}^2$ 且 U, V 相互独立. 而

$$\frac{U}{\sqrt{V/(n-1)}} = \frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{\sqrt{S^2/\sigma^2}} = \frac{\bar{X} - \mu}{\sqrt{S^2/n}} = T,$$

故由定理 6.4 可最终得到 $T \sim t(n-1)$. □

需要注意, 推论 6.5 当中我们必须要求 $X_1, \dots, X_n$ 相互独立且均服从正态分布 $\mathcal{N}(\mu, \sigma^2)$; 若样本 $X_1, \dots, X_n$ 不是从正态总体中抽样得来的, 即使 n 非常大, 我们也不能因为中心极限定理而认为推论 6.5 成立.

6.2.3 F 分布

我们称随机变量 X 服从自由度为 (n_1, n_2) 的 F 分布⁴, 若其概率密度函数为

$$f_X(x) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} x^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中 n_1, n_2 均为正整数. 我们用 $F(n_1, n_2)$ 来指代自由度为 (n_1, n_2) 的 F 分布, 并用 $X \sim F(n_1, n_2)$ 表示 X 服从自由度为 (n_1, n_2) 的 F 分布. 图 6.3 给出了 F 分布概率密度函数的典型图像.




图 6.3: F 分布概率密度函数图像.

以下定理给出了 F 分布的由来, 其证明作为选读内容将在 6.3.3 小节给出.

定理 6.6. 设 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, 且 U, V 相互独立. 则随机变量

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度为 (n_1, n_2) 的 F 分布.

由定理 6.6 可看出, 若 $F \sim F(n_1, n_2)$, 则 $F^{-1} \sim F(n_2, n_1)$. 此外, 我们还可得到如下推论:

⁴ F 分布又被称作 Snedecor's F distribution、the Fisher-Snedecor distribution 等. 统计学家 Ronald Fisher 于 1922 年首次给出了 F 分布的形式, 而统计学家 George W. Snedecor 将其用 F 分布命名, 以纪念 Ronald Fisher.

推论 6.7. 设 $X_1, \dots, X_{n_1}$ 为总体 $\mathcal{N}(\mu_1, \sigma_1^2)$ 的一组样本, $Y_1, \dots, Y_{n_2}$ 为总体 $\mathcal{N}(\mu_2, \sigma_2^2)$ 的一组样本, 且 $X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}$ 相互独立. 令

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} \left(X_i - \frac{1}{n_1} \sum_{j=1}^{n_1} X_j \right)^2,$$

$$S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} \left(Y_i - \frac{1}{n_2} \sum_{j=1}^{n_2} Y_j \right)^2.$$

则

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

我们将推论 6.7 的证明留作习题.

6.2.4 抽样分布的上分位数

上面三个小节给出了 χ^2 分布、 t 分布与 F 分布的概率密度函数. 但对于许多数理统计问题, 更常用的其实是这些抽样分布的**上分位数**.

定义 6.3. 设 $F(x)$ 为一连续型分布的分布函数, 其概率密度函数为 $f(x)$. 进一步假设 $f(x)$ 在某个开区间 $I \subseteq \mathbb{R}$ 上严格大于 0 而在该开区间外等于 0. 则对任意 $0 < \alpha < 1$, 我们将满足

$$1 - F(r) = \int_r^{+\infty} f(x) dx = \alpha$$

的实数 r 称作分布 $F(x)$ 的**上 α 分位数** ($1 - \alpha$ quantile). 换句话说, 若随机变量 X 的分布函数为 $F(x)$, 则 X 大于等于上 α 分位数的概率就等于 α .

注 6.1. 对于更加一般的分布也可定义其上分位数, 但在本课程中, 我们只需考虑定义 6.3 所讨论的情形就足够了. ■

不难验证, 若某个分布满足定义 6.3 中所列出的条件, 则它的上 α 分位数是关于 α 的连续且严格单调递减的函数.

下面我们讨论几个重要分布的上分位数.

标准正态分布. 对于标准正态分布 $\mathcal{N}(0, 1)$, 我们将其上 α 分位数记作 z_α , 也就是说 z_α 由如下等式给出:

$$\int_{z_\alpha}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = 1 - \Phi(z_\alpha) = \alpha.$$

若用 Φ^{-1} 表示 Φ 的反函数, 则有

$$z_\alpha = \Phi^{-1}(1 - \alpha).$$

图 6.4a 给出了 z_α 的图示. 不难看出 $\alpha \rightarrow 0^+$ 时 $z_\alpha \rightarrow +\infty$, 以及 $\alpha \rightarrow 1^-$ 时 $z_\alpha \rightarrow -\infty$. 此外, 由 $\Phi(-x) = 1 - \Phi(x)$ 可得

$$z_{1-\alpha} = -z_\alpha, \quad \forall \alpha \in]0, 1[.$$

χ^2 分布. 对于自由度为 n 的 χ^2 分布, 我们将其上 α 分位数记作 $\chi_\alpha^2(n)$. 图 6.4b 给出了 $\chi_\alpha^2(n)$ 的图示. 不难看出 $\alpha \rightarrow 0^+$ 时 $\chi_\alpha^2(n) \rightarrow +\infty$, 以及 $\alpha \rightarrow 1^-$ 时 $\chi_\alpha^2(n) \rightarrow 0$. 此外, 我们通常会将 $\sqrt{\chi_\alpha^2(n)}$ 记作 $\chi_\alpha(n)$.

t 分布. 对于自由度为 n 的 t 分布, 我们将其上 α 分位数记作 $t_\alpha(n)$. 图 6.4c 给出了 $t_\alpha(n)$ 的图示. 不难看出 $\alpha \rightarrow 0^+$ 时 $t_\alpha(n) \rightarrow +\infty$, 以及 $\alpha \rightarrow 1^-$ 时 $t_\alpha(n) \rightarrow -\infty$. 此外, 由分布 $t(n)$ 的概率密度函数的对称性, 可得

$$t_{1-\alpha}(n) = -t_\alpha(n), \quad \forall \alpha \in]0, 1[.$$

经验上, 当 $n \geq 45$ 时, 对于常用的 α 的值, 我们会采用近似 $t_\alpha(n) \approx z_\alpha$, 这是因为 n 足够大时, $t(n)$ 的概率密度函数 (以及分布函数) 可以被标准正态分布的概率密度函数 (以及分布函数) 很好地近似.

F 分布. 对于自由度为 (n_1, n_2) 的 F 分布 $F(n_1, n_2)$, 我们将其上 α 分位数记作 $F_\alpha(n_1, n_2)$. 图 6.4d 给出了 $F_\alpha(n_1, n_2)$ 的图示. 不难看出 $\alpha \rightarrow 0^+$ 时 $F_\alpha(n_1, n_2) \rightarrow +\infty$, 以及 $\alpha \rightarrow 1^-$ 时 $F_\alpha(n_1, n_2) \rightarrow 0$. 此外, F 分布的上分位数满足如下性质:

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}, \quad (6.1)$$

这是因为 $X \sim F(n_1, n_2)$ 时有

$$\begin{aligned} 1 - \alpha &= \mathbb{P}(X > F_{1-\alpha}(n_1, n_2)) \\ &= \mathbb{P}\left(\frac{1}{X} < \frac{1}{F_{1-\alpha}(n_1, n_2)}\right) = 1 - \mathbb{P}\left(\frac{1}{X} > \frac{1}{F_{1-\alpha}(n_1, n_2)}\right), \end{aligned}$$

从而

$$\alpha = \mathbb{P}\left(\frac{1}{X} > \frac{1}{F_{1-\alpha}(n_1, n_2)}\right),$$




图 6.4: 四种抽样分布的上分位数图示.

表 6.1: 部分编程语言中计算上分位数的表达式.

	Python 3	R	MATLAB
z_α	<code>norm.isf(alpha)</code>	<code>qnorm(1-alpha)</code>	<code>norminv(1-alpha)</code>
$\chi_\alpha^2(n)$	<code>chi2.isf(alpha, n)</code>	<code>qchisq(1-alpha, df=n)</code>	<code>chi2inv(1-alpha, n)</code>
$t_\alpha(n)$	<code>t.isf(alpha, n)</code>	<code>qt(1-alpha, df=n)</code>	<code>tinv(1-alpha, n)</code>
$F_\alpha(n_1, n_2)$	<code>f.isf(alpha, n1, n2)</code>	<code>qf(1-alpha, df1=n1, df2=n2)</code>	<code>finv(1-alpha, n1, n2)</code>

注: Python 3 中需安装库 SciPy 并加入导入语句 `from scipy.stats import *`

而由 F 分布的性质可知 $1/X \sim F(n_2, n_1)$, 故上式即意味着 $F_\alpha(n_2, n_1) = 1/F_{1-\alpha}(n_1, n_2)$.

需要指出的是, 以上讨论的几个分布的上 α 分位数通常都不能表示为 α 的初等函数. 我们一般是通过查表或是数值计算的方法来获取这些上 α 分位数的值. 表 6.1 列出了一些常用编程语言中用于计算上分位数的表达式.

6.3 (*) 相关定理的证明

6.3.1 定理 6.3 的证明

令 $Y_i = (X_i - \mu)/\sigma$, 则有 $Y_i \sim \mathcal{N}(0, 1)$ 且 $Y_1, \dots, Y_n$ 相互独立. 记 $\mathbf{Y} = (Y_1, \dots, Y_n)$, 则随机向量 $\mathbf{Y}$ 的联合概率密度函数为

$$\begin{aligned} f_{\mathbf{Y}}(\mathbf{y}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y_i^2}{2}\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{\mathbf{y}^\top \mathbf{y}}{2}\right), \quad \mathbf{y} = (y_1, \dots, y_n) \in \mathbb{R}^n. \end{aligned}$$

下面用 $\mathbf{1}$ 表示分量均为 1 的 n 维 (列) 向量, $\mathbf{I}$ 表示 n 维单位矩阵, 则有

$$\begin{aligned} \frac{(n-1)S^2}{\sigma^2} &= \sum_{i=1}^n \left(Y_i - \frac{1}{n} \sum_{j=1}^n Y_j \right)^2 = \left(\mathbf{Y} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \mathbf{Y} \right)^\top \left(\mathbf{Y} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \mathbf{Y} \right) \\ &= \mathbf{Y}^\top \left(\mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top \right) \mathbf{Y}. \end{aligned} \quad (6.2)$$

为了进一步对上式右端进行化简, 考虑对实对称矩阵 $\mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top$ 进行正交对角化. 不难看出该矩阵的一个特征值为 0, 相应的归一化的特征向量为 $\frac{1}{\sqrt{n}} \mathbf{1}$, 而其它的 $n-1$ 个特征值均为 1. 故有

$$\mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top = \mathbf{Q} \begin{bmatrix} 0 & & \\ & 1 & \\ & & \ddots \\ & & & 1 \end{bmatrix} \mathbf{Q}^\top, \quad \mathbf{Q} = \begin{bmatrix} \frac{1}{\sqrt{n}} \mathbf{1} & \tilde{\mathbf{Q}} \end{bmatrix},$$

其中 $\tilde{\mathbf{Q}} \in \mathbb{R}^{n \times (n-1)}$ 的各列正交归一且均为矩阵 $\mathbf{I} - \frac{1}{n} \mathbf{1} \mathbf{1}^\top$ 特征值 1 的特征向量. 令

$$\mathbf{Z} = \mathbf{Q}^\top \mathbf{Y} = \begin{bmatrix} \frac{1}{\sqrt{n}} \mathbf{1} & \tilde{\mathbf{Q}} \end{bmatrix}^\top \mathbf{Y} = \begin{bmatrix} \sqrt{n} \cdot \bar{X} \\ \tilde{\mathbf{Q}}^\top \mathbf{Y} \end{bmatrix},$$

并将正交对角化的结果代入式 (6.2), 可得

$$\begin{aligned} \frac{(n-1)S^2}{\sigma^2} &= (\mathbf{Q}^\top \mathbf{Y})^\top \begin{bmatrix} 0 & & \\ & 1 & \\ & & \ddots \\ & & & 1 \end{bmatrix} \mathbf{Q}^\top \mathbf{Y} = \mathbf{Z}^\top \begin{bmatrix} 0 & & \\ & 1 & \\ & & \ddots \\ & & & 1 \end{bmatrix} \mathbf{Z} \\ &= \sum_{i=2}^n Z_i^2. \end{aligned}$$

接下来我们需要考察随机向量 $\mathbf{Z}$ 的分布. 由于 $\mathbf{Q}^\top$ 为正交矩阵, 利用推论 4.4 可得 $\mathbf{Z} = \mathbf{Q}^\top \mathbf{Y}$ 的联合概率密度函数为

$$\begin{aligned} f_{\mathbf{Z}}(\mathbf{z}) &= f_{\mathbf{Y}}(\mathbf{Q}\mathbf{z}) \cdot \frac{1}{|\det \mathbf{Q}^\top|} = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{\mathbf{z}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{z}}{2}\right) \\ &= \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{\mathbf{z}^\top \mathbf{z}}{2}\right) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z_i^2}{2}\right), \quad \mathbf{z} = (z_1, \dots, z_n) \in \mathbb{R}^n. \end{aligned}$$

故 $\mathbf{Z}$ 的各个分量 $Z_1, \dots, Z_n$ 相互独立且均服从标准正态分布 $\mathcal{N}(0, 1)$. 由此可立即看出 $\bar{X} = Z_1/\sqrt{n}$ 与 $(n-1)S^2/\sigma^2 = Z_2^2 + \dots + Z_n^2$ 相互独立, 再由推论 6.2 可得 $(n-1)S^2/\sigma^2$ 服从自由度为 $n-1$ 的 χ^2 分布.

6.3.2 定理 6.4 的证明

首先需要分析 $Z = \sqrt{Y/n}$ 的分布. 不难看出, 对任意 $z \leq 0$ 有 $F_Z(z) = \mathbb{P}(Z \leq z) = 0$. 而对任意 $z > 0$, 有

$$F_Z(z) = \mathbb{P}(Y \leq nz^2) = \int_0^{nz^2} \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2} dx,$$

利用导数的链式法则可看出上式右端对任意 $z > 0$ 可导, 其导函数为

$$\frac{1}{2^{n/2} \Gamma(n/2)} (nz^2)^{n/2-1} e^{-nz^2/2} \cdot 2nz = 2 \frac{(n/2)^{n/2}}{\Gamma(n/2)} z^{n-1} \exp\left(-\frac{nz^2}{2}\right).$$

故

$$f_Z(z) = \begin{cases} 2 \frac{(n/2)^{n/2}}{\Gamma(n/2)} z^{n-1} \exp\left(-\frac{nz^2}{2}\right), & z > 0, \\ 0, & z \leq 0. \end{cases}$$

接下来利用习题 4.6 的第二条结论, 可得 $\frac{X}{\sqrt{Y/n}} = X/Z$ 为连续型随机变量, 且其概率密度函数为

$$\begin{aligned} f_{X/Z}(t) &= \int_{-\infty}^{+\infty} |z| f_Z(z) f_X(tz) dz \\ &= \int_0^{+\infty} z \cdot 2 \frac{(n/2)^{n/2}}{\Gamma(n/2)} z^{n-1} \exp\left(-\frac{nz^2}{2}\right) \cdot \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2 z^2}{2}\right) dz \\ &= \frac{\sqrt{2} (n/2)^{n/2}}{\sqrt{\pi} \Gamma(n/2)} \int_0^{+\infty} z^n \exp\left[-\frac{(n+t^2)z^2}{2}\right] dz. \end{aligned}$$

对上式右端做换元 $u = (n+t^2)z^2/2$, 可得

$$\begin{aligned} f_{X/Z}(t) &= \frac{\sqrt{2} (n/2)^{n/2}}{\sqrt{\pi} \Gamma(n/2)} \int_0^{+\infty} \frac{2^{(n-1)/2}}{(n+t^2)^{(n+1)/2}} u^{(n-1)/2} e^{-u} du \\ &= \frac{1}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2} \cdot \Gamma\left(\frac{n+1}{2}\right), \end{aligned}$$

其中最后一步利用了 Γ 函数的定义. 故 $X/Z = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布.

6.3.3 定理 6.6 的证明

为证明定理 6.6, 只需注意到 U/n_1 与 V/n_2 的概率密度函数分别为

$$f_{U/n_1}(x) = \begin{cases} \frac{n_1}{2^{n_1/2} \Gamma(n_1/2)} (n_1 x)^{n_1/2-1} e^{-n_1 x/2}, & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0, \end{cases}$$

$$f_{V/n_2}(x) = \begin{cases} \frac{n_2}{2^{n_2/2} \Gamma(n_2/2)} (n_2 x)^{n_2/2-1} e^{-n_2 x/2}, & \text{若 } x > 0, \\ 0, & \text{若 } x \leq 0, \end{cases}$$

再将它们代入习题 4.6 第二部分的结论, 可得 F 的概率密度 $f_F(z)$ 在 $z > 0$ 时为

$$\begin{aligned} f_F(z) &= \int_{-\infty}^{+\infty} |x| f_{V/n_2}(x) f_{U/n_1}(zx) dx \\ &= \frac{n_1^{n_1/2} n_2^{n_2/2}}{2^{(n_1+n_2)/2} \Gamma(n_1/2) \Gamma(n_2/2)} z^{n_1/2-1} \int_0^{+\infty} x^{(n_1+n_2)/2-1} e^{-(n_1 z + n_2)x/2} dx \\ &= \frac{n_1^{n_1/2} n_2^{n_2/2}}{\Gamma(n_1/2) \Gamma(n_2/2)} z^{n_1/2-1} (n_1 z + n_2)^{-(n_1+n_2)/2} \int_0^{+\infty} t^{(n_1+n_2)/2-1} e^{-t} dt \\ &= \frac{\Gamma((n_1+n_2)/2)}{\Gamma(n_1/2) \Gamma(n_2/2)} \left(\frac{n_1}{n_2}\right)^{n_1/2} z^{n_1/2-1} \left(1 + \frac{n_1}{n_2} z\right)^{-(n_1+n_2)/2}, \end{aligned}$$

而 $z < 0$ 时则有 $f_F(z) = \int_{-\infty}^{+\infty} |x| f_{V/n_2}(x) f_{U/n_1}(zx) dx = 0$. 将 F 的概率密度函数 f_F 与 F 分布的定义进行对照, 即可看出 $F \sim F(n_1, n_2)$.

6.4 习题

习题 6.1. 设 $X_1, \dots, X_n$ 为总体 X 的一组样本, 且 $\mu = \mathbb{E}[X]$ 与 $\sigma^2 = \text{Var}(X)$ 均存在, $n \geq 2$.

1. 试求样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望与方差, 以及样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 的期望.
2. 若 X 的四阶矩存在, 并记 $\nu_k = \mathbb{E}[(X-\mu)^k]$, $k = 3, 4$. 试求 $\text{Var}(S^2)$ 与 $\text{Cov}(\bar{X}, S^2)$.
3. 若 $X \sim \mathcal{N}(\mu, \sigma^2)$, 试求 $\text{Var}(S^2)$ 与 $\text{Cov}(\bar{X}, S^2)$.

提示 你其实并不需要用到上一小题的结论. 考虑利用定理 6.3.

4. 任取 $i \neq j$, 证明 $X_i - \bar{X}$ 与 $X_j - \bar{X}$ 的相关系数为 $-1/(n-1)$.

习题 6.2. 令 $\hat{F}_n(x)$, $x \in \mathbb{R}$ 表示样本容量为 n 时的经验分布函数.

1. 任取实数 x , 试求 $\text{Var}(\hat{F}_n(x))$.

2. 任取不相等的实数 x, y , 试求 $\text{Cov}(\hat{F}_n(x), \hat{F}_n(y))$.

习题 6.3. 设总体 $X \sim \mathcal{N}(\mu, \sigma^2)$, $X_1, \dots, X_n$ 与 $Y_1, \dots, Y_m$ 分别为总体 X 的容量为 n 与 m 的样本, 且 $X_1, \dots, X_n, Y_1, \dots, Y_m$ 相互独立. 令

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{Y} = \frac{1}{m} \sum_{j=1}^m Y_j.$$

现任取 $\epsilon > 0$, 试将概率

$$\mathbb{P}(|\bar{X} - \bar{Y}| > \epsilon)$$

表示为标准正态分布某个上分位数的函数, 并求出 $\sigma^2 = 3, n = 10, m = 15, \epsilon = 0.3$ 时上述概率的值 (保留 3 位小数).

习题 6.4. 1. 设总体 X 服从参数为 β 的指数分布, $X_1, \dots, X_n$ 为总体 X 的一组样本. 证明 $2\beta \sum_{i=1}^n X_i$ 服从自由度为 $2n$ 的 χ^2 分布.

2. 设总体 X 的分布函数 $F(x)$ 在 $\mathbb{R}$ 上连续且严格单调递增, $X_1, \dots, X_n$ 为总体 X 的一组样本. 证明 $-2 \sum_{i=1}^n \ln F(X_i)$ 服从自由度为 $2n$ 的 χ^2 分布.

习题 6.5. 1. 分布 $t(n)$ 在 n 取何值时期望存在? n 取何值时方差存在?

2. 设 $X \sim t(1)$, 证明 $1/X \sim t(1)$.

3. 设 $U, V \sim \mathcal{N}(0, 1)$ 且 U, V 相互独立. 证明

$$U/V, \quad U/|V|, \quad |U|/V$$

均服从自由度为 1 的 t 分布.

习题 6.6. 设 $X_1, \dots, X_n, X_{n+1}$ 为总体 $\mathcal{N}(\mu, \sigma^2)$ 的一组样本, 令

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad T = \frac{X_{n+1} - \bar{X}_n}{\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right]^{1/2}}.$$

试求实数 c 的值使得 cT 服从某个 t 分布, 并确定该 t 分布的自由度.

习题 6.7. 设 $X_1, \dots, X_n$ 为总体 $\mathcal{N}(\mu, \sigma^2)$ 的一组样本, $Y \sim \mathcal{N}(0, \sigma^2)$ 且 $Y, X_1, \dots, X_n$ 相互独立. 在总体参数 μ 与 σ^2 未知的情况下, 试找出一个 $X_1, \dots, X_n, Y$ 的函数 $g(X_1, \dots, X_n, Y)$ 使其服从自由度为 $n-1$ 的 t 分布.

习题 6.8. 证明推论 6.7.

习题 6.9. 设 $X \sim t(n)$. 试求 X^2 的分布.

习题 6.10. 设 $X_1, \dots, X_m, X_{m+1}, \dots, X_n$ 独立同分布且服从正态分布 $\mathcal{N}(0, 1)$. 对任意 $0 < \alpha < 1$, 试求使得等式

$$\mathbb{P}\left(\frac{X_1^2 + \dots + X_m^2}{X_1^2 + \dots + X_n^2} \geq r_\alpha\right) = \alpha$$

成立的实数 r_α . 提示 你需要用 F 分布的上分位数表示 r_α .

第七章 参数估计 I: 点估计

本章以及下一章中, 我们对数理统计中的**参数估计** (parameter estimation) 问题进行介绍. 在参数估计问题中, 我们假设总体的概率分布未知, 但可以由某个参数 θ 所唯一确定, 也就是说, 总体可以表示为形如 $F(x; \theta)$ 的分布函数 (也可以是形如 $p(x; \theta)$ 的分布列或形如 $f(x; \theta)$ 的概率密度函数). 这个未知参数 θ 可以是一个标量, 也可以是一个多维向量, 而不同的参数值 θ 对应于不同的概率分布¹. 我们用 Θ 来表示所有可能的参数取值构成的集合. 现假设我们已经获取了该总体的一组样本, 那么应该如何根据样本的值, 来对这个总体的真实参数值, 或者是真实参数值的某个函数值进行推断?

例 7.1. 假设我们想要用温度传感器测量某个恒温箱中的温度. 由于测量原理以及仪器精度限制, 传感器给出的测量值 X 带有一定的随机性, 它服从期望为真实温度、方差为 σ^2 的正态分布, 其中 σ^2 已经由传感器生产厂家给出. 已知 $\mu_{\min}, \mu_{\max}$ 为恒温箱温度的最小与最大可能取值. 我们希望通过多次测量, 来对真实温度进行推断.

上述问题可以转化为如下参数估计问题: 总体的概率密度函数可以表示为

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R},$$

其中 μ 为未知的参数, 它的取值范围为区间 $[\mu_{\min}, \mu_{\max}]$. 通过多次测量可获得该总体的一组样本 $X_1, \dots, X_n$, 我们希望基于样本 $X_1, \dots, X_n$ 对未知参数 μ 进行估计. ■

例 7.2. 依然考虑例 7.1 的情况, 然而这次我们假设测量值 X 的方差也是未知的, 只知道它大于 0. 这种情况下, 我们需要把期望 μ 与方差 σ^2 均作为未知参数:

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R},$$

¹一些实际问题中可能会出现同一个概率分布可由不同的参数值表示的情形. 本讲义中不对这类情况下的参数估计问题进行讨论.

其中 $\mu \in [\mu_{\min}, \mu_{\max}]$, 而方差的范围可以取为 $\sigma^2 \in [0, +\infty[$. 但另一方面, 若我们只关心真实温度的值, 那么只需要对未知参数 (μ, σ^2) 的函数值 $g(\mu, \sigma^2) = \mu$ 进行估计即可. ■

7.1 点估计问题

本章中, 我们首先介绍参数估计当中的点估计 (point estimation) 问题. 在点估计问题中, 我们希望基于获得的样本数据, 给出未知参数 (或者它的某个函数值) 的单个估计值, 作为参数估计的最终结果. 具体而言, 设总体的未知参数为 $\theta \in \Theta$, 而我们希望对它的一个函数值 $\eta = g(\theta)$ 进行估计, 其中 g 是一个已知的函数². 令 $X_1, \dots, X_n$ 为该总体的一组样本, 则点估计的任务就是构造出一个统计量 $\hat{\eta}(X_1, \dots, X_n)$, 并在获取到样本的具体取值 $x_1, \dots, x_n$ 后将它们代入该统计量中, 把算出的数值 $\hat{\eta}(x_1, \dots, x_n)$ 作为对 $\eta = g(\theta)$ 进行估计的最终结果. 我们将上述点估计过程构造出的统计量 $\hat{\eta}(X_1, \dots, X_n)$ 称为 η 的一个点估计量 (point estimator), 简称为估计量, 而代入具体样本值以后得到的 $\hat{\eta}(x_1, \dots, x_n)$ 则称为 η (关于该组样本值) 的点估计值. 不难看出, 解决点估计问题的核心在于点估计量的设计.

需要注意的是, 由于样本中每个 X_i 都是随机变量, 故点估计量 $\hat{\eta}(X_1, \dots, X_n)$ 本身也是一个随机变量, 且由于 $\hat{\eta}(X_1, \dots, X_n)$ 是一个统计量, 故函数 $\hat{\eta}$ 必须不依赖于未知参数 θ . 在不产生混淆的情况下, 我们也经常直接用 $\hat{\eta}$ 表示点估计量 $\hat{\eta}(X_1, \dots, X_n)$.

例 7.3. 考虑例 7.1 的情形. 为了对总体的期望 μ 进行点估计, 可以取样本期望

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad (7.1)$$

作为 μ 的点估计量. 由弱大数定律可得, 给定任意 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \leq \epsilon) = 1,$$

从而当样本容量 n 足够大时, $\bar{X}_n$ 与真实期望 μ 的偏离程度不超过 ϵ 将是一个大概率事件. 这意味着将样本均值作为期望的点估计量是合理的.

注意到样本均值在方差未知的情况下依然能够构造出来, 因而对于例 7.2 所考虑的分差未知的情形, 我们依然可以将样本均值作为 $\mu = g(\mu, \sigma^2)$ 的一个点估计量. ■

² 若想要对参数 θ 本身进行估计, 令 g 为恒等映射即可.

例 7.4. 考虑例 7.2 的情形, 但假设这次我们也希望对方差 σ^2 进行估计, 以对传感器的测量精度有一个定量上的认识. 此时可以取样本方差

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n),$$

为 σ^2 的点估计量. 由习题 5.3 的结论以及几乎处处收敛与依概率收敛的关系, 可知给定任意 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|S_n^2 - \sigma^2| \leq \epsilon) = 1.$$

从而当样本容量 n 足够大时, 样本方差 S_n^2 与真实方差 σ^2 的偏离程度不超过 ϵ 将是一个大概率事件. 这意味着将样本方差作为方差的点估计量是合理的. ■

例 7.5. 设总体的分布函数为 $F(x; \theta)$, 其中 $\theta \in \Theta$ 为未知参数, 并设对任意的 $\theta \in \Theta$, 分布 $F(x; \theta)$ 的 k 阶矩都存在 (其中 k 为一给定正整数), 并将其记为 $\nu_k(\theta)$. 考虑对 $\nu_k(\theta)$ 的点估计问题, 则可以取样本 k 阶矩

$$\hat{\nu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

作为 $\nu_k(\theta)$ 的点估计量. 由大数定律可知 $\hat{\nu}_k \xrightarrow{P} \nu_k(\theta)$, 故将 $\hat{\nu}_k$ 作为 $\nu_k(\theta)$ 的点估计量是合理的. ■

对于例 7.3、7.4 及 7.5 所考虑的情形, 由于待估计的参数都具有明确的期望的意义, 我们可以自然想到用样本均值、样本方差以及样本矩来构造相应的点估计量. 然而对于更加一般的点估计问题, 其点估计量的设计则往往不会这样简单; 此外, 我们还需要对设计出来的点估计量的性能进行定量上的评估. 接下来, 我们将对点估计问题的频率学派理论与方法进行初步介绍, 并给出矩估计与最大似然估计两种设计点估计量的方法.

7.2 点估计方法的评价

在数理统计学中, 未知参数的统计推断理论被分为频率学派与贝叶斯学派两种. 在频率学派的理论中, 我们将总体的未知参数 θ 作为一个确定性的量来处理, 这种观点下, 我们对未知参数推断所下的结论通常类似于“若未知参数的取值满足某某条件, 那么相应的总体生成我们当前所观测到的样本是大概率/正常事件”. 而在贝叶斯学派的理论

中, 我们将总体的未知参数 θ 作为一个随机变量来处理, 认为它首先服从一个先验分布 (prior distribution), 这种观点下, 我们对未知参数推断所下的结论通常类似于“在给定的观测到的样本数据的条件下, 未知参数以很大的概率满足某某条件”. 本课程中, 我们将主要关注频率学派的理论.

7.2.1 点估计的偏差与均方误差; 无偏性与有效性

在频率学派的理论中, 对小样本情形下点估计量的评价主要是以偏差和均方误差为基础. 简单起见, 我们假设未知参数 θ 是一个实数 (标量), 且它就是我们要估计的参数, 但相关概念不难推广到对未知参数的函数值 $g(\theta)$ 进行估计的情况.

定义 7.1. 设总体的分布函数为 $F(x; \theta)$, 其中 $\theta \in \Theta$ 为未知参数, 并设 $\hat{\theta}: \mathbb{R}^n \rightarrow \mathbb{R}$ 为一个 n 元函数. 现任取 $\theta \in \Theta$, 并设 $X_1, \dots, X_n$ 为总体 $F(x; \theta)$ 的一组样本, 令

$$b_{\theta}(\hat{\theta}) = \mathbb{E}[\hat{\theta}(X_1, \dots, X_n)] - \theta, \quad (7.2)$$

$$\text{MSE}_{\theta}(\hat{\theta}) = \mathbb{E}[(\hat{\theta}(X_1, \dots, X_n) - \theta)^2] \quad (7.3)$$

我们称 $b_{\theta}(\hat{\theta})$ 为点估计量 $\hat{\theta}(X_1, \dots, X_n)$ 关于 θ 的**偏差** (bias), $\text{MSE}_{\theta}(\hat{\theta})$ 为点估计量 $\hat{\theta}(X_1, \dots, X_n)$ 关于 θ 的**均方误差** (mean square error, MSE).

需要注意, 给定点估计量 $\hat{\theta}(X_1, \dots, X_n)$ 后, 它的偏差 $b_{\theta}(\hat{\theta})$ 与均方误差 $\text{MSE}_{\theta}(\hat{\theta})$ 都与 θ 的取值有关; 在针对给定的 $\theta \in \Theta$ 计算 $b_{\theta}(\hat{\theta})$ 与 $\text{MSE}_{\theta}(\hat{\theta})$ 时, 相应的样本 $X_1, \dots, X_n$ 则是从参数为 θ 的总体 $F(x; \theta)$ 中抽样而来的. 之所以需要考虑任意 $\theta \in \Theta$ 所对应的偏差与均方误差, 是因为我们并不知道真实的总体对应的是哪个 θ , 保险起见我们需要考虑所有可能的参数取值, 并希望点估计量在参数 $\theta \in \Theta$ 任取的情况下都能具有较优的性能. 为了强调样本 $X_1, \dots, X_n$ 与参数 θ 的依赖关系, 我们有时会用如下形式的记号

$$\mathbb{E}_{\theta}[\hat{\theta}(X_1, \dots, X_n)] \quad \text{与} \quad \mathbb{P}_{\theta}(\hat{\theta}(X_1, \dots, X_n) \in B)$$

来强调样本 $X_1, \dots, X_n$ 来自于参数为 θ 的总体.

直观上看, 均方误差通常是评价点估计量好坏的一个比较恰当的定量指标; 可以认为点估计量的均方误差越小, 则给出的估计值越集中于真实值. 不难验证点估计量 $\hat{\theta}$ 的均方误差满足如下等式:

$$\text{MSE}_{\theta}(\hat{\theta}) = [b_{\theta}(\hat{\theta})]^2 + \text{Var}_{\theta}(\hat{\theta}), \quad \forall \theta \in \Theta,$$

其中 $\text{Var}_\theta(\hat{\theta})$ 表示样本 $X_1, \dots, X_n$ 来自于参数为 θ 的总体时 $\hat{\theta}(X_1, \dots, X_n)$ 的方差. 该等式被称为均方误差的**偏差—方差分解** (bias-variance decomposition). 上式意味着点估计量的均方误差由偏差与方差两部分组成. 理想情况下, 当我们设计点估计量时, 我们希望能够同时让偏差 $b_\theta(\hat{\theta})$ 与方差 $\text{Var}_\theta(\hat{\theta})$ 对任意的 $\theta \in \Theta$ 都取得足够小, 然而在许多实际问题中, 点估计量的偏差 $b_\theta(\hat{\theta})$ 与方差 $\text{Var}_\theta(\hat{\theta})$ 之间通常会存在一定冲突, 当我们把一个量取得非常小的时候, 可能导致另一个量出现明显的增大. 这意味着, 如果我们以均方误差作为评价点估计量好坏的指标, 那么为了对每个可能的 $\theta \in \Theta$ 均取得足够小的均方误差, 我们通常需要在偏差与方差之间进行权衡.

然而, 在经典的频率学派点估计理论中, 对于偏差恒为 0 这种情形的点估计量的研究占据了比较重要的位置.

定义 7.2. 考虑定义 7.1 的设定. 若对于任意的 $\theta \in \Theta$, 点估计量 $\hat{\theta}(X_1, \dots, X_n)$ 关于 θ 的偏差都等于 0, 即

$$b_\theta(\hat{\theta}) = 0, \quad \forall \theta \in \Theta,$$

则称 $\hat{\theta}(X_1, \dots, X_n)$ 是 θ 的一个**无偏估计量** (unbiased estimator).

例 7.6. 设总体的未知参数为 $\theta \in \Theta$, $\mu(\theta)$ 与 $\sigma^2(\theta)$ 分别给出了参数为 θ 时总体相应的期望与方差. 现考虑样本 $X_1, \dots, X_n$ 的样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \text{其中 } \bar{X} = \frac{1}{n} \sum_{j=1}^n X_j,$$

记 $Y_i = X_i - \mu(\theta)$, $\bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j = \bar{X} - \mu(\theta)$, 则对任意 $\theta \in \Theta$, 有

$$\begin{aligned} \mathbb{E}_\theta[S^2] &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}_\theta[(Y_i - \bar{Y})^2] \\ &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}_\theta[(Y_i - \bar{Y}) Y_i] \\ &= \frac{1}{n-1} \sum_{i=1}^n \left(\mathbb{E}_\theta[Y_i^2] - \frac{1}{n} \sum_{j=1}^n \mathbb{E}_\theta[Y_j Y_i] \right) \\ &= \frac{1}{n-1} \cdot n \left(\sigma^2(\theta) - \frac{1}{n} \sigma^2(\theta) \right) = \sigma^2(\theta), \end{aligned}$$

其中第二步利用了 $\text{Cov}(Y_i - \bar{Y}, \bar{Y}) = 0$, 它来自于习题 4.10 的结论; 第四步则是由于 Y_i 与 Y_j 在 $i \neq j$ 时相互独立, 以及 $\mathbb{E}_\theta[Y_i] = 0$. 因此样本方差 S^2 是总体方差 $\sigma^2(\theta)$ 的一个无偏估计量; 这也是样本方差当中用 $n-1$ 而非 n 作为系数的分母的原因之一. ■

根据均方误差的偏差—方差分解, 在限制点估计量的偏差恒为零以后, 其点估计量的方差即等于它的均方误差:

$$\text{MSE}_\theta(\hat{\theta}) = \text{Var}_\theta(\hat{\theta}).$$

因此在对两个无偏估计量的好坏进行比较时, 我们就可以考虑以它们的方差为依据. 不过, 由于点估计量的方差依赖于参数 θ 的值, 而参数的真实值又是未知的, 因此在比较两个点估计量的方差时, 我们通常需要考虑所有可能的参数 θ 的取值. 这就引入了如下有效性的定义.

定义 7.3. 设 $\hat{\theta}_1(X_1, \dots, X_n)$ 与 $\hat{\theta}_2(X_1, \dots, X_n)$ 为参数 θ 的两个无偏估计量. 若

$$\text{Var}_\theta(\hat{\theta}_1) \leq \text{Var}_\theta(\hat{\theta}_2)$$

对任意 $\theta \in \Theta$ 都成立, 且存在某个 $\theta \in \Theta$ 使得上述不等式成为严格不等式, 则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ **有效** ($\hat{\theta}_1$ is more efficient than $\hat{\theta}_2$).

基于以上无偏估计量与有效性的定义, 频率学派的统计学家们进一步发展了一套关于一致最小方差无偏估计量(uniformly minimum variance unbiased estimator, UMVUE)的理论³. 这套理论从数学的角度上看是比较优美的, 这也是无偏估计量在经典的频率学派点估计理论中占据重要位置的原因之一. 但需要指出的是, 无偏性并不是点估计量所必须满足的性质. 对于某些具体问题, 无偏性可能是必要的, 或是能带来一些额外的优势(到底是何种优势则需要具体问题具体分析); 但对于其它一些情形, 适当程度地放弃无偏性可能会换来更小的均方误差.

例 7.7. (*) 考虑一个对总体 X 的未知参数 θ 进行在线点估计的场景: 假设在每个离散时刻 $t \in \mathbb{N}_+$, 我们能够从总体 X 中获取一组新的样本 $X_1^t, \dots, X_n^t$. 考虑如下点估计流程: 首先构造一个 n 元函数 $g: \mathbb{R}^n \rightarrow \mathbb{R}$, 并做初始化 $\hat{\theta}_0 = 0$. 接下来在每个 t 时刻, 令

$$\hat{\theta}_t = \frac{t-1}{t}\hat{\theta}_{t-1} + \frac{1}{t}g(X_1^t, \dots, X_n^t),$$

并将 $\hat{\theta}_t$ 作为 t 时刻参数 θ 的点估计结果. 不难看出上式实际上是对 $g(X_1^\tau, \dots, X_n^\tau)$, $\tau = 1, \dots, t$ 在线求平均的过程, 从而

$$\hat{\theta}_t = \frac{1}{t} \sum_{\tau=1}^t g(X_1^\tau, \dots, X_n^\tau).$$

³ 感兴趣的读者可参阅 [16-18] 等更高阶的数理统计教材.

若 $\mathbb{E}_\theta[g(X_1, \dots, X_n)]$ 存在, 则由大数定律可得

$$\hat{\theta}_t \xrightarrow{a.s.} \mathbb{E}_\theta[g(X_1, \dots, X_n)],$$

其中 $X_1, \dots, X_n$ 相互独立且与 X 同分布. 不难看出在上述设定下, $g(X_1, \dots, X_n)$ 的无偏性将是一个合理的要求, 否则 $\hat{\theta}_t$ 与 θ 真值之间的差无法通过让更新轮次 t 足够大而接近于 0. ■

例 7.8. (*) 设总体 X 服从几何分布

$$\mathbb{P}_\theta(X = k) = (1 - \theta)^{k-1}\theta, \quad k = 1, 2, \dots,$$

其中 θ 为未知参数, 其取值范围为 $]0, 0.5]$. 现假设 X_1 为来自该总体的一个容量为 1 的样本, 我们希望设计一个 θ 的点估计量 $\hat{\theta}(X_1)$. 由于 X_1 的取值为正整数, 我们只需考虑函数 $\hat{\theta}$ 在自变量为正整数时的取值即可.

若要求 $\hat{\theta}(X_1)$ 是无偏的, 则有

$$\mathbb{E}_\theta[\hat{\theta}(X_1)] = \sum_{k=1}^{\infty} \hat{\theta}(k) \cdot (1 - \theta)^{k-1}\theta = \theta, \quad \forall \theta \in]0, 0.5],$$

即

$$1 = \sum_{k=0}^{\infty} \hat{\theta}(k+1) \cdot (1 - \theta)^k, \quad \forall \theta \in]0, 0.5].$$

可以证明满足上式的 $\hat{\theta}$ 只能是

$$\hat{\theta}(k) = \begin{cases} 1, & \text{若 } k = 1, \\ 0, & \text{若 } k = 2, 3, \dots \end{cases}$$

因此对 θ 的无偏估计量只可能是

$$\hat{\theta}(X_1) = 1_{\{X_1=1\}},$$

也就是说 $X_1 = 1$ 时点估计的值为 1, 而 X_1 取其它值时点估计的值为 0, 从而无偏估计量的均方误差为

$$\mathbb{E}_\theta[(1_{X_1=1} - \theta)^2] = (1 - \theta)^2 \cdot \theta + \sum_{k=2}^{\infty} \theta^2 \cdot (1 - \theta)^{k-1}\theta = \theta(1 - \theta).$$

然而, 如果考虑如下点估计量

$$\hat{\theta}(X_1) = (1 + X_1)^{-1},$$




图 7.1: 点估计量 $1_{\{X_1=1\}}$ 与 $(1 + X_1)^{-1}$ 估计几何分布参数 θ 的均方误差曲线.

则它的均方误差为

$$\mathbb{E}_\theta \left[((1 + X_1)^{-1} - \theta)^2 \right] = \sum_{k=1}^{\infty} ((1 + k)^{-1} - \theta)^2 \cdot (1 - \theta)^{k-1} \theta.$$

上式右端的求和没有初等表达式, 需要用特殊函数来表示, 但通过理论分析可以证明, 当 $0 < \theta \leq 0.5$ 时, 上式右端总是小于 $\theta(1 - \theta)$. 图 7.1 展示了两种点估计量的均方误差在 $0 < \theta \leq 0.5$ 时的值. 这说明, 若以均方误差作为点估计量优劣的评价指标, 则对于所考虑的参数范围 $0 < \theta \leq 0.5$, 有偏的估计量 $(1 + X_1)^{-1}$ 均优于无偏估计量 $1_{\{X_1=1\}}$.

本例部分取自 [18] 的 Example 8.1. ■

注 7.1. 虽然经典的频率学派理论中关于一致最小方差无偏估计的理论方法在实际问题中应用有限, 但它们为大样本情形下点估计量的设计与分析, 特别是最大似然估计法的性能分析建立了部分基础. ■

7.2.2 点估计的相合性

点估计的相合性考虑的是样本容量逐渐增大时, 一套点估计方法能否给出收敛于真实参数值的估计量. 换句话说, 我们考虑的不再是单个点估计量 $\hat{\theta}$, 而是考虑一系列点估计量 $\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(n)}, \dots$, 其中每个 $\hat{\theta}^{(n)} = \hat{\theta}^{(n)}(X_1, \dots, X_n)$ 给出的是样本容量为 n 时的点估计量, 我们希望 $n \rightarrow \infty$ 时, 点估计量 $\hat{\theta}^{(n)}$ 作为随机变量能够 (在某种方式下) 收敛于真实参数值 θ .

定义 7.4. 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(n)}, \dots$ 为参数 θ 的一系列点估计量, 其中

$\hat{\theta}^{(n)} = \hat{\theta}^{(n)}(X_1, \dots, X_n)$. 若对任意的 $\theta \in \Theta$ 均有 $\hat{\theta}^{(n)} \xrightarrow{P} \theta$, 即

$$\lim_{n \rightarrow \infty} \mathbb{P}_{\theta} \left(|\hat{\theta}^{(n)}(X_1, \dots, X_n) - \theta| \leq \epsilon \right) = 1$$

对任意 $\epsilon > 0$ 以及 $\theta \in \Theta$ 均成立, 则称这列点估计量是**相合的** (consistent).

与无偏性不同, 相合性是对一套点估计方法 (也就是对任意样本容量 n 构造点估计量 $\hat{\theta}^{(n)}$ 的方法) 的最基本要求. 如果一套点估计方法没有相合性, 那么直观上看, 无论样本容量有多大, 我们也难以把未知参数估计到任意高的精度, 这样的点估计方法对于大多数问题都是不可取的.

7.3 矩估计与最大似然估计

本节中我们介绍两种常用的点估计方法: 矩估计法与最大似然估计法.

7.3.1 矩估计

设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$, 其中 $\theta_1, \dots, \theta_k$ 表示总体的 k 个未知的标量参数, 且 $(\theta_1, \dots, \theta_k)$ 的所有可能取值构成集合 Θ . 进一步假设对任意 $(\theta_1, \dots, \theta_k) \in \Theta$, 相应的概率分布 $F(x; \theta_1, \dots, \theta_k)$ 的 k 阶矩存在, 并记

$$\mathbb{E}_{\theta_1, \dots, \theta_k} [X^j] = \mu_j(\theta_1, \dots, \theta_k), \quad \forall j = 1, \dots, k.$$

换句话说, 函数 $\mu_j : \Theta \rightarrow \mathbb{R}$ 将任一组可能的参数 $(\theta_1, \dots, \theta_k)$ 映射为相应分布的 j 阶矩. 现在, 暂时假设我们通过某种手段, 获得了总体 X 的前 k 阶矩的精确值, 并将它们分别记为 $m_1, m_2, \dots, m_k$, 则可知未知参数 $\theta_1, \dots, \theta_k$ 满足如下 k 个方程:

$$\begin{aligned} m_1 &= \mu_1(\theta_1, \dots, \theta_k), \\ m_2 &= \mu_2(\theta_1, \dots, \theta_k), \\ &\vdots \\ m_k &= \mu_k(\theta_1, \dots, \theta_k). \end{aligned} \tag{7.4}$$

那么当映射

$$(\theta_1, \dots, \theta_k) \mapsto (\mu_1(\theta_1, \dots, \theta_k), \dots, \mu_k(\theta_1, \dots, \theta_k))$$

是一个从 Θ 到 $\mathbb{R}^k$ 的单射时, 通过求解方程组 (7.4), 我们即可求出未知参数 $\theta_1, \dots, \theta_k$ 的值.

上述求解过程假定我们已经得到了总体 X 的前 k 阶矩的值. 通常情况下, 矩的求解需要事先知道 X 的具体分布情况, 但若我们获得了总体 X 的一组容量足够大的样本 $X_1, \dots, X_n$, 那么 X 的 j 阶矩就可以用样本做出近似估计:

$$\begin{aligned} m_1 &\approx \frac{1}{n} \sum_{i=1}^n X_i, \\ m_2 &\approx \frac{1}{n} \sum_{i=1}^n (X_i)^2, \\ &\vdots \\ m_k &\approx \frac{1}{n} \sum_{i=1}^n (X_i)^k. \end{aligned}$$

我们通常把 $\frac{1}{n} \sum_{i=1}^n (X_i)^j$ 称作 j 阶样本矩. 矩估计方法, 就是指将 (7.4) 当中前 k 阶矩的精确值替换为相应的样本矩, 再求解相应的方程组:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i &= \mu_1(\hat{\theta}_1, \dots, \hat{\theta}_k), \\ \frac{1}{n} \sum_{i=1}^n (X_i)^2 &= \mu_2(\hat{\theta}_1, \dots, \hat{\theta}_k), \\ &\vdots \\ \frac{1}{n} \sum_{i=1}^n (X_i)^k &= \mu_k(\hat{\theta}_1, \dots, \hat{\theta}_k). \end{aligned} \tag{7.5}$$

上述方程组的解 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 分别给出了未知参数 $\theta_1, \dots, \theta_k$ 的点估计量.

例 7.9. 设总体 X 服从区间 $[\theta_1, \theta_1 + \theta_2]$ 上的均匀分布, 其中 $\theta_1 \in \mathbb{R}$ 以及 $\theta_2 > 0$ 为未知参数. 则有

$$\begin{aligned} \mu_1(\theta_1, \theta_2) &= \mathbb{E}_{\theta_1, \theta_2}[X] = \theta_1 + \frac{\theta_2}{2}, \\ \mu_2(\theta_1, \theta_2) &= \mathbb{E}_{\theta_1, \theta_2}[X^2] = \left(\theta_1 + \frac{\theta_2}{2}\right)^2 + \frac{\theta_2^2}{12}. \end{aligned}$$

那么当 $X_1, \dots, X_n$ 为总体 X 的一组样本时, 根据矩估计方法的步骤, 可得 θ_1 与 θ_2 的矩估计量 $\hat{\theta}_1, \hat{\theta}_2$ 为如下方程的解:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n X_i &= \mu_1(\hat{\theta}_1, \hat{\theta}_2) = \hat{\theta}_1 + \frac{\hat{\theta}_2}{2}, \\ \frac{1}{n} \sum_{i=1}^n (X_i)^2 &= \mu_2(\hat{\theta}_1, \hat{\theta}_2) = \left(\hat{\theta}_1 + \frac{\hat{\theta}_2}{2}\right)^2 + \frac{\hat{\theta}_2^2}{12}. \end{aligned}$$

由此可解得

$$\begin{aligned}\hat{\theta}_2 &= 2\sqrt{3} \left[\frac{1}{n} \sum_{i=1}^n (X_i)^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \right]^{1/2}, \\ \hat{\theta}_1 &= \frac{1}{n} \sum_{i=1}^n X_i - \frac{\hat{\theta}_2}{2}.\end{aligned}$$

基于弱大数定律可以证明, 当方程组 (7.4) 具有唯一解, 且该唯一解是 $(m_1, \dots, m_k)$ 的连续函数时, 矩估计具有相合性, 也就是说当样本容量趋于无穷大时, 矩估计量依概率收敛于真实的参数值⁴.

7.3.2 最大似然估计

在最大似然估计法中, 我们首先需要引入样本的似然函数, 它在数值上等于样本 $(X_1, \dots, X_n)$ 的联合分布列或联合概率密度函数, 但我们把它看作是给定样本观测值时关于未知参数的一个函数.

定义 7.5. 设总体 X 的分布列或概率密度函数为 $f(x; \theta_1, \dots, \theta_k)$, 其中 $\theta_1, \dots, \theta_k$ 表示 k 个未知参数, 且 $(\theta_1, \dots, \theta_k)$ 的所有可能取值构成集合 Θ . 对任意正整数 n 以及 $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$, 定义简单随机样本的**似然函数** (likelihood function) $L(\cdot; \mathbf{x}) : \Theta \rightarrow [0, +\infty[$ 为

$$L(\theta_1, \dots, \theta_k; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_k).$$

许多情况下, 我们还会用到**对数似然函数** (log likelihood function)

$$\ln L(\theta_1, \dots, \theta_k; \mathbf{x}) = \sum_{i=1}^n \ln f(x_i; \theta_1, \dots, \theta_k).$$

最大似然估计法的基本步骤如下: 给定样本容量 n , 对每个 $\mathbf{x} = (x_1, \dots, x_n)$, 求解使得似然函数 $L(\theta_1, \dots, \theta_k; \mathbf{x})$ 取最大值的点⁵:

$$(\hat{\theta}_1(\mathbf{x}), \dots, \hat{\theta}_k(\mathbf{x})) = \arg \max_{(\theta_1, \dots, \theta_k) \in \Theta} L(\theta_1, \dots, \theta_k; \mathbf{x})$$

⁴ 该结果的严格表述以及证明见选读内容 7.3.3 小节.

⁵ 若 Θ 中存在多个点使得似然函数取到最大值, 则在其中任取一个即可. 若似然函数不存在最大值点, 则称 θ 的最大似然估计量不存在.

接下来我们将样本 $X_1, \dots, X_n$ 代入上式给出的函数 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 当中, 即可对每一个参数 θ_j 得到一个点估计量 $\hat{\theta}_j(X_1, \dots, X_n)$. 我们将这个点估计量称为**最大似然估计量** (maximum likelihood estimator). 由于 $x \mapsto \ln x$ 是单调递增的函数, 在求解最大似然估计量时, 我们也可以对对数似然函数 $\ln L(\theta_1, \dots, \theta_k; \mathbf{x})$ 进行最大化, 而且许多情况下对数似然函数的最大值点更好求解. 特别是, 当 Θ 为 $\mathbb{R}^k$ 的开集且对数似然函数在 Θ 上可微时, 我们可以通过求解方程组

$$\frac{\partial \ln L(\theta_1, \dots, \theta_k; \mathbf{x})}{\partial \theta_j} = 0, \quad j = 1, \dots, k \quad (7.6)$$

来得到对数似然函数的驻点, 而后从这些驻点中进一步找出最大值点. 方程 (7.6) 经常被称为**对数似然方程** (log-likelihood equation).

例 7.10. 设总体 X 服从一元正态分布, 其期望 $\mu \in \mathbb{R}$ 与方差 $\sigma^2 > 0$ 均未知. 则相应的似然函数为

$$\begin{aligned} L(\mu, \sigma^2; \mathbf{x}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right), \end{aligned}$$

对数似然函数为

$$\ln L(\mu, \sigma^2; \mathbf{x}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2} \ln \sigma^2 - \frac{n}{2} \ln(2\pi).$$

为了求解对数似然函数的最大值点, 我们计算对数似然函数分别对 μ 与 σ^2 的偏导数并令它们等于零, 可得到如下方程组:

$$\begin{aligned} 0 &= \frac{\partial \ln L(\mu, \sigma^2; \mathbf{x})}{\partial \mu} = \frac{1}{\sigma^2} \left(\sum_{i=1}^n x_i - n\mu \right), \\ 0 &= \frac{\partial \ln L(\mu, \sigma^2; \mathbf{x})}{\partial (\sigma^2)} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2}. \end{aligned}$$

解上述方程组, 可得

$$\begin{aligned} \hat{\mu}(\mathbf{x}) &= \frac{1}{n} \sum_{i=1}^n x_i, \\ \hat{\sigma}^2(\mathbf{x}) &= \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}(\mathbf{x}))^2. \end{aligned}$$

可以证明, 上式给出的 $\hat{\mu}(\mathbf{x})$ 与 $\hat{\sigma}^2(\mathbf{x})$ 的确使得对数似然函数取到最大值. 故期望 μ 与方差 σ^2 的最大似然估计量为

$$\begin{aligned}\hat{\mu}(X_1, \dots, X_n) &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}, \\ \hat{\sigma}^2(X_1, \dots, X_n) &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2.\end{aligned}$$

可以看到, 期望的最大似然估计量就是样本均值, 但方差的最大似然估计量与样本方差相差一个因子 $(n-1)/n$. ■

例 7.11. 设总体 X 服从区间 $[0, \theta]$ 上的均匀分布, 其中 $\theta > 0$ 为未知参数. 令 $X_1, \dots, X_n$ 为总体 X 的一组样本, 我们希望求 θ 的最大似然估计量.

由题设不难得到似然函数为

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \left(\frac{1}{\theta} \cdot \mathbf{1}_{x_i \leq \theta}(\theta) \right) = \begin{cases} \theta^{-n}, & \text{若 } \theta \geq \max\{x_1, \dots, x_n\}, \\ 0, & \text{其它情况,} \end{cases}$$

其中 $\mathbf{1}_{x_i \leq \theta}(\theta)$ 在 $x_i \leq \theta$ 时为 1 而在其它情况下为 0. 由于 $\theta \mapsto \theta^{-n}$ 严格单调递减, 故当 $\theta = \max\{x_1, \dots, x_n\}$ 时似然函数取到最大值, 因而 θ 的最大似然估计量为

$$\hat{\theta} = \max\{X_1, \dots, X_n\}. \quad \blacksquare$$

最大似然估计法具有一个比较直观的解释: 当我们收集到样本数据后, 那么一般来说, 与其它可能的参数值相比, 真实参数值应当更有利于产生这些数据, 或者说真实参数值应当使得产生这些数据的可能性 (近似) 达到最大. 然而, 真正让最大似然估计法被广为接受的原因, 还是它在大样本情形下所具有的良好估计性能. 可以证明, 在较为宽松的条件下, 最大似然估计具有如下性质 (表述并不十分严格):

1. 最大似然估计具有相合性.
 2. 与其它具有相合性的点估计方法相比, 最大似然估计法在大样本极限时具有最小的均方误差.
 3. 在大样本极限时, 最大似然估计量的分布趋于一个期望为真实参数值的正态分布.
- 我们将在选读内容 7.3.3 小节中给出一种简单情形下相合性的证明. 后两条性质的严格表述与证明可参阅 [17] 第 7.3 节.

注 7.2. 本节中, 我们针对一些形式比较简单的参数化分布族推导了最大似然估计量的表达式. 然而, 对于稍微复杂一些的参数化分布族, 一般是没有办法求出对数似然函数最大值点的闭式表达式的, 此时我们就需要借助最优化算法迭代求解最大似然估计值. 常见的可用于求解最大似然估计值的最优化算法包括梯度上升法 (gradient ascent method)、共轭梯度法 (conjugate gradient method)、BFGS 算法 (Broyden–Fletcher–Goldfarb–Shanno algorithm) 等 (参见 [19]), 以及针对隐变量模型的期望–最大化算法 (expectation–maximization algorithm) 等 (参见 [20]); 当矩估计量可以求解时, 我们也会考虑用矩估计值作为最优化算法迭代的初始点. 许多情况下对数似然函数不是凹函数, 这进一步增加了最大似然估计的难度, 需要采取一些额外技术 (例如多次随机初始化) 进行近似求解. ■

7.3.3 (*) 矩估计与最大似然估计的相合性证明

我们首先证明矩估计的相合性, 它实际上是如下引理的直接推论:

引理 7.1. 设 $\mathcal{M}$ 为 $\mathbb{R}^k$ 的开子集, $(c_1, \dots, c_k)$ 为 $\mathcal{M}$ 内的一个点, $g: \mathbb{R}^k \rightarrow \mathbb{R}$ 为一函数, 且在 $\mathcal{M}$ 上连续. 若

$$X_{1,1}, X_{1,2}, \dots, X_{1,n}, \dots$$

$$X_{2,1}, X_{2,2}, \dots, X_{2,n}, \dots$$

$$\vdots$$

$$X_{k,1}, X_{k,2}, \dots, X_{k,n}, \dots$$

为 k 列随机变量, 且固定任意 $j = 1, \dots, k$, 均有

$$X_{j,n} \xrightarrow{P} c_j, \quad n \rightarrow \infty,$$

则

$$g(X_{1,n}, \dots, X_{k,n}) \xrightarrow{P} g(c_1, \dots, c_k), \quad n \rightarrow \infty.$$

证明. 任取 $\epsilon > 0$ 与 $\epsilon' > 0$. 由于 g 是开集 $\mathcal{M}$ 上的连续函数, 故存在 $\delta > 0$ 使得对任意的 $(x_1, \dots, x_k) \in \mathbb{R}^k$, 有

$$\max_{1 \leq j \leq k} |x_j - c_j| \leq \delta \implies |g(x_1, \dots, x_k) - g(c_1, \dots, c_k)| \leq \epsilon,$$

从而对任意 $n \in \mathbb{N}_+$, 有

$$\mathbb{P}\left(\max_{1 \leq j \leq k} |X_{j,n} - c_j| \leq \delta\right) \leq \mathbb{P}(|g(X_{1,n}, \dots, X_{k,n}) - g(c_1, \dots, c_k)| \leq \epsilon). \quad (7.7)$$

另一方面, 由弱大数定律可得, 对任意 $j = 1, \dots, k$, 均有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_{j,n} - c_j| > \delta) = 0, \quad \forall j = 1, \dots, k.$$

故存在正整数 N , 使得 $n > N$ 时均有

$$\mathbb{P}(|X_{j,n} - c_j| > \delta) \leq \frac{\epsilon'}{k}, \quad \forall j = 1, \dots, k.$$

因而 $n > N$ 时有

$$\begin{aligned} \mathbb{P}\left(\max_{1 \leq j \leq k} |X_{j,n} - c_j| > \delta\right) &= \mathbb{P}\left(\bigcup_{j=1}^k \{|X_{j,n} - c_j| > \delta\}\right) \\ &\leq \sum_{j=1}^k \mathbb{P}(|X_{j,n} - c_j| > \delta) \leq k \cdot \frac{\epsilon'}{k} = \epsilon'. \end{aligned}$$

将以上结果代入式 (7.7), 可得 $n > N$ 时有

$$\begin{aligned} \mathbb{P}(|g(X_{1,n}, \dots, X_{k,n}) - g(c_1, \dots, c_k)| \leq \epsilon) &\geq 1 - \mathbb{P}\left(\max_{1 \leq j \leq k} |X_{j,n} - c_j| > \delta\right) \\ &\geq 1 - \epsilon'. \end{aligned}$$

由 $\epsilon' > 0$ 的任意性, 可得

$$\lim_{n \rightarrow \infty} \mathbb{P}(|g(X_{1,n}, \dots, X_{k,n}) - g(c_1, \dots, c_k)| \leq \epsilon) = 1,$$

再由 $\epsilon > 0$ 的任意性可得 $n \rightarrow \infty$ 时有 $g(X_{1,n}, \dots, X_{k,n}) \xrightarrow{P} g(c_1, \dots, c_k)$. □

定理 7.2 (矩估计的相合性). 设总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_k)$, 其中未知参数 $(\theta_1, \dots, \theta_k)$ 的所有可能取值构成集合 Θ , 且对每个 $(\theta_1, \dots, \theta_k) \in \Theta$, 分布 $F(x; \theta_1, \dots, \theta_k)$ 的 k 阶矩均存在. 令向量值函数 $\mu: \Theta \rightarrow \mathbb{R}^k$ 由下式给出:

$$\mu(\theta_1, \dots, \theta_k) = (\mathbb{E}_{\theta_1, \dots, \theta_k}[X^1], \dots, \mathbb{E}_{\theta_1, \dots, \theta_k}[X^k]),$$

其中 $\mathbb{E}_{\theta_1, \dots, \theta_k}[X^j]$ 表示取期望时 X 服从的分布为 $F(x; \theta_1, \dots, \theta_k)$. 记 $\mathcal{M} = \mu(\Theta)$, 并进一步假设如下条件成立:

1. $\mathcal{M}$ 是一个开集.
2. μ 是一个单射, 从而在 $\mathcal{M}$ 上有逆映射 $\mu^{-1}: \mathcal{M} \rightarrow \Theta$.
3. μ^{-1} 在 $\mathcal{M}$ 上连续.

记 j 阶样本矩为 $\overline{X_n^j} = \frac{1}{n} \sum_{i=1}^n (X_i)^j$, 并记样本容量为 n 的矩估计量为

$$(\hat{\theta}_1^{(n)}, \dots, \hat{\theta}_k^{(n)}) = \begin{cases} \boldsymbol{\mu}^{-1}(\overline{X_n^1}, \dots, \overline{X_n^k}), & \text{若 } (\overline{X_n^1}, \dots, \overline{X_n^k}) \in \mathcal{M}, \\ (\theta_1^*, \dots, \theta_k^*), & \text{其它情况,} \end{cases}$$

其中 $(\theta_1^*, \dots, \theta_k^*)$ 为从 Θ 中任取的固定元素⁶. 则当总体的参数为任一 $(\theta_1, \dots, \theta_k) \in \Theta$ 时, 对于每个 $l = 1, \dots, k$, 相应的矩估计量 $\hat{\theta}_l^{(n)}$ 在 $n \rightarrow \infty$ 时均依概率收敛于 θ_l .

证明. 固定 $(\theta_1, \dots, \theta_k) \in \Theta$, 用随机变量 X 代表参数 $(\theta_1, \dots, \theta_k)$ 对应的总体, 并令 $(m_1, \dots, m_k) = \boldsymbol{\mu}(\theta_1, \dots, \theta_k)$. 任取 $l \in \{1, \dots, k\}$, 并令 $g_l: \mathbb{R}^k \rightarrow \mathbb{R}$ 为将 $(\overline{X_n^1}, \dots, \overline{X_n^k})$ 对应到 $\hat{\theta}_l^{(n)}$ 的函数. 注意到 g_l 在 $\mathcal{M}$ 上就等于向量值函数 $\boldsymbol{\mu}^{-1}$ 的第 l 个分量, 进而有

$$g_l(m_1, \dots, m_k) = \theta_l.$$

由弱大数定律, 可得对任意的 $j = 1, \dots, k$, 当 $n \rightarrow \infty$ 时均有

$$\overline{X_n^j} \xrightarrow{P} m_j.$$

而由定理条件, 可知 g_l 在开集 $\mathcal{M}$ 上连续, 且 $(m_1, \dots, m_k) \in \mathcal{M}$. 故可以利用引理 7.1, 得

$$g_l(\overline{X_n^1}, \dots, \overline{X_n^k}) \xrightarrow{P} g_l(m_1, \dots, m_k), \quad n \rightarrow \infty,$$

也即

$$\hat{\theta}_l^{(n)} \xrightarrow{P} \theta_l, \quad n \rightarrow \infty. \quad \square$$

接下来我们给出最大似然估计相合性的证明. 简单起见, 此处只考虑未知参数为单个实数 (标量), 且参数范围为有限集合的情形.

定理 7.3 (最大似然估计的相合性). 设总体 X 的概率密度函数为 $f(x; \theta)$, 其中 θ 为未知参数, 且 θ 的所有可能取值构成一有限集合 Θ . 令 $\hat{\theta}^{(n)}$ 表示样本容量为 n 时参数 θ 的最大似然估计量, 则当总体的参数取为任一 $\theta \in \Theta$ 时, 均有

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta(|\hat{\theta}^{(n)} - \theta| \leq \epsilon) = 1, \quad \forall \epsilon > 0.$$

⁶ 引入 $(\theta_1^*, \dots, \theta_k^*)$ 主要是为了让矩估计量在 $(\overline{X_n^1}, \dots, \overline{X_n^k})$ 的取值落在 $\boldsymbol{\mu}$ 的值域外面时依然有定义.

证明. 为了避免符号上的混淆, 我们将总体的真实参数改用 $\theta_0 \in \Theta$ 表示. 令 $X_1, X_2, \dots$ 为一列相互独立且与 X 同分布的随机变量. 任取 $\theta' \in \Theta \setminus \{\theta_0\}$, 由琴生不等式可得⁷

$$\begin{aligned} \mathbb{E}_{\theta_0} \left[\ln \frac{f(X; \theta')}{f(X; \theta_0)} \right] &< \ln \mathbb{E}_{\theta_0} \left[\frac{f(X; \theta')}{f(X; \theta_0)} \right] \\ &= \ln \int_{-\infty}^{+\infty} \frac{f(x; \theta')}{f(x; \theta_0)} \cdot f(x; \theta_0) dx = \ln 1 = 0. \end{aligned} \quad (7.8)$$

上式中能够取到严格不等号是因为 $x \mapsto -\ln x$ 是严格凸的, 且 θ' 给出与 θ_0 不同的概率分布. 接下来, 对任意 $\theta \in \Theta$, 记事件 E_θ 为

$$E_\theta = \left\{ \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \ln \frac{f(X_i; \theta)}{f(X_i; \theta_0)} = \mathbb{E}_{\theta_0} \left[\ln \frac{f(X; \theta)}{f(X; \theta_0)} \right] \right\},$$

则由 Kolmogorov 强大数定律, 可知对任意 $\theta \in \Theta$, 均有 $\mathbb{P}_{\theta_0}(E_\theta) = 1$, 而又因为 Θ 是有限集, 故

$$\mathbb{P}_{\theta_0} \left(\bigcap_{\theta \in \Theta} E_\theta \right) = 1.$$

接下来任取 $\omega \in \bigcap_{\theta \in \Theta} E_\theta$, 由式 (7.8) 可知

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \ln \frac{f(X_i(\omega); \theta')}{f(X_i(\omega); \theta_0)} < 0, \quad \forall \theta' \neq \theta_0,$$

而由极限的保号性, 可知存在足够大的正整数 $N(\omega)$, 使得 $n \geq N(\omega)$ 时均有

$$\sum_{i=1}^n \ln \frac{f(X_i(\omega); \theta')}{f(X_i(\omega); \theta_0)} < 0, \quad \forall \theta' \neq \theta_0,$$

也即 $\sum_{i=1}^n \ln f(X_i(\omega); \theta') < \sum_{i=1}^n \ln f(X_i(\omega); \theta_0)$, $\forall \theta' \neq \theta_0$. 这意味着 $n \geq N(\omega)$ 时有

$$\arg \max_{\theta \in \Theta} \sum_{i=1}^n \ln f(X_i(\omega); \theta) = \theta_0.$$

但由最大似然估计量的定义, 可知

$$\hat{\theta}^{(n)} = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \ln f(X_i; \theta),$$

故

$$\lim_{n \rightarrow \infty} \hat{\theta}^{(n)}(\omega) = \theta_0.$$

⁷ 本讲义第 2、3 章中对于期望的定义与讨论不包括它取 $\pm\infty$ 的情形, 但实际上对于某些随机变量, 我们可以定义其期望为 $+\infty$ 或 $-\infty$. 可以证明, $\mathbb{E}_{\theta_0} \left[\ln \frac{f(X; \theta')}{f(X; \theta_0)} \right]$ 要么取有限值, 要么取 $-\infty$, 而它取 $-\infty$ 的情形同样可以被不等式 (7.8) 包括进来. 此外, 后面应用强大数定律时, 所得到的结论对于 $\mathbb{E}_{\theta_0} \left[\ln \frac{f(X; \theta')}{f(X; \theta_0)} \right] = -\infty$ 的情形也是适用的.

由 $\omega \in \bigcap_{\theta \in \Theta} E_\theta$ 的任意性, 即得到

$$\mathbb{P}_{\theta_0} \left(\lim_{n \rightarrow \infty} \hat{\theta}^{(n)} = \theta_0 \right) \geq \mathbb{P}_{\theta_0} \left(\bigcap_{\theta \in \Theta} E_\theta \right) = 1.$$

最后, 由几乎必然收敛与依概率收敛的关系, 可知 $\hat{\theta}^{(n)} \xrightarrow{P} \theta_0$. $\square$

注 7.3. 不难将上面的证明过程移植到总体为离散型随机变量的情形. 而对于更加一般的 Θ , 为证明最大似然估计相合性, 则需要对总体所在的参数化分布族施加一些限制条件, 且需要用到不少分析上的技巧, 但刨去这些技巧之后, 背后的证明思路依然和上述证明是一致的; 可参阅 [17] 第 7.3.2 节. $\blacksquare$

7.4 贝叶斯参数估计方法简介

以上几节介绍的点估计理论与方法都是基于频率学派的观点, 即未知参数是一个确定性的量. 而在贝叶斯学派的理论当中, 则是把未知参数作为一个随机变量来处理. 具体而言, 我们用一个随机变量或随机向量 Θ 代表未知参数⁸, 这个未知参数服从某个给定的概率分布 $\pi(\theta)$ (简单起见, 我们假定 Θ 是连续型的, $\pi(\theta)$ 是一个概率密度函数), 我们将其称为未知参数 Θ 的**先验分布** (prior distribution), 而总体则由条件分布列 $p(x|\theta)$ 或条件概率密度函数 $f(x|\theta)$ 表示. 可以认为样本是通过如下过程获取的: 首先从先验分布中抽样得到一个未知参数的值, 再从该参数值给出的条件分布中抽样得到样本. 或者也可以采取主观概率诠释 (见 1.3.1 小节), 认为 $\pi(\theta)$ 给出了我们在收集到样本数据之前关于 Θ 的主观概率认知.

简单起见, 我们只考虑用条件概率密度函数 $f(x|\theta)$ 表示的总体. 此时, 从总体中抽样所得到的简单随机样本 $X_1, \dots, X_n$ 则具有如下联合条件分布:

$$f_{X_1, \dots, X_n | \Theta}(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta).$$

贝叶斯参数估计的任务则是在观测到样本 $X_1, \dots, X_n$ 的取值 $x_1, \dots, x_n$ 后, 反推未知参数 Θ 在给定 $X_1 = x_1, \dots, X_n = x_n$ 条件下的条件分布, 这个条件分布在贝叶斯参数估计理论中又被叫作 Θ 的**后验分布** (posterior distribution). 我们将后验分布对应的条件

⁸ 与其它章节不同, 本节我们用 Θ 表示作为随机变量或随机向量的未知参数, 而不再表示所有可能的参数取值构成的集合.

概率密度函数记作 $\pi(\theta|x_1, \dots, x_n) = \pi(\theta|\mathbf{x})$. 由习题 4.12 给出的贝叶斯公式, 可得

$$\pi(\theta|\mathbf{x}) = \frac{\pi(\theta) \prod_{i=1}^n f(x_i|\theta)}{\int \pi(\theta) \prod_{i=1}^n f(x_i|\theta) d\theta}. \quad (7.9)$$

我们进一步定义贝叶斯参数估计中的**似然函数** (likelihood function) 为

$$L(\theta|\mathbf{x}) = \prod_{i=1}^n f(x_i|\theta),$$

则式 (7.9) 可以简单改写为

$$\pi(\theta|\mathbf{x}) \propto L(\theta|\mathbf{x}) \cdot \pi(\theta). \quad (7.10)$$

上式是贝叶斯参数估计方法的核心. 在贝叶斯参数估计方法中, 我们可以直接将未知参数的后验分布作为参数估计的最终结果, 也可以基于后验分布进一步给出未知参数的点估计量. 常用的贝叶斯点估计量包括如下两种:

1. 最小均方误差 (minimum mean square error, MMSE) 估计量 $\hat{\theta}_{\text{MMSE}}(X_1, \dots, X_n)$: 该估计量实际上就是 Θ 在给定样本 $X_1, \dots, X_n$ 时的条件期望 $\mathbb{E}[\Theta|X_1, \dots, X_n] = \mathbb{E}[\Theta|\mathbf{X}]$, 它可由后验分布算得:

$$\hat{\theta}_{\text{MMSE}}(\mathbf{x}) = \mathbb{E}[\Theta|\mathbf{X} = \mathbf{x}] = \int \theta \cdot \pi(\theta|\mathbf{x}) d\theta.$$

之所以将其称为最小均方误差估计量, 是因为 $\hat{\theta}_{\text{MMSE}}(X_1, \dots, X_n)$ 是所有统计量中使得均方误差达到最小的统计量 (见 4.4.4 小节):

$$\hat{\theta}_{\text{MMSE}} = \arg \min_{\hat{\theta}} \text{MSE}_{\Theta}(\hat{\theta}), \quad \text{其中 } \text{MSE}_{\Theta}(\hat{\theta}) = \mathbb{E} \left[|\hat{\theta}(X_1, \dots, X_n) - \Theta|^2 \right].$$

需要注意的是, 上式中的均方误差 $\text{MSE}_{\Theta}(\hat{\theta})$ 是把未知参数作为随机变量并取全期望而得到的, 从而与参数的具体取值无关, 它并非式 (7.3) 定义的频率学派理论中依赖于参数取值的均方误差 $\text{MSE}_{\theta}(\hat{\theta})$.

注 7.4. 实际上, 由于

$$\text{MSE}_{\Theta}(\hat{\theta}) = \int \pi(\theta) d\theta \int |\hat{\theta}(x_1, \dots, x_n) - \theta|^2 \prod_{i=1}^n f(x_i|\theta) dx_1 \cdots dx_n,$$

若把条件概率密度函数 $f(\cdot|\theta)$ 当成是由 θ 参数化的概率分布, 则上式右端出现的积分 $\int |\hat{\theta}(x_1, \dots, x_n) - \theta|^2 \prod_{i=1}^n f(x_i|\theta) dx_1 \cdots dx_n$ 给出的就是频率学派理论中依赖于参数值 θ 的均方误差 $\text{MSE}_{\theta}(\hat{\theta})$, 从而

$$\text{MSE}_{\Theta}(\hat{\theta}) = \int \text{MSE}_{\theta}(\hat{\theta}) \pi(\theta) d\theta,$$

也就是说, 我们可以把 $\text{MSE}_{\Theta}(\hat{\theta})$ 当作是由 $\text{MSE}_{\theta}(\hat{\theta})$ 按照先验分布 $\pi(\theta)$ 进行加权平均而得到的. ■

2. 最大后验 (maximum a posteriori, MAP) 估计量 $\hat{\theta}_{\text{MAP}}(X_1, \dots, X_n)$: 该估计量是通过求后验分布概率密度函数的最大值点得到的:

$$\hat{\theta}_{\text{MAP}}(\mathbf{x}) = \arg \max_{\theta} \pi(\theta | \mathbf{x}).$$

将式 (7.10) 代入可得

$$\hat{\theta}_{\text{MAP}}(\mathbf{x}) = \arg \max_{\theta} (\ln L(\theta | \mathbf{x}) + \ln \pi(\theta)).$$

由上式可看出 MAP 估计量与最大似然估计量具有相似之处, 但 MAP 估计量中不仅需要考虑到似然函数的取值 (它反映了样本值对于参数估计的影响), 还需要考虑到先验概率密度函数的取值 (它反映了未知参数的先验信息对于参数估计的影响). 直观上, 通常认为对数似然函数 $\ln L(\theta | \mathbf{x})$ 衡量了候选参数值 θ 与样本数据的拟合程度, 而 $\ln \pi(\theta)$ 则是对参数施加的一个正则项 (regularization term), 这个正则项能够帮助我们避免过拟合 (overfitting).

例 7.12. 仍考虑例 7.1 的情形, 但我们换用贝叶斯方法对未知的期望 (温度) 进行估计. 我们换用 Θ 来表示未知的期望, 并设它的先验分布为 $\mathcal{N}(\mu_0, \sigma_0^2)$, 其中 μ_0, σ_0^2 均为已知量 (它们有时被称为超参数). 而在给定 $\Theta = \theta$ 后, 总体的条件分布依然为正态分布 $\mathcal{N}(\theta, \sigma^2)$, 其中 σ^2 已知. 则此时先验分布的概率密度函数为

$$\pi(\theta) = \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{(\theta - \mu_0)^2}{2\sigma_0^2}\right),$$

而似然函数 $L(\theta | \mathbf{x})$ 则等于

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \theta)^2}{2\sigma^2}\right) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right).$$

由此可算得在给定 $(X_1, \dots, X_n) = \mathbf{x}$ 时 Θ 的后验分布为

$$\begin{aligned} \pi(\theta | \mathbf{x}) &\propto \pi(\theta) \cdot L(\theta | \mathbf{x}) \\ &\propto \exp\left(-\frac{(\theta - \mu_0)^2}{2\sigma_0^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right) \\ &\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right) \theta^2 + \left(\frac{\mu_0}{\sigma_0^2} + \frac{1}{\sigma^2} \sum_{i=1}^n x_i\right) \theta\right) \\ &\propto \exp\left(-\frac{(\theta - \tilde{\theta})^2}{2\tilde{\sigma}^2}\right), \end{aligned}$$

其中

$$\tilde{\sigma}^2 = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}, \quad \tilde{\theta} = \tilde{\sigma}^2 \left(\frac{\mu_0}{\sigma_0^2} + \frac{1}{\sigma^2} \sum_{i=1}^n x_i \right).$$

注意到在计算 $\pi(\theta|\mathbf{x})$ 的过程中, 我们只需保留与 θ 有关的项, 而可以把仅与已知参数、超参数以及 $\mathbf{x}$ 有关的系数均“吸收”进正比例符号 $\propto$ 当中. 通过以上的计算可看出, Θ 在给定 $X_1 = x_1, \dots, X_n = x_n$ 时的条件分布为正态分布 $\mathcal{N}(\tilde{\theta}, \tilde{\sigma}^2)$. 若要对 Θ 进行点估计, 则其 MMSE 与 MAP 估计量均为

$$\hat{\theta}(X_1, \dots, X_n) = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1} \left(\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{X}}{\sigma^2} \right),$$

其中 $\bar{X}$ 为样本均值. 注意到当 $n \rightarrow \infty$ 时, $\hat{\theta}(X_1, \dots, X_n)$ 将(逐点)收敛于样本均值 $\bar{X}$, 而 $\bar{X}$ 则是频率学派点估计理论中正态总体期望的最大似然估计量. ■

7.5 习题

习题 7.1 (偏差-方差分解). 设 $\hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的一个点估计量. 证明对任意 $\theta \in \Theta$, 均有

$$\text{MSE}_{\theta}(\hat{\theta}) = [b_{\theta}(\hat{\theta})]^2 + \text{Var}_{\theta}(\hat{\theta}).$$

习题 7.2. 设总体 X 的一个未知参数为 $\theta \in \Theta$, 而 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(n)}, \dots$ 为一列 θ 的点估计量, 其中 $\hat{\theta}^{(n)} = \hat{\theta}^{(n)}(X_1, \dots, X_n)$. 若对任意 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时这列点估计量的偏差均趋于 0, 即

$$\lim_{n \rightarrow \infty} \mathbb{E}_{\theta} [\hat{\theta}^{(n)}] = \theta, \quad \forall \theta \in \Theta,$$

则称这列点估计量是**渐近无偏的** (asymptotically unbiased).

证明: 若 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(n)}, \dots$ 是渐进无偏的, 且

$$\lim_{n \rightarrow \infty} \text{Var}_{\theta}(\hat{\theta}^{(n)}) = 0, \quad \forall \theta \in \Theta,$$

则 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(n)}, \dots$ 是相合的. 提示 对 $|\hat{\theta}^{(n)} - \theta|^2$ 利用 Markov 不等式.

习题 7.3 (最大似然估计的不变性). 设总体 X 的分布列或概率密度函数为 $f(x; \theta)$, 其中未知参数 θ 的所有可能取值构成集合 Θ . 设 $g: \Theta \rightarrow \mathcal{H}$ 为一个从集合 Θ 到集合 $\mathcal{H}$ 的双射. 令 $\hat{\theta}_{\text{ML}}$ 为参数 θ 的最大似然估计量, 而令 $\hat{\eta}_{\text{ML}}$ 为 $\eta = g(\theta)$ 的最大似然估计量.

证明

$$\hat{\eta}_{\text{ML}} = g(\hat{\theta}_{\text{ML}}).$$

注: $\eta = g(\theta)$ 的最大似然估计量是指将 $f(x; g^{-1}(\eta))$ 作为总体的分布列或概率密度函数, 并用 $\eta \in \mathcal{H}$ 替代 θ 作为未知参数, 而后求 η 的最大似然估计量.

习题 7.4. 设总体 X 服从期望为 θ 的指数分布, 其中 $\theta > 0$ 为未知参数. 换句话说, X 的概率密度函数可表示为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

令 $X_1, \dots, X_n$ 为总体 X 的一组样本.

1. 设 $\alpha = (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n$ 满足 $\sum_{i=1}^n \alpha_i = 1$, 并令

$$\hat{\theta}_\alpha = \sum_{i=1}^n \alpha_i X_i.$$

证明 $\hat{\theta}_\alpha$ 是 θ 的一个无偏估计量.

2. 试求 $\alpha = (\alpha_1, \dots, \alpha_n)$, 使它在满足 $\sum_{i=1}^n \alpha_i = 1$ 的同时让 $\hat{\theta}_\alpha$ 的均方误差取到最小.

习题 7.5. 设总体 X 的分布列为 $p(x; \theta)$, 其中 $\theta \in \{1, 2, 3\}$ 为未知参数. 分布列族 $\{p(\cdot; \theta)\}$ 由下表给出:

x	$p(x; 1)$	$p(x; 2)$	$p(x; 3)$
0	1/3	1/4	0
1	1/3	1/4	0
2	0	1/4	1/4
3	1/6	1/4	1/2
4	1/6	0	1/4

试求未知参数 θ 的最大似然估计量.

习题 7.6. 设总体 X 的分布列为

$$p(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\},$$

其中 $\theta \in [0, 1]$ 为未知参数 (我们规定 $0^0 = 1$). 试求 θ 的矩估计量与最大似然估计量.

习题 7.7. 设总体 X 服从参数为 λ 的泊松分布, 其中 λ 为未知参数. 试求 λ 的矩估计与最大似然估计量.

习题 7.8. 设总体 X 服从区间 $[0, \theta]$ 上的均匀分布, 其中 $\theta > 0$ 为未知参数.

1. 试求样本容量为 n 时 θ 的矩估计量 $\hat{\theta}_{\text{MM}}^{(n)}$.
2. 令样本容量为 n 时 θ 的最大似然估计量为 $\hat{\theta}_{\text{ML}}^{(n)}$. 试求 $\hat{\theta}_{\text{MM}}^{(n)}$ 与 $\hat{\theta}_{\text{ML}}^{(n)}$ 的偏差与均方误差, 并判断它们是否是无偏估计量.
3. 证明参数 θ 的矩估计量 $\hat{\theta}_{\text{MM}}^{(n)}$ 与最大似然估计量 $\hat{\theta}_{\text{ML}}^{(n)}$ 均具有相合性.

习题 7.9. 设总体 X 服从区间 $[a, b]$ 上的均匀分布, 其中 a, b 均为未知参数, $b > a$.

1. 试求 a 与 b 的最大似然估计量.
2. 现假设我们已知 $b = 2a$ 且 $a > 0$. 试求参数 a 的矩估计量与最大似然估计量.

习题 7.10. 设总体 X 的概率密度函数为

$$f(x; \theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1, \\ 0, & \text{其它情况,} \end{cases}$$

其中 $\theta > 0$ 为未知参数.

1. 试求 θ 的矩估计量 $\hat{\theta}_{\text{MM}}$ 与最大似然估计量 $\hat{\theta}_{\text{ML}}$.
2. (*) 证明 θ 的最大似然估计具有相合性. 提示 利用引理 7.1.
3. 试求 $\hat{\theta}_{\text{ML}}$ 的偏差与均方误差.
4. 若将 $1/\hat{\theta}_{\text{ML}}$ 作为 $\eta = 1/\theta$ 的点估计量, 证明该点估计量是无偏的.

习题 7.11. 设总体 X 的概率密度函数为

$$f(x; \theta) = \frac{\lambda}{2} \exp(-\lambda|x - \theta|), \quad x \in \mathbb{R},$$

其中 $\theta \in \mathbb{R}$ 与 $\lambda > 0$ 为未知参数.

1. 试求 θ 与 λ 的矩估计量.
2. 试求 θ 与 λ 的最大似然估计量.

提示 你可能需要先证明如下结果: 给定 $x_1, \dots, x_n \in \mathbb{R}$, 使得 $\sum_{i=1}^n |x_i - \theta|$ 取最小值的 θ 是 $x_1, \dots, x_n$ 的中位数. 此处的中位数按如下方式定义: 当 n 为奇数时, 中

位数是第 $(n+1)/2$ 大的数; 当 n 为偶数时, 中位数可以是任意小于等于第 $n/2$ 大而大于等于第 $n/2+1$ 大的数.

习题 7.12. 设总体 X 服从参数为 (α, β) 的 Γ 分布, 也就是说 X 的概率密度函数为

$$f(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中 $\alpha > 0, \beta > 0$ 为参数. 将总体 X 的样本记为 $X_1, \dots, X_n$.

1. 设 α, β 均未知. 试求 α 与 β 的矩估计量.
2. 设 α 已知而 β 未知, 试求 β 的最大似然估计量, (*) 并证明其相合性.
3. 设 α, β 均未知, 证明 α 的最大似然估计量 $\hat{\alpha}_{\text{ML}}$ 满足如下方程:

$$\ln \hat{\alpha}_{\text{ML}} - \frac{\Gamma'(\hat{\alpha}_{\text{ML}})}{\Gamma(\hat{\alpha}_{\text{ML}})} = \ln \left(\frac{1}{n} \sum_{i=1}^n X_i \right) - \frac{1}{n} \sum_{i=1}^n \ln X_i.$$

4. (*) 设 α, β 均未知, 考虑如下 α 与 β 的估计量:

$$\hat{\alpha}^{(n)} = \frac{n \sum_{i=1}^n X_i}{n \sum_{i=1}^n X_i \ln X_i - (\sum_{i=1}^n X_i) (\sum_{i=1}^n \ln X_i)},$$

$$\hat{\beta}^{(n)} = \frac{\hat{\alpha}^{(n)}}{\frac{1}{n} \sum_{i=1}^n X_i}.$$

证明估计量 $\hat{\alpha}^{(n)}$ 与 $\hat{\beta}^{(n)}$ 的相合性.

第八章 参数估计 II: 区间估计

8.1 区间估计与置信区间

设总体的分布函数为 $F(x; \theta)$, 其中未知参数 θ 的所有可能取值构成集合 Θ , 且为简单起见, 设 Θ 是 $\mathbb{R}$ 上的一个区间. 在点估计问题中, 我们通过构造合适的统计量 $\hat{\theta}$, 基于获得的样本值来给出未知参数 θ 的单个估计值. 然而, 在某些实际问题中, 我们可能不仅需要进行点估计, 还希望基于样本对这个点估计的精度进行某种推断. 例如, 我们可能希望找到一个阈值, 使得点估计值与真实值的距离能够以大概率小于等于该阈值, 那么我们就可以用这个阈值来代表估计的精度. 由于真实的总体未知, 我们也只能基于样本值来给出这个阈值, 故这个阈值也对应于一个统计量. 将以上想法进行整理后, 我们就得到了如下问题: 应当如何构造点估计量 $\hat{\theta}$ 以及一个阈值统计量 $D = D(X_1, \dots, X_n)$, 使得不等式

$$\mathbb{P}_\theta(|\hat{\theta} - \theta| \leq D) \geq 1 - \alpha$$

对任意 $\theta \in \Theta$ 成立, 其中 α 是一个事先定好的足够小的实数. 不难看出上述问题也等价于如何构造统计量 $\underline{\theta} = \underline{\theta}(X_1, \dots, X_n)$ 与 $\bar{\theta} = \bar{\theta}(X_1, \dots, X_n)$, 使得

$$\mathbb{P}_\theta([\underline{\theta}, \bar{\theta}] \ni \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta, \quad (8.1)$$

其中 α 是一个事先定好的足够小的实数. 换句话说, 我们希望找到一个依赖于样本的区间 $[\underline{\theta}, \bar{\theta}]$, 使得无论总体的真实参数 θ 是什么, 这个区间能够覆盖住真实参数 θ 的概率至少为 $1 - \alpha$. 我们把这一类问题称为**区间估计** (interval estimation) 问题, 而将满足条件 (8.1) 的端点为统计量的区间 $[\underline{\theta}, \bar{\theta}]$ 称为 θ 的**置信区间** (confidence interval), 并把 $1 - \alpha$ 叫作该置信区间的**置信水平** (confidence level)¹. 我们还经常将 $\underline{\theta}$ 与 $\bar{\theta}$ 分别称为

¹ 注意到若 $1 - \alpha$ 是 $[\underline{\theta}, \bar{\theta}]$ 的置信水平, 那么任何小于等于 $1 - \alpha$ 的正实数也都是 $[\underline{\theta}, \bar{\theta}]$ 的置信水平. 有些场合为了表意上的确切, 当给定置信区间而谈论其置信水平时, 我们是指满足 (8.1) 的 $1 - \alpha$ 当中最大的那个值.

置信下限与置信上限 (lower/upper confidence limit) .

对于置信水平为 $1 - \alpha$ 的置信区间 $[\underline{\theta}, \bar{\theta}]$, 我们可以认为 $1 - \alpha$ 衡量了区间估计的可靠性, 而 $\bar{\theta} - \underline{\theta}$ 则衡量了区间估计的精度. 不难理解可靠性与精度之间是存在一定矛盾的, 一般来说, 在样本容量 n 受限的情形下, 我们不可能把区间估计的可靠性与精度都同时提升到一个很高的水平. 在经典的频率学派区间估计理论中, 我们采取的方案是先给定可靠性的一个下限 (也即确定置信水平), 在保证这个下限的前提下尽量提升区间估计的精度². 换句话说, 在针对给定的 α 求解置信区间 $[\underline{\theta}, \bar{\theta}]$ 时, 我们会在保证其置信水平至少为 $1 - \alpha$ 的前提下, 尽量让该区间的宽度 $\bar{\theta} - \underline{\theta}$ 取得越小越好. 通常, 这将迫使我们让 $[\underline{\theta}, \bar{\theta}] \ni \theta$ 的概率尽可能地下探到 $1 - \alpha$ (但不得低于 $1 - \alpha$); 特别是, 当总体 X 是连续型随机变量时, 我们通常就按要求

$$\inf_{\theta \in \Theta} \mathbb{P}_{\theta}([\underline{\theta}, \bar{\theta}] \ni \theta) = 1 - \alpha$$

来求置信区间.

需要注意的是, 式 (8.1) 当中的未知参数 θ 是被作为一个确定性的量来处理的, 也就是说, 我们目前是以频率学派的视角来处理区间估计问题的, 而这也要求我们在理解式 (8.1) 的含义时需要格外小心. 特别是, 我们不能认为式 (8.1) 体现了未知参数 θ 的统计规律 (因为 θ 是一个确定性的量). 一种解释 (8.1) 含义的方式如下: 设总体的参数为某个确定性的 θ , 而我们通过从这个总体中反复地抽样, 按照统计量 $\underline{\theta}$ 与 $\bar{\theta}$ 来大量重复上述置信区间的构造流程 (比方说重复 M 次), 从而获得 M 个置信区间的结果. 由于每次抽样获得的样本值是不同的, 这 M 个区间也互不相同. 则平均而言, 在这大量的区间估计给出的结果中, 把参数真值 θ 覆盖住的区间所占的比例将至少为 $1 - \alpha$; 可参考图 8.1 给出的图示.

例 8.1 (方差已知时正态总体期望的区间估计). 设总体 X 服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中方差 σ^2 已知而期望 μ 未知, $X_1, \dots, X_n$ 为总体 X 的一组样本, 我们希望对期望 μ 进行区间估计, 找出其置信水平为 $1 - \alpha$ 的一个置信区间.

注意到样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 服从正态分布 $\mathcal{N}(\mu, \sigma^2/n)$, 因而

$$\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim \mathcal{N}(0, 1).$$

² 这套区间估计的范式是由统计学家 Jerzy Neyman 首先建立的.




图 8.1: 固定总体参数 θ , 对某个置信水平为 90% 的置信区间构造流程重复 100 次的实验结果. 图中每个 “I” 字图形表示一个区间估计的结果, 蓝色表示该区间覆盖住了参数真值, 而红色表示该区间没能覆盖住参数真值. 当重复次数进一步提升并趋于无穷时, 蓝色区间所占比例将趋于 90%.

可以看出随机变量 $(\bar{X} - \mu)/\sqrt{\sigma^2/n}$ 的分布已不再依赖于未知参数 μ . 现任取 $\lambda \in]0, 1[$, 依照标准正态分布上分位数的定义以及正态分布的对称性, 可得 (见图 8.2)

$$\mathbb{P}_{\mu} \left(-z_{(1-\lambda)\alpha} \leq \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \leq z_{\lambda\alpha} \right) = 1 - \alpha.$$

对上式进行变形, 得到

$$\mathbb{P}_{\mu} \left(\left[\bar{X} - z_{\lambda\alpha} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{(1-\lambda)\alpha} \frac{\sigma}{\sqrt{n}} \right] \ni \mu \right) = 1 - \alpha.$$

由此可得, 形如

$$\left[\bar{X} - z_{\lambda\alpha} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{(1-\lambda)\alpha} \frac{\sigma}{\sqrt{n}} \right].$$

的随机区间均为 μ 的置信水平为 $1 - \alpha$ 的置信区间. 但在所有这些置信区间中, 令 $\lambda = 1/2$ 可以使置信区间的宽度达到最小, 因而我们通常就将

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \quad (8.2)$$

作为 μ 的置信水平为 $1 - \alpha$ 的置信区间. ■

注 8.1. 例 8.1 考虑的是总体服从正态分布的情形. 而若总体不服从正态分布但其方差 σ^2 已知, 且样本容量 n 足够大, 则由中心极限定理可得 $(\bar{X} - \mu)/\sqrt{\sigma^2/n}$ 近似服从标准正态分布, 此时我们可以依照例 8.1 的步骤对期望 μ 的置信区间进行近似求解, 并最终得到其置信水平为 $1 - \alpha$ 的置信区间可以近似由式 (8.2) 给出. ■




图 8.2: 正态总体的方差已知时, 利用枢轴量 $(\bar{X} - \mu)/\sqrt{\sigma^2/n}$ 求解期望的置信区间.

注 8.2. 对于某些场合, 我们可能只是想估计出未知参数 θ 的一个上界, 并在保证一定可靠性的前提下让这个上界尽可能接近参数的真值. 换句话说, 给定 α , 我们只需找到一个尽量小的统计量 $\bar{\theta}$ 使得

$$\mathbb{P}_{\theta}(\theta \leq \bar{\theta}) \geq 1 - \alpha \quad (8.3)$$

即可. 我们将满足 (8.3) 的统计量 $\bar{\theta}$ 称作置信水平为 $1 - \alpha$ 的**单侧置信上界** (one-sided upper confidence bound). 对于单侧置信上界, 其估计精度可以直接由它的大小来衡量, 即单侧置信上界越小则估计精度越高. 同理也可定义**单侧置信下界** (one-sided lower confidence bound) 的概念. 此外, 我们也将形如

$$]-\infty, \bar{\theta}] \quad \text{或} \quad [\underline{\theta}, +\infty[$$

的置信区间称作**单侧置信区间** (one-sided confidence interval).

以例 8.1 考虑的情形为例, 给定置信水平 $1 - \alpha$, 则未知参数 μ 的两个单侧置信区间可以分别取为

$$\left] -\infty, \bar{X} + z_{\alpha} \frac{\sigma}{\sqrt{n}} \right] \quad \text{与} \quad \left[\bar{X} - z_{\alpha} \frac{\sigma}{\sqrt{n}}, +\infty \right[$$

(注意上式中用到的上分位数为 z_{α} 而非 $z_{\alpha/2}$). ■

我们可以将例 8.1 的区间估计步骤进行推广, 得到求解置信区间的一个较为一般的方法:

1. 构造一个依赖于样本 $X_1, \dots, X_n$ 与参数值 θ 的随机变量 $h(X_1, \dots, X_n; \theta)$, 使得 $h(X_1, \dots, X_n; \theta)$ 的分布不再与未知参数有关 (换句话说, $h(X_1, \dots, X_n; \theta)$ 在取不同的 θ 时所服从的分布都是相同的). 我们将该随机变量 $h(X_1, \dots, X_n; \theta)$ 称作一个**枢轴量** (pivotal quantity).

在例 8.1 当中, 枢轴量即为 $(\bar{X} - \mu)/\sqrt{\sigma^2/n}$.

2. 找出两个合适的常数 l 与 u , 使得

$$\mathbb{P}_\theta(l \leq h(X_1, \dots, X_n; \theta) \leq u) \geq 1 - \alpha.$$

特别是, 若 $h(X_1, \dots, X_n; \theta)$ 为连续型随机变量, 则找出满足

$$\mathbb{P}_\theta(l \leq h(X_1, \dots, X_n; \theta) \leq u) = 1 - \alpha$$

的常数 l, u .

在例 8.1 当中, 由于枢轴量服从标准正态分布, 故可以取 $l = -z_{(1-\alpha)\lambda}$, $u = z_{\lambda\alpha}$. 而取 $\lambda = 1/2$ 可以使得最终构造出来的置信区间宽度最小.

3. 尝试将不等式 $l \leq h(X_1, \dots, X_n; \theta) \leq u$ 等价地变形为如下形式:

$$\underline{\theta}(X_1, \dots, X_n) \leq \theta \leq \bar{\theta}(X_1, \dots, X_n).$$

若这样的等价变形可行, 则可知 θ 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$[\underline{\theta}(X_1, \dots, X_n), \bar{\theta}(X_1, \dots, X_n)].$$

我们将上述求解置信区间的方法称作**枢轴量法**. 需要注意的是, 枢轴量法并非万能, 其中枢轴量的构造对于总体分布的形式较为复杂的情形往往是比较困难的.

注 8.3. 若总体的未知参数为 $\theta \in \Theta$ (它可以是标量也可以是多维向量), 而我们想对 $\eta = g(\theta)$ 进行区间估计, 其中 $g: \Theta \rightarrow \mathbb{R}$ 为一个实值函数, 则此时 η 的置信水平为 $1 - \alpha$ 的置信区间 $[\underline{\eta}, \bar{\eta}]$ 需满足如下条件:

$$\mathbb{P}_\theta([\underline{\eta}, \bar{\eta}] \ni g(\theta)) \geq 1 - \alpha, \quad \forall \theta \in \Theta,$$

其中区间端点 $\underline{\eta}, \bar{\eta}$ 仍要求为统计量. 此时依然可以考虑用枢轴量法构造置信区间, 不过我们会要求枢轴量的形式为 $h(X_1, \dots, X_n; g(\theta))$, 也就是说它只和 $X_1, \dots, X_n$ 与 $g(\theta)$ 有关; 另一方面, 我们仍然要求 $h(X_1, \dots, X_n; g(\theta))$ 的分布与 θ 无关. 此时通过

$$\mathbb{P}_\theta(l \leq h(X_1, \dots, X_n; g(\theta)) \leq u) \geq 1 - \alpha$$

即可构造 $\eta = g(\theta)$ 的置信区间.

上述情形的一个特例是总体存在多个未知标量参数 $\theta, \lambda_1, \dots, \lambda_k$, 而我们想对其中一个未知标量参数 θ 进行区间估计. 此时其余的参数 $\lambda = (\lambda_1, \dots, \lambda_k)$ 被称为**多余参数**

(nuisance parameter, 其它中文称谓还包括冗余参数、讨厌参数、干扰参数等). 存在多余参数 λ 时, θ 的置信水平为 $1 - \alpha$ 的置信区间 $[\underline{\theta}, \bar{\theta}]$ 则需满足如下条件:

$$\mathbb{P}_{\theta, \lambda}([\underline{\theta}, \bar{\theta}] \ni \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta, \lambda \in \Lambda,$$

其中 Θ 为 θ 的取值范围, Λ 为多余参数 λ 的取值范围. 对于存在多余参数的情形, 若要用枢轴量法求 θ 的置信区间, 则要求枢轴量 $h(X_1, \dots, X_n; \theta)$ 只和 $X_1, \dots, X_n$ 与 θ 有关而与 λ 无关, 且同时要求 $h(X_1, \dots, X_n; \theta)$ 的分布与 θ 和 λ 均无关. 此时由

$$\mathbb{P}_{\theta, \lambda}(l \leq h(X_1, \dots, X_n; \theta) \leq u) \geq 1 - \alpha$$

构造的 θ 的置信区间则可用于多余参数 λ 未知的情形. ■

在接下来的几节中, 我们将针对几类常见的区间估计问题, 介绍其置信区间的求解流程. 我们只给出(双侧)置信区间的构造流程, 但读者可自行推导相应的单侧置信上界与单侧置信下界.

8.2 单个总体下的区间估计

8.2.1 正态总体期望的区间估计

方差 σ^2 已知的情形. 我们首先考虑总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 且方差 σ^2 已知的情形. 此时对期望 μ 进行区间估计的步骤与结果已经由例 8.1 给出了: μ 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]. \quad (8.2)$$

现在考虑这样一个问题: 我们希望 μ 的置信区间的宽度小于等于 2ε , 其中 $\varepsilon > 0$ 为事先给定的表征估计精度的常数, 同时保证置信水平为 $1 - \alpha$, 那么样本容量 n 应该至少取为多少? 对于这个问题, 由式 (8.2) 不难得到 n 所应当满足的不等式

$$2z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq 2\varepsilon,$$

解得

$$n \geq \left(\frac{z_{\alpha/2} \sigma}{\varepsilon} \right)^2.$$




图 8.3: 正态总体的方差未知时, 利用枢轴量 $(\bar{X} - \mu)/\sqrt{S^2/n}$ 求解期望的置信区间.

方差 σ^2 未知的情形. 现考虑总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 且期望 μ 与方差 σ^2 均未知的情形. 注意到此时 $\sigma^2 > 0$ 为多余参数, 而 μ 的置信水平为 $1 - \alpha$ 的置信区间 $[\underline{\mu}, \bar{\mu}]$ 则应当满足

$$\mathbb{P}_{\mu, \sigma^2}([\underline{\mu}, \bar{\mu}] \ni \mu) \geq 1 - \alpha, \quad \forall \mu \in \mathbb{R}, \sigma^2 > 0.$$

我们仍采用枢轴量法来求 μ 的置信区间. 在方差 σ^2 未知的情况下, 我们考虑用样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 来代替 σ^2 以构造枢轴量, 从而让枢轴量表达式中不出现多余参数 σ^2 :

$$T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}}.$$

由推论 6.5 可知, T 服从参数为 $n-1$ 的 t 分布, 因而 T 的确可以作为一个枢轴量. 那么在置信水平为 $1 - \alpha$ 时, 利用 $t(n-1)$ 的上分位数可得 (见图 8.3)

$$\mathbb{P}_{\mu, \sigma^2}(-t_{\alpha/2}(n-1) \leq T \leq t_{\alpha/2}(n-1)) = 1 - \alpha,$$

从而有

$$\mathbb{P}_{\mu, \sigma^2} \left(\left[\bar{X} - t_{\alpha/2}(n-1) \sqrt{\frac{S^2}{n}}, \bar{X} + t_{\alpha/2}(n-1) \sqrt{\frac{S^2}{n}} \right] \ni \mu \right) = 1 - \alpha,$$

故 μ 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\bar{X} - t_{\alpha/2}(n-1) \sqrt{\frac{S^2}{n}}, \bar{X} + t_{\alpha/2}(n-1) \sqrt{\frac{S^2}{n}} \right]. \quad (8.4)$$

注 8.4. 当样本容量 n 足够大 (例如 $n \geq 45$) 时, 可以在置信区间 (8.4) 中近似取 $t_{\alpha/2}(n-1) \approx z_{\alpha/2}$. ■




图 8.4: 正态总体的期望未知时, 利用枢轴量 $(n-1)S^2/\sigma^2$ 求解方差的置信区间.

注 8.5. 当总体不再服从正态分布时, 即使样本容量 n 很大, 我们通常也不能用上述方法求出方差未知时期望的一个近似置信区间, 这是因为 $\bar{X}$ 与 S^2 一般来说不再相互独立, 从而推论 6.5 一般来说不再成立. ■

8.2.2 正态总体方差的区间估计

现考虑总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的情形, 其中期望 μ 与方差 σ^2 均未知, 我们对方差 σ^2 进行区间估计, 则此时 μ 成为多余参数.

仍考虑用枢轴量法求解置信区间. 定理 6.3 提示我们, 可以尝试将 $(n-1)S^2/\sigma^2$ 作为枢轴量, 其中 S^2 为样本方差, 则有

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

利用 $\chi^2(n-1)$ 的上分位数, 可得 (见图 8.4)

$$\mathbb{P}_{\mu, \sigma^2} \left(\chi^2_{1-\alpha/2}(n-1) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi^2_{\alpha/2}(n-1) \right) = 1 - \alpha,$$

从而有

$$\mathbb{P}_{\mu, \sigma^2} \left(\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right] \ni \sigma^2 \right) = 1 - \alpha,$$

故方差 σ^2 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right]. \quad (8.5)$$

注 8.6. 虽然 χ^2 分布的概率密度函数不具有对称性, 但在利用服从 χ^2 分布的枢轴量 $h(X_1, \dots, X_n; \theta)$ 构造 (双侧) 置信区间时, 通常仍取 l, u 使得

$$\mathbb{P}(h(X_1, \dots, X_n; \theta) \leq l) = \mathbb{P}(h(X_1, \dots, X_n; \theta) \geq u) = \frac{\alpha}{2},$$

也就是说我们将 $h(X_1, \dots, X_n; \theta)$ 不属于 $[l, u]$ 的概率等分到区间 $[l, u]$ 的两侧. ■

注 8.7. 若正态总体的期望 μ 已知, 则枢轴量可以取为

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2,$$

该枢轴量服从参数为 n 的 χ^2 分布. 接下来 σ^2 置信区间的构造我们留给读者完成. ■

8.2.3 大样本情形下比例的区间估计

本小节中我们考虑这样一个情形: 总体 X 服从参数为 p 的伯努利分布, 但 $p \in [0, 1]$ 未知, 我们希望对 p 进行区间估计. 在一些实际问题中, 若我们想要考察某类对象中满足某个特定条件的对象所占比例如何, 则可以认为总体 X 服从参数为 p 的伯努利分布, 其中 p 就代表待估计的比例.

我们只考虑样本容量 n 足够大的情形. 此时由中心极限定理可知

$$\frac{\bar{X} - p}{\sqrt{p(1-p)/n}}$$

近似服从标准正态分布 $\mathcal{N}(0, 1)$, 故我们可以尝试将其作为枢轴量进行置信区间的计算. 利用标准正态分布的上分位数, 可得

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \leq z_{\alpha/2}\right) \approx 1 - \alpha.$$

注意到上式括号中的不等式等价于

$$\left| \frac{\bar{X} - p}{\sqrt{p(1-p)/n}} \right| \leq z_{\alpha/2}, \quad (8.6)$$

我们可以直接对该不等式两边进行平方, 得到它等价于

$$\left(1 + \frac{z_{\alpha/2}^2}{n}\right) p^2 - \left(2\bar{X} + \frac{z_{\alpha/2}^2}{n}\right) p + \bar{X}^2 \leq 0.$$

求解该关于 p 的一元二次不等式, 可得

$$\underline{p} \leq p \leq \bar{p},$$

其中

$$\begin{aligned}\underline{p} &= \left(1 + \frac{z_{\alpha/2}^2}{n}\right)^{-1} \left(\bar{X} + \frac{z_{\alpha/2}^2}{2n} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{z_{\alpha/2}^2}{4n^2}}\right), \\ \bar{p} &= \left(1 + \frac{z_{\alpha/2}^2}{n}\right)^{-1} \left(\bar{X} + \frac{z_{\alpha/2}^2}{2n} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{z_{\alpha/2}^2}{4n^2}}\right).\end{aligned}$$

由于 $\underline{p}$ 与 $\bar{p}$ 的表达式过于繁琐, 考虑到样本容量 n 比较大, 我们将 $\underline{p}$ 与 $\bar{p}$ 泰勒展开到 $1/\sqrt{n}$ 的一阶项, 可得

$$\begin{aligned}\underline{p} &= \bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} + o\left(\frac{1}{\sqrt{n}}\right), \\ \bar{p} &= \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} + o\left(\frac{1}{\sqrt{n}}\right).\end{aligned}$$

故不等式 (8.6) 在 n 非常大时的近似解为

$$\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \leq p \leq \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}.$$

由此可得

$$\mathbb{P}\left(\left[\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}\right] \ni p\right) \approx 1 - \alpha.$$

也就是说, 当样本容量 n 非常大时, p 的置信水平为 $1 - \alpha$ 的置信区间可以近似取为

$$\left[\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}\right].$$

注 8.8. 实际上, 不等式 (8.6) 的近似解也可通过如下方法得到: 显然不等式 (8.6) 等价于

$$\bar{X} - z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \leq p \leq \bar{X} + z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}.$$

以上不等式中最左端与最右端均依赖于未知参数 p , 故不能作为统计量给出置信区间的端点, 但由于已经假设 n 非常大, 根据大数定律, 可以认为 $\bar{X}$ 的取值将与 p 非常接近,

因而可以在上述不等式的最左端与最右端中把 p 替换为 $\bar{X}$, 由此得到不等式 (8.6) 的如下近似解:

$$\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \leq p \leq \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}.$$

这个结果与之前先严格求解不等式再用泰勒展开近似所得到的结果是一致的. ■

8.3 两个总体下的区间估计

在某些场合下, 我们可能会面临对两个总体进行比较的问题. 例如, 为了验证一种新的食品添加剂在某个剂量下是否具有毒性, 我们可能需要进行如下形式的试验: 首先将足够多的小白鼠分成实验组和对照组, 让实验组的小白鼠按照一定剂量服用该食品添加剂, 而让对照组的小白鼠服用一定剂量的安慰剂, 随后统计并比较两组小白鼠的某项生化指标. 在这个例子中, 我们就可以用两个总体 X_1 与 X_2 分别代表服用食品添加剂小鼠与服用安慰剂小鼠的某项生化指标, 而实验组的检测结果即可看作是总体 X_1 的一组样本 $X_{1,1}, \dots, X_{1,n_1}$, 对照组的检测结果则可看作是总体 Y 的一组样本 $X_{2,1}, \dots, X_{2,n_2}$.

本节中, 我们将对一些两个总体下的区间估计问题进行介绍. 如无特别说明, 我们用 X_1, X_2 表示两个总体, 用 $X_{k,1}, \dots, X_{k,n_k}$ 表示总体 X_k 的一组样本 (其中 $k = 1, 2$), 且假定 $X_{1,1}, \dots, X_{1,n_1}, X_{2,1}, \dots, X_{2,n_2}$ 相互独立. 此外, 用如下符号

$$\bar{X}_k = \frac{1}{n_k} \sum_{i=1}^n X_{k,i}, \quad S_k^2 = \frac{1}{n_k - 1} \sum_{i=1}^n (X_{k,i} - \bar{X}_k)^2, \quad k = 1, 2$$

来表示两组样本 $X_{1,1}, \dots, X_{1,n_1}$ 与 $X_{2,1}, \dots, X_{2,n_2}$ 各自的样本均值和样本方差.

8.3.1 两个正态总体下期望之差的估计

设总体 X_1 服从正态分布 $\mathcal{N}(\mu_1, \sigma_1^2)$, 而总体 X_2 服从正态分布 $\mathcal{N}(\mu_2, \sigma_2^2)$, 我们希望对两个总体的期望的差 $\mu_1 - \mu_2$ 进行区间估计. 我们根据两个总体方差信息的知晓程度, 讨论两种容易求解的情况.

两总体方差均已知的情况. 设两个总体的方差 σ_1^2, σ_2^2 均已知. 我们构造枢轴量

$$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}.$$

利用例 4.13 所给出的两个独立的正态随机变量线性组合后概率分布的结论, 不难验证上述枢轴量服从标准正态分布 $\mathcal{N}(0, 1)$. 由此可得

$$\mathbb{P}_{\mu_1, \mu_2} \left(-z_{\alpha/2} \leq \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \leq z_{\alpha/2} \right) = 1 - \alpha.$$

对上式进行等价变换可得

$$\mathbb{P}_{\mu_1, \mu_2} \left(\left[\bar{X}_1 - \bar{X}_2 - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X}_1 - \bar{X}_2 + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right] \ni \mu_1 - \mu_2 \right) = 1 - \alpha.$$

故 $\mu_1 - \mu_2$ 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\bar{X}_1 - \bar{X}_2 - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X}_1 - \bar{X}_2 + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right].$$

两总体方差未知, 但已知它们相等的情况. 设 σ_1^2, σ_2^2 均未知, 但已知 $\sigma_1^2 = \sigma_2^2$; 习惯上我们用 σ^2 来表示这两个方差共同的值. 此时我们考虑构造一个服从 t 分布的枢轴量. 为此, 我们先利用定理 6.3 得到如下结论:

1. $\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)$, S_1^2 以及 S_2^2 这三个随机变量相互独立;
2. $(n_k - 1)S_k^2/\sigma_k^2 \sim \chi^2(n_k - 1)$, 其中 $k = 1, 2$. 由于 $\sigma_1^2 = \sigma_2^2 = \sigma^2$, 这进一步意味着

$$\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2}$$

服从自由度为 $n_1 + n_2 - 2$ 的 χ^2 分布.

而由于 $\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2) \sim \mathcal{N}(0, \sigma^2(1/n_1 + 1/n_2))$, 接下来我们利用定理 6.4, 即可看出

$$\frac{[\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)] / \sqrt{\sigma^2(1/n_1 + 1/n_2)}}{\sqrt{[(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2] / (\sigma^2(n_1 + n_2 - 2))}} = \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{S_p^2 (1/n_1 + 1/n_2)}} \quad (8.7)$$

服从自由度为 $n_1 + n_2 - 2$ 的 t 分布, 其中我们记

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2};$$

统计量 S_p^2 通常被称为**合并方差** (pooled variance). 故式 (8.7) 给出了一个枢轴量. 利用 t 分布的上分位数, 可得

$$\mathbb{P} \left(-t_{\alpha/2}(n_1 + n_2 - 2) \leq \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{S_p^2 (1/n_1 + 1/n_2)}} \leq t_{\alpha/2}(n_1 + n_2 - 2) \right) = 1 - \alpha.$$




图 8.5: 两个正态总体下, 利用枢轴量 $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$ 求解方差之比的置信区间.

由此可算得 $\mu_1 - \mu_2$ 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\bar{X}_1 - \bar{X}_2 - t_{\alpha/2}(n_1+n_2-2) \sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}, \bar{X}_1 - \bar{X}_2 + t_{\alpha/2}(n_1+n_2-2) \sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \right].$$

8.3.2 两个正态总体下方差之比的估计

设总体 X_1 服从正态分布 $\mathcal{N}(\mu_1, \sigma_1^2)$, 而总体 X_2 服从正态分布 $\mathcal{N}(\mu_2, \sigma_2^2)$, 其中 $\mu_1, \mu_2, \sigma_1, \sigma_2$ 均为未知参数. 我们希望对两个总体的方差之比 σ_1^2/σ_2^2 进行区间估计.

既然是对方差之比进行区间估计, 那么一个自然的想法是利用关于样本方差之比的定理 6.6 来设计枢轴量. 由定理 6.6 可得,

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

利用 F 分布的上分位数, 可得 (见图 8.5)

$$\mathbb{P}\left(F_{1-\alpha/2}(n_1-1, n_2-1) \leq \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \leq F_{\alpha/2}(n_1-1, n_2-1)\right) = 1 - \alpha.$$

对上式括号中的不等式进行等价变换, 易得 σ_1^2/σ_2^2 的一个置信水平为 $1 - \alpha$ 的置信区间为

$$\left[\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1-1, n_2-1)}, \frac{S_1^2/S_2^2}{F_{1-\alpha/2}(n_1-1, n_2-1)} \right],$$

或者根据 F 分布上分位数的性质 (6.1) 式, 也可表示为

$$\left[\frac{S_1^2}{S_2^2} F_{1-\alpha/2}(n_2-1, n_1-1), \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2-1, n_1-1) \right].$$

8.3.3 大样本情形下两个伯努利总体比例之差的区间估计

设 X_1 服从参数为 p_1 的伯努利分布, 而 X_2 服从参数为 p_2 的伯努利分布, 其中 $p_1, p_2 \in [0, 1]$ 均未知. 在两个样本的容量 n_1, n_2 均足够大的情形下, 我们可以利用中心极限定理, 得到

$$\frac{\bar{X}_1 - p_1}{\sqrt{p_1(1-p_1)/n_1}} \quad \text{与} \quad \frac{\bar{X}_2 - p_2}{\sqrt{p_2(1-p_2)/n_2}}$$

均近似服从标准正态分布 $\mathcal{N}(0, 1)$, 且二者互相独立. 进一步可知

$$\frac{\bar{X}_1 - \bar{X}_2 - (p_1 - p_2)}{\sqrt{p_1(1-p_1)/n_1 + p_2(1-p_2)/n_2}}$$

近似服从标准正态分布 $\mathcal{N}(0, 1)$. 但需要注意的是, 上式给出的随机变量并非 $X_1, \dots, X_n$ 与 $p_1 - p_2$ 的函数, 故不能把它作为对 $p_1 - p_2$ 进行区间估计的枢轴变量. 为此, 我们考虑到在大样本情形下, 有如下近似成立:

$$\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}} \approx \sqrt{\frac{\bar{X}_1(1-\bar{X}_1)}{n_1} + \frac{\bar{X}_2(1-\bar{X}_2)}{n_2}},$$

因而可以认为

$$\frac{\bar{X}_1 - \bar{X}_2 - (p_1 - p_2)}{\sqrt{\bar{X}_1(1-\bar{X}_1)/n_1 + \bar{X}_2(1-\bar{X}_2)/n_2}}$$

也近似服从标准正态分布, 且由于该随机变量是 $X_1, \dots, X_n$ 与 $p_1 - p_2$ 的函数, 故可以把它作为近似的枢轴量用于求解置信区间. 利用标准正态分布的分位数, 可得

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X}_1 - \bar{X}_2 - (p_1 - p_2)}{\sqrt{\bar{X}_1(1-\bar{X}_1)/n_1 + \bar{X}_2(1-\bar{X}_2)/n_2}} \leq z_{\alpha/2}\right) \approx 1 - \alpha.$$

上式括号中的不等式可等价变形为

$$\underline{\Delta} \leq p_1 - p_2 \leq \bar{\Delta},$$

其中

$$\begin{aligned} \underline{\Delta} &= \bar{X}_1 - \bar{X}_2 - z_{\alpha/2} \sqrt{\frac{\bar{X}_1(1-\bar{X}_1)}{n_1} + \frac{\bar{X}_2(1-\bar{X}_2)}{n_2}}, \\ \bar{\Delta} &= \bar{X}_1 - \bar{X}_2 + z_{\alpha/2} \sqrt{\frac{\bar{X}_1(1-\bar{X}_1)}{n_1} + \frac{\bar{X}_2(1-\bar{X}_2)}{n_2}}. \end{aligned}$$

由此可得, $p_1 - p_2$ 的置信水平为 $1 - \alpha$ 的置信区间可近似取为 $[\underline{\Delta}, \bar{\Delta}]$.

8.4 习题

习题 8.1. 考虑对正态总体 $\mathcal{N}(\mu, \sigma^2)$ 的期望 μ 进行区间估计, 其中 σ^2 已知, 样本容量为 n , 并取置信水平为 $1 - \alpha$. 证明对于如下形式的置信区间

$$\left[\bar{X} - z_{\lambda\alpha} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{(1-\lambda)\alpha} \frac{\sigma}{\sqrt{n}} \right],$$

取 $\lambda = 1/2$ 将使置信区间宽度达到最小.

习题 8.2. 某检测机构对某条河流的水体进行了取样, 获得了一个容量为 36 的样本, 并对其锌离子浓度进行了测量, 得到锌离子浓度的样本均值为 0.260 毫克/升. 已知该河流水体的锌离子浓度测量值服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其标准差 σ 为 0.03 毫克/升.

1. 试求 μ 的置信水平分别为 95% 与 99% 的置信区间.
2. 若要求置信水平为 95% 的同时让置信区间的宽度小于等于 0.1 毫克/升, 则样本容量应至少为多大?

习题 8.3. 某研究机构针对某地大嘴鲈鱼的汞污染进行了调查. 研究人员从当地的湖泊中随机抓取了 53 条大嘴鲈鱼, 并测量了这些鱼肌肉组织内的汞浓度, 数据如下表所列 (单位为 ppm):

1.230	0.490	0.490	1.080	0.590	0.280	0.180	0.100	0.940
1.330	0.190	1.160	0.980	0.340	0.340	0.190	0.210	0.400
0.040	0.830	0.050	0.630	0.340	0.750	0.040	0.860	0.430
0.044	0.810	0.150	0.560	0.840	0.870	0.490	0.520	0.250
1.200	0.710	0.190	0.410	0.500	0.560	1.100	0.650	0.270
0.270	0.500	0.770	0.730	0.340	0.170	0.160	0.270	

设该地大嘴鲈鱼肌肉组织内的汞浓度服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 μ 未知. 试求下列两种情形下 μ 的置信水平为 95% 的置信区间.

1. σ^2 未知.
2. 基于大量历史数据, 确定 $\sigma = 0.3846$.

习题 8.4. 某工厂对其生产的涂料进行了粘着力测试, 共随机抽取了 22 件产品组成一组样本, 并对它们发生脱落时的张力强度进行了测量, 数据如下 (单位为 MPa):

19.8	19.8	14.9	7.5	15.4	15.4	15.4	15.4	7.9	12.7	11.9
11.4	11.4	11.4	17.6	16.7	15.8	19.5	19.5	13.6	11.9	11.4

设该涂料发生脱落时的张力强度服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 μ 与 σ^2 均未知. 试求 μ 的置信水平为 95% 的置信区间.

习题 8.5. 某生产洗衣液的工厂用一台机器对洗衣液进行灌装, 由于精度问题, 该机器每次灌装的洗衣液体积带有一定误差, 设灌装体积服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 μ 与 σ^2 均未知. 工厂随机抽查了 20 瓶用该机器灌装的洗衣液, 测出它们的灌装体积的样本方差为 13.38 (单位: 平方毫升). 试求出 σ^2 的置信水平为 95% 的单侧置信上界.

习题 8.6. 一家工厂在对其生产的某个批次的轴承进行抽查时发现, 在随机选取的 85 个轴承中有 10 个质量未达标. 试求该批次轴承劣品率的置信水平为 95% 的置信区间.

习题 8.7. 某家涂料工厂希望提升其产品的干燥速度, 故而尝试了一种新配方. 为了测试新配方的有效性, 厂家在其实验室内对涂料的干燥时间进行了测试, 其中对老配方测试了 10 次, 平均干燥时间为 121 分钟; 对新配方也测试了 10 次, 平均干燥时间为 112 分钟. 设两种配方涂料的干燥时间分别服从正态分布 $\mathcal{N}(\mu_1, \sigma^2)$ (老配方) 与 $\mathcal{N}(\mu_2, \sigma^2)$ (新配方), 且通过前期研究已确定 σ 为 8 分钟. 试求 $\mu_1 - \mu_2$ 的置信水平为 95% 的置信区间.

习题 8.8. 某个评测机构需要对两种型号的汽车在行驶速度为 90 km/h 时的油耗进行比较. 该机构对 12 台 A 型号汽车与 10 台 B 型号汽车的每升油行驶里程进行了测试, 测得 12 台 A 型号汽车每升油行驶里程的样本均值为 16 km, 样本标准差为 1.0 km; 10 台 B 型号汽车每升油行驶里程的样本均值为 11 km, 样本标准差为 0.8 km. 假设这两种汽车的每升油行驶里程都服从正态分布, 且方差相等. 试求这两种汽车每升油平均行驶里程之差的置信区间, 取置信水平为 90%.

注: 本题选自 [21] 第 9 章习题 9.42.

习题 8.9. 硅晶圆的生产过程中需要对晶圆表面进行氧化, 而氧化层厚度的均匀性将直接影响后续半导体器件的生产过程. 某家工厂对两种氧化工艺进行了测试, 在实验室中将两种氧化工艺各自用于对 16 片晶圆的表面进行氧化, 并测量了氧化层的厚度. 设第一种氧化工艺下 16 片晶圆氧化层厚度的样本标准差 (样本方差的算术平方根) 为 1.96

埃, 第二种氧化工艺下 16 片晶圆氧化层厚度的样本标准差为 2.13 埃. 设两种氧化工艺下氧化层的厚度均服从正态分布, 方差分别记为 σ_1^2 与 σ_2^2 . 试求 σ_1^2/σ_2^2 的置信水平为 95% 的置信区间.

习题 8.10. 某家药厂开发出了一种治疗抑郁症的新药, 现在需要进行临床试验验证其疗效. 共有 200 名抑郁症患者参与了试验, 这 200 名患者被随机等分为实验组与对照组, 其中实验组的患者服用新药, 而对照组的患者服用安慰剂, 每名患者对于自己在实验组还是对照组以及服用的是新药还是安慰剂均不知情. 设经过一段时间的治疗后, 实验组中有 27 人的病情出现了好转, 而对照组中有 19 人的病情出现了好转. 若将新药在抑郁症人群中产生疗效的比例记为 p_1 , 将安慰剂在抑郁症人群中产生疗效的比例记为 p_2 , 试求 $p_1 - p_2$ 的置信水平为 95% 的置信区间.

习题 8.11 (配对样本下的区间估计). 下表给出了某区随机选取的 9 名高三学生生物科目的一模考试与二模考试的分数:

学生编号	1	2	3	4	5	6	7	8	9
一模分数	83	68	80	86	89	74	82	76	83
二模分数	90	70	76	83	95	78	81	85	88

设该区高三学生生物科目二模平均分为 μ_2 , 一模平均分为 μ_1 . 此外, 任选一名该区的高三学生, 其生物科目的二模分数与一模分数的差服从正态分布. 试求 $\mu_2 - \mu_1$ 的一个置信水平为 95% 的置信区间.

提示 在这个问题中, 我们不能将一模分数与二模分数看成来自两个不同总体的相互独立的样本, 这是因为一名学生的一模分数与二模分数之间通常存在相关性.

习题 8.12. 设总体 X 服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 为未知参数, 样本容量记为 n .

1. 若 σ^2 已知, 则 n 应当满足什么条件, 能保证 μ 的置信水平为 $1 - \alpha$ 的置信区间的宽度小于等于 $\sigma/4$?
2. 现设 σ^2 未知.
 - (a) 试求 μ 的置信水平为 $1 - \alpha$ 的置信区间的宽度的期望.
 - (b) n 应当满足什么条件, 能保证 μ 的置信水平为 $1 - \alpha$ 的置信区间的宽度能以

0.9 的概率小于等于 $\sigma/4$?

注: 本题改编自 [16] 第 9 章习题 9.34 与 9.35.

习题 8.13. 设总体 X 服从期望为 θ 的指数分布, 其中 $\theta > 0$ 未知. 试用枢轴量法求出 θ 的一个置信水平为 $1 - \alpha$ 的置信区间.

提示 利用习题 6.4 的结论.

习题 8.14. 设总体服从区间 $[0, \theta]$ 上的均匀分布, 其中 $\theta > 0$ 为未知参数, $X_1, \dots, X_n$ 为该总体的一组样本. 任取 $0 < \alpha < 1$, 试求 θ 的一个置信水平为 $1 - \alpha$ 的置信区间.

提示 试求 $\theta^{-1} \max\{X_1, \dots, X_n\}$ 的概率密度函数. 它是否可以作为一个枢轴量?

注: 本题取自 [22] 第 8.9 节习题 22.

第九章 假设检验

9.1 假设检验的问题设定与流程

本章中, 我们介绍数理统计中的另一大类问题: **假设检验** (hypothesis testing). 在假设检验问题中, 我们对总体具体服从怎样的分布提出一种假设, 并收集样本数据, 检验样本数据是否与提出的假设存在统计意义上的不一致/不相容. 本章中除了最后一节外, 我们主要考虑总体的分布可以被某个未知参数 θ 参数化的情形, 则此时对于总体的假设就归结为一个表示参数范围的集合. 我们用

$$H : \theta \in \Theta_0$$

来表示这样一个假设 H : 当总体的真实参数 θ 为集合 Θ_0 的元素时, 就认为假设 H 成立, 否则认为假设 H 不成立. 下面几个例子给出了假设检验问题中一些常见的假设形式:

- 总体服从正态分布 $\mathcal{N}(\mu, \sigma_0^2)$, 其中方差 σ_0^2 已知但期望 μ 未知. 此时我们把 μ 作为未知参数, 则假设

$$H : \mu = \mu_0$$

表示“总体服从正态分布 $\mathcal{N}(\mu_0, \sigma_0^2)$ ”.

- 总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 与方差 σ^2 均为未知参数. 则假设

$$H : \mu = \mu_0, \sigma^2 > 0$$

表示“总体服从期望为 μ_0 的某个正态分布”. 注意这一假设当中并未把方差 σ^2 限定为单个值.

- 总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 与方差 σ^2 均为未知参数. 则假设

$$H : \mu \neq \mu_0, \sigma^2 > 0$$

表示“总体服从期望不等于 μ_0 的某个正态分布”.

- 总体服从正态分布 $\mathcal{N}(\mu_0, \sigma^2)$, 其中期望 μ_0 已知但方差 σ^2 为未知参数, σ_0 为某个给定实数. 则假设

$$H: \sigma^2 > \sigma_0^2$$

表示“总体服从方差大于 σ_0^2 的某个正态分布”.

若假设 $H: \theta \in \Theta_0$ 中 Θ_0 只包含一个元素, 则称 H 为**简单假设** (simple hypothesis); 否则称 H 为**复合假设** (composite hypothesis). 在上述四个例子中, 只有第一个例子是简单假设, 而后三个例子都是复合假设.

在假设检验问题中, 我们通常会提出两个假设 H_0 与 H_1 , 其中 H_0 被称为**原假设**或**零假设** (null hypothesis), 而 H_1 被称为**备择假设** (alternative hypothesis), H_0 与 H_1 当中有且仅有一个假设成立. 当总体的分布能够被未知参数 θ 参数化时, 原假设 H_0 与备择假设 H_1 就可以用各自相应的参数范围表示为如下形式:

$$H_0: \theta \in \Theta_0, \quad H_1: \theta \in \Theta_1,$$

其中 Θ_0 与 Θ_1 为给定的集合, $\Theta_0 \cup \Theta_1$ 包含了未知参数 θ 的所有可能取值, 而 $\Theta_0 \cap \Theta_1 = \emptyset$. 在后面我们将看到, 在频率学派的假设检验理论中, 原假设与备择假设有着不一样的地位. 在许多实际场合中, 我们做假设检验的目的是利用收集到的样本数据, 以统计上足够可靠的方式, 揭示出某种尚未发现或证实的规律或现象, 此时通常取原假设表示总体符合已知规律或常理, 或是总体与旧有理论相容, 而备择假设则用来表示总体按照某种方式或朝着某个方向偏离了已知规律或常理, 或是出现了某种旧有理论解释不了的状态. 尤其在科学研究过程中, 当我们获取了足够的实验数据并希望用假设检验的框架分析是否有新发现, 或是新方法是否有效时, 我们往往把“没有新发现”“旧理论成立”“新方法无效”作为原假设, 并希望获得的实验数据能够给出充分可靠的证据来否定原假设.

现设原假设为 $H_0: \theta \in \Theta_0$, 备择假设为 $H_1: \theta \in \Theta_1$. 简单起见我们先考虑 Θ_0 只包含一个元素 θ_0 , 也就是说 H_0 是简单假设的情形, 此时一套典型的假设检验的流程如下:

1. 根据原假设 H_0 与备择假设 H_1 的形式, 设计一个统计量 $T = \phi(X_1, \dots, X_n)$, 使得当 H_0 成立时, T 具有取值偏小的趋势, 而 H_1 成立时, T 具有取值偏大的趋势. 我们把这个统计量 T 称为**检验统计量** (test statistic).

2. 在获取到具体的样本值 $x_1, \dots, x_n$ 以后, 先算出 $t = \phi(x_1, \dots, x_n)$, 而后计算

$$\hat{p} = \mathbb{P}_{\theta_0}(T \geq t) = \mathbb{P}_{\theta_0}(\phi(X_1, \dots, X_n) \geq t). \quad (9.1)$$

我们对式 (9.1) 所定义的 $\hat{p}$ 进行进一步解释. 首先, 我们需要获取一组样本值 $x_1, \dots, x_n$; 随后, 我们考察这样一个问题: 设 H_0 成立, 若我们再从总体中抽样得到一组新的样本, 则这组新样本对应的检验统计量的值大于等于已获取样本值 $x_1, \dots, x_n$ 对应的检验统计量的值的概率 $\mathbb{P}_{\theta}(T \geq t)$ 是多少; 或者说, H_0 成立时, 与已获取样本检验统计量的取值相比, 新样本的检验统计量取同样极端或更加极端的值的概率是多少. 我们将这个概率 $\hat{p}$ 称为样本值 $x_1, \dots, x_n$ 的 **p 值** (p -value).

3. 根据 p 值的大小, 判断获取到的样本值 $x_1, \dots, x_n$ 与原假设 H_0 之间是否存在统计意义上的不一致.
- 若 p 值非常小 (例如小于 0.01), 则意味着在原假设 H_0 下, 产生与现有样本值相比同样极端或更加极端的样本是小概率事件. 我们依照**小概率原理**的精神, 认为小概率事件在一次观察中基本不可能发生, 故可以认为获取到的样本值 $x_1, \dots, x_n$ 相对于原假设 H_0 发生了显著的偏离, 这也就意味着该组样本值为否定原假设提供了统计上显著的证据.
 - 反之, 若 p 值并不是非常小 (例如大于 0.1), 那么我们认为获取到的样本值 $x_1, \dots, x_n$ 并不能为否定原假设 H_0 提供统计上显著的证据. 但须注意, 此时也不意味着有充分证据支持 H_0 成立.

原则上看, 由于 p 值是可以连续分布于区间 $[0, 1]$ 内的, 当我们把它作为样本值 $x_1, \dots, x_n$ 与原假设之间不一致程度的定量指标时, 这个指标也是连续渐变而非一刀切的. 许多场合下, 我们会直接将具体的 p 值作为假设检验的最终结论. 但在其它一些场合, 我们可能需要明确地在原假设 H_0 与备择假设 H_1 之间进行二选一, 此时我们会在假设检验之前事先划定一个阈值 α , 而当最后算出的 p 值小于 α 时即拒绝原假设 H_0 而接受备择假设 H_1 , 否则接受原假设 H_0 而拒绝备择假设 H_1 . 典型的阈值包括 $\alpha = 0.05$ 与 $\alpha = 0.01$ 等, 但阈值的设定也应具体问题具体分析. 我们也把这个事先设定的阈值 α 称为上述假设检验流程的**显著性水平** (significance level).

观察上述假设检验的流程不难发现, 该流程中除了检验统计量 T 的设计以外, 似乎与备择假设 H_1 没有什么直接关系. 我们通过下面的例子对此进行说明.

例 9.1 (方差已知时正态分布期望的假设检验). 已知总体 X 服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中方差 σ^2 已知但期望 μ 未知, 只知道 μ 大于等于某个给定的值 μ_0 . 我们希望检验 μ 是等于 μ_0 还是大于 μ_0 . 此时可取原假设 H_0 与备择假设 H_1 分别为

$$H_0: \mu = \mu_0, \quad H_1: \mu > \mu_0.$$

考虑到备择假设与原假设的差异仅体现在期望上, 且备择假设 H_1 的期望相较于原假设 H_0 的期望偏大, 故我们考虑用

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}},$$

作为检验统计量; 直观上看, 备择假设 H_1 下 Z 的取值相较于原假设 H_0 下具有偏大的趋势. 上式中的分母 $\sigma/\sqrt{n}$ 在这个例子中无关紧要, 只是为了让 Z 在假设 H_0 下的方差被归一化, 以方便 p 值的计算.

现假设我们获取了一组样本值 $x_1, \dots, x_n$, 并记

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}, \quad \text{其中 } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

由于 H_0 为简单假设, 故相应的 p 值就直接等于

$$\begin{aligned} \hat{p} &= \mathbb{P}_{\mu_0}(Z \geq z) \\ &= 1 - \Phi(z) = 1 - \Phi\left(\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}\right). \end{aligned}$$

如若设定了显著性水平 α 并需要决定是否拒绝 H_0 , 则当 $1 - \Phi(z) < \alpha$, 也即

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} > z_\alpha$$

时我们拒绝 H_0 , 否则不拒绝 H_0 . ■

我们发现, 在例 9.1 当中, 备择假设 H_1 的作用仅体现在检验统计量的设计上, 而且也仅仅起到一种经验性的指导作用. 而若要系统性地回答“如何设计检验统计量”这一问题, 则首先需要回答“什么样的检验统计量是一个好的检验统计量”, 而这这就要求我们给出检验统计量的定量评价方法. 我们将在 9.2 节对频率学派的 Neyman-Pearson 理论进行初步的介绍.

另一方面, 限于本讲义面对的读者群体, 我们也不要求读者掌握较为一般的情况下检验统计量的设计方法, 而只是在随后的几节中, 针对一些常见的假设检验问题, 给出相应的检验统计量以及检验步骤.

9.1.1 双侧检验

在本节一开始给出的假设检验流程中, 我们要求检验统计量 $T = \phi(X_1, \dots, X_n)$ 在原假设成立时具有取值偏小的趋势, 而在备择假设成立时具有取值偏大的趋势. 也就是说, 从检验统计量 T 的视角来看, 备择假设相对于原假设的偏离是单侧 (one-sided) 的. 但对某些问题而言, 考虑双侧 (two-sided) 的检验统计量 T 可能是更合理的: 原假设成立时 T 的取值相对集中, 而备择假设成立时 T 则既可能具有取值偏大的趋势, 也可能有取值偏小的趋势; 或者说, T 取过大的值或者过小的值都提示着相对于原假设出现了偏离. 一般来说, 给定原假设 $H_0: \theta \in \Theta_0$ 与备择假设 $H_1: \theta \in \Theta_1$, 若集合 Θ_1 相对于 Θ_0 既包括正向的偏离也包括负向的偏离, 则会考虑采用双侧的检验统计量.

若采用双侧的检验统计量 T 进行假设检验, 且原假设为简单假设 $H_0: \theta = \theta_0$, 则相应的 p 值可采取如下定义¹:

$$\hat{p} = 2 \min \{ \mathbb{P}_{\theta_0}(T \geq t), \mathbb{P}_{\theta_0}(T \leq t) \}, \quad (9.2)$$

换句话说, 我们将考虑 T 的取值在两个方向上的极端性, 而只要在一个方向上取值是极端的, 我们就让 $\hat{p}$ 取一个很小的值. 我们把这类基于双侧检验统计量, 且 p 值由式 (9.2) 给出的假设检验过程称为**双侧检验**.

我们对式 (9.2) 当中出现的系数 2 做出一些解释: 设 T 为某个假设检验问题的双侧检验统计量, 且在原假设 $H_0: \theta = \theta_0$ 下, T 服从连续型分布, 其相对于原点具有对称性:

$$\mathbb{P}_{\theta_0}(T \geq x) = \int_x^{+\infty} f_T(y; \theta_0) dy = \int_{-\infty}^{-x} f_T(y; \theta_0) dy = \mathbb{P}_{\theta_0}(T \leq -x), \quad \forall x \in \mathbb{R} \quad (9.3)$$

该对称性意味着用 $|T|$ 作为单侧检验统计量也是合理的. 若用 T 作为双侧检验统计量, 则相应的 p 值为

$$\begin{aligned} \hat{p}_2 &= 2 \min \{ \mathbb{P}_{\theta_0}(T \geq t), \mathbb{P}_{\theta_0}(T \leq t) \} \\ &= 2 \min \{ \mathbb{P}_{\theta_0}(T \geq t), \mathbb{P}_{\theta_0}(T \geq -t) \} = 2 \mathbb{P}_{\theta_0}(T \geq |t|). \end{aligned}$$

¹ 当 T 在原假设下的分布不是连续型分布时, 理论上不排除 (9.2) 给出大于 1 的 p 值的可能性, 此时我们通常强行取 $\hat{p} = 1$.

(*) 此外, 当 T 在原假设下的分布不是连续型分布时, 相应的双侧检验的 p 值也存在其它定义方法, 典型的如 [18] 第 4.7 节所给出的定义. 与 [18] 第 4.7 节的定义相比, 式 (9.2) 定义的 p 值可能会略偏大, 从而对样本值偏离原假设程度的判断会更保守一些, 但胜在易于理解、计算方便.

而若采用 $|T|$ 作为单侧检验统计量, 相应的 p 值为

$$\hat{p}_1 = \mathbb{P}_{\theta_0}(|T| \geq |t|) = \mathbb{P}_{\theta_0}(T \geq |t|) + \mathbb{P}_{\theta_0}(T \leq -|t|) = 2\mathbb{P}_{\theta_0}(T \geq |t|).$$

故 $\hat{p}_2 = \hat{p}_1$. 这说明当对称性 (9.3) 得到满足时, 无论用 T 进行双侧假设检验还是用 $|T|$ 进行单侧的假设检验, 给出的结果都是一致的. 这也就是为什么定义式 (9.2) 中需要加上系数 2.

若对称性 (9.3) 得不到满足, 则通常不考虑用 $|T|$ 进行单侧的假设检验. 在 9.3.3 小节中我们将讨论正态总体方差的假设检验问题, 其中用到的检验统计量 X^2 对于假设检验问题 $H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2$ 就是一个典型的双侧检验统计量.

例 9.2. 已知总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中方差 σ^2 已知而期望 μ 未知, 且 μ 的所有可能取值覆盖整个实数集 $\mathbb{R}$. 考虑如下原假设与备择假设:

$$H_0: \mu = \mu_0, \quad H_1: \mu \neq \mu_0,$$

其中 μ_0 为给定的实数. 该问题当中 H_1 相对于 H_0 的偏离体现在期望上, 且既包括正向的偏离也包括负向的偏离. 故我们考虑将

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

作为双侧检验统计量. 直观上看, 在原假设 H_0 下 Z 的取值相对于备择假设 H_1 下具有更加集中于 0 附近的趋势, 而当 Z 在某一组样本上的取值过大或过小时, 可以认为原假设 H_0 与该样本值之间出现了不一致.

现设 $x_1, \dots, x_n$ 为观测到的一组样本值, 并记

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}, \quad \text{其中 } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

则 p 值为

$$\begin{aligned} \hat{p} &= 2 \min \{ \mathbb{P}_{\theta_0}(Z \geq z), \mathbb{P}_{\theta_0}(Z \leq z) \} \\ &= 2 \min \{ 1 - \Phi(z), \Phi(z) \} \\ &= 2 \min \{ 1 - \Phi(z), 1 - \Phi(-z) \} \\ &= 2(1 - \Phi(|z|)) = 2 \left(1 - \Phi \left(\frac{|\bar{x} - \mu|}{\sigma/\sqrt{n}} \right) \right). \end{aligned}$$

而若设定了显著性水平 α 并需要决定是否拒绝 H_0 , 则当 $2(1 - \Phi(|z|)) < \alpha$, 也即

$$|z| = \frac{|\bar{x} - \mu_0|}{\sigma/\sqrt{n}} > z_{\alpha/2}$$

时我们拒绝 H_0 , 否则不拒绝 H_0 .

对于该假设检验问题, 也可以用 $|Z|$ 作为单侧检验统计量, 最后得到的结果是一样的. ■

9.2 假设检验的 Neyman–Pearson 理论简介

假设检验的 Neyman–Pearson 理论是由统计学家 Jerzy Neyman 与 Egon Pearson 发展起来的, 是一套广为接受的频率学派的假设检验理论, 也是大多数数理统计教科书中频率学派假设检验的标准理论. Neyman–Pearson 理论的几个核心要点如下:

1. Neyman–Pearson 理论面向的是在原假设与备择假设之间二选一的假设检验问题: 需事先设定一个显著性水平 $\alpha \in]0, 1[$, 当 p 值小于 α 时拒绝 H_0 而接受 H_1 , 当 p 值大于等于 α 时接受 H_0 而拒绝 H_1 .
2. 基于第 1 点, Neyman–Pearson 理论进一步引入了**第 I 类错误**与**第 II 类错误**的概念, 分别对应于 H_0 成立时拒绝 H_0 , 以及 H_1 成立时接受 H_0 两种情况. 可以证明, 当 H_0 为简单假设时, 若检验统计量在 H_0 下服从连续型分布, 则 H_0 成立时发生第 I 类错误的概率就等于显著性水平 α .
3. 在引入两类错误后, Neyman–Pearson 理论用如下方法评价检验统计量 T 的优劣程度: 在给定任一显著性水平 α 后, 考察用 T 进行假设检验时导致的第 II 类错误的概率; 大致来说, 这个概率越小, 则认为 T 是越好的检验统计量.

注 9.1. (*) 有些教材中会认为“不拒绝 H_0 ”并不意味着“接受 H_0 ”, 出现这种看法主要是因为频率学派的假设检验实际上应当分为两种范式: Fisher 的显著性检验范式与 Neyman–Pearson 的假设检验范式. Fisher 显著性检验范式的目的在于用 p 值对样本值与原假设的不一致性进行定量的衡量, 其中备择假设只用于指导检验统计量的设计 (在 Fisher 的原始理论中甚至没有备择假设); 而 Neyman–Pearson 假设检验范式则是一个二选一的决策过程, 其中的备择假设直接与第 II 类错误及其概率的定量刻画相关. 这两套范式用到的数学理论有很明显的重叠, 但在对结果的诠释上是应当做出区分的, 然而目前的教学往往将二者混淆在一起. 笔者认为, 在 Fisher 的显著性检验范式中, 较大的 p 值的确并不意味着可以接受 H_0 , 而只能表明现有的数据尚不能构成否定 H_0 的有力证据; 但在 Neyman–Pearson 的假设检验范式中, 由于已经将 H_1 成立时不拒绝 H_0 归类为一种错误, 并且考虑了应当如何对这种错误进行定量刻画甚至最小化, 故实际上已无

必要对“不拒绝 H_0 ”与“接受 H_0 ”做出区分. ■

接下来我们对上述内容进行进一步展开. 为简单起见, 我们假定原假设 $H_0: \theta = \theta_0$ 是一个简单假设.

9.2.1 假设检验的拒绝域法

当我们设定了显著性水平 $\alpha \in]0, 1[$, 并要求假设检验过程必须在 H_0 与 H_1 之间二选一时, 可以将假设检验的过程等价地用另一种流程表述. 我们用 $\hat{p}(x_1, \dots, x_n)$ 来表示样本值 $x_1, \dots, x_n$ 对应的 p 值, 则在给定显著性水平 α 后, 假设检验的过程可以总结为

$$\text{若 } \hat{p}(x_1, \dots, x_n) < \alpha, \text{ 则拒绝 } H_0; \text{ 否则接受 } H_0. \quad (\text{P})$$

设检验统计量 $T = \phi(X_1, \dots, X_n)$ 是单侧的. 此时我们令

$$c_\alpha = \max\{c \in \mathbb{R} \mid \mathbb{P}_{\theta_0}(T \geq c) \geq \alpha\}; \quad (9.4)$$

换句话说, c_α 为满足不等式 $\mathbb{P}_{\theta_0}(T \geq c) \geq \alpha$ 的所有实数 c 当中最大的数. 则可以证明

$$\hat{p}(x_1, \dots, x_n) < \alpha \iff \phi(x_1, \dots, x_n) > c_\alpha.$$

这意味着我们可以把假设检验的过程等价地写为

$$\text{若 } \phi(x_1, \dots, x_n) > c_\alpha, \text{ 则拒绝 } H_0; \text{ 否则接受 } H_0. \quad (\text{C1})$$

也就是说, 我们只需算出样本值 $x_1, \dots, x_n$ 所对应的检验统计量 T 的取值, 并将其与 c_α 比较即可判断是否应当拒绝 H_0 . 我们将式 (9.4) 给出的 c_α 称为 (显著性水平为 α 时检验统计量 T 的) **临界值** (critical value), 并将集合

$$C_\alpha =]c_\alpha, +\infty[$$

称为**拒绝域** (rejection region 或 critical region).

当原假设 H_0 下检验统计量 T 为连续型随机变量, 且 T 的概率密度函数在某个开区间上恒大于 0 而在该开区间外恒等于 0 时, 单侧检验的临界值 c_α 可通过求解方程

$$\mathbb{P}_{\theta_0}(T \geq c_\alpha) = \alpha \quad (9.5)$$

得到. 在例 9.1 当中, 我们实际上已经求出了显著性水平为 α 时检验统计量 Z 的临界值为 z_α , 它也可直接由方程 (9.5) 解出:

$$\mathbb{P}_{\mu_0}(Z \geq c_\alpha) = \alpha \iff c_\alpha = z_\alpha.$$

对于双侧检验, 则需要用两个临界值来框定拒绝域:

$$\begin{aligned} c_\alpha^u &= \max\left\{c \in \mathbb{R} \mid \mathbb{P}_{\theta_0}(T \geq c) \geq \frac{\alpha}{2}\right\}, \\ c_\alpha^l &= \min\left\{c \in \mathbb{R} \mid \mathbb{P}_{\theta_0}(T \leq c) \geq \frac{\alpha}{2}\right\}. \end{aligned} \quad (9.6)$$

此时可以证明

$$\hat{p}(x_1, \dots, x_n) < \alpha \iff \phi(x_1, \dots, x_n) > c_\alpha^u \text{ 或 } \phi(x_1, \dots, x_n) < c_\alpha^l.$$

这意味着我们可以把假设检验的过程等价地写为

$$\text{若 } \phi(x_1, \dots, x_n) > c_\alpha^u \text{ 或 } \phi(x_1, \dots, x_n) < c_\alpha^l, \text{ 则拒绝 } H_0; \text{ 否则接受 } H_0. \quad (\text{C2})$$

相应的拒绝域为

$$C_\alpha =]-\infty, c_\alpha^l[\cup]c_\alpha^u, +\infty[.$$

而若 T 在原假设下还是连续型随机变量, 且概率密度函数在某个开区间上恒大于 0 而在该开区间外恒等于 0, 则双侧检验的两个临界值可通过求解方程

$$\mathbb{P}_{\theta_0}(T \geq c_\alpha^u) = \mathbb{P}_{\theta_0}(T \leq c_\alpha^l) = \frac{\alpha}{2} \quad (9.7)$$

得到.

习惯上, 我们将 (P) 给出的判断是否拒绝 H_0 的方法称为 **p 值法**, 而将 (C1) 与 (C2) 给出的方法称为**临界值法**或**拒绝域法**. p 值法与拒绝域法等价性的证明则作为选读内容, 感兴趣的读者可参阅附录 C.1.

9.2.2 第 I 类错误与第 II 类错误

在 Neyman-Pearson 理论中, 我们将假设检验发生的错误分为两类:

1. 当原假设 H_0 成立 (即总体的真实参数 θ 属于 Θ_0) 时, 若假设检验过程给出的结论是拒绝原假设, 则称发生了**第 I 类错误** (type I error).

2. 当备择假设 H_1 成立 (即总体的真实参数 θ 属于 Θ_1) 时, 若假设检验过程给出的结论是接受原假设, 则称发生了**第 II 类错误** (type II error).

在定义了两类错误以后, Neyman–Pearson 理论会进一步考察发生第 I 类错误与第 II 类错误的概率. 这里我们对“发生错误的概率”进行一些必要的说明与澄清: 由于 Neyman–Pearson 理论属于频率学派理论, 因而总体的未知参数 θ 是一个确定性的未知量. 在 Neyman–Pearson 理论中, 假设检验结果的随机性来自于样本的随机性, 我们会考察

1. 当总体真实参数 θ 属于 Θ_0 时, 若通过反复从总体中抽样, 大量地重复用检验统计量 T 进行假设检验, 则检验结果中发生第 I 类错误 (此时的错误也只能是第 I 类错误) 的频率在重复次数趋于无穷时将趋于多少;
2. 当总体真实参数 θ 属于 Θ_1 时, 若通过反复从总体中抽样, 大量地重复用检验统计量 T 进行假设检验, 则检验结果中发生第 II 类错误 (此时的错误也只能是第 II 类错误) 的频率在重复次数趋于无穷时将趋于多少.

根据概率的频率诠释 (或者说大数定律), 可知以上两种被考察的量分别为

$$\mathbb{P}_\theta(T \in C_\alpha) = \mathbb{P}_\theta(\phi(X_1, \dots, X_n) \in C_\alpha), \quad \theta \in \Theta_0 \quad (9.8)$$

以及

$$\mathbb{P}_\theta(T \notin C_\alpha) = \mathbb{P}_\theta(\phi(X_1, \dots, X_n) \notin C_\alpha), \quad \theta \in \Theta_1, \quad (9.9)$$

其中 C_α 表示显著性水平为 α 的拒绝域. 我们将 (9.8) 给出的概率称作 (原假设成立时) 发生第 I 类错误的概率, 而将 (9.9) 给出的概率称作 (备择假设成立时) 发生第 II 类错误的概率. 这两类错误概率的值都依赖于 θ 的值. 我们还会引入**功效函数** (power function)

$$w(\theta) = w_T^\alpha(\theta) = \mathbb{P}_\theta(T \in C_\alpha), \quad \theta \in \Theta_0 \cup \Theta_1.$$

不难看出, $w(\theta)$ 在 $\theta \in \Theta_0$ 时等于第 I 类错误的概率, 而在 $\theta \in \Theta_1$ 时等于 1 减去第 II 类错误的概率.

可以证明, 当 Θ_0 仅包含单个点 θ_0 (即原假设 H_0 为简单假设), 且检验统计量 T 为连续型随机变量时, 有

$$\mathbb{P}_{\theta_0}(T \in C_\alpha) = \alpha.$$

也就是说, 显著性水平 α 就等于第 I 类错误的概率. 对于更一般的情况, 可以证明 $\mathbb{P}_{\theta_0}(T \in C_\alpha) \leq \alpha$, 也就是说显著性水平 α 给出了第 I 类错误概率的一个上界; 证明参见

附录 C.2, 为选读内容.

一般来说, 在样本容量固定的情况下, 我们不可能同时让第 I 类错误的概率与第 II 类错误的概率都取得任意小. 在 Neyman-Pearson 理论中, 我们会先固定一个显著性水平, 或者说为第 I 类错误的概率设定一个上限作为约束, 而后在这个约束下, 考察应如何选取检验统计量 T , 使得 $w_T^\alpha(\theta)$ 的值对于任意的 $\theta \in \Theta_1$ 都尽可能取得比较大 (也就是说让 $\theta \in \Theta_1$ 时发生第 II 类错误的概率都尽可能比较小); 这也是 Neyman-Pearson 理论中定义 “最优” 检验统计量的基本思路. 在给出了检验统计量最优性的定义后, 即可进一步研究应当如何基于原假设与备择假设的形式, 找出一个最优的检验统计量. Neyman-Pearson 的假设检验理论也包括了关于最优检验法的 Neyman-Pearson 引理以及一致最大功效检验 (uniformly most powerful test) 等的一套理论. 这部分理论其实是 Neyman-Pearson 理论的重要组成部分, 但限于本讲义面向的读者群体, 我们不对这套理论进行详细介绍, 仅将其最基础的部分放在 9.6 节作为选读内容.

需要指出的是, Neyman-Pearson 理论虽然是目前广为接受的频率学派假设检验理论, 但从实际应用的角度来看, 它也并非对于任何问题都适用或都具有可操作性. 对某些实际问题, Neyman-Pearson 理论的基于第 I 类与第 II 类错误概率的评价方式是否合适是值得商榷的. 此外, 对某些实际问题, 若是基于 Neyman-Pearson 理论来设计检验统计量, 可能会牵扯到许多复杂的计算, 此时一些经验性的检验统计量的设计方法反而可能会更加实用.

9.2.3 基于功效函数估计样本容量

对功效函数做分析可以为样本容量的选择做出指导. 我们用一个例子对此进行说明.

例 9.3. 设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 σ^2 已知而 μ 未知. 原假设与备择假设为

$$H_0: \mu = \mu_0, \quad H_1: \mu \neq \mu_0.$$

由例 9.2 的结果可知, 显著性水平 α 时, 检验统计量 $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$ 的拒绝域为

$]-\infty, -z_{\alpha/2}[\cup]z_{\alpha/2}, +\infty[$. 故功效函数为

$$\begin{aligned} w(\mu) &= \mathbb{P}_{\mu}\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z_{\alpha/2}\right) + \mathbb{P}_{\mu}\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -z_{\alpha/2}\right) \\ &= \mathbb{P}_{\mu}\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} > z_{\alpha/2} + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}}\right) + \mathbb{P}_{\mu}\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < -z_{\alpha/2} + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}}\right) \\ &= 1 - \Phi\left(z_{\alpha/2} - \frac{\mu - \mu_0}{\sigma/\sqrt{n}}\right) + \Phi\left(-z_{\alpha/2} - \frac{\mu - \mu_0}{\sigma/\sqrt{n}}\right) \\ &= \Phi\left(-z_{\alpha/2} + \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right) + \Phi\left(-z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right), \end{aligned}$$

其中最后一步用到了 $1 - \Phi(x) = \Phi(-x)$ 及 $\Phi(x+y) + \Phi(x-y) = \Phi(x+|y|) + \Phi(x-|y|)$.

现在考虑这样一个场景: 在备择假设 $\mu \neq \mu_0$ 的所有可能性中, 我们尤其关注 $|\mu - \mu_0| \geq \delta$ 的情形, 其中 $\delta > 0$ 为事先适当选定的一个正实数, 并希望对于这些 μ 的可能取值能够尽量避免第 II 类错误; 而对于 $0 < |\mu - \mu_0| < \delta$ 的情形, 则由于 μ 与 μ_0 较为接近, 即使发生第 II 类错误我们也可以忍受². 此时我们可以问这样一个问题: 在保持显著性水平 α 不变的前提下, 若要将 $|\mu - \mu_0| \geq \delta$ 时的第 II 类错误概率降低到 β 以下, 则样本容量 n 应至少为多大? 由上述功效函数的计算可得, 第 II 类错误的概率为

$$\begin{aligned} 1 - w(\mu) &= \Phi\left(z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right) - \Phi\left(-z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right) \\ &< \Phi\left(z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right). \end{aligned}$$

实际上, 上式中最后一步的放缩通常是相当紧的, 这是因为当 $\sqrt{n}|\mu - \mu_0|$ 足够大时, $\Phi\left(-z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right)$ 与 $\Phi\left(z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right)$ 相比可忽略 (也可见图 9.1 给出的示意). 由此可得, 若要让 $|\mu - \mu_0| < \delta$ 时的第 II 类错误概率小于等于 β , 一个充分条件为

$$\Phi\left(z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma}\right) \leq \beta, \quad \forall \mu : |\mu - \mu_0| \geq \delta,$$

即

$$z_{\alpha/2} - \frac{\sqrt{n}|\mu - \mu_0|}{\sigma} \leq -z_{\beta}, \quad \forall \mu : |\mu - \mu_0| \geq \delta,$$

也即

$$n \geq \left[\frac{(z_{\alpha/2} + z_{\beta})\sigma}{\delta} \right]^2. \quad \blacksquare$$

² 由于功效函数 $w(\mu)$ 是连续函数, 故当第 I 类错误概率 $w(\mu_0)$ 小于等于 α 时, 不可能让所有的 $\mu \neq \mu_0$ 都给出很小的第 II 类错误概率 $1 - w(\mu)$, 因此我们需要以 δ 为阈值将 $\mu \neq \mu_0$ 的情形分为 $|\mu - \mu_0| \geq \delta$ 与 $0 < |\mu - \mu_0| < \delta$ 两类, 主要关注 $|\mu - \mu_0| \geq \delta$ 时的第 II 类错误概率而容忍 $|\mu - \mu_0| < \delta$ 时的第 II 类错误.




图 9.1: 例 9.3 中第 II 类错误的计算示意图. 虚曲线为 $\mathcal{N}(0, 1)$ 的概率密度函数, 实曲线为 $\mathcal{N}(\sqrt{n}|\mu - \mu_0|/\sigma, 1)$ 的概率密度函数, 其分布函数即为 $\Phi(z - \sqrt{n}|\mu - \mu_0|/\sigma)$. 蓝色阴影表示实曲线下从 $z = -z_{\alpha/2}$ 到 $z = z_{\alpha/2}$ 部分的面积, 不难看出它严格小于但又约等于实曲线下从 $z = -\infty$ 到 $z = z_{\alpha/2}$ 部分的面积.

理想情况下, 对于在原假设与备择假设之间二选一的假设检验问题, 我们均需要在事前进行类似于例 9.3 那样的分析, 找出合适的样本容量 n 以使得第 II 类错误概率对于备择假设中我们所关心的情形都能取到足够小的值, 这样才能保证在原假设与备择假设之间进行二选一的决策是合适的.

9.2.4 原假设为复合假设时的假设检验

到目前为止, 我们所介绍的假设检验的理论主要关注原假设为简单假设的情形. 当原假设 $H_0: \theta \in \Theta_0$ 为复合假设时, 相关的一般性理论则较为复杂, 这里不对其进行介绍, 而只对两种常见的特殊情形进行讨论.

检验统计量在原假设下服从同一个分布的情形

原假设复合性的一种常见来源是多余参数 (nuisance parameter), 此时总体的未知参数 $\theta = (\psi, \lambda)$ 由两部分 ψ 和 λ 组成, 而原假设和备择假设则分别为

$$H_0: \psi = \psi_0, \quad H_1: \psi \begin{cases} \neq \\ > \\ < \end{cases} \psi_0.$$

换句话说, 我们关心 ψ 的取值是否为 ψ_0 , 而 λ 则是一个多余参数. 若将 λ 的所有可能取值构成的集合记为 Θ_λ , 则可以将原假设表示为 $H_0: \theta \in \Theta_0 = \{\psi_0\} \times \Theta_\lambda$. 对于此类

问题, 我们通常会首先考虑找一个合适的检验统计量 T , 使其满足 (或近似满足) 如下额外条件:

条件 9.1. T 在原假设 H_0 下的分布是与 $\theta \in \Theta_0$ 的具体取值无关的. 换句话说, 对任意 $\theta \in \Theta_0$, T 均服从同一个分布.

该条件意味着我们可以把复合假设 H_0 当作是一个简单假设去处理, 从而相应的 p 值为

- 单侧检验: $\hat{p} = \mathbb{P}_{H_0}(T \geq t)$;
- 双侧检验: $\hat{p} = 2 \min\{\mathbb{P}_{H_0}(T \geq t), \mathbb{P}_{H_0}(T \leq t)\}$.

其中 t 为检验统计量 T 在代入样本观测值 $x_1, \dots, x_n$ 后的取值, $\mathbb{P}_{H_0}(T \geq t)$ 表示原假设 H_0 下 $T \geq t$ 的概率 (它与 $\theta \in \Theta_0$ 的具体值无关). 而给定显著性水平 $\alpha \in]0, 1[$ 后, 相应的拒绝域 C_α 可由如下方法得到:

- 单侧检验: $C_\alpha =]c_\alpha, +\infty[$, 其中

$$c_\alpha = \max\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\};$$

而若 T 在原假设下服从连续型分布, 且相应的率密度函数在某个开区间上恒大于 0 而在该开区间外恒等于 0, 则临界值可通过求解 $\mathbb{P}_{H_0}(T > c_\alpha) = \alpha$ 得到.

- 双侧检验: $C_\alpha =]-\infty, c_\alpha^l[\cup]c_\alpha^u, +\infty[$, 其中

$$\begin{aligned} c_\alpha^u &= \max\left\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \frac{\alpha}{2}\right\}, \\ c_\alpha^l &= \min\left\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \leq c) \geq \frac{\alpha}{2}\right\}. \end{aligned}$$

而若 T 在原假设下服从连续型分布, 且相应的率密度函数在某个开区间上恒大于 0 而在该开区间外恒等于 0, 则临界值可通过求解 $\mathbb{P}_{H_0}(T > c_\alpha^u) = \mathbb{P}_{H_0}(T < c_\alpha^l) = \alpha/2$ 得到.

可以证明 (见附录 C), 对于上述假设检验流程, 有如下结论成立:

- $\hat{p} < \alpha$ 当且仅当 $t \in C_\alpha$.
- 显著性水平 α 给出了第 I 类错误概率的一个上界.
- 若 T 在 H_0 下服从连续型分布, 则显著性水平 α 就等于第 I 类错误概率.

在本章的后两节中, 我们将针对一些具体的例子, 讨论如何构造满足条件 9.1 的检验统计量, 并给出相应的 p 值与拒绝域.

一类常见的单侧检验的情形

在实践中还经常会遇到另一类原假设为复合假设的情形: 原假设与复合假设的形式分别为

$$H_0: \psi \leq \psi_0, \quad H_1: \psi > \psi_0, \quad (9.10)$$

其中 ψ 既可以是未知参数本身, 也可以是未知参数的一个分量 (此时其它的分量为多余参数), $\psi_0 \in \mathbb{R}$ 是一个已知的常数. 对于这种情形, 通常的做法是设计一个单侧检验统计量 T , 使得在原假设 H_0 下 T 具有取值偏小的趋势, 而在备择假设 H_1 下具有取值偏大的取值, 且 T 还满足如下额外条件:

- 条件 9.2.** 1. 给定任意 $\psi \in \mathbb{R}$, T 的分布是唯一确定的, 而与多余参数的取值无关.
2. 给定任意 $t \in \mathbb{R}$, 概率 $\mathbb{P}_\psi(T \geq t)$ 在 $\psi \in]-\infty, \psi_0]$ 上的最大值由 $\mathbb{P}_{\psi_0}(T \geq t)$ 给出.

不难看出, 条件 9.2 的第一条能够帮助我们排除多余参数的影响, 而若第二条也成立, 则 $\psi = \psi_0$ 给出了原假设最为极端的情况, 这意味着我们可以把原假设 $H_0: \psi \leq \psi_0$ 替换为 $H'_0: \psi = \psi_0$ 进行假设检验, 也就是说我们可以用针对

$$H'_0: \psi = \psi_0, \quad H_1: \psi > \psi_0 \quad (9.11)$$

的假设检验方法来检验原问题, 此时的原假设 H'_0 要么是简单假设, 要么由于条件 9.2 第一条的成立而可以转化为之前处理过的情形.

在本章随后的内容中, 我们将只讨论形如 (9.11) (或把 H_1 中的不等号反向) 的单侧检验问题, 但相关结果不难根据上述讨论推广到形如 (9.10) 的假设检验问题上.

9.3 单个总体下的假设检验


9.3.1 正态总体期望的假设检验

方差 σ^2 已知的情形. 设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中方差 $\sigma^2 > 0$ 已知, 我们考虑对未知的期望 μ 的取值进行假设检验. 相关的结果实际上已经由例 9.1 与例 9.2 算出来了, 表 9.1 对其进行了汇总; 图 9.2 给出了显著性水平为 α 时拒绝域的图示.

表 9.1: 方差 σ^2 已知时, 正态总体期望 μ 的假设检验方法

原假设 H_0	备择假设 H_1	检验统计量	拒绝域	p 值
$\mu = \mu_0$	$\mu > \mu_0$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$z > z_\alpha$	$1 - \Phi(z)$
$\mu = \mu_0$	$\mu < \mu_0$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$z < -z_\alpha$	$\Phi(z)$
$\mu = \mu_0$	$\mu \neq \mu_0$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$ z > z_{\alpha/2}$	$2(1 - \Phi(z))$

注: $\bar{X}$ 表示样本均值; $z = (\bar{x} - \mu_0)/(\sigma/\sqrt{n})$ 表示获取到样本值 $x_1, \dots, x_n$ 以后检验统计量 Z 的取值, 其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$; α 为事先给定的显著性水平.

图 9.2: 方差 σ^2 已知时, 正态总体期望 μ 的假设检验拒绝域图示, 其中显著性水平为 α .

方差 σ^2 未知的情形. 设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 与方差 $\sigma^2 > 0$ 均未知. 我们首先考虑如下假设检验问题:

$$H_0: \mu = \mu_0, \sigma^2 > 0, \quad H_1: \mu > \mu_0, \sigma^2 > 0,$$

其中 μ_0 为一给定的实数. 不难看出此时的原假设为复合假设, 而 σ^2 实际上可以看成是一个多余参数 (nuisance parameter). 对于该问题, 我们考虑用

$$T = \frac{\bar{X} - \mu_0}{\sqrt{S^2/n}} \quad (9.12)$$

作为单侧检验统计量. 该检验统计量的一个重要特点在于它满足条件 9.1: 无论多余参数 σ^2 的实际取值如何, 在原假设 H_0 下 T 的分布总是不变的, 而且很容易看出这个不

变的分布就是 $t(n-1)$, 这意味着我们在计算 p 值与临界值时可以直接套用原假设为简单假设时的公式. 由于备择假设中期望相对于原假设的偏离是正向的, 因此 T 的取值越大则意味着相对于 H_0 越显著的偏离. 当显著性水平为 α 时, 由临界值的计算式 $\mathbb{P}_{H_0}(T > c_\alpha) = \alpha$ 可求得 $c_\alpha = t_\alpha(n-1)$, 故拒绝域由

$$t = \frac{\bar{x} - \mu_0}{\sqrt{s^2/n}} > t_\alpha(n-1)$$

给出, 其中 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ 为样本观测值 $x_1, \dots, x_n$ 的样本方差. p 值则由

$$\hat{p} = \mathbb{P}_{\mu_0}(T \geq t) = 1 - F_{n-1}^t \left(\frac{\bar{x} - \mu_0}{\sqrt{s^2/n}} \right)$$

给出, 其中 F_{n-1}^t 表示 $t(n-1)$ 的分布函数.

类似地, 若我们希望对期望 μ 进行双侧检验:

$$H_0: \mu = \mu_0, \sigma^2 > 0, \quad H_1: \mu \neq \mu_0, \sigma^2 > 0,$$

则可以将式 (9.12) 给出的 T 作为双侧检验统计量. 当显著性水平为 α 时, 由临界值计算式 $\mathbb{P}_{H_0}(T > c_\alpha^u) = \mathbb{P}_{H_0}(T < c_\alpha^l) = \alpha/2$ 可得

$$c_\alpha^u = t_{\alpha/2}(n-1), \quad c_\alpha^l = -t_{\alpha/2}(n-1),$$

故拒绝域由

$$|t| = \frac{|\bar{x} - \mu_0|}{\sqrt{s^2/n}} > t_{\alpha/2}(n-1)$$

给出. p 值表达式由

$$\begin{aligned} \hat{p} &= 2 \min\{\mathbb{P}_{\mu_0}(T \geq t), \mathbb{P}_{\mu_0}(T \leq t)\} \\ &= 2 \mathbb{P}(T \geq |t|) = 2 \left(1 - F_{n-1}^t \left(\frac{|\bar{x} - \mu_0|}{\sqrt{s^2/n}} \right) \right) \end{aligned}$$

给出.

上述利用 t 分布检验统计量进行假设检验的方法被称为 **t 检验法**. 表 9.2 对相关的假设检验方法进行了汇总.

9.3.2 配对样本的 t 检验

配对样本的 t 检验可以看成是单个正态总体期望的 t 检验的特殊情形: 设总体不再是一个随机变量而是一个二维随机向量 (X, Y) , 而从该总体中抽样得到的样本是一组配对的随机变量 $(X_1, Y_1), \dots, (X_n, Y_n)$, 且满足如下条件:

表 9.2: 方差 σ^2 未知时, 正态总体期望 μ 的假设检验方法

原假设 H_0	备择假设 H_1	检验统计量	拒绝域	p 值
$\mu = \mu_0, \sigma^2 > 0$	$\mu > \mu_0, \sigma^2 > 0$	$T = \frac{\bar{X} - \mu_0}{\sqrt{S^2/n}}$	$t > t_\alpha(n-1)$	$1 - F_{n-1}^t(t)$
$\mu = \mu_0, \sigma^2 > 0$	$\mu < \mu_0, \sigma^2 > 0$	$T = \frac{\bar{X} - \mu_0}{\sqrt{S^2/n}}$	$t < -t_\alpha(n-1)$	$F_{n-1}^t(t)$
$\mu = \mu_0, \sigma^2 > 0$	$\mu \neq \mu_0, \sigma^2 > 0$	$T = \frac{\bar{X} - \mu_0}{\sqrt{S^2/n}}$	$ t > t_{\alpha/2}(n-1)$	$2(1 - F_{n-1}^t(t))$

注: $\bar{X}$ 表示样本均值, S^2 表示样本方差; $t = (\bar{x} - \mu_0)/\sqrt{s^2/n}$ 表示获取到样本值 $x_1, \dots, x_n$ 以后检验统计量 T 的取值, 其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$; α 为事先给定的显著性水平.

1. $X - Y$ 服从正态分布 $\mathcal{N}(\mu_D, \sigma_D^2)$, 其中 μ_D 与 σ_D^2 均未知.
2. 每个 (X_i, Y_i) , $i = 1, \dots, n$ 均与 (X, Y) 同分布.
3. 随机向量 $(X_1, Y_1), \dots, (X_n, Y_n)$ 之间相互独立. 换句话说, 任取 n 个二元实值函数 $f_1, \dots, f_n: \mathbb{R}^2 \rightarrow \mathbb{R}$, 随机变量 $f_1(X_1, Y_1), \dots, f_n(X_n, Y_n)$ 均相互独立.

注意上述条件中不要求 X 与 Y 相互独立. 上述配对形式的总体与样本的一个典型的应用场景如下: 为了比较两种方法之间的差异, 我们采取对比实验, 随机选取 n 个对象并在这 n 个对象上分别应用这两种方法, 随后观测两种方法在每个对象上各自给出的效果, 得到成对的样本数据; 此时 $X - Y$ 的期望 μ_D 即可看成是对两种方法效果差别的定量描述.

考虑如下假设检验问题:

$$H_0: \mu_D = \Delta_0, \quad H_1: \mu_D \neq \Delta_0,$$

其中 Δ_0 为某个给定的实数³. 由于 $X_i - Y_i$ 均服从正态分布 $\mathcal{N}(\mu_D, \sigma_D^2)$, 其中方差 σ_D^2 未知, 故可以直接将针对单个正态总体期望的 t 检验法套用过来: 令

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n (X_i - Y_i)$$

³ 若取 $\Delta_0 = 0$, 则原假设即意味着被测试的两种方法的平均效果没有差别.

以及

$$S_D^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - Y_i - \bar{D})^2,$$

则双侧检验统计量应取为

$$T = \frac{\bar{D} - \Delta_0}{\sqrt{S_D^2/n}}.$$

T 在原假设 H_0 下服从自由度为 $n-1$ 的 t 分布, 此后依照上一节给出的 t 检验步骤进行假设检验即可. 对于备择假设为 $H_1: \mu_D > \Delta_0$ 或 $H_1: \mu_D < \Delta_0$ 的单侧检验也可按类似方法处理.

9.3.3 正态总体方差的假设检验

设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 与方差 σ^2 均未知. 我们先考虑如下假设检验问题:

$$H_0: \sigma^2 = \sigma_0^2, \quad H_1: \sigma^2 \neq \sigma_0^2,$$

其中 σ_0^2 为一给定的常数. 注意上式中指明 H_0 与 H_1 时, 为了符号上的简单未将未知期望的取值范围 $\mu \in \mathbb{R}$ 明确写出来, H_0 与 H_1 实际上均为复合假设. 对于该假设检验问题, 可以考虑用

$$X^2 = \frac{(n-1)S^2}{\sigma_0^2} \quad (9.13)$$

作为双侧检验统计量. 虽然原假设是复合假设, 但该检验统计量在原假设下总是服从卡方分布 $\chi^2(n-1)$ 而与未知期望 μ 的取值无关, 故条件 9.1 成立, 我们可以套用原假设为简单假设时的公式来计算 p 值与临界值. 当显著性水平为 α 时, 由临界值计算式

$$\mathbb{P}_{H_0}(X^2 > c_\alpha^l) = \mathbb{P}_{H_0}(X^2 < c_\alpha^u) = \frac{\alpha}{2},$$

可解得

$$c_\alpha^l = \chi_{1-\alpha/2}^2(n-1), \quad c_\alpha^u = \chi_{\alpha/2}^2(n-1),$$

相应的拒绝域由

$$\frac{(n-1)s^2}{\sigma_0^2} > \chi_{\alpha/2}^2(n-1) \text{ 或 } \frac{(n-1)s^2}{\sigma_0^2} < \chi_{1-\alpha/2}^2(n-1)$$

给出. 而 p 值为

$$\begin{aligned}\hat{p} &= 2 \min \left\{ \mathbb{P} \left(X^2 \geq \frac{(n-1)s^2}{\sigma_0^2} \right), \mathbb{P} \left(X^2 \leq \frac{(n-1)s^2}{\sigma_0^2} \right) \right\} \\ &= 2 \min \left\{ 1 - F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right), F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right) \right\} \\ &= \begin{cases} 2F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right), & \text{若 } F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right) \leq \frac{1}{2}, \\ 2 - 2F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right), & \text{若 } F_{n-1}^{\chi^2} \left(\frac{(n-1)s^2}{\sigma_0^2} \right) > \frac{1}{2}, \end{cases}\end{aligned}$$

其中 $F_{n-1}^{\chi^2}$ 表示卡方分布 $\chi^2(n-1)$ 的分布函数.

类似地, 若备择假设为 $H_1: \sigma^2 > \sigma_0^2$ 或 $H_1: \sigma^2 < \sigma_0^2$, 则仍可将 (9.13) 作为检验统计量, 只不过此时 H_1 相对于 H_0 的偏离是单向的, 故应将 X^2 作为单侧检验量来计算 p 值或拒绝域. 相应的结果总结于表 9.3 中; 图 9.3 给出了拒绝域的图示.

9.3.4 比例的假设检验

设总体 X 服从参数为 p 的伯努利分布, 其中 p 未知; 我们通常将参数 p 解释为某种比例 (可参考 8.2.3 小节的说法). 考虑如下假设检验问题:

$$H_0: p = p_0, \quad H_1: p \neq p_0.$$

当样本容量 n 较小时, 我们可以考虑用 p 值法: 以 $K = \sum_{i=1}^n X_i$ 作为双侧检验统计量, 则在原假设 H_0 下, K 服从参数为 (n, p_0) 的二项分布, 从而对于样本观测值




图 9.3: 期望 μ 未知时, 正态总体方差 σ^2 的假设检验拒绝域图示, 其中横坐标为 $(n-1)s^2/\sigma_0^2$, 显著性水平取为 α .

表 9.3: 期望 μ 未知时, 正态总体方差 σ^2 的假设检验方法

H_0	H_1	检验统计量	拒绝域	p 值
$\sigma^2 = \sigma_0^2$	$\sigma^2 > \sigma_0^2$	$\frac{(n-1)S^2}{\sigma_0^2}$	$\frac{(n-1)s^2}{\sigma_0^2} > \chi_{\alpha}^2(n-1)$	$1 - F_{n-1}^{\chi^2}\left(\frac{(n-1)s^2}{\sigma_0^2}\right)$
$\sigma^2 = \sigma_0^2$	$\sigma^2 < \sigma_0^2$	$\frac{(n-1)S^2}{\sigma_0^2}$	$\frac{(n-1)s^2}{\sigma_0^2} < \chi_{1-\alpha}^2(n-1)$	$F_{n-1}^{\chi^2}\left(\frac{(n-1)s^2}{\sigma_0^2}\right)$
$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\frac{(n-1)S^2}{\sigma_0^2}$	$\frac{(n-1)s^2}{\sigma_0^2} > \chi_{\alpha/2}^2(n-1)$ 或 $\frac{(n-1)s^2}{\sigma_0^2} < \chi_{1-\alpha/2}^2(n-1)$	$2 \min \left\{ F_{n-1}^{\chi^2}\left(\frac{(n-1)s^2}{\sigma_0^2}\right), 1 - F_{n-1}^{\chi^2}\left(\frac{(n-1)s^2}{\sigma_0^2}\right) \right\}$

注: S^2 为样本方差, s^2 为观测到的样本的样本方差值; α 为事先给定的显著性水平.

$x_1, \dots, x_n$, 其 p 值为

$$\begin{aligned} \hat{p} &= 2 \min \left\{ \mathbb{P}_{p_0} \left(\sum_{i=1}^n X_i \geq \sum_{i=1}^n x_i \right), \mathbb{P}_{p_0} \left(\sum_{i=1}^n X_i \leq \sum_{i=1}^n x_i \right) \right\} \\ &= 2 \min \left\{ 1 - \sum_{j=0}^{k-1} \binom{n}{j} p_0^j (1-p_0)^{n-j}, \sum_{j=0}^k \binom{n}{j} p_0^j (1-p_0)^{n-j} \right\} \end{aligned} \quad (9.14a)$$

$$= 2 \min \left\{ \sum_{j=k}^n \binom{n}{j} p_0^j (1-p_0)^{n-j}, 1 - \sum_{j=k+1}^n \binom{n}{j} p_0^j (1-p_0)^{n-j} \right\}, \quad (9.14b)$$

其中我们记

$$k = \sum_{i=1}^n x_i.$$

具体计算时只需在 (9.14a) 与 (9.14b) 两个计算式中选一个计算更方便的即可. 若需要在 H_0 与 H_1 之间二选一, 则可比较 p 值与事先设定的显著性水平 α , 当 p 值小于 α 时拒绝原假设, 否则接受原假设.

注 9.2. (*) 利用分部积分, 可证明 $1 \leq j \leq n-1$ 时,

$$n \binom{n-1}{j-1} \int_0^p t^{j-1} (1-t)^{n-j} dt - n \binom{n-1}{j} \int_0^p t^j (1-t)^{n-j-1} dt = \binom{n}{j} p^j (1-p)^{n-j},$$

而

$$n \int_0^p t^{n-1} dt = \binom{n}{n} p^n (1-p)^0,$$

故 $1 \leq k \leq n$ 时, 可得

$$\begin{aligned}
 & \sum_{j=k}^n \binom{n}{j} p^j (1-p)^{n-j} \\
 &= \sum_{j=k}^{n-1} \left[n \binom{n-1}{j-1} \int_0^p t^{j-1} (1-t)^{n-j} dt - n \binom{n-1}{j} \int_0^p t^j (1-t)^{n-j-1} dt \right] \\
 & \quad + n \int_0^p t^{n-1} dt \\
 &= n \binom{n-1}{k-1} \int_0^p t^{k-1} (1-t)^{n-k} dt \\
 &= I_p(k, n-k+1),
 \end{aligned}$$

其中

$$I_x(a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^x t^{a-1} (1-t)^{b-1} dt$$

为不完全 Beta 函数 (incomplete beta function). 由此可将 p 值表达式 (9.14b) 改写为

$$\hat{p} = 2 \min\{I_{p_0}(k, n-k+1), 1 - I_{p_0}(k+1, n-k)\},$$

从而 $\hat{p} < \alpha$ 给出的拒绝域可等价表示为

$$I_{p_0}(k, n-k+1) < \frac{\alpha}{2} \text{ 或 } 1 - I_{p_0}(k+1, n-k) < \frac{\alpha}{2}.$$

我们可以进一步利用 Beta 分布的上分位数或 F 分布的上分位数来表示拒绝域, 感兴趣的读者可参阅 [23] 第 3.8.3 节以及 [24] 第 27.2 节. ■

当样本容量 n 足够大时, 利用中心极限定理可得

$$\mathbb{P}_{p_0} \left(\sum_{i=1}^n X_i \geq k \right) = \mathbb{P}_{p_0} \left(\sum_{i=1}^n X_i \geq k - \frac{1}{2} \right) \approx 1 - \Phi \left(\frac{k - 1/2 - np_0}{\sqrt{np_0(1-p_0)}} \right),$$

其中第一步为连续性修正. 同理,

$$\mathbb{P}_{p_0} \left(\sum_{i=1}^n X_i \leq k \right) \approx \Phi \left(\frac{k + 1/2 - np_0}{\sqrt{np_0(1-p_0)}} \right) = 1 - \Phi \left(\frac{-k - 1/2 + np_0}{\sqrt{np_0(1-p_0)}} \right),$$

故

$$\hat{p} \approx 2 \left(1 - \Phi \left(\frac{|k - np_0| - 1/2}{\sqrt{np_0(1-p_0)}} \right) \right).$$

而当给定显著性水平为 α 时, 相应的拒绝域可近似由

$$\frac{|k - np_0| - 1/2}{\sqrt{np_0(1-p_0)}} > z_{\alpha/2}$$

给出.

对于备择假设为 $H_1: p < p_0$ 或 $H_1: p > p_0$ 的单侧检验问题, 仍可利用上述方法导出相应的 p 值与拒绝域, 我们将具体的推导留给读者完成.

9.4 两个总体下的假设检验

本节将讨论一些两个总体下的假设检验问题. 我们用 $X_{1,1}, \dots, X_{1,n_1}$ 表示第一个总体的样本容量为 n_1 的样本, 用 $X_{2,1}, \dots, X_{2,n_2}$ 表示第二个总体的样本容量为 n_2 的样本, 且 $X_{1,1}, \dots, X_{1,n_1}, X_{2,1}, \dots, X_{2,n_2}$ 相互独立. 此外, 用如下符号

$$\bar{X}_k = \frac{1}{n_k} \sum_{i=1}^n X_{k,i}, \quad S_k^2 = \frac{1}{n_k - 1} \sum_{i=1}^n (X_{k,i} - \bar{X}_k)^2, \quad k = 1, 2$$

来表示两组样本 $X_{1,1}, \dots, X_{1,n_1}$ 与 $X_{2,1}, \dots, X_{2,n_2}$ 各自的样本均值和样本方差. 符号 $\bar{x}_1, s_1^2$ 与 $\bar{x}_2, s_2^2$ 则代表获取到样本值 $x_{1,1}, \dots, x_{1,n_1}$ 与 $x_{2,1}, \dots, x_{2,n_2}$ 以后算得的各自的样本均值与样本方差值.

9.4.1 两个正态总体期望之差的假设检验

设两个总体分别服从正态分布 $\mathcal{N}(\mu_1, \sigma_1^2)$ 与 $\mathcal{N}(\mu_2, \sigma_2^2)$. 我们根据两个总体方差信息的知晓程度, 讨论几种容易求解的情况.

两总体方差均已知的情况. 设两个总体的方差 σ_1^2, σ_2^2 均已知. 考虑如下假设检验问题:

$$H_0: \mu_1 - \mu_2 = \Delta_0, \quad H_1: \mu_1 - \mu_2 \neq \Delta_0,$$

其中 Δ_0 为一给定实数. 由于两个总体的方差均已知, 故可以考虑用如下双侧检验统计量进行假设检验:

$$Z = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}. \quad (9.15)$$

不难看出, 检验统计量 Z 在原假设 H_0 下服从标准正态分布 $\mathcal{N}(0, 1)$. 故在获得样本观测值 $x_{1,1}, \dots, x_{1,n_1}$ 与 $x_{2,1}, \dots, x_{2,n_2}$ 后, 相应的 p 值为

$$\hat{p} = 2(1 - \Phi(|z|)), \quad z = \frac{\bar{x}_1 - \bar{x}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}.$$

若事先给定了显著性水平 α , 则拒绝域由

$$|z| > z_{\alpha/2}$$

给出.

若备择假设被替换为 $H_1: \mu_1 - \mu_2 > \Delta_0$ 或 $H_1: \mu_1 - \mu_2 < \Delta_0$, 则可以将 (9.15) 作为单侧检验统计量进行假设检验, 相关的推导留给读者自己完成. 表 9.4 总结了方差已知时, 两个正态总体期望之差的假设检验方法.

表 9.4: 方差 σ_1^2, σ_2^2 已知时, 两个正态总体期望之差 $\mu_1 - \mu_2$ 的假设检验方法

原假设 H_0	备择假设 H_1	检验统计量	拒绝域	p 值
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 > \Delta_0$	$Z = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	$z > z_\alpha$	$1 - \Phi(z)$
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 < \Delta_0$	$Z = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	$z < -z_\alpha$	$\Phi(z)$
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 \neq \Delta_0$	$Z = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	$ z > z_{\alpha/2}$	$2(1 - \Phi(z))$

注: $\bar{X}_1, \bar{X}_2$ 表示两个样本的样本均值; $z = (\bar{x}_1 - \bar{x}_2 - \Delta_0)/\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}$ 表示获取到样本值以后检验统计量 Z 的取值; α 为事先给定的显著性水平.

两总体方差未知, 但已知它们相等的情况. 设两个总体的方差 σ_1^2, σ_2^2 均未知, 但已知二者相等 (即 $\sigma_1^2 = \sigma_2^2$). 考虑如下假设检验问题:

$$H_0: \mu_1 - \mu_2 = \Delta_0, \quad H_1: \mu_1 - \mu_2 \neq \Delta_0,$$

其中 Δ_0 为一给定实数. 需注意的是, 上述问题中 H_0 与 H_1 均为复合假设.

我们参考相同情形下对 $\mu_1 - \mu_2$ 进行区间估计时枢轴量的设计方法 (见 8.3.1 小节第二部分内容), 取

$$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}} \quad (9.16)$$

为检验统计量, 其中

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

为合并方差. 依照 8.3.1 小节第二部分的推导, 可知在原假设 H_0 下 T 服从自由度为 $n_1 + n_2 - 2$ 的 t 分布. 由此可得, 在获得样本观测值 $x_{1,1}, \dots, x_{1,n_1}$ 与 $x_{2,1}, \dots, x_{2,n_2}$ 后, 相应的 p 值为

$$\hat{p} = 2(1 - F_{n_1+n_2-2}^t(|t|)), \quad t = \frac{\bar{x}_1 - \bar{x}_2 - \Delta}{\sqrt{s_p^2(1/n_1 + 1/n_2)}},$$

其中 s_p^2 为将样本值代入统计量 S_p^2 后的取值, $F_{n_1+n_2-2}^t$ 为分布 $t(n_1 + n_2 - 2)$ 的分布函数. 若事先给定了显著性水平 α , 则拒绝域由

$$|t| > t_{\alpha/2}(n_1 + n_2 - 2)$$

给出.

若备择假设被替换为 $H_1: \mu_1 - \mu_2 > \Delta_0$ 或 $H_1: \mu_1 - \mu_2 < \Delta_0$, 则可以将 (9.16) 作为单侧检验统计量进行假设检验, 相关的推导留给读者自己完成. 表 9.5 总结了方差已知时, 两个正态总体期望之差的假设检验方法.

(*) 两总体方差未知, 且不能事先认为它们相等的情况. 这种情况下, 如下形式的假设检验问题

$$H_0: \mu_1 - \mu_2 = \Delta_0, \quad H_1: \mu_1 - \mu_2 \neq \Delta_0$$

表 9.5: 方差 σ_1^2, σ_2^2 未知但相等时, 两个正态总体期望之差 $\mu_1 - \mu_2$ 的假设检验方法

H_0	H_1	检验统计量	拒绝域	p 值
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 > \Delta_0$	$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}$	$t > t_\alpha(n_1 + n_2 - 2)$	$1 - F_{n_1+n_2-2}^t(t)$
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 < \Delta_0$	$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}$	$t < -t_\alpha(n_1 + n_2 - 2)$	$F_{n_1+n_2-2}^t(t)$
$\mu_1 - \mu_2 = \Delta_0$	$\mu_1 - \mu_2 \neq \Delta_0$	$T = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}$	$ t > t_{\alpha/2}(n_1 + n_2 - 2)$	$2(1 - F_{n_1+n_2-2}^t(t))$

注: $\bar{X}_1, \bar{X}_2$ 表示两个样本的样本均值, S_p^2 表示合并方差; $t = (\bar{x}_1 - \bar{x}_2 - \Delta_0)/\sqrt{s_p^2(1/n_1 + 1/n_2)}$ 表示获取到样本值以后检验统计量 T 的取值; α 为事先给定的显著性水平.

(以及对 $\mu_1 - \mu_2$ 进行区间估计的问题) 被称为 **Behrens-Fisher 问题**, 它曾是应用统计领域的一个著名问题. 对于 Behrens-Fisher 问题, 理想情况下, 我们希望找到一个检验统计量 T , 使其满足如下条件:

1. T 在原假设 H_0 下的概率分布是确切已知的 (尤其是与方差 σ_1^2, σ_2^2 无关的);
2. T 可以表示为

$$T = \phi(\bar{X}_1, \bar{X}_2, S_1^2, S_2^2),$$

其中 ϕ 是一个性态良好的函数.

3. 设 $x_{1,1}, \dots, x_{1,n_1}, x_{2,1}, \dots, x_{2,n_2}$ 为一组样本值. 对任意实数 $\alpha \neq 0$ 及 β , 将样本值做变换

$$x_{k,i} \mapsto \alpha x_{k,i} + \beta, \quad \forall i = 1, \dots, n_k, k = 1, 2$$

后不会改变 p 值.

4. 设 $x_{1,1}, \dots, x_{1,n_1}, x_{2,1}, \dots, x_{2,n_2}$ 与 $x'_{1,1}, \dots, x'_{1,n_1}, x'_{2,1}, \dots, x'_{2,n_2}$ 为两组样本值, 且有 $|\bar{x}_1 - \bar{x}_2 - \Delta_0| > |\bar{x}'_1 - \bar{x}'_2 - \Delta_0|$, $s_1^2 = s'^2_1$, $s_2^2 = s'^2_2$, 则前一组样本的 p 值小于后一组样本的 p 值;

上述四条性质都是比较自然的. 然而, Linnik 等人的工作 [25] 基本上否定了具备上述性质的检验统计量的存在性, 这也就是为什么 Behrens-Fisher 问题曾长期是应用统计领域的难题. 这里我们提及两种较易实现的针对 Behrens-Fisher 问题的检验法; 为简单起见设 $\Delta_0 = 0$.

- Bartlett-Scheffé 检验: 此类检验法可看成是由配对检验法衍生出来的. 具体而言, 对于两个样本容量相等 (也就是 $n_1 = n_2$) 的情形, 考虑将 $X_{1,i}$ 与 $X_{2,i}$ 配成一对 $(X_{1,i}, X_{2,i})$, 则由于 $X_{1,i} \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_{2,i} \sim \mathcal{N}(\mu_2, \sigma_2^2)$, 且 $X_{1,i}$ 与 $X_{2,i}$ 相互独立, 可知 $X_{1,i} - X_{2,i}$ 服从正态分布 $\mathcal{N}(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$. 接下来取检验统计量为

$$T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S_D^2/n}},$$

其中

$$S_D^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{1,i} - \bar{X}_1 - X_{2,i} + \bar{X}_2)^2,$$

则在原假设 H_0 下 T 服从自由度为 $n-1$ 的 t 分布, 此后依照通常的 t 检验步骤计算 p 值/拒绝域即可. 上述方法还可推广到 $n_1 \neq n_2$ 的情形; 见 Scheffé 的原始论文 [26] 以及教材 [27] 第 9.9 节. Bartlett-Scheffé 检验法的优点在于检验统计量在

原假设下的分布是确切已知而与 σ_1^2 和 σ_2^2 无关的, 而缺点则是检验结果会与配对的次序相关, 且与接下来介绍的 t^* 检验法相比, 在显著性水平与样本容量保持一致时, 它通常更不容易在备择假设成立时拒绝原假设, 从而第 II 类错误的概率更高.

- t^* 检验: 该类检验法基于如下统计量:

$$T^* = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

直观上看, T^* 相当于将式 (9.15) 中的方差替换为样本方差, 故应当是一个合理的检验统计量, 且不难看出原假设 H_0 下 T^* 的分布关于原点对称, 故可以考虑用 $|T^*|$ 做单侧检验. 然而, $|T^*|$ 在原假设 H_0 下并不服从一个确切已知的分布, 其分布与方差之比 σ_1^2/σ_2^2 有关; 更具体地说, 给定 $c > 0$, 原假设下的概率 $\mathbb{P}(|T^*| \geq c)$ 是 σ_1^2/σ_2^2 的函数, 我们将这个函数暂记为 $\beta(\sigma_1^2/\sigma_2^2; c)$. 我国概率统计学科的奠基人、著名数学家许宝騄先生在他攻读博士期间完成的论文 [28] 中对 $\beta(\sigma_1^2/\sigma_2^2; c)$ 的性质进行了详细的研究, 其中的结论指出

$$\begin{aligned} \sup_{\sigma_1^2, \sigma_2^2} \beta(\sigma_1^2/\sigma_2^2; c) &= 2(1 - F_{\min\{n_1, n_2\}-1}^t(c)), \\ \min_{\sigma_1^2, \sigma_2^2} \beta(\sigma_1^2/\sigma_2^2; c) &= 2(1 - F_{n_1+n_2-2}^t(c)). \end{aligned}$$

基于此, 我们可以令 p 值为

$$\hat{p} = \sup_{\sigma_1^2, \sigma_2^2} \beta(\sigma_1^2/\sigma_2^2; |t^*|) = 2(1 - F_{\min\{n_1, n_2\}-1}^t(|t^*|)),$$

而显著性水平 α 下的拒绝域则由

$$|t^*| > t_{\alpha/2}(\min\{n_1, n_2\} - 1)$$

给出, 该拒绝域给出的实际第 I 类错误概率可以保证小于等于 α . 不过在 σ_1^2 与 σ_2^2 相差不大的情况下, 上述 p 值与拒绝域会稍显保守. Welch [29] 则提出了如下近似:

$$\beta(\sigma_1^2/\sigma_2^2; |t^*|) \approx 2(1 - F_{\nu}^t(|t^*|)),$$

其中⁴

$$\nu = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}.$$

相应的拒绝域则由 $|t^*| > t_{\alpha/2}(\nu)$ 给出, 但应当指出, 该拒绝域给出的实际第 I 类错误概率并不能严格保证小于等于 α .

⁴ 该式给出的 ν 一般不为整数, 但仍可代入 t 分布概率密度函数的定义式中并算出相应的分布函数值.

关于 Behrens–Fisher 问题的讨论还可参考 [27] 第 9.9 节、[18] 例 5.6 与第 5.2 (iv) 节, 以及论文 [30].

9.4.2 两个正态总体方差的假设检验

设两个总体各自服从正态分布 $\mathcal{N}(\mu_1, \sigma_1^2)$ 与 $\mathcal{N}(\mu_2, \sigma_2^2)$, 其中期望 μ_1, μ_2 与方差 σ_1^2, σ_2^2 均未知. 考虑如下假设检验问题:

$$H_0 : \sigma_1^2 = \sigma_2^2, \quad H_1 : \sigma_1^2 \neq \sigma_2^2.$$

注意 H_0 与 H_1 均为复合假设. 对于该假设检验问题, 可令

$$F = \frac{S_1^2}{S_2^2} \quad (9.17)$$

为双侧检验统计量. 在原假设 H_0 下, F 服从自由度为 $(n_1 - 1, n_2 - 1)$ 的 F 分布. 故在获得样本观测值 $x_{1,1}, \dots, x_{1,n_1}$ 与 $x_{2,1}, \dots, x_{2,n_2}$ 后, 相应的 p 值为

$$\begin{aligned} \hat{p} &= 2 \min \left\{ \mathbb{P}_{H_0} \left(\frac{S_1^2}{S_2^2} \geq \frac{s_1^2}{s_2^2} \right), \mathbb{P}_{H_0} \left(\frac{S_1^2}{S_2^2} \leq \frac{s_1^2}{s_2^2} \right) \right\} \\ &= 2 \min \left\{ 1 - F_{n_1-1, n_2-1}^F \left(\frac{s_1^2}{s_2^2} \right), F_{n_1-1, n_2-1}^F \left(\frac{s_1^2}{s_2^2} \right) \right\}, \end{aligned}$$

其中 F_{n_1-1, n_2-1}^F 表示分布 $F(n_1 - 1, n_2 - 1)$ 的分布函数. 而若事先给定显著性水平 α , 则由临界值计算式 (9.7) 可得

$$c_\alpha^u = F_{\alpha/2}(n_1 - 1, n_2 - 1), \quad c_\alpha^l = F_{1-\alpha/2}(n_1 - 1, n_2 - 1),$$

故拒绝域由

$$\frac{s_1^2}{s_2^2} > F_{\alpha/2}(n_1 - 1, n_2 - 1) \text{ 或 } \frac{s_1^2}{s_2^2} < F_{1-\alpha/2}(n_1 - 1, n_2 - 1)$$

给出.

若备择假设被替换为 $H_1 : \sigma_1^2 > \sigma_2^2$ 或 $H_1 : \sigma_1^2 < \sigma_2^2$, 则可以将 (9.17) 作为单侧检验统计量进行假设检验, 相关的推导留给读者自己完成. 表 9.6 总结了期望未知时, 对两个正态总体的方差进行假设检验的方法.

表 9.6: 期望未知时, 两个正态总体方差之比 σ_1^2/σ_2^2 的假设检验方法

H_0	H_1	检验统计量	拒绝域	p 值
$\frac{\sigma_1^2}{\sigma_2^2} = 1$	$\frac{\sigma_1^2}{\sigma_2^2} > 1$	$F = \frac{S_1^2}{S_2^2}$	$\frac{s_1^2}{s_2^2} > f_{\alpha}(n_1-1, n_2-1)$	$1 - F_{n_1-1, n_2-1}^F\left(\frac{s_1^2}{s_2^2}\right)$
$\frac{\sigma_1^2}{\sigma_2^2} = 1$	$\frac{\sigma_1^2}{\sigma_2^2} < 1$	$F = \frac{S_1^2}{S_2^2}$	$\frac{s_1^2}{s_2^2} < f_{1-\alpha}(n_1-1, n_2-1)$	$F_{n_1-1, n_2-1}^F\left(\frac{s_1^2}{s_2^2}\right)$
$\frac{\sigma_1^2}{\sigma_2^2} = 1$	$\frac{\sigma_1^2}{\sigma_2^2} \neq 1$	$F = \frac{S_1^2}{S_2^2}$	$\frac{s_1^2}{s_2^2} > f_{\alpha/2}(n_1-1, n_2-1)$ 或 $\frac{s_1^2}{s_2^2} < f_{1-\alpha/2}(n_1-1, n_2-1)$	$2 \min\left\{F_{n_1-1, n_2-1}^F\left(\frac{s_1^2}{s_2^2}\right), 1 - F_{n_1-1, n_2-1}^F\left(\frac{s_1^2}{s_2^2}\right)\right\}$

注: S_1^2, S_2^2 为两个样本的样本方差, s_1^2, s_2^2 表示获取到样本值以后两个样本方差的取值; α 为事先给定的显著性水平.

9.4.3 大样本情形下比例之差的假设检验

设两个样本分别服从参数为 p_1 与 p_2 的伯努利分布, 考虑如下原假设与备择假设给出的假设检验问题:

$$H_0 : p_1 = p_2, \quad H_1 : p_1 \neq p_2.$$

我们只考虑样本容量 n_1 与 n_2 均足够大的情形. 由中心极限定理可得, 随机变量

$$\tilde{Z} = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{p_1(1-p_1)/n_1 + p_2(1-p_2)/n_2}} \quad (9.18)$$

在原假设 H_0 下近似服从标准正态分布 $\mathcal{N}(0, 1)$, 然而 $\tilde{Z}$ 依赖于未知的参数 p_1, p_2 , 不能直接作为检验统计量, 故类似于 8.3.3 小节中针对比例之差设计枢轴量的方法, 我们考虑在大样本情形下将 p_1 与 p_2 替换为它们的点估计量. 不过, 注意到原假设 H_0 下 p_1 与 p_2 取相同的值, 因而可以用

$$\hat{\Pi} = \frac{\sum_{i=1}^{n_1} X_{1,i} + \sum_{i=1}^{n_2} X_{2,i}}{n_1 + n_2}$$

将两个样本合并起来对原假设下的 $p_1 = p_2$ 进行估计; 有时会将 $\hat{\Pi}$ 称为**合并比例**⁵. 当 $n_1 + n_2$ 足够大时, $\hat{\Pi}$ 可以作为原假设下 $p_1 = p_2$ 的一个很好的近似. 故我们最终取

$$Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\hat{\Pi}(1 - \hat{\Pi})(1/n_1 + 1/n_2)}}$$

为双侧检验估计量, 它在原假设 H_0 下近似服从标准正态分布 $\mathcal{N}(0, 1)$. 由此可得 p 值为

$$\hat{p} = 2(1 - \Phi(|z|)),$$

其中

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\hat{\pi}(1 - \hat{\pi})(1/n_1 + 1/n_2)}}, \quad \hat{\pi} = \frac{\sum_{i=1}^{n_1} x_{1,i} + \sum_{i=1}^{n_2} x_{2,i}}{n_1 + n_2}.$$

而若事先设定了显著性水平 α , 则拒绝域由

$$|z| > z_{\alpha/2}$$

给出.

对于备择假设为 $H_1: p_1 < p_2$ 或 $H_1: p_1 > p_2$ 的单侧检验问题, 仍可利用上述方法导出相应的 p 值与拒绝域, 我们将具体的推导留给读者完成.

9.5 (*) 一些非参数检验问题

本节中, 我们将介绍一些非参数检验问题. 所谓的非参数检验, 是指假设检验问题中不再假定总体的分布函数一定可以表示为 $F(x; \theta)$ 的形式; 换句话说, 不再认为总体的未知信息全都包含在某个未知的参数 θ 当中. 对于非参数检验, 原则上其原假设与备择假设的形式会更为灵活, 但本节考虑的问题中备择假设 H_1 多是表达原假设 H_0 的某种“否定”, 下面给出几个例子:

- H_0 : 总体的分布函数为 $F_0(x)$,
 H_1 : 总体的分布函数不是 $F_0(x)$,
 其中 F_0 为一给定的分布函数.
- H_0 : 总体服从某个泊松分布,
 H_1 : 总体取值为非负整数, 其分布不是泊松分布.

⁵ 若原假设换为 $H_0: p_1 - p_2 = \Delta_0$, 其中 Δ_0 为非零值, 则不能再合并比例来构造检验统计量.

- H_0 : 总体 (X, Y) 当中 X 与 Y 相互独立,
 H_1 : 总体 (X, Y) 当中 X 与 Y 不独立.

通常, 若备择假设 H_1 可以通过对原假设 H_0 按某种方式取“否定”自然地看出来, 那我们就显式地指明备择假设 H_1 , 而仅指明原假设 H_0 .

9.5.1 拟合优度检验

拟合优度检验 (test of goodness-of-fit) 是针对总体是否具有某一个指定的分布或属于某一个分布族而进行的假设检验. 最简单的拟合优度检验问题具有如下形式: 给定一个确定的分布函数 $F_0(x)$, 我们想要基于获得的样本, 检验总体的分布函数是否就是 $F_0(x)$, 即

$$H_0: \text{总体的分布函数为 } F_0(x), \quad H_1: \text{总体的分布函数不是 } F_0(x).$$

我们简要介绍两种拟合优度检验的方法: Pearson 卡方检验法与 Kolmogorov-Smirnov 检验法.

Pearson 卡方检验法. 设 $X_1, \dots, X_n$ 为来自未知总体的样本, 其中样本容量 n 足够大. $\mathcal{R}$ 为实数集的一个子集, 它使得分布函数为 $F_0(x)$ 的随机变量取值落于 $\mathcal{R}$ 内的概率为 1. 在 Pearson 卡方检验法中, 我们首先将 $\mathcal{R}$ 划分成 m 个互不相交的子集 $B_1, B_2, \dots, B_m$. 例如

- 若 $\mathcal{R} = \mathbb{R}$, 则通常会将各个 B_k 取为如下形式的区间:

$$\mathbb{R} =]-\infty, a_1] \cup]a_1, a_2] \cup]a_2, a_3] \cup \dots \cup]a_{m-2}, a_{m-1}] \cup]a_{m-1}, +\infty[. \quad (9.19)$$

- 当 $\mathcal{R} = \{r_1, r_2, \dots\}$ 为一可数集时, $F_0(x)$ 可以当作一个离散型分布, 记其分布列为 $p_0(x)$, 则一种 $\mathcal{R}$ 的划分方法是将 $r_1, r_2, \dots$ 先按照 $p_0(r_j)$ 的值进行降序排序, 而后取

$$B_1 = \{r_1\}, B_2 = \{r_2\}, \dots, B_{m-1} = \{r_{m-1}\}, B_m = \{r_m, r_{m+1}, \dots\}. \quad (9.20)$$

我们将分布 $F_0(x)$ 下随机变量属于集合 B_k 的概率记为 p_k . 例如, 若 $\mathcal{R} = \mathbb{R}$ 并采用式 (9.19) 的划分方式, 则

$$\begin{aligned} p_1 &= F_0(a_1), & p_m &= 1 - F_0(a_{m-1}), \\ p_k &= F_0(a_k) - F_0(a_{k-1}), & k &= 2, \dots, m-1, \end{aligned}$$

而若 $\mathcal{R} = \{r_1, r_2, \dots\}$ 并采用式 (9.20) 的划分方式, 则

$$p_k = p_0(r_k), \quad k = 1, 2, \dots, m-1, \quad p_m = \sum_{j \geq m} p_0(r_j),$$

其中 $p_0(x)$ 表示 $F_0(x)$ 相应的分布列. 直观上看, 若原假设 H_0 成立, 则当样本容量 n 足够大时, 样本 $X_1, \dots, X_n$ 当中落在集合 B_k 内的数目应当约等于 np_k , 也就是说

$$\sum_{i=1}^n 1_{\{X_i \in B_k\}} \approx np_k, \quad \text{若原假设 } H_0 \text{ 成立.}$$

而若样本容量 n 非常大时, 上述近似相等的关系依然对于某个 k 不成立, 则意味着原假设不能很好地解释我们所获取的样本数据, 或者说, 分布函数 $F_0(x)$ 作为一个统计模型不能很好地对样本数据进行拟合. 基于上述考虑, Karl Pearson 设计了如下检验统计量用于拟合优度检验:

$$Q = \sum_{k=1}^m \frac{(N_k - np_k)^2}{np_k}, \quad \text{其中 } N_k = \sum_{i=1}^n 1_{\{X_i \in B_k\}}. \quad (9.21)$$

直观上看, 若 Q 取值明显偏大, 则意味着样本相对于原假设 H_0 产生了显著的偏离. 注意到式 (9.21) 当中, 对每个衡量偏离程度的 $(N_k - np_k)^2$ 还乘以了因子 $1/(np_k)$; 大致来说, 这个因子起到了对各个偏离程度 $(N_k - np_k)^2$ 进行平衡的作用, 并使得检验统计量 Q 在原假设 H_0 下的渐近分布 (也就是样本容量 n 趋于无穷大时分布的极限) 能够被推导出来.

定理 9.1. 令 X^2 为式 (9.21) 定义的检验统计量, 并设原假设 H_0 成立 (即 $F_0(x)$ 为总体的分布函数). 则当 $n \rightarrow \infty$ 时, X^2 的分布函数将逐点收敛于 $\chi^2(m-1)$ 的分布函数.

定理 9.1 的证明不做要求, 感兴趣的读者可参阅 [17] 定理 7.131, 但我们指出它的背后实际上是中心极限定理. 定理中 χ^2 分布的自由度为 $m-1$ 则与 $\sum_{k=1}^m N_k = n$ 这一等式关系有关.

在搞清楚大样本情形下 X^2 在原假设成立时的分布以后, 我们即可得到 p 值与拒绝域. 设 $x_1, \dots, x_n$ 为获取的样本值, 对每个 $k = 1, \dots, m$, 用 n_k 表示 $x_1, \dots, x_n$ 当中落在集合 B_k 中的点的个数, 则 p 值为

$$\hat{p} = 1 - F_{m-1}^{\chi^2}(q), \quad \text{其中 } q = \sum_{i=1}^n \frac{(n_k - np_k)^2}{np_k},$$

而拒绝域则由

$$q > \chi_{\alpha}^2(m-1)$$

给出, 其中 α 为事先给定的显著性水平.

在 Pearson 卡方检验当中, 总体值域 $\mathcal{R}$ 的划分方式 (包括子集的数目 m 以及每个子集 B_k 的具体取法) 会对检验的最终结果产生影响. 经验指出, 通常应当使得划分之后算出的各个 p_k 值至少满足 $np_k \geq 5$. 此外, 由于定理 9.1 给出的仅仅是检验统计量的渐近分布, 故 Pearson 卡方检验只适用于大样本情形, 经验上, 通常认为样本容量小于 50 的情形不适合用 Pearson 卡方检验法.

例 9.4. 设有一枚均匀性未知的立方体骰子, 六个面上依次标有点数 $1, 2, \dots, 6$. 将该骰子投掷 600 次后, 六个点数各自出现的次数依次为 96, 87, 117, 92, 102, 106. 我们采用 Pearson 卡方检验法来对骰子的均匀性进行检验. 令总体 X 为骰子投掷出的点数, 则骰子的均匀性意味着 X 服从 $\{1, 2, \dots, 6\}$ 上的离散型均匀分布, 也即

$$\mathbb{P}_{H_0}(X = k) = \frac{1}{6}, \quad k = 1, 2, \dots, 6.$$

我们自然取 $\mathcal{R} = \{1, \dots, 6\}$ 并将其划分为 $\mathcal{R} = \{1\} \cup \{2\} \cup \dots \cup \{6\}$. 按照该划分方式, Pearson 卡方检验的检验统计量的值为

$$\begin{aligned} q &= \frac{(96-100)^2}{100} + \frac{(87-100)^2}{100} + \frac{(117-100)^2}{100} \\ &\quad + \frac{(92-100)^2}{100} + \frac{(102-100)^2}{100} + \frac{(106-100)^2}{100} \\ &= 5.78, \end{aligned}$$

而检验统计量在原假设下近似服从自由度为 $6 - 1 = 5$ 的 χ^2 分布, 故 p 值为

$$\hat{p} = 1 - F_5^{\chi^2}(5.78) = 0.328.$$

这个 p 值是比较大的, 因而从我们获得的投掷结果来看, 还没有充分理由认为骰子是非均匀的. ■

(*) Kolmogorov-Smirnov 检验法. 在 Kolmogorov-Smirnov 检验法中, 我们首先基于经验分布函数来构造如下随机变量:

$$\begin{aligned} D_n &= \sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F_0(x) \right| \\ &= \sup_{x \in \mathbb{R}} \left| \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}} - F_0(x) \right|, \end{aligned} \tag{9.22}$$

习惯上我们会显式地把样本容量 n 放在该随机变量的角标中. 以 D_n 为基础来设计拟合优度检验统计量的合理性部分来自于如下 Glivenko–Cantelli 定理:

定理 9.2 (Glivenko–Cantelli). 设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, 它们的分布函数均为 $F_0(x)$. 令 D_n 由式 (9.22) 定义, 则当 $n \rightarrow \infty$ 时, D_n 几乎必然收敛于 0.

不难看出, D_n 衡量了经验分布函数 $\hat{F}_n(x)$ 与 $F_0(x)$ 之间的最大差值, 而 Glivenko–Cantelli 定理则保证了样本容量趋于无穷大时该差值趋于 0. 因此, 直观上看, 若样本容量 n 非常大时, 我们根据样本观测值算出的检验统计量的值 d_n 依然较大, 则说明样本值相对于原假设 H_0 有显著的偏离.

当然, 由于 D_n 在 $n \rightarrow \infty$ 时趋于 0, 我们需要将其乘以适当的系数, 使其具有非退化的渐近分布, 再将它作为检验统计量, 以方便 p 值与临界值的计算. 这方面的结果由如下定理给出:

定理 9.3 (Kolmogorov–Smirnov). 设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布, 它们的分布函数均为 $F_0(x)$. 令 D_n 由式 (9.22) 定义, 则对任意 $t > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n}D_n \leq t) = 1 - 2 \sum_{i=1}^{\infty} (-1)^{i-1} e^{-2i^2 t^2}. \quad (9.23)$$

式 (9.23) 指出, 我们可以将 $\sqrt{n}D_n$ 作为检验统计量, 而该检验统计量在大样本极限时的分布函数由式 (9.23) 给出. 式 (9.23) 右端给出的分布又被称为 Kolmogorov 分布. 接下来, 我们即可依据式 (9.23) 来计算大样本情形的 p 值与临界值. 设 $x_1, \dots, x_n$ 为获得的样本观测值, 其中样本容量 n 足够大, $\sqrt{n}d_n$ 为检验统计量 $\sqrt{n}D_n$ 在该组样本上的取值, 则 p 值为

$$\hat{p} = 2 \sum_{i=1}^{\infty} (-1)^{i-1} e^{-2nd_n^2 i^2},$$

而给定显著性水平 α 后, 临界值则由 Kolmogorov 分布的上 α 分位数给出.

注 9.3. 当分布函数 $F_0(x)$ 对应于一个连续型分布时, 通常会考虑用 Kolmogorov–Smirnov 检验法而非 Pearson 卡方检验法来进行拟合优度检验. 而若分布函数 $F_0(x)$ 对应于一个离散型分布, 则通常会先考虑用 Pearson 卡方检验. 另一方面, Pearson 卡方检验具有较高的灵活性, 可以推广到其它更复杂的拟合优度检验问题中, 包括总体是多维随机向量时的拟合优度检验问题, 以及对总体是否来自于给定的一族参数化分布进行检验的问题 (例如对 “ H_0 : 总体服从某个泊松分布” 进行检验; 见 [22] 第 10.2 节). ■

9.5.2 列联表与独立性检验

本小节中我们考虑这样一个问题: 设总体为一个二维随机变量 (X, Y) , 获取的简单随机样本为 $(X_1, Y_1), \dots, (X_n, Y_n)$. 应当如何通过样本来检验总体当中 X 与 Y 之间的独立性? 换句话说, 我们希望检验原假设

$$H_0: \text{总体 } (X, Y) \text{ 中 } X \text{ 与 } Y \text{ 相互独立.}$$

我们将这样的假设检验称为**独立性检验** (test of independence).

接下来介绍的独立性检验法可以看作是 Pearson 提出的卡方检验法的一个变种. 设已知总体 (X, Y) 当中 X 与 Y 的取值范围分别由有限集 $\mathcal{R}_X$ 与 $\mathcal{R}_Y$ 给出⁶, 其中

$$\mathcal{R}_X = \{a_1, a_2, \dots, a_r\}, \quad \mathcal{R}_Y = \{b_1, b_2, \dots, b_c\},$$

而 r 与 c 分别为 $\mathcal{R}_X$ 与 $\mathcal{R}_Y$ 的元素个数. 随后, 对每个 $j = 1, \dots, r$ 与 $k = 1, \dots, c$, 我们统计样本 $(X_1, Y_1), \dots, (X_n, Y_n)$ 当中等于 (a_j, b_k) 的数目有多少:

$$N_{jk} = \sum_{i=1}^n \mathbf{1}_{\{X_i=a_j, Y_i=b_k\}}, \quad j = 1, \dots, r, \quad k = 1, \dots, c,$$

并令

$$\begin{aligned} N_{j+} &= \sum_{k=1}^c N_{jk} = \sum_{i=1}^n \mathbf{1}_{\{X_i=a_j\}}, \\ N_{+k} &= \sum_{j=1}^r N_{jk} = \sum_{i=1}^n \mathbf{1}_{\{Y_i=b_k\}}. \end{aligned}$$

显然 $n = \sum_{j,k} N_{jk} = \sum_{j=1}^r N_{j+} = \sum_{k=1}^c N_{+k}$. 若原假设 H_0 成立, 也就是说 X 与 Y 相互独立, 则当样本容量 n 足够大时, 对任意的 j 和 k , 均应当有

$$\begin{aligned} N_{jk} &\approx n \cdot \mathbb{P}_{H_0}(X = a_j, Y = b_k) \\ &= n \cdot \mathbb{P}_{H_0}(X = a_j) \cdot \mathbb{P}_{H_0}(Y = b_k) \approx \frac{1}{n} N_{j+} N_{+k}. \end{aligned}$$

基于上述考虑, 仿照拟合优度检验中检验统计量的构造, 我们取

$$Q = \sum_{j=1}^r \sum_{k=1}^c \frac{(N_{jk} - \hat{E}_{jk})^2}{\hat{E}_{jk}}, \quad \text{其中 } \hat{E}_{jk} = \frac{1}{n} N_{j+} N_{+k} \quad (9.24)$$

为检验统计量. 原假设成立时, 该检验统计量在大样本极限下的渐近分布由如下定理给出:

⁶ 若 X 或 Y 的值域为无限集, 则需要像上一节那样先将 X 与 Y 的值域划分为有限多个组别.

定理 9.4. 令 Q 为式 (9.24) 定义的检验统计量, 并设原假设 H_0 成立 (即 X 与 Y 相互独立). 则当 $n \rightarrow \infty$ 时, Q 的分布函数将逐点收敛于 $\chi^2((r-1)(c-1))$ 的分布函数.

换句话说, 检验统计量 Q 在大样本情形下近似服从自由度为 $(r-1)(c-1)$ 的 χ^2 分布. 由此即可得到大样本情形下的 p 值与临界值: 设 $(x_1, y_1), \dots, (x_n, y_n)$ 为样本观测数据, 则 p 值约为

$$\hat{p} \approx 1 - F_{(r-1)(c-1)}^{\chi^2}(q),$$

其中 q 为检验统计量 Q 在该组样本上的取值. 若给定了显著性水平 α , 则拒绝域可近似表示为

$$q > \chi_{\alpha}^2((r-1)(c-1)).$$

在将上述检验法用于实际问题时, 我们习惯上会把样本数据 $(x_1, y_1), \dots, (x_n, y_n)$ 进行处理并表示为如下形式的表格:

X	Y				总计
	b_1	b_2	$\cdots$	b_c	
a_1	n_{11}	n_{12}	$\cdots$	n_{1c}	n_{1+}
a_2	n_{21}	n_{22}	$\cdots$	n_{2c}	n_{2+}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_r	n_{r1}	n_{r2}	$\cdots$	n_{rc}	n_{r+}
总计	n_{+1}	n_{+2}	$\cdots$	n_{+c}	n

其中 n_{jk} 即为统计量 N_{jk} 在给定样本数据后的具体取值, 也就是 $(x_1, y_1), \dots, (x_n, y_n)$ 中有多少个点取值为 (a_j, b_k) ; n_{j+} 与 n_{+k} 同理. 上述形式的表格被称为**列联表**(contingency table).

例 9.5 (本例取自 [22] 第 10.4 节练习 3). A 大学每周五下午会面向全校本科学生举办由访问学者主讲的学术讲座. 在 4 次讲座过后, 讲座负责人随机调查了 70 名大一学生、70 名大二学生、60 名大三学生与 50 名大四学生的讲座参与情况, 并汇总为如下表格:

年级	讲座参与次数					总人数
	0	1	2	3	4	
大一	10	16	27	6	11	70
大二	14	19	20	4	13	70
大三	15	15	17	4	9	60
大四	19	8	6	5	12	50
总人数	58	58	70	19	45	250

我们希望判断讲座参与次数与年级是否相互独立. 为了计算检验统计量 (9.24) 的值, 我们首先计算各个 $\hat{e}_{jk}$ 的值, 可得

$$[\hat{e}_{jk}] = \begin{bmatrix} 16.24 & 16.24 & 19.6 & 5.32 & 12.6 \\ 16.24 & 16.24 & 19.6 & 5.32 & 12.6 \\ 13.92 & 13.92 & 16.8 & 4.56 & 10.8 \\ 11.6 & 11.6 & 14 & 3.8 & 9 \end{bmatrix}.$$

接下来即可算得检验统计量 (9.24) 的值为

$$q = \sum_{j=1}^4 \sum_{k=1}^5 \frac{(n_{jk} - \hat{e}_{jk})^2}{\hat{e}_{jk}} = 18.9386,$$

而 $(r-1)(c-1) = (4-1) \times (5-1) = 12$, 故 p 值为

$$\hat{p} = 1 - F_{12}^{\chi^2}(18.9386) = 0.0900.$$

由该 p 值, 可认为讲座参与次数与年级之间呈现出一些不独立的迹象, 但若想要做出更确切的结论则需要进一步收集数据. ■

9.6 (*) Neyman–Pearson 引理

Neyman–Pearson 引理是假设检验理论中的一个基本定理, 它给出了原假设与备择假设均为简单假设时, 应当如何选择“最优”的检验统计量.

首先讨论原假设与备择假设均为简单假设时, 如何评价检验统计量的优劣. 考虑在原假设与备择假设之间二选一的假设检验问题, 设样本容量为 n , 检验统计量为 $T = \phi(X_1, \dots, X_n)$, $\alpha \in]0, 1[$ 为显著性水平, 此时的假设检验流程为

若 $\phi(x_1, \dots, x_n) \in C_\alpha$, 则拒绝 H_0 ; 否则接受 H_0 .

其中 C_α 为相应的拒绝域. 我们将相应的第 I 类错误概率与第 II 类错误概率分别记为

$$P_I(\alpha; T) = \mathbb{P}_{H_0}(T \in C_\alpha) \quad \text{与} \quad P_{II}(\alpha; T) = \mathbb{P}_{H_1}(T \notin C_\alpha).$$

固定 T 时, $P_I(\alpha; T)$ 与 $P_{II}(\alpha; T)$ 都是显著性水平 α 的函数, 且 $P_I(\alpha; T) \leq \alpha$; 若 T 在假设下为连续型随机变量, 则进一步有 $P_I(\alpha; T) = \alpha$.

在前文中已经提到, 在样本容量固定的情况下, 通常不可能同时让 $P_I(\alpha; T)$ 与 $P_{II}(\alpha; T)$ 都取到任意小, 而在 Neyman-Pearson 理论中, 会先设定一个显著性水平 (或者说, 为第 I 类错误概率设定一个上界), 而后考察应如何选取检验统计量, 使得第 II 类错误的概率达到最小. 这个思路可以总结为如下定义:

定义 9.1. 给定简单假设 H_0, H_1 以及显著性水平 $\alpha \in]0, 1[$, 设 T 为一检验统计量, 其样本容量为 n . 若对任意样本容量为 n 的检验统计量 T' , 均有 $P_{II}(\alpha; T') \geq P_{II}(\alpha; T)$, 则称 T 在显著性水平 α 下是最优的.

在阐明了最优的检验统计量应如何定义之后, 我们介绍 Neyman-Pearson 引理的相关结果.

定理 9.5. 设 H_0 与 H_1 为简单假设, 总体在 H_0 与 H_1 下均服从连续型分布, 相应的概率密度函数分别为 f_0 与 f_1 , 样本容量固定为 n . 令单侧检验统计量 T_{LR} 为⁷

$$T_{LR} = \frac{\prod_{i=1}^n f_1(X_i)}{\prod_{i=1}^n f_0(X_i)}.$$

则对任意给定的 $\alpha \in]0, 1[$, 当 $P_I(\alpha; T_{LR}) = \alpha$ 时, T_{LR} 在显著性水平 α 下是最优的.

证明. 设 $\alpha \in]0, 1[$ 使得 $P_I(\alpha; T_{LR}) = \alpha$. 将 T_{LR} 在显著性水平 α 下的拒绝域记为 $]\kappa_\alpha, +\infty[$; 根据 T_{LR} 的取值范围, 不难看出 $\kappa_\alpha \geq 0$. 令 T 为任意检验统计量, 其显著性

⁷ 当 $\prod_{i=1}^n f_0(X_i) = 0$ 时, 我们规定 T_{LR} 的取值为 $+\infty$.

水平 α 下的拒绝域记为 C_α . 定义

$$\tau_{\text{LR}}(\mathbf{x}) = \begin{cases} 1, & \text{若 } \frac{\prod_{i=1}^n f_1(x_i)}{\prod_{i=1}^n f_0(x_i)} > \kappa_\alpha, \\ 0, & \text{其它情形,} \end{cases}$$

$$\tau(\mathbf{x}) = \begin{cases} 1, & \text{若 } \phi(\mathbf{x}) \in C_\alpha, \\ 0, & \text{其它情形,} \end{cases}$$

以及

$$U(\mathbf{x}) = (\tau_{\text{LR}}(\mathbf{x}) - \tau(\mathbf{x})) \left(\prod_{i=1}^n f_1(x_i) - \kappa_\alpha \prod_{i=1}^n f_0(x_i) \right),$$

其中记 $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$, 则

- 当 $\tau_{\text{LR}}(\mathbf{x}) = 1$ 时, 有 $\tau_{\text{LR}}(\mathbf{x}) - \tau(\mathbf{x}) \geq 0$ 以及 $\prod_{i=1}^n f_1(x_i) - \kappa_\alpha \prod_{i=1}^n f_0(x_i) > 0$, 故此时 $U(\mathbf{x}) \geq 0$;
- 当 $\tau_{\text{LR}}(\mathbf{x}) = 0$ 时, 有 $\tau_{\text{LR}}(\mathbf{x}) - \tau(\mathbf{x}) \leq 0$ 以及 $\prod_{i=1}^n f_1(x_i) - \kappa_\alpha \prod_{i=1}^n f_0(x_i) \leq 0$, 故此时仍有 $U(\mathbf{x}) \geq 0$.

因此 $U(\mathbf{x})$ 恒大于等于 0, 这意味着 $\int_{\mathbb{R}^n} U(\mathbf{x}) d\mathbf{x} \geq 0$. 另一方面,

$$\begin{aligned} \int_{\mathbb{R}^n} U(\mathbf{x}) d\mathbf{x} &= \int_{\mathbb{R}^n} \tau_{\text{LR}}(\mathbf{x}) \prod_{i=1}^n f_1(x_i) d\mathbf{x} - \int_{\mathbb{R}^n} \tau(\mathbf{x}) \prod_{i=1}^n f_1(x_i) d\mathbf{x} \\ &\quad - \kappa_\alpha \left(\int_{\mathbb{R}^n} \tau_{\text{LR}}(\mathbf{x}) \prod_{i=1}^n f_1(x_i) d\mathbf{x} - \int_{\mathbb{R}^n} \tau(\mathbf{x}) \prod_{i=1}^n f_0(x_i) d\mathbf{x} \right) \\ &= \mathbb{E}_{H_1}[\tau_{\text{LR}}(X_1, \dots, X_n)] - \mathbb{E}_{H_1}[\tau(X_1, \dots, X_n)] \\ &\quad - \kappa_\alpha (\mathbb{E}_{H_0}[\tau_{\text{LR}}(X_1, \dots, X_n)] - \mathbb{E}_{H_0}[\tau(X_1, \dots, X_n)]) \\ &= \mathbb{P}_{H_1}(T \in C_\alpha) - \mathbb{P}_{H_1}(T_{\text{LR}} > \kappa_\alpha) - \kappa_\alpha (\mathbb{P}_{H_0}(T_{\text{LR}} > \kappa_\alpha) - \mathbb{P}_{H_0}(T \in C_\alpha)) \\ &= P_{\text{II}}(\alpha; T) - P_{\text{II}}(\alpha; T_{\text{LR}}) - \kappa_\alpha (P_{\text{I}}(\alpha; T_{\text{LR}}) - P_{\text{I}}(\alpha; T)). \end{aligned}$$

而由于 $P_{\text{I}}(\alpha; T) \leq \alpha = P_{\text{I}}(\alpha; T_{\text{LR}})$, 根据 $\int_{\mathbb{R}^n} U(\mathbf{x}) d\mathbf{x} \geq 0$ 以及 $\kappa_\alpha \geq 0$, 可知必定有 $P_{\text{II}}(\alpha; T) - P_{\text{II}}(\alpha; T_{\text{LR}}) \geq 0$. 对照定义 9.1 可知 T_{LR} 在显著性水平 α 下是最优的. $\square$

定理 9.5 中的检验统计量 T_{LR} 是备择假设与原假设下的似然函数值之比, 故而它又被称为**似然比** (likelihood ratio), 相应的假设检验方法被称为**似然比检验**. 定理 9.5 确立了原假设与备择假设均为简单假设时似然比检验的最优性, 它是 Neyman-Pearson 引理中最为重要的一部分. 完整的 Neyman-Pearson 引理还确立了在任意显著性水平下

最优检验的存在性以及最优检验在拒绝域上的唯一性, 但表述与建立这些结果需引入随机化检验的概念, 这里就不再继续展开了, 感兴趣的读者可进一步查阅 [31]、[32] 等数理统计教材.

9.7 习题

习题 9.1. 设原假设与备择假设分别为 H_0 与 H_1 , T 为一满足条件 9.1 的检验统计量, 并设 T 在 H_0 下服从连续型分布. 将显著性水平为 α 时的拒绝域记为 C_α .

1. 证明 C_α 具有如下意义的单调性: 若 $\alpha, \alpha' \in]0, 1[$ 满足 $\alpha < \alpha'$, 则 $C_\alpha \subseteq C_{\alpha'}$.

提示 针对单侧检验与双侧检验的情形, 分别利用式 (9.5) 与式 (9.7).

2. 将 T 在显著性水平 α 下的第 II 类错误概率记为 $P_{II}(\alpha)$, 证明 $P_{II}(\alpha)$ 关于 α 单调不增.

习题 9.2 (p 值在原假设下的概率分布). 设 H_0 为简单假设, 检验统计量 $T = \phi(X_1, \dots, X_n)$ 在 H_0 下为连续型随机变量, 相应的分布函数记为 $F_T^0: \mathbb{R} \rightarrow [0, 1]$. 进一步设存在开区间 I , 使得 F_T^0 在 I 上严格单调递增, 且有 $\{F_T^0(t) \mid t \in I\} =]0, 1[$. 用 $\hat{p}(x_1, \dots, x_n)$ 表示样本值 $x_1, \dots, x_n$ 对应的 p 值.

1. 证明: 当 T 为单侧检验统计量时, 有

$$\hat{p}(x_1, \dots, x_n) = 1 - F_T^0(\phi(x_1, \dots, x_n));$$

当 T 为双侧检验统计量时, 有

$$\hat{p}(x_1, \dots, x_n) = 2 \min \{F_T^0(\phi(x_1, \dots, x_n)), 1 - F_T^0(\phi(x_1, \dots, x_n))\}.$$

2. 利用习题 4.2 的结论证明: 随机变量 $\hat{p}(X_1, \dots, X_n)$ 在 H_0 成立时服从 $]0, 1[$ 上的均匀分布.

注: 本题的结论可以进一步推广, 见附录 C.2 中的定理 C.3.

3. 根据统计量的定义, 可知 $1 - \hat{p}(X_1, \dots, X_n)$ 是一个统计量. 证明: 无论 T 是单侧还是双侧检验统计量, 若将 $1 - \hat{p}(X_1, \dots, X_n)$ 作为单侧检验统计量, 则用它进行假设检验的结果与用 T 进行假设检验的结果相同.

习题 9.3. 设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中 σ^2 已知而 μ 未知. 考虑如下假设检验问题:

$$H_0: \mu = \mu_0, \quad H_1: \mu < \mu_0,$$

其中 μ_0 为一给定的实数. 令 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ 为单侧检验统计量, α 为显著性水平 (注意此时拒绝域的形式为 $z < -z_\alpha$).

1. 试求功效函数 $w(\mu)$.
2. 若希望 $\mu \leq \mu_0 - \delta$ 时的第 II 类错误概率小于等于 β , 其中 $\delta > 0$ 与 $\beta \in]0, 1[$ 给定, 试求样本容量 n 应当满足的条件.

习题 9.4. 1. 证明: 若 $X \sim t(n)$, 则 $X^2 \sim F(1, n)$.

2. 设总体服从正态分布 $\mathcal{N}(\mu, \sigma^2)$, 其中期望 μ 与方差 σ^2 均未知. 考虑如下假设检验问题:

$$H_0: \mu = \mu_0, \quad H_1: \mu \neq \mu_0.$$

试设计一个服从 F 分布的检验统计量, 用于对上述假设检验问题进行单侧检验, 并给出显著性水平为 α 时的拒绝域.

习题 9.5. 一家医疗机构从某工厂的工人中随机抽取了 25 名女工, 并测量了她们的体温、心率、血压等生理指标. 其中这 25 名女工的体温数据列举如下 (单位: 摄氏度): 36.2, 36.3, 36.4, 36.5, 36.6, 36.6, 36.7, 36.7, 36.7, 36.7, 36.8, 36.8, 36.8, 36.9, 36.9, 36.9, 36.9, 37.0, 37.0, 37.0, 37.1, 37.1, 37.2, 37.2, 37.2. 设该工厂女工的体温服从期望为 μ 的正态分布. 试对假设 $H_0: \mu = 37.0$, $H_1: \mu \neq 37.0$ 进行假设检验; 取显著性水平为 5%.

习题 9.6. 某家机构希望对市售方便食品的热量标注是否准确进行调查, 从市场上随机购买了 10 份不同种类的方便食品, 并委托权威实验室对它们的热量值进行了测量, 结果如下表所示 (单位: 千卡):

编号	1	2	3	4	5	6	7	8	9	10
标称热量值	180	220	190	230	200	370	250	240	80	180
实测热量值	212	319	231	306	211	431	288	265	145	228

试对上述数据对应的总体分布做出合理的假设, 并检验市售方便食品热量的标称值是否等于实测值; 取显著性水平为 5%.

习题 9.7. 设随机变量 X 服从参数为 (n, p) 的二项分布, 其中 $n = 19$ 已知而 p 未知. 我们对 X 进行了一次观测, 得到一个观测值 8, 试对

$$H_0 : p = 1/3, \quad H_1 : p \neq 1/3$$

进行假设检验.

习题 9.8. 某家新能源车企通过问卷调查的方式, 询问了 500 名当地居民购买新能源汽车的意愿, 并希望得知当地居民中愿意购买新能源汽车的比例是否超过了五年前的数据 60%. 在将该问题转化为一个假设检验问题并设定了某个显著性水平后, 发现该假设检验问题的拒绝域为 $K > 315$, 其中 K 为 500 名被调查居民中愿意购买新能源汽车的人数.

1. 若真实情况是依然只有 60% 的当地居民愿意购买新能源汽车, 试求此时第 I 类错误的概率.
2. 若真实情况是恰好有 75% 的当地居民愿意购买新能源汽车, 试求此时第 II 类错误的概率.

习题 9.9. 设两个总体分别服从正态分布 $\mathcal{N}(\mu_1, \sigma_1^2)$ 与 $\mathcal{N}(\mu_2, \sigma_2^2)$, 其中 σ_1^2 与 σ_2^2 已知. 考虑如下假设检验问题:

$$H_0 : \mu_1 - \mu_2 = \Delta_0, \quad H_1 : \mu_1 - \mu_2 \neq \Delta_0.$$

设两个总体的样本分别为 $X_{1,1}, \dots, X_{1,n_1}$ 与 $X_{2,1}, \dots, X_{2,n_2}$, 取检验统计量为

$$Z = \frac{\bar{X}_1 - \bar{X}_2 - \Delta_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}.$$

1. 试求功效函数 $w(\mu_1, \mu_2)$.
2. 若希望 $|\mu_1 - \mu_2 - \Delta_0| > \delta$ 时的第 II 类错误概率小于等于 β , 其中 $\delta > 0$ 与 $\beta \in]0, 1[$ 给定, 并假定 $n_1 = n_2$, 试求两个样本的样本容量应当满足的条件.

习题 9.10. 一研究机构开发了一种新的用于训练深度神经网络的专用芯片, 并希望它在某个测试样例上的训练时间较另一种商用芯片至少缩短一半, 故考虑如下形式的假设检验问题:

$$H_0 : \mu_1 = 2\mu_2, \quad H_1 : \mu_1 > 2\mu_2,$$

其中 μ_1 表示商用芯片在测试样例上训练时间的期望, 而 μ_2 表示新芯片在测试样例上训练时间的期望. 设两个总体均服从正态分布, 且各自的方差 σ_1^2 与 σ_2^2 均已知. 若用 $X_{1,1}, \dots, X_{1,n_1}$ 表示商用芯片测试 n_1 次的试验结果, $X_{2,1}, \dots, X_{2,n_2}$ 表示新芯片测试 n_2 次的试验结果, 试推导上述假设检验问题的 p 值与拒绝域表达式.

习题 9.11. 某家轮胎厂需要从两家橡胶厂中选择一家采购原料, 故从两家橡胶厂各自获取了 25 个样品, 并测试它们在经过一千次高速摩擦后的损耗. 对于橡胶厂 A, 其 25 个样品的平均损耗为 20.3 毫克/千次, 标准差为 1.9 毫克/千次, 而对于橡胶厂 B, 其 25 个样品的平均损耗为 18.5 毫克/千次, 标准差为 2.3 毫克/千次. 设两家橡胶厂产品的损耗都服从正态分布, 它们的期望与方差均未知, 但已知它们的方差相等.

1. 试检验两家橡胶厂产品的平均损耗是否相同, 并计算该检验的 p 值; 取显著性水平为 5%.
2. 试检验橡胶厂 A 产品的平均损耗是否大于橡胶厂 B; 取显著性水平为 5%.

习题 9.12. 某实验室对两个品牌的干电池进行了测试, 下表给出了两个品牌各 9 个样品在实验环境下电压从 1.5V 下降到 0.8V 所需要的时间 (以下将该量简称为“寿命”, 单位为小时):

品牌 A	8.65	8.74	8.91	8.72	8.85	8.52	8.62	8.68	8.86
品牌 B	8.76	8.81	8.81	8.70	8.73	8.76	8.68	8.64	8.79

已知两个品牌干电池的寿命均服从正态分布. 试检验两个品牌干电池寿命的方差是否相同; 取显著性水平为 0.05.

习题 9.13. 某医学院课题组对阿斯匹林用于结直肠癌患者的药效进行了研究, 共调查了 1279 名结直肠癌患者, 其中 549 名患者在确诊后定期服用阿斯匹林, 在这 549 名患者中最终有 81 名因结直肠癌死亡; 另 730 名患者在确诊后未服用过阿斯匹林, 这 730 名患者中最终有 141 名因结直肠癌死亡. 试检验定期服用阿斯匹林是否能够降低结直肠癌患者的死亡率; 取显著性水平为 5%, 并算出 p 值.

习题 9.14. Benford 定律称, 在一个由真实世界的某类数据构成的大数据集中, 以 n 为首位数字的数出现的概率约为

$$p_0(n) = \log_{10} \left(1 + \frac{1}{n} \right), \quad n = 1, 2, \dots, 9.$$

下表给出了某份数据集中以 n 为首位数字的数出现的频数:

首位数字	1	2	3	4	5	6	7	8	9
频数	342	180	164	155	86	65	54	47	56

试检验该数据集是否服从 Benford 定律.

注: 本题数据取自 [33].

习题 9.15 (p -hacking). 设 A 在一项研究工作中需要验证课题组提出的新方法是否起效, 故设计了实验流程并考虑用配对 t 检验方法对

$$H_0: \text{新方法无效}, \quad H_1: \text{新方法有效}$$

进行检验, 但一次实验之后发现得到的 p 值大于 0.05. 由于领域内顶刊只发表 p 值小于 0.05 的实验结果, 迫于压力, A 决定采取如下策略: 不断重复该实验, 直到某次实验给出的 p 值小于 0.05 或是实验次数达到 M , 其中 M 为一个大于 1 的正整数. 若最终得到的 p 值小于 0.05 则将该次实验数据保留并整理成论文投稿, 而若 M 次实验的 p 值均大于等于 0.05, 则将这几次实验中最小的 p 值在课题组组会上进行汇报并讨论新方法的改进. 设各次实验相互独立, 每次计算 p 值时均只采用当次实验的数据.

1. 考虑单次实验, 用 $\hat{P}$ 表示其 p 值并将其看成一个随机变量 (其随机性来自于样本的随机性). 则在原假设 H_0 下, $\hat{P}$ 服从怎样的分布?
2. 用随机变量 $\hat{P}_M$ 表示 A 按照上述策略最终获得的 p 值. 若原假设 H_0 成立 (也就是说新方法是无效的), 则 $\hat{P}_M$ 服从怎样的分布 (给出其分布函数)? A 按照上述策略最终能够获得 $\hat{P}_M < 0.05$ 的实验结果的概率是多少?
3. A 最终获得了 $\hat{P}_M < 0.05$ 的实验结果并将成果发表在了领域内顶刊上, 但遭到了同行质疑, 经过调查后 A 承认了上述 p -hacking 的行为. 某同行 B 希望基于 A 公开发表的实验数据算出一个合理的 p 值, 故考虑用一个因子 $c > 1$ 与 $\hat{P}_M$ 相乘来进行修正. 试求出一个 c 值使得

$$\mathbb{P}_{H_0}(c\hat{P}_M < \alpha) \leq \alpha, \quad \forall \alpha \in]0, 1[$$

成立.

第十章 一元线性回归

10.1 一元线性回归模型

本章当中, 我们将对**线性回归** (linear regression) 进行简单的介绍. 与前几章不同的是, 在线性回归以及更一般的回归分析问题中, 我们不再只关注单个变量的概率分布情况, 而是考虑两个或多个取值连续的变量并考察它们的依赖关系. 具体而言, 我们认为这些具有依赖关系的取值连续的变量由一些确定性的变量 $x^{(1)}, \dots, x^{(d)}$ 与一些随机变量 $Y^{(1)}, \dots, Y^{(l)}$ 给出, 其中

- $x^{(1)}, \dots, x^{(d)}$ 看成自变量 (independent variable). $x^{(1)}, \dots, x^{(d)}$ 的其它名称还包括 regressors, exogenous variables, explanatory variables, covariates, input variables, predictor variables 等.
- $Y^{(1)}, \dots, Y^{(l)}$ 看成是带有随机因素的因变量 (dependent variable), 其 (联合) 概率分布的具体形式取决于 $x^{(1)}, \dots, x^{(d)}$ 的值. $Y^{(1)}, \dots, Y^{(l)}$ 的其它名称还包括 regressands, endogenous variables, response variables, output variables 等.

而回归分析的基本任务, 就是通过收集样本数据, 对 $(Y^{(1)}, \dots, Y^{(l)})$ 的分布以何种方式依赖于 $x^{(1)}, \dots, x^{(d)}$ 的取值进行推断; 或者说, 我们希望考察, 当把 $(Y^{(1)}, \dots, Y^{(l)})$ 的分布与 $x^{(1)}, \dots, x^{(d)}$ 的取值的关系用某种统计模型进行建模以后, 这个统计模型能否与收集到的样本数据相吻合.

在本章中, 我们主要考察自变量 x 与因变量 Y 均为一维变量 (也就是一元回归) 的情形. 我们假定样本由成对数据

$$(x_1, Y_1), \dots, (x_n, Y_n)$$

给出, 其中每个 x_i 均为确定性的量, 而 Y_i 则与自变量取值为 x_i 时的因变量 Y 同分布, 且 $Y_1, Y_2, \dots, Y_n$ 之间相互独立. 通常, 我们不会让 $x_1, \dots, x_n$ 都等于同一个值, 否则我

们只能推断 x 等于单个值时 Y 的分布信息, 而无法推断 x 变动时 Y 的分布对 x 的依赖关系.

在一元线性回归分析中, 我们将自变量 x 与因变量 Y 之间的依赖关系用如下方式进行建模:

$$Y = \beta_0 + \beta_1 x + \varepsilon, \quad (10.1a)$$

其中 ε 服从期望为 0、方差为 $\sigma^2 > 0$ 的某个分布, 且该分布与 x 的取值无关. β_0, β_1 被称为**回归系数** (regression coefficient), 它们与方差 σ^2 均为未知的参数. 函数 $\mu(x) = \beta_0 + \beta_1 x$ 则被称为**回归函数**, 有时也会用符号 $\mathbb{E}[Y|x]$ 来表示它. 我们通常把 ε 看作对 $\beta_0 + \beta_1 x$ 进行观测时产生的随机误差. 对于样本 $(x_1, Y_1), \dots, (x_n, Y_n)$, 则有

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad (10.1b)$$

其中随机误差 $\varepsilon_1, \dots, \varepsilon_n$ 独立同分布且期望为 0、方差为 σ^2 . 式 (10.1) 给出了一种用于描述 x 与 Y 之间依赖关系的统计模型, 我们将其称为一元线性回归模型.

注 10.1. 需要指出的是, 一元线性回归模型中的“一元”指的是自变量的维数为 1, 而“线性”则是指 $\mu(x) = \mathbb{E}[Y|x]$ 关于回归系数 β_0, β_1 是线性的. 例如, 若 x 与 Y 之间的关系由如下式子给出:

$$Y = \beta_0 + \beta_1 \phi(x) + \varepsilon,$$

其中 $\phi: \mathbb{R} \rightarrow \mathbb{R}$ 为任意函数, 那么我们依然可以把它作为一元线性回归模型进行处理, 这是因为只需令 $t = \phi(x)$ 即可将模型化为 (10.1) 的形式, 随后直接套用一元线性回归模型的理论与方法即可. ■

对于一元线性回归模型, 我们可以提出如下几类问题:

- 若线性回归模型 (10.1) 很好地描述了 x 与 Y 之间的依赖关系, 则应当如何对未知参数 β_0, β_1 与 σ^2 进行点估计、区间估计与假设检验?
- 给定一个新的自变量的值 x_0 , 如何基于线性回归模型 (10.1) 与获得的样本, 对 $x = x_0$ 时 Y 的取值进行预测?
- 如何判断线性回归模型 (10.1) 能否足够好地解释观测数据?

在接下来的几节, 我们将对前两类问题给出解答, 而对第三类问题只作简要介绍.

10.2 未知参数的点估计

10.2.1 系数 β_0 与 β_1 的点估计

最小二乘估计 (least squares estimation, LSE) 是对线性回归模型 (10.1) 中的未知参数 β_0, β_1 进行点估计的经典方法. 在最小二乘估计中, 我们考虑如下最优化问题:

$$\min_{\beta_0, \beta_1} \frac{1}{2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2, \quad (10.2)$$

在求解 (10.2) 时我们把各个 Y_i 看作定值, 则求得的最优解可看作 $Y_1, \dots, Y_n$ 的函数. 我们将 (10.2) 的最优解记为 $\hat{\beta}_0$ 与 $\hat{\beta}_1$, 它们就是 β_0 与 β_1 的**最小二乘点估计量**. 我们先介绍如何求解最优化问题 (10.2), 再对 (10.2) 给出的点估计的合理性进行解释.

首先注意到, 最优化问题 (10.2) 中对 β_0 与 β_1 的取值未做出其它约束, 故可以考虑对目标函数

$$S(\beta_0, \beta_1) = \frac{1}{2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2$$

求偏导得到驻点, 再验证驻点是否是最小值点. $S(\beta_0, \beta_1)$ 的偏导数由

$$\begin{aligned} \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} &= - \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i), \\ \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} &= - \sum_{i=1}^n x_i (Y_i - \beta_0 - \beta_1 x_i) \end{aligned}$$

给出, 而 $S(\beta_0, \beta_1)$ 的海塞矩阵 (Hessian matrix) 则为

$$\mathbf{H}(\beta_0, \beta_1) = \begin{bmatrix} \frac{\partial^2 S(\beta_0, \beta_1)}{\partial \beta_0^2} & \frac{\partial^2 S(\beta_0, \beta_1)}{\partial \beta_0 \partial \beta_1} \\ \frac{\partial^2 S(\beta_0, \beta_1)}{\partial \beta_1 \partial \beta_0} & \frac{\partial^2 S(\beta_0, \beta_1)}{\partial \beta_1^2} \end{bmatrix} = \begin{bmatrix} n & n\bar{x} \\ n\bar{x} & \sum_{i=1}^n x_i^2 \end{bmatrix}$$

而由于 $x_1, \dots, x_n$ 不都等于同一个值, 故

$$\det \mathbf{H}(\beta_0, \beta_1) = n \sum_{i=1}^n x_i^2 - n^2 \bar{x}^2 = n \sum_{i=1}^n (x_i - \bar{x})^2 > 0,$$

再注意到 $\mathbf{H}(\beta_0, \beta_1)$ 的两个对角元均为正数, 可得 $\mathbf{H}(\beta_0, \beta_1)$ 为正定矩阵, 因此 $S(\beta_0, \beta_1)$ 是一个强凸的可微函数, 由多元微积分知识可知, $S(\beta_0, \beta_1)$ 仅存在唯一一个驻点, 且该

驻点就是它的最小值点. 由此可得最优化问题 (10.2) 的最优解满足方程组

$$\begin{aligned} n\hat{\beta}_0 + \left(\sum_{i=1}^n x_i\right) \hat{\beta}_1 &= \sum_{i=1}^n Y_i, \\ \left(\sum_{i=1}^n x_i\right) \hat{\beta}_0 + \left(\sum_{i=1}^n x_i^2\right) \hat{\beta}_1 &= \sum_{i=1}^n x_i Y_i, \end{aligned} \quad (10.3)$$

该方程组也被称为 normal equations¹. 解 normal equations 可得

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}, \quad (10.4a)$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i Y_i - n\bar{x} \cdot \bar{Y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (10.4b)$$

其中我们记

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

式 (10.4) 给出的 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 即为 β_0 与 β_1 的最小二乘估计量. 习惯上, 我们还会引入如下记号:

$$\begin{aligned} S_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2, \\ S_{xY} &= \sum_{i=1}^n (x_i - \bar{x}) Y_i = \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y}), \end{aligned} \quad (10.5)$$

则 $\hat{\beta}_1$ 可表示为

$$\hat{\beta}_1 = \frac{S_{xY}}{S_{xx}}.$$

值得注意的是, $\hat{\beta}_1$ 与 $\hat{\beta}_0$ 均可看成 $Y_1, \dots, Y_n$ 的线性函数. 在得到回归系数的点估计值以后, 我们可以进一步对回归函数在任意 x 处的取值进行点估计:

$$\hat{\mu}(x) = \hat{\beta}_0 + \hat{\beta}_1 x = \bar{Y} + \hat{\beta}_1 (x - \bar{x}).$$

特别地, 我们记

$$\hat{Y}_i = \hat{\mu}(x_i) = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad i = 1, \dots, n.$$

此外, 我们将

$$e_i = Y_i - \hat{Y}_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

称为第 i 个残差 (residual).

接下来, 我们对最小二乘估计的合理性进行解释.

¹ 许多地方把 normal equations 译为“正规方程组”, 但笔者认为这个翻译可能欠妥, 这是因为通常会把 normal equations 中的 normal 理解为法向或正交的意思, 故“法方程组”可能是一个更合适的译名; 感兴趣的读者可参阅注 10.2 的进一步解释. 不过 normal equations 这个名称的提出者 Gauss 却并未解释为何采用这个名称.

最小二乘估计作为最大似然估计. 在一开始的线性回归模型 (10.1) 中, 我们并未指定随机误差 ε 的分布具有怎样的形式, 而只是限定其期望为 0 且方差有限. 而在许多场合下, 为了方便用概率论工具对最小二乘估计进行定量研究, 我们会进一步假定 ε 服从正态分布 $\mathcal{N}(0, \sigma^2)$, 此时可以证明, 最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1$ 也是 β_0, β_1 的最大似然估计: 注意到 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 时, 有 $Y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$, 故 $(Y_1, \dots, Y_n)$ 的联合概率密度函数为

$$f(\mathbf{y}; \beta_0, \beta_1, \sigma^2, \mathbf{x}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right),$$

其中记 $\mathbf{x} = (x_1, \dots, x_n)$, $\mathbf{y} = (y_1, \dots, y_n)$. 而将 $f(\mathbf{y}; \beta_0, \beta_1, \sigma^2, \mathbf{x})$ 当中的 $\mathbf{x}$ 与 $\mathbf{y}$ 固定, 并把未知参数 $\beta_0, \beta_1, \sigma^2$ 作为自变量, 即可得到似然函数 $L(\beta_0, \beta_1, \sigma^2; \mathbf{x}, \mathbf{y})$. 相应的对数似然函数为

$$\ln L(\beta_0, \beta_1, \sigma^2; \mathbf{x}, \mathbf{y}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 - \frac{n}{2} \ln(2\pi\sigma^2), \quad (10.6)$$

而关于 β_0 与 β_1 的对数似然方程则为

$$\begin{aligned} 0 &= \frac{\partial \ln L(\beta_0, \beta_1, \sigma^2; \mathbf{x}, \mathbf{y})}{\partial \beta_0} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i), \\ 0 &= \frac{\partial \ln L(\beta_0, \beta_1, \sigma^2; \mathbf{x}, \mathbf{y})}{\partial \beta_1} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i). \end{aligned}$$

立刻可看出上述方程组与 normal equations (10.3) 具有相同的形式. 由此可得如下结论: 当随机误差 ε 服从正态分布 $\mathcal{N}(0, \sigma^2)$ 时, β_0 与 β_1 的最大似然估计量就是最小二乘估计量.

(*) **最小二乘估计作为最佳无偏线性估计.** 我们还可以从最佳无偏线性估计的角度解释最小二乘估计的合理性. 设 $(x_1, Y_1), \dots, (x_n, Y_n)$ 为一组样本, 考虑 β_0 与 β_1 的关于 $Y_1, \dots, Y_n$ 具有线性形式的点估计量:

$$\hat{\beta}_1 = \sum_{i=1}^n a_i Y_i, \quad \hat{\beta}_0 = \sum_{i=1}^n b_i Y_i,$$

其中 $a_1, \dots, a_n$ 与 $b_1, \dots, b_n$ 为待定系数, 且要求它们具有无偏性. 我们希望在线性与无偏性的约束下, 找到使得均方误差

$$\text{MSE}_{\beta_1}(\hat{\beta}_1) = \mathbb{E}\left[(\hat{\beta}_1 - \beta_1)^2\right] \quad \text{与} \quad \text{MSE}_{\beta_0}(\hat{\beta}_0) = \mathbb{E}\left[(\hat{\beta}_0 - \beta_0)^2\right]$$

对任意的 β_0, β_1 与 $\sigma^2 > 0$ 均能取到最小值的系数 $a_1, \dots, a_n$ 与 $b_1, \dots, b_n$. 为了后面推导的方便, 我们罗列如下事实:

1. $Y_1, \dots, Y_n$ 相互独立.
2. $\mathbb{E}[Y_i] = \beta_0 + \beta_1 x_i, \text{Var}(Y_i) = \sigma^2$.

首先考虑 β_1 的最佳无偏线性估计. $\hat{\beta}_1 = \sum_{i=1}^n a_i Y_i$ 的无偏性要求

$$\beta_1 = \mathbb{E} \left[\sum_{i=1}^n a_i Y_i \right] = \beta_0 \cdot \sum_{i=1}^n a_i + \beta_1 \cdot \sum_{i=1}^n a_i x_i, \quad \forall \beta_0, \beta_1$$

由 β_0 与 β_1 的任意性, 可得到

$$\sum_{i=1}^n a_i = 0, \quad \sum_{i=1}^n a_i x_i = 1.$$

接下来我们将均方误差 $\text{MSE}_{\beta_1}(\hat{\beta}_1)$ 进行展开, 并注意到 $\hat{\beta}_1$ 的无偏性, 可得

$$\begin{aligned} \text{MSE}_{\beta_1}(\hat{\beta}_1) &= \text{Var}(\hat{\beta}_1) = \text{Var} \left(\sum_{i=1}^n a_i Y_i \right) \\ &= \sum_{i=1}^n a_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n a_i^2. \end{aligned}$$

因此 β_1 的最佳线性无偏估计的系数 $a_1, \dots, a_n$ 为如下带约束最优化问题的解:

$$\min_{a_1, \dots, a_n} \frac{1}{2} \sum_{i=1}^n a_i^2 \quad \text{s.t.} \quad \sum_{i=1}^n a_i = 0, \quad \sum_{i=1}^n a_i x_i = 1.$$

上述问题是一个典型的凸优化问题, 可以用拉格朗日乘子法求出最优解: 该问题的拉格朗日函数为

$$\mathcal{L}(a_1, \dots, a_n, \mu, \lambda) = \frac{1}{2} \sum_{i=1}^n a_i^2 + \mu \sum_{i=1}^n a_i + \lambda \left(\sum_{i=1}^n a_i x_i - 1 \right).$$

故最优性条件为

$$\begin{aligned} 0 &= \frac{\partial \mathcal{L}(a_1, \dots, a_n, \mu, \lambda)}{\partial a_i} = a_i + \mu + \lambda x_i, \\ 0 &= \sum_{i=1}^n a_i, \quad 0 = \sum_{i=1}^n a_i x_i - 1. \end{aligned}$$

上述方程组的解为

$$a_i = \frac{x_i - \bar{x}}{\sum_j x_j^2 - n\bar{x}^2}, \quad \mu = \frac{\bar{x}}{\sum_j x_j^2 - n\bar{x}^2}, \quad \lambda = -\frac{1}{\sum_j x_j^2 - n\bar{x}^2}.$$

不难发现由上述系数 $a_1, \dots, a_n$ 给出的线性估计量就是 β_1 的最小二乘估计量. 同理可证明 β_0 的最佳线性估计量就是最小二乘估计量, 相关的计算与验证过程交给读者完成.




图 10.1: Normal equations 几何直观示意图.

注 10.2. (*) Normal equations (10.3) 有非常直观的几何解释. 设 $(x_1, Y_1), \dots, (x_n, Y_n)$ 为一组样本, 仍将 $Y_1, \dots, Y_n$ 看作是定值, 则 $\mathbf{Y} = (Y_1, \dots, Y_n)$ 可看作 $\mathbb{R}^n$ 当中的一个点或一个向量. 记 $\mathbf{x} = (x_1, \dots, x_n)$, 并用 $\mathbf{1}$ 表示分量均为 1 的 n 维向量. 令

$$V = \{\beta_0 \mathbf{1} + \beta_1 \mathbf{x} \mid \beta_0, \beta_1 \in \mathbb{R}\},$$

则当 $\mathbf{x}$ 的元素不全相等时, V 构成了 $\mathbb{R}^n$ 的一个二维子空间, 而最优化问题 (10.2) 则可以等价表示为

$$\min_{\mathbf{z} \in V} \frac{1}{2} \|\mathbf{Y} - \mathbf{z}\|^2,$$

其中 $\|\cdot\|$ 表示欧氏空间 $\mathbb{R}^n$ 当中的标准 ℓ_2 范数. 换句话说, 求解 β_0 与 β_1 的最小二乘估计量, 等价于在子空间 V 中找到一个点 (我们将其记为 $\hat{\mathbf{Y}}$) 使得它与 $\mathbf{Y}$ 的距离最小. 由欧氏空间的几何关系, 不难理解这个与 $\mathbf{Y}$ 的距离最小的点 $\hat{\mathbf{Y}}$ 应当使得 $\mathbf{Y} - \hat{\mathbf{Y}}$ 与二维子空间 V 正交 (见图 10.1). 由于 $\{\mathbf{1}, \mathbf{x}\}$ 是子空间 V 的一组基, 可知 $\mathbf{Y} - \hat{\mathbf{Y}}$ 与 V 正交当且仅当 $\mathbf{Y} - \hat{\mathbf{Y}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}$ 均正交, 即

$$\begin{aligned} 0 &= \mathbf{1}^\top (\mathbf{Y} - \hat{\mathbf{Y}}), \\ 0 &= \mathbf{x}^\top (\mathbf{Y} - \hat{\mathbf{Y}}). \end{aligned}$$

将 $\hat{\mathbf{Y}} = \hat{\beta}_0 \mathbf{1} + \hat{\beta}_1 \mathbf{x}$ 代入并进行化简, 可得

$$\begin{aligned} 0 &= \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i), \\ 0 &= \sum_{i=1}^n x_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i), \end{aligned}$$

上述方程组正是 normal equations. ■

10.2.2 最小二乘估计的偏差与均方误差

本小节中, 我们对 β_0 与 β_1 的最小二乘估计的偏差与均方误差进行分析. 设自变量 x 与因变量 Y 之间的确服从 (10.1) 给出的线性回归模型. 注意到 $\mathbb{E}[Y_i] = \beta_0 + \beta_1 x_i$, 可得

$$\begin{aligned}\mathbb{E}[\hat{\beta}_1] &= \mathbb{E}\left[\sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i\right] \\ &= \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} (\beta_0 + \beta_1 x_i) \\ &= \frac{\beta_0}{S_{xx}} \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} + \frac{\beta_1}{S_{xx}} \sum_{i=1}^n (x_i^2 - x_i \bar{x}) \\ &= \frac{\beta_1}{S_{xx}} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \beta_1,\end{aligned}$$

其中利用了 $\sum_{i=1}^n (x_i - \bar{x}) = 0$, 故 $\hat{\beta}_1$ 是 β_1 的一个无偏估计量. $\hat{\beta}_1$ 的均方误差也就等于其方差, 为

$$\begin{aligned}\text{Var}(\hat{\beta}_1) &= \text{Var}\left(\sum_{i=1}^n \frac{(x_i - \bar{x})Y_i}{S_{xx}}\right) \\ &= \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{S_{xx}^2} \text{Var}(Y_i) \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{S_{xx}^2} \cdot \sigma^2 = \frac{\sigma^2}{S_{xx}}.\end{aligned}$$

对于 $\hat{\beta}_0$ 则有

$$\mathbb{E}[\hat{\beta}_0] = \mathbb{E}[\bar{Y} - \hat{\beta}_1 \bar{x}] = (\beta_0 + \beta_1 \bar{x}) - \beta_1 \bar{x} = \beta_0,$$

其中利用了 $\mathbb{E}[\bar{Y}] = \beta_0 + \beta_1 \bar{x}$ 以及 $\hat{\beta}_1$ 的无偏性, 故可得 $\hat{\beta}_0$ 是无偏的. 而 $\hat{\beta}_0$ 的均方误差也就等于其方差, 为

$$\begin{aligned}\text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{Y} - \hat{\beta}_1 \bar{x}) \\ &= \text{Var}\left(\sum_{i=1}^n \left(\frac{1}{n} - \frac{x_i - \bar{x}}{S_{xx}} \bar{x}\right) Y_i\right) \\ &= \sum_{i=1}^n \left(\frac{1}{n} - \frac{x_i - \bar{x}}{S_{xx}} \bar{x}\right)^2 \text{Var}(Y_i) \\ &= \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} - \frac{x_i - \bar{x}}{S_{xx}} \bar{x}\right)^2,\end{aligned}$$

而

$$\begin{aligned}\sum_{i=1}^n \left(\frac{1}{n} - \frac{x_i - \bar{x}}{S_{xx}} \bar{x} \right)^2 &= \sum_{i=1}^n \left(\frac{1}{n^2} + \frac{\bar{x}^2}{S_{xx}^2} (x_i - \bar{x})^2 - \frac{2\bar{x}}{n} (x_i - \bar{x}) \right) \\ &= \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})^2 - \frac{2\bar{x}}{n} \sum_{i=1}^n (x_i - \bar{x}) \\ &= \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}},\end{aligned}$$

故

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right).$$

最后, 我们对 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 的协方差进行计算:

$$\begin{aligned}\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) &= \text{Cov}(\bar{Y} - \hat{\beta}_1 \bar{x}, \hat{\beta}_1) \\ &= \text{Cov}\left(\frac{1}{n} \sum_{i=1}^n Y_i, \frac{1}{S_{xx}} \sum_{j=1}^n (x_j - \bar{x}) Y_j\right) - \text{Var}(\hat{\beta}_1) \cdot \bar{x} \\ &= \frac{1}{n S_{xx}} \sum_{i,j=1}^n (x_j - \bar{x}) \text{Cov}(Y_i, Y_j) - \frac{\sigma^2 \bar{x}}{S_{xx}} \\ &= \frac{1}{n S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \sigma^2 - \frac{\sigma^2 \bar{x}}{S_{xx}} \\ &= -\frac{\sigma^2 \bar{x}}{S_{xx}},\end{aligned}$$

其中倒数第二步是由于 $Y_1, \dots, Y_n$ 相互独立且 $\text{Var}(Y_i) = \sigma^2$.

需要指出, 上述推导均不需要假定 $\varepsilon_1, \dots, \varepsilon_n$ 服从正态分布.

10.2.3 方差 σ^2 的点估计

为了对线性回归模型 (10.1) 中随机误差 ε 的方差 σ^2 进行估计, 我们注意到, 若估计量 $\hat{\beta}_0, \hat{\beta}_1$ 的值与 β_0, β_1 的真值非常接近, 则直观上可以认为

$$\begin{aligned}\varepsilon_i &= Y_i - \beta_0 - \beta_1 x_i \\ &\approx Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = e_i.\end{aligned}$$

注意到随机误差 ε_i 不可观测但 e_i 是一个可观测的统计量, 这提示着我们残差 e_i 在对 σ^2 的估计中将起到关键作用. 不难看出 e_i 的期望为 0, 而为了计算 e_i 的方差, 我们注意

到

$$\begin{aligned}
 e_i &= Y_i - (\bar{Y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i = Y_i - \bar{Y} - \hat{\beta}_1 (x_i - \bar{x}) \\
 &= Y_i - \frac{1}{n} \sum_{j=1}^n Y_j - \frac{x_i - \bar{x}}{S_{xx}} \sum_{j=1}^n (x_j - \bar{x}) Y_j \\
 &= \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}\right) Y_i - \sum_{j \neq i} \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}\right) Y_j,
 \end{aligned}$$

而由于 $Y_1, \dots, Y_n$ 之间相互独立, 故

$$\begin{aligned}
 \text{Var}(e_i) &= \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}\right)^2 \text{Var}(Y_i) + \sum_{j \neq i} \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}\right)^2 \text{Var}(Y_j) \\
 &= \left[1 + \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}\right)^2 - 2\left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}\right)\right] \sigma^2 \\
 &\quad + \sum_{j \neq i} \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}\right)^2 \sigma^2 \\
 &= \sigma^2 \left[1 - 2\left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}\right) + \sum_{j=1}^n \left(\frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}\right)^2\right] \\
 &= \sigma^2 \left[1 - \frac{2}{n} - \frac{2(x_i - \bar{x})^2}{S_{xx}} + \sum_{j=1}^n \left(\frac{1}{n^2} + \frac{(x_i - \bar{x})^2(x_j - \bar{x})^2}{S_{xx}^2} + \frac{2(x_i - \bar{x})(x_j - \bar{x})}{nS_{xx}}\right)\right] \\
 &= \sigma^2 \left[1 - \frac{2}{n} - \frac{2(x_i - \bar{x})^2}{S_{xx}} + \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}^2} \sum_{j=1}^n (x_j - \bar{x})^2 + \frac{2(x_i - \bar{x})}{nS_{xx}} \sum_{j=1}^n (x_j - \bar{x})\right] \\
 &= \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}\right),
 \end{aligned}$$

其中最后一步利用了 $\sum_{j=1}^n (x_j - \bar{x})^2 = S_{xx}$ 以及 $\sum_{j=1}^n (x_j - \bar{x}) = 0$. 接下来, 我们令

$$SS_{\text{Res}} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n e_i^2, \quad (10.7)$$

并将其称为**残差平方和** (residual sum of squares), 则有

$$\mathbb{E}[SS_{\text{Res}}] = \sum_{i=1}^n \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}\right) = (n-2)\sigma^2.$$

由此可得 σ^2 的一个无偏估计量为

$$\hat{\sigma}^2 = \frac{1}{n-2} SS_{\text{Res}} = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2. \quad (10.8)$$

残差平方和 SS_{Res} 的一个更加便于计算的表达式为

$$SS_{\text{Res}} = SS_{\text{T}} - \hat{\beta}_1 S_{xY}, \quad \text{其中 } SS_{\text{T}} = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad (10.9)$$

SS_T 被称为**校正平方和** (corrected sum of squares). 我们将上式的证明留作习题.

需要说明的是, $\hat{\sigma}^2$ 的无偏性并不需要假定 ε 服从正态分布.

10.3 回归系数的区间估计与假设检验

在本节中, 我们均假设自变量 x 与因变量 Y 之间的确服从 (10.1) 给出的线性回归模型. 此外, 还假设随机误差 ε 服从正态分布 $\mathcal{N}(0, \sigma^2)$, 此时即有

$$Y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2).$$

首先引入如下引理:

引理 10.1. 设线性回归模型 (10.1) 中的随机误差 ε 服从正态分布 $\mathcal{N}(0, \sigma^2)$, 并令 $\hat{\sigma}^2$ 为式 (10.8) 给出的 σ^2 的点估计量. 则

1. $\hat{\sigma}^2$ 与 $\hat{\beta}_1$ 相互独立, 且 $\hat{\sigma}^2$ 也与 $\hat{\beta}_0$ 相互独立.
2. $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-2)$.

引理 10.1 的证明将放在第 10.3.4 节作为选读内容. 但引理中 χ^2 分布的自由度 $n-2$ 可由前面 $\mathbb{E}[SS_{\text{Res}}]$ 的计算结果猜出一二.

10.3.1 β_1 的区间估计以及假设检验

首先考虑 β_1 的置信区间与假设检验. 注意到

$$\hat{\beta}_1 = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) Y_i$$

可表示为相互独立的正态分布随机变量 $Y_1, \dots, Y_n$ 的线性组合, 故 $\hat{\beta}_1$ 也服从正态分布, 其期望为 β_1 , 而方差即为 σ^2/S_{xx} , 也就是说

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right),$$

而引理 10.1 则保证了 $(n-2)\hat{\sigma}^2/\sigma^2$ 服从 $\chi^2(n-2)$ 且与 $\hat{\beta}_1$ 独立. 因而

$$\frac{(\hat{\beta}_1 - \beta_1)/\sqrt{\sigma^2/S_{xx}}}{\sqrt{\hat{\sigma}^2/\sigma^2}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2/S_{xx}}}$$

必定服从自由度为 $n-2$ 的 t 分布, 且与 β_0, β_1 以及 σ^2 的取值无关. 接下来我们依次处理 β 的置信区间与假设检验问题:

1. 设置信水平取为 $1-\alpha$. 由于 $(\hat{\beta}_1 - \beta_1)/\sqrt{\hat{\sigma}^2/S_{xx}} \sim t(n-2)$ 对 β_0, β_1 与 σ^2 的所有可能取值均成立, 故可将其作为枢轴量, 得

$$\mathbb{P}\left(\left|\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2/S_{xx}}}\right| \leq t_{\alpha/2}(n-2)\right) = 1 - \alpha,$$

对上式中括号内的不等式进行等价变形, 可得

$$\mathbb{P}\left(\left[\hat{\beta}_1 - t_{\alpha/2}(n-2)\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}, \hat{\beta}_1 + t_{\alpha/2}(n-2)\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\right] \ni \beta_1\right) = 1 - \alpha.$$

从而 β_1 的一个置信水平为 $1-\alpha$ 的置信区间为

$$\left[\hat{\beta}_1 - t_{\alpha/2}(n-2)\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}, \hat{\beta}_1 + t_{\alpha/2}(n-2)\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\right].$$

2. 考虑假设检验问题

$$H_0: \beta_1 = \beta_{1,0}, \quad H_1: \beta_1 \neq \beta_{1,0},$$

其中 $\beta_{1,0}$ 为事先取定的常数. 则可以取检验统计量为

$$T = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\hat{\sigma}^2/S_{xx}}},$$

它在原假设 H_0 下服从分布 $t(n-2)$. 故 p 值为²

$$\hat{p} = 2\left(1 - F_{n-2}^t\left(\frac{|\hat{\beta}_1 - \beta_{1,0}|}{\sqrt{\hat{\sigma}^2/S_{xx}}}\right)\right),$$

其中 F_{n-2}^t 表示分布 $t(n-2)$ 的分布函数. 而给定显著性水平 α 后, 相应的拒绝域可由

$$\frac{|\hat{\beta}_1 - \beta_{1,0}|}{\sqrt{\hat{\sigma}^2/S_{xx}}} > t_{\alpha/2}(n-2)$$

给出.

² 为了符号上的简便, 后文中我们经常将一个统计量 (关于 $(x_1, Y_1), \dots, (x_n, Y_n)$ 的函数) 与该统计量在某组样本观测值 $(x_1, y_1), \dots, (x_n, y_n)$ 上的取值用同一个符号表示, 读者需根据上下文确定指代的是前者还是后者.

10.3.2 β_0 的区间估计以及假设检验

接下来考虑 β_0 的区间估计与假设检验. 与 $\hat{\beta}_1$ 的情形类似, 可得

$$\hat{\beta}_0 \sim \mathcal{N}\left(\beta_0, \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right),$$

而引理 10.1 保证了 $(n-2)\hat{\sigma}^2/\sigma^2$ 服从 $\chi^2(n-2)$ 且与 $\hat{\beta}_0$ 独立, 故

$$\frac{(\hat{\beta}_0 - \beta_0)/\sqrt{\sigma^2(1/n + \bar{x}^2/S_{xx})}}{\sqrt{\hat{\sigma}^2/\sigma^2}} = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2(1/n + \bar{x}^2/S_{xx})}}$$

必定服从自由度为 $n-2$ 的 t 分布, 且与 β_0, β_1 以及 σ^2 的取值无关. 仿照 β_1 的置信区间与假设检验过程的推导步骤, 可得到如下结论:

1. β_0 的一个置信水平为 $1-\alpha$ 的置信区间为

$$\left[\hat{\beta}_0 - t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}, \hat{\beta}_0 + t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)} \right].$$

2. 考虑假设检验问题

$$H_0: \beta_0 = \beta_{0,0}, \quad H_1: \beta_0 \neq \beta_{0,0},$$

其中 $\beta_{0,0}$ 为事先取定的常数. 则可以取检验统计量为

$$T = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}},$$

p 值为

$$\hat{p} = 2 \left(1 - F_{n-2}^t \left(\frac{|\hat{\beta}_0 - \beta_{0,0}|}{\sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} \right) \right),$$

而给定显著性水平 α 后, 相应的拒绝域可由

$$\frac{|\hat{\beta}_0 - \beta_{0,0}|}{\sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} > t_{\alpha/2}(n-2)$$

给出.

10.3.3 回归函数值的区间估计

现今 x_0 为任意实数, 我们考虑对回归函数在 x_0 处的值 $\mu(x_0) = \beta_0 + \beta_1 x_0$ 进行区间估计. 为构造枢轴量, 我们首先注意到 $\hat{\mu}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0$ 是关于 $Y_1, \dots, Y_n$ 的线性函

数, 而 $Y_1, \dots, Y_n$ 相互独立且服从正态分布, 故 $\hat{\mu}(x_0)$ 也服从正态分布, 其期望为

$$\mathbb{E}[\hat{\mu}(x_0)] = \mu(x_0) = \beta_0 + \beta_1 x_0,$$

而方差则为

$$\begin{aligned} \text{Var}(\hat{\mu}(x_0)) &= \text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_0) \\ &= \text{Var}(\hat{\beta}_0) + x_0^2 \text{Var}(\hat{\beta}_1) + 2x_0 \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ &= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) + x_0^2 \cdot \frac{\sigma^2}{S_{xx}} - 2 \frac{x_0 \bar{x}}{S_{xx}} \sigma^2 \\ &= \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right). \end{aligned}$$

根据上述结果, 我们考虑构造如下枢轴量:

$$\frac{\hat{\mu}(x_0) - \mu(x_0)}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}}.$$

不难基于引理 10.1 验证该枢轴量服从分布 $t(n-2)$, 故

$$\mathbb{P} \left(-t_{\alpha/2}(n-2) \leq \frac{\hat{\mu}(x_0) - \mu(x_0)}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}} \leq t_{\alpha/2}(n-2) \right) = 1 - \alpha,$$

经过等价变形可得

$$\mathbb{P}(\hat{\mu}^l(x_0) \leq \mu(x_0) \leq \hat{\mu}^u(x_0)) = 1 - \alpha,$$

其中

$$\begin{aligned} \hat{\mu}^l(x_0) &= \hat{\mu}(x_0) - t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}, \\ \hat{\mu}^u(x_0) &= \hat{\mu}(x_0) + t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}. \end{aligned}$$

故 $\mu(x_0) = \beta_0 + \beta_1 x_0$ 的一个置信水平为 $1 - \alpha$ 的置信区间为 $[\hat{\mu}^l(x_0), \hat{\mu}^u(x_0)]$. 不难发现, $|x_0 - \bar{x}|$ 越大, 则置信区间的宽度 $\hat{\mu}^u(x_0) - \hat{\mu}^l(x_0)$ 也就越大, 这意味着, 在保持置信水平为 $1 - \alpha$ 的情况下, x_0 越远离 $\bar{x}$, 则区间估计的精度越低.

需要注意的是, $[\hat{\mu}^l(x_0), \hat{\mu}^u(x_0)]$ 给出的只是单个点 x_0 处回归函数值 $\mu(x_0)$ 的置信区间, 我们并不能把它理解为“回归函数 $\mu(x)$ 的图像落在 $\hat{\mu}^l(x_0)$ 与 $\hat{\mu}^u(x_0)$ 之间的概率为 $1 - \alpha$ ”.

10.3.4 (*) 引理 10.1 的证明

为符号上的方便, 令

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}, \quad \hat{\boldsymbol{\beta}} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}, \quad \mathbf{e} = \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}.$$

且用 $\mathbf{I}_k$ 表示 $k \times k$ 单位阵. 则不难验证

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \\ \mathbf{e} &= \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \boldsymbol{\varepsilon}, \end{aligned}$$

且 normal equations 可表示为如下形式:

$$\mathbf{X}^T \mathbf{X} \hat{\boldsymbol{\beta}} = \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} = \mathbf{X}^T \mathbf{Y},$$

故

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon}.$$

考虑对矩阵 $\mathbf{X}$ 做奇异值分解, 则由于 $\mathbf{X}$ 列满秩, 可得

$$\mathbf{X} = \begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix} \begin{bmatrix} \boldsymbol{\Sigma}_c \\ \mathbf{0}_{(n-2) \times 2} \end{bmatrix} \mathbf{V}^T = \mathbf{U}_c \boldsymbol{\Sigma}_c \mathbf{V}^T,$$

其中 $\boldsymbol{\Sigma}_c$ 为 2×2 的对角阵且对角元均大于 0, $\mathbf{V} \in \mathbb{R}^{2 \times 2}$ 为正交阵, 而 $\mathbf{U}_c \in \mathbb{R}^{n \times 2}$, $\mathbf{U}_\perp \in \mathbb{R}^{n \times (n-2)}$ 使得 $\mathbf{U} = \begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix} \in \mathbb{R}^{n \times n}$ 为正交阵, 即

$$\begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix}^T \begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix} = \begin{bmatrix} \mathbf{U}_c^T \mathbf{U}_c & \mathbf{U}_c^T \mathbf{U}_\perp \\ \mathbf{U}_\perp^T \mathbf{U}_c & \mathbf{U}_\perp^T \mathbf{U}_\perp \end{bmatrix} = \begin{bmatrix} \mathbf{I}_2 & \mathbf{0}_{2 \times (n-2)} \\ \mathbf{0}_{(n-2) \times 2} & \mathbf{I}_{n-2} \end{bmatrix}$$

以及

$$\begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix} \begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix}^T = \mathbf{U}_c \mathbf{U}_c^T + \mathbf{U}_\perp \mathbf{U}_\perp^T = \mathbf{I}_n.$$

故

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon} = (\mathbf{V} \boldsymbol{\Sigma}_c^2 \mathbf{V}^T)^{-1} \mathbf{V}^T \boldsymbol{\Sigma}_c \mathbf{U}_c^T \boldsymbol{\varepsilon} = \mathbf{V}^T \boldsymbol{\Sigma}_c^{-1} \mathbf{U}_c^T \boldsymbol{\varepsilon}.$$

由此可得

$$\mathbf{e} = \mathbf{X}(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) + \boldsymbol{\varepsilon} = -\mathbf{U}_c \boldsymbol{\Sigma}_c \mathbf{V}^T \mathbf{V} \boldsymbol{\Sigma}_c^{-1} \mathbf{U}_c^T \boldsymbol{\varepsilon} + \boldsymbol{\varepsilon} = (\mathbf{I}_n - \mathbf{U}_c \mathbf{U}_c^T) \boldsymbol{\varepsilon} = \mathbf{U}_\perp \mathbf{U}_\perp^T \boldsymbol{\varepsilon}.$$

由于 $[\mathbf{U}_c \ \mathbf{U}_\perp]$ 为正交阵, 而 $\boldsymbol{\varepsilon}$ 服从多元正态分布 $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, 故随机向量

$$\tilde{\boldsymbol{\varepsilon}} = \begin{bmatrix} \mathbf{U}_c & \mathbf{U}_\perp \end{bmatrix}^\top \boldsymbol{\varepsilon} = \begin{bmatrix} \mathbf{U}_c^\top \boldsymbol{\varepsilon} \\ \mathbf{U}_\perp^\top \boldsymbol{\varepsilon} \end{bmatrix}$$

同样服从多元正态分布 $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, 而该多元正态分布的协方差矩阵为对角阵, 这意味着 $\tilde{\boldsymbol{\varepsilon}}$ 的各个分量相互独立. 再注意到 $\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + \mathbf{V}^\top \boldsymbol{\Sigma}_c^{-1} \mathbf{U}_c^\top \boldsymbol{\varepsilon}$ 是 $\tilde{\boldsymbol{\varepsilon}}$ 的前两个分量的函数, 而

$$SS_{\text{res}} = \sum_{i=1}^n e_i^2 = \mathbf{e}^\top \mathbf{e} = \boldsymbol{\varepsilon}^\top \mathbf{U}_\perp \mathbf{U}_\perp^\top \mathbf{U}_\perp \mathbf{U}_\perp^\top \boldsymbol{\varepsilon} = \boldsymbol{\varepsilon}^\top \mathbf{U}_\perp \mathbf{U}_\perp^\top \boldsymbol{\varepsilon}$$

是 $\tilde{\boldsymbol{\varepsilon}}$ 的后 $n-2$ 个分量的函数, 可得 $\hat{\boldsymbol{\beta}}$ 与 SS_{Res} 相互独立.

为了求 SS_{Res} 的分布, 注意到

$$\frac{SS_{\text{Res}}}{\sigma^2} = \frac{1}{\sigma^2} \boldsymbol{\varepsilon}^\top \mathbf{U}_\perp \mathbf{U}_\perp^\top \boldsymbol{\varepsilon} = \sum_{i=1}^{n-2} (\sigma^{-1} \mathbf{U}_\perp^\top \boldsymbol{\varepsilon})_i^2,$$

而由于 $\mathbf{U}_\perp^\top \boldsymbol{\varepsilon}$ 的分量即为 $\tilde{\boldsymbol{\varepsilon}}$ 的后 $n-2$ 个分量, 故 $\sigma^{-1} \mathbf{U}_\perp^\top \boldsymbol{\varepsilon}$ 的各个分量相互独立且服从标准正态分布 $\mathcal{N}(0, 1)$. 由此可得 $SS_{\text{Res}}/\sigma^2 \sim \chi^2(n-2)$.

10.4 因变量的点预测与区间预测

本节中我们考虑这样一个问题: 假设基于样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 已经构造出了回归系数的点估计量 $\hat{\beta}_0, \hat{\beta}_1$, 而我们对因变量 Y 在 $x = x_0$ 处的值 Y_0 感兴趣, 其中 x_0 为一给定的实数且与 $x_1, \dots, x_n$ 相异; 换句话说

$$Y_0 = \beta_0 + \beta_1 x_0 + \varepsilon_0,$$

其中 ε_0 与 $\varepsilon_1, \dots, \varepsilon_n$ 独立且同分布, 则在尚未观测到 Y_0 的值的情况下, 我们应当如何对 Y_0 的值进行预测?

由于随机误差 ε_0 与 $\varepsilon_1, \dots, \varepsilon_n$ 独立, 若仅基于样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 对 ε_0 预测, 则只能将其预测为 $\mathbb{E}[\varepsilon_0] = 0$, 故我们可以直接用 $\mu(x_0)$ 的点估计量

$$\hat{\mu}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

作为 Y_0 的点预测量, 且不难看出它满足如下意义的“无偏性”: $\mathbb{E}[\hat{\mu}(x_0) - Y_0] = 0$. 但许多情况下, 仅给出单个点预测是不够的, 我们还希望对点预测的精度有定量的刻画. 具

体而言, 我们希望找到一个仅依赖于 $(x_1, Y_1), \dots, (x_n, Y_n)$ 的随机区间 $[\hat{Y}_0^l, \hat{Y}_0^u]$, 使得

$$\mathbb{P}(Y_0 \in [\hat{Y}_0^l, \hat{Y}_0^u]) = 1 - \alpha,$$

其中 $\alpha \in]0, 1[$ 为事先给定的常数. 我们将满足上述条件的 $[\hat{Y}_0^l, \hat{Y}_0^u]$ 称为 Y_0 的置信水平为 $1 - \alpha$ 的**预测区间** (prediction interval).

现假设 $\varepsilon_0, \varepsilon_1, \dots, \varepsilon_n$ 均服从正态分布 $\mathcal{N}(0, \sigma^2)$. 为了求出 Y_0 的预测区间, 这次我们从点预测误差

$$e_p = Y_0 - \hat{\mu}(x_0)$$

入手. 注意到 e_p 为 $Y_0, Y_1, \dots, Y_n$ 的线性函数, 而 $Y_0, Y_1, \dots, Y_n$ 相互独立且服从正态分布, 故 e_p 也服从正态分布, 其期望为 $\mathbb{E}[e_p] = 0$, 而方差为

$$\begin{aligned} \text{Var}(e_p) &= \text{Var}(Y_0 - \hat{\mu}(x_0)) \\ &= \text{Var}(Y_0) + \text{Var}(\hat{\mu}(x_0)) \\ &= \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right), \end{aligned}$$

其中第二步是因为 $\mu(x_0) - \hat{\mu}(x_0)$ 与 ε_0 相互独立. 在求得 e_p 的方差后, 即可考虑构造如下枢轴量:

$$\frac{e_p}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}} = \frac{Y_0 - \hat{\mu}(x_0)}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}}.$$

利用引理 10.1 可验证其服从分布 $t(n-2)$, 故

$$\mathbb{P} \left(-t_{\alpha/2}(n-2) \leq \frac{Y_0 - \hat{\mu}(x_0)}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}} \leq t_{\alpha/2}(n-2) \right) = 1 - \alpha,$$

经过等价变形并根据前述预测区间的定义可得, 若令

$$\begin{aligned} \hat{Y}_0^l &= \hat{\mu}(x_0) - t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}, \\ \hat{Y}_0^u &= \hat{\mu}(x_0) + t_{\alpha/2}(n-2) \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}, \end{aligned}$$

则 $[\hat{Y}_0^l, \hat{Y}_0^u]$ 给出了 Y_0 的一个置信水平为 $1 - \alpha$ 的预测区间. 不难看出, 预测区间 $[\hat{Y}_0^l, \hat{Y}_0^u]$ 的宽度 $\hat{Y}_0^u - \hat{Y}_0^l$ 随着 $|x_0 - \bar{x}|$ 的增大而增大, 这意味着, 在保持置信水平为 $1 - \alpha$ 的情况下, x_0 越远离 $\bar{x}$, 则对 Y_0 进行区间预测的精度越低. 此外, Y_0 的预测区间总是宽于 $\mu(x_0)$ 的置信区间, 这是因为对 Y_0 进行区间预测时需要把 Y_0 上的随机误差 ε_0 也考虑进来.

10.5 回归显著性检验

对回归系数 β_1 进行假设检验的方法已在第 10.3.1 小节中进行了介绍. 在实际问题中, 最常用的针对 β_1 的假设检验问题具有如下形式:

$$H_0: \beta_1 = 0, \quad H_1: \beta_1 \neq 0. \quad (10.10)$$

这是因为若我们无法拒绝原假设 H_0 , 则很有可能意味着如下几种情况:

- x 对 Y 的取值在平均意义上并没有影响. 此时通常需要考虑寻找其它对 Y 的取值具有显著影响的变量.
- x 对 Y 取值的影响并不能简单地由 $\mathbb{E}[Y|x] = \beta_0 + \beta_1 x$ 所表述. 此时通常需要考虑用其它统计模型对 x 与 Y 的关系进行建模.
- 样本容量 n 太小. 此时需要收集更多的数据以得到更确切的结论.

总之, 若无法拒绝原假设 H_0 , 则说明得到的线性回归模型并不理想, 尚不能直接应用而需要进一步更正. 我们将 (10.10) 给出的假设检验问题称为**回归显著性检验** (test for significance of regression).

对于一元线性回归, 其回归显著性检验可以有三种等价的方法, 我们依次对其进行介绍.

t 检验法. 显著性回归的 t 检验法就是第 10.3.1 小节中给出的检验法: 取

$$T = \frac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2/S_{xx}}} = \sqrt{\frac{(n-2)S_{xx}}{SS_{\text{Res}}}} \cdot \hat{\beta}_1, \quad (10.11)$$

则在原假设 $H_0: \beta_1 = 0$ 下, T 服从分布 $t(n-2)$, 相应的 p 值与拒绝域分别由

$$\hat{p} = 2 \left(1 - F_{n-2}^t \left(\frac{|\hat{\beta}_1|}{\sqrt{\hat{\sigma}^2/S_{xx}}} \right) \right) \quad \text{与} \quad \frac{|\hat{\beta}_1|}{\sqrt{\hat{\sigma}^2/S_{xx}}} > t_{\alpha/2}$$

给出, 其中 α 为事先取定的显著性水平.

F 检验法. 在习题 9.4 中已经让读者证明, 服从分布 $t(k)$ 的随机变量在平方后服从分布 $F(1, k)$, 因此我们也可以取检验统计量为

$$F = T^2 = \frac{\hat{\beta}_1^2}{\hat{\sigma}^2/S_{xx}}, \quad (10.12)$$

则在原假设 H_0 下有 $F \sim F(1, n-2)$, 由此可得相应的 p 值与拒绝域的形式. 另一方面, 检验统计量 F 实际上还可表示为

$$F = \frac{SS_R}{SS_{\text{Res}}/(n-2)}, \quad (10.13)$$

其中

$$SS_R = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{Y})^2$$

被称为**回归平方和** (regression sum of squares). 式 (10.13) 成立是因为

$$\begin{aligned} \hat{\beta}_1^2 &= \hat{\beta}_1 \cdot \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y}) \\ &= \frac{\hat{\beta}_1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \hat{Y}_i) + \frac{1}{S_{xx}} \sum_{i=1}^n (\hat{\beta}_1 x_i - \hat{\beta}_1 \bar{x})(\hat{Y}_i - \bar{Y}) \\ &= \frac{\hat{\beta}_1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x})(Y_i - \hat{Y}_i) + SS_R, \end{aligned}$$

而由 normal equations (10.3) 可推得

$$0 = \sum_{i=1}^n x_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n x_i (Y_i - \hat{Y}_i),$$

以及

$$0 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n (Y_i - \hat{Y}_i),$$

故

$$\sum_{i=1}^n (x_i - \bar{x})(Y_i - \hat{Y}_i) = \sum_{i=1}^n x_i (Y_i - \hat{Y}_i) - \bar{x} \sum_{i=1}^n (Y_i - \hat{Y}_i) = 0,$$

从而

$$\hat{\beta}_1^2 = \frac{SS_R}{S_{xx}},$$

再将其带入式 (10.12) 中并利用 $\hat{\sigma}^2 = SS_{\text{Res}}/(n-2)$ 即可得到表达式 (10.13). 由此可知, p 值与拒绝域还可表示为

$$\hat{p} = 1 - F_{1, n-2}^F \left(\frac{SS_R}{SS_{\text{Res}}/(n-2)} \right) \quad \text{与} \quad \frac{SS_R}{SS_{\text{Res}}/(n-2)} > F_{\alpha}(1, n-2),$$

其中 $F_{1, n-2}^F$ 表示分布 $F(1, n-2)$ 的分布函数, α 为事先给定的显著性水平.

上述 F 检验法又被称为**方差分析法** (analysis-of-variance approach).

相关系数检验法. 我们还可以利用如下样本相关系数

$$R = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (10.14)$$

对 (10.10) 进行检验: 由上述 R 的定义式可得

$$\begin{aligned} R &= \frac{S_{xY}}{\sqrt{S_{xx}} \sqrt{SS_T}} = \frac{S_{xY}/S_{xx}}{\sqrt{SS_T/S_{xx}}} \\ &= \frac{\hat{\beta}_1}{\sqrt{(SS_{\text{Res}} + \hat{\beta}_1 S_{xY})/S_{xx}}} = \frac{\hat{\beta}_1}{\sqrt{SS_{\text{Res}}/S_{xx} + \hat{\beta}_1^2}} \\ &= \frac{\sqrt{S_{xx}/SS_{\text{Res}}} \cdot \hat{\beta}_1}{\sqrt{1 + S_{xx}\hat{\beta}_1^2/SS_{\text{Res}}}} = \frac{T}{\sqrt{n-2+T^2}}, \end{aligned}$$

其中 T 即为 (10.11) 给出的检验统计量. 上式指出, R 与 T 之间存在连续且严格单调递增的对应关系. 反解上式可得

$$T = \frac{\sqrt{n-2}R}{\sqrt{1-R^2}},$$

由此还可得到

$$F = T^2 = \frac{(n-2)R^2}{1-R^2} \quad \text{以及} \quad R^2 = \frac{F}{n-2+F}.$$

故 p 值为

$$\hat{p} = 2 \left(1 - F_{n-2}^t \left(\frac{\sqrt{n-2}|r|}{\sqrt{1-r^2}} \right) \right) = 1 - F_{1,n-2}^F \left(\frac{(n-2)r^2}{1-r^2} \right),$$

其中 r 为统计量 R 在代入样本观测值后的取值, 而拒绝域则可表示为

$$|r| > \frac{t_{\alpha/2}(n-2)}{\sqrt{n-2+[t_{\alpha/2}(n-2)]^2}} \quad \text{或} \quad r^2 > \frac{F_{\alpha}(1, n-2)}{n-2+F_{\alpha}(1, n-2)},$$

其中 α 为显著性水平.

10.6 残差分析初步

在以上几节内容中, 我们基本上都假定了线性回归模型 (10.1) 能够很好地描述自变量 x 与因变量 Y 之间的依赖关系, 且在区间估计与假设检验问题中我们进一步假定了随机误差服从正态分布. 具体而言, 我们做出了如下 4 条假设:

1. x_i 与 Y_i 之间具有近似的线性关系. 换句话说, 存在实数 β_0, β_1 使得 $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, 其中 ε_i 为期望为 0 的随机误差;

2. 每个 ε_i 均具有相同的方差 (方差齐性);
3. ε_i 之间相互独立;
4. 每个 ε_i 均服从正态分布.

但许多情况下, 除了观测到的样本值 $(x_1, y_1), \dots, (x_n, y_n)$ 以外, 我们可能并没有足够的先验证据证实上述全部 4 条假设, 因此需要根据观测到的样本值来分析上述假设是否合理. 这种对模型假设合理性的分析通常被称为**残差分析** (residual analysis), 这是因为大多数相关方法都是以残差这个量为核心的.

本节中我们对最基本也是最常用的残差分析方法进行介绍, 这些方法都是定性或半定量而非完全定量的图示方法, 但在实践中通常都能发挥重要作用. 以下均用 $(x_1, y_1), \dots, (x_n, y_n)$ 表示一组样本的观测值, 而 $\hat{\beta}_0, \hat{\beta}_1, e_i, \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 等则代表相应的统计量在这组样本上的取值.

残差散点图. 残差散点图, 是指将各个 (x_i, e_i) 或 $(\hat{y}_i, e_i)$ 绘于二维坐标平面上而得到的散点图³. 在前面我们已经分析过, 若样本的产生服从线性回归模型, 且 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 是 β_0 与 β_1 实际值的良好近似, 则可以近似认为 $e_i \approx \varepsilon_i$. 这意味着, 在上面提到的前 3 条假设都满足的情况下, 残差散点图中的各个点应当是随机而大致均匀地分布在 x 轴上下两侧、不同横坐标处的残差之间不存在明显的变化规律, 且残差上下波动的幅度在横坐标变化时近似保持一致.

图 10.2 给出了几种典型的残差散点图的示例, 直观上看,

1. 图 10.2b 与 10.2c 表明随机误差 ε_i 的方差并不相同, 也就是说方差齐性的假设被破坏.
2. 图 10.2d 表明, 因变量 x 与自变量 Y 之间存在未被模型刻画的非线性关系.
3. 图 10.2e 则表明, 数据当中可能存在异常值, 此时需要采用其它方法对异常值等进行辨识.

而图 10.2a 所示的残差散点图则直观上看是比较正常、与线性回归模型假设无明显冲突的.

在画残差散点图之前, 我们还可以先将残差进行归一化. 由第 10.2.3 节的计算可知,

³ 对于一元线性回归, 横坐标用 x_i 或 $\hat{y}_i$ 均可, 它们给出的散点图具有相似关系.




图 10.2: 几个典型的残差散点图示例.

当线性回归模型假设得到满足时, 有

$$\text{Var}(e_i) = \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right),$$

故我们可以令

$$t_i = \frac{e_i}{\sqrt{\hat{\sigma}^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right)}},$$

而后画 $(x_i, t_i), i = 1, \dots, n$ 的散点图. t_i 则被称为 Studentized residual. 通常, 若样本点 $(x_i, y_i), i = 1, \dots, n$ 当中存在个别点的 x_i 与 $\bar{x}$ 相差很大, 使得 $(x_i - \bar{x})^2/S_{xx}$ 与 1 相比不可忽略, 则这些点的残差的方差相比于其它点在理论上就是明显偏小的, 此时用 Studentized residual 的散点图进行残差分析是更加合理的.

关于残差的其它归一化方法可参考 [34] 第 4.2.2 节.

(*) **正态概率图.** 正态概率图是用于判断随机误差 ε 是否服从正态分布 $\mathcal{N}(0, \sigma^2)$ 的定性方法. 具体而言, 设我们已经对前 3 条假设的合理性进行了验证. 将残差 $e_1, \dots, e_n$ 由小到大进行排序, 得到

$$e_{(1)} < e_{(2)} < \dots < e_{(n)}.$$

由于 $e_i \approx \varepsilon_i$, 当样本容量 n 足够大且各个 ε_i 服从正态分布时, 应当有

$$\begin{aligned} \Phi\left(\frac{t}{\sigma}\right) &\approx \frac{1}{n} \sum_{i=1}^n \frac{1_{\{\varepsilon_i \leq t\}} + 1_{\{\varepsilon_i < t\}}}{2} \\ &\approx \frac{1}{n} \sum_{i=1}^n \frac{1_{\{e_i \leq t\}} + 1_{\{e_i < t\}}}{2} \\ &= \frac{\max\{i \mid e_{(i)} \leq t\} + \max\{i \mid e_{(i)} < t\}}{2n}, \end{aligned}$$

其中第一个约等号来自于用经验分布函数近似分布函数, 且加入了类似于连续性修正的步骤. 在上式中将 $t = e_{(j)}$ 代入, 即可得到

$$\begin{aligned} \Phi\left(\frac{e_{(j)}}{\sigma}\right) &\approx \frac{\max\{i \mid e_{(i)} \leq e_{(j)}\} + \max\{i \mid e_{(i)} < e_{(j)}\}}{2n} \\ &= \frac{j + (j - 1)}{2n} = \frac{j - 1/2}{n}, \end{aligned}$$

从而

$$e_{(j)} \approx \sigma \cdot \Phi^{-1}\left(\frac{j - 1/2}{n}\right).$$




图 10.3: 几个典型的正态概率图示例.

上式意味着, 在随机误差的正态性假设得到满足的情况下, 如果我们将各个点

$$\left(\Phi^{-1}\left(\frac{j-1/2}{n}\right), e_{(j)} \right), \quad j = 1, \dots, n$$

画在二维坐标平面上得到一散点图, 则这些点应落于过原点的某条直线附近, 该散点图被称为**正态概率图** (normal probability plot)⁴; 利用 σ^2 的点估计值 $\hat{\sigma}^2 = SS_{\text{Res}}/(n-2)$, 我们还可以在正态概率图上作出直线 $y = \sqrt{\hat{\sigma}^2}x$ 以和图上的散点进行比对. 图 10.3 给出了两种典型的正态概率图, 其中图 10.3a 意味着观测到的样本与随机误差的正态性假设无明显冲突, 而图 10.3b 则意味着随机误差的正态性假设很有可能是被打破的.

10.7 习题

习题 10.1. 证明最小二乘估计中残差的如下性质:

1. $\sum_{i=1}^n e_i = 0.$
2. $\sum_{i=1}^n x_i e_i = 0.$
3. $\sum_{i=1}^n \hat{Y}_i e_i = 0.$

⁴ 有些地方将正态概率图的横坐标取为 $e_{(j)}$ 而纵坐标取为 $\Phi^{-1}((j-1/2)/n)$. 此外, 在绘制正态概率图时也可用归一化残差 (如 Studentized residual t_i) 来代替原始残差 e_i .

习题 10.2. 证明如下方差分析恒等式 (analysis-of-variance identity) :

$$\begin{aligned} SS_T &= SS_{\text{Res}} + \hat{\beta}_1 S_{xY} \\ &= SS_{\text{Res}} + SS_R, \end{aligned}$$

其中

$$SS_T = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad SS_{\text{Res}} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2, \quad SS_R = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

分别为校正平方和 (corrected sum of squares)、残差平方和 (residual sum of squares) 与回归平方和 (regression sum of squares) .

习题 10.3. 对于一元线性回归, 证明样本相关系数 R 满足

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2},$$

其中 $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$, 而 $\hat{\beta}_0, \hat{\beta}_1$ 为回归系数的最小二乘估计量.

习题 10.4. 考虑一化工蒸馏过程中, 制取出的氧气纯度与残留物中烃类物质浓度的关系. 通过实验, 得到如下数据:

实验编号	1	2	3	4	5	6	7	8	9	10
烃类浓度 (%)	0.99	1.02	1.15	1.29	1.46	1.36	0.87	1.23	1.55	1.40
氧气纯度 (%)	90.01	89.05	91.43	93.74	96.73	94.45	87.59	91.77	99.42	93.65
实验编号	11	12	13	14	15	16	17	18	19	20
烃类浓度 (%)	1.19	1.15	0.98	1.01	1.11	1.20	1.26	1.32	1.43	0.95
氧气纯度 (%)	93.54	92.52	90.56	89.54	89.85	90.39	93.25	93.41	94.98	87.33

试将烃类浓度作为自变量、氧气纯度作为因变量, 建立二者的线性回归模型, 求出

1. 回归系数的最小二乘估计值;
2. 方差 σ^2 的点估计值;

3. SS_{Res} , SS_{R} 与 SS_{T} 的值.

4. 样本相关系数的值.

习题 10.5. 一研究机构收集了某类 32 辆汽车每升油行驶里程 Y 与汽车重量 x 的数据, 并对其进行了线性回归分析, 得到回归系数的最小二乘估计值为 $\hat{\beta}_0 = 68.17$ 与 $\hat{\beta}_1 = -1.112$, 方差估计值为 $\hat{\sigma}^2 = 4.281^2$. 此外, 其它相关数据包括 $\bar{x} = 30.91$ 以及 $\sum_{i=1}^n (x_i - \bar{x})^2 = 2054.8$. 设有一辆同类汽车的重量为 $x = 24$, 试对其每升油行驶里程进行点预测, 并求出其置信水平为 95% 的预测区间 (假设线性回归模型的确成立, 且随机误差服从正态分布).

习题 10.6. 在一线性回归问题中, 数据由下表给出:

i	x_i	y_i	i	x_i	y_i
1	0.3	0.4	6	1.0	0.8
2	1.4	0.9	7	2.0	0.7
3	1.0	0.4	8	-1.0	-0.4
4	-0.3	-0.3	9	-0.7	-0.2
5	-0.2	0.3	10	0.7	0.7

1. 求出 $F = \frac{SS_{\text{R}}}{SS_{\text{Res}}/(n-2)}$, 再对回归显著性进行检验, 取显著性水平为 5%.
2. 试求出 $x = 0.5$ 时 $\mathbb{E}[Y|x] = \beta_0 + \beta_1 x$ 的置信水平为 95% 的置信区间.
3. 试对 $x = 1.2$ 时的因变量进行区间预测, 取置信水平为 95%.

注: 本题数据取自 [22] 第 11.3 节习题 1.

习题 10.7. 设因变量 x 与自变量 Y 之间满足关系式

$$Y = \beta_0 + \beta_1 x + \varepsilon,$$

其中随机误差 ε 的期望为 0 而方差为 σ^2 , 系数 β_0 已知, 而系数 β_1 与方差 σ^2 未知. 令 $(x_1, Y_1), \dots, (x_n, Y_n)$ 为一组样本.

1. 考虑用最小二乘法对 β_1 进行点估计:

$$\hat{\beta}_1 = \arg \min_{\beta_1 \in \mathbb{R}} \frac{1}{2} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

试求 $\hat{\beta}_1$ 的表达式.

2. 试求 σ^2 的一个无偏估计量.
3. 任取 $x_0 \in \mathbb{R}$, 试求 $\hat{Y}_0 = \beta_0 + \hat{\beta}_1 x_0$ 的方差.

习题 10.8. 设某个自变量 x 与因变量 Y 之间服从线性回归模型, 我们可以设计实验并选择在哪些 $x_1, \dots, x_n$ 处观测相应的 $Y_1, \dots, Y_n$ 的值. 若要求 $-1 \leq x_i \leq 1$, 则应当怎样选取 $x_1, \dots, x_n$ 使得 β_1 的最小二乘估计的均方误差最小?

注: 本题取自 [34] 习题 2.29.

附录 A 一些数学上的补充说明

A.1 形如 $\sum_{x \in \mathcal{X}} f(x)$ 的求和式

本节中, 我们将定义形如

$$\sum_{x \in \mathcal{X}} f(x) \quad (\text{A.1})$$

的求和式应如何取值. 这里 $\mathcal{X}$ 为一可数集, $f: \mathcal{X} \rightarrow \mathbb{R}$ 为实值函数¹. 该求和式取值的严格定义如下:

- 当 $\mathcal{X}$ 为空集时, 定义 $\sum_{x \in \mathcal{X}} f(x) = 0$; 当 $\mathcal{X}$ 为有限集时, $\sum_{x \in \mathcal{X}} f(x)$ 定义为所有 $f(x)$, $x \in \mathcal{X}$ 的和. 这两种情况下, 我们总是称 $\sum_{x \in \mathcal{X}} f(x)$ 是**收敛**的.
- 当 $\mathcal{X}$ 为可数无限集时, 则任取一序列 $x_1, x_2, x_3, \dots$ 使其不重复地枚举 $\mathcal{X}$ 的所有元素, 当级数 $\sum_{j=1}^{\infty} |f(x_j)|$ 收敛时, 我们称 $\sum_{x \in \mathcal{X}} f(x)$ **收敛**, 并定义

$$\sum_{x \in \mathcal{X}} f(x) = \sum_{j=1}^{\infty} f(x_j),$$

否则称 $\sum_{x \in \mathcal{X}} f(x)$ **发散**.

由于求和式 $\sum_{x \in \mathcal{X}} f(x)$ 收敛要求 $\sum_{j=1}^{\infty} f(x_j)$ 绝对收敛, 因此 $\sum_{x \in \mathcal{X}} f(x)$ 的值与序列 $(x_j)_{j=1}^{\infty}$ 的具体取法无关, 也就是说以上定义是无歧义的.

根据以上定义可知, $\sum_{x \in \mathcal{X}} f(x)$ 收敛当且仅当 $\sum_{x \in \mathcal{X}} |f(x)|$ 收敛.

由上述定义及级数收敛的相关知识, 不难得到求和式的如下性质:

命题 A.1. 设 $\mathcal{X}$ 为一至多可数集, f, g 为两个定义在 $\mathcal{X}$ 上的实值函数.

1. 若 $\sum_{x \in \mathcal{X}} f(x)$ 与 $\sum_{x \in \mathcal{X}} g(x)$ 均收敛, 则对任意 $\alpha, \beta \in \mathbb{R}$, $\sum_{x \in \mathcal{X}} (\alpha f(x) + \beta g(x))$ 也

¹第二章注 2.1 中的求和式 (2.1) 即为式 (A.1) 的特殊情形. 此外, 注 2.1 中还给出了本讲义所采纳的一些简化记法, 这些简化记法对应的取值仍可最终归结于式 (A.1) 的取值.

收敛, 且

$$\sum_{x \in \mathcal{X}} (\alpha f(x) + \beta g(x)) = \alpha \sum_{x \in \mathcal{X}} f(x) + \beta \sum_{x \in \mathcal{X}} g(x).$$

2. 若 $0 \leq f(x) \leq g(x)$, $\forall x \in \mathcal{X}$, 且 $\sum_{x \in \mathcal{X}} g(x)$ 收敛, 则 $\sum_{x \in \mathcal{X}} f(x)$ 也收敛, 且

$$\sum_{x \in \mathcal{X}} f(x) \leq \sum_{x \in \mathcal{X}} g(x).$$

在涉及到离散随机变量的理论推导当中, 我们经常需要对多重求和式交换求和次序. 利用以下定理, 我们可以验证求和次序是否可交换.

定理 A.2. 设 $\mathcal{X}$ 为至多可数集, 函数 $f: \mathcal{X} \rightarrow [0, +\infty[$ 取值非负, $\mathcal{I}$ 为一至多可数集, 每个 $i \in \mathcal{I}$ 对应于一个集合 $\mathcal{X}_i \subseteq \mathcal{X}$, 且满足

$$\bigcup_{i \in \mathcal{I}} \mathcal{X}_i = \mathcal{X} \quad \text{以及} \quad \mathcal{X}_i \cap \mathcal{X}_j = \emptyset, \quad \forall i \neq j,$$

则 $\sum_{x \in \mathcal{X}} f(x)$ 收敛当且仅当

1. 对于每个 $i \in \mathcal{I}$, $\sum_{x \in \mathcal{X}_i} f(x)$ 均收敛, 且
2. $\sum_{i \in \mathcal{I}} s(i)$ 收敛, 其中

$$s(i) = \sum_{x \in \mathcal{X}_i} f(x).$$

此外, 当 $\sum_{x \in \mathcal{X}} f(x)$ 收敛时有

$$\sum_{x \in \mathcal{X}} f(x) = \sum_{i \in \mathcal{I}} s(i) = \sum_{i \in \mathcal{I}} \left(\sum_{x \in \mathcal{X}_i} f(x) \right).$$

定理 A.2 的证明较长且涉及到不少数学分析的知识点, 我们将它放在 A.1.1 节中作为选读内容. 下面我们给出该定理的一个直接推论:

推论 A.3. 设 $\mathcal{X}, \mathcal{Y}$ 为两个可数无限集, $f: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$ 为一实值函数. 若如下求和式中的任意一个收敛:

$$\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} |f(x, y)| \right), \quad \sum_{y \in \mathcal{Y}} \left(\sum_{x \in \mathcal{X}} |f(x, y)| \right),$$

则

$$\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f(x, y) \right) \quad \text{与} \quad \sum_{y \in \mathcal{Y}} \left(\sum_{x \in \mathcal{X}} f(x, y) \right)$$

均收敛, 且二者的取值相同.

证明. (*) 令

$$\mathcal{U}_x = \{x\} \times \mathcal{Y}, \quad \forall x \in \mathcal{X} \quad \text{以及} \quad \mathcal{V}_y = \mathcal{X} \times \{y\}, \quad \forall y \in \mathcal{Y},$$

则不难看出

$$\bigcup_{x \in \mathcal{X}} \mathcal{U}_x = \bigcup_{y \in \mathcal{Y}} \mathcal{V}_y = \mathcal{X} \times \mathcal{Y}$$

以及

$$\mathcal{U}_{x_1} \cap \mathcal{U}_{x_2} = \emptyset, \quad \forall x_1 \neq x_2,$$

$$\mathcal{V}_{y_1} \cap \mathcal{V}_{y_2} = \emptyset, \quad \forall y_1 \neq y_2.$$

令

$$f^+(x, y) = \max\{f(x, y), 0\}, \quad f^-(x, y) = \max\{-f(x, y), 0\},$$

则有 $0 \leq f^+(x, y) \leq |f(x, y)|$ 以及 $0 \leq f^-(x, y) \leq |f(x, y)|$. 故由待证推论中所设的条件、命题 A.1 第 2 部分以及定理 A.2 可得, 以下三个求和式均收敛且具有相同的取值:

$$\sum_{(x,y) \in \mathcal{X} \times \mathcal{Y}} f^+(x, y), \quad \sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f^+(x, y) \right), \quad \sum_{y \in \mathcal{Y}} \left(\sum_{x \in \mathcal{X}} f^+(x, y) \right).$$

同理, 以下三个求和式均收敛且具有相同的取值:

$$\sum_{(x,y) \in \mathcal{X} \times \mathcal{Y}} f^-(x, y), \quad \sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f^-(x, y) \right), \quad \sum_{y \in \mathcal{Y}} \left(\sum_{x \in \mathcal{X}} f^-(x, y) \right).$$

最后, 由 $f(x, y) = f^+(x, y) - f^-(x, y)$, 以及命题 A.1 第 1 部分可得

$$\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f(x, y) \right) \quad \text{与} \quad \sum_{y \in \mathcal{Y}} \left(\sum_{x \in \mathcal{X}} f(x, y) \right)$$

均收敛, 且二者的取值相同. □

推论 A.3 又被称为无限和的 Fubini 定理.

注 A.1. (*) 需要注意的是, $\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} |f(x, y)| \right)$ 收敛仅仅是 $\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f(x, y) \right)$ 收敛的一个充分条件而非必要条件. 由定义, $\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f(x, y) \right)$ 收敛的充要条件是

1. 每个 $\sum_{y \in \mathcal{Y}} |f(x, y)|$ 均收敛, 且
2. $\sum_{x \in \mathcal{X}} \left| \sum_{y \in \mathcal{Y}} f(x, y) \right|$ 收敛.

作为一个例子, 我们考虑 $\mathcal{X} = \mathcal{Y} = \mathbb{N}$,

$$f(x, y) = \begin{cases} 1, & \text{若 } y = x, \\ -1, & \text{若 } y = x + 1, \\ 0, & \text{其它情况.} \end{cases}$$

则 $\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} |f(x, y)| \right)$ 发散, 但对每个 $x \in \mathcal{X}$, 均有

$$\sum_{y \in \mathcal{Y}} |f(x, y)| = |1| + |-1| = 2,$$

以及

$$\sum_{x \in \mathcal{X}} \left| \sum_{y \in \mathcal{Y}} f(x, y) \right| = \sum_{x \in \mathcal{X}} |1 + (-1)| = 0.$$

因此 $\sum_{x \in \mathcal{X}} \left(\sum_{y \in \mathcal{Y}} f(x, y) \right)$ 收敛. 注意到该例中的多重求和式不能交换求和次序. ■

关于求和式 $\sum_{x \in \mathcal{X}} f(x)$ 更详细的内容, 读者可参考 [35] 第 8.2 节.

A.1.1 (*) 定理 A.2 的证明

我们先证明如下引理:

引理 A.4. 设 $\mathcal{X}$ 非空, $f(x) \geq 0, \forall x \in \mathcal{X}$, 则 $\sum_{x \in \mathcal{X}} f(x)$ 收敛时

$$\sum_{x \in \mathcal{X}} f(x) = \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\},$$

且 $\sum_{x \in \mathcal{X}} f(x)$ 发散当且仅当上式右端为 $+\infty$.

证明. 待证结论在 $\mathcal{X}$ 为有限集时显然成立, 故接下来我们假设 $\mathcal{X}$ 为可数无限集. 令序列 $\bar{x}_1, \bar{x}_2, \dots$ 为任一不重复地枚举 $\mathcal{X}$ 的所有元素的序列, 并记

$$s = \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \in [0, +\infty].$$

先考虑 $s = +\infty$ 的情形. 由 s 的定义可知, 对任意正整数 k , 均存在正整数 ℓ_k 以及互不相同的正整数 $j(k, 1), \dots, j(k, \ell_k)$ 使得

$$f(\bar{x}_{j(k,1)}) + \dots + f(\bar{x}_{j(k,\ell_k)}) > k.$$

现令 $m(k) = \max\{j(k, 1), \dots, j(k, \ell_k)\}$, $k \in \mathbb{N}_+$, 则给定任一正整数 k 时, 只要取 $n \geq m(k)$ 就有

$$\sum_{j=1}^n f(\bar{x}_j) \geq \sum_{j=1}^{m(k)} f(\bar{x}_j) \geq f(\bar{x}_{j(k,1)}) + \dots + f(\bar{x}_{j(k,\ell_k)}) > k.$$

故 $\sum_{j=1}^{\infty} f(\bar{x}_j)$ 发散, 从而 $\sum_{x \in \mathcal{X}} f(x)$ 发散.

再考虑 s 为有限实数的情形. 由 s 的定义可知, 对任意正整数 n , 有

$$\sum_{j=1}^n f(\bar{x}_j) = f(\bar{x}_1) + \dots + f(\bar{x}_n) \leq s,$$

故 $\sum_{j=1}^{\infty} f(\bar{x}_j)$ 收敛且 $\sum_{j=1}^{\infty} f(\bar{x}_j) \leq s$. 现取任一 $\epsilon > 0$, 则由 s 的定义, 存在自然数 n_ϵ 以及互不相同的正整数 $j(1), \dots, j(n_\epsilon)$ 使得

$$f(\bar{x}_{j(1)}) + \dots + f(\bar{x}_{j(n_\epsilon)}) > s - \epsilon.$$

从而

$$\sum_{j=1}^{\infty} f(\bar{x}_j) \geq f(\bar{x}_{j(1)}) + \dots + f(\bar{x}_{j(n_\epsilon)}) > s - \epsilon.$$

由 $\epsilon > 0$ 的任意性可得 $\sum_{j=1}^{\infty} f(\bar{x}_j) \geq s$. 综上, 可得 $\sum_{x \in \mathcal{X}} f(x)$ 收敛且等于 s . $\square$

现在我们开始证明定理 A.2. 为方便起见, 我们将指标集 $\mathcal{X}$ 与每个 $\mathcal{X}_i$ 均扩充为可数无限集, 并在扩充出来的指标 x 上定义 $f(x) = 0$. 不难看出这样的扩充不影响求和式的敛散性以及取值.

首先假设存在某个 $\iota \in \mathcal{I}$ 使得 $\sum_{x \in \mathcal{X}_\iota} f(x)$ 发散. 由引理 A.4 可得

$$\begin{aligned} & \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \\ & \geq \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X}_\iota \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \\ & = +\infty, \end{aligned}$$

从而 $\sum_{x \in \mathcal{X}} f(x)$ 发散.

接下来设每个 $\sum_{x \in \mathcal{X}_i} f(x)$ 均收敛但 $\sum_{i \in \mathcal{I}} s(i)$ 发散. 取 M 为任意正实数, 则存在正整数 m_1 以及 $\iota_1, \dots, \iota_{m_1} \in \mathcal{I}$ 使得

$$\sum_{k=1}^{m_1} s(\iota_k) > M.$$

再取 $\epsilon = M/(2m_1)$, 由于每个 $\sum_{x \in \mathcal{X}_i} f(x)$ 均收敛, 根据引理 A.4, 存在正整数 m_2 及如下各元素互不相同的矩阵:

$$\begin{bmatrix} \tilde{x}(\iota_1, 1) & \tilde{x}(\iota_1, 2) & \cdots & \tilde{x}(\iota_1, m_2) \\ \tilde{x}(\iota_2, 1) & \tilde{x}(\iota_2, 2) & \cdots & \tilde{x}(\iota_2, m_2) \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{x}(\iota_{m_1}, 1) & \tilde{x}(\iota_{m_1}, 2) & \cdots & \tilde{x}(\iota_{m_1}, m_2) \end{bmatrix} \in \mathcal{X}^{m_1 \times m_2},$$

使得

$$\sum_{\ell=1}^{m_2} f(\tilde{x}(\iota_k, \ell)) > s(\iota_k) - \epsilon, \quad \forall k = 1, \dots, m_1,$$

从而有

$$\begin{aligned} & \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \\ & \geq \sum_{k=1}^{m_1} \sum_{\ell=1}^{m_2} f(\tilde{x}(\iota_k, \ell)) > \sum_{k=1}^{m_1} (s(\iota_k) - \epsilon) = \sum_{k=1}^{m_1} s(\iota_k) - \frac{M}{2} \\ & > \frac{M}{2}. \end{aligned}$$

由 $M > 0$ 的任意性得上式左端为 $+\infty$, 再由引理 A.4 可知 $\sum_{x \in \mathcal{X}} f(x)$ 发散.

最后考虑每个 $\sum_{x \in \mathcal{X}_i} f(x)$ 以及 $\sum_{i \in \mathcal{I}} s(i)$ 均收敛的情况. 一方面, 对任意互不相同的 $x_1, \dots, x_n \in \mathcal{X}$, 存在互不相同的 $\iota_1, \dots, \iota_\kappa \in \mathcal{I}$, 使得对任意 $k = 1, \dots, \kappa$, 集合 $\mathcal{Z}_k = \mathcal{X}_{\iota_k} \cap \{x_1, \dots, x_n\}$ 为非空有限集, 且 $\bigcup_{k=1}^\kappa \mathcal{Z}_k = \{x_1, \dots, x_n\}$, 从而

$$\begin{aligned} \sum_{j=1}^n f(x_j) &= \sum_{k=1}^\kappa \sum_{x \in \mathcal{Z}_k} f(x) \leq \sum_{k=1}^\kappa s(\iota_k) \\ &\leq \sup \left\{ \sum_{k=1}^n s(i_k) \mid i_1, \dots, i_n \in \mathcal{I} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \\ &= \sum_{i \in \mathcal{I}} s(i). \end{aligned}$$

由于 $x_1, \dots, x_n \in \mathcal{X}$ 任意, 可得

$$\sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \leq \sum_{i \in \mathcal{I}} s(i),$$

故 $\sum_{x \in \mathcal{X}} f(x)$ 收敛且小于等于 $\sum_{i \in \mathcal{I}} s(i)$. 另一方面, 记 $s = \sum_{i \in \mathcal{I}} s(i)$, 并任取 $\epsilon > 0$, 则存在正整数 m_1 以及互不相同的 $\iota_1, \dots, \iota_{m_1}$ 使得

$$\sum_{k=1}^{m_1} s(\iota_k) > s - \frac{\epsilon}{2}$$

而由于每个 $\sum_{x \in \mathcal{X}_i} f(x)$ 均收敛, 可知存在正整数 m_2 及各个元素互不相同的矩阵

$$\begin{bmatrix} \tilde{x}(\iota_1, 1) & \tilde{x}(\iota_1, 2) & \cdots & \tilde{x}(\iota_1, m_2) \\ \tilde{x}(\iota_2, 1) & \tilde{x}(\iota_2, 2) & \cdots & \tilde{x}(\iota_2, m_2) \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{x}(\iota_{m_1}, 1) & \tilde{x}(\iota_{m_1}, 2) & \cdots & \tilde{x}(\iota_{m_1}, m_2) \end{bmatrix} \in \mathcal{X}^{m_1 \times m_2},$$

使得

$$\sum_{\ell=1}^{m_2} f(\tilde{x}(\iota_k, \ell)) > s(\iota_k) - \frac{\epsilon}{2m_1}, \quad \forall k = 1, \dots, m_1.$$

从而

$$\begin{aligned} & \sup \left\{ \sum_{j=1}^n f(x_j) \mid x_1, \dots, x_n \in \mathcal{X} \text{ 且互不相同}, n \in \mathbb{N}_+ \right\} \\ & \geq \sum_{k=1}^{m_1} \sum_{\ell=1}^{m_2} f(\tilde{x}(\iota_k, \ell)) > \sum_{k=1}^{m_1} \left(s(\iota_k) - \frac{\epsilon}{2m_1} \right) = \sum_{k=1}^{m_1} s(\iota_k) - \frac{\epsilon}{2} \\ & > s - \epsilon. \end{aligned}$$

由 $\epsilon > 0$ 的任意性可得上式左端等于 s . 综合以上结果, 最终可得

$$\sum_{x \in \mathcal{X}} f(x) = s = \sum_{i \in \mathcal{I}} s(i).$$

A.2 Γ 函数以及涉及正态分布密度函数的积分

考虑如下形式的积分:

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} x^{2n} \exp\left(-\frac{x^2}{2}\right) dx,$$

其中 n 为任意自然数, 记上述积分的值为 I_n . 不难由对称性看出

$$I_n = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} x^{2n} \exp\left(-\frac{x^2}{2}\right) dx$$

接下来做换元 $t = x^2/2$, 则有

$$I_n = \sqrt{\frac{2}{\pi}} \int_0^{+\infty} (2t)^n \exp(-t) \frac{dt}{\sqrt{2t}} = \frac{2^n}{\sqrt{\pi}} \int_0^{+\infty} t^{n-1/2} \exp(-t) dt.$$

我们引入 Γ 函数:

$$\Gamma(x) := \int_0^{+\infty} t^{x-1} \exp(-t) dt, \quad x \in]0, +\infty[, \quad (\text{A.2})$$

其中 $x \in]0, 1[$ 时上式的积分理解为广义积分. 则 $I_n = 2^n \Gamma(n + 1/2) / \sqrt{\pi}$.

定理 A.5. 对任意 $x > 0$, 有

$$\Gamma(x+1) = x\Gamma(x).$$

特别地, 对任意自然数 n , 有

$$\Gamma(n+1) = n!, \quad \Gamma\left(n + \frac{1}{2}\right) = \frac{(2n-1)!!}{2^n} \sqrt{\pi}.$$

证明. 由 Γ 函数的定义, 有

$$\begin{aligned} \Gamma(x+1) &= \int_0^{+\infty} t^x \exp(-t) dt = - \int_0^{+\infty} t^x \frac{d}{dt}(\exp(-t)) dt \\ &= -t^x \exp(-t) \Big|_0^{+\infty} + \int_0^{+\infty} \exp(-t) \frac{d}{dt}(t^x) dt \\ &= x \int_0^{+\infty} t^{x-1} \exp(-t) dt = x\Gamma(x). \end{aligned}$$

而

$$\Gamma(1) = \int_0^{+\infty} \exp(-t) dt = 1,$$

故对任意自然数 n ,

$$\Gamma(n+1) = n\Gamma(n) = n(n-1)\Gamma(n-1) = \cdots = n!\Gamma(1) = n!.$$

接下来我们求 $\Gamma(1/2)$. 注意到

$$\begin{aligned}\Gamma\left(\frac{1}{2}\right) &= \int_0^{+\infty} \frac{\exp(-t)}{\sqrt{t}} dt \\ &\stackrel{u=\sqrt{t}}{=} \int_0^{+\infty} \frac{\exp(-u^2)}{u} d(u^2) \\ &= 2 \int_0^{+\infty} \exp(-u^2) du = \int_{-\infty}^{+\infty} \exp(-u^2) du,\end{aligned}$$

而

$$\begin{aligned}\left(\int_{-\infty}^{+\infty} \exp(-u^2) du\right)^2 &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \exp(-(u^2 + v^2)) du dv \\ &\stackrel{\substack{u=\rho \sin \theta \\ v=\rho \cos \theta}}{=} \int_0^{2\pi} \int_0^{+\infty} \exp(-\rho^2) \rho d\rho d\theta \\ &= \pi,\end{aligned}$$

故 $\Gamma(1/2) = \sqrt{\pi}$, 从而对任意正整数 n , 有

$$\begin{aligned}\Gamma\left(n + \frac{1}{2}\right) &= \left(n - \frac{1}{2}\right) \Gamma\left(n - \frac{1}{2}\right) = \left(n - \frac{1}{2}\right) \left(n - \frac{3}{2}\right) \Gamma\left(n - \frac{3}{2}\right) \\ &= \cdots = \left(n - \frac{1}{2}\right) \left(n - \frac{3}{2}\right) \cdots \frac{1}{2} \Gamma\left(\frac{1}{2}\right) \\ &= \frac{(2n-1)(2n-3)\cdots 3 \cdot 1}{2^n} \Gamma\left(\frac{1}{2}\right) = \frac{(2n-1)!!}{2^n} \sqrt{\pi}.\end{aligned}$$

因 -1 的双阶乘规定为 1, 故上式对任意自然数 n 均成立, 至此定理证毕. $\square$

回到本节最初的问题, 将上述定理的结果代入 $I_n = 2^n \Gamma(n + 1/2)/\sqrt{\pi}$, 则有

$$I_n = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} x^{2n} \exp\left(-\frac{x^2}{2}\right) dx = (2n-1)!! \quad (\text{A.3})$$

Γ 函数的其它性质可参考 [9] 第二十一章第 4 节.

A.3 一些线性代数知识

定义 A.1. 给定实的方阵 $\mathbf{M} \in \mathbb{R}^{n \times n}$.

1. 若 $\mathbf{M}^T = \mathbf{M}$, 则称 $\mathbf{M}$ 是实对称的.
2. 若 $\mathbf{M}$ 是实对称的, 且对任意 $\mathbf{x} \in \mathbb{R}^n \setminus \{0\}$, 有 $\mathbf{x}^T \mathbf{M} \mathbf{x} > 0$, 则称 $\mathbf{M}$ 是正定的, .
3. 若 $\mathbf{Q}^T \mathbf{Q} = \mathbf{Q} \mathbf{Q}^T = \mathbf{I}_n$, 或等价地说, $\mathbf{Q}$ 的列向量构成了 $\mathbb{R}^n$ 的一组标准正交基, 则称 $\mathbf{M}$ 是实正交的.

以下定理是线性代数中有关实对称矩阵的经典结果, 相关论述可参考 [36] 第 6.4 节或 [37] 第 7.1 节.

定理 A.6. 设 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 为一实对称阵, 则存在一组 $\mathbb{R}^n$ 的标准正交基 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$, 使得每个 $\mathbf{v}_i$ 均为 $\mathbf{M}$ 的特征向量; 或等价地说, 存在一实正交矩阵 $\mathbf{Q} \in \mathbb{R}^{n \times n}$, 使得 $\mathbf{Q}^T \mathbf{M} \mathbf{Q}$ 为一对角阵, 其对角元给出 $\mathbf{M}$ 的所有特征值.

下面的定理则给出了正定矩阵的一种判别方法.

定理 A.7. 设 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 为一实对称阵. 则 $\mathbf{M}$ 是正定阵当且仅当 $\mathbf{M}$ 的所有特征值均为正数.

证明. 对 $\mathbf{M}$ 做特征值分解:

$$\mathbf{M} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T, \quad \mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix},$$

其中 $\mathbf{Q}$ 为实正交阵, $\lambda_1, \dots, \lambda_n$ 给出 $\mathbf{M}$ 的所有特征值. 任取 $\mathbf{x} \in \mathbb{R}^n \setminus \{0\}$, 并令 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$, 则有

$$\mathbf{x}^T \mathbf{M} \mathbf{x} = (\mathbf{Q}^T \mathbf{x})^T \mathbf{M} (\mathbf{Q}^T \mathbf{x}) = \mathbf{y}^T \mathbf{\Lambda} \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2,$$

且 $\mathbf{y} \neq \mathbf{0}$ (否则 $\mathbf{x} = \mathbf{Q} \mathbf{y} = \mathbf{0}$). 若 $\mathbf{M}$ 的所有特征值均为正数, 则显然有 $\mathbf{x}^T \mathbf{M} \mathbf{x} = \sum_{i=1}^n \lambda_i y_i^2 > 0$, 再由 $\mathbf{x} \in \mathbb{R}^n \setminus \{0\}$ 的任意性可得 $\mathbf{M}$ 正定; 反之, 若存在某个特征值 $\lambda_j \leq 0$, 则令 $\mathbf{y}$ 的第 j 个分量为 1 而其余分量为 0, 再令 $\mathbf{x} = \mathbf{Q}^T \mathbf{y}$, 则 $\mathbf{x}$ 为非零向量, 且 $\mathbf{x}^T \mathbf{M} \mathbf{x} = \lambda_j y_j^2 \leq 0$, 从而 $\mathbf{M}$ 不是正定阵. $\square$

以下命题给出了正定矩阵的一些有用的性质.

命题 A.8. 设 $\mathbf{M} = (m_{ij}) \in \mathbb{R}^{n \times n}$ 为一正定阵, 则

1. $\mathbf{M}$ 可逆, 且 $\mathbf{M}^{-1}$ 也是正定矩阵.
2. 对任意列满秩的矩阵 $\mathbf{P}$, 矩阵 $\mathbf{P}^T \mathbf{M} \mathbf{P}$ 正定.

特别地, 任取 $\{1, \dots, n\}$ 的非空子集 J , 则由所有满足 $i \in J, j \in J$ 的 m_{ij} 排成的 $\mathbf{M}$ 的子矩阵为正定阵.

证明. 1. 对 $\mathbf{M}$ 做特征值分解:

$$\mathbf{M} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T, \quad \mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix},$$

其中 $\mathbf{Q}$ 为实正交阵, $\lambda_1, \dots, \lambda_n$ 给出 $\mathbf{M}$ 的所有特征值. 由于 $\mathbf{M}$ 正定, 可得 $\lambda_i > 0, \forall i = 1, \dots, n$, 故

$$\mathbf{\Lambda}^{-1} = \begin{bmatrix} \lambda_1^{-1} & & \\ & \ddots & \\ & & \lambda_n^{-1} \end{bmatrix},$$

从而

$$\mathbf{M}^{-1} = (\mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T)^{-1} = \mathbf{Q} \mathbf{\Lambda}^{-1} \mathbf{Q}^T.$$

从上式可进一步看出 $\lambda_1^{-1}, \dots, \lambda_n^{-1}$ 给出 $\mathbf{M}$ 的所有特征值, 而 $\lambda_i^{-1} > 0, \forall i = 1, \dots, n$, 故 $\mathbf{M}^{-1}$ 正定.

2. 任取 $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$, 并令 $\mathbf{y} = \mathbf{P} \mathbf{x}$. 由于 $\mathbf{P}$ 列满秩, 可得 $\mathbf{y} \neq \mathbf{0}$ (否则 $\mathbf{P} \mathbf{x} = \mathbf{0}$ 意味着 $\mathbf{P}$ 的列向量的某个线性组合等于 $\mathbf{0}$), 再由 $\mathbf{M}$ 的正定性可得

$$\mathbf{x}^T \mathbf{P}^T \mathbf{M} \mathbf{P} \mathbf{x} = \mathbf{y}^T \mathbf{M} \mathbf{y} > 0.$$

最后由 $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ 的任意性可得 $\mathbf{P}^T \mathbf{M} \mathbf{P}$ 为正定阵.

特别地, 对任意非空的 $J \subseteq \{1, \dots, n\}$, 令 m 为 J 的元素个数, 并令 $\mathbf{P} \in \mathbb{R}^{n \times m}$ 为 $\mathbf{e}_j, j \in J$ 按 j 的大小次序从左到右排成的矩阵, 则 $\mathbf{P}$ 列满秩, 且 $\mathbf{P}^T \mathbf{M} \mathbf{P}$ 即为所有 $m_{ij} (i \in J, j \in J)$ 排成的 $\mathbf{M}$ 的子矩阵. 由之前的结果可知该子矩阵正定. $\square$

最后, 我们介绍矩阵的**奇异值分解** (singular value decomposition).

定理 A.9. 设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{A}$ 的秩为 r . 则存在向量 $\mathbf{u}_1, \dots, \mathbf{u}_r \in \mathbb{R}^m, \mathbf{v}_1, \dots, \mathbf{v}_r \in \mathbb{R}^n$ 以及正实数 $\sigma_1, \dots, \sigma_r$, 使得

1. $\mathbf{u}_1, \dots, \mathbf{u}_r$ 相互正交, 且 $\mathbf{u}_i^\top \mathbf{u}_i = 1, \forall i = 1, \dots, r$.
2. $\mathbf{v}_1, \dots, \mathbf{v}_r$ 相互正交, 且 $\mathbf{v}_i^\top \mathbf{v}_i = 1, \forall i = 1, \dots, r$.
3. $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 为矩阵 $\mathbf{A}^\top \mathbf{A}$ 的 r 个不为零的特征值, 同时也是 $\mathbf{A} \mathbf{A}^\top$ 的 r 个不为零的特征值.
4. 矩阵 $\mathbf{A}$ 可分解为

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top \quad (\text{A.4})$$

定理 A.9 的证明可参考 [37] 第 7.4 节. 我们将式 (A.4) 的右端称为矩阵 $\mathbf{A}$ 的**奇异值分解**, 而将 $\sigma_1, \dots, \sigma_r$ 称为 $\mathbf{A}$ 的**奇异值** (singular value). 注意矩阵的奇异值分解并不要求矩阵是方阵. 矩阵的奇异值分解还可以有其它表示形式, 例如

- 式 (A.4) 可等价写为

$$\mathbf{A} = \mathbf{U}_c \Sigma_c \mathbf{V}_c^\top, \quad (\text{A.5})$$

其中 $\mathbf{U}_c \in \mathbb{R}^{m \times r}$ 的各个列向量分别为 $\mathbf{u}_1, \dots, \mathbf{u}_r$, $\mathbf{V}_c \in \mathbb{R}^{n \times r}$ 的各个列向量分别为 $\mathbf{v}_1, \dots, \mathbf{v}_r$, 而 Σ_c 则为一对角阵, 其对角元为 $\sigma_1, \dots, \sigma_r$.

- 矩阵 $\mathbf{A}$ 的奇异值分解还可写为

$$\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^\top, \quad (\text{A.6})$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times m}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ 为实正交阵, 而

$$\Sigma = \begin{bmatrix} \Sigma_c & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}, \quad \Sigma_c = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \in \mathbb{R}^{r \times r}.$$

附录 B (*) 一般情形的条件期望

本章将对条件期望的一般理论进行简要的介绍. 为了数学上的严格性, 我们先简要介绍一下 Borel 集与 Borel 可测函数的概念.

定义 B.1. 把 $\mathbb{R}^n$ 看作一个样本空间, 将 $\mathbb{R}^n$ 上包含了所有方块的最小的事件域 (σ -代数) 称作 $\mathbb{R}^n$ 的 **Borel 代数** (Borel algebra), 并将其记作 $\mathcal{B}(\mathbb{R}^n)$. 这里的“方块”是指任何能表示成 n 个一维区间的笛卡尔积的集合. 换句话说, 若 $\mathbb{R}^n$ 上的一个事件域 $\mathcal{F} \subseteq 2^{\mathbb{R}^n}$ 包含了所有方块, 则必定有 $\mathcal{B}(\mathbb{R}^n) \subseteq \mathcal{F}$.

Borel 代数 $\mathcal{B}(\mathbb{R}^n)$ 中的元素被称为 **Borel 集**.

可以证明, 所有 $\mathbb{R}^n$ 的开子集、闭子集, 以及可数多个开子集或闭子集经过若干步并集、交集、差集运算所得到的集合都属于 $\mathcal{B}(\mathbb{R}^n)$; 也就是说, 绝大多数常见的 $\mathbb{R}^n$ 的子集都是 Borel 集. 然而, 基于集合论的选择公理, 可以证明存在某些 $\mathbb{R}^n$ 的子集不是 Borel 集, 直观上我们会认为这样的集合是病态的.

定义 B.2. 给定函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 若对任意区间 $I \subseteq \mathbb{R}$, 它在 f 下的原像

$$f^{-1}(I) = \{x \in \mathbb{R}^n \mid f(x) \in I\}$$

都是 $\mathbb{R}^n$ 的 Borel 集, 则称函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是 **Borel 可测的** (Borel measurable).

由于非 Borel 集的存在, 可证明不 Borel 可测的函数也是存在的. 不过以下定理说明, 常见的函数都是 Borel 可测函数; 我们在这里不给出其证明, 感兴趣的读者可参考 [14] 第 13 节的内容.

定理 B.1. 1. 定义在 $\mathbb{R}^n$ 上的连续函数可测.

2. 设 $f, g: \mathbb{R}^n \rightarrow \mathbb{R}$ 为可测函数, 则 $f + g, f - g, f \cdot g, \max\{f, g\}, \min\{f, g\}$ 可测. 若进一步有 $g(x) \neq 0, \forall x$, 则 f/g 可测.

3. Borel 可测函数经过复合后是 Borel 可测的. 例如, 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 与 $g: \mathbb{R} \rightarrow \mathbb{R}$ 是可测的, 则 $g \circ f$ 可测; 又如, 若 $f: \mathbb{R}^m \rightarrow \mathbb{R}, g: \mathbb{R}^n \rightarrow \mathbb{R}$ 与 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ 可测, 则函数 $(x, y) \mapsto h(f(x), g(y))$ 可测.
4. 设 $f_1, f_2, \dots$ 为一列可测函数, 令

$$f_\infty(x) = \begin{cases} \lim_{n \rightarrow \infty} f_n(x), & \text{若极限存在,} \\ 0, & \text{若极限不存在,} \end{cases} \quad \forall x,$$

则 f_∞ 可测.

此外也可以证明, 若 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 为 Borel 可测函数, 那么对任意 n 个随机变量 $X_1, \dots, X_n$, 将 g 作用于它们得到的 $g(X_1, \dots, X_n)$ 也必定是随机变量.

在条件期望的一般理论中, 一些技术细节会对函数的 Borel 可测性有要求. 本讲义不会对这些技术细节进行展开, 但为了严格起见, 本章其余内容中, 一旦谈到函数 (包括一元与多元函数) 则都是指 Borel 可测函数.

B.1 一般情形条件期望的定义

我们首先给出如下两个命题, 来铺垫一般情形下条件期望的定义.

命题 B.2. 设 (X, Y) 为离散型或连续型随机向量, 且 $\mathbb{E}[X]$ 存在. $\phi_X(Y)$ 为满足定义 4.5 的 $\mathbb{E}[X|Y]$ 的一个版本. 则对任意有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 均有

$$\mathbb{E}[\phi_X(Y) \cdot g(Y)] = \mathbb{E}[X \cdot g(Y)]. \quad (\text{B.1})$$

证明. 这里只给出 (X, Y) 为连续型随机向量时的证明; 离散情形的证明是类似的.

记 $U = \{y \in \mathbb{R} \mid f_Y(y) = 0\}$. 利用期望的 LOTUS, 可得

$$\begin{aligned} \mathbb{E}[\phi_X(Y) \cdot g(Y)] &= \int_{-\infty}^{+\infty} \phi_X(y) g(y) \cdot f_Y(y) dy \\ &= \int_{y: f_Y(y) > 0} \left(\int_{-\infty}^{+\infty} x \cdot \frac{f_{X,Y}(x, y)}{f_Y(y)} dx \right) g(y) \cdot f_Y(y) dy \\ &= \iint_{\mathbb{R}^2} x \cdot g(y) \cdot \mathbf{1}_{\mathbb{R} \setminus U}(y) \cdot f_{X,Y}(x, y) dx dy \\ &= \mathbb{E}[X \cdot g(Y) \cdot \mathbf{1}_{\{Y \notin U\}}], \end{aligned}$$

其中第三步将累次积分化为重积分. 接下来, 注意到

$$\mathbb{P}(1_{\{Y \in U\}} = 1) = \mathbb{P}(Y \in U) = \int_U f_Y(y) dy = 0,$$

这意味着随机变量 $1_{\{Y \in U\}}$ 几乎必然等于 0, 因此 $X \cdot g(Y) \cdot 1_{\{Y \in U\}}$ 也几乎必然等于 0, 从而有

$$\mathbb{E}[X \cdot g(Y) \cdot 1_{\{Y \in U\}}] = 0.$$

最终可得

$$\begin{aligned} \mathbb{E}[\phi_X(Y) \cdot g(Y)] &= \mathbb{E}[X \cdot g(Y) \cdot 1_{\{Y \notin U\}}] \\ &= \mathbb{E}[X \cdot g(Y) \cdot 1_{\{Y \notin U\}}] + \mathbb{E}[X \cdot g(Y) \cdot 1_{\{Y \in U\}}] \\ &= \mathbb{E}[X \cdot g(Y)]. \end{aligned}$$

命题得证. □

命题 B.3. 设 X, Y 为两个随机变量, 且 $\mathbb{E}[X]$ 存在. $\phi_{X,1}, \phi_{X,2} : \mathbb{R} \rightarrow \mathbb{R}$ 为两个函数, 使得对任意有界函数 $g : \mathbb{R} \rightarrow \mathbb{R}$, 均有

$$\mathbb{E}[\phi_{X,1}(Y) \cdot g(Y)] = \mathbb{E}[\phi_{X,2}(Y) \cdot g(Y)] = \mathbb{E}[X \cdot g(Y)],$$

则

$$\mathbb{P}(\phi_{X,1}(Y) = \phi_{X,2}(Y)) = 1.$$

证明. 令 $h(y) = \phi_{X,1}(y) - \phi_{X,2}(y)$, 则由命题条件可得, 对任意有界函数 $g : \mathbb{R} \rightarrow \mathbb{R}$, 有

$$\mathbb{E}[h(Y) \cdot g(Y)] = 0.$$

若 h 本身也是有界函数, 则可以直接令 $g = h$ 得到 $\mathbb{E}[h(Y)^2] = 0$, 再由定理 3.12 可得 $\mathbb{P}(h(Y) = 0) = 1$. 若 h 不是有界函数, 则需要用期望的单调收敛定理 (超出本讲义范围, 读者可参阅 [3, 14] 等文献) 来处理, 这里不做详细展开而只是给出大致思路: 首先令

$$h_n(y) = \begin{cases} |h(y)|, & \text{若 } |h(y)| \leq n, \\ 0, & \text{若 } |h(y)| > n. \end{cases}$$

则将 $g(y) = \text{sgn}(h(y)) \cdot h_n(y)$ 代入 $\mathbb{E}[h(Y) \cdot g(Y)] = 0$ 即可得到¹

$$\mathbb{E}[|h(Y)| \cdot h_n(Y)] = \mathbb{E}[h_n(Y)^2] = 0.$$

再由期望的单调收敛定理, 得 $\mathbb{E}[|h(Y)|^2] = \lim_{n \rightarrow \infty} \mathbb{E}[h_n(Y)^2] = 0$, 故 $\mathbb{P}(h(Y) = 0) = 1$. □

¹ sgn 为符号函数, 满足 $x \neq 0$ 时 $\text{sgn}(x) = x/|x|$, 而 $x = 0$ 时 $\text{sgn}(x) = 0$.

命题 B.2 与 B.3 指出, 式 (B.1) 实际上可以看成是条件期望的定义性性质: 定义 4.5 给出的条件期望满足式 (B.1), 而满足式 (B.1) 的随机变量 $\phi_X(Y)$ 又在几乎必然相等的意义下是唯一的². 此外, 无论 (X, Y) 服从怎样的联合分布, 只要 $\mathbb{E}[X]$ 存在且 g 有界, 则式 (B.1) 总是有意义的. 因此我们可以基于式 (B.1) 来定义一般情形的条件期望.

定义 B.3. 设 X, Y 为两个随机变量, 且 $\mathbb{E}[X]$ 存在, $\phi_X: \mathbb{R} \rightarrow \mathbb{R}$ 为一函数. 若对任意有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 均有

$$\mathbb{E}[\phi_X(Y) \cdot g(Y)] = \mathbb{E}[X \cdot g(Y)], \quad (\text{B.1})$$

则称 $\phi_X(Y)$ 为给定 Y 的条件下 X 的条件期望的一个版本 (version), 记作 $\mathbb{E}[X|Y] = \phi_X(Y)$, 并对任意 $y \in \mathbb{R}$, 记 $\mathbb{E}[X|Y=y] = \phi_X(y)$.

定义 B.3 中并未对条件期望进行具体构造. 在高等概率论中, 条件期望的构造一般是通过实分析理论中的 Radon-Nikodym 定理, 或是在函数空间上对 L^2 范数进行最小化得到的, 本讲义不对其进行展开, 感兴趣的读者可参考 [3] 第 9 章的内容, 或 [14] 第 32 与 34 节的内容. 最终可以证明, 对任意随机变量 X, Y , 只要 $\mathbb{E}[X]$ 存在, 那么条件期望 $\mathbb{E}[X|Y]$ 必定存在.

至此, 我们给出对条件期望 $\mathbb{E}[X|Y]$ 的一般性定义. 这里再补充说明几点:

1. 由于条件期望通常有多个版本, 但在几乎必然相等的意义下又是唯一的, 故经常会用形如

$$f(\mathbb{E}[X|Y], \mathbb{E}[Z|W]) = 0 \quad \text{a.s.}$$

的写法, 来表示任取 $\mathbb{E}[X|Y]$ 的一个版本 $\phi_X(Y)$ 与 $\mathbb{E}[Z|W]$ 的一个版本 $\phi_Z(W)$ 后, 等式 $f(\phi_X(Y), \phi_Z(W)) = 0$ 几乎必然成立, 其中 a.s. 是 almost surely 的缩写. 而当条件期望外面又套了一层期望 $\mathbb{E}[\cdot]$ 之后, 许多情况下该期望的值就不依赖于条件期望版本的选择了, 此时就直接写作

$$\mathbb{E}[f(\mathbb{E}[X|Y], \mathbb{E}[Z|W])] = 0$$

等等.

² 讲义正文中给出的条件期望的定义 (定义 4.5) 也只能保证条件期望在几乎必然相等意义下的唯一性, 而不能保证绝对的唯一性.

2. 给定随机变量 Y 的条件下, 事件 E 的条件概率可通过

$$\mathbb{P}(E|Y) = \mathbb{E}[1_E|Y]$$

来定义, 也就是说, 我们把条件概率作为条件期望的一种特殊情形处理. 注意到最原始的条件概率的定义 1.3 与上式定义的条件概率有如下联系:

$$\mathbb{P}(E|1_F)(\omega) = \begin{cases} \mathbb{P}(E|F), & \text{若 } \omega \in F, \\ \mathbb{P}(E|F^c), & \text{若 } \omega \in F^c, \end{cases}$$

其中假定 $0 < \mathbb{P}(F) < 1$. 也就是说, 随机变量 $\mathbb{P}(E|1_F)$ 在 F 发生时等于 $\mathbb{P}(E|F)$, 而在 F 不发生时等于 $\mathbb{P}(E|F^c)$.

3. 利用勒贝格积分的微分理论 (不要求读者了解, 可参见 [38] 第 7 章) 可证明, 若令 φ 为

$$\varphi_X(y) = \begin{cases} \lim_{\epsilon \rightarrow 0^+} \mathbb{E}[X | |Y - y| \leq \epsilon], & \text{若该极限存在,} \\ 0, & \text{其它情况,} \end{cases}$$

则有 $\mathbb{E}[X|Y] = \varphi_X(Y)$, 即 $\mathbb{E}[X|Y = y] = \varphi_X(y)$. 这意味着我们可以将 $\mathbb{E}[X|Y = y]$ 不严格地理解为 $\epsilon > 0$ 非常小时, X 在 $\{|Y - y| \leq \epsilon\}$ 条件下的条件期望.

B.2 条件期望的性质

本节将对定理 4.15 列出的部分条件期望的性质给出一般性的证明.

定理 B.4. 设 X, Y, Z 为随机变量, 且 $\mathbb{E}[X], \mathbb{E}[Y]$ 存在, 则如下命题成立:

1. 线性: 对任意实数 α, β , 有

$$\mathbb{E}[\alpha X + \beta Y | Z] = \alpha \mathbb{E}[X | Z] + \beta \mathbb{E}[Y | Z] \quad \text{a.s.}$$

2. 若 $X \geq 0$ 几乎必然成立, 则 $\mathbb{E}[X | Z] \geq 0$ 几乎必然成立.

3. 全期望公式:

$$\mathbb{E}[\mathbb{E}[X | Z]] = \mathbb{E}[X].$$

4. 若函数 $h: \mathbb{R} \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[h(Z)X]$ 存在, 则

$$\mathbb{E}[h(Z)X | Z] = h(Z) \mathbb{E}[X | Z] \quad \text{a.s.}$$

5. 若 X 与 Z 相互独立, 则

$$\mathbb{E}[X|Z] = \mathbb{E}[X] \quad \text{a.s.}$$

证明. 1. 为证明条件期望的线性, 只需证明 $\alpha \mathbb{E}[X|Z] + \beta \mathbb{E}[Y|Z]$ (式中条件期望的版本任取) 能够给出 $\mathbb{E}[\alpha X + \beta Y|Z]$ 的一个版本即可. 显然 $\alpha \mathbb{E}[X|Z] + \beta \mathbb{E}[Y|Z]$ 依然是随机变量 Z 的一个函数. 现取有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 则

$$\begin{aligned} & \mathbb{E}[(\alpha \mathbb{E}[X|Z] + \beta \mathbb{E}[Y|Z]) \cdot g(Z)] \\ &= \alpha \mathbb{E}[\mathbb{E}[X|Z] \cdot g(Z)] + \beta \mathbb{E}[\mathbb{E}[Y|Z] \cdot g(Z)] \\ &= \alpha \mathbb{E}[X \cdot g(Z)] + \beta \mathbb{E}[Y \cdot g(Z)] \\ &= \mathbb{E}[(\alpha X + \beta Y) \cdot g(Z)], \end{aligned}$$

其中第二步用到了(非条件)期望的线性, 第三步则来自于 $\mathbb{E}[X|Z]$ 与 $\mathbb{E}[Y|Z]$ 作为条件期望的定义, 第四步又再次利用了(非条件)期望的线性. 由有界函数 g 的任意性, 可得 $\alpha \mathbb{E}[X|Z] + \beta \mathbb{E}[Y|Z]$ 给出了 $\mathbb{E}[\alpha X + \beta Y|Z]$ 的一个版本.

2. 采用反证法, 若 $\mathbb{P}(\mathbb{E}[X|Z] < 0) > 0$, 则由概率的单调性, 可知存在 $\epsilon > 0$ 使得 $\mathbb{P}(\mathbb{E}[X|Z] < -\epsilon) > 0$. 再令 $g(Z) = \mathbf{1}_{\{\mathbb{E}[X|Z] < -\epsilon\}}$, 则

$$\mathbb{E}[\mathbb{E}[X|Z] \cdot g(Z)] \leq \mathbb{E}[(-\epsilon) \cdot \mathbf{1}_{\{\mathbb{E}[X|Z] < -\epsilon\}}] = -\epsilon \mathbb{P}(\mathbb{E}[X|Z] < -\epsilon) < 0,$$

但由于 $X \cdot g(Z) \geq 0$ a.s., 故

$$\mathbb{E}[X \cdot g(Z)] \geq 0,$$

与 $\mathbb{E}[X \cdot g(Z)] = \mathbb{E}[\mathbb{E}[X|Z] \cdot g(Z)]$ 相矛盾.

3. 直接令 g 为取值为 1 的常函数并代入式 (B.1) 中即可.

4. 先假设 h 本身为有界函数. 任取有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 则有

$$\begin{aligned} \mathbb{E}[(h(Z) \mathbb{E}[X|Z]) \cdot g(Z)] &= \mathbb{E}[\mathbb{E}[X|Z] \cdot (h(Z)g(Z))] \\ &= \mathbb{E}[X \cdot (h(Z)g(Z))] \\ &= \mathbb{E}[(h(Z)X) \cdot g(Z)] \end{aligned}$$

其中第二步利用了 $\mathbb{E}[X|Z]$ 的定义并注意到 $h \cdot g$ 为有界函数. 再由有界函数 g 的任意性, 可得 $h(Z) \cdot \mathbb{E}[X|Z]$ 为 $\mathbb{E}[h(Z)X|Z]$ 的一个版本.

对于一般情形的函数 h , 需要取用一系列有界函数 $h_1, h_2, \dots$ 对 h 进行逼近, 则有

$$\mathbb{E}[h_n(Z) \mathbb{E}[X|Z] \cdot g(Z)] = \mathbb{E}[(h_n(Z)X) \cdot g(Z)],$$

再用期望的控制收敛定理(超出本讲义范围,读者可参阅 [3, 14] 等文献)取 $n \rightarrow \infty$ 的极限即可. 具体的步骤这里略去.

5. 显然 $\mathbb{E}[X]$ 可以看成 Z 的一个常函数. 而对任意有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 有

$$\mathbb{E}[X \cdot g(Z)] = \mathbb{E}[X] \cdot \mathbb{E}[g(Z)] = \mathbb{E}[\mathbb{E}[X] \cdot g(Z)],$$

其中我们用到了 X 与 $g(Z)$ 的独立性. 故 $\mathbb{E}[X]$ 给出了 $\mathbb{E}[X|Z]$ 的一个版本. $\square$

B.3 条件期望的计算

本节中, 我们给出 (X, Y) 为离散型或连续型随机向量时, 条件期望 $\mathbb{E}[h(X, Y)|Y]$ 的计算方法, 也就是条件期望的 law of the unconscious statistician (LOTUS).

定理 B.5. 设 X, Y 为两个随机变量, 二元函数 $h: \mathbb{R}^2 \rightarrow \mathbb{R}$ 使得 $\mathbb{E}[h(X, Y)]$ 存在, 且对任意 $y \in \mathbb{R}$, $\mathbb{E}[h(X, y)]$ 均存在.

1. 若 (X, Y) 为离散型随机向量, 令

$$\phi_X(y) = \begin{cases} \sum_x h(x, y) \cdot \frac{p_{X,Y}(x, y)}{p_Y(y)}, & \text{若 } p_Y(y) > 0, \\ \mathbb{E}[h(X, y)], & \text{若 } p_Y(y) = 0. \end{cases} \quad (\text{B.2})$$

则 $\mathbb{E}[h(X, Y)|Y] = \phi_X(Y)$.

2. 若 (X, Y) 为连续型随机向量, 令

$$\phi_X(y) = \begin{cases} \int_{-\infty}^{+\infty} h(x, y) \cdot \frac{f_{X,Y}(x, y)}{f_Y(y)} dx, & \text{若 } f_Y(y) > 0, \\ \mathbb{E}[h(X, y)], & \text{若 } f_Y(y) = 0. \end{cases} \quad (\text{B.3})$$

则 $\mathbb{E}[h(X, Y)|Y] = \phi_X(Y)$.

证明. 证明的基本思路就是验证式 (B.2) 或式 (B.3) 给出的 $\phi_X(Y)$ 是否满足条件期望的定义式 (B.1).

1. 当 (X, Y) 为离散型随机向量时, 任取有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 则有

$$\begin{aligned}
 \mathbb{E}[\phi_X(Y) \cdot g(Y)] &= \sum_y \phi_X(y) g(y) p_Y(y) \\
 &= \sum_y \left(\sum_x h(x, y) \cdot \frac{p_{X,Y}(x, y)}{p_Y(y)} \right) g(y) p_Y(y) \\
 &= \sum_{(x,y)} h(x, y) g(y) p_{X,Y}(x, y) \\
 &= \mathbb{E}[h(X, Y) \cdot g(Y)],
 \end{aligned}$$

其中第一步与最后一步来自于期望的 LOTUS, 第三步是因为 $p_Y(y) = 0$ 时必定有 $p_{X,Y}(x, y) = 0$. 故式 (B.1) 对任意有界函数 g 均成立.

2. 当 (X, Y) 为连续型随机向量时, 记集合 $U = \{y \in \mathbb{R} \mid f_Y(y) = 0\}$, 任取有界函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 则有

$$\begin{aligned}
 \mathbb{E}[\phi_X(Y) \cdot g(Y)] &= \int_{-\infty}^{+\infty} \phi_X(y) g(y) f_Y(y) dy \\
 &= \int_{\mathbb{R} \setminus U} \left(\int_{-\infty}^{+\infty} h(x, y) \cdot \frac{f_{X,Y}(x, y)}{f_Y(y)} dx \right) g(y) f_Y(y) dy \\
 &= \iint_{\mathbb{R}^2} h(x, y) g(y) \mathbf{1}_{\mathbb{R} \setminus U}(y) f_{X,Y}(x, y) dx dy \\
 &= \mathbb{E}[h(X, Y) \cdot g(Y) \cdot \mathbf{1}_{\{Y \notin U\}}],
 \end{aligned}$$

其中第一步与最后一步来自于期望的 LOTUS, 第三步将累次积分化为了重积分. 最后, 利用与命题 B.2 的证明中类似的步骤, 可得 $\mathbb{E}[h(X, Y) \cdot g(Y) \cdot \mathbf{1}_{\{Y \in U\}}] = 0$, 并进一步得到式 (B.1) 对任意有界函数 g 均成立. $\square$

附录 C (*) 假设检验的补充证明

C.1 p 值法与拒绝域法的等价性

首先对假设检验的 p 值法与拒绝域法进行简要回顾. 令 θ 为未知参数, 并考虑如下假设检验问题:

$$H_0 : \theta \in \Theta_0, \quad H_1 : \theta \in \Theta_1. \quad (\text{C.1})$$

设 $T = \phi(X_1, \dots, X_n)$ 为该问题的检验统计量, 它满足如下条件:

条件 C.1. T 在原假设 H_0 下的分布是与 $\theta \in \Theta_0$ 的具体取值无关的. 换句话说, 对任意 $\theta \in \Theta_0$, T 均服从同一个分布.

令 $t = \phi(x_1, \dots, x_n)$ 为 T 在代入样本观测值 $x_1, \dots, x_n$ 后的取值. 则相应的 p 值为

- 单侧检验: $\hat{p}(x_1, \dots, x_n) = \mathbb{P}_{H_0}(T \geq t)$;
- 双侧检验: $\hat{p}(x_1, \dots, x_n) = 2 \min\{\mathbb{P}_{H_0}(T \geq t), \mathbb{P}_{H_0}(T \leq t)\}$.

而给定显著性水平 $\alpha \in]0, 1[$ 后, 相应的拒绝域 C_α 为

- 单侧检验: $C_\alpha =]c_\alpha, +\infty[$, 其中

$$c_\alpha = \max\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\}; \quad (\text{C.2})$$

- 双侧检验: $C_\alpha =]-\infty, c_\alpha^l[\cup]c_\alpha^u, +\infty[$, 其中

$$\begin{aligned} c_\alpha^u &= \max\left\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \frac{\alpha}{2}\right\}, \\ c_\alpha^l &= \min\left\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \leq c) \geq \frac{\alpha}{2}\right\}. \end{aligned} \quad (\text{C.3})$$

为使得临界值的表达式 (C.2) 与 (C.3) 有意义, 须要求形如 $\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\}$ 的集合非空且有有限的最大值, 而这可由如下引理保证:

引理 C.1. 设 Y 为任一随机变量, 则任取 $\alpha \in]0, 1[$, 均存在 $y_\alpha \in \mathbb{R}$, 使得

$$\{y \in \mathbb{R} \mid \mathbb{P}(Y \geq y) \geq \alpha\} =]-\infty, y_\alpha].$$

证明. 注意到 $\mathbb{P}(Y \geq y)$ 可看成 $-Y$ 的分布函数在 $-y$ 处的取值, 故由分布函数的基本性质, 可得 (i) $\mathbb{P}(Y \geq y)$ 关于 y 单调递减; (ii) $y \rightarrow +\infty$ 时 $\mathbb{P}(Y \geq y) \rightarrow 0$, 而 $y \rightarrow -\infty$ 时 $\mathbb{P}(Y \geq y) \rightarrow 1$; (iii) $\mathbb{P}(Y \geq y)$ 关于 y 左连续.

接下来, 记

$$S_\alpha = \{y \in \mathbb{R} \mid \mathbb{P}(Y \geq y) \geq \alpha\}.$$

由于 $\alpha < 1$ 且 $y \rightarrow -\infty$ 时 $\mathbb{P}(Y \geq y) \rightarrow 1$, 故集合 S_α 非空. 再令

$$y_\alpha = \sup S_\alpha = \sup\{y \in \mathbb{R} \mid \mathbb{P}(Y \geq y) \geq \alpha\}.$$

则由 $\alpha > 0$ 以及 $y \rightarrow +\infty$ 时 $\mathbb{P}(Y \geq y) \rightarrow 0$, 可得 $y_\alpha < +\infty$. 而由上确界的定义, 可知对任意 $s < y_\alpha$, 均存在 $s' > s$ 使得 $s' \in S_\alpha$, 从而

$$\mathbb{P}(Y \geq s) \geq \mathbb{P}(Y \geq s') \geq \alpha,$$

其中第一个不等号来自 $\mathbb{P}(Y \geq s)$ 关于 s 的单调性, 而第二个不等号则是因为 $s' \in S_\alpha$. 上式意味着 $s < y_\alpha$ 时必定有 $s \in S_\alpha$, 从而 S_α 只可能取 $]-\infty, y_\alpha]$ 或 $]-\infty, y_\alpha[$ 的形式. 最后, 由

$$\mathbb{P}(Y \geq s) \geq \alpha, \quad \forall s < y_\alpha,$$

令 s 从左侧趋向 y_α 并利用 $\mathbb{P}(Y \geq y)$ 关于 y 的左连续性, 可得

$$\mathbb{P}(Y \geq y_\alpha) \geq \alpha,$$

即 $y_\alpha \in S_\alpha$, 故 $S_\alpha =]-\infty, y_\alpha]$, 引理得证. □

接下来我们将证明 p 值法与拒绝域法是等价的.

定理 C.2. 设 T 为假设检验问题 (C.1) 的检验统计量, 且条件 C.1 成立. 则对任意样本观测值 $x_1, \dots, x_n$ 与显著性水平 $\alpha \in]0, 1[$, 均有

$$\hat{p}(x_1, \dots, x_n) < \alpha \iff \phi(x_1, \dots, x_n) \in C_\alpha.$$

证明. 首先考虑单侧检验的情形, 我们分别证明等价性的两个方向.

- “ $\Leftarrow$ ” 方向: 设 $\phi(x_1, \dots, x_n) \in C_\alpha$, 也即

$$\phi(x_1, \dots, x_n) > c_\alpha = \max\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\}.$$

上式意味着 $\phi(x_1, \dots, x_n) \notin \{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\}$, 从而

$$\mathbb{P}_{H_0}(T \geq \phi(x_1, \dots, x_n)) < \alpha,$$

也即 $\hat{p}(x_1, \dots, x_n) < \alpha$.

- “ $\Rightarrow$ ” 方向: 设 $\hat{p}(x_1, \dots, x_n) < \alpha$, 也就是说

$$\mathbb{P}_{H_0}(T \geq \phi(x_1, \dots, x_n)) < \alpha.$$

该不等式意味着

$$\phi(x_1, \dots, x_n) \notin \{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\}.$$

而由引理 C.1 可得 $\{c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \alpha\} =]-\infty, c_\alpha]$, 故由上式可得

$$\phi(x_1, \dots, x_n) > c_\alpha.$$

由此我们建立了条件 C.1 下单侧检验 p 值法与拒绝域法的等价性.

接下来考虑双侧检验. 此时由 p 值的定义可得

$$\begin{aligned} \hat{p}(x_1, \dots, x_n) &= 2 \min \{ \mathbb{P}_{H_0}(T \geq t), \mathbb{P}_{H_0}(T \leq t) \} < \alpha \\ \iff \mathbb{P}_{H_0}(T \geq t) &< \frac{\alpha}{2} \text{ 或 } \mathbb{P}_{H_0}(T \leq t) < \frac{\alpha}{2}. \end{aligned}$$

而仿照单侧检验的证明过程, 不难得到

$$\mathbb{P}_{H_0}(T \geq t) < \frac{\alpha}{2} \iff \phi(x_1, \dots, x_n) > \max \left\{ c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \geq c) \geq \frac{\alpha}{2} \right\} = c_\alpha^u$$

以及

$$\mathbb{P}_{H_0}(T \leq t) < \frac{\alpha}{2} \iff \phi(x_1, \dots, x_n) < \min \left\{ c \in \mathbb{R} \mid \mathbb{P}_{H_0}(T \leq c) \geq \frac{\alpha}{2} \right\} = c_\alpha^l.$$

综上所述可得

$$\hat{p}(x_1, \dots, x_n) < \alpha \iff \phi(x_1, \dots, x_n) > c_\alpha^u \text{ 或 } \phi(x_1, \dots, x_n) < c_\alpha^l,$$

从而对于双侧检验, 在条件 C.1 下 p 值法与拒绝域法也是等价的. $\square$

C.2 显著性水平与第 I 类错误概率的关系

本节中我们证明, 在条件 C.1 下, 显著性水平 α 给出了第 I 类错误概率的上界, 且当 T 在原假设 H_0 下为连续型随机变量时, 显著性水平 α 就等于第 I 类错误概率.

定理 C.3. 设 T 为假设检验问题 (C.1) 的检验统计量, 且条件 C.1 成立, $\hat{p}: \mathbb{R}^n \rightarrow \mathbb{R}$ 为将样本值映射到 p 值的函数, $\alpha \in]0, 1[$ 为给定的显著性水平, C_α 为相应的拒绝域. 则

$$\mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) = \mathbb{P}_{H_0}(T \in C_\alpha) \leq \alpha.$$

特别是, 若 T 在原假设 H_0 下为连续型随机变量, 则

$$\mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) = \mathbb{P}_{H_0}(T \in C_\alpha) = \alpha,$$

从而随机变量 $\hat{p}(X_1, \dots, X_n)$ 服从 $[0, 1]$ 上的均匀分布.

为了证明定理 C.3, 我们首先给出如下引理:

引理 C.4. 设 Y 为一随机变量, $q(y) = \mathbb{P}(Y \geq y)$, $y \in \mathbb{R}$. 则

$$\mathbb{P}(q(Y) < \alpha) \leq \alpha, \quad \forall \alpha \in]0, 1[.$$

特别是, 若 Y 为连续型随机变量, 则

$$\mathbb{P}(q(Y) < \alpha) = \alpha, \quad \forall \alpha \in]0, 1[.$$

从而 $q(Y)$ 服从 $[0, 1]$ 上的均匀分布.

证明. 定义函数 $q_+^{-1}:]0, 1[\rightarrow \mathbb{R}$ 为

$$q_+^{-1}(\alpha) = \max\{y \in \mathbb{R} \mid q(y) \geq \alpha\}, \quad \alpha \in]0, 1[.$$

则不难由 q 的单调性得到 $q_+^{-1}(\alpha)$ 关于 α 单调递减. 此外, 由引理 C.1 得

$$\{y \in \mathbb{R} \mid q(y) \geq \alpha\} =]-\infty, q_+^{-1}(\alpha)], \quad (\text{C.4})$$

从而 $y > q_+^{-1}(\alpha)$ 当且仅当 $q(y) < \alpha$, 故

$$\mathbb{P}(q(Y) < \alpha) = \mathbb{P}(Y > q_+^{-1}(\alpha)) = q(q_+^{-1}(\alpha) + 0),$$

其中 $q(q_+^{-1}(\alpha) + 0)$ 表示 $q(y)$ 在 y 从右侧趋向于 $q_+^{-1}(\alpha)$ 时的右极限. 而另一方面, 由式 (C.4) 可得, 当 $y > q_+^{-1}(\alpha)$ 时有 $q(y) < \alpha$, 故令 y 从右侧趋向于 $q_+^{-1}(\alpha)$ 并由极限的保号性可得 $q(q_+^{-1}(\alpha) + 0) \leq \alpha$, 从而

$$\mathbb{P}(q(Y) < \alpha) \leq \alpha.$$

而若 Y 为连续型随机变量, 则有

$$\mathbb{P}(q(Y) < \alpha) = \mathbb{P}(Y > q_+^{-1}(\alpha)) = \mathbb{P}(Y \geq q_+^{-1}(\alpha)) = q(q_+^{-1}(\alpha)) \geq \alpha,$$

其中第二个等号用到了 Y 服从连续型分布, 而最后一步不等号则是因为式 (C.4) 意味着 $q_+^{-1}(\alpha) \in \{y \in \mathbb{R} \mid q(y) \geq \alpha\}$. 故 $\alpha \leq \mathbb{P}(q(Y) < \alpha) \leq \alpha$, 从而 $\mathbb{P}(q(Y) < \alpha) = \alpha$. $\square$

在得到引理 C.4 后, 定理 C.3 则可看成它的一个推论.

证明 (定理 C.3). 记 $q(y) = \mathbb{P}_{H_0}(T \geq y)$. 对于单侧检验的情形, 有

$$\hat{p}(x_1, \dots, x_n) = q(\phi(x_1, \dots, x_n)),$$

即 $\hat{p}(X_1, \dots, X_n) = q(T)$, 接下来由引理 C.4 即可得

$$\mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) = \mathbb{P}_{H_0}(q(T) < \alpha) \leq \alpha,$$

而若 T 在原假设 H_0 下为连续型随机变量, 则有

$$\mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) = \mathbb{P}_{H_0}(q(T) < \alpha) = \alpha.$$

对于双侧检验的情形, 进一步令 $q'(y) = \mathbb{P}_{H_0}(-T \geq y)$, 则有

$$\hat{p}(x_1, \dots, x_n) = 2 \min \{q(\phi(x_1, \dots, x_n)), q'(-\phi(x_1, \dots, x_n))\},$$

从而

$$\begin{aligned} \mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) &= \mathbb{P}_{H_0}(2 \min \{q(T), q'(-T)\} < \alpha) \\ &= \mathbb{P}_{H_0}\left(q(T) < \frac{\alpha}{2} \text{ 或 } q'(-T) < \frac{\alpha}{2}\right) \\ &\leq \mathbb{P}_{H_0}\left(q(T) < \frac{\alpha}{2}\right) + \mathbb{P}_{H_0}\left(q'(-T) < \frac{\alpha}{2}\right) \\ &\leq \frac{\alpha}{2} + \frac{\alpha}{2} = \alpha, \end{aligned}$$

其中最后一个不等号来自于引理 C.4. 而若 T 为连续型随机变量, 则由于

$$q(y) < \frac{\alpha}{2} \implies \mathbb{P}(Y \geq y) < \frac{1}{2},$$

而

$$\begin{aligned} q'(-y) < \frac{\alpha}{2} &\implies \mathbb{P}(-Y \geq -y) < \frac{1}{2} \\ &\implies \mathbb{P}(Y \geq y) = 1 - \mathbb{P}(-Y \geq -y) > \frac{1}{2}, \end{aligned}$$

故 $q(y) < \alpha/2$ 与 $q'(-y) < \alpha/2$ 不能同时成立, 从而

$$\begin{aligned} \mathbb{P}_{H_0}(\hat{p}(X_1, \dots, X_n) < \alpha) &= \mathbb{P}_{H_0}\left(q(T) < \frac{\alpha}{2} \text{ 或 } q'(-T) < \frac{\alpha}{2}\right) \\ &= \mathbb{P}_{H_0}\left(q(T) < \frac{\alpha}{2}\right) + \mathbb{P}_{H_0}\left(q'(-T) < \frac{\alpha}{2}\right) \\ &= \frac{\alpha}{2} + \frac{\alpha}{2} = \alpha. \end{aligned}$$

定理证毕. □

参考文献

- [1] KOLMOGOROFF A. Grundbegriffe der Wahrscheinlichkeitsrechnung[M]. Springer Berlin, Heidelberg, 1933. English Ed.: KOLMOGOROV A N. Foundations of the theory of probability[M]. Dover Publications, Inc., 2018.
- [2] BERNARDO J M, SMITH A F M. Bayesian theory[M]. John Wiley & Sons, Ltd., 2000.
- [3] WILLIAMS D. Probability with martingales[M]. Cambridge University Press, 1991.
- [4] ROSS S. A first course in probability[M]. 10th ed. Pearson Education Limited, 2020.
- [5] CHUNG K L, AITSAHLIA F. Elementary probability theory[M]. Springer, 2003.
- [6] BERTSEKAS D P, TSITSIKLIS J N. Introduction to probability[M]. 2nd ed. Athena Scientific, 2008.
- [7] HARCHOL-BALTER M. Introduction to probability for computing[M]. Cambridge University Press, 2024.
- [8] GRIMMETT G R, STIRZAKER D R. Probability and random processes[M]. 3rd ed. Oxford University Press, 2001.
- [9] 张筑生. 数学分析新讲: 第三册[M]. 北京大学出版社, 1991.
- [10] GRIMMETT G, WELSH D. Probability: An introduction[M]. 2nd ed. Oxford University Press, 2014.

- [11] VON NEUMANN J. Various techniques used in connection with random digits[M]// National Bureau of Standards Applied Math Series: Vol. 12 Monte Carlo Methods. 1951: 36-38.
- [12] 陈天权. 数学分析讲义: 第二册[M]. 北京大学出版社, 2010.
- [13] 张筑生. 数学分析新讲: 第二册[M]. 北京大学出版社, 1990.
- [14] BILLINGSLEY P. Probability and measure[M]. 3rd ed. John Wiley & Sons, Inc., 1995.
- [15] FELLER W. An introduction to probability theory and its applications: I[M]. 3rd ed. John Wiley & Sons, Inc., 1968.
- [16] CASELLA G, BERGER R. Statistical inference[M]. 2nd ed. CRC Press, 2024.
- [17] SCHERVISH M J. Theory of statistics[M]. Springer, 1995.
- [18] COX D R, HINKLEY D V. Theoretical statistics[M]. CRC Press, 1974.
- [19] NOCEDAL J, WRIGHT S J. Numerical optimization[M]. 2nd ed. Springer, 2006.
- [20] MCLACHLAN G J, KRISHNAN T. The EM algorithm and extensions[M]. 2nd ed. John Wiley & Sons, Inc., 2008.
- [21] WALPOLE R E, MYERS R H, MYERS S L, et al. Probability and statistics for engineers and scientists[M]. 9th ed. Pearson, 2022.
- [22] DEGROOT M H, SCHERVISH M J. Probability and statistics[M]. 4th ed. Addison-Wesley, 2010.
- [23] JOHNSON N L, KEMP A W, KOTZ S. Univariate discrete distributions[M]. 3rd ed. John Wiley & Sons, Inc., 2005.
- [24] JOHNSON N L, KOTZ S, BALAKRISHNAN N. Continuous univariate distributions: Vol. 2[M]. 2nd ed. John Wiley & Sons, Inc., 1995.
- [25] LINNIK J V. Statistical problems with nuisance parameters[M]. American Mathematical Society, 1968. Translated from the Russian by Scripta Technica.

- [26] SCHEFFÉ H. On solutions of the Behrens–Fisher problem, based on the t -distribution[J]. The Annals of Mathematical Statistics, 1943, 14(1): 35-44.
- [27] DUDEWICZ E J, MISHRA S N. Modern mathematical statistics[M]. John Wiley & Sons, Inc., 1988.
- [28] 许宝騄. Contribution to the theory of “Student’s” t -test as applied to the problem of two samples[J]. Statistical Research Memoirs, 1938, 2: 1-24. 同时收录于《许宝騄文集》, 科学出版社, 1981.
- [29] WELCH B L. Further note on Mrs. Aspin’s tables and on certain approximations to the tabled function[J]. Biometrika, 1949, 36(3/4): 293-296. Appendix to Mrs. Aspin’s paper.
- [30] SCHEFFÉ H. Practical solutions of the Behrens–Fisher problem[J]. Journal of the American Statistical Association, 1970, 65(332): 1501-1508.
- [31] BICKEL P J, DOKSUM K A. Mathematical statistics: Basic ideas and selected topics: Vol. 1[M]. 2nd ed. CRC Press, 2015.
- [32] YOUNG G A, SMITH R L. Essentials of statistical inference[M]. Cambridge University Press, 2005.
- [33] KIRKWOOD A A, COX T, HACKSHAW A. Application of methods for central statistical monitoring in clinical trials[J]. Clinical Trials, 2013, 10(5): 783-806.
- [34] MONTGOMERY D C, PECK E A, VINING G G. Introduction to linear regression analysis[M]. 6th ed. John Wiley & Sons, Inc., 2021.
- [35] TAO T. Analysis I[M]. Hindustan Book Agency, 2015.
- [36] 郑广平, 裘祖干, 陆章基. 线性代数与解析几何[M]. 复旦大学出版社, 2004.
- [37] LAY D C, LAY S R, MCDONALD J J. Linear algebra and its applications[M]. 5th ed. Pearson Education, Inc., 2016.
- [38] RUDIN W. Real and complex analysis[M]. McGraw-Hill, Inc., 1987.