
课程与课题结合说明

北京多站点 PM2.5 浓度的统计推断 · 组员版

北京大学 2026 春季《概率与数理统计》大作业

阅读对象：全体组员 · 约 5 分钟

文档日期：2026 年 5 月 26 日

本文说明课程要求、讲义章节与本课题的对应关系，便于分工与撰写正式报告。Markdown 源文件见 `reference/课程与课题结合说明.md`；重新生成 PDF 请运行：`python scripts/build_course_topic_pdf.py`

一、大作业在考什么？

要求	含义
真实数据 + 统计推断	提出实际问题，用数理统计方法分析，对规律给出推断；不能捏造数据
可复现	助教凭报告 + 代码 + 数据能复现全部图表与数值
报告要素	问题提出 → 概率/统计模型 → 方法介绍 → 数据与预处理 → 结果与讨论 → 参考文献
篇幅	PDF 建议 4–6 页；细节可放代码与 README
拓展实践	建议含动手实践（如 Bootstrap、简单 Monte Carlo 仿真），体现课外自主学习

本选题走「基于实际数据的统计推断」路线，并用 Bootstrap / 仿真满足「动手实践」；不主打机器学习预测。课程要求全文见 [reference/大作业安排.pdf](#)。

二、我们研究什么？

- 数据：UCI Beijing Multi-Site Air Quality，北京 12 个监测站，2013-03-01 至 2017-02-28，小时级；主分析聚合为站点 – 日日均 PM2.5（见 `src/config.py`）。
- 定位：以统计推断为主线（分布 → 区间/检验 → 回归 → 拓展），不是预测比赛。
- 现实意义：PM2.5 关系公众健康与污染治理；2013 – 2017 是北京大气污染治理推进期。讨论可联系政策背景，但须区分相关与因果。

三、讲义章节 ☐ 本课题（核心对照表）

讲义分概率论（第 1–5 章）与数理统计（第 6–10 章）。本课题主要落在第 3–4 章 + 第 6–10 章；第 5 章在拓展部分呼应。

讲义章节	课内知识点	在本课题中的用法
第 3 章 连续型	密度、偏态、重尾	描述 PM2.5 分布；说明不宜直接假定正态；对 $\log(\text{PM2.5}+1)$ 做 QQ 图
第 4.2 节	Pearson / Spearman 相关	分析 PM2.5 与温度、风速、降水等气象变量的关联
第 6 章	总体、样本、统计量； χ^2 、t、F	明确样本 = 站点 – 日观测；构造均值、方差；为估计与检验铺垫
第 8 章	置信区间	估计分季节、分城区/郊区日均 PM2.5 均值的置信区间
第 9 章	检验、方差分析	季节差异（ANOVA）；城区 vs 郊区（Welch t 检验等）
第 9.5 节	非参数检验	Kruskal-Wallis 等，作为右偏数据下参数检验的稳健性补充
第 10 章	线性回归、残差	多元回归： $\log(\text{PM2.5}+1) \sim \text{气象} + \text{季节/站点虚拟变量}$ ；残差诊断
第 5 章（拓展）	大数定律、CLT	Bootstrap 置信区间；可选仿真比较 t 检验在偏态数据下的表现

写报告建议：在「方法介绍」一节用一张小表列出「第 X 章 → 本文用法」，让评阅人看出这是概率统计课作业，而非纯 Python 画图作业。

四、四个研究问题与课程方法的对应

编号	研究问题	主要方法	负责
Q1	日均 PM2.5 分布形态？能否用正态模型？	直方图、QQ 图、描述统计、偏度	B：EDA
Q2	季节、城区/郊区是否有显著差异？	置信区间；ANOVA + Kruskal-Wallis；Welch t	C：推断
Q3	气象因素与 PM2.5 如何关联？	相关分析；多元线性回归 + 残差诊断	C：回归
Q4	重污染日概率是否随季节/区域变化？	比例估计、Wilson 区间；可选 logistic	C + D
拓展	偏态下传统区间是否可靠？	Bootstrap；可选 Monte Carlo 仿真	C

正式报告 4 – 6 页中，Q1 – Q3 占主体；Q4 与 Bootstrap 约占 0.5 – 1 页。

五、与分工的对应

组员	分工	与课程内容的联系
A (rhr)	协调、总进度、仓库	把控报告是否覆盖问题 – 模型 – 方法 – 数据 – 结果 – 文献全链条
B	预处理、EDA、data/process ed/	落实第 6 章「样本」定义：日均聚合、缺失处理（每天至少 18 有效小时）
C	推断与回归	第 8 – 10 章 + 9.5 节 + Bootstrap；输出 reports/tables、figures
D (ljl)	报告 PDF、排版	将对照表写入方法与结果；控制 4 – 6 页；撰写 AI 使用声明

六、三条必须统一的统计规范

- 分析单位：主分析用站点 – 日日均数据；不用小时数据直接做 t 检验（小时强相关会夸大显著性）。
- 变换：推断与回归优先使用 log(PM2.5+1)；正文说明原始浓度右偏、重尾。
- 表述：相关与回归只说明关联，不写「风速导致 PM2.5 下降」式因果句；局限中写明站点非随机布设、时间自相关等。

七、数据与仓库提醒

- 只使用 data/.../PRSA_Data_*.csv（12 个站点）；勿用同目录 data.csv、test.csv（股票样例）。
- 时间范围即 2013-03-01~2017-02-28；文件夹名含 2017 不代表有更晚年份。
- 使用 AI 须在最终报告中单独一节声明（模板见 reference/大作业安排.pdf）。

八、一句话总结

用北京 PM2.5 真实数据，把讲义第 6 – 10 章的估计、检验、回归完整走一遍，并用第 3 – 4 章描述分布与相关，用 Bootstrap 体现拓展与动手实践——这就是本课题与课程的结合方式。

更细的时间表与图表清单见 reports/项目计划书.pdf（若已生成）。文档版本：2026-05-26；分工或选题调整请在组内同步并更新 Markdown 源文件后重新生成 PDF。