

北京多站点 PM2.5 浓度的统计推断

分布特征、季节/站点差异与气象因素影响分析

《概率与数理统计》课程大作业项目计划书

数据来源：UCI Beijing Multi-Site Air Quality Data

计划日期：2026 年 5 月 26 日

建议提交形态：PDF 报告 + 可复现代码 + 原始/处理数据说明

本计划书用于确定研究问题、统计方法、数据处理标准、代码组织和项目进度。后续报告应在此基础上压缩为 4-6 页的正式课程报告，并附带可复现实验材料。

一、项目基本介绍

本项目拟以北京市 12 个空气质量监测站在 2013 年 3 月 1 日至 2017 年 2 月 28 日的小时级空气质量与气象数据为研究对象，围绕 PM2.5 浓度的分布特征、季节差异、站点差异与气象因素影响展开统计推断。相比单纯绘图或套用复杂预测模型，本项目强调课程知识的完整落地：从数据清洗、统计量描述、分布建模、区间估计、假设检验到回归建模，形成一条可解释、可复现、能回应现实问题的分析链。

推荐题目：北京多站点 PM2.5 浓度的统计推断：分布特征、季节/站点差异与气象因素影响分析。

选题价值

- 现实意义明确：PM2.5 是评价空气污染和健康风险的重要指标，分析其变化规律有助于理解污染暴露、季节性污染和气象扩散条件。
- 数据质量较高：UCI 数据集包含 12 个站点、420,768 条小时记录，字段覆盖 PM2.5、PM10、SO2、NO2、CO、O3、温度、气压、露点、降水、风向和风速等变量。
- 课程贴合度高：可以系统运用描述统计、随机变量分布、相关系数、参数估计、置信区间、假设检验、一元/多元线性回归等课内内容。
- 拓展空间可控：在主线之外可加入 bootstrap 置信区间、稳健回归或 logistic 回归作为自主学习内容，但不追求方法堆叠。

项目定位

本项目不以“预测比赛”为核心，而以“统计推断”为核心：先提出关于 PM2.5 分布、差异与影响因素的统计问题，再用恰当模型和检验方法给出证据，并讨论结论的限制。这样更符合课程大作业对“问题提出、概率模型建立、方法介绍、数据分析结果与讨论、参考文献”的要求。

二、研究问题与预期结论

研究问题	统计表达	拟采用方法	预期产出
PM2.5 的总体分布形态如何？	PM2.5 是否强右偏、重尾？ $\log(\text{PM2.5}+1)$ 后是否更接近正态？	直方图、核密度图、QQ 图、偏度/峰度、候选分布拟合	说明原始浓度不宜直接套用正态模型，并为后续变换建模提供依据
季节之间是否存在显著差异？	春、夏、秋、冬的日均 PM2.5 均值或中位数是否相同？	置信区间、单因素 ANOVA、Kruskal-Wallis 稳健性检验	量化冬季污染更高、夏季较低等季节性规律
不同站点是否存在空间差异？	12 个站点的 PM2.5 水平是否相同，城区与郊区是否不同？	分组箱线图、方差分析、非参数检验、效应量比较	识别污染水平较高与较低的典型站点，讨论城市功能区差异
气象因素如何影响 PM2.5？	风速、降水、温度、气压、露点、风向等变量与 PM2.5 的关系如何？	相关分析、多元线性回归、虚拟变量、残差诊断	建立可解释模型，判断风速、季节、站点等因素的方向和显著性
重污染风险能否被简单建模？	日均 PM2.5 是否超过阈值，如 75 或 150 微克/立方米？	比例估计、置信区间、可选 logistic 回归	给出不同季节/站点的重污染概率估计，作为拓展结果

初步数据体检显示，PM2.5 缺失约 2.08%，整体均值约 79.79，中位数约 55，95% 分位数约 242，最大值达 999，呈明显右偏和重尾特征；冬季均值约 95.48，夏季约 64.67，季节差异具有清晰的分析价值。

三、数据来源与预处理方案

原始数据来自 UCI Machine Learning Repository 的 Beijing Multi-Site Air Quality Data。项目文件夹中真正用于分析的是 data/beijing+multi+site+air+quality+data/PRSA2017_Data_20130301-20170228/PRSA_Data_20130301-20170228 下的 12 个站点 CSV 文件；顶层的 data.csv、test.csv 为股票价格样例数据，不属于本项目，应在 README 中明确排除。

处理环节	具体做法	理由
时间字段构造	将 year、month、day、hour 合成为 datetime，并检查每站是否覆盖完整小时序列	保证时间索引正确，为日均聚合和季节划分打基础
缺失值处理	对 PM2.5 和气象变量统计缺失比例；小时级缺失可使用站点内时间插值，日均聚合要求一天至少 18 个有效小时	避免少量缺失破坏分析，同时防止用信息不足的日期构造日均值
分析单位选择	主分析使用“站点-日期”的日均 PM2.5；小时级数据用于补充展示日变化	小时记录存在强自相关，直接当作独立样本会夸大显著性
异常值处理	不随意删除高浓度值；仅对明显不可能值做标记，并在分布分析中保留重污染尾部	高值本身是污染研究的重要对象，不能简单视为噪声
变量构造	构造 season、year、month、weekday、是否重污染、风向类别等变量	便于进行分组比较、回归建模和结果解释

数据预处理脚本应做到可复现：输入原始 CSV，输出统一的 processed_daily.csv 和 processed_hourly.csv；所有图表和统计结论都应由处理后数据自动生成。

四、统计模型与方法路线

本项目方法路线按照“描述 - 推断 - 建模 - 验证”的顺序展开。报告中每一种方法都应解释它回答的具体问题，避免只罗列方法名称。

1. 描述统计与分布建模

- 计算 PM2.5 的均值、中位数、标准差、四分位数、偏度、峰度和主要分位点。
- 绘制 PM2.5 原始值与 log(PM2.5+1) 的直方图、密度图和 QQ 图，比较其正态性。
- 可选比较对数正态、Gamma 等候选分布，但重点放在解释“为什么直接正态假设不合适”。

2. 区间估计与假设检验

- 估计总体日均 PM2.5 的均值置信区间，以及不同季节、不同站点的均值置信区间。
- 检验季节均值是否相同、站点均值是否相同；同时报告 p 值和效应大小，避免只说“显著”。
- 由于 PM2.5 分布右偏，可将 ANOVA 与非参数检验结合，作为结论稳健性的说明。

3. 相关分析与回归建模

- 先计算 PM2.5 与气象变量的 Pearson/Spearman 相关系数，观察方向和强度。

- 建立以 $\log(\text{PM}_{2.5}+1)$ 为因变量的多元线性回归模型，解释变量包括风速、温度、气压、露点、降水、季节和站点虚拟变量。
- 检查残差图、异方差、共线性和异常点，说明模型适用范围。
- 拓展模型可将“是否重污染日”作为二分类变量，使用 logistic 回归估计重污染概率。

4. 自主学习与仿真部分

为满足作业对动手实践和课程拓展的要求，建议加入 bootstrap 置信区间：对日均数据按站点-日期重抽样，估计季节均值差或重污染概率差的 bootstrap 置信区间，并与传统置信区间进行比较。该部分既有实际意义，又不会使项目偏离主线。

五、代码组织与可复现要求

优秀作业不只是报告漂亮，还应让助教能够根据提交材料复现全部结果。建议将项目按成熟 GitHub 项目的习惯组织。

路径	内容	说明
README.md	项目简介、数据来源、复现命令、主要结论、AI 使用说明	作为项目入口，优先保证清晰可读
data/raw/	原始 UCI CSV 数据	保持原样，不在代码中覆盖
data/processed/	清洗后的 hourly/daily 数据	由脚本生成，可被复现
src/load_data.py	读取、合并、校验 12 个站点数据	包含字段检查和时间范围检查
src/preprocess.py	缺失处理、日均聚合、变量构造	输出可分析数据表
src/eda.py	描述统计和分布图	生成报告中的基础图表
src/inference.py	置信区间、假设检验、bootstrap	对应课程统计推断内容
src/regression.py	相关分析、回归模型、诊断图	生成模型结果表和残差图
reports/figures/	报告使用的图片	由脚本自动输出，文件名规范
reports/report.pdf	最终报告	建议 4-6 页，附参考文献和 AI 声明

基本代码规范：函数命名清晰，避免在 notebook 中堆叠不可复现的临时代码；随机过程如 bootstrap 需固定随机种子；所有统计结果尽量由脚本生成并保存为 CSV/PNG，减少手工复制错误。

六、项目安排与分工建议

课程提交截止日期为 2026 年 6 月 21 日。建议在期末考试前完成主体分析，最后一周只做报告润色、复现检查和压缩包整理。若小组为 3-4 人，可按“数据与代码、统计推断、建模可视化、报告整合”分工。

阶段	时间建议	主要任务	阶段产出
阶段 1：定题与数据核验	5 月 26 日 - 5 月 29 日	确认研究问题；核对数据范围、字段、缺失比例；排除无关 data.csv/test.csv	数据体检记录、项目计划书、README 初稿

阶段	时间建议	主要任务	阶段产出
阶段2：预处理与EDA	5月30日-6月3日	完成数据合并、缺失处理、日均聚合；绘制分布、季节、站点差异图	processed 数据、EDA 图表、描述统计表
阶段3：统计推断	6月4日-6月8日	完成置信区间、假设检验、bootstrap；比较季节和站点差异	推断结果表、检验结论、方法说明草稿
阶段4：回归与拓展	6月9日-6月13日	完成相关分析、多元回归、残差诊断；可选 logistic 回归	模型结果表、诊断图、可解释结论
阶段5：报告与复现	6月14日-6月18日	撰写 4-6 页 PDF 报告；整理参考文献、AI 声明、复现命令	报告初稿、完整代码、README
阶段6：终检与提交	6月19日-6月21日	从零运行代码；检查图片、页码、压缩包结构；邮件提交	最终 PDF、ZIP 压缩包、提交邮件

分工建议

- 成员 A：负责数据读取、清洗、缺失处理和项目目录规范。
- 成员 B：负责描述统计、分布分析、置信区间和假设检验。
- 成员 C：负责相关分析、回归建模、模型诊断和图表美化。
- 成员 D：负责 README、报告整合、参考文献、AI 使用声明和最终复现检查。若小组人数不足，可合并相邻角色。

七、报告结构建议

正式报告建议控制在 4-6 页，附录或代码文件承担更多细节。报告不应把所有图表都堆进去，而应选择最能支撑结论的图表。

章节	建议篇幅	核心内容
1. 问题提出	约 0.5 页	说明 PM2.5 研究意义、数据背景和本文要回答的统计问题
2. 数据来源与预处理	约 0.75 页	介绍 UCI 数据、站点、时间范围、变量、缺失处理和日均聚合策略
3. 方法介绍	约 1 页	说明分布分析、置信区间、假设检验、回归和 bootstrap 的统计思想
4. 结果与讨论	约 2-3 页	展示关键图表和表格，回答分布、季节、站点和气象因素问题
5. 结论与局限	约 0.5 页	总结主要发现，说明相关不等于因果、时间相关性、站点覆盖等限制
6. AI 使用声明与参考文献	约 0.5 页	按课程要求列明 AI 工具贡献，并列出数据和方法参考来源

建议主图表

- PM2.5 原始分布与 log 变换分布对比图。
- 按季节划分的日均 PM2.5 箱线图或小提琴图。
- 12 个站点日均 PM2.5 均值与置信区间图。
- 气象变量与 PM2.5 的相关热力图或回归系数图。

- 模型残差诊断图或重污染概率结果图。

八、质量标准与风险控制

质量维度	优秀标准	风险与应对
问题意识	每个统计方法都对应一个明确问题，结论能回到空气污染机制或规律	避免方法堆叠；报告中删去不能支撑结论的分析
统计严谨性	说明样本单位、缺失处理、模型假设、p值和置信区间含义	小时数据相关性强；主分析改用日均站点数据
可解释性	优先使用可解释模型，报告方向、大小和不确定性	不将相关关系表述为因果关系
代码质量	目录清楚、函数封装、固定随机种子、输出可复现	避免只交 notebook；关键流程脚本化
报告呈现	图表简洁，正文围绕核心结论，AI 声明和参考文献完整	避免图太多、文字太散；最终统一图表风格

最终交付清单

- 正式报告 PDF：建议命名为 report.pdf。
- 完整代码：包含数据预处理、分析、绘图和结果生成脚本。
- 原始数据或数据来源说明：保留 UCI 原始 CSV，并说明顶层无关 CSV 不参与分析。
- README.md：包含项目介绍、复现命令、环境依赖、主要结果和 AI 使用说明。
- 参考文献列表：至少包含 UCI 数据集页面、PM2.5 健康/环境背景资料、统计方法资料。

总体判断：该选题具备成为优秀作业的潜力。成功关键不是加入更多复杂模型，而是围绕 PM2.5 的分布、差异与影响因素形成清晰主线，并保证分析严谨、代码整洁、结果可复现。